Bài toán học máy

Đọc đề và nộp mô hình đầu tiên.

> Câu lạc bộ lập trình phải đặt ghế cho buổi sinh hoạt thứ Bảy. Đặt thiếu thì người đến sau không có chỗ; đặt quá nhiều thì phòng chật. Chiều thứ Sáu, ta biết số người đã đăng ký và dự báo khả năng mưa. Ta chưa biết số người thực sự đến. Có thể dùng những buổi trước để dự đoán con số ấy không?

Đó là câu hỏi xuyên suốt bài này. Ta sẽ viết một baseline: phương án đơn giản, chạy được và cho một mốc so sánh. Trước khi học mô hình phức tạp, cần xác định một hàng dữ liệu đại diện cho gì, thông tin nào được phép dùng và kết quả sẽ được chấm thế nào.

SAU BÀI NÀY, CÓ THỂ

- Viết rõ input, output, thời điểm dự đoán và metric của một bài.
- Phân biệt classification, regression và học không giám sát qua đầu ra cần tạo.
- Dựng baseline scikit-learn, so với phương án đoán hằng số và đọc sai số.
- Tạo bảng dự đoán có ID đúng thứ tự, kiểm shape và định dạng trước khi nộp.

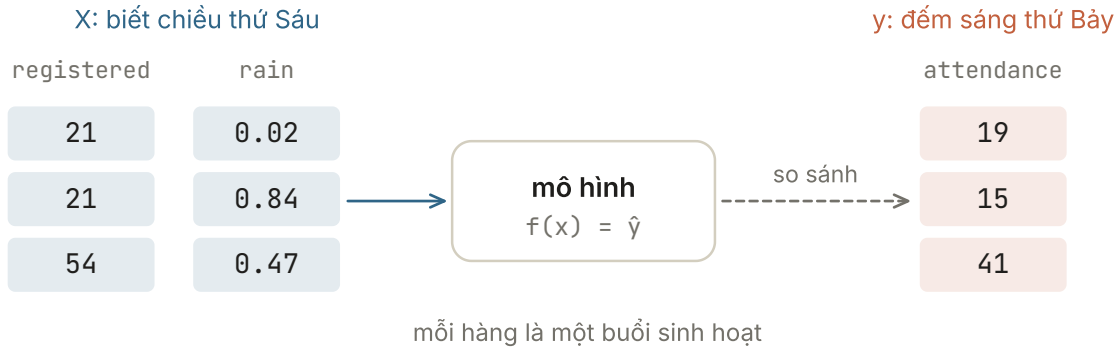
Từ câu chuyện đến một hàng dữ liệu

Ta quy ước mỗi hàng là **một buổi sinh hoạt**, không phải một học sinh. Đặc trưng (feature) là thông tin dùng để dự đoán; nhãn hay mục tiêu (target) là giá trị cần đoán. Bảng có thể chứa cả hai lúc huấn luyện, nhưng lúc sử dụng mô hình thì chỉ có đặc trưng.

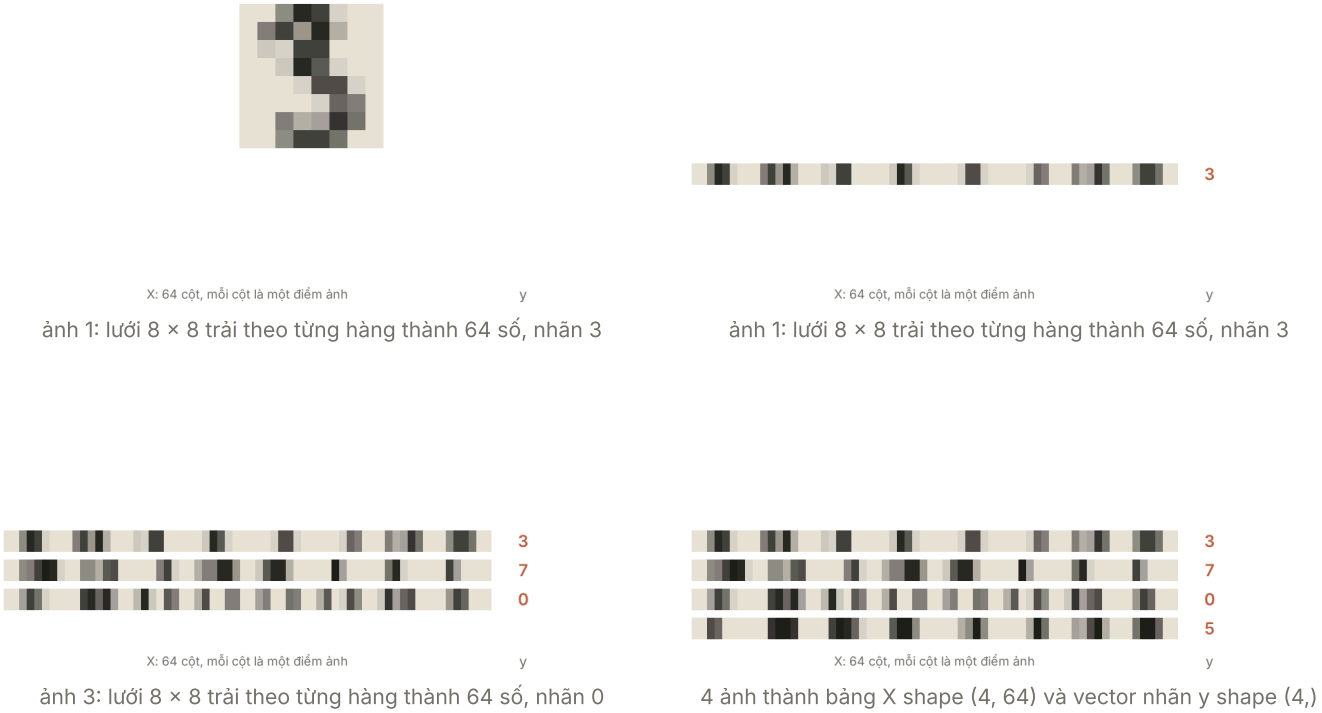
Cột	Ý nghĩa	Biết chiều thứ Sáu?	Dùng làm gì?
`session_id`	Mã buổi sinh hoạt	Có	Ghép kết quả với đúng buổi
`registered`	Số người đã đăng ký	Có	Feature
`rain_forecast`	Xác suất mưa được dự báo lúc chốt đăng ký	Có	Feature

Cột	Ý nghĩa	Biết chiều thứ Sáu?	Dùng làm gì?
`attendance`	Số người thực sự đến	Không	Target

Không đưa `attendance` vào input. Cũng không thay `rain_forecast` bằng lượng mưa đo được sau buổi sinh hoạt: tên cột khác nhau chỉ một chút, nhưng thời điểm biết thông tin đã đổi. Bài 1.4 gọi những đường tắt như vậy là data leakage.



Từ thông tin chiều thứ Sáu, mô hình đoán số người đến; nhãn chỉ có sau buổi.



Ảnh chữ số viết tay thật 8 × 8 trải thành một hàng 64 số: mỗi ảnh là một hàng của X, chữ số đúng là giá trị y.

Hãy luôn viết một câu hợp đồng trước code: "Với mỗi buổi, từ dữ liệu có sẵn chiều thứ Sáu, dự đoán số người đến vào thứ Bảy; sai số đo bằng số người." Câu này quyết định cách chọn cột, cách chia dữ liệu và cách đọc kết quả.

HỎI NHANH

Câu lạc bộ muốn chạy mô hình vào chiều thứ Sáu để đoán số người đến buổi sáng thứ Bảy. Cột nào **không** được dùng làm feature?

A Số người đăng ký tính đến chiều thứ Sáu

B Số buổi câu lạc bộ đã tổ chức từ đầu học kỳ

C Dự báo mưa lưu lúc chiều thứ Sáu

D Số người quét mã vào cửa sáng thứ Bảy

Đầu ra quyết định loại bài toán

Nếu hỏi "có ít nhất 30 người đến hay không?", output là một nhãn trong hai lớp: đây là classification (phân loại). Nếu hỏi "có bao nhiêu người đến?", output là một số: đây là regression (hồi quy). Số người là số nguyên, nhưng regression vẫn có thể dự đoán số thực như 28.4, hiểu là mức ước lượng. Có làm tròn hay không phải theo metric và quy định đầu ra.

Trong supervised learning (học có giám sát), mô hình học từ cặp $(\mathbf{x}_i, y_i)$: đặc trưng và nhãn của mẫu thứ i. Trong unsupervised learning (học không giám sát), ta chưa có nhãn mục tiêu; ví dụ chia các buổi thành nhóm theo kiểu hoạt động. Clustering không tự cho biết nhóm nào "tốt", vì đó chưa phải câu hỏi mà dữ liệu trả lời.

Ở đây chọn regression. Mô hình là một hàm f nhận đặc trưng và trả dự đoán $\hat{y} = f(\mathbf{x})$. Huấn luyện là dùng những cặp cũ để chọn hàm đó. Dự đoán (inference) là áp dụng hàm đã chọn lên đặc trưng mới. Cùng một đoạn `predict` phải chạy được khi không có nhãn.



Loại bài toán do đầu ra quyết định: một nhãn, một số, hay chưa có nhãn.

HỎI NHANH

Input là ảnh chụp một bài giải. Output là một trong ba nhãn “đúng”, “sai”, “chưa đủ bước”. Đây là loại bài toán nào?

A Regression, vì nhãn mã hóa được thành 0, 1, 2

B Classification có giám sát, với ba lớp

C Clustering, vì cần chia bài giải thành ba nhóm

D Classification nhị phân, đúng hoặc không đúng

Tạo một bộ dữ liệu có thể kiểm chứng

Ta tự sinh 120 buổi. Công thức giả định rằng số đến tăng theo đăng ký, giảm theo dự báo mưa, cộng thêm nhiễu do những yếu tố không ghi lại. Vì tự sinh nên ta biết quy luật thật, và có thể đối chiếu xem mô hình học được bao nhiêu phần của nó.

Python

```
import numpy as np
import pandas as pd

rng = np.random.default_rng(11)
n = 120
registered = rng.integers(15, 65, size=n)
```

```
rain_forecast = rng.uniform(0, 1, size=n)
attendance = np.rint(
    4 + 0.75 * registered - 7 * rain_forecast
    + rng.normal(0, 2, size=n)
).clip(0)
data = pd.DataFrame({
    "session_id": np.arange(n),
    "registered": registered,
    "rain_forecast": rain_forecast,
    "attendance": attendance,
})
X = data[["registered", "rain_forecast"]]
y = data["attendance"]
print(X.shape, y.shape)
print(data.head(3).round(2).to_string(index=False))
```

KẾT QUẢ

```
(120, 2) (120,)
 session_id  registered  rain_forecast  attendance
          0          21           0.02        19.0
          1          21           0.84        15.0
          2          54           0.47        41.0
```

Nhìn shape trước: `X` có 120 hàng, hai cột; `y` có 120 phần tử. `data[[...]]` chọn một bảng hai chiều; `data["attendance"]` chọn một vector nhãn. Mã buổi vẫn nằm trong `data`, nhưng không xuất hiện trong `X`. Không có lý do chung nào để số thứ tự tự nó dự đoán số người đến.

HỎI NHANH

`session_id` chạy từ 0 đến 119 theo thứ tự thời gian. Vì sao không đưa cột này vào `X`?

A ID chỉ là mã để ghép kết quả, buổi mới sẽ có ID chưa từng thấy

B Đưa vào cũng không sao, mô hình tự bỏ qua cột vô dụng

C Nên đưa vào, miễn là chuẩn hóa trước cho cùng thang

D Phải đưa vào để dự đoán giữ đúng thứ tự các buổi

Đại lượng	Shape	Một phần tử nói gì?
X	`(120, 2)`	Hai feature của một buổi
$\mathbf{y}$	`(120,)`	Số người đến
$\hat{\mathbf{y}}$	`(số_buổi_cần_đoán,)`	Một dự đoán cho mỗi buổi

Ba phần dữ liệu, ba công việc

Ta giả định các hàng đang xếp theo thứ tự buổi. Dùng 80 buổi đầu để học (train), 20 buổi sau để so sánh phương án (validation), 20 buổi cuối để báo cáo cuối (test). Tỉ lệ này chỉ phục vụ ví dụ; dữ liệu thật còn phụ thuộc số mẫu, nhóm và thời gian.



Chia theo thứ tự buổi: học trên quá khứ, chọn và chấm trên các buổi sau.

Test có nhãn trong bài để ta mô phỏng phép đánh giá. Trong cuộc thi, nhãn test thường không được cung cấp; tập dùng để xuất bài nộp cũng hay được gọi là `test`. Cần phân biệt tập đánh giá độc lập có nhãn được giữ riêng với tập dự đoán không có nhãn của đề.

Python

```
train_rows = np.arange(0, 80)
valid_rows = np.arange(80, 100)
test_rows = np.arange(100, 120)
X_train, y_train = X.iloc[train_rows], y.iloc[train_rows]
X_valid, y_valid = X.iloc[valid_rows], y.iloc[valid_rows]
X_test, y_test = X.iloc[test_rows], y.iloc[test_rows]
print(len(train_rows), len(valid_rows), len(test_rows))
print(len(set(train_rows) & set(test_rows)))
```

KẾT QUẢ

```
80 20 20
0
```

Dòng cuối phải bằng 0: không có hàng nào vừa học vừa chấm test. Đó là điều kiện cần nhưng chưa đủ: nếu một buổi bị ghi thành hai hàng, hay nhiều hàng cùng thuộc một nhóm gắn bó (cùng trường, cùng người), còn phải chia theo nhóm, bài 1.3 sẽ làm.

HỎI NHANH

Có hai mô hình, ta cần chọn một. Ta so điểm của chúng trên tập nào?

A Validation

B Train, vì mô hình đã học trên đó

C Test, tập đã giữ riêng từ đầu

D Gộp train và test lại

Baseline và một thước đo đọc được

Ta dùng mean absolute error (MAE): trung bình trị tuyệt đối của các sai số. Với m mẫu đang chấm,

$$\text{MAE} = \frac{1}{m}\sum_{i=1}^{m} |\hat{y}_i - y_i|.$$

MAE bằng 2 nghĩa là trung bình độ lệch có độ lớn hai người; không có nghĩa mọi buổi đều sai đúng hai người. Số càng nhỏ càng tốt. Bài 1.6 sẽ so với những metric khác.

Baseline hằng số dùng `DummyRegressor(strategy="mean")`: dự đoán mọi buổi bằng trung bình **train**. Phương án thứ hai là `LinearRegression`, cộng các đóng góp của hai feature. Ta chưa cần tự cài thuật toán tìm hệ số; bài 2.1 sẽ giải thích cách học nó.

Python

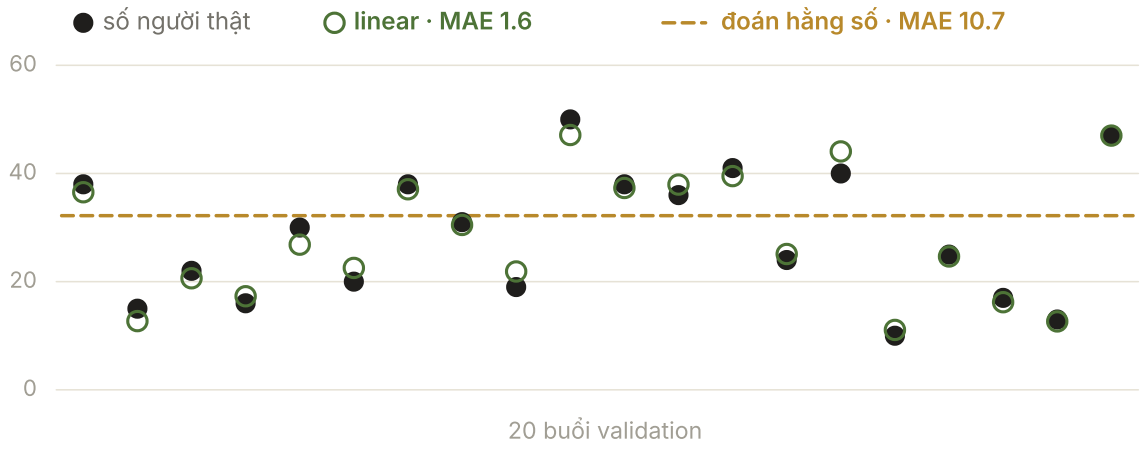
```python
from sklearn.dummy import DummyRegressor
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error

models = {
    "mean": DummyRegressor(strategy="mean"),
    "linear": LinearRegression(),
}
valid_mae = {}
for name, model in models.items():
    model.fit(X_train, y_train)             # chỉ học từ train
    prediction = model.predict(X_valid)
    assert prediction.shape == y_valid.shape
    valid_mae[name] = mean_absolute_error(y_valid, prediction)
    print(name, f"valid MAE = {valid_mae[name]:.3f}")
chosen_name = min(valid_mae, key=valid_mae.get)
print("Chọn bằng validation:", chosen_name)
```

KẾT QUẢ

```
mean valid MAE = 10.740
linear valid MAE = 1.561
Chọn bằng validation: linear
```

So hai dòng `valid MAE` trên cùng 20 buổi: đoán hằng số sai trung bình gần 11 người, linear chỉ sai khoảng 1.6 người. Số đăng ký và dự báo mưa mang gần hết thông tin cần thiết, đúng như công thức sinh dữ liệu. Baseline hằng số còn một vai trò nữa: nó là mốc tối thiểu để phát hiện lỗi.



Trên 20 buổi validation: đường hằng số lệch xa, linear bám sát số người thật.

HỎI NHANH

Trên cùng 20 buổi validation, một mô hình mới có MAE 11.5 người, còn baseline đoán hằng số có MAE 10.74. Ta nên làm gì tiếp?

A Giữ mô hình mới, vì nó dùng nhiều thông tin hơn

B Bỏ baseline đi, vì đoán hằng số không phải mô hình

C Tìm lỗi trong dữ liệu hoặc trong cách tính điểm

D Tính thêm điểm trên test để có thêm ý kiến

Ta chốt lựa chọn, học lại trên train cộng validation rồi chấm test đúng một lần. Sau khi đã xem test, mọi chỉnh sửa tiếp theo đều biến nó thành một tập validation khác.

Python

```
final_model = models[chosen_name]
final_model.fit(X.iloc[:100], y.iloc[:100])
test_prediction = final_model.predict(X_test)
print(f"Test MAE = {mean_absolute_error(y_test, test_prediction):.3f}")
```

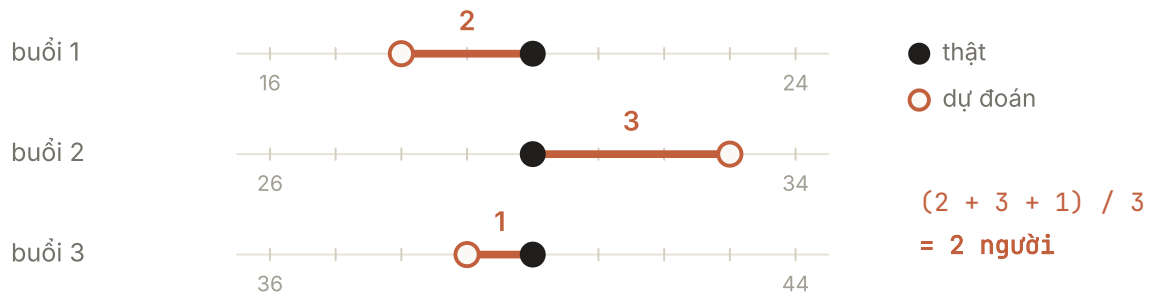
KẾT QUẢ

```
Test MAE = 1.317
```

Đọc theo đơn vị "người" để trả lời câu hỏi đặt ghế: dự đoán lệch trung bình chừng một, hai người, nên đặt thêm vài ghế dự phòng là đủ; MAE là trung bình nên có buổi vẫn lệch nhiều hơn. Con số này đo trên 20 buổi nên còn dao động, và nó chỉ đúng chừng nào câu lạc bộ còn giống những buổi đã thấy; nếu quy mô đột ngột đổi, mô hình phải học lại.

Ví dụ tính tay và kiểm bảng kết quả

Ba buổi có số người thật $(20, 30, 40)$, dự đoán $(18, 33, 39)$. Sai số là $(-2, 3, -1)$; MAE $= (2 + 3 + 1)/3 = 2$ người. Trung bình sai số có dấu bằng 0, nhưng dự đoán vẫn sai. Trị tuyệt đối chặn việc sai cao và sai thấp triệt tiêu nhau.



MAE là trung bình độ dài các đoạn sai số, tính theo đơn vị người.

Giả sử đề yêu cầu CSV gồm `session_id,attendance`. Ta tạo bảng trong bộ nhớ, giữ ID theo thứ tự input, và đọc lại bằng pandas như một phép kiểm vòng kín.

Python

```python
from io import StringIO

submission = pd.DataFrame({
    "session_id": data.iloc[test_rows]["session_id"].to_numpy(),
    "attendance": test_prediction,
})
csv_text = submission.to_csv(index=False)
read_back = pd.read_csv(StringIO(csv_text))
assert list(read_back.columns) == ["session_id", "attendance"]
assert read_back["session_id"].is_unique
assert np.isfinite(read_back["attendance"]).all()
assert read_back["session_id"].tolist() == list(test_rows)
print(read_back.head(3).round(2).to_string(index=False))
print("Số hàng:", len(read_back))
```

KẾT QUẢ

```
 session_id  attendance
        100       16.19
        101       26.21
        102       42.31
Số hàng: 20
```

`index=False` tránh thêm một cột số thứ tự ngoài ý muốn. Với đề thật, tên cột và định dạng lấy đúng theo đề; các `assert` trên là danh sách kiểm cần sửa theo.

HỎI NHANH

Một bạn sắp xếp cột dự đoán từ nhỏ đến lớn nhưng để nguyên cột ID. File nộp còn đúng không?

A Đúng, vì số hàng và số cột vẫn khớp với đề

B Đúng, vì MAE không phụ thuộc thứ tự hàng

C Sai, vì phải sắp theo ID tăng dần

D Sai, vì dự đoán đã bị ghép nhầm sang mẫu khác

Bẫy cài đặt

`model.score` không luôn trả metric đề cần: với regression thường là R^2, còn với classifier thường là accuracy. Trong ví dụ ta gọi `mean_absolute_error` tường minh. Hai metric có thể xếp hạng phương án khác nhau.

Nếu đọc nhãn bằng `data[["attendance"]]`, shape sẽ là `(n,1)`; khi tự trừ với dự đoán `(n,)`, NumPy có thể tạo ma trận `(n,n)`. Hãy giữ nhãn một chiều và kiểm shape. Không đưa ID vào mô hình chỉ vì nó là số; trước hết hỏi mã đó có ý nghĩa ở thời điểm sử dụng không.

Khi đi thi

- **Viết hợp đồng trước code:** đơn vị mẫu, nhãn, metric, cột output, thứ tự ID, thời điểm dự đoán.
- **Nộp một baseline sớm:** đoán hằng số hay trung bình nhóm, để kiểm cả đường đi tới file nộp lẫn có mốc so sánh.
- **Chấm đúng metric của đề:** gọi hàm metric tường minh; nếu đề có scorer local, đối chiếu cùng một bảng dự đoán với scorer đó.

- **Đọc quy định môi trường** (Internet, dữ liệu ngoài, GPU) từ thông báo của chính cuộc thi.

Tóm tắt

- Bài học máy bắt đầu bằng đơn vị mẫu, thời điểm dự đoán, input và output.
- Train học; validation chọn; test độc lập báo cáo sau khi chốt.
- Baseline chỉ có giá trị khi chấm đúng metric trên cùng dữ liệu.
- Bảng dự đoán cần đúng cả shape, giá trị và quan hệ với ID.

Kiểm tra cuối bài

CÂU 1

Một bảng có 12 trường, mỗi trường ghi lại 8 buổi sinh hoạt. Ta cần đoán số người đến từng buổi. Mỗi mẫu là gì, và target của nó là gì?

A Mỗi mẫu là một cột, target là tổng của cột ấy

B Mỗi mẫu là một buổi, target là số người thực sự đến buổi ấy

C Mỗi mẫu là một trường, target là số người đến trung bình qua 8 buổi

D Mỗi mẫu là một người, target là số buổi người ấy tham gia

CÂU 2

Đề yêu cầu đoán số người đến từng buổi và chấm bằng MAE. Một bạn trong nhóm đổi sang bài phân loại "đông" (từ 30 người trở lên) hay "vắng" cho dễ huấn luyện. Làm vậy sai ở đâu?

A Không sai, vì phân loại thường chính xác hơn hồi quy

B Đầu ra không còn là thứ đề chấm bằng MAE

C Phân loại cần nhiều dữ liệu hơn nên không chạy được

D Nhãn "đông" hay "vắng" để lộ thông tin của buổi

CÂU 3

Bảng chỉ có feature của từng buổi, không có cột nhãn. Ta muốn gom các buổi giống nhau thành từng nhóm. Đây là loại bài toán nào?

A Học không giám sát, chẳng hạn clustering

B Học có giám sát, vì feature đã là số

C Classification có giám sát

D Regression có giám sát

PHỎNG THEO USA-NA-AIO 2026 · Vòng 1 · Part 1.1

CÂU 4

Một mô hình được huấn luyện và kiểm trên dữ liệu năm 2023: đúng 99.8% trên train, 92% trên validation. Đem dùng cho dữ liệu năm 2025 thì chỉ còn đúng 64%. Vấn đề chính nằm ở đâu?

A Dữ liệu năm 2025 đã khác dữ liệu năm 2023

B Validation cùng năm với train nên con số 92% là ảo

C Dữ liệu năm 2025 bị gán nhãn sai nên điểm thấp giả tạo

D Mô hình quá yếu, dù đúng tới 99.8% trên train

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 286

CÂU 5

Hai mẫu có nhãn thật là 10 và 20. Mô hình đoán 13 và 19. MAE bằng bao nhiêu?

A 1

B 4

C 5

D 2

CÂU 6

Baseline `DummyRegressor(strategy="mean")` đoán mọi buổi bằng một số trung bình. Số trung bình ấy phải tính trên tập nào?

A Validation

B Test

C Train

D Cả ba tập

CÂU 7

Đề chấm bằng MAE. Trên cùng tập validation, mô hình A có MAE 3 và sai số lớn nhất là 7. Mô hình B có MAE 4 và sai số lớn nhất là 5. Ta chọn mô hình nào?

A A, vì tổng hai con số của A nhỏ hơn

B A, vì MAE thấp hơn

C B, vì sai số lớn nhất nhỏ hơn

D B, vì hai con số của B gần nhau hơn

CÂU 8

Validation chỉ gồm các trường đã có trong train. Trên đó, baseline có MAE 8, còn linear có MAE 2. Ta muốn dùng mô hình cho trường mới. Nên làm thí nghiệm nào tiếp theo?

A Chia ngẫu nhiên thêm nhiều lần, lấy lần có điểm tốt nhất

B Học lại linear trên cả validation rồi tính MAE ngay trên đó

C Giữ cách chia cũ, chỉ làm tròn MAE cho gọn

D Để riêng toàn bộ vài trường ra, rồi so lại hai mô hình

CÂU 9

Một đội thử vài mô hình, chọn mô hình có điểm test cao nhất, rồi báo điểm test ấy là đánh giá độc lập. Làm vậy có đúng không?

A Đúng, vì test không dùng trong `fit`

B Đúng, nếu chỉ thử hai mô hình

C Sai, vì test đã được dùng để chọn

D Đúng, nếu điểm test cao hơn validation

CÂU 10

Ghi file nộp bằng pandas. Viết thế nào để file không có thêm cột index?

A `to_csv(index=True)`

B `sort_values("attendance")`

C `reset_index()` rồi xuất mọi cột

D `to_csv(index=False)`

Đọc thêm

- James, Witten, Hastie, Tibshirani và Taylor — An Introduction to Statistical Learning, chương 2. Đọc để phân biệt dự đoán, suy luận và các loại bài toán học thống kê.
- scikit-learn — DummyRegressor. Xem các baseline hằng số và ý nghĩa của `strategy`.
- scikit-learn — Metrics and scoring. Tra đúng hàm metric thay vì mặc định dùng `model.score`.

Nguồn ảnh: ảnh chữ số lấy từ bộ `load_digits` của scikit-learn (UCI, CC BY 4.0).