Clustering

Chia nhóm dữ liệu khi không có nhãn.

> Câu lạc bộ có nhiều hồ sơ học tập nhưng chưa biết nên chia thành mấy nhóm. Ta muốn xem những học sinh có kiểu học giống nhau có tự tụ lại hay không, trước khi con người đặt tên cho nhóm. Clustering không có nhãn đúng để bắt chước. Vì vậy bài này không chỉ học lệnh `fit_predict`: ta phải nói rõ thế nào là gần, thế nào là một cụm, và tại sao hai thuật toán có thể cho hai câu trả lời đều hợp lý.

MỤC TIÊU SAU BÀI NÀY

- Tính một vòng gán/cập nhật K-Means và inertia.
- Phân biệt core, border, noise của DBSCAN.
- Đọc số cụm, metric và ảnh hưởng thang đo mà không tự gọi cụm là nhãn thật.

K-Means

Giả định: có K cụm, mỗi cụm là một "đám" tròn quanh một tâm. K-Means tìm K tâm $\boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_K$ cực tiểu tổng bình phương khoảng cách từ mỗi điểm đến tâm gần nhất (inertia):

$$J = \sum_{i=1}^{n} \min_{k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2.$$

Thuật toán Lloyd lặp hai bước đến khi không đổi:

1. **Gán**: mỗi điểm thuộc cụm có tâm gần nhất.
2. **Cập nhật**: mỗi tâm dời về trung bình các điểm của cụm.

Mỗi bước đều không làm J tăng, và số cách chia là hữu hạn, nên thuật toán chắc chắn dừng. Nhưng nó chỉ dừng ở một **cực tiểu địa phương**: khởi tạo khác cho kết quả khác. Khởi tạo k-means++ chọn tâm đầu tiên ngẫu nhiên, rồi chọn mỗi tâm tiếp theo với xác

suất tỉ lệ với bình phương khoảng cách từ điểm đến tâm gần nhất đã có, nên các tâm ban đầu thường nằm xa nhau. Thư viện còn chạy nhiều lần (`n_init`) và giữ kết quả có J nhỏ nhất.

HỎI NHANH

Có ba điểm trên trục số: 0, 1 và 10. k-means++ đã chọn tâm đầu tiên là 0. Xác suất điểm 10 được chọn làm tâm thứ hai là bao nhiêu?

A khoảng 0.33

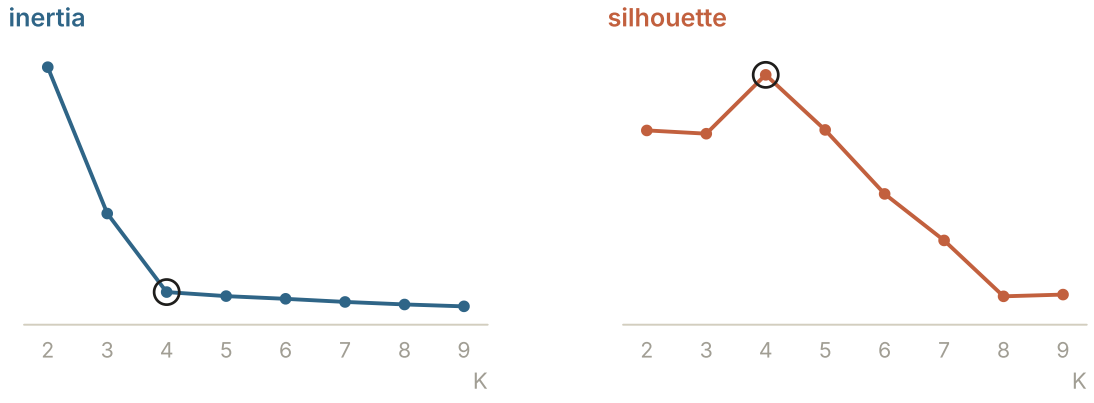
B khoảng 0.91

C khoảng 0.99

D khoảng 0.01

Chi phí mỗi vòng là $O(nKd)$, nên K-Means chạy được trên dữ liệu rất lớn; `MiniBatchKMeans` còn nhanh hơn nữa.

Chọn K. Vẽ J theo K rồi tìm "khuỷu tay" (elbow method), hoặc chọn K có hệ số silhouette trung bình cao nhất. Thường thì K còn phụ thuộc mục đích: chia khách hàng thành 4 nhóm hay 6 nhóm là quyết định kinh doanh, không phải định lý.



Bốn cụm sinh sẵn: inertia giảm mãi theo K nhưng gãy khúc ở K = 4; silhouette cao nhất cũng ở K = 4.

Giới hạn. K-Means thích cụm tròn, kích thước gần bằng nhau, cùng mật độ. Với cụm hình trăng lưỡi liềm hay cụm lồng nhau, nó chia sai một cách rất tự tin. Tâm lại là trung bình, nên một điểm ngoại lệ đủ xa có thể kéo tâm rời khỏi đám điểm của nó.

HỎI NHANH

Tăng K lên bằng số điểm n, mỗi điểm có một tâm riêng. Inertia tối ưu khi ấy bằng bao nhiêu?

A Bằng phương sai của dữ liệu

B 0

C Bằng n

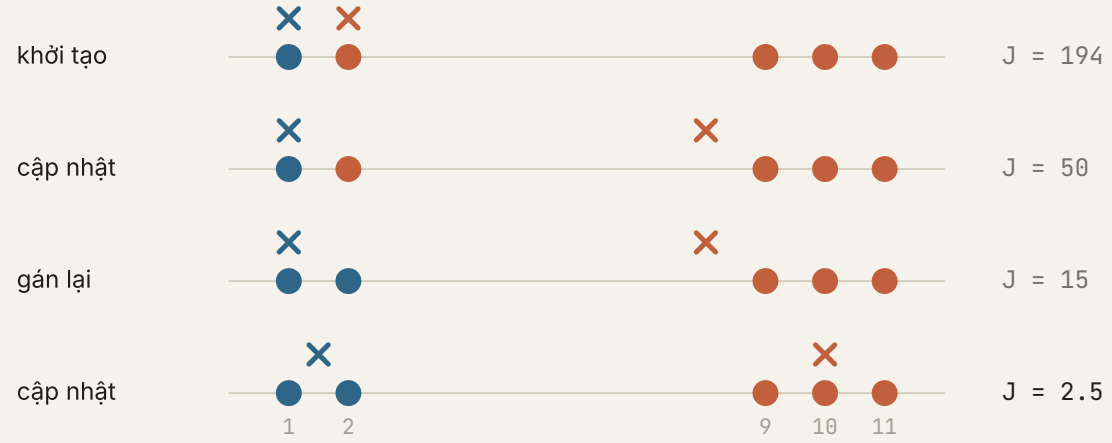
D Không xác định, vì cụm quá nhỏ

Ví dụ tính tay

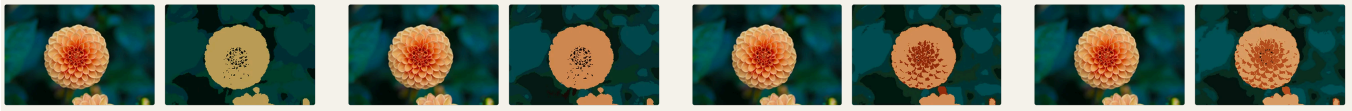
Dữ liệu một chiều $1, 2, 9, 10, 11$, $K = 2$, khởi tạo tệ: $\mu_1 = 1$, $\mu_2 = 2$.

- Gán: $\{1\}$ về μ_1; $\{2, 9, 10, 11\}$ về μ_2.
- Cập nhật: $\mu_1 = 1$, $\mu_2 = 32/4 = 8$.
- Gán lại: điểm 2 giờ gần μ_1 hơn ($1 < 6$), nên cụm thành $\{1, 2\}$ và $\{9, 10, 11\}$.
- Cập nhật: $\mu_1 = 1.5$, $\mu_2 = 10$. Gán lại không đổi, dừng với $J = 0.5 + 2 = 2.5$.

Lần này khởi tạo tệ vẫn tự sửa được, và J giảm qua từng bước: $194 \to 50 \to 15 \to 2.5$. Chỉ cần dời một điểm là sự may mắn ấy biến mất.



Ví dụ tính tay với khởi tạo tệ (tâm 1 và 2): sau hai vòng điểm 2 đổi cụm, J giảm 194 → 50 → 15 → 2.5.



vòng 0: inertia 68.8 triệu (tâm là 6 điểm ảnh lấy ngẫu nhiên)

vòng 1: inertia 50.9 triệu

vòng 3: inertia 31.0 triệu

vòng 11: inertia 25.6 triệu; tâm không đổi nữa, dừng

K-Means gom các màu của ảnh hoa thành 6 cụm: sau mỗi vòng gán rồi lấy trung bình, mỗi điểm ảnh được tô bằng màu tâm cụm của nó.

HỎI NHANH

Giữ khởi tạo $\mu_1 = 1$, $\mu_2 = 2$, nhưng đổi điểm 2 thành 5, tức dữ liệu là 1, 5, 9, 10, 11. Thuật toán Lloyd dừng ở cách chia nào?

A $\{1, 5\}$ và $\{9, 10, 11\}$

B $\{1\}$ và $\{5, 9, 10, 11\}$

C $\{1, 5, 9\}$ và $\{10, 11\}$

D Không dừng, các tâm dao động mãi

DBSCAN

Giả định: cụm là vùng **dày đặc**, ngăn cách bởi vùng thưa. Hai tham số: bán kính `eps` và số điểm tối thiểu `min_samples`.

- Điểm lõi (core): có ít nhất `min_samples` điểm trong bán kính `eps`.
- Điểm biên (border): không phải lõi nhưng nằm trong bán kính của một điểm lõi.
- Điểm nhiễu (noise): không thuộc hai loại trên, gán nhãn -1.

Các điểm lõi nối với nhau thành cụm. DBSCAN không cần biết trước số cụm, tìm được cụm hình dạng bất kỳ và tự loại nhiễu. Điểm yếu: một `eps` duy nhất không hợp với dữ liệu có các cụm mật độ khác nhau. HDBSCAN khắc phục điều này và thường là lựa chọn tốt hơn khi có sẵn.

HỎI NHANH

Dữ liệu có hai cụm. Cụm A dày, các láng giềng thường cách nhau 0.1. Cụm B thưa, các láng giềng thường cách nhau 0.8. Với `eps=0.2`, DBSCAN dễ cho ra kết quả nào?

A Cả hai cụm đều được tìm đúng

B B thành cụm, còn phần lớn A thành noise

C A thành cụm, còn phần lớn B thành noise

D A và B bị gộp thành một cụm

Hierarchical clustering

Agglomerative clustering bắt đầu với mỗi điểm là một cụm, rồi liên tục gộp hai cụm gần nhau nhất. Khoảng cách giữa hai cụm (linkage) có thể là:

- *single*: hai điểm gần nhất, tạo cụm dạng chuỗi dài;

- *complete*: hai điểm xa nhất, tạo cụm gọn;
- *average*: trung bình mọi cặp;
- *Ward*: mức tăng tổng phương sai khi gộp, gần với tinh thần của K-Means.

Kết quả là một cây gộp (dendrogram); cắt cây ở độ cao nào thì được số cụm tương ứng. Cách này cho cái nhìn nhiều tầng, nhưng tốn $O(n^2)$ bộ nhớ nên chỉ hợp với vài chục nghìn điểm.



Hai cụm {0, 1} và {3, 10}: single linkage đo cặp gần nhất (2), complete linkage đo cặp xa nhất (10).

HỎI NHANH

Hai cụm trên trục số là $\{0, 1\}$ và $\{3, 10\}$. Khoảng cách giữa chúng theo single linkage và theo complete linkage lần lượt là bao nhiêu?

A 3 và 9

B 6 và 6

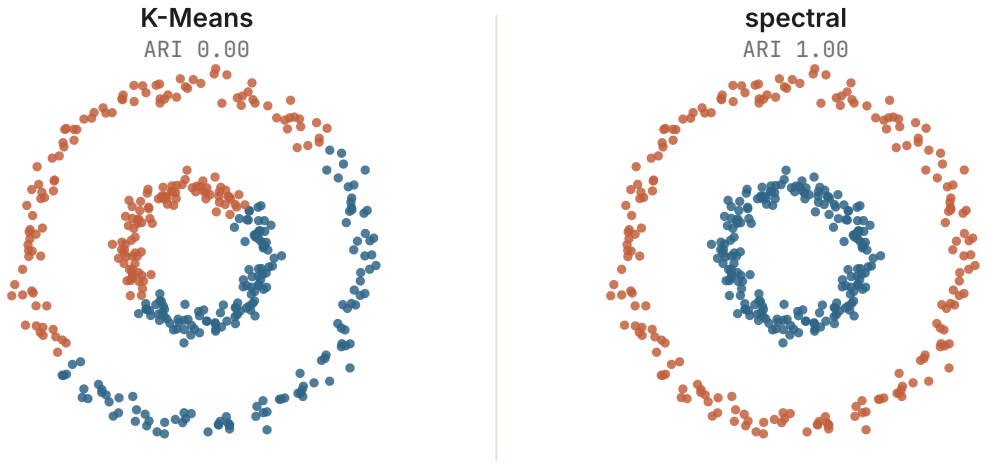
C 2 và 6

D 2 và 10

Spectral clustering

Spectral clustering dựng đồ thị tương đồng giữa các điểm (ví dụ nối mỗi điểm với các láng giềng gần), lấy vài vector riêng của ma trận Laplacian của đồ thị làm tọa độ mới, rồi

chạy K-Means trên tọa độ đó. Hai điểm cùng nằm trên một "dải" dữ liệu sẽ gần nhau trong tọa độ mới dù xa nhau theo đường thẳng. Mạnh với cụm không lồi, nhưng tốn kém với n lớn.



Hai vòng đồng tâm: K-Means cắt đôi theo một đường thẳng; spectral clustering trên đồ thị láng giềng tách đúng từng vòng.

HỎI NHANH

Hai vòng tròn đồng tâm, mỗi vòng là một cụm. K-Means với $K = 2$ cho ARI gần bằng 0, còn spectral clustering trên đồ thị láng giềng thì tách đúng. Lý do chính là gì?

A Đồ thị láng giềng gần như không có cạnh nối hai vòng

B Spectral clustering dùng nhiều tâm hơn K-Means

C Vòng trong có mật độ điểm cao hơn vòng ngoài

D K-Means không chạy được trên dữ liệu hai chiều

Đánh giá cụm

Không có nhãn thì đo độ "gọn và tách biệt". Với điểm i, gọi $a(i)$ là khoảng cách trung bình đến các điểm cùng cụm, $b(i)$ là khoảng cách trung bình nhỏ nhất đến một cụm

khác. Hệ số silhouette

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i),\ b(i)\}} \in [-1, 1].$$

s gần 1 là điểm nằm đúng cụm, gần 0 là nằm giữa hai cụm, âm là có lẽ xếp nhầm. Lưu ý silhouette cũng "thích" cụm tròn, nên đánh giá thấp kết quả tốt của DBSCAN trên dữ liệu hình trăng.

HỎI NHANH

Một điểm có $a(i) = 1$, tức khoảng cách trung bình tới cụm của nó, và $b(i) = 4$, tức khoảng cách trung bình tới cụm khác gần nhất. Silhouette của điểm này bằng bao nhiêu?

A 0.25

B 3

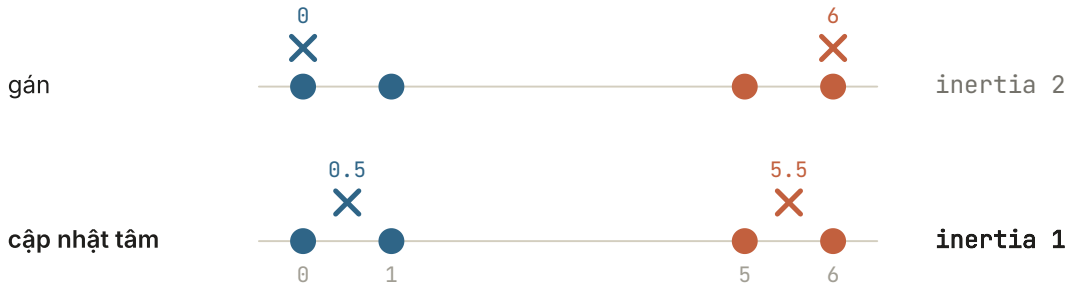
C 0.75

D -0.75

Nếu có nhãn thật (đề thi chấm phân cụm thường có), dùng Adjusted Rand Index (ARI) hoặc Normalized Mutual Information (NMI). Cả hai không phụ thuộc cách đặt tên cụm: cụm "0" của mô hình có là cụm "3" của đáp án cũng không sao.

Một vòng Lloyd trên giấy và máy

Lấy bốn điểm một chiều 0, 1, 5, 6, hai tâm ban đầu 0 và 6. Mỗi điểm vào tâm gần nhất, nên nhóm trái gồm 0,1 và nhóm phải gồm 5,6. Tâm mới là 0.5 và 5.5. Inertia trước cập nhật là 2; sau cập nhật là 1. Ta cài đúng hai thao tác gán và cập nhật để máy đi lại con đường vừa tính tay.



Một vòng Lloyd trên bốn điểm 0, 1, 5, 6: gán theo tâm gần nhất, rồi dời tâm (dấu ×) về trung bình nhóm; inertia từ 2 xuống 1.

Python

```python
import numpy as np

values = np.array([[0.], [1.], [5.], [6.]])
centers = np.array([[0.], [6.]])
distance2 = np.sum((values[:, None, :] - centers[None, :, :]) ** 2, axis=2)
assigned = np.argmin(distance2, axis=1)
before = np.sum(distance2[np.arange(len(values)), assigned])
new_centers = np.array([values[assigned == k].mean(axis=0) for k in range(2)])
after = np.sum((values - new_centers[assigned]) ** 2)
print("gán:", assigned.tolist())
print("tâm mới:", new_centers.ravel().tolist())
print("inertia:", float(before), "->", float(after))
```

KẾT QUẢ

```
gán: [0, 0, 1, 1]
tâm mới: [0.5, 5.5]
inertia: 2.0 -> 1.0
```

Nếu một cụm không còn điểm nào, mean của mảng rỗng là NaN, và NaN lặng lẽ lan sang mọi bước sau. Ví dụ nhỏ trên không gặp, nhưng bản cài tổng quát phải chọn trước một quy tắc. Hòa khoảng cách và sai số số thực cũng cần quy ước, nhất là khi điều kiện dừng là “tâm không đổi”.

HỎI NHANH

Tự cài Lloyd bằng NumPy, tới một vòng thì có một cụm không được gán điểm nào. Xử lý thế nào là hợp lý?

A Coi tâm NaN là 0 rồi chạy tiếp

B Đặt lại tâm theo một quy tắc được ghi rõ

C Lấy bớt vài điểm của cụm khác chia sang

D Chia tổng tọa độ cho K thay vì cho số điểm

DBSCAN: một cụm không cần tròn

Một điểm core có ít nhất `min_samples` điểm trong bán kính `eps`, **tính cả chính nó** trong quy ước của scikit-learn. Từ core, ta lan qua các core lân cận rồi nhận thêm border ở rìa. Một điểm border ít hàng xóm vẫn có thể thuộc cụm. Bản cài chỉ giữ các điểm đủ ngưỡng sẽ biến mọi border thành noise; đó đã là một thuật toán khác.



eps = 0.16, min_samples = 3: 0.1 và 0.2 là core (đoạn ngang là bán kính quanh chúng); 0 và 0.35 là border, vẫn vào cụm; 3 là noise.

```python
from sklearn.cluster import DBSCAN

density_points = np.array([[0.], [0.1], [0.2], [0.35], [3.]])
db = DBSCAN(eps=0.16, min_samples=3).fit(density_points)
```

```
print("nhãn cụm:", db.labels_.tolist())
print("core:", db.core_sample_indices_.tolist())
assert db.labels_[-1] == -1
```

KẾT QUẢ

```
nhãn cụm: [0, 0, 0, 0, -1]
core: [1, 2]
```

Điểm 0.1 có ba điểm trong `eps`, còn 0 chỉ có hai; 0 vẫn vào cụm vì nó nối được với core 0.1. Điểm 3 quá xa nên nhãn −1. ID cụm 0,1,... không phải nhãn học sinh yếu/giỏi và có thể đổi thứ tự khi dữ liệu đổi. Với điểm border chạm được hai cụm, thứ tự xử lý có thể quyết định nó thuộc cụm nào; không ép output phải giống nếu đề chưa quy ước.

HỎI NHANH

Giữ `eps=0.16` như ví dụ trên, nhưng đặt `min_samples=1`. Điểm 3 nhận nhãn gì?

A −1, vì vẫn ở xa mọi điểm khác

B Cụm 0, cùng với bốn điểm còn lại

C Báo lỗi, vì `min_samples` quá nhỏ

D Một cụm riêng, chỉ có mình nó

Đánh giá cần đúng câu hỏi

Nếu có nhãn tham khảo, chỉ dùng để chấm chứ không dùng khi fit, ARI so hai cách chia mà không quan tâm tên cụm. Accuracy thô thì có quan tâm: chỉ cần đổi tên cụm là điểm sụp. Không có nhãn thì silhouette so khoảng cách trong và ngoài cụm, nhưng nó ưu ái một kiểu hình học và không luôn phản ánh mục tiêu thực tế. Đừng chọn số cụm chỉ vì silhouette cao rồi đặt tên tùy tiện.

HỎI NHANH

Nhãn tham khảo là $[0, 0, 1, 1]$, mô hình trả về $[1, 1, 0, 0]$. Accuracy so thẳng và ARI lần lượt bằng bao nhiêu?

A 0 và 1

B 1 và 1

C 0 và 0

D 0.5 và 0

Inertia tối ưu không tăng khi K tăng, nên "chọn K có inertia nhỏ nhất" luôn đẩy về rất nhiều cụm. Elbow là một gợi ý hình học, không phải định lý về K thật. Cần kiểm thêm độ ổn định khi đổi seed, đổi đặc trưng, bớt mẫu, và xem nhóm có dùng được cho mục đích sau đó không.

Dùng thư viện

Python

```python
from sklearn.cluster import DBSCAN, KMeans
from sklearn.datasets import make_moons
from sklearn.metrics import adjusted_rand_score, silhouette_score
from sklearn.preprocessing import StandardScaler

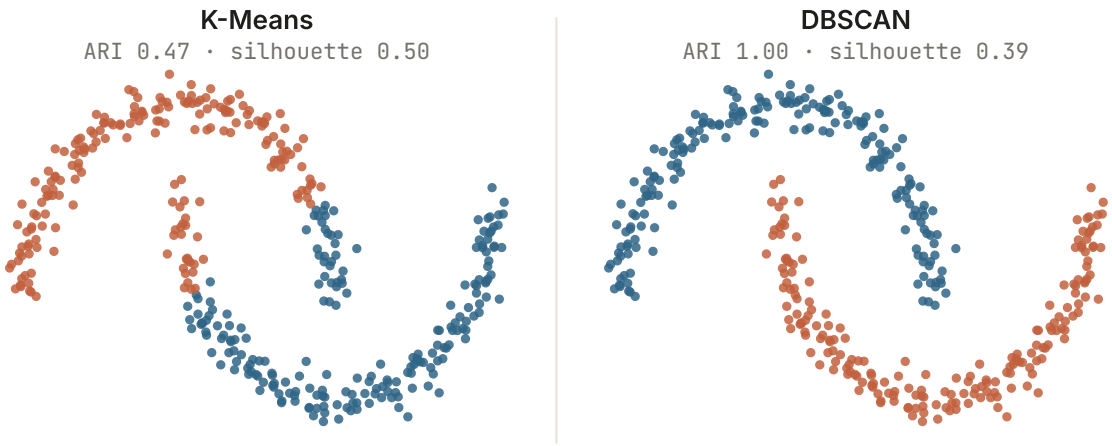
X, y = make_moons(n_samples=400, noise=0.06, random_state=0)
X = StandardScaler().fit_transform(X)
for name, model in [("K-Means", KMeans(n_clusters=2, n_init=10, random_state=0)),
                    ("DBSCAN ", DBSCAN(eps=0.3, min_samples=5))]:
    labels = model.fit_predict(X)
    print(name, "ARI =", round(adjusted_rand_score(y, labels), 2),
          " silhouette =", round(silhouette_score(X, labels), 2))
```

KẾT QUẢ

```
K-Means ARI = 0.47  silhouette = 0.5
```

```
DBSCAN  ARI = 1.0  silhouette = 0.39
```

Kết quả minh họa đúng cái bẫy ở trên: DBSCAN khớp nhãn hoàn toàn theo ARI, nhưng silhouette lại chấm K-Means cao hơn. Con số `eps=0.3` cũng chỉ có nghĩa sau `StandardScaler`: bán kính luôn đi kèm thang đo.



Hai trăng khuyết (code bài): K-Means cắt theo tâm nên trộn hai trăng; DBSCAN theo mật độ tách đúng, dù silhouette chấm thấp hơn.

HỎI NHANH

Trong code trên, nhân `X` đã chuẩn hóa lên 10 lần nhưng giữ `eps=0.3`. DBSCAN sẽ trả về gì?

A Gần như mọi điểm thành noise

B Như cũ, vì hình dạng các cụm không đổi

C Hai mặt trăng bị gộp thành một cụm

D Số cụm tăng lên khoảng mười lần

Bẫy cần kiểm

ĐỌC ĐÚNG ĐIỀU KIỆN

Không tính silhouette khi chỉ có một cụm hoặc mỗi điểm là một cụm. Nhãn −1 của DBSCAN là noise, không phải một cụm ngang hàng với các cụm khác; khi đánh giá, nói rõ có loại noise hay không. Tỉ lệ noise quá cao thường gợi ý kiểm lại thang đo, `eps` hoặc mật độ, chưa chứng minh thuật toán sai. `DBSCAN` trong scikit-learn không có `predict` như `KMeans`; gán dữ liệu mới cần một quy tắc riêng.

HỎI NHANH

Đã fit DBSCAN trên dữ liệu cũ, giờ có thêm một điểm mới. Gán nhãn cho điểm mới thế nào để nhất quán với mô hình đã có?

A Gọi `db.predict(x_new)` như với K-Means

B Fit lại DBSCAN chỉ trên các điểm mới

C Lấy nhãn ở cùng vị trí trong `db.labels_`

D Lấy nhãn của điểm core gần nhất trong bán kính `eps`, nếu có

Khi đi thi

- **Bài chấm bằng ARI/NMI**: thử vài thuật toán và tham số theo hình dạng dữ liệu thay vì mặc định K-Means. Phân cụm trên embedding tốt (Phase 4) thường quan trọng hơn đổi thuật toán.
- **Cụm làm bước tiền xử lý**: USA-NA-AIO 2026 (vòng 2, Problem 5) cho baseline chạy K-Means $k = 4$ trên các điểm (x, y) để tách bốn đường cong trộn lẫn, rồi fit từng đường. Đường cong cắt nhau thì cụm theo tâm gần nhất trộn điểm; vượt baseline bắt đầu từ chỗ đó.

- **Cụm làm đặc trưng**: mã cụm hoặc khoảng cách đến các tâm K-Means là đặc trưng bổ sung cho mô hình có giám sát.
- **Cụm làm group cho validation**: ảnh gần trùng nhau, các bản ghi của cùng một người, nên nằm trọn trong một fold. Phân cụm giúp tìm ra các nhóm đó để dùng `GroupKFold` (bài 1.3).
- **Luôn chuẩn hóa** trước các thuật toán dựa trên khoảng cách, và chỉ fit scaler trên phần dữ liệu giao thức cho phép.

Tóm tắt

- Phân cụm không có đáp án; mỗi thuật toán là một giả định về hình dạng cụm.
- K-Means: cụm tròn quanh tâm, nhanh, cần K, chỉ đạt cực tiểu địa phương; k-means++ và `n_init` giảm rủi ro kẹt.
- DBSCAN: cụm là vùng dày đặc, tự tìm số cụm và nhiễu, nhạy với `eps` và thang đo.
- Phân cấp cho cây gộp nhiều tầng; spectral xử lý cụm không lồi.
- Không nhãn thì dùng silhouette (cẩn thận với cụm không tròn); có nhãn thì dùng ARI, NMI.

Kiểm tra cuối bài

Mười câu kiểm cả cách hiểu, phép tính và quy trình. Câu sai chỉ ra phần cần đọc lại; hãy làm trước khi mở lời giải.

CÂU 1

Ở bước cập nhật của K-Means, một cụm đang có ba điểm $(1, 1)$, $(3, 1)$ và $(2, 4)$. Tâm mới của cụm là điểm nào?

A $(2, 2)$

B $(2, 6)$

C $(6, 2)$

D $(1, 2)$

PHỎNG THEO MIT 6.036 · Final Fall 2021 · Clustering 2(a–b)

CÂU 2

Có bảy điểm $x_1, \ldots, x_7$, $K = 2$, hai tâm khởi tạo là x_3 và x_6. Khoảng cách từ x_1, x_2, x_4, x_5, x_7 tới x_3 lần lượt là 3, 4, 4, 3, 6. Tới x_6 lần lượt là 2, 7, 1, 8, 1. Sau bước gán đầu tiên, hai cụm là gì?

A $\{x_1, x_2, x_3, x_4\}$ và $\{x_5, x_6, x_7\}$

B $\{x_2, x_3, x_5\}$ và $\{x_1, x_4, x_6, x_7\}$

C $\{x_1, x_2, x_3, x_5\}$ và $\{x_4, x_6, x_7\}$

D $\{x_2, x_3, x_4, x_7\}$ và $\{x_1, x_5, x_6\}$

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q8.3

CÂU 3

Chạy k-means++ trên năm điểm $(0,0)$, $(1,2)$, $(2,3)$, $(3,1)$, $(4,1)$ với $K=3$, tâm đầu tiên là $(0,0)$. Xác suất $(4,1)$ được chọn làm tâm thứ hai là bao nhiêu?

A khoảng 0.200

B khoảng 0.314

C khoảng 0.378

D khoảng 0.250

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q8.2

CÂU 4

Hai lần khởi tạo K-Means với cùng K cho inertia 12 và 9 trên cùng dữ liệu. Theo inertia thì chọn kết quả nào, và điều gì vẫn chưa kết luận được?

A Chọn kết quả 9, nhưng chưa chứng minh được đó là cực tiểu toàn cục

B Chọn kết quả 12, vì lần khởi tạo đầu ổn định hơn

C Kết quả 9 chắc chắn là toàn cục, vì thấp hơn 12

D Hai kết quả phải bằng nhau, vì mỗi bước Lloyd đều tối ưu chính xác

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q8.1(ii)

CÂU 5

Một cụm K-Means gồm các điểm trên trục số 1, 2, 3. Thêm điểm ngoại lai 30 vào cụm. Tâm mới bằng bao nhiêu? Nếu thay trung bình bằng median thì sao?

A 2 và 2

B 9 và 2.5

C 9 và 9

D 2.5 và 9

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q8.1(iii)

CÂU 6

DBSCAN dùng khoảng cách Euclid, `eps=1.1`, `min_samples=3`, tính cả điểm đang xét. Ba điểm trên trục số là 0, 1 và 2. Điểm nào là core?

A Cả 0, 1 và 2

B Chỉ 0 và 2

C Không điểm nào

D Chỉ điểm 1

CÂU 7

Muốn phân cụm những vùng có mật độ khác nhau, trong bốn thuật toán sau thì thuật toán nào phù hợp hơn?

A K-Means

B Hồi quy tuyến tính

C DBSCAN

D Hồi quy logistic

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 271

CÂU 8

Trong spectral clustering, vì sao ta dùng các vector riêng của Laplacian đồ thị?

A Để tính nhanh hơn

B Để chuẩn hóa dữ liệu

C Để giảm số chiều dữ liệu

D Để làm lộ ra cấu trúc cụm

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 36

CÂU 9

Nhãn cụm của bốn mẫu là `[0, 0, 1, 1]`. Đổi tên các cụm thành `[7, 7, 3, 3]` mà không đổi cách chia nhóm. ARI so với cùng một nhãn tham khảo thay đổi thế nào?

A Giảm, vì các số hiệu không liên tiếp

B Chỉ giữ nguyên nếu nhãn tham khảo cũng đổi

C Không đổi

D Tăng, vì số hiệu cụm lớn hơn

CÂU 10

Mỗi bộ dữ liệu gồm 400 điểm (x, y) sinh từ bốn hàm: mũ, log, sin và tuyến tính, mỗi hàm 100 điểm có nhiễu. Baseline của đề chạy K-Means với $k = 4$ trên (x, y), rồi fit riêng từng cụm. Bước phân cụm này yếu ở đâu?

A $k = 4$ là sai, vì đề chưa cho số hàm thật

B K-Means không chạy được trên dữ liệu hai chiều

C Thiếu chuẩn hóa y nên K-Means báo lỗi

D Các đường cong cắt nhau, nên các cụm bị trộn lẫn

PHỎNG THEO USA-NA-AIO 2026 · Vòng 2 · Ngày 2 · Problem 5

Đọc thêm

- James, Witten, Hastie, Tibshirani — *An Introduction to Statistical Learning*, mục 12.4. K-Means, phân cụm phân cấp và cách đọc dendrogram.
- Arthur, Vassilvitskii (2007) — *k-means++: The Advantages of Careful Seeding*. Khởi tạo theo bình phương khoảng cách, kèm bảo đảm về sai số kỳ vọng.

- Ester và cộng sự (1996) — *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise*. Bài gốc của DBSCAN.
- scikit-learn — Clustering. Bảng so sánh trực quan các thuật toán, ý nghĩa `eps`, `min_samples` và các metric đánh giá.
- ISLP — Unsupervised learning lab. Thực hành PCA, K-Means và phân cụm phân cấp.

Nguồn ảnh: ảnh hoa là ảnh mẫu `flower.jpg` kèm scikit-learn (vultilion, Flickr, CC BY 2.0).