Feature engineering

Trắc nghiệm 25 Thực hành 11 PDF bài

> Một cửa hàng muốn dự đoán số đơn vào đầu mỗi giờ. Bảng lịch sử có giờ, mã cửa hàng và số đơn, nhưng nếu vô tình dùng doanh số của chính giờ đang dự đoán thì validation đẹp đến mức không còn đáng tin. Feature engineering là biến thông tin **đang có lúc dự đoán** thành đặc trưng có ích. Ta kết thúc chương bằng câu hỏi này, vì mô hình tốt nhất vẫn không cứu được một cột sinh sai thời điểm.

MỤC TIÊU SAU BÀI NÀY

- Tạo đặc trưng số, phân loại, chu kỳ và lịch sử theo đúng thời điểm.
- Đọc shape/output của lag, rolling và encoding trên nhóm.
- So nhóm đặc trưng bằng cùng fold và tránh target/time leakage.

Mỗi mô hình cần một kiểu đặc trưng

Tạo đặc trưng (feature engineering) là biến dữ liệu thô thành thông tin mô hình dùng dễ hơn, như tính tuổi từ ngày sinh. Học máy cổ điển cần người làm việc này; mạng học sâu ở các phase sau tự học đặc trưng từ ảnh, chữ, âm thanh. Với dữ liệu bảng cỡ vừa, gradient boosting trên cây kèm vài đặc trưng tốt thường là lựa chọn mạnh nhất.

Cùng một dữ liệu, cách biến đổi đúng phụ thuộc mô hình sẽ dùng:

Thao tác	Mô hình tuyến tính, kNN, SVM	Mô hình cây
Chuẩn hóa thang đo	Cần	Không cần
Log cho biến lệch	Thường có ích	Gần như không đổi, vì log giữ thứ tự
One-hot cột phân loại	Cần	Thường kém ordinal hoặc hỗ trợ danh mục sẵn có

Thao tác	Mô hình tuyến tính, kNN, SVM	Mô hình cây
Tương tác, tỉ số	Phải tự tạo	Học được phần nào, nhưng tạo sẵn vẫn giúp
Giá trị thiếu	Phải điền	XGBoost, LightGBM, HistGB tự xử lý

HỎI NHANH

Áp $\log(1+x)$ cho cột thu nhập, rồi học lại một cây quyết định trên cùng dữ liệu. Chuyện gì xảy ra?

A Cây sâu hơn, vì phân phối cân đối hơn

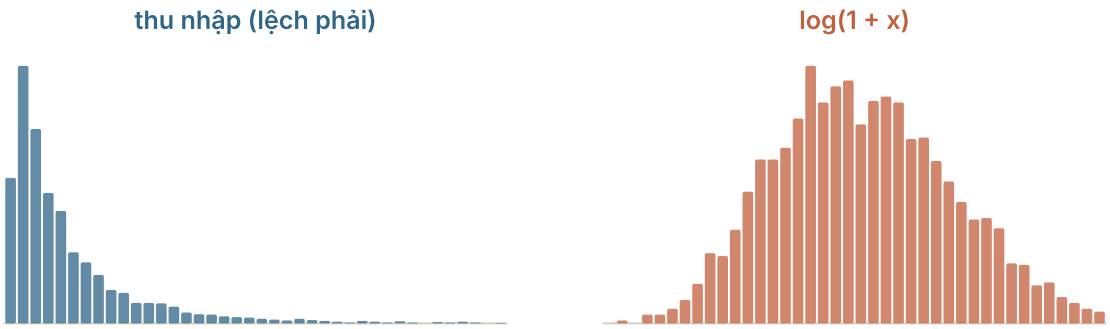
B Cây chia train y hệt, chỉ có ngưỡng là đổi

C Cây tốt hơn hẳn, nhờ bớt lệch phải

D Phải chuẩn hóa lại thì cây mới chạy được

Đặc trưng số

- **Biến đổi.** Biến lệch phải (thu nhập, số lượt xem) qua $\log(1+x)$ trở nên cân đối hơn, có ích cho mô hình tuyến tính và kNN. Với target lệch như giá nhà, học $\log$(giá) biến sai số thành sai số theo tỉ lệ: lệch 10% ở căn 3 tỉ hay căn 300 tỉ tính như nhau, nên vài căn rất đắt không lấn át loss.



Cùng 3000 giá trị thu nhập: phân phối gốc dồn sát 0 với đuôi dài; sau log(1 + x) gần cân đối, hợp với mô hình tuyến tính và kNN.

- **Tỉ số và hiệu.** Tổng tiền chia số món ra giá trung bình mỗi món; số đơn trừ số đơn hủy ra số đơn thành công. Những phép tính con người thấy "có nghĩa" thường là đặc trưng tốt, vì cây phải dùng rất nhiều ngưỡng mới xấp xỉ được một phép chia số học. Điều kiện duy nhất: mọi thành phần của phép tính phải có sẵn lúc dự đoán.
- **Rời rạc hóa** (binning) thành khoảng, ví dụ nhóm tuổi: đôi khi giúp mô hình tuyến tính bắt được quan hệ không đơn điệu.

HỎI NHANH

Cần dự đoán giá nhà trước khi bán. Cột `price/area` được tạo từ giá bán thực tế. Lúc dự đoán, `area` đã biết nhưng `price` thì chưa. Feature này có hợp lệ không?

A Có, vì chia cho diện tích đã loại ảnh hưởng của target

B Có, nếu chỉ fit scaler trên train

C Có, nếu dùng cây thay cho linear regression

D Không, vì phép tính cần chính target chưa biết

Đặc trưng phân loại

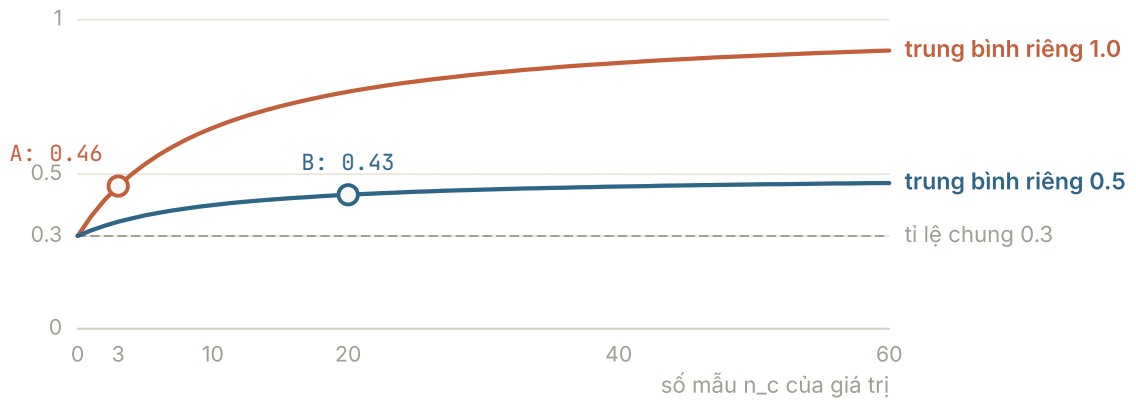
Cách mã hóa	Ý tưởng	Dùng khi
One-hot	Mỗi giá trị một cột 0/1	Ít giá trị khác nhau; mô hình tuyến tính
Ordinal	Mỗi giá trị một số nguyên	Có thứ tự thật (S < M < L), hoặc cho mô hình cây
Tần suất	Thay giá trị bằng số lần xuất hiện	Nhiều giá trị; độ phổ biến có ý nghĩa
Target encoding	Thay giá trị bằng trung bình y của nó	Rất nhiều giá trị (mã quận, mã sản phẩm)

Target encoding mạnh nhưng nguy hiểm: dùng y để tạo đặc trưng chính là cửa ngõ rò rỉ dữ liệu. Hai quy tắc:

1. **Tính out-of-fold.** Giá trị mã hóa của một mẫu chỉ được tính từ các fold khác, không bao giờ dùng chính y của nó.
2. **Làm mượt** (smoothing) cho giá trị hiếm. Với giá trị c xuất hiện n_c lần, trung bình nhãn $\bar{y}_c$, trung bình toàn cục $\bar{y}$ và hệ số m:

$$\mathrm{TE}(c) = \frac{n_c\,\bar{y}_c + m\,\bar{y}}{n_c + m}.$$

Ví dụ: quận A chỉ có 3 mẫu và cả 3 đều có nhãn 1, trong khi tỉ lệ chung là 0.3. Với $m = 10$, $\mathrm{TE}(A) = (3 \cdot 1 + 10 \cdot 0.3)/13 \approx 0.46$, không phải 1.0. Ba mẫu chưa đủ để tin rằng quận A "chắc chắn" mang nhãn 1.



Target encoding làm mượt với m = 10: giá trị ít mẫu bị kéo về tỉ lệ chung 0.3, nhiều mẫu thì tiến dần về trung bình riêng.

HỎI NHANH

Vẫn $m = 10$ và tỉ lệ chung là 0.3. Quận B có 20 mẫu, một nửa mang nhãn 1. Giá trị mã hóa của B bằng bao nhiêu?

A khoảng 0.43

B 0.50

C 0.30

D khoảng 0.40

CatBoost cài sẵn một biến thể an toàn của target encoding; LightGBM cũng nhận trực tiếp cột phân loại.

Khi một mẫu có thể mang nhiều giá trị cùng lúc, như một phim có nhiều diễn viên trong danh sách 200 người, dùng multi-hot: 200 cột 0/1, cho phép nhiều số 1 trên cùng một hàng.

Giá trị thiếu

Trước khi xử lý, hỏi vì sao ô bị trống. Xóa mọi dòng có ô trống thường đắt hơn tưởng: 20 cột, mỗi ô thiếu ngẫu nhiên 15% thì chỉ $0.85^{20} \approx 4\%$ số dòng còn đủ.

- Điền bằng median (số) hoặc giá trị phổ biến nhất (phân loại), học trên train rồi áp lên mọi tập.
- Thêm cột chỉ báo "có bị thiếu không". **Việc thiếu cũng là thông tin**: khách bỏ trống ô thu nhập có thể khác hẳn khách điền đầy đủ. Điền cũng làm cột trông ổn định hơn thật: 2, 4, 8 cùng hai ô điền bằng trung bình $14/3$ thì phương sai giảm từ 6.22 xuống 3.73.
- Với các thư viện boosting, thường để nguyên NaN cho mô hình tự học hướng đi tốt nhất.

HỎI NHANH

Khách bỏ trống ô thu nhập có tỉ lệ vỡ nợ 40%, khách điền đầy đủ chỉ 10%. Ta điền median vào ô trống và không thêm cột nào khác. Hệ quả chính là gì?

A Mô hình mất đi tín hiệu "bỏ trống", một tín hiệu rất mạnh

B Không sao, vì median giữ nguyên phân phối

C Tốt hơn, vì dữ liệu không còn giá trị NaN

D Mô hình báo lỗi, vì cột đã đổi kiểu dữ liệu

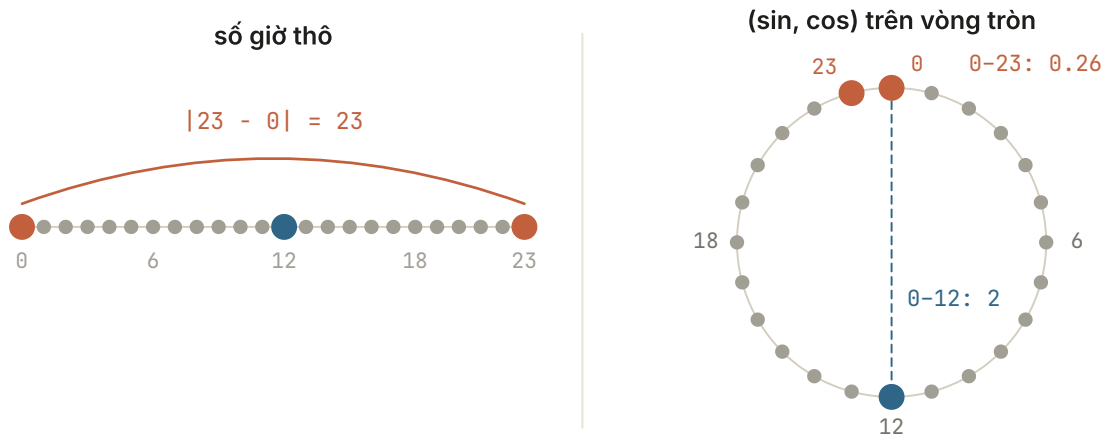
Thời gian

- Trước hết đưa mọi cách viết ngày ("11/10/2026", "2026-10-11") về một định dạng, và biết chắc "11/10" là ngày–tháng hay tháng–ngày.
- Tách ngày giờ thành năm, tháng, ngày trong tuần, giờ, ngày lễ, cuối tuần.

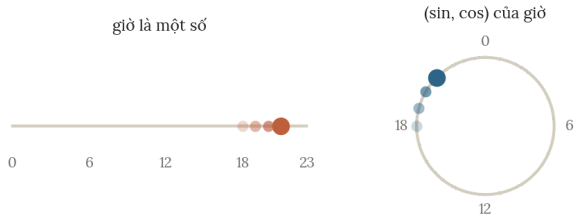
- Đặc trưng có chu kỳ như giờ trong ngày nên mã hóa trên đường tròn, để 23 giờ và 0 giờ nằm gần nhau:

$$x_{\sin} = \sin\frac{2\pi t}{T}, \qquad x_{\cos} = \cos\frac{2\pi t}{T}, \qquad T = 24.$$

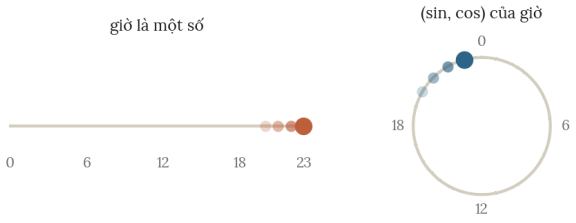
Với cách này, khoảng cách giữa 23 giờ và 0 giờ là 0.26, còn giữa 12 giờ và 0 giờ là 2, đúng như trực giác. Nếu chỉ dùng số giờ thì 23 và 0 cách nhau xa nhất.



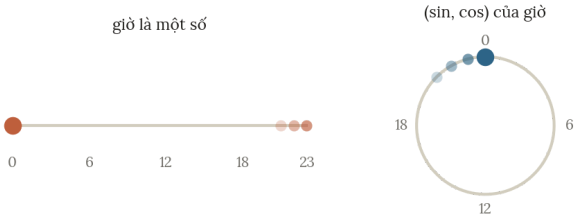
Số giờ thô đặt 23 giờ xa 0 giờ nhất; mã hóa (sin, cos) đặt chúng cạnh nhau trên vòng tròn.



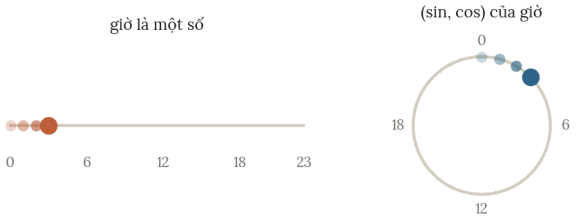
21 giờ: sin −0.71, cos +0.71



23 giờ: sin −0.26, cos +0.97



0 giờ: sin +0.00, cos +1.00 · trên trục số nhảy từ 23 về 0, trên vòng tròn chỉ đi một bước



3 giờ: sin +0.71, cos +0.71

Giờ trong ngày chạy từ 18 giờ qua nửa đêm: trên trục số 23 và 0 cách nhau xa nhất; mã hóa (sin, cos) đặt chúng cạnh nhau trên vòng tròn.

HỎI NHANH

Sau khi mã hóa giờ bằng sin và cos với $T = 24$, khoảng cách Euclid giữa 22 giờ và 2 giờ bằng bao nhiêu?

A 20

B 1

C 4

D khoảng 0.26

Chuỗi thời gian

Dự đoán y_t từ quá khứ, các đặc trưng hay dùng:

- **Lag**: $y_{t-1}, y_{t-7}, y_{t-365}$, tùy chu kỳ của dữ liệu.
- **Thống kê cửa sổ trượt** (rolling): trung bình, độ lệch chuẩn của k bước gần nhất.
- **Sai phân quá khứ**: $y_{t-1} - y_{t-2}$ để dự đoán y_t, đo xu hướng từ những giá trị đã có.

Quy tắc vàng: mọi đặc trưng tại thời điểm t chỉ được dùng thông tin **trước** t. Rolling mean phải dịch lùi một bước (`shift(1)`) trước khi lấy cửa sổ; nếu không, giá trị cần dự đoán đã nằm sẵn trong đặc trưng. Validation cũng phải chia theo thời gian (bài 1.3).

HỎI NHANH

Dùng sai phân $y_t - y_{t-1}$ làm feature để dự đoán y_t. Có hợp lệ không?

A Có, vì sai phân đo xu hướng gần nhất

B Có, nếu y_{t-1} đã được lấy bằng `shift(1)`

C Không, vì nó chứa chính y_t

D Không, vì sai phân chỉ thêm nhiễu

Đặc trưng gộp nhóm

Thống kê theo nhóm thường là đặc trưng mạnh nhất trong dữ liệu bảng: số đơn trung bình của mỗi khách, giá trung bình của mỗi danh mục, độ lệch của một giao dịch so với thói quen của chính người đó. Với `pandas`, đó là một dòng `groupby(...).transform("mean")`. Nếu thống kê có dùng y, quy tắc out-of-fold ở phần target encoding vẫn áp dụng.

HỎI NHANH

Thêm cột `shop_mean = groupby("shop")["sales"].transform("mean")`, tính trên toàn bảng train theo giờ, rồi dùng nó để dự đoán `sales`. Có vấn đề gì?

A Không sao, đây chỉ là thống kê theo nhóm

B Cột này trùng thông tin với one-hot của shop

C `transform` làm xáo trộn thứ tự các hàng

D Mỗi hàng chứa cả sales của chính nó lẫn sales tương lai

Văn bản, ảnh, âm thanh

Dữ liệu không có cấu trúc cũng cần thành vector:

- Văn bản: đếm từ, TF-IDF (bài 6.1), hoặc embedding câu (bài 6.2).
- Ảnh, âm thanh: embedding từ model pretrained (Chương 4).

Sau đó, mọi kỹ thuật của chương này dùng lại được: PCA cho embedding, kNN trên embedding, gradient boosting trên embedding ghép với đặc trưng bảng.

Làm có kiểm chứng

Thêm đặc trưng là thêm giả thuyết; giả thuyết cần được kiểm. Quy trình đơn giản mà hiệu quả:

1. Dựng baseline và ghi điểm cross-validation.
2. Thêm **một nhóm** đặc trưng, đo lại bằng đúng cùng các fold. Giữ nếu tăng rõ, bỏ nếu không.
3. Ghi lại mọi thử nghiệm: nhóm đặc trưng, điểm từng fold, thời gian chạy.

Làm ngược lại, tức bỏ từng nhóm khỏi mô hình đầy đủ (ablation), cho biết nhóm nào thật sự gánh điểm. Feature importance của mô hình cây chỉ là gợi ý; permutation importance trên validation đáng tin hơn. Đừng lọc đặc trưng chỉ bằng điểm của từng cột riêng lẻ: với $y = x_1 \text{ XOR } x_2$, mỗi cột một mình không nói gì về y (thông tin tương hỗ bằng 0), nhưng hai cột cùng nhau xác định y hoàn toàn.

HỎI NHANH

Mô hình đầy đủ có MAE 2.0 trên các fold cố định. Bỏ nhóm lag thì MAE là 2.9, bỏ nhóm thời gian là 2.02, bỏ nhóm thống kê cửa hàng là 2.3. Nhóm nào đóng góp nhiều nhất?

A Nhóm lag

B Nhóm thời gian

C Nhóm thống kê cửa hàng

D Chưa biết khi chưa xem feature importance

Danh sách kiểm tra rò rỉ

Trước khi vui mừng vì điểm validation tăng vọt, tự hỏi:

- Đặc trưng này có dùng y của chính mẫu đó không?
- Có dùng thông tin từ tương lai không?
- Có được tính trên cả train lẫn test cùng lúc, kiểu chuẩn hóa hay đếm tần suất trên toàn bộ dữ liệu, theo cách mà lúc triển khai thật không làm được không?
- Lúc dự đoán thật, đặc trưng này có sẵn không?

Một đặc trưng tốt đến mức khó tin thì thường đúng là không nên tin.

HỎI NHANH

Đếm tần suất của mã sản phẩm trên train và test gộp lại, không dùng nhãn. Cách này hợp lệ khi nào?

A Luôn hợp lệ, vì không đụng tới nhãn

B Không bao giờ, vì đã nhìn vào dữ liệu test

C Chỉ khi mô hình phía sau là cây

D Khi lúc dự đoán thật cũng có sẵn cả lô ấy

Đi một hàng dữ liệu theo dòng thời gian

Hãy nhìn cửa hàng A với doanh số đã biết 5, 7, 6 ở ba giờ trước. Khi dự đoán giờ kế tiếp, `lag_1` bằng 6 và trung bình hai giá trị gần nhất là $(7 + 6)/2 = 6.5$. Nếu đang dự đoán chính giờ có số 6 mà rolling lại gồm số 6, ta đã dùng đáp án. `shift(1)` không phải mẹo cú pháp: nó thể hiện thời điểm thông tin trở nên có sẵn.

Python

```
import numpy as np
import pandas as pd

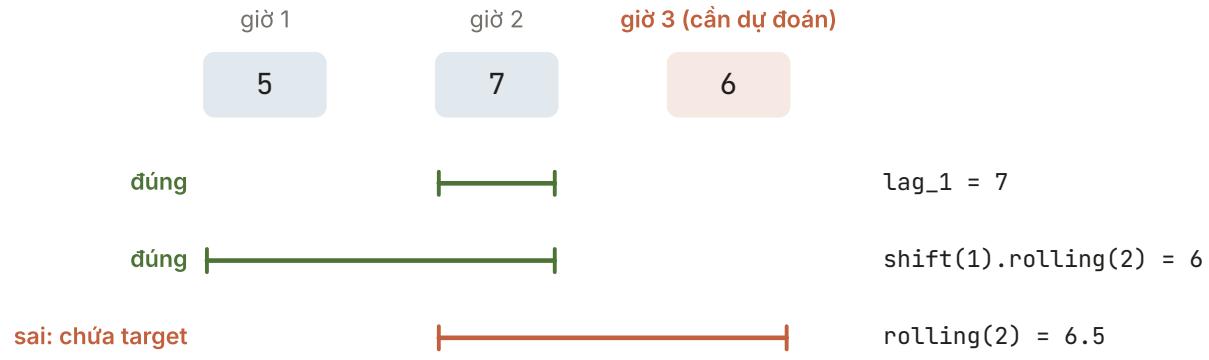
history = pd.DataFrame({"shop": ["A", "A", "A", "B", "B"],
                        "time": [1, 2, 3, 1, 2],
                        "sales": [5., 7., 6., 3., 4.]})
history = history.sort_values(["shop", "time"])
history["lag_1"] = history.groupby("shop")["sales"].shift(1)
history["mean_prev_2"] = history.groupby("shop")["sales"].transform(
    lambda s: s.shift(1).rolling(2, min_periods=2).mean()
)
print(history.to_string(index=False))
assert history.loc[2, "mean_prev_2"] == 6.
```

KẾT QUẢ

```
shop  time  sales  lag_1  mean_prev_2
   A     1    5.0    NaN          NaN
```

```
A     2     7.0     5.0          NaN
A     3     6.0     7.0          6.0
B     1     3.0     NaN          NaN
B     2     4.0     3.0          NaN
```

Ở giờ 3 của A, `mean_prev_2` là 6 vì hai giờ trước có 5 và 7. Đầu chuỗi thiếu lịch sử nên NaN là đúng, không phải code hỏng. Cần chiến lược điền thiếu học trên train hoặc model xử lý NaN; điền bằng dữ liệu tương lai để "đỡ mất hàng" là leakage. Dữ liệu cũng phải sort theo thời gian trong từng nhóm trước shift, không theo thứ tự file tùy ý.



Dự đoán giờ 3 của cửa hàng A: lag và rolling sau shift(1) chỉ dùng giờ 1–2; rolling thẳng ôm luôn doanh số giờ 3 cần dự đoán.

HỎI NHANH

Quên `shift(1)`, viết thẳng `rolling(2).mean()` trên doanh số 5, 7, 6 của cửa hàng A. Giá trị ở giờ 3 bằng bao nhiêu?

A 6, giống hệt bản có shift

B 7, giá trị gần nhất trước đó

C 6.5, có chứa luôn target của giờ 3

D NaN, vì chưa đủ lịch sử

Một pipeline xử lý cột chưa từng gặp

Mã cửa hàng là danh mục, không phải một số có khoảng cách vật lý. One-hot dành một cột cho mỗi giá trị đã thấy; ở test có mã mới thì `handle_unknown="ignore"` tạo hàng 0 trong nhóm cột đó. Nó giúp code chạy đúng schema, nhưng không làm mô hình hiểu cửa hàng mới. Cần nghĩ về một đặc trưng chung như khu vực hay diện tích nếu thông tin đó có sẵn.

Python

```python
from sklearn.compose import ColumnTransformer
from sklearn.impute import SimpleImputer
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import OneHotEncoder, StandardScaler

train_features = pd.DataFrame({"size": [10., np.nan, 30.], "shop": ["A", "B", "A"]})
new_features = pd.DataFrame({"size": [20.], "shop": ["C"]})
numeric = make_pipeline(SimpleImputer(strategy="median"), StandardScaler())
preprocessor = ColumnTransformer([
    ("number", numeric, ["size"]),
    ("category", OneHotEncoder(handle_unknown="ignore", sparse_output=False), ["shop"]),
])
encoded_train = preprocessor.fit_transform(train_features)
encoded_new = preprocessor.transform(new_features)
print("shape:", encoded_train.shape, encoded_new.shape)
print("mẫu mới:", encoded_new.round(3).tolist())
```

KẾT QUẢ

```
shape: (3, 3) (1, 3)
mẫu mới: [[0.0, 0.0, 0.0]]
```

Hàng mới có cột số chuẩn hóa bằng 0 vì 20 bằng median/mean của train sau điền thiếu, còn hai cột A/B đều bằng 0 vì C chưa xuất hiện. Quan trọng là không `fit_transform` lại trên từng tập: như vậy số cột và ý nghĩa cột có thể đổi, chưa kể thống kê validation bị dùng để học phép biến đổi.

HỎI NHANH

Trong code trên, nếu lỡ gọi `preprocessor.fit_transform(new_features)` thay vì `transform`, đầu ra có shape gì?

A `(1, 3)`, như cũ

B `(1, 4)`

C `(1, 2)`

D Báo lỗi, vì C chưa từng xuất hiện

Từ giả thuyết đến bằng chứng

Một đặc trưng nên có hai câu giải thích: nó được biết lúc nào, và vì sao có thể liên quan target. Ví dụ "giờ cuối tuần" có thể đổi nhu cầu; "mã đơn" có thể chỉ vô tình tăng theo thời gian. Đọc importance để tìm giả thuyết, rồi thêm/bỏ nhóm cột trên cùng fold để kiểm. Hai fold khác nhau có thể làm điểm thay đổi nhiều hơn hiệu quả đặc trưng, nên đổi split cùng lúc với đổi feature không trả lời được câu hỏi feature có ích hay không.

HỎI NHANH

Với mô hình cây, cột `order_id` đứng đầu bảng feature importance. Phản ứng hợp lý nhất là gì?

A Giữ lại, vì importance cao là feature tốt

B Nghi ngờ, vì mã có thể tăng dần theo thời gian

C Chuẩn hóa `order_id` rồi học lại

D One-hot `order_id` cho mô hình hiểu rõ hơn

Nếu predict nhiều giờ tương lai một lần, các target của những giờ đầu tương lai **chưa có** để làm lag cho giờ sau. Phải dự đoán đệ quy, thiết kế direct horizon hoặc dùng thông tin được đề cho, chứ không dùng target tương lai từ validation như thể nó là lịch sử thật. Đây là khác biệt giữa dự đoán từng bước khi mỗi giờ nhận nhãn mới và dự báo một khối tương lai; cả hai hợp lệ nhưng phải mô phỏng đúng giao thức.

Dùng thư viện

Python

```python
import numpy as np
import pandas as pd

df = pd.DataFrame({
    "time": pd.date_range("2026-10-01", periods=6, freq="h"),
    "shop": ["A", "B", "A", "A", "B", "A"],
    "sales": [5, 3, 7, 6, 4, 9],
})
df["hour_sin"] = np.sin(2 * np.pi * df["time"].dt.hour / 24)
df["hour_cos"] = np.cos(2 * np.pi * df["time"].dt.hour / 24)
df["lag_1"] = df.groupby("shop")["sales"].shift(1)
df["roll_mean_2"] = df.groupby("shop")["sales"].transform(lambda s:
s.shift(1).rolling(2).mean())
df["shop_count"] = df.groupby("shop").cumcount()  # số lần đã xuất hiện trước hàng hiện tại
print(df.drop(columns="time").round(2).to_string())
```

KẾT QUẢ

```
  shop  sales  hour_sin  hour_cos  lag_1  roll_mean_2  shop_count
0    A      5      0.00      1.00    NaN          NaN           0
1    B      3      0.26      0.97    NaN          NaN           0
2    A      7      0.50      0.87    5.0          NaN           1
3    A      6      0.71      0.71    7.0          6.0           2
4    B      4      0.87      0.50    3.0          NaN           1
5    A      9      0.97      0.26    6.0          6.5           3
```

HỎI NHANH

Hàng 4, thuộc cửa hàng B, có `lag_1 = 3` nhưng `roll_mean_2` lại là NaN. Vì sao?

A `shift` làm mất dữ liệu của B

B Trước đó B mới có một giờ bán

C Rolling tính chung cả A và B

D Do `round(2)` khi in kết quả

Khi đi thi

- **Đọc mô tả dữ liệu như đọc đề.** Mỗi cột sinh ra thế nào, đo lúc nào, có gì ở test mà không có ở train.
- **Ưu tiên đặc trưng có nghĩa**: tỉ số, thống kê theo nhóm, thời gian. Đây là nơi tăng điểm nhiều nhất cho gradient boosting.
- **Cẩn thận với target encoding và thống kê dùng nhãn**: luôn out-of-fold.
- **Soi cột ID và cột thời gian**: mã tăng dần hay ngày tạo bản ghi có thể lén mang thông tin thời gian vào mô hình.
- **Mỗi lần chỉ đổi một thứ** và so trên cùng các fold. Không có log thí nghiệm thì sau hai tiếng sẽ khó nhớ điểm tăng nhờ đâu.

Tóm tắt

- Đặc trưng là nơi kiến thức về bài toán biến thành điểm số; cách biến đổi phụ thuộc mô hình.
- Cột phân loại: one-hot, ordinal, tần suất, target encoding (out-of-fold, có làm mượt).
- Thời gian: tách thành phần, mã hóa chu kỳ bằng sin/cos; chuỗi thời gian dùng lag và rolling chỉ từ quá khứ.

- Thêm đặc trưng có kiểm chứng bằng cross-validation; luôn soát rò rỉ.

Kiểm tra cuối bài

Mười câu kiểm cả cách hiểu, phép tính và quy trình. Câu sai chỉ ra phần cần đọc lại; hãy làm trước khi mở lời giải.

CÂU 1

Cần dự đoán giá bán của ngày mai. Nếu các dữ kiện được mô tả đúng, feature nào tạo được ngay lúc dự đoán?

A Giá bán thực tế ngày mai chia cho diện tích

B Chênh lệch giữa giá dự đoán và giá bán thực tế ngày mai

C Nhóm giá chia theo target của chính ngôi nhà

D Giá của các nhà lân cận đã bán tháng trước

CÂU 2

Dự đoán số khách của một buổi hòa nhạc. Một feature là "số khách của buổi trước, nếu biết". Nên mã hóa thế nào?

A One-hot cho từng giá trị số khách

B Giữ dạng số đã chuẩn hóa, điền 0 khi không biết

C Giữ dạng số đã chuẩn hóa, thêm một cột đánh dấu khi không biết

D Bỏ cột này, vì đôi khi bị thiếu

PHỎNG THEO MIT 6.036 · Final, Spring 2022 · Q5(a)

CÂU 3

Doanh số các giờ đã biết là 4, 8, 6. Ta dự báo giờ kế tiếp, dùng trung bình trượt của hai giờ gần nhất. Feature hợp lệ bằng bao nhiêu?

A 7

B 6

C 8

D (6 + doanh số của giờ cần dự báo)/2

CÂU 4

Bảng gồm nhiều cửa hàng, các hàng chưa xếp theo thời gian. Muốn tạo lag 1 bằng `groupby("store").shift(1)`, ta phải làm gì trước?

A Sắp theo sales cho giá trị lag ổn định hơn

B Shift cả bảng trước, rồi mới group theo store

C Chỉ cần `reset_index`, vì `shift` tự đọc cột time

D Sắp theo store rồi theo time, sau đó mới shift trong từng nhóm

CÂU 5

`OneHotEncoder` fit trên hai loại A và B, với `drop=None` và `handle_unknown="ignore"`. Validation có hai loại B và C. Sau transform, hai vector là gì?

A B là `(0, 1)`, C là `(0, 0)`

B B là `(0, 1)`, C là `(1, 0)`

C B là `(0, 1, 0)`, C là `(0, 0, 1)`

D B là `(1, 0)`, C là `(0, 1)`

CÂU 6

Dữ liệu có $D = 10$ feature. Mở rộng đa thức bậc hai gồm mọi số hạng bậc một, mọi bình phương và mọi tích chéo $x_i x_j$ với $i < j$, không tính hệ số tự do. Có tất cả bao nhiêu feature mới?

A 55

B 65

C 100

D 110

PHỎNG THEO CMU 10-601 · Exam 2 Practice · Q3.1(a)

CÂU 7

Một loại hiếm chỉ có một mẫu train, với $y = 100$. Target encoding lấy trung bình theo loại trên toàn bộ train, tính cả nhãn của chính mẫu ấy. Rủi ro cụ thể là gì?

A Không sao, `StandardScaler` sẽ loại hết rò rỉ này

B Thêm nhiều cây thì encoding sẽ độc lập với y

C Feature của mẫu ấy chính là $y = 100$

D Encoding chỉ gây lỗi khi loại là chuỗi

CÂU 8

Mô hình A trên bộ fold cũ có MAE 3.0. Thêm một feature mới và đổi sang bộ fold khác thì MAE còn 2.6. Muốn biết riêng tác động của feature, ta chạy gì tiếp?

A So MAE trên train của hai mô hình, trên hai bộ fold hiện có

B Chọn bộ fold nào cho mô hình có feature mới điểm tốt nhất

C Lấy $3.0 - 2.6$ làm mức cải thiện chắc chắn do feature

D So A và A cộng feature mới trên cùng một bộ fold cố định

CÂU 9

Lúc 0 giờ, ta phải dự báo cùng lúc cả 24 giờ tới, và không nhận được nhãn nào trong khối ấy. Lag của giờ 2 có được dùng doanh số thật của giờ 1 không?

A Được, nếu dùng trung bình trượt thay vì lag đơn

B Không, vì lúc 0 giờ chưa có doanh số giờ 1

C Được, vì giờ 1 đứng trước giờ 2

D Được, nếu giờ 1 thuộc tập validation

CÂU 10

Đầu vào (x_1, x_2) được thay bằng vector feature $(1, x_1^2, x_2^2)$, rồi học logistic regression với tham số (b, w_1, w_2). Ranh giới quyết định, nơi $P(Y = 1) = P(Y = 0)$, là tập nào?

A $b + w_1 x_1^2 + w_2 x_2^2 = 0$, chẳng hạn một ellipse

B $b + w_1 x_1 + w_2 x_2 = 0$, một đường thẳng

C $w_1 x_1^2 = w_2 x_2^2$, hai đường thẳng qua gốc

D $x_1^2 + x_2^2 = 1$, luôn là đường tròn

PHỎNG THEO CMU 10-601 · Exam 2 Practice · Q2.5(a)

Đọc thêm

- Kuhn, Johnson — *Feature Engineering and Selection*, bản đọc trực tuyến miễn phí. Biểu diễn dữ liệu, lựa chọn đặc trưng và kiểm nghiệm.
- Zheng, Casari — *Feature Engineering for Machine Learning*. Từ biến đổi số, mã hóa danh mục đến văn bản.

- Géron — *Hands-On Machine Learning*, chương 2. Một dự án trọn vẹn với `ColumnTransformer` và pipeline.
- scikit-learn — Preprocessing data. Scaler, encoder, imputer và cách ghép chúng vào pipeline.
- scikit-learn — TargetEncoder. Đọc khác biệt `fit_transform` với `fit` rồi `transform` và cơ chế cross-fitting.