Tensor và autograd

Làm quen PyTorch và GPU.

> Một nhóm học sinh muốn dự đoán thời gian chạy của lời giải từ ba đặc trưng: số đỉnh, số cạnh và số truy vấn. Trong C++, có thể lưu dữ liệu bằng `vector<array<double, 3>>`. Sang PyTorch, cùng bảng ấy trở thành tensor. Điều mới không chỉ là cú pháp: PyTorch còn ghi lại phép tính để trả lời câu hỏi "nên chỉnh mỗi trọng số bao nhiêu để dự đoán bớt sai?". Bài này nối mảng nhiều chiều với đồ thị tính toán, rồi kiểm một gradient bằng tay trước khi giao việc cho autograd.

MỤC TIÊU SAU BÀI NÀY

- Đọc shape theo ý nghĩa từng chiều và dự đoán shape trước khi chạy code.
- Phân biệt phép nhân từng phần tử, nhân ma trận, reshape và hoán đổi chiều.
- Tính gradient của một biểu thức nhỏ, kiểm autograd và xóa gradient đúng lúc.
- Phân biệt `detach`, `no_grad`, bản sao dữ liệu và chuyển thiết bị CPU/GPU.

Từ mảng C++ tới tensor

Tensor là một khối số có shape, kiểu dữ liệu (dtype) và nơi lưu (device). Một số có shape `()`, một vector ba số có shape `(3,)`, bảng hai hàng ba cột có shape `(2, 3)`. Ba thuộc tính ấy là phần hợp đồng đầu vào của phép tính, giống kích thước mảng và kiểu số trong một lời giải CP. Tensor không tự biết chiều nào là học sinh, token hay đặc trưng; người viết phải đặt ý nghĩa đó.

Trọng số và đặc trưng thường dùng `float32`; mã lớp hoặc token ID dùng `int64`, còn gọi là `torch.long`. Tensor số nguyên không thể đặt `requires_grad=True`, vì đạo hàm chỉ có nghĩa trên số thực. `torch.tensor` suy dtype từ dữ liệu, nên chỉ một dấu chấm thập phân cũng đổi kiểu của cả tensor. Ví dụ dưới dùng số nhỏ để tính tay được: một bảng hai mẫu, chiếu sang hai đặc trưng mới.

```
Python
```

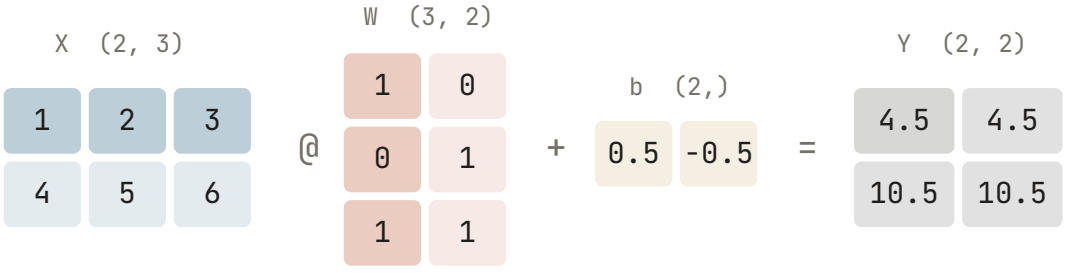
```python
import torch

torch.set_num_threads(1)
torch.manual_seed(7)
X = torch.tensor([[1., 2., 3.], [4., 5., 6.]])
W = torch.tensor([[1., 0.], [0., 1.], [1., 1.]])
b = torch.tensor([0.5, -0.5])
Y = X @ W + b
print(tuple(X.shape), X.dtype, X.device)
print(Y.tolist())
print(torch.tensor([1, 2, 3]).dtype, torch.tensor([1., 2., 3.]).dtype)
```

KẾT QUẢ

```
(2, 3) torch.float32 cpu
[[4.5, 4.5], [10.5, 10.5]]
torch.int64 torch.float32
```

Dòng đầu cho cả shape, dtype và device. Dòng thứ hai gồm hai hàng vì ta vẫn có hai mẫu. Với hàng đầu, đầu ra thứ nhất là $1 + 3 + 0.5 = 4.5$; đầu ra thứ hai là $2 + 3 - 0.5 = 4.5$. Bias `(2,)` được cộng vào từng hàng. `@` gộp chiều đặc trưng, còn `X * X` chỉ bình phương từng ô. Dòng cuối cho thấy dtype đi theo dữ liệu: `[1, 2, 3]` thành `int64`, `[1., 2., 3.]` thành `float32`.



X @ W + b: hàng đầu của X nhân cột đầu của W rồi cộng bias cho ô 4.5; chiều 3 bị gộp, hai mẫu giữ nguyên.

Đại lượng	Ý nghĩa	Shape
`X`	B mẫu, mỗi mẫu d đặc trưng	`(B, d)`
`W`	d đầu vào thành h đầu ra	`(d, h)`

Đại lượng	Ý nghĩa	Shape
`b`	Bias cho từng đầu ra	`(h,)`
`X @ W + b`	Đặc trưng mới của từng mẫu	`(B, h)`

HỎI NHANH

`X` có shape `(8, 3)`, `W` có shape `(3, 5)`. `X @ W` có shape gì?

A `(3, 3)`

B `(5, 8)`

C `(8, 5)`

D `(8, 3, 5)`

Shape đúng phải đi cùng ý nghĩa đúng

Khi xử lý chuỗi, tensor thường là `(B, L, d)`: batch, độ dài, đặc trưng. `reshape` chia lại cách nhìn một dãy phần tử; nó không đổi thứ tự logic của dãy. `transpose` hoặc `permute` mới hoán đổi các trục. Đây giống khác biệt giữa đánh lại chỉ số của mảng một chiều và chuyển vị thật một bảng hai chiều.

Python

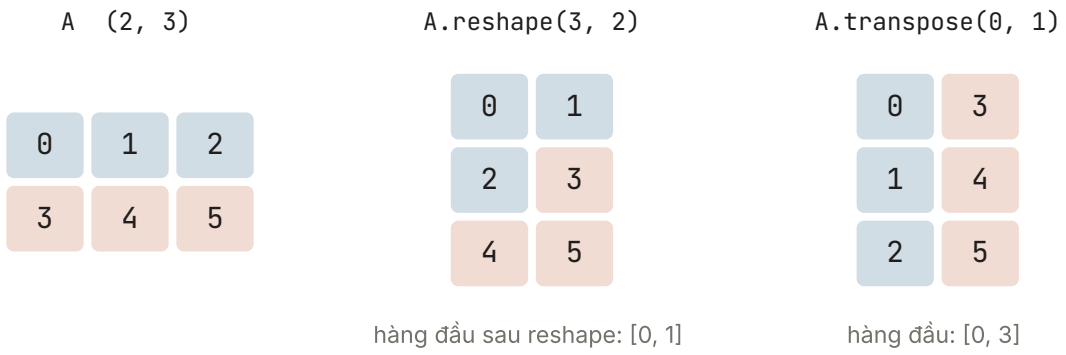
```
A = torch.arange(6).reshape(2, 3)
print(A.tolist())
print(A.reshape(3, 2).tolist())
print(A.transpose(0, 1).tolist())
print(A.unsqueeze(0).shape, A.sum(dim=1).shape)
```

KẾT QUẢ

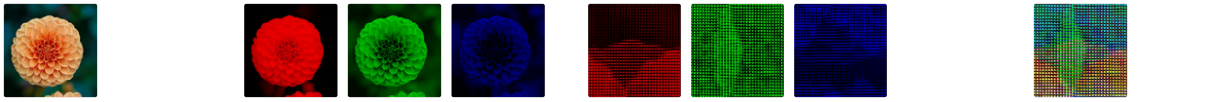
```
[[0, 1, 2], [3, 4, 5]]
[[0, 1], [2, 3], [4, 5]]
```

```
[[0, 3], [1, 4], [2, 5]]
torch.Size([1, 2, 3]) torch.Size([2])
```

So hai bảng `(3, 2)`: reshape gom hai phần tử liên tiếp thành một hàng; transpose lấy các cột cũ làm hàng mới. Shape bằng nhau không bảo đảm dữ liệu mang cùng nghĩa. `unsqueeze(0)` thêm chiều batch kích thước 1; `sum(dim=1)` gộp ba cột của mỗi hàng. `squeeze(0)` chỉ xóa chiều 0 nếu nó bằng 1. Tránh dùng `squeeze()` không chỉ định chiều khi batch có thể bằng 1: chiều batch có thể mất ngoài ý muốn.



Cùng shape (3, 2), khác nội dung: reshape giữ thứ tự 0, 1, 2, ...; transpose đưa cột cũ thành hàng mới (màu là hàng gốc của A).



x: shape (96, 96, 3), kênh màu ở chiều cuối

`x.permute(2, 0, 1)`: (3, 96, 96), ba lát là đúng ba kênh R, G, B

`x.reshape(3, 96, 96)`: cũng (3, 96, 96), nhưng mỗi "kênh" là một phần ba dãy số, trộn cả R, G, B

xem lại kết quả reshape như một ảnh: hình bị xé thành sọc

Ảnh hoa thật đổi từ (H, W, 3) sang (3, H, W): permute giữ đúng ba kênh màu; reshape cho cùng shape nhưng trộn lẫn các kênh.

HỎI NHANH

Bảng `A` có shape `(2, 3)`. Muốn đổi thành `(3, 2)` sao cho các cột cũ thành hàng mới, ta dùng gì?

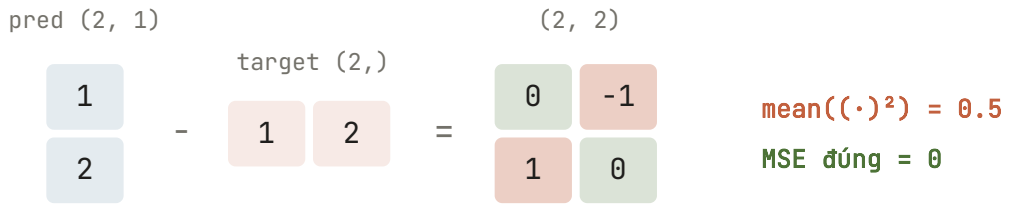
A `A.reshape(3, 2)`

B `A.view(3, 2)`

C `A.unsqueeze(0)`

D `A.transpose(0, 1)`

Broadcasting cũng cần kiểm. Phép cộng `(B, h)` với `(h,)` có ý nghĩa bias; phép trừ dự đoán `(B, 1)` với nhãn `(B,)` lại tạo `(B, B)`. Máy không hiểu ta định so từng mẫu. Đặt `assert prediction.shape == target.shape` trước loss hồi quy là một kiểm tra rẻ nhưng hữu ích. Shape chỉ đủ để chứng minh phép toán hợp lệ; tên chiều và thứ tự mẫu mới chứng minh phép toán đang giải bài toán cần giải.



mỗi dự đoán bị trừ cho mọi nhãn; chỉ đường chéo là cặp đúng

Trừ (2, 1) cho (2,) không báo lỗi mà broadcast thành (2, 2): hai ô lệch đường chéo làm MSE thành 0.5 thay vì 0.

HỎI NHANH

Dự đoán `pred = [[1.], [2.]]`, shape `(2, 1)`, khớp đúng nhãn `target = [1., 2.]`, shape `(2,)`. Vậy mà `((pred - target) ** 2).mean()` lại in ra `0.5`. Vì sao?

A `float32` làm tròn 1 và 2 nên hiệu khác 0

B Phép trừ bị broadcast thành `(2, 2)`, so mọi cặp với nhau

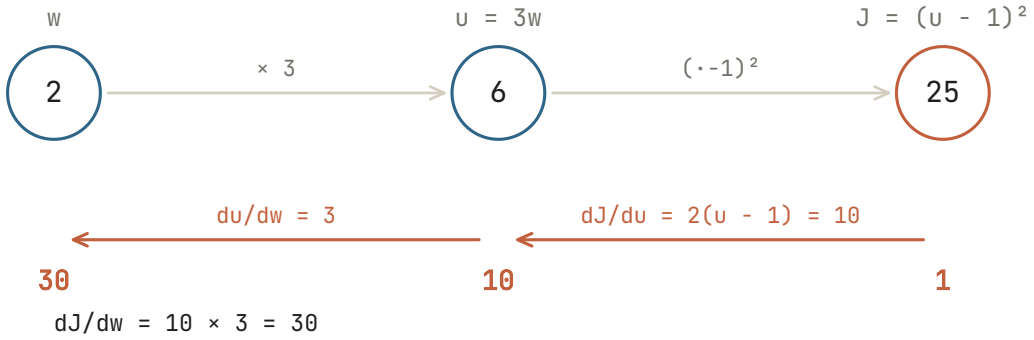
C Nhãn phải có kiểu `long` thì phép trừ mới đúng

D `mean()` chia thêm cho chiều thứ hai

Autograd lưu đường đi của phép tính

Trong bài linear regression, ta tự viết gradient. Với mạng nhiều lớp, biểu thức dài hơn nhưng mỗi phép cục bộ vẫn nhỏ: nhân, cộng, bình phương, ReLU. Autograd ghép đạo hàm cục bộ bằng quy tắc hàm hợp. Nó tính đạo hàm của phép tính đã thực hiện, không tìm công thức tối ưu và không tự sửa trọng số.

Hình dung một DAG trong CP. Forward tính các đỉnh theo thứ tự topo, lưu giá trị cần thiết. Backward đi ngược DAG, truyền độ nhạy của loss về các đầu vào. Nếu một biến góp mặt ở nhiều nhánh, các đóng góp gradient được **cộng**, giống cộng số đường đi từ các nhánh tới một đỉnh. PyTorch dựng DAG ngay trong lúc forward chạy và dựng lại ở mỗi lần forward (đồ thị động). Vì vậy `if` hay vòng lặp Python trong forward không cản autograd: backward đi theo đúng nhánh đã thực sự chạy.



Forward tính 2 → 6 → 25; backward đi ngược, nhân các đạo hàm cục bộ: dJ/dw = 10 × 3 = 30.

HỎI NHANH

Cho `x = torch.tensor(-3., requires_grad=True)`, rồi `y = 2 * x if x > 0 else x ** 2` và `y.backward()`. `x.grad` bằng bao nhiêu?

A `-6.0`, đạo hàm của nhánh `x ** 2`

B `2.0`, đạo hàm của nhánh `2 * x`

C `-2.0`, trung bình đạo hàm của hai nhánh

D Báo lỗi, vì graph phải cố định trước khi forward

Ví dụ tính tay

Đặt $w = 2$, $u = 3w$, $J = (u-1)^2$. Forward cho $u = 6$, $J = 25$. Nếu tăng w một lượng rất nhỏ, u tăng ba lần lượng đó. Còn J nhạy với u một lượng $2(u-1) = 10$. Vì vậy

$$\frac{dJ}{dw} = \frac{dJ}{du}\frac{du}{dw} = 2(u-1)\cdot 3 = 30.$$

Gradient dương nói rằng tăng w một chút sẽ làm loss tăng tại điểm đang xét. Muốn đi xuống, gradient descent dùng $w \leftarrow w - \eta\, 30$. Với $\eta = 0.01$, một bước cho $w = 1.7$; đó là phép cập nhật riêng, không thuộc `backward()`.

Python

```python
w = torch.tensor(2., requires_grad=True)
u = 3 * w
J = (u - 1) ** 2
J.backward()
print(round(J.item(), 2), round(w.grad.item(), 2))
with torch.no_grad():
    w -= 0.01 * w.grad
print(round(w.item(), 2))
```

KẾT QUẢ

```
25.0 30.0
1.7
```

Hai số ở dòng đầu cần khớp 25 và 30 đã tính tay; dòng sau kiểm phép cập nhật 1.7. `requires_grad=True` yêu cầu ghi đường tính toán liên quan. `w` là tensor lá do ta tạo trực tiếp; gradient được tích vào `w.grad`. Tensor trung gian không mặc định giữ `.grad`; điều đó không có nghĩa đường đạo hàm qua nó bị mất. `J` là scalar nên `backward()` biết bắt đầu từ độ nhạy 1. Với đầu ra vector, cần chọn cách gộp thành scalar hoặc cung cấp vector gradient phù hợp.

HỎI NHANH

Vẫn $J = (3w - 1)^2$, nhưng tại $w = 0$. Gradient bằng bao nhiêu, và một bước gradient descent đẩy w theo hướng nào?

A 6, giảm w, tức đi ngược dấu gradient

B 6, tăng w, tức đi theo dấu gradient

C -6, giảm w, tức đi theo dấu gradient

D -6, tăng w, tức đi ngược dấu gradient

Gradient được cộng dồn

PyTorch cộng gradient mới vào `.grad`. Cách này cho phép tích lũy nhiều microbatch, nhưng trong training loop bình thường ta phải xóa trước mỗi bước. Sau `backward()`, PyTorch giải phóng các giá trị trung gian của graph, nên mỗi lượt dưới đây có forward riêng:

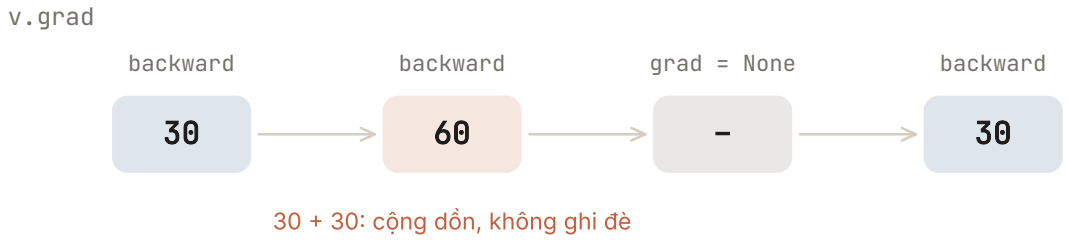
Python

```
v = torch.tensor(2., requires_grad=True)
((3 * v - 1) ** 2).backward()
print(v.grad.item())
((3 * v - 1) ** 2).backward()
print(v.grad.item())
v.grad = None
((3 * v - 1) ** 2).backward()
print(v.grad.item())
```

KẾT QUẢ

```
30.0
60.0
30.0
```

Dãy 30, 60, 30 cho thấy gradient cộng dồn và phép xóa đã hoạt động. Trong training loop, việc xóa do `optimizer.zero_grad(set_to_none=True)` đảm nhận. Gọi `backward()` hai lần trên cùng một graph sẽ báo lỗi; đừng sửa bằng `retain_graph=True`: giữ graph tốn bộ nhớ, không xóa gradient cũ, và graph cũ vẫn mô tả trọng số cũ. Mỗi bước huấn luyện cần forward mới rồi backward mới.



Mỗi lần backward cộng thêm vào v.grad: 30 rồi 60; đặt grad = None xong thì lượt mới lại ra 30.

HỎI NHANH

Một bạn tính `loss` một lần trước vòng lặp, rồi mỗi epoch gọi `loss.backward()` và `optimizer.step()`. Sang epoch thứ hai thì báo `RuntimeError: Trying to backward through the graph a second time`. Sửa thế nào?

A Thêm `retain_graph=True` để graph không bị giải phóng

B Gọi `optimizer.zero_grad()` trước lần `backward()` thứ hai

C Đưa forward và phép tính `loss` vào trong vòng lặp

D Đổi thành `loss.detach().backward()` để tách khỏi graph cũ

Detach, no_grad và bản sao

Khi lưu dự đoán để tính metric, ta không muốn giữ cả đường tính toán. `detach()` tạo tensor không nối gradient về nguồn. Nó vẫn có thể dùng chung vùng nhớ với tensor gốc; muốn lưu snapshot độc lập, dùng `detach().clone()`. `no_grad()` tạm ngừng ghi graph cho các phép trong khối, thích hợp cho suy luận hoặc cập nhật thủ công. Nó không tự chuyển model sang `eval()`; chế độ layer sẽ học ở bài 3.4 và 3.6.

Ta kiểm ý nghĩa "cắt đường gradient" bằng biểu thức v^3. Nếu giữ cả hai nhánh, đạo hàm tại $v = 2$ là $3v^2 = 12$. Nếu tính v^2 rồi detach, hệ số 4 ấy được coi như hằng số:

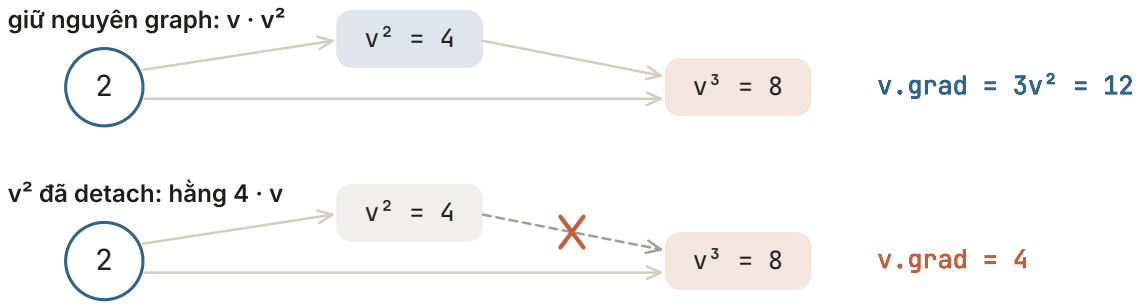
Python

```
v.grad = None
square = v ** 2
frozen_square = square.detach()
(frozen_square * v).backward()
print(v.grad.item(), frozen_square.requires_grad)
snapshot = square.detach().clone()
print(snapshot.item())
```

KẾT QUẢ

```
4.0 False
4.0
```

Gradient 4 là đúng với **graph đã bị cắt**, dù giá trị forward vẫn bằng 8. Detach không phải thủ thuật sửa lỗi backward mà không đổi bài toán: nó có thể làm tham số trước điểm cắt không học được. Chuyển tensor cần gradient sang NumPy cũng nên viết `tensor.detach().cpu().numpy()` khi chỉ phục vụ phân tích. Với một số đơn lẻ như loss, `loss.item()` trả về số Python; ghi log bằng số này không giữ graph.



Cùng giá trị forward 8: giữ graph thì gradient là 12; detach v² thì đường qua v² bị cắt, chỉ còn 4.

HỎI NHANH

`w` bằng 2 và đã có `w.grad` bằng 30. Chạy `snap = w.detach()`, rồi `with torch.no_grad(): w -= 0.1 * w.grad`. `snap.item()` in ra gì?

A `2.0`, vì `snap` đã tách khỏi graph

B `2.0`, vì `no_grad` không làm đổi giá trị của `w`

C `-1.0`, vì `snap` dùng chung vùng nhớ với `w`

D Báo lỗi, vì tensor đã detach thì không đọc được

Thiết bị và nơi lưu dữ liệu

GPU thực hiện nhiều phép số song song, nhưng mọi tensor trong một phép tính phải cùng device. Với tensor, `.to(device)` trả về **tensor mới** trên device đã chọn, nên phải gán lại: `X = X.to(device)`. Với model, `model.to(device)` chuyển tham số và buffer của module tại chỗ. Đoạn sau chọn CUDA khi có, nếu không thì dùng CPU; các dòng còn lại không phụ thuộc máy:

Python

```
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
X_device = X.to(device)
linear = torch.nn.Linear(3, 2).to(device)
with torch.no_grad():
    result = linear(X_device)
print(str(device), tuple(result.shape))
print(result.detach().cpu().numpy().shape)
```

KẾT QUẢ

```
cpu (2, 2)
(2, 2)
```

Máy chạy bài không có CUDA nên dòng đầu in `cpu`; trên máy có CUDA hoạt động, cùng đoạn code chọn `cuda` mà không phải sửa dòng nào. Dòng hai đi theo đường thường dùng khi lấy kết quả ra phân tích: ngắt graph, chép về CPU, rồi mới sang NumPy. Tên GPU trong mô tả môi trường chưa đủ chứng minh CUDA dùng được; `torch.cuda.is_available()` cùng một batch chạy thử mới xác nhận. GPU cũng không tự nhanh hơn: với dữ liệu rất nhỏ, thời gian chép dữ liệu và khởi động có thể lớn hơn phần tính. Bài 3.7 có recipe đo thời gian mỗi bước trên máy CUDA.

HỎI NHANH

Model đã gọi `model.to('cuda')`. Trong vòng lặp có dòng `X.to('cuda')`, không gán lại, rồi `model(X)`, và PyTorch báo các tensor nằm trên hai device khác nhau. Vì sao?

A `X.to` trả về một bản mới, còn `X` cũ vẫn ở CPU

B `model.to` cũng phải gán lại thì model mới chuyển

C Phải dùng `X.cuda()`, vì `.to` chỉ đổi dtype

D Batch quá nhỏ nên PyTorch giữ `X` ở CPU

Bẫy cài đặt

Lỗi shape thường xuất hiện xa nơi tạo tensor. In shape tại ranh giới `dataset → model → loss`, rồi giảm về một batch để truy ra chiều sai. Nếu mô hình nhị phân cho `(B, 1)`, hãy dùng `squeeze(-1)` và nhãn `(B,)`; đừng xóa mọi chiều 1. Kiểm dtype của nhãn trước khi gọi loss và device trước nhân ma trận. Khi gradient bằng `None`, lần theo chỗ detach, no_grad, phép ép sang số Python hoặc tham số không tham gia forward.

Trong CP, một phép ép kiểu sai có thể âm thầm tràn số. Với AI, một broadcast sai có thể âm thầm đổi hàm mục tiêu. Vì vậy bộ kiểm nhỏ gồm shape, tính tay và gradient là phần tương đương với brute force để đối chiếu. Chỉ khi một mẫu nhỏ đúng mới tăng batch, thêm lớp và chuyển GPU.

HỎI NHANH

Tính tay $J = (3w - 1)^2 + w$ tại $w = 2$ được $dJ/dw = 31$, nhưng autograd lại in `1.0`. Forward viết:

```
u = torch.tensor(3 * w.item())
J = (u - 1) ** 2 + w
```

Nguyên nhân là gì?

A Tính tay sai, vì số hạng $+w$ chỉ đóng góp 1

B `.item()` đổi sang số Python, cắt mất đường đi qua `u`

C `torch.tensor` tạo `u` kiểu `int64` nên mất đạo hàm

D Thiếu `retain_graph=True` để giữ nhánh đi qua `u`

Khi đi thi

- **In shape ở ranh giới.** In shape sau dataset, sau model và trước loss; đặt `assert pred.shape == target.shape` cho hồi quy. Dùng `squeeze(-1)`, không dùng `squeeze()` khi batch có thể bằng 1.
- **Kiểm dtype theo loss.** Nhãn lớp cho cross-entropy là `long`; nhãn hồi quy và nhãn của BCE là `float`. `torch.tensor` suy dtype từ dữ liệu, nên đọc dtype ngay khi tạo tensor từ list hay CSV.
- **Một batch trước khi tiêu ngân sách GPU.** Chạy forward và backward trên một batch: loss hữu hạn, gradient của mọi tham số cần học khác `None`, rồi mới chạy cả epoch.
- **Code không gắn với máy.** Đặt `device` một chỗ, chuyển model, input và nhãn bằng `.to(device)`; không gõ cứng `.cuda()`, để notebook vẫn chạy khi máy chấm chỉ có CPU.

- **Suy luận trong `no_grad`, ghi log bằng `.item()`.** Dự đoán cho submission đưa về `.detach().cpu()` trước khi ghép; loss ghi bằng `.item()` để không giữ graph qua hàng nghìn bước.

Tóm tắt

Tensor là mảng kèm shape, dtype và device. Autograd ghi DAG của forward, rồi cộng gradient theo các đường ở backward. `backward()` chưa cập nhật trọng số; `.grad` cần xóa đúng chu kỳ. `detach()` cắt graph, `clone()` tạo bản sao, `.item()` lấy ra số Python, `no_grad()` ngừng ghi graph cho một khối. Những kiểm tra ấy giữ nguyên khi mạng trở nên phức tạp hơn.

Kiểm tra cuối bài

CÂU 1

Batch embedding `E` có shape `(4, 6, 8)`: 4 câu, mỗi câu 6 token, mỗi token 8 đặc trưng. Muốn mỗi câu có một vector bằng trung bình các token, ta gọi `E.mean(dim=?)`, và nhận được shape gì?

A `dim=0`, shape `(6, 8)`

B `dim=1`, shape `(4, 8)`

C `dim=1`, shape `(4, 1, 8)`

D `dim=2`, shape `(4, 6)`

CÂU 2

`a = torch.tensor([1, 2, 3])` và `b = torch.Tensor([1, 2, 3])`. Hai tensor này có dtype gì?

A a là `float32`, b là `float32`

B a là `int64`, b là `int64`

C a là `int64`, b là `float32`

D a là `float32`, b là `int64`

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 129

CÂU 3

`x = torch.tensor([1., -2., 3.], requires_grad=True)`, `loss = (x ** 2).mean()`, rồi `loss.backward()`. `x.grad` bằng bao nhiêu, làm tròn hai chữ số?

A `[0.67, -1.33, 2.00]`

B `[2.00, -4.00, 6.00]`

C `[0.33, 1.33, 3.00]`

D `4.67`

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 53

CÂU 4

Một model khai báo ba lớp `fc1`, `fc2`, `fc3` trong `__init__`, nhưng `forward` chỉ gọi `fc1` rồi `fc2`. Sau `loss.backward()`, `fc3.weight.grad` là gì?

A Tensor toàn 0, vì `fc3` không ảnh hưởng tới loss

B `None`, vì `fc3` không có trong đồ thị của forward

C Gradient bình thường, vì `fc3` có trong `model.parameters()`

D Báo lỗi lúc backward, vì có tham số không được dùng

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 54

CÂU 5

Huấn luyện full-batch trên dữ liệu cố định. Mỗi epoch gọi `optimizer.zero_grad()`, tính `loss`, gọi `loss.backward()`, nhưng quên `optimizer.step()`. Loss in ra qua các epoch sẽ thế nào?

A Giảm chậm, vì backward tự cập nhật với learning rate mặc định

B Tăng dần, vì gradient cộng dồn qua các epoch

C Không đổi, vì backward chỉ tính gradient

D Thành NaN, vì graph cũ không được giải phóng

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 120

CÂU 6

Một bạn khởi tạo `w = torch.randn(3, requires_grad=True) * 0.01`, tính loss rồi gọi `backward()`. `w.grad` là `None`, và PyTorch đưa ra cảnh báo. Vì sao?

A `w` được sinh ra từ một phép nhân, không phải tensor lá

B Nhân với 0.01 làm mất `requires_grad` của `w`

C `torch.randn` tạo tensor không hỗ trợ đạo hàm

D Gradient quá nhỏ nên bị làm tròn thành `None`

CÂU 7

`loss` là tensor 0 chiều, `logits` là tensor `(32, 10)`, cả hai còn nối với graph. Ta muốn (a) ghi loss vào log dưới dạng số Python, và (b) giữ `logits` ở dạng tensor nhưng không giữ graph. Gọi gì?

A (a) `loss.detach()`, (b) `logits.detach()`

B (a) `loss.detach()`, (b) `logits.item()`

C (a) `loss.item()`, (b) `logits.item()`

D (a) `loss.item()`, (b) `logits.detach()`

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 145

CÂU 8

Hàm dự đoán tập test chạy `preds.append(model(xb))` cho 2000 batch trên GPU. Bộ nhớ tăng dần rồi báo out of memory, dù batch nào cũng rất nhỏ. Sửa thế nào?

A Gọi `optimizer.zero_grad()` sau mỗi batch dự đoán

B Giảm batch size xuống một nửa rồi chạy lại

C Gọi `torch.cuda.empty_cache()` sau mỗi batch

D Chạy trong `torch.no_grad()`, và lưu kết quả bằng `.cpu()`

CÂU 9

`X` có shape `(64, 10)`: 64 mẫu, mỗi mẫu 10 đặc trưng. Để trừ mỗi hàng cho trung bình của chính hàng đó, một bạn viết `m = X.mean(dim=1)` rồi `X - m`. Kết quả thế nào?

A Báo lỗi, vì `(64, 10)` và `(64,)` không broadcast được

B Chạy đúng, mỗi hàng trừ trung bình của chính nó

C Chạy được, nhưng ra `(64, 64)`, so mọi cặp mẫu

D Chạy được, nhưng trừ trung bình theo từng cột

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 104

CÂU 10

Model có tham số trên CUDA, `X` đang ở CPU, và `y` là nhãn lớp kiểu `long` dùng cho cross-entropy. Muốn train một batch trên CUDA, ta làm gì?

A Chỉ chuyển `X`, vì hàm loss tự chuyển `y` theo input

B Chuyển cả `X` lẫn `y` tới device của model

C Gọi `model.eval()` để tự đồng bộ device của input

D Đổi `y` sang `float` để loss nhận nhãn ở CPU

Đọc thêm

- PyTorch — Automatic Differentiation: đọc về graph động, gradient cộng dồn và cách tắt theo dõi.
- D2L — Forward/Backward Propagation: xem đồ thị tính toán như cầu nối từ đạo hàm một biến sang mạng.
- PyTorch 2.9 — Tensor: tra shape, dtype, device và các thao tác tensor trước khi ghép model lớn.

Nguồn ảnh: ảnh hoa là ảnh mẫu `flower.jpg` kèm scikit-learn (vultilion, Flickr, CC BY 2.0).