# Training loop

Trắc nghiệm 28 Thực hành 2 PDF bài

> Một mạng nhỏ đã cho loss giảm đẹp trong notebook. Nhưng đóng notebook rồi mở lại, kết quả đổi: model mới được khởi tạo ngẫu nhiên, mean/std thất lạc, dropout vẫn bật. “Loss giảm” chưa đủ để có một chương trình dùng được. Bài này xây cả đường đi từ dữ liệu tới checkpoint và suy luận ở một tiến trình mới; mỗi bước có một hợp đồng kiểm được.

MỤC TIÊU SAU BÀI NÀY

- Dùng Dataset/DataLoader và phân biệt batch, step, epoch.
- Viết loop theo thứ tự zero_grad → forward → loss → backward → step.
- Chấm validation ở eval/no_grad, lưu trạng thái có điểm tốt nhất.
- Khôi phục kiến trúc và tiền xử lý, kiểm kết quả ở tiến trình Python mới.

## Một bài nhỏ để kiểm toàn bộ quy trình

Ta tự sinh 96 điểm hai đặc trưng; nhãn là 1 nếu $x_1 + 0.5x_2 > 0$, còn lại là 0. Quy tắc đã biết trước, nên nếu kết quả tệ thì lỗi nằm ở pipeline chứ không phải ở độ khó của dữ liệu. Chia train/validation trước; mean/std chỉ tính trên train và được dùng lại trên validation.

Python

```python
from pathlib import Path
import json
import subprocess
import sys
import torch
from torch import nn
from torch.utils.data import TensorDataset, DataLoader

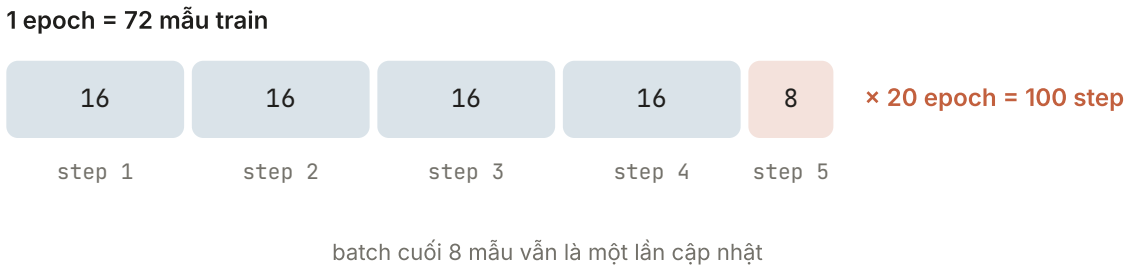
torch.set_num_threads(1)
torch.manual_seed(21)
torch.use_deterministic_algorithms(True)
```

```
generator = torch.Generator().manual_seed(21)
raw_X = torch.randn(96, 2, generator=generator)
y = (raw_X[:, 0] + .5 * raw_X[:, 1] > 0).long()
order = torch.randperm(96, generator=generator)
train_id, valid_id = order[:72], order[72:]
mean = raw_X[train_id].mean(dim=0)
scale = raw_X[train_id].std(dim=0, unbiased=False).clamp_min(1e-6)
X = (raw_X - mean) / scale
train_data = TensorDataset(X[train_id], y[train_id])
valid_data = TensorDataset(X[valid_id], y[valid_id])
train_loader = DataLoader(train_data, batch_size=16, shuffle=True,
    generator=torch.Generator().manual_seed(21), num_workers=0)
valid_loader = DataLoader(valid_data, batch_size=16, shuffle=False, num_workers=0)
print(len(train_data), len(valid_data), len(train_loader))
print(tuple(next(iter(valid_loader))[0].shape))
```

KẾT QUẢ

```
72 24 5
(16, 2)
```

Có 72 mẫu train, 24 validation và 5 batch mỗi epoch: bốn batch 16 mẫu, một batch 8 mẫu. Batch là một nhóm dùng cho một phép gradient; step là một lần cập nhật optimizer; epoch là một lần duyệt tập train. Một epoch không phải một step khi dùng minibatch. `TensorDataset` gom các tensor cùng chiều đầu; dataset thực tế có thể tự đọc tệp ở `__getitem__`. DataLoader ghép các mẫu và quyết định thứ tự lấy. Một epoch có $\lceil n/B \rceil$ step: 10 000 ảnh với batch 64 là 157 step; 1000 mẫu, batch 32, 5 epoch là $32 \cdot 5 = 160$ lần cập nhật. Với `shuffle=True`, thứ tự được xáo lại ở đầu mỗi epoch; tập train xếp sẵn hết mèo rồi mới tới chó mà không xáo thì mỗi đoạn batch chỉ thấy một lớp, và mô hình bị kéo qua lại giữa hai lớp.




72 mẫu train, batch size 16: mỗi epoch có 5 batch (bốn batch 16 và một batch 8), mỗi batch một step, nên 20 epoch là 100 step.

Ở Windows, nhiều worker có thể tạo tiến trình con và yêu cầu bảo vệ code bằng `if __name__ == '__main__'`. Ví dụ đầu tiên dùng `num_workers=0` để dễ chạy nối tiếp trong notebook. Việc tăng worker nên dựa trên đo nút nghẽn, không phải mặc định "càng nhiều càng nhanh".

HỎI NHANH

Train có 72 mẫu, batch size 16, không bỏ batch cuối. Train 20 epoch thì optimizer cập nhật bao nhiêu lần?

A 20

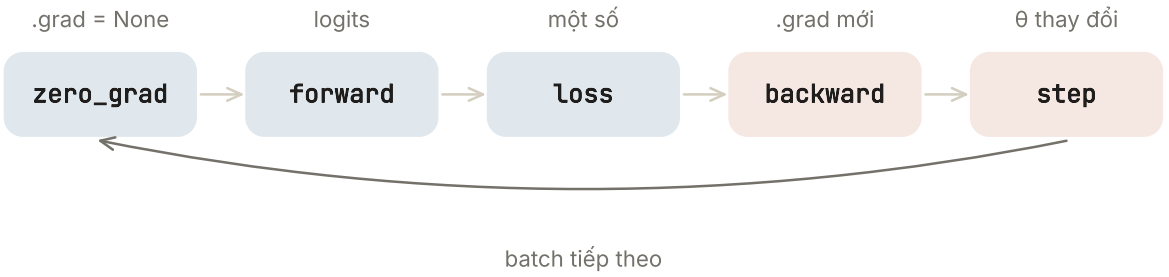
B 80

C 100

D 1440

## Loop là một chu trình trạng thái

`zero_grad` xóa gradient cũ. Forward dùng trọng số hiện tại để tạo logits, loss so logits với nhãn, backward tính gradient, step mới sửa trọng số. Đảo step lên trước backward thì optimizer dùng gradient cũ hoặc không có gradient. Gọi zero_grad sau backward trước step thì xóa chính tín hiệu vừa tính. Optimizer được tạo từ `model.parameters()`, tức các trọng số và bias sẽ được chỉnh, và nó quyết định chỉnh theo cách nào (SGD, Adam ở bài 3.5). Nếu cần cắt gradient bằng `clip_grad_norm_`, đặt nó sau backward và trước step.




đổi thứ tự backward / zero_grad / step là mất hoặc dùng sai gradient

Mỗi batch đi đúng một vòng zero_grad → forward → loss → backward → step rồi mới sang batch tiếp theo.

Vì sao phải xóa? Backward không ghi đè `.grad` mà **cộng** gradient mới vào đó. Với hàm $\mathbf{x}^\top \mathbf{w}$, gradient theo $\mathbf{w}$ chính là $\mathbf{x}$, nên dễ nhìn thấy điều này:

Python

```
w = torch.zeros(2, requires_grad=True)
for xi in [torch.tensor([1., 2.]), torch.tensor([3., -1.])]:
    (xi @ w).backward()
    print(w.grad.tolist())
```

KẾT QUẢ

```
[1.0, 2.0]
[4.0, 1.0]
```

Lần thứ hai `.grad` là $[1, 2] + [3, -1] = [4, 1]$, không phải $[3, -1]$. Thiếu `zero_grad`, mỗi step dùng tổng gradient của mọi batch đã qua, nên bước cập nhật lớn dần. Cộng dồn có chủ ý lại là một kỹ thuật: gradient accumulation (bài 3.7) gom gradient vài batch nhỏ rồi mới step một lần.

HỎI NHANH

Một vòng lặp gọi `loss.backward()`, rồi `optimizer.zero_grad(set_to_none=True)`, rồi `optimizer.step()`. Train loss đứng yên ở mức ban đầu qua mọi epoch, và không có lỗi nào. Vì sao?

A Learning rate quá nhỏ nên mỗi bước gần như không đổi gì

B Gradient bị xóa trước `step()`, nên không có gì để cập nhật

C Gradient cộng dồn qua các batch nên các bước triệt tiêu nhau

D Backward chưa chạy xong vì `zero_grad` được gọi ngay sau nó

Model có hai lớp linear xen ReLU. Loss nhận logits `(B,2)` và nhãn long `(B,)`. Ta gom code train một epoch thành một hàm. Loss báo cáo nhân batch size trước khi cộng, để batch cuối nhỏ không được tính ngang trọng lượng với batch đầy:

Python

```python
def make_model():
    return nn.Sequential(nn.Linear(2, 8), nn.ReLU(), nn.Linear(8, 2))

model = make_model()
optimizer = torch.optim.Adam(model.parameters(), lr=.03)
criterion = nn.CrossEntropyLoss()

def train_epoch(model, loader, optimizer):
    model.train()
    loss_sum = 0.
    seen = 0
    for xb, yb in loader:
        optimizer.zero_grad(set_to_none=True)
        logits = model(xb)
        assert logits.shape == (len(yb), 2)
        loss = criterion(logits, yb)
        assert torch.isfinite(loss)
        loss.backward()
        optimizer.step()
        loss_sum += loss.item() * len(yb)
        seen += len(yb)
```

```
    return loss_sum / seen

def evaluate(model, loader):
    model.eval()
    loss_sum = 0.
    correct = 0
    seen = 0
    with torch.no_grad():
        for xb, yb in loader:
            logits = model(xb)
            loss_sum += criterion(logits, yb).item() * len(yb)
            correct += (logits.argmax(dim=1) == yb).sum().item()
            seen += len(yb)
    return loss_sum / seen, correct / seen

print('initial validation:', tuple(round(v, 4) for v in evaluate(model, valid_loader)))
```

KẾT QUẢ

```
initial validation: (0.7394, 0.4583)
```

Trước khi học, accuracy $0.4583 = 11/24$, gần mức đoán bừa của hai lớp, và loss $0.7394$ gần $\ln 2 \approx 0.693$, loss của một model chia đều xác suất cho hai lớp. Đó là điểm xuất phát đúng. Với $K$ lớp, loss ban đầu lệch xa $\ln K$ là dấu hiệu nên kiểm khởi tạo hoặc nhãn trước khi train.

Hai `assert` trong `train_epoch` là hợp đồng rẻ: logits đúng shape `(B,2)` và loss hữu hạn. Loss thành `nan` thường do learning rate quá lớn làm trọng số phân kỳ, hoặc do phép `log`, phép chia không an toàn trong loss tự viết; assert dừng loop ngay ở batch đầu tiên gặp lỗi, trước khi `nan` lan vào trọng số.

`model.train()` và `model.eval()` điều khiển hành vi layer như dropout, BatchNorm. `no_grad()` điều khiển việc ghi graph. Eval không tự tắt gradient; no_grad không tự tắt dropout. Mạng nhỏ này chưa có hai layer đó, nhưng giữ hai lời gọi để loop dùng được khi kiến trúc thay đổi.

Training loss trong hàm là trung bình loss quan sát **trong khi trọng số thay đổi** qua các batch. Nó không nhất thiết bằng loss đánh giá lại toàn bộ train ở checkpoint cuối epoch. Nếu cần so train/validation chặt chẽ, gọi cùng `evaluate` trên cả hai loader sau epoch, dùng cùng chế độ layer.

HỎI NHANH

Model có lớp Dropout, tức lớp tắt ngẫu nhiên một số nơ-ron trong lúc train (bài 3.6 sẽ học kỹ). Hàm chấm validation có `with torch.no_grad():` nhưng quên `model.eval()`. Chuyện gì xảy ra?

A Dropout vẫn tắt ngẫu nhiên nơ-ron, nên điểm dao động

B `no_grad` tự chuyển model sang eval, nên vẫn đúng

C Graph vẫn được ghi lại, vì model còn ở chế độ train

D Báo lỗi, vì Dropout cần gradient mới chạy được

## Chọn checkpoint theo validation

Nếu chỉ lưu epoch cuối, ta có thể bỏ mất model đã tổng quát hóa tốt hơn ở giữa quá trình. Ta chọn loss validation nhỏ nhất; metric lựa chọn trong bài thật có thể là F1, RMSE hoặc metric của scorer. Chốt hướng "nhỏ hơn tốt" hay "lớn hơn tốt" trước khi viết điều kiện so sánh.

Mỗi snapshot tensor cần một bản sao. Các tensor trong `model.state_dict()` dùng chung bộ nhớ với tham số; chỉ gán `best_state = model.state_dict()` rồi tiếp tục học thì "bản tốt nhất" đổi theo model. Dùng clone hoặc deepcopy để lưu snapshot thực sự, hoặc ghi tệp ngay khi tốt hơn.

Python

```
best_loss = float('inf')
best_epoch = -1
best_state = None
history = []
for epoch in range(35):
    training_loss = train_epoch(model, train_loader, optimizer)
    valid_loss, valid_accuracy = evaluate(model, valid_loader)
    history.append((epoch + 1, training_loss, valid_loss, valid_accuracy))
    if valid_loss < best_loss:
```

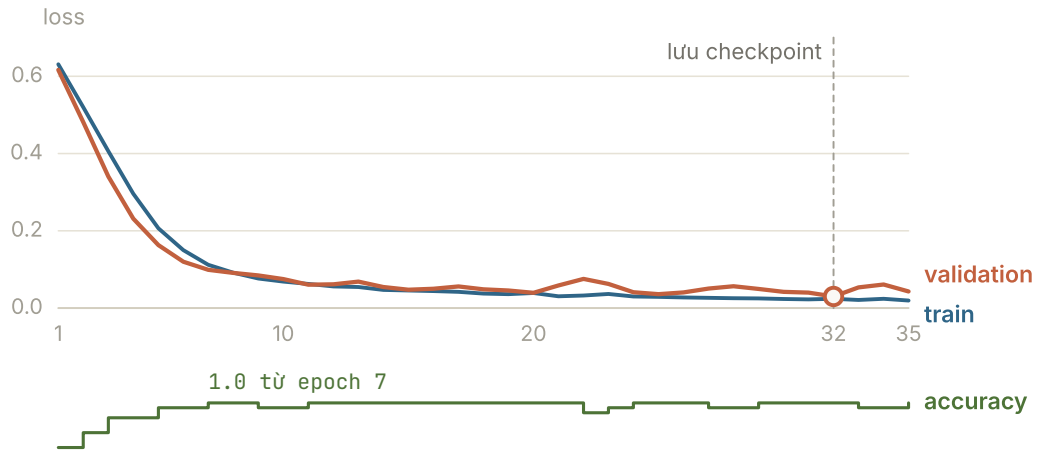
```
        best_loss = valid_loss
        best_epoch = epoch + 1
        best_state = {name: value.detach().cpu().clone()
                      for name, value in model.state_dict().items()}
    if epoch in [0, 9, 19, 34]:
        print(epoch + 1, round(training_loss, 4),
              round(valid_loss, 4), round(valid_accuracy, 4))

perfect = [e for e, _, _, accuracy in history if accuracy == 1.0]
print('accuracy 1.0:', len(perfect), 'epochs, first', perfect[0])
model.load_state_dict(best_state)
model.eval()
print('best epoch:', best_epoch)
print('best validation:', tuple(round(v, 4) for v in evaluate(model, valid_loader)))
```

KẾT QUẢ

```
1 0.6312 0.6167 0.625
10 0.0687 0.0751 0.9583
20 0.039 0.0396 1.0
35 0.0197 0.0429 1.0
accuracy 1.0: 21 epochs, first 7
best epoch: 32
best validation: (0.03, 1.0)
```

Mỗi dòng epoch có train loss, validation loss và validation accuracy. Train loss giảm gần như đều từ 0.6312 xuống 0.0197, còn validation loss thấp nhất ở epoch 32 (0.03) rồi lên 0.0429 ở epoch 35: epoch cuối không phải epoch tốt nhất. Validation chỉ 24 mẫu nên accuracy đi theo nấc 1/24; 21 trong 35 epoch cùng đạt 1.0, accuracy không phân biệt được chúng, còn loss thì phân biệt được. Điểm `(0.03, 1.0)` đã được dùng để chọn epoch, nên nó hơi lạc quan so với dữ liệu mới.




Log 35 epoch của bài: train loss giảm đều; validation loss thấp nhất ở epoch 32 rồi tăng nhẹ, nên checkpoint lấy epoch 32. Accuracy đạt 1.0 từ epoch 7 và không còn phân biệt được các epoch.



bước 0 (epoch 0.0): accuracy validation 0.142, loss 2.313



bước 10 (epoch 0.1): accuracy validation 0.577, loss 1.658



bước 80 (epoch 0.9): accuracy validation 0.757, loss 0.719



bước 1880 (epoch 20.0): accuracy validation 0.852, loss 0.420

Cùng vòng train, chấm validation, lần này trên 6000 ảnh Fashion-MNIST thật: viền xanh là đoán đúng, viền cam là đoán sai.

HỎI NHANH

Code chọn checkpoint ghi `best_state = model.state_dict()`, không clone, mỗi khi validation loss tốt hơn. Train hết 35 epoch rồi `model.load_state_dict(best_state)`. Model có trọng số của epoch nào?

A Epoch 32, epoch có validation loss nhỏ nhất

B Epoch 1, lần đầu điều kiện được thỏa

C Không xác định, vì tensor cũ đã bị giải phóng

D Epoch 35, vì `best_state` thay đổi theo model

HỎI NHANH

Giả sử vòng lặp trên chọn checkpoint theo validation accuracy, với điều kiện `valid_accuracy > best_accuracy` và `best_accuracy` khởi tạo bằng 0, thay vì theo loss. Checkpoint là epoch nào?

A Epoch 7, lần đầu accuracy đạt 1.0

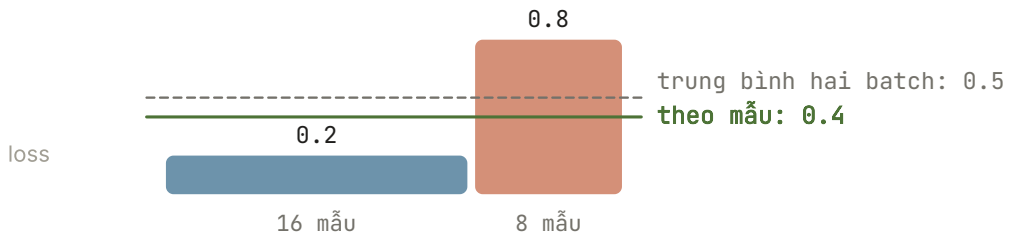
B Epoch 20, mốc log đầu tiên có accuracy 1.0

C Epoch 32, cũng là epoch có loss nhỏ nhất

D Epoch 35, lần cuối accuracy đạt 1.0

## Ví dụ tính tay: trung bình đúng theo mẫu

Giả sử batch đầu có 16 mẫu, loss mean 0.2; batch cuối có 8 mẫu, loss mean 0.8. Trung bình hai số bằng 0.5, nhưng trung bình theo 24 mẫu là $(16 \cdot 0.2 + 8 \cdot 0.8)/24 = 0.4$. Đó là lý do code nhân `len(yb)` trước khi cộng. Cách này đúng với cross-entropy không trọng số của bài. Khi dùng class weight, `ignore_index` hoặc loss trung bình theo pixel, mẫu số đúng là tổng trọng số hoặc số phần tử thật sự được tính, nên cần đọc `reduction` của loss trước khi cộng. `CrossEntropyLoss` mặc định bỏ qua nhãn $-100$ (`ignore_index`) và chia cho số nhãn còn lại. Đổi `reduction='mean'` sang `'sum'` với batch 64 mà giữ learning rate của SGD là nhân bước đi lên 64 lần.




Batch 16 mẫu loss 0.2 và batch 8 mẫu loss 0.8: chiều rộng là số mẫu; trung bình theo mẫu là 0.4, không phải 0.5.

HỎI NHANH

Một epoch có bốn batch 16 mẫu, batch nào cũng có loss trung bình 0.1, và một batch cuối 8 mẫu có loss trung bình 0.7. Loss trung bình theo mẫu của cả epoch là bao nhiêu?

A 0.10

B 0.17

C 0.22

D 0.40

## Lưu đủ để suy luận lại

Ta lưu state_dict, mean/std và vài đầu vào kiểm tra kèm logits mong đợi, vào thư mục `receipts/phase-3` cạnh notebook. `torch.load` một tệp lạ có thể chạy code tùy ý, nên chỉ tải checkpoint đáng tin cậy; `weights_only=True` chỉ cho phép tensor và kiểu dữ liệu cơ bản, đủ cho packet này. Đưa đầu vào mới qua model đã học để lấy dự đoán gọi là suy luận (inference), khác với huấn luyện là lúc trọng số còn được chỉnh. Packet phục vụ suy luận; muốn tiếp tục training chính xác còn cần trạng thái optimizer, scheduler, số epoch và trạng thái RNG.

Python

```
artifact_dir = Path('receipts/phase-3')
artifact_dir.mkdir(parents=True, exist_ok=True)
checkpoint_path = artifact_dir / '3-4-best.pt'
query = torch.tensor([[1., 0.], [-1., 0.]])
with torch.no_grad():
    expected = model((query - mean) / scale)
torch.save({'state': best_state, 'mean': mean, 'scale': scale,
            'query': query, 'expected': expected, 'epoch': best_epoch}, checkpoint_path)
fresh = make_model()
packet = torch.load(checkpoint_path, map_location='cpu', weights_only=True)
fresh.load_state_dict(packet['state'])
```

```
fresh.eval()
with torch.no_grad():
    reloaded = fresh((packet['query'] - packet['mean']) / packet['scale'])
print('same logits:', torch.allclose(reloaded, expected, atol=1e-7))
print('classes:', reloaded.argmax(dim=1).tolist())
```

KẾT QUẢ

```
same logits: True
classes: [1, 0]
```

`True` kiểm khôi phục trong cùng tiến trình; hai lớp `[1, 0]` khớp quy tắc ban đầu: $(1, 0)$ cho $x_1 + 0.5x_2 = 1 > 0$, $(-1, 0)$ cho $-1 < 0$.

HỎI NHANH

Phiên Colab bị ngắt ở epoch 20, và checkpoint chỉ có `state_dict` của model. Ta tạo một Adam mới rồi train tiếp 15 epoch. So với chạy liền 35 epoch thì sao?

A Giống hệt, vì trọng số model đã mô tả đủ trạng thái

B Giống hệt, nếu đặt lại seed như lúc đầu

C Khác, vì các trung bình động của Adam và thứ tự xáo dữ liệu đều bắt đầu lại

D Báo lỗi, vì `load_state_dict` đòi cả state của optimizer

Phép kiểm trong cùng tiến trình chưa cho biết notebook có dựa vào biến cũ hay không, nên ta tạo một script nhỏ chạy bằng Python mới. Script tự tạo kiến trúc, đọc checkpoint và chỉ dùng thông tin trong packet:

Python

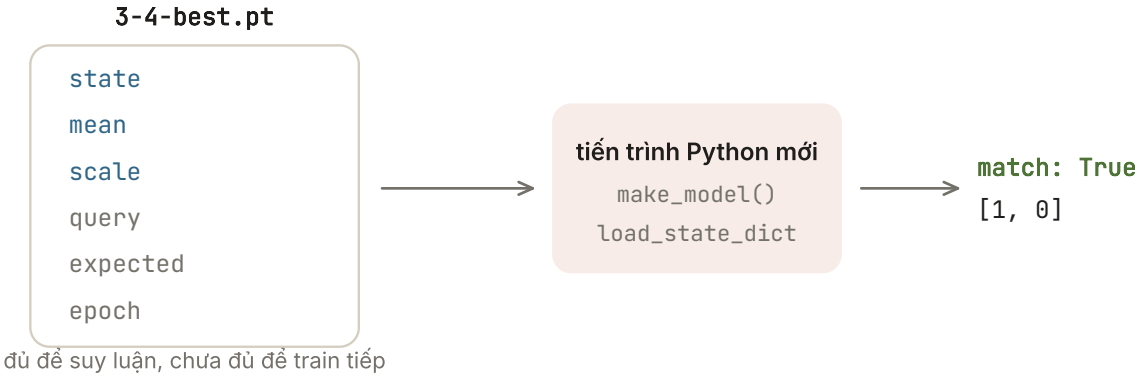
```
inference_source = '''import sys
import torch
from torch import nn
torch.set_num_threads(1)
packet = torch.load(sys.argv[1], map_location="cpu", weights_only=True)
model = nn.Sequential(nn.Linear(2, 8), nn.ReLU(), nn.Linear(8, 2))
model.load_state_dict(packet["state"])
```

```
model.eval()
with torch.no_grad():
    x = (packet["query"] - packet["mean"]) / packet["scale"]
    logits = model(x)
print("new process match:", torch.allclose(logits, packet["expected"], atol=1e-7))
print("new process classes:", logits.argmax(dim=1).tolist())
'''
inference_path = artifact_dir / '3-4-infer.py'
inference_path.write_text(inference_source, encoding='utf-8')
result = subprocess.check_output([sys.executable, '-B', '-X', 'utf8',
    str(inference_path), str(checkpoint_path)], text=True)
print(result.rstrip())
```

KẾT QUẢ

```
new process match: True
new process classes: [1, 0]
```

Phép kiểm này giống chạy lời giải CP trên input mới qua stdin: kết quả không được phụ thuộc vào biến còn sót trong môi trường thử. Ở bài thi thật, script suy luận còn phải theo hợp đồng nộp bài của đề (format file, thứ tự ID, asset đề cho), vì vậy phép kiểm ở phiên mới phải chạy đúng script sẽ nộp.




Packet checkpoint của bài: trọng số, mean và scale của train, cùng đầu vào kiểm và logits mong đợi; một tiến trình Python mới chỉ dùng packet mà vẫn cho cùng kết quả.

HỎI NHANH

Trong notebook, model mới nạp checkpoint đã cho `same logits: True`. Vì sao bài vẫn chạy thêm một script ở tiến trình Python mới?

A `torch.load` chỉ đọc đúng tệp khi chạy ở tiến trình khác

B Tiến trình mới đổi seed nên phép so khắt khe hơn

C `allclose` trong cùng tiến trình luôn trả về `True`

D Notebook có thể đang dựa vào biến cũ không có trong packet

## Tái lập

Seed của khởi tạo model, chia dữ liệu và DataLoader cần được quản lý. Bài đặt seed, dùng CPU một thread và deterministic algorithms, nên chạy lại trong cùng môi trường cho cùng số. PyTorch không hứa kết quả giống từng bit giữa mọi phiên bản, nền tảng và GPU; vì vậy lưu phiên bản thư viện, split và cấu hình cùng điểm số.

Tái lập được một lần chạy chưa có nghĩa là một lần chạy đủ để so hai cấu hình. Ngay trong log trên, validation loss đi từ 0.0396 (epoch 20) xuống 0.03 (epoch 32) rồi lên 0.0429 (epoch 35). Chênh lệch giữa hai cấu hình chỉ đáng tin khi lớn hơn rõ mức dao động giữa các seed.

HỎI NHANH

Thử learning rate 0.03 và 0.01, mỗi cấu hình chạy một lần với cùng seed 21. Validation loss tốt nhất lần lượt là 0.030 và 0.028. Kết luận nào hợp lý?

A Chọn 0.01, vì cùng seed nên chênh lệch chỉ do learning rate

B Chọn 0.03, vì chênh 0.002 quá nhỏ nên giữ cấu hình cũ

C Chưa chọn được, cần chạy thêm vài seed rồi so trung bình

D Chọn 0.01, vì validation loss thấp hơn là đủ để quyết định

## Tự viết Dataset và collate_fn

`TensorDataset` cần cả bộ dữ liệu nằm sẵn trong một tensor. Thư mục hàng nghìn ảnh, mỗi ảnh một cỡ, thì nên viết một lớp con của `Dataset` với hai hàm ở bài 0.1: `__len__` trả số mẫu, `__getitem__(i)` đọc **một** mẫu từ đĩa khi cần.

Python

```
import numpy as np
import pandas as pd
from PIL import Image
from tempfile import TemporaryDirectory
from torch.utils.data import Dataset

class FolderDataset(Dataset):
    def __init__(self, root, table, size=8):
        self.root, self.table, self.size = Path(root), table.reset_index(drop=True), size

    def __len__(self):
        return len(self.table)

    def __getitem__(self, i):
        row = self.table.iloc[i]
        image = Image.open(self.root / row["file"]).convert("L").resize((self.size,
self.size))
        x = torch.from_numpy(np.asarray(image, dtype=np.float32) / 255).unsqueeze(0)   # (1,
```

```
H, W)
        return x, int(row["label"])

with TemporaryDirectory() as directory:
    root = Path(directory)
    rng = np.random.default_rng(0)
    rows = []
    for i in range(10):
        w, h = rng.integers(10, 30, size=2)                    # mỗi ảnh một kích thước
        label = i % 2                                          # nhãn 1: ảnh sáng hơn
        pixels = rng.integers(0, 120, size=(h, w)) + 120 * label
        Image.fromarray(pixels.astype(np.uint8)).save(root / f"{i}.png")
        rows.append({"file": f"{i}.png", "label": label})
    data = FolderDataset(root, pd.DataFrame(rows))
    loader = DataLoader(data, batch_size=4, shuffle=False, num_workers=0)
    xb, yb = next(iter(loader))
    print(len(data), len(loader), tuple(data[0][0].shape), tuple(xb.shape), yb.tolist())
    print(round(float(xb[yb == 0].mean()), 3), round(float(xb[yb == 1].mean()), 3))
```

KẾT QUẢ

```
10 3 (1, 8, 8) (4, 1, 8, 8) [0, 1, 0, 1]
0.236 0.709
```

`__getitem__` đưa mọi ảnh về $(1, 8, 8)$, nên DataLoader xếp bốn mẫu thành batch $(4, 1, 8, 8)$; 10 mẫu, batch 4 cho 3 batch. Độ sáng 0.236 và 0.709 khớp cách sinh: ảnh nhãn 1 sáng hơn 120 mức. Đổi cỡ, chuẩn hóa, augmentation (chương 5) đều đặt trong `__getitem__`.

Văn bản và âm thanh mỗi mẫu một độ dài. DataLoader mặc định ghép bằng `torch.stack` nên báo lỗi; `collate_fn` tự viết đệm chuỗi ngắn bằng 0 và giữ độ dài thật.

Python

```
from torch.nn.utils.rnn import pad_sequence

pairs = [(torch.tensor([5, 2, 9]), 1), (torch.tensor([7]), 0), (torch.tensor([3, 3, 1, 4]),
1)]
try:
    next(iter(DataLoader(pairs, batch_size=3)))
except RuntimeError as error:
    print("không có collate_fn:", str(error).split(" at entry")[0])

def pad_collate(batch):
```

```
    seqs, labels = zip(*batch)
    lengths = torch.tensor([len(s) for s in seqs])
    return pad_sequence(seqs, batch_first=True, padding_value=0), lengths,
torch.tensor(labels)

for tokens, lengths, labels in DataLoader(pairs, batch_size=3, collate_fn=pad_collate):
    print(tokens)
    print(lengths.tolist(), labels.tolist())
```

KẾT QUẢ

```
không có collate_fn: stack expects each tensor to be equal size, but got [3]
tensor([[5, 2, 9, 0],
        [7, 0, 0, 0],
        [3, 3, 1, 4]])
[3, 1, 4] [1, 0, 1]
```




collate_fn đệm 0 cho bằng chuỗi dài nhất và giữ độ dài thật.

`collate_fn` nhận list các mẫu do `__getitem__` trả về và trả về một batch. Số 0 là token đệm; tính loss trên cả ma trận mà không dùng `lengths` hay mặt nạ thì model học cả phần đệm. Chương 6 dùng khuôn này kèm attention mask. `collate_fn` cũng là chỗ gọn để bỏ mẫu hỏng: nếu `__getitem__` trả `None` cho ảnh không đọc được, lọc các `None` trước khi gom batch; tốt hơn nữa là lọc danh sách tệp hỏng trước khi huấn luyện.

HỎI NHANH

`Dataset` trả về ảnh khác cỡ nhau, DataLoader `batch_size=32`, không có `collate_fn`. Lấy batch đầu tiên thì sao?

A Mọi ảnh được đổi về cỡ của ảnh đầu tiên

B Mọi ảnh được cắt về cỡ nhỏ nhất trong batch

C Báo lỗi vì không xếp được các tensor khác shape

D Batch là một list ảnh rời

## Khi đi thi

- **Chạy thử nhỏ trước khi chạy dài.** Vài batch với `assert` shape và loss hữu hạn, đo thời gian một epoch rồi nhân với số epoch để biết có vừa ngân sách GPU và thời gian không.
- **Lưu best ra tệp ngay khi validation tốt hơn**, theo đúng metric của đề và đúng hướng so sánh (< cho loss, > cho F1, accuracy). Phiên notebook có thể ngắt giữa chừng.
- **Checkpoint đi kèm tiền xử lý.** Mean/std fit trên train, danh sách và thứ tự feature, bảng chỉ số → tên lớp. Không fit lại scaler trên test.
- **Kiểm submission ở phiên mới.** Khởi động lại runtime, chạy đúng script nộp từ checkpoint, chấm thử trên validation, rồi so số hàng, thứ tự ID và tên cột với file mẫu.
- **Không chọn epoch bằng test hay bảng điểm công khai.** Validation dùng để chọn càng nhiều lần thì điểm của nó càng lạc quan; giữ một lần kiểm độc lập sau cùng.

## Tóm tắt

Training loop là một chu trình có trạng thái, không phải chỉ `loss.backward()`. Chia dữ liệu và tiền xử lý trước; train theo batch với đúng thứ tự; validation dùng eval/no_grad.

Lưu snapshot tốt theo metric đã chọn và kiểm suy luận ở tiến trình mới. Kết quả tái lập cần cả code, checkpoint, split và môi trường. Dữ liệu thật vào loop qua `Dataset` tự viết; mẫu dài ngắn khác nhau thì cần `collate_fn`.

## Kiểm tra cuối bài

CÂU 1

Tập train có $N$ mẫu, mỗi mẫu $d$ đặc trưng, mô hình tuyến tính. So chi phí tính toán của **một epoch** SGD, mỗi bước dùng một mẫu, với **một vòng** gradient descent dùng cả tập. Câu nào đúng?

A Cùng bậc $O(Nd)$, vì cả hai đều đi qua $N$ mẫu một lần

B Epoch SGD đắt hơn $N$ lần, vì có $N$ lần cập nhật

C Epoch SGD rẻ hơn $N$ lần, vì mỗi bước chỉ nhìn một mẫu

D Không so được, vì thứ tự mẫu trong SGD là ngẫu nhiên

PHỎNG THEO CMU 10-601 · Exam 2 Practice · Q1.4

CÂU 2

Một vòng lặp quên hẳn `optimizer.zero_grad()`. Tham số $w$ bắt đầu bằng 1, optimizer là SGD với learning rate 0.1, và ở batch nào gradient của loss theo $w$ cũng bằng 2. Sau 3 batch, $w$ và `w.grad` bằng bao nhiêu?

A $w = 0.4$, `w.grad` bằng 2

B $w = 0.4$, `w.grad` bằng 6

C $w = -0.2$, `w.grad` bằng 2

D $w = -0.2$, `w.grad` bằng 6

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 126

CÂU 3

Loss train in ra sau mỗi 50 bước là 0.69, 0.48, 1.9, 27.3, rồi `nan`. Dữ liệu đã chuẩn hóa, loss là `nn.CrossEntropyLoss`, optimizer là Adam với learning rate 1.0. Nên kiểm gì trước?

A Batch size, tăng lên cho loss bớt nhiễu

B Learning rate, giảm 10 lần rồi xem độ lớn của gradient

C Số epoch, dừng sớm trước khi loss thành `nan`

D Kiến trúc, thêm lớp để mạng học tiếp được

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 141

CÂU 4

Dòng log epoch 1 của bài có train loss 0.6312 và validation loss 0.6167. Validation thấp hơn train có phải dấu hiệu lỗi không?

A Có, validation thấp hơn nghĩa là dữ liệu đã lọt vào train

B Có, phải gọi `model.eval()` khi train để hai số so được với nhau

C Không, vì train loss được lấy trong lúc trọng số còn đang học

D Không, vì ở epoch đầu validation luôn thấp hơn train

CÂU 5

Hàm chấm validation có `model.eval()` nhưng không có `no_grad`, và gom `all_logits.append(model(xb))` để tính F1 sau vòng lặp. Bộ nhớ tăng theo từng batch, rồi báo hết bộ nhớ giữa chừng. Sửa thế nào?

A Gọi thêm `model.eval()` để tắt hẳn autograd

B Bọc vòng chấm trong `with torch.no_grad():`

C Gọi `optimizer.zero_grad()` trước mỗi batch chấm

D Giảm batch size khi train để dành chỗ cho validation

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 127

CÂU 6

Lưu MLP của bài, gồm `Linear(2, 8)`, `ReLU`, `Linear(8, 2)`, bằng `torch.save(model.state_dict(), 'best.pt')`. Tệp này chứa gì?

A 4 tensor, tổng cộng 42 số: weight và bias của hai lớp Linear

B 6 tensor, thêm một mục cho ReLU và một mục cho kiến trúc

C 4 tensor trọng số kèm `.grad` để train tiếp được

D Cả object model, nạp lại không cần dựng kiến trúc

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 134

CÂU 7

Đổi tiêu chí chọn checkpoint từ validation loss sang macro-F1, nhưng vẫn giữ `best = float('inf')` và điều kiện `if f1 < best:`. Checkpoint được giữ là gì?

A Epoch cuối, vì F1 luôn nhỏ hơn `inf`

B Không có, vì F1 không so được với `inf`

C Epoch có F1 cao nhất, đúng như mong muốn

D Epoch có F1 thấp nhất trong lúc train

CÂU 8

Script nộp bài đọc `test.csv` có cùng tên cột với train nhưng khác thứ tự cột, rồi chuẩn hóa bằng mean và std tính lại trên chính test. Model là MLP như trong bài. Phải sửa thế nào?

A Theo thứ tự cột của test, mean và std tính lại trên test

B Theo thứ tự cột của test, mean và std đã lưu từ train

C Theo thứ tự cột đã lưu, mean và std đã lưu từ train

D Theo thứ tự cột đã lưu, mean và std tính lại trên test

CÂU 9

Phân loại 10 lớp cân bằng, validation accuracy trong notebook là 0.91. Script nộp chạy ở phiên mới, nạp đúng checkpoint, chuẩn hóa bằng mean và std đã lưu, số hàng và thứ tự ID khớp file mẫu. Vậy mà điểm chấm chỉ khoảng 0.10. Giả thuyết nào khớp nhất?

A Model overfit validation, cần thêm regularization rồi train lại

B Bảng đổi chỉ số ra tên lớp ở script nộp khác với lúc train

C Test lệch phân phối nên scaler cần fit lại trên test

D Phiên mới có seed khác nên dự đoán thành ngẫu nhiên

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 284

CÂU 10

Bài đặt seed, chạy trên CPU với một thread, và bật `use_deterministic_algorithms`. Như vậy bảo đảm được điều gì?

A Chạy lại trong cùng môi trường thì cho cùng kết quả

B Kết quả giống từng bit trên mọi máy và mọi phiên bản

C Dựng lại được model kể cả khi không lưu cách chia dữ liệu

D Không cần validation nữa, vì kết quả đã cố định

---

## Đọc thêm

- PyTorch — Datasets & DataLoaders: đọc cách chia trách nhiệm dataset, sampler và ghép batch.
- PyTorch — Optimizing Model Parameters: đối chiếu train/test loop và thứ tự gradient.
- PyTorch — Saving and Loading Models: xem state_dict, checkpoint và lưu best model bằng bản sao.
- PyTorch 2.9 — Reproducibility: đọc giới hạn của seed và deterministic algorithms.

Nguồn ảnh: ảnh quần áo lấy từ bộ Fashion-MNIST của Zalando (giấy phép MIT).