Huấn luyện trên GPU

Trắc nghiệm 20 Thực hành 1 PDF bài

> Một chương trình CP đúng trên mẫu nhỏ vẫn cần kiểm giới hạn thời gian và bộ nhớ. Mạng neural cũng vậy, nhưng trước khi đo GPU ta phải biết nó học được một batch, không sinh NaN và không giữ graph thừa. Câu hỏi của bài này là: làm thế nào phân biệt lỗi tính toán với thiếu tài nguyên, rồi dự báo một lượt chạy trong ngân sách được cấp?

MỤC TIÊU SAU BÀI NÀY

- Dùng phép overfit một batch để kiểm pipeline trước training dài.
- Lần theo lỗi shape, dtype, device, NaN và gradient mất tới điểm xuất hiện đầu tiên.
- Ước lượng bộ nhớ tham số/optimizer, nhận ra chi phí activation và xử lý OOM bằng microbatch, gradient accumulation, mixed precision.
- Chạy recipe CUDA có warmup, đồng bộ, đo peak VRAM và quy số đo thành ngân sách thời gian.

Chưa cần GPU để kiểm mạng biết học

Overfit một batch nghĩa là cố ý học lại một nhóm rất nhỏ nhiều lần. Với dữ liệu không có nhãn mâu thuẫn và mạng đủ capacity, train loss thường có thể giảm rất sâu. Nếu chưa làm được, đừng vội tăng dataset: có thể loss ghép sai, nhãn lệch mẫu, optimizer thiếu tham số hoặc graph bị cắt. Đây là kiểm sức khỏe pipeline, không phải điểm validation.

Ta dùng bốn góc của một hình vuông, nhãn theo dấu tọa độ thứ nhất. Tắt dropout, không augmentation để mục tiêu ổn định. Mạng nhỏ và seed cố định chạy CPU:

Python

```python
import torch
from torch import nn

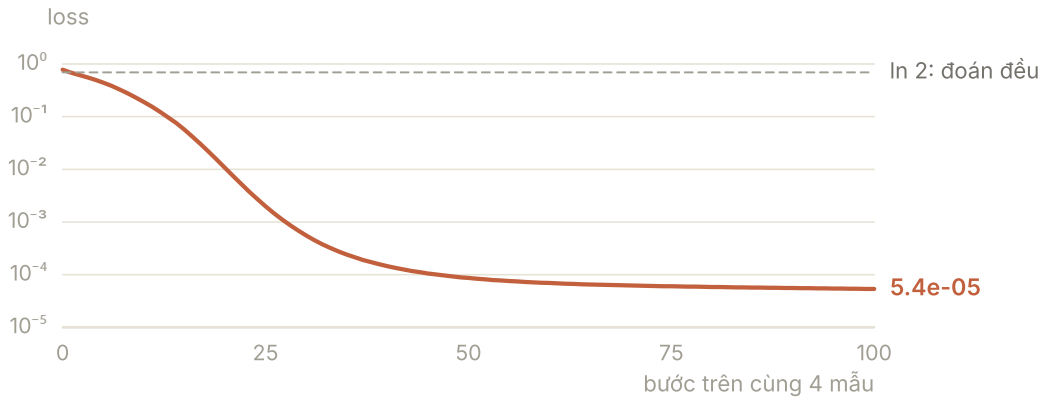
torch.set_num_threads(1)
torch.manual_seed(31)
```

```
xb = torch.tensor([[-1., -1.], [-1., 1.], [1., -1.], [1., 1.]])
yb = torch.tensor([0, 0, 1, 1], dtype=torch.long)
model = nn.Sequential(nn.Linear(2, 8), nn.ReLU(), nn.Linear(8, 2))
optimizer = torch.optim.Adam(model.parameters(), lr=.05)
criterion = nn.CrossEntropyLoss()
initial_loss = criterion(model(xb), yb).item()
for step in range(100):
    model.train()
    optimizer.zero_grad(set_to_none=True)
    logits = model(xb)
    assert logits.shape == (4, 2)
    loss = criterion(logits, yb)
    assert torch.isfinite(loss)
    loss.backward()
    assert all(p.grad is not None and torch.isfinite(p.grad).all()
               for p in model.parameters())
    optimizer.step()
model.eval()
with torch.no_grad():
    final_logits = model(xb)
    final_loss = criterion(final_logits, yb).item()
    accuracy = (final_logits.argmax(dim=1) == yb).float().mean().item()
print('loss:', round(initial_loss, 6), '->', round(final_loss, 6))
print('one-batch accuracy:', accuracy)
```

KẾT QUẢ

```
loss: 0.776305 -> 5.4e-05
one-batch accuracy: 1.0
```

Đọc loss đầu/cuối và accuracy trên **cùng bốn mẫu đã học**. Accuracy 1 ở đây chỉ xác nhận model có thể khớp nhóm nhỏ; nó không chứng minh khả năng dự đoán mẫu chưa thấy. Kiểm `grad is not None` thích hợp với mạng này vì mọi tham số tham gia forward. Model có nhánh điều kiện hoặc tham số đóng băng cần kiểm theo thiết kế, không bắt mọi tham số đều có gradient.



Overfit một batch bốn mẫu (code bài): loss đi từ gần ln 2 xuống cỡ 10^{-5} sau 100 bước, chứng tỏ forward, loss, backward và step đã nối đúng.



bước 0: loss 2.4, đúng 1/16 | bước 20: loss 0.53, đúng 16/16 | bước 50: loss 0.038, đúng 16/16 | bước 200: loss 0.0024, đúng 16/16

Overfit một batch 16 ảnh Fashion-MNIST: lặp lại trên cùng batch, loss phải về gần 0 và cả 16 ảnh được đoán đúng.

HỎI NHANH

Sau 100 bước trên bốn mẫu, loss giảm từ 0.776 xuống 5.4e-05, và accuracy bằng 1.0. Ta kết luận được gì?

A Model sẽ đạt accuracy cao trên tập validation

B Có thể bỏ validation, vì loss đã gần bằng 0

C Forward, loss, backward và bước cập nhật đã được nối đúng

D Learning rate 0.05 cũng sẽ hợp với dữ liệu thật

HỎI NHANH

Thử cho model học thuộc 16 ảnh của một bài 10 lớp. Loss đứng yên ở 2.3026 suốt 200 bước, accuracy cũng không đổi. Nên kiểm gì trước?

A Thêm dữ liệu, vì 16 ảnh là quá ít để học

B Optimizer có nắm đúng tham số không, và có gọi `step()` không

C Tăng dropout để model bớt học thuộc batch

D Giảm batch xuống 1 cho gradient rõ hơn

Tìm lỗi theo điểm xuất hiện đầu tiên

Khi pipeline không học hoặc báo lỗi, ta lần ngược tới chỗ sai đầu tiên thay vì vá chỗ triệu chứng lộ ra. Với lỗi shape, in shape của input, logits và target, gọi tên từng chiều (batch, lớp, đặc trưng) chứ không chỉ đếm số chiều. Với lỗi dtype, target của cross-entropy là chỉ số lớp kiểu `long`, còn target của BCE là số thực. Với lỗi device, model và mọi tensor đi vào cùng một phép phải nằm cùng nơi. Với NaN, kiểm lần lượt input, activation, logits, loss rồi gradient để tìm phép đầu tiên tạo giá trị không hữu hạn; `torch.isfinite` phát hiện cả NaN lẫn vô cùng. Một `nan` ở cuối có thể bắt đầu từ một phép chia cho 0 rất sớm.

Có thể bật `torch.autograd.detect_anomaly()` trên vài bước kiểm để thư viện hỗ trợ truy dấu backward; nó chậm nên không dùng trong mọi lượt đo. Nếu loss hữu hạn nhưng gradient nổ, giảm learning rate chưa chắc chữa được phép đạo hàm không ổn định: kiểm log, chia và căn bậc hai tại miền không hợp lệ. `torch.where` vẫn lấy đạo hàm cả nhánh không được chọn: `torch.where(x > 0, x.sqrt(), 0)` với $x = -1$ có `sqrt(-1)` là NaN, và NaN nhân 0 trong backward vẫn là NaN; kẹp đầu vào trước khi lấy căn. Nếu gradient bằng `None`, kiểm `detach/no_grad` hoặc tham số chưa được dùng.

Để minh họa cách khoanh vùng mà không gây training nổ, ta kiểm một đầu vào lỗi:

```
Python
```

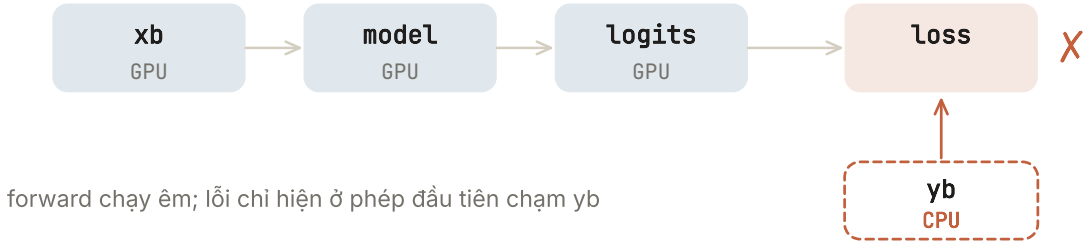
```
bad_input = torch.tensor([[1., float('nan')], [2., 3.]])
finite_rows = torch.isfinite(bad_input).all(dim=1)
print('finite rows:', finite_rows.tolist())
print('bad row indices:', (~finite_rows).nonzero(as_tuple=True)[0].tolist())
```

KẾT QUẢ

```
finite rows: [False, True]
bad row indices: [0]
```

Hàng đầu sai ngay từ input; đổi optimizer không sửa được dữ liệu ấy. Tùy bài, ta cần điều tra nguồn, điền thiếu bằng thống kê train hoặc loại dòng theo quy định dữ liệu; không tùy tiện thay mọi NaN thành 0 rồi coi pipeline đã đúng.

Lỗi device thường hiện ra ở dòng khác với chỗ gây ra nó. Model đã chuyển lên GPU, input cũng đã chuyển, nhưng một tensor khác tạo trong vòng lặp (target, mask, trọng số lớp) vẫn nằm ở CPU; phép đầu tiên chạm tới nó mới báo lỗi.



Model và xb đã ở GPU nên forward chạy được; target yb còn ở CPU nên lỗi device chỉ hiện ra ở dòng tính loss.

HỎI NHANH

Đã gọi `model.to('cuda')` và `xb = xb.to('cuda')`. Forward chạy được, nhưng dòng `loss = criterion(logits, yb)` báo các tensor không nằm trên cùng thiết bị. Vì sao?

A Model mới lên GPU một phần, phải gọi lại `.to`

B `yb` vẫn ở CPU, phải chuyển nó sang cùng thiết bị

C Loss phải tính ở CPU, nên đưa logits về CPU

D `yb` phải đổi sang float cho khớp với logits

HỎI NHANH

Logits có shape `(4, 3)`, target tạo bằng `torch.tensor([0., 2., 1., 1.])`. `nn.CrossEntropyLoss()` báo `expected scalar type Long but found Float`. Sửa thế nào?

A Đổi logits sang `.long()` cho cùng kiểu

B Đổi loss sang `BCEWithLogitsLoss`

C Tạo target kiểu `long`, chẳng hạn bằng `.long()`

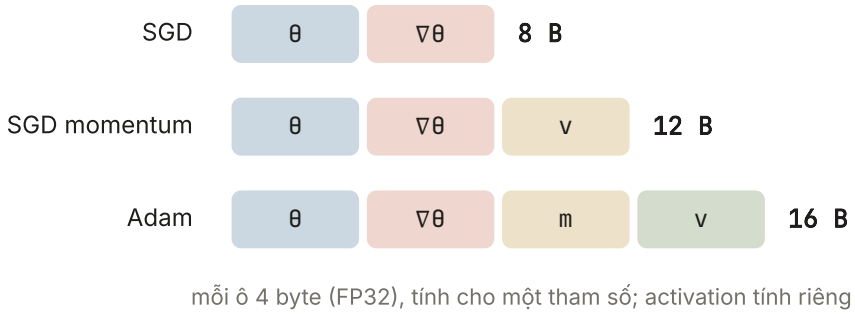
D Đưa target về shape `(4, 3)` bằng `.view`

Bộ nhớ có nhiều phần

Một tham số FP32 chiếm 4 byte. Training còn có gradient, và Adam giữ hai moment cùng thang FP32 trong cấu hình thường gặp. Chỉ các phần này đã khoảng $4P + 4P + 8P = 16P$ byte cho P tham số. Đây là ước lượng, còn phụ thuộc dtype, optimizer và triển khai; chưa tính activation, input batch, temporary workspace và allocator.

Đổi ra con số: 1 triệu tham số FP32 là 4 MB. Bảng embedding 100 000 từ, mỗi vector 300 chiều FP32, là 120 MB.

Activation phải giữ lại vì backward cần chúng (bài 3.2); suy luận không có backward nên dùng xong là bỏ. Mỗi ảnh tạo 1 triệu giá trị ở mỗi lớp, 50 lớp, batch 64, FP32 đã là $64 \cdot 50 \cdot 10^6 \cdot 4$ byte ≈ 12.8 GB. Gradient checkpointing chỉ lưu đầu ra của vài lớp rồi tính lại phần giữa khi backward, đổi thêm một lượt forward lấy bộ nhớ: 100 lớp chia 10 đoạn thì chỉ giữ cỡ 10 điểm lưu cộng 10 lớp của đoạn đang tính lại, thay vì 100.



Mỗi tham số FP32 cần 4 byte cho trọng số, 4 cho gradient, cộng trạng thái optimizer: SGD 8 byte, SGD momentum 12, Adam 16.

Python

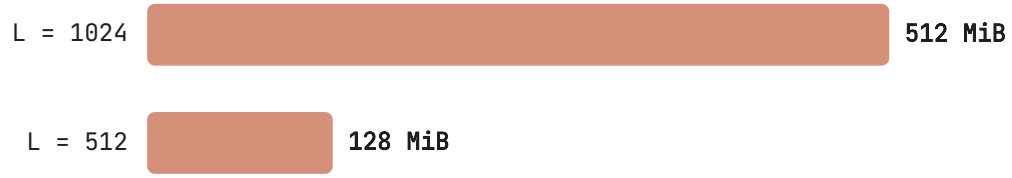
```python
parameter_count = sum(p.numel() for p in model.parameters())
weight_bytes = sum(p.numel() * p.element_size() for p in model.parameters())
print('parameters:', parameter_count)
print('weight bytes:', weight_bytes)
print('FP32 Adam parameter-state estimate:', 16 * parameter_count, 'bytes')
B, heads, L = 16, 8, 1024
score_bytes = B * heads * L * L * 4
print('materialized attention scores:', score_bytes // 2**20, 'MiB')
```

KẾT QUẢ

```
parameters: 42
weight bytes: 168
FP32 Adam parameter-state estimate: 672 bytes
materialized attention scores: 512 MiB
```

Mạng 42 tham số rất nhỏ, nhưng một attention score tensor giả định `(16,8,1024,1024)` FP32 đã là 512 MiB. Dòng đó là **tính kích thước**, không cấp phát tensor ấy. Bình phương độ dài chính là $O(L^2)$ quen thuộc của thuật toán duyệt mọi cặp. Kernel attention tối ưu

(như FlashAttention) tính theo từng khối và không materialize toàn bộ score, nên 512 MiB là chi phí của cách cài thẳng, không phải của mọi kernel.



score (16, 8, L, L) FP32: L giảm một nửa, bộ nhớ giảm bốn lần

Tensor attention score (16, 8, L, L) ở FP32: 512 MiB với L = 1024 nhưng chỉ 128 MiB với L = 512, vì kích thước tỉ lệ với L^2.

HỎI NHANH

Đổi Adam sang SGD có momentum, tức mỗi tham số giữ một buffer vận tốc, và vẫn dùng FP32. Phần weight, gradient và trạng thái optimizer còn khoảng bao nhiêu byte cho mỗi tham số?

A 4

B 8

C 12

D 16

Ví dụ tính tay: batch giảm thì phần nào giảm?

Với MLP, weight không đổi khi giảm batch 64 xuống 32; activation dạng `(B,h)` thường giảm khoảng một nửa. Gradient và optimizer state cũng không giảm vì số tham số giữ nguyên. Vì vậy VRAM peak không giảm đúng một nửa. Với attention materialize score, giảm độ dài 1024 xuống 512 làm riêng score giảm bốn lần: tensor `(16,8,512,512)` FP32 chỉ còn $16 \cdot 8 \cdot 512^2 \cdot 4$ byte $=$ 128 MiB thay vì 512 MiB, trong khi trọng số giữ nguyên.

HỎI NHANH

Giảm batch size đi một nửa, giữ nguyên kiến trúc và optimizer. Phần bộ nhớ nào giảm theo, trong khi weights vẫn đứng yên?

A Input và activation của batch

B Mọi phần cùng giảm đúng một nửa

C Weights và hai moment của Adam

D Chỉ bộ nhớ đệm của allocator

Hết bộ nhớ: microbatch và gradient accumulation

Lỗi `CUDA out of memory` nghĩa là allocator không xin được thêm vùng nhớ cho tensor kế tiếp. Cách sửa trực tiếp là giảm phần lớn nhất: batch, độ dài chuỗi, kích thước ảnh hoặc độ rộng mạng. `torch.cuda.empty_cache()` chỉ trả lại phần cache chưa được tensor sống nào dùng; nó không giải phóng tensor còn được tham chiếu. Nguồn rò hay gặp là giữ tensor loss qua các step, như `history.append(loss)` hay `total = total + loss`: mỗi loss kéo theo graph của step đó. Nếu vòng validation vừa quên `torch.no_grad()` vừa giữ loss như vậy, backward không bao giờ chạy nên mỗi graph còn nguyên các activation đã lưu, và bộ nhớ tăng theo từng batch. Metric scalar nên lưu bằng `loss.item()`. Sau khi sửa OOM, khởi động lại tiến trình để bỏ trạng thái cũ.

Giảm batch làm gradient nhiễu hơn và đổi động học huấn luyện. Muốn giữ batch hiệu dụng (effective batch) cũ, ta chia batch thành k microbatch, gọi `backward()` cho từng microbatch và chỉ gọi `optimizer.step()` sau k lần. PyTorch **cộng** gradient vào `.grad` qua các lần backward; loss mặc định lại là trung bình trong batch, nên mỗi loss microbatch phải chia cho k thì tổng mới bằng gradient trung bình của cả batch. Thí nghiệm dưới so gradient của một batch 32 mẫu với bốn microbatch 8 mẫu, có và không chia loss:

```
Python
```

```
torch.manual_seed(7)
X_acc = torch.randn(32, 2)
y_acc = (X_acc[:, 0] > 0).long()
net = nn.Sequential(nn.Linear(2, 8), nn.ReLU(), nn.Linear(8, 2))

def gradient_vector(module):
    return torch.cat([p.grad.flatten() for p in module.parameters()])

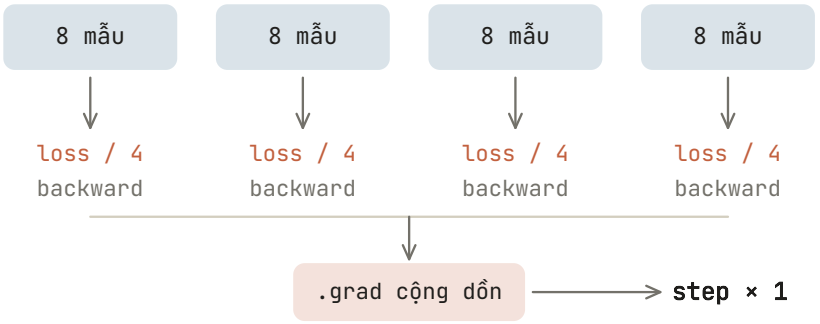
net.zero_grad(set_to_none=True)
criterion(net(X_acc), y_acc).backward()            # cả batch 32 mẫu một lần
full_grad = gradient_vector(net).clone()

accumulation_steps = 4
for divide_loss in (True, False):
    net.zero_grad(set_to_none=True)
    for x_part, y_part in zip(X_acc.chunk(accumulation_steps),
y_acc.chunk(accumulation_steps)):
        micro_loss = criterion(net(x_part), y_part)  # mỗi microbatch 8 mẫu
        if divide_loss:
            micro_loss = micro_loss / accumulation_steps
        micro_loss.backward()                          # .grad cộng dồn qua các lần backward
    accumulated = gradient_vector(net)
    ratio = (accumulated.norm() / full_grad.norm()).item()
    print('divide by 4:', divide_loss, '| norm ratio:', round(ratio, 4),
          '| matches full batch:', torch.allclose(accumulated, full_grad, atol=1e-6))
```

KẾT QUẢ

```
divide by 4: True | norm ratio: 1.0 | matches full batch: True
divide by 4: False | norm ratio: 4.0 | matches full batch: False
```

Khi chia loss cho 4, gradient cộng dồn trùng gradient của batch 32 tới sai số làm tròn. Không chia, gradient lớn gấp đúng 4 lần: với SGD, điều đó tương đương lặng lẽ nhân learning rate với 4. Phép trùng cần hai điều kiện. Các microbatch phải bằng nhau; microbatch cuối thiếu mẫu thì phải chia theo số mẫu thật. Mạng cũng không được có lớp tính thống kê theo batch: BatchNorm chuẩn hóa theo từng microbatch 8 mẫu, nên accumulation không tái tạo được thống kê của batch 32. Bộ nhớ activation chỉ còn cỡ một microbatch, còn weight, gradient và trạng thái optimizer giữ nguyên. Mỗi optimizer step tốn k lượt forward/backward nối tiếp, nên accumulation tiết kiệm bộ nhớ chứ không tăng tốc. Số lần cập nhật chia cho k: 50 000 mẫu, batch 128 có 390 batch đủ mỗi epoch, 10 epoch với $k = 4$ cho 975 lần step.



Gradient accumulation: bốn microbatch 8 mẫu, mỗi cái backward với loss chia 4, .grad cộng dồn rồi mới step một lần; kết quả trùng gradient của batch 32.

HỎI NHANH

Batch 64 bị OOM, batch 16 thì chạy được. Ta dùng accumulation 4 microbatch, mỗi microbatch 16 mẫu, trên 6400 mẫu train. Mỗi epoch có bao nhiêu lần `backward()` và bao nhiêu lần `optimizer.step()`?

A 100 lần backward, 100 lần step

B 400 lần backward, 400 lần step

C 100 lần backward, 400 lần step

D 400 lần backward, 100 lần step

Mixed precision là lựa chọn số học

Mixed precision dùng dtype thấp hơn cho những phép chịu được và giữ những phép nhạy ở FP32. `autocast` chọn dtype theo từng phép: nhân ma trận và convolution chạy FP16, còn softmax, log, exp, phép tổng và phần lớn hàm loss giữ FP32. Model không bị ép toàn bộ thành half, và bản trọng số mà optimizer cập nhật vẫn là FP32. Lợi ích là nhiều activation chỉ còn 2 byte thay vì 4, và Tensor Core của GPU chạy phép FP16 nhanh hơn nhiều. Cái giá là FP16 chỉ biểu diễn được một khoảng số hẹp.

Gradient ở nhiều lớp rất nhỏ. FP16 không biểu diễn được số dương nhỏ hơn khoảng $6 \cdot 10^{-8}$, nên một gradient cỡ 10^{-8} bị làm tròn về 0. GradScaler nhân loss với một hệ số lớn (mặc định khởi đầu $2^{16} = 65\,536$) trước backward; theo quy tắc chuỗi, mọi gradient cũng được nhân theo, rồi được chia lại trước khi optimizer cập nhật. Phép thử trên CPU cho thấy cơ chế:

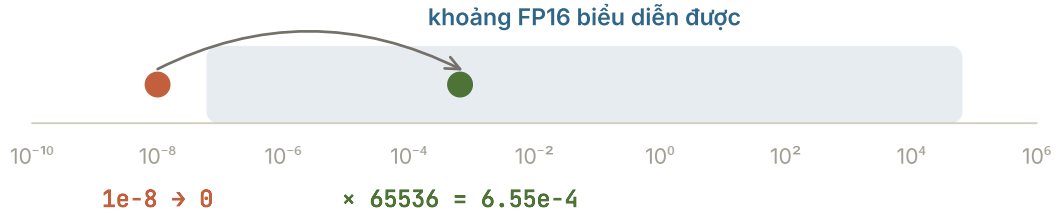
Python

```
tiny_grad = torch.tensor(1e-8)
scale = 65536.0
print('FP16 of 1e-8:', tiny_grad.half().item())
scaled_half = (tiny_grad * scale).half()
print('FP16 of 1e-8 * 65536:', round(scaled_half.item(), 8))
print('unscaled in FP32:', f'{scaled_half.float().item() / scale:.4e}')
```

KẾT QUẢ

```
FP16 of 1e-8: 0.0
FP16 of 1e-8 * 65536: 0.00065517
unscaled in FP32: 9.9972e-09
```

Đưa thẳng 10^{-8} vào FP16 cho 0: gradient ấy mất hẳn. Nhân 65536 trước thì được $6.55 \cdot 10^{-4}$, nằm gọn trong khoảng của FP16; chia lại ở FP32 cho $9.9972 \cdot 10^{-9}$, lệch khoảng 0.03% vì FP16 chỉ giữ được khoảng ba chữ số có nghĩa. Nếu hệ số lớn quá làm gradient tràn thành inf hoặc NaN, `scaler.step` bỏ qua bước đó và `scaler.update()` giảm hệ số; sau một chuỗi bước ổn định, hệ số được tăng lại. GradScaler không chữa được nhãn sai hay learning rate quá lớn. Bản trọng số FP32 cũng cần vì một lý do tương tự: cập nhật thường nhỏ hơn trọng số rất nhiều, và trong FP16 phép cộng $1 + 10^{-4}$ làm tròn về đúng 1, nên cập nhật sẽ mất nếu cộng thẳng vào bản 16 bit. BF16 có cùng khoảng số mũ với FP32 nên thường không cần scaler, nhưng chỉ chạy nhanh trên GPU từ thế hệ Ampere trở đi; với T4, mixed precision nghĩa là FP16 kèm GradScaler.



Gradient 10^{-8} nằm dưới số dương nhỏ nhất của FP16 nên thành 0; GradScaler nhân 65536 đưa nó vào khoảng biểu diễn được ($6.55 \cdot 10^{-4}$), rồi chia lại ở FP32.

HỎI NHANH

GradScaler nhân loss với 65536 trước khi backward. Vì sao bước cập nhật không lớn gấp 65536 lần?

A Gradient được chia lại trước khi cập nhật

B Learning rate cũng tự chia cho 65536

C FP16 tự làm tròn gradient về giá trị thật

D Hệ số chỉ nhân vào con số loss in ra log

Thứ tự một step trong recipe: autocast cho forward và loss → `scaler.scale(loss).backward()` → `scaler.unscale_(optimizer)` → clip nếu cần → `scaler.step(optimizer)` → `scaler.update()`. Clip phải đứng sau `unscale_`: trước đó norm gradient còn lớn gấp hệ số scale, nên ngưỡng clip 1.0 gần như luôn bị kích hoạt và sau khi chia lại, gradient bị thu nhỏ quá mức. Recipe dùng API `torch.amp` theo tài liệu PyTorch 2.9; mã cũ hơn viết `torch.cuda.amp`.

Chuyển sang máy có CUDA theo recipe

Phần đo tốc độ nằm trong recipe gpu_probe.py, chạy riêng trên máy có GPU. Recipe tự tạo một MLP 512→256→10 với AdamW và một batch ngẫu nhiên ngay trên GPU, nên

không cần tải dữ liệu hay model. Lệnh đầu chỉ kiểm môi trường: in phiên bản PyTorch, bản CUDA mà PyTorch được build kèm và trạng thái `CUDA_READY` hoặc `CPU_ONLY`. Hai lệnh sau chạy benchmark ở FP32 và ở mixed precision:

```
python content/phase-3/recipes/gpu_probe.py
python content/phase-3/recipes/gpu_probe.py --run --precision fp32
python content/phase-3/recipes/gpu_probe.py --run --precision amp
```

Benchmark cần GPU CUDA hoạt động và bản PyTorch tương thích. Trên máy chỉ có CPU, recipe dừng với `CUDA_NOT_AVAILABLE`; khi hết bộ nhớ, nó dừng với `CUDA_OOM` và gợi ý giảm `--batch`. Mỗi lượt chạy 5 step warmup, đồng bộ, đặt lại bộ đếm peak memory, đo 50 step (đổi bằng `--warmup`, `--steps`) rồi đồng bộ lần nữa.

Kết quả là một dòng JSON gồm tên GPU (`device`), `milliseconds_per_step`, `samples_per_second` (batch × số step chia thời gian), `peak_allocated_MiB` (bộ nhớ tensor dùng lúc cao nhất) và `peak_reserved_MiB` (phần allocator giữ, thường lớn hơn vì có cache). So hai dòng FP32 và AMP cùng batch để thấy mixed precision tiết kiệm bao nhiêu thời gian và bộ nhớ trên đúng card đó. Nếu môi trường thi cấp T4, chạy chính phép đo ấy trên T4: số giây không suy ra được từ tên card. Phần đo chỉ gồm loop training trên batch đã ở GPU (`includes_data_loading: false`); nếu đọc ảnh hay chép CPU→GPU mới là nút thắt, phải đo riêng pipeline đầy đủ.

CUDA chạy bất đồng bộ: CPU xếp lệnh vào hàng đợi rồi đi tiếp ngay, nên đồng hồ CPU đọc lúc ấy chỉ đo việc gửi lệnh dù GPU chưa làm xong. Đồng bộ trước và sau đoạn đo, hoặc dùng CUDA events, mới đo được công việc thực. Không gọi `.item()` ở mỗi batch trong benchmark nếu không cần, vì lấy số về CPU buộc phải đồng bộ và làm thay đổi chính thứ đang đo.

GPU nhanh nhờ chạy song song hàng nghìn phép trên tensor lớn. Mạng 42 tham số với batch 4 ở đầu bài thì ngược lại: mỗi step chỉ vài trăm phép nhân, còn chi phí khởi chạy kernel, chép dữ liệu và đồng bộ là cố định, nên trên GPU nó có thể chậm hơn trên CPU.

HỎI NHANH

Đo thời gian chạy CUDA bằng `time.perf_counter()` của CPU mà không synchronize. Con số đo được có thể phản ánh điều gì?

A Thời gian GPU thực sự chạy hết các kernel

B Thời gian chép dữ liệu từ ổ đĩa lên GPU

C Thời gian đã tự trừ đi các bước khởi động

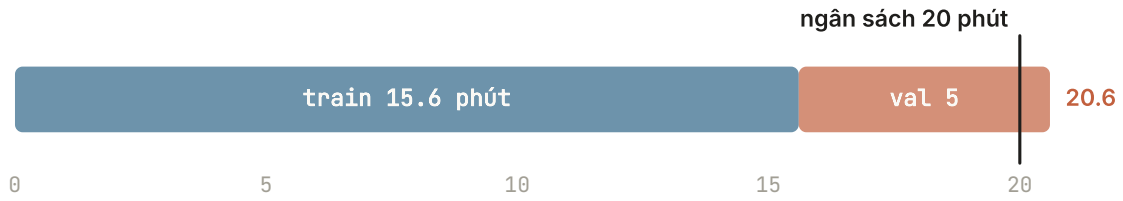
D Phần lớn chỉ là thời gian CPU gửi lệnh đi

Ước lượng thời gian chạy

Gọi t là median step time đo trên những batch đại diện. Với N mẫu, batch B và E epoch, phần train xấp xỉ

$$T_{\text{train}} \approx E \left\lceil \frac{N}{B} \right\rceil t.$$

Lấy median sau warmup, vì vài step đầu chậm do khởi tạo kernel và allocator. Chẳng hạn $N = 50\,000$, $B = 128$ cho $\lceil 390.6 \rceil = 391$ step mỗi epoch; nếu đo được $t = 0.12$ giây thì 20 epoch tốn $20 \cdot 391 \cdot 0.12 \approx 938$ giây, khoảng 15.6 phút. Batch tăng thông lượng chứ không giảm độ trễ: một batch 32 ảnh mất 0.4 giây là 80 ảnh mỗi giây, gấp 4 lần chạy từng ảnh 0.05 giây, nhưng ảnh nào cũng phải chờ cả batch xong. Đó mới là phần train: còn validation, đọc dữ liệu, lưu checkpoint và thời gian khởi động. t phải đo với shape giống dữ liệu thật trên đúng phần cứng được cấp; số đo của mạng rất nhỏ không dùng để suy ra cho model pretrained lớn.



20 epoch × 391 step × 0.12 s, cộng 20 lần validation 15 s

Ước lượng ngân sách: train 20 × 391 × 0.12 s ≈ 15.6 phút, cộng validation 5 phút đã vượt 20 phút trước khi tính đọc dữ liệu và checkpoint.

HỎI NHANH

Tiếp ví dụ trên, với t đã đo trên chính máy được cấp: phần train mất khoảng 15.6 phút, ngân sách là 20 phút, và mỗi epoch còn có validation đo được 15 giây. Kế hoạch 20 epoch có vừa không?

A Vừa, còn dư hơn 4 phút cho phần khác

B Vừa, vì validation dùng `no_grad` nên gần như không tốn

C Không vừa, cộng validation vào đã khoảng 20.6 phút

D Chưa biết được, phải đo lại t trên T4

Khi đi thi

- **Kiểm một batch trước khi chạy dài.** Overfit 4–16 mẫu, assert shape và `torch.isfinite` cho loss, gradient; lỗi bắt ở đây rẻ hơn nhiều so với lỗi lộ ra sau một giờ GPU.
- **Đọc môi trường ở ô đầu tiên.** In `torch.cuda.is_available()`, tên GPU và phiên bản PyTorch; đọc luật về giờ GPU, Internet và thư viện của đề trước khi chọn model.
- **Quy ngân sách ra số step.** Đo median t sau warmup, tính $E\lceil N/B\rceil t$, cộng validation, I/O, checkpoint và để dư cho một lần chạy lại.
- **OOM: sửa có thứ tự.** Giảm batch hoặc độ dài, bật mixed precision, dùng accumulation với loss chia k; khởi động lại tiến trình sau khi sửa. Model có

BatchNorm thì microbatch nhỏ làm đổi thống kê.

- **Lưu sớm, lưu thường xuyên.** Phiên GPU có thể bị ngắt khi hết giờ: ghi `state_dict` mỗi epoch và tạo file submission từ checkpoint tốt nhất ngay khi có.

Tóm tắt

Kiểm khả năng học trước, đo tốc độ sau. Shape/dtype/device, số hữu hạn và graph sống là các điểm cần khoanh vùng, bắt đầu từ nơi lỗi xuất hiện đầu tiên. VRAM gồm trọng số, gradient, trạng thái optimizer, activation và phần tạm; giảm batch chỉ giảm phần activation. Gradient accumulation giữ batch hiệu dụng khi loss mỗi microbatch được chia k, đổi bộ nhớ lấy thời gian. Mixed precision cần autocast và GradScaler đúng thứ tự, unscale trước khi clip. Số hiệu năng phải đo trên phần cứng và pipeline thực tế.

Kiểm tra cuối bài

CÂU 1

Training ổn định suốt 22 epoch, sang epoch 23 thì loss đột ngột thành NaN. Muốn tìm ra nguyên nhân thay vì đoán, cách nào chặt chẽ nhất?

A Giảm learning rate 10 lần, thêm clip, chuyển sang AMP

B Bật anomaly detection, ghi log activation, và xem batch gây lỗi

C Cộng epsilon vào mọi mẫu số rồi train lại từ epoch 1

D Thay BatchNorm bằng LayerNorm, và thu nhỏ model

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 283

CÂU 2

Vòng validation không bọc trong `torch.no_grad()`, và chạy `val_losses.append(loss)` sau mỗi batch. VRAM tăng dần qua các batch validation, rồi OOM. Sửa thế nào cho đúng gốc?

A Bọc vòng lặp trong `torch.no_grad()`, và lưu `loss.item()`

B Gọi `torch.cuda.empty_cache()` sau mỗi batch validation

C Gọi `model.eval()` trước vòng validation là đủ

D Giảm batch validation một nửa, giữ nguyên code

CÂU 3

Fine-tune một mô hình ngôn ngữ BERT 110 triệu tham số bằng AdamW FP32 trên GPU 16 GB. Batch 32 với chuỗi dài 512 bị OOM. Phần weight, gradient và hai moment chiếm khoảng bao nhiêu, và phần còn lại chủ yếu là gì?

A Khoảng 0.44 GB, phần còn lại chủ yếu là activation

B Khoảng 0.44 GB, OOM là do số tham số quá lớn

C Khoảng 1.76 GB, OOM là do số tham số quá lớn

D Khoảng 1.76 GB, phần còn lại chủ yếu là activation

CÂU 4

Train một mạng phân loại ảnh ResNet-50 với batch 128 trên GPU 16 GB có Tensor Core cho FP16 thì OOM, dù chỉ vượt bộ nhớ một chút. Cách nào cân bằng tốt nhất giữa bộ nhớ và tốc độ?

A Accumulation 4 microbatch × 32, kèm gradient checkpointing

B Mixed precision FP16, kèm loss scaling động

C Giảm batch còn 32, chấp nhận gradient nhiễu hơn

D Gọi `empty_cache()` sau mỗi backward, và bật `pin_memory`

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 285

CÂU 5

Fine-tune BERT 110 triệu tham số trên GPU 16 GB. Batch 32 bị OOM, còn batch 8 vừa bộ nhớ nhưng training dao động. Ta dùng gradient accumulation với `accumulation_steps=4`. Kết quả là gì?

A Nhanh gấp 4, vì bốn microbatch được tính song song

B Bộ nhớ giảm 75%, vì gradient bị bỏ sau mỗi microbatch

C Accuracy tăng, vì nhiễu gradient đóng vai trò regularization

D Batch hiệu dụng là 32, còn activation chỉ cần cho 8 mẫu

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 296

CÂU 6

Vòng gradient accumulation:

```
accumulation_steps = 4
optimizer.zero_grad()
for i, (inputs, targets) in enumerate(loader):
    loss = criterion(model(inputs), targets)
    loss = loss / accumulation_steps      # dòng A
    loss.backward()
    if (i + 1) % accumulation_steps == 0:
        optimizer.step()
        optimizer.zero_grad()
```

Vì sao cần dòng A?

A Để gradient cộng dồn bằng đúng gradient của cả batch lớn

B Để tránh tràn số khi gọi backward nhiều lần liên tiếp

C Không bắt buộc, dòng A chỉ đổi con số loss in ra log

D Để bù cho thống kê BatchNorm vốn tính trên microbatch nhỏ

ĐỀ THI NOAI 2026 Singapore · Chung kết · Câu 11

CÂU 7

Ba cách viết một bước mixed precision, sau khi đã tính `loss` trong `autocast`:

```
# Cách A
loss.backward(); optimizer.step()
# Cách B
scaler.scale(loss).backward(); scaler.step(optimizer); scaler.update()
# Cách C
scaler.scale(loss).backward()
scaler.unscale_(optimizer)
torch.nn.utils.clip_grad_norm_(model.parameters(), max_norm=1.0)
scaler.step(optimizer); scaler.update()
```

Cách A làm training hỏng, cách B chạy tốt. Khi nào phải dùng cách C thay cho B?

A Khi mạng rất sâu, để chống gradient bùng nổ

B Khi có clip gradient, để ngưỡng clip đúng nghĩa

C Khi batch rất nhỏ làm gradient dao động mạnh

D Chỉ khi debug, để in ra độ lớn gradient thật

ĐỀ THI NOAI 2026 Singapore · Chung kết · Câu 16

CÂU 8

Chuyển đúng mạng $2 \to 8 \to 2$ ở đầu bài, batch 4 mẫu, sang GPU. Mỗi bước lại chậm hơn trên CPU. Lý do hợp lý nhất là gì?

A Việc quá nhỏ, nên chi phí gọi kernel và chép dữ liệu lấn át

B GPU chỉ nhanh hơn CPU khi đã bật mixed precision

C Adam phải chép hai moment về CPU sau mỗi bước

D Batch 4 không chia hết cho số lõi tính của GPU

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 144

CÂU 9

Giả sử chạy `gpu_probe.py --run --batch 128`, và dòng JSON báo `milliseconds_per_step` bằng 25. Thông lượng là bao nhiêu, và con số ấy đã tính cả việc đọc dữ liệu chưa?

A 3200 mẫu mỗi giây, đã tính cả đọc dữ liệu

B 3200 mẫu mỗi giây, chưa tính đọc dữ liệu

C 5120 mẫu mỗi giây, chưa tính đọc dữ liệu

D 5120 mẫu mỗi giây, đã tính cả đọc dữ liệu

CÂU 10

Ngân sách 140 giờ GPU, và ResNet-50 cần 90 epoch để hội tụ. Số đo sau 90 epoch: batch 256 đạt top-1 76.5%, mỗi epoch 8 giờ. Batch 2048, dùng optimizer LARS cho batch lớn và warmup 5 epoch, đạt 75.8%, mỗi epoch 1.5 giờ. Batch 8192 đạt 73.2%, mỗi epoch 0.5 giờ. Chọn cách nào để accuracy cao nhất trong ngân sách?

A Batch 256, chạy tới khi hết ngân sách

B Batch 8192 đủ 90 epoch, chỉ hết 45 giờ

C Accumulation 4 × 2048, vừa có tốc độ của 8192 vừa có chất lượng của 2048

D Batch 2048 với LARS và warmup, chạy đủ 90 epoch

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 295

Đọc thêm

- PyTorch 2.9 — CUDA semantics: đọc bất đồng bộ, synchronize, allocator và phép đo thời gian.
- PyTorch 2.9 — AMP: tra autocast, GradScaler và dtype theo phép.
- PyTorch — AMP examples: đọc gradient clipping sau unscale và accumulation đúng.

Nguồn ảnh: ảnh quần áo lấy từ bộ Fashion-MNIST của Zalando (giấy phép MIT).

Tải gói recipe của chương — gồm các module phụ và hướng dẫn chuẩn bị asset.