Embedding và dữ liệu chuỗi

Đưa câu dài ngắn khác nhau vào mạng.

> Một bài luyện tập có tên hai từ, bài khác có tên sáu từ. Muốn xử lý nhiều tên trong một batch, ta cần bảng chữ nhật, nhưng chuỗi không tự có cùng độ dài. Thêm số 0 cho đủ bảng chỉ là cách lưu; model phải biết các ô thêm ấy không phải từ thật. Bài này nối thao tác mảng trong CP với embedding, padding, mask, pooling và RNN. Câu hỏi xuyên suốt: thêm PAD có làm đổi biểu diễn của câu không?

MỤC TIÊU SAU BÀI NÀY

- Đổi token ID thành vector bằng embedding và ghi shape `(B,L,d)`.
- Ghép chuỗi bằng padding và mask; tính masked mean bằng tay và kiểm bất biến khi thêm PAD.
- Nhận ra mean pooling bỏ thứ tự; đọc trạng thái RNN đúng vị trí khi có PAD.
- Giải thích vì sao gradient tắt dần trên chuỗi dài và LSTM sửa theo hướng nào.

ID là địa chỉ, không phải độ lớn

Giả sử mã "đồ_thị" là 2 và "dp" là 3. Không có nghĩa dp lớn hơn đồ thị một đơn vị về kiến thức. Đưa ID thẳng vào lớp linear như một số thực sẽ tạo một quan hệ số không có cơ sở. Embedding dùng ID làm địa chỉ hàng trong bảng E shape `(V,d)`, với V là số token trong vocabulary, d là số thành phần vector.

One-hot $\mathbf{u}_k$ (số 1 ở vị trí k, còn lại 0) nhân bảng cũng chọn đúng hàng k: $\mathbf{u}_k^\top E = E_k$. Lookup trực tiếp cho cùng kết quả mà không phải tạo one-hot rộng V cột. Các hàng của embedding là tham số; gradient từ loss sửa các hàng đã được dùng. Khi khởi tạo ngẫu nhiên, vector chưa có nghĩa ngôn ngữ. Ý nghĩa đến từ mục tiêu học trên dữ liệu (mục backprop dưới đây) hoặc từ một bảng pretrained đã học sẵn.

Ta quy ước `PAD=0`, `UNK=1`, đồ_thị=2, dp=3, toán=4. UNK là token thật để biểu diễn token chưa biết; PAD là phần điền cho bảng. Hai vai trò cần hai ID khác nhau. Vocabulary và

mapping phải lưu cùng checkpoint: fit vocabulary trên train, token mới gặp ở test ánh xạ về UNK (hoặc do tokenizer đã có xử lý).

HỎI NHANH

Một bạn đưa thẳng cột ID, với đồ_thị = 2, dp = 3, toán = 4, vào `nn.Linear(1, 8)` như một feature số. Câu nào đúng?

A Linear tự học một vector riêng cho từng ID, giống Embedding

B Đầu ra là hàm tuyến tính của ID, nên đánh số lại là đổi model

C Chuẩn hóa ID bằng mean và std trước thì thành lookup đúng nghĩa

D Không sao, nếu ID được gán theo thứ tự tần suất xuất hiện

HỎI NHANH

Vocabulary có 50 000 token, embedding rộng 300, batch token ID có shape `(32, 128)`. Nếu tạo one-hot float32 rồi nhân với bảng thay cho lookup, riêng tensor one-hot chiếm khoảng bao nhiêu?

A Khoảng 4.9 MB, bằng đầu ra lookup `(32, 128, 300)`

B Khoảng 60 MB, bằng bảng embedding `(50000, 300)`

C Khoảng 819 MB, so với 4.9 MB của đầu ra lookup

D Khoảng 16 KB, vì one-hot chỉ lưu một số 1 cho mỗi token

Padding tạo bảng, mask giữ ý nghĩa

Trong CP, thường lưu độ dài bên cạnh mảng chứa dư. Mask cũng là thông tin ấy nhưng biểu diễn theo từng ô. `pad_sequence` tạo độ dài bằng chuỗi dài nhất trong batch, không

nhất thiết độ dài toàn dataset. Nếu giới hạn độ dài bằng truncation, ta đang bỏ thông tin thật và phải chọn giới hạn theo bài toán.

Python

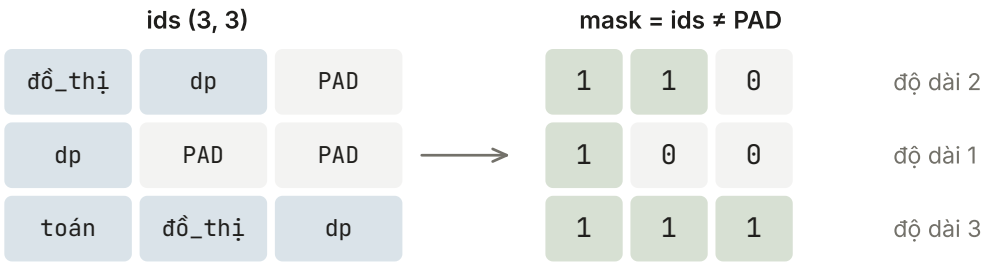
```python
import torch
from torch import nn
from torch.nn.utils.rnn import pad_sequence

torch.set_num_threads(1)
torch.manual_seed(37)
PAD, UNK = 0, 1
sequences = [torch.tensor([2, 3]), torch.tensor([3]), torch.tensor([4, 2, 3])]
ids = pad_sequence(sequences, batch_first=True, padding_value=PAD)
valid_mask = ids.ne(PAD)
print(ids.tolist())
print(valid_mask.int().tolist())
print('lengths:', valid_mask.sum(dim=1).tolist())
```

KẾT QUẢ

```
[[2, 3, 0], [3, 0, 0], [4, 2, 3]]
[[1, 1, 0], [1, 0, 0], [1, 1, 1]]
lengths: [2, 1, 3]
```

Đọc độ dài 2, 1, 3; chiều bảng là `(3,3)` vì có ba mẫu và chuỗi dài nhất có ba token. Tokenizer chi tiết ở chương ngôn ngữ; bài này bắt đầu khi đã có token ID. Index embedding phải là số nguyên trong `[0,V)`, không được chuẩn hóa ID bằng mean/std như feature liên tục.



bảng rộng bằng câu dài nhất trong batch; ô xám là PAD

Ba câu của bài sau pad_sequence thành bảng (3, 3); mask đánh dấu 1 ở token thật, nên tổng mỗi hàng chính là độ dài câu.

HỎI NHANH

Một batch gồm ba câu dài 5, 12 và 7 token. Câu dài nhất của cả dataset có 200 token. `pad_sequence(..., batch_first=True)` cho ra tensor shape gì, và có bao nhiêu ô PAD?

A `(3, 12)`, 12 ô PAD

B `(12, 3)`, 12 ô PAD

C `(3, 12)`, không lưu ô PAD nào

D `(3, 200)`, 576 ô PAD

Một bảng embedding đặt tay để nhìn phép tính

Để mọi phép tính đọc được bằng mắt, ta đặt tay các vector hai chiều: đồ_thị $[2, 0]$, dp $[0, 4]$, toán $[2, 2]$, UNK $[1, 1]$, PAD $[0, 0]$. Trong model thật, các hàng này là tham số học từ dữ liệu. `padding_idx=0` làm hai việc: khởi tạo hàng PAD bằng 0 và chặn gradient đi vào hàng ấy. Nó không canh giữ hàng PAD về sau: `copy_` dưới đây, hay nạp một checkpoint, ghi đè cả hàng 0 bằng đúng giá trị được nạp, nên sau khi nạp cần tự kiểm hàng PAD.

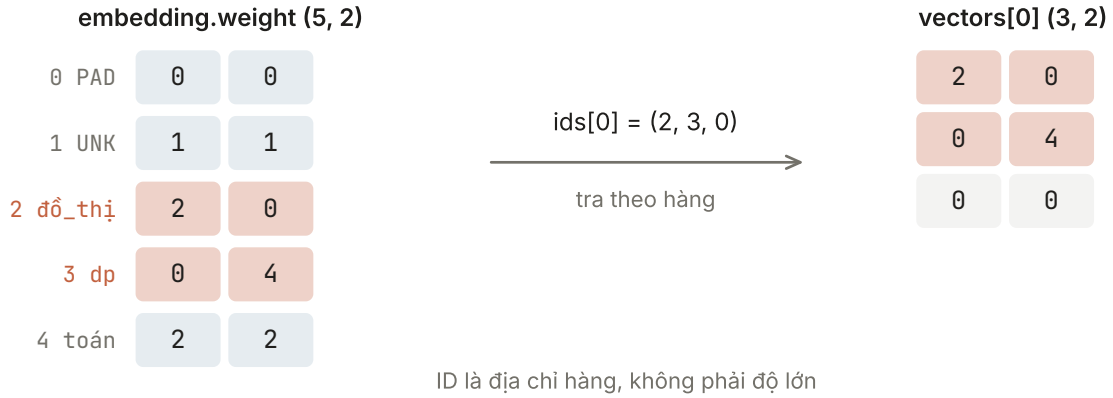
Python

```
table = torch.tensor([[0., 0.], [1., 1.], [2., 0.], [0., 4.], [2., 2.]])
embedding = nn.Embedding(5, 2, padding_idx=PAD)
with torch.no_grad():
    embedding.weight.copy_(table)
vectors = embedding(ids)
print('shapes:', tuple(ids.shape), tuple(embedding.weight.shape), tuple(vectors.shape))
print(vectors[0].tolist())
```

KẾT QUẢ

```
shapes: (3, 3) (5, 2) (3, 3, 2)
[[2.0, 0.0], [0.0, 4.0], [0.0, 0.0]]
```

`ids (B,L)` tra mỗi ô ra d số nên `vectors` là `(B,L,d)`, ở đây `(3,3,2)`. Câu đầu gồm hai token và PAD; hàng cuối vector 0 vẫn là một ô trong tensor. Nếu gọi mean theo toàn chiều L, phép chia sẽ tính cả ô đó vào mẫu số. Đó là lỗi dù PAD vector đã bằng 0.



Bảng embedding đặt tay của bài: câu đầu (2, 3, PAD) tra ra ba hàng của bảng, nên vectors có thêm chiều cuối d = 2.

Đại lượng	Shape	Ý nghĩa
`ids`	`(B,L)` long	ID từng token
`embedding.weight`	`(V,d)` float	Bảng tham số
`vectors`	`(B,L,d)` float	Vector từng token
`valid_mask`	`(B,L)` bool	True là token thật trong code bài này
`pooled`	`(B,d)` float	Một vector cho mỗi chuỗi

HỎI NHANH

Input ID có shape `(8, 12)`, embedding rộng 16. Đầu ra có shape gì?

A `(8, 16)`

B `(12, 16)`

C `(8, 16, 12)`

D `(8, 12, 16)`

HỎI NHANH

Tạo `nn.Embedding(5, 2, padding_idx=0)`, rồi nạp một checkpoint có hàng 0 bằng `[0.3, -0.1]`. Lookup một ô PAD trả về gì, và masked mean của bài còn đúng không?

A `[0, 0]`, masked mean vẫn đúng

B `[0, 0]`, masked mean sai theo

C `[0.3, -0.1]`, masked mean vẫn đúng

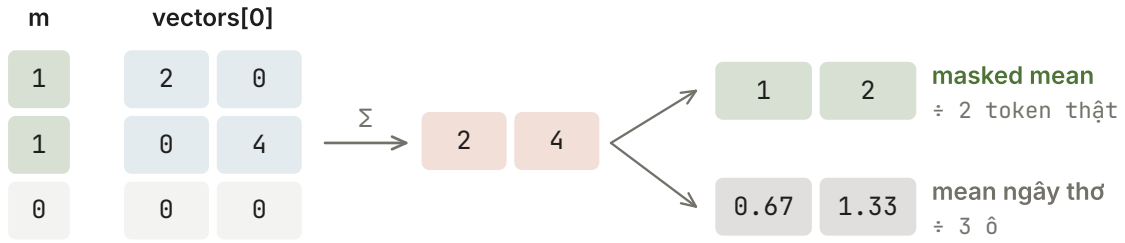
D `[0.3, -0.1]`, masked mean sai theo

Masked mean giống đếm phần tử hợp lệ

Muốn một vector cho cả chuỗi, cách baseline là trung bình các token thật. Gọi $m_{i,t}$ bằng 1 ở token hợp lệ, 0 ở PAD, ta có

$$\mathbf{s}_i = \frac{\sum_{t=1}^{L} m_{i,t}\mathbf{e}_{i,t}}{\sum_{t=1}^{L} m_{i,t}}.$$

Tử số là tổng vector; mẫu số là số token thật. Mask `(B,L)` cần thêm chiều cuối thành `(B,L,1)` để nhân với vectors `(B,L,d)`. Tổng theo `dim=1` gộp độ dài, giữ batch và đặc trưng. Kết quả giống xử lý truy vấn tổng rồi chia số phần tử trong CP: mẫu số sai thì tổng đúng vẫn cho đáp án sai.



Masked mean của câu đầu: cộng vector theo mask được (2, 4), chia cho 2 token thật ra (1, 2); chia cho cả 3 ô thì ra (0.67, 1.33).

Python

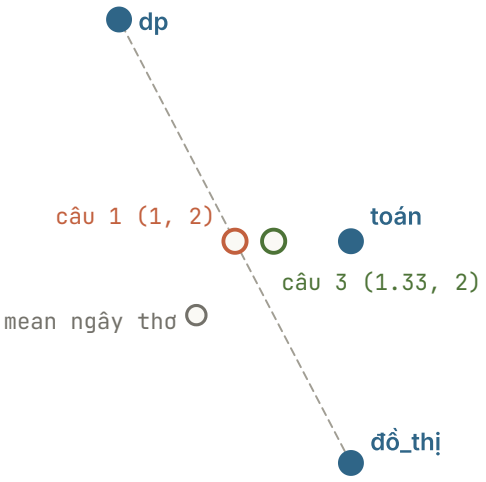
```python
def masked_mean(vectors, valid_mask):
    assert vectors.shape[:2] == valid_mask.shape
    counts = valid_mask.sum(dim=1, keepdim=True)
    if torch.any(counts == 0):
        raise ValueError('Mỗi chuỗi cần ít nhất một token hợp lệ')
    weighted = vectors * valid_mask.unsqueeze(-1)
    return weighted.sum(dim=1) / counts

pooled = masked_mean(vectors, valid_mask)
print('masked:', [[round(v, 4) for v in row] for row in pooled.tolist()])
print('naive first:', [round(v, 4) for v in vectors.mean(dim=1)[0].tolist()])
```

KẾT QUẢ

```
masked: [[1.0, 2.0], [0.0, 4.0], [1.3333, 2.0]]
naive first: [0.6667, 1.3333]
```

Câu đầu đúng là $([2,0]+[0,4])/2=[1,2]$, còn mean ngây thơ chia 3 cho $[2/3,4/3]$. Câu chỉ dp vẫn phải ra $[0,4]$ bất kể nó được pad dài bao nhiêu. Câu thứ ba có $([2,2]+[2,0]+[0,4])/3=[4/3,2]$. Các số ấy giúp kiểm độc lập đoạn pooling.



Vector token đặt tay trong mặt phẳng: câu 1 là trung điểm của đồ_thị và dp; mean ngây thơ chia cho 3 ô (tính cả PAD) kéo điểm về phía gốc.

HỎI NHANH

Vector của PAD bằng 0. Hai token thật có tổng vector là $(4, 6)$. Câu được pad thêm hai PAD, và code lấy mean trên cả bốn vị trí, ra $(1, 1.5)$. Sai ở đâu?

A Ở tử số, vì hai PAD đã cộng thêm vào tổng

B Ở mẫu số, vì chia cho 4 vị trí thay vì 2 token thật

C Ở mask, vì mask chỉ cần khi PAD mang ID âm

D Không sai, vì PAD bằng 0 nên mean nào cũng như nhau

HỎI NHANH

Trong `masked_mean`, một bạn bỏ `keepdim=True`, nên `counts` có shape `(B,)`. Chạy với hai câu đầu của bài, `[2, 3]` và `[3]`, tức $B = d = 2$, code không báo lỗi. Kết quả là gì?

```
counts = valid_mask.sum(dim=1)          # shape (2,)
return weighted.sum(dim=1) / counts     # (2,2) / (2,)
```

A `[[1, 2], [0, 4]]`, như bản đúng

B `[[1, 2], [0, 2]]`

C Báo lỗi broadcast, vì hai tensor khác số chiều

D `[[1, 4], [0, 4]]`

Kiểm bất biến khi thêm PAD

Một phép kiểm có ý nghĩa là thêm hai cột PAD và yêu cầu vector pooling không đổi. Đây giống kiểm tính bất biến của thuật toán khi thêm phần tử ngoài miền truy vấn. Ta còn kiểm đầu vào rỗng: không muốn chia 0, cũng không muốn âm thầm trả vector 0 rồi nhầm thành một câu hợp lệ.

Python

```
extra_ids = torch.cat([ids, torch.zeros(len(ids), 2, dtype=torch.long)], dim=1)
extra_pooled = masked_mean(embedding(extra_ids), extra_ids.ne(PAD))
print('adding PAD changes nothing:', torch.allclose(pooled, extra_pooled))
try:
    empty_ids = torch.zeros(1, 3, dtype=torch.long)
    masked_mean(embedding(empty_ids), empty_ids.ne(PAD))
except ValueError:
    print('empty sequence rejected:', True)
```

KẾT QUẢ

```
adding PAD changes nothing: True
```

```
empty sequence rejected: True
```

Hai dòng True kiểm hai hợp đồng khác nhau: padding vô nghĩa không làm đổi kết quả; chuỗi rỗng bị xử lý rõ. Bài thật có thể quy định câu rỗng thành một token đặc biệt EMPTY hoặc UNK, nhưng quy tắc phải nằm trong dataset và áp dụng giống train/test. `clamp_min(1)` có thể tránh chia 0 nhưng không tự giải thích ý nghĩa câu rỗng.

HỎI NHANH

Thay `raise ValueError` bằng `counts.clamp_min(1)`, rồi chạy trên một câu toàn PAD. Chuyện gì xảy ra?

A Lỗi chia cho 0, chương trình dừng ngay ở câu ấy

B Trả về nan, loss thành nan nên lỗi lộ ra ngay

C Trả về vector 0, rồi trôi vào classifier như một câu thật

D Trả về embedding của UNK, vì câu rỗng là token lạ

Embedding cũng học bằng backprop

Để đọc gradient bằng mắt, đặt loss là tổng mọi thành phần của các vector lookup. Mỗi lần token xuất hiện, hàng embedding của nó nhận gradient $[1, 1]$; cộng qua các vị trí ra đúng số lần dùng. Hàng PAD nhận 0 vì `padding_idx`.

Python

```
embedding.zero_grad(set_to_none=True)
embedding(ids).sum().backward()
print('gradient rows:', embedding.weight.grad.tolist())
print('PAD has zero gradient:', embedding.weight.grad[PAD].eq(0).all().item())
classifier = nn.Linear(2, 2)
print('classifier logits shape:', tuple(classifier(pooled.detach()).shape))
```

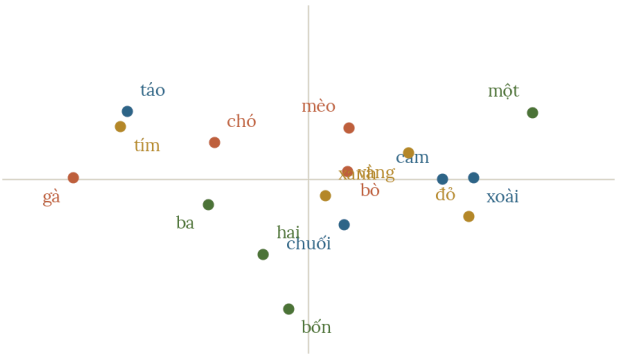
KẾT QUẢ

```
gradient rows: [[0.0, 0.0], [0.0, 0.0], [2.0, 2.0], [3.0, 3.0], [1.0, 1.0]]
PAD has zero gradient: True
classifier logits shape: (3, 2)
```

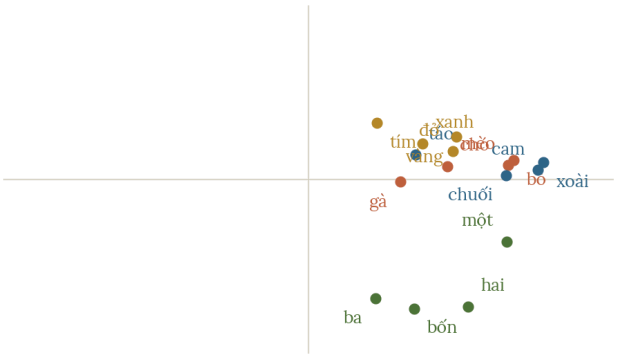
Token 2 xuất hiện hai lần, token 3 ba lần, token 4 một lần nên gradient các hàng tương ứng là $[2, 2]$, $[3, 3]$, $[1, 1]$. Hàng UNK không xuất hiện nên nhận 0. Trong training thật, dùng `classifier(masked_mean(embedding(ids),mask))`, loss nhãn câu, backward và optimizer; **không detach** `pooled` nếu muốn embedding học cùng classifier. Dòng cuối ở đây detach vì chỉ kiểm shape và không tiếp tục training.

Nếu optimizer có weight decay áp trực tiếp vào toàn bảng, hàng PAD được nạp khác 0 có thể còn đổi theo decay dù lookup không tạo gradient; hãy kiểm chính sách weight và giữ PAD bằng 0 theo thiết kế. Không đánh đồng "gradient PAD bằng 0" với "mọi cơ chế đều không bao giờ thay PAD".

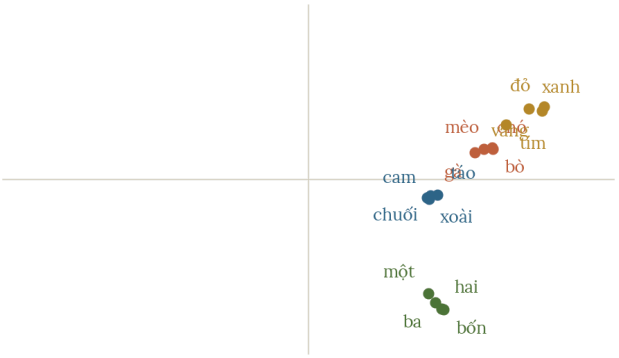
Vậy ý nghĩa của vector đến từ đâu? Từ mục tiêu học. Word2vec (skip-gram) là ví dụ kinh điển: mỗi từ phải dự đoán các từ đứng quanh nó trong văn bản, không cần nhãn nào. "BFS" và "DFS" thường đứng cạnh "duyệt", "đỉnh", "đồ_thị", nên gradient đẩy hai hàng embedding của chúng theo những hướng giống nhau và hai vector trở nên gần nhau, dù ID không liên quan gì. Gần nhau ở đây nghĩa là được dùng trong ngữ cảnh giống nhau, chưa chắc là cùng nghĩa. Bảng học cùng classifier chỉ mang những nét giúp phân loại; bảng pretrained mang nét chung của một kho văn bản lớn và thường là điểm khởi đầu tốt khi dữ liệu train ít.



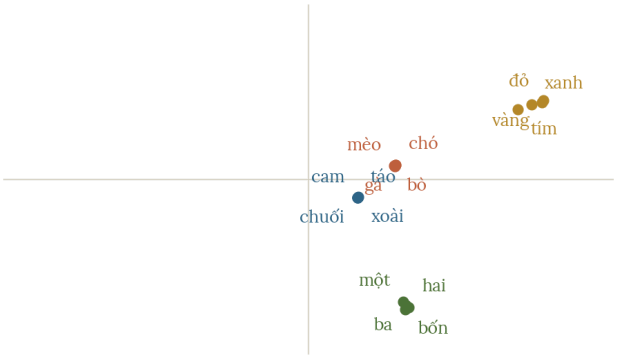
epoch 0: vector khởi tạo ngẫu nhiên



epoch 35



epoch 120



epoch 400: con vật, trái cây, con số, màu tách thành bốn nhóm

Embedding hai chiều học bằng skip-gram trên 64 câu ngắn: chỉ nhờ đoán từ đứng cạnh, các từ cùng loại dần đứng gần nhau.

HỎI NHANH

Với `padding_idx=0` và loss là `embedding(ids).sum()`, batch là `ids = [[4, 4, 0], [4, 2, 0]]`. Gradient của hàng 4 và của hàng 0 là gì?

A Hàng 4 nhận `[3, 3]`, hàng 0 nhận `[0, 0]`

B Hàng 4 nhận `[1, 1]`, hàng 0 nhận `[0, 0]`

C Hàng 4 nhận `[2, 2]`, hàng 0 nhận `[0, 0]`

D Hàng 4 nhận `[3, 3]`, hàng 0 nhận `[2, 2]`

Ví dụ tính tay: mất thứ tự

Mean của “đồ_thị dp” và “dp đồ_thị” bằng nhau. Ta đổi vị trí và kiểm:

Python

```
pair = torch.tensor([[2, 3], [3, 2]])
pair_vectors = masked_mean(embedding(pair), pair.ne(PAD))
print('same after swapping:', torch.allclose(pair_vectors[0], pair_vectors[1]))
```

KẾT QUẢ

```
same after swapping: True
```

Phép cộng giao hoán nên mean pooling mất thứ tự. Nó là baseline tốt khi nhãn phụ thuộc chủ yếu vào tập từ (chủ đề, từ khóa), nhưng không đủ khi “A thắng B” khác “B thắng A”. Muốn phân biệt, token phải tương tác với vị trí **trước khi pooling**: RNN ở mục sau đọc lần lượt từng token; self-attention kèm thông tin vị trí ở bài 3.9 cho mọi token nhìn nhau. Chỉ cộng positional encoding rồi lấy mean ngay vẫn chưa đủ: tổng vector token và tổng vector vị trí đều không đổi khi hoán vị token trong cùng các slot. Self-attention không có tín hiệu vị trí rồi mean cuối cũng giữ tính bất biến hoán vị. Embedding riêng chỉ gán vector cho token, chưa cho token biết ngữ cảnh câu.

HỎI NHANH

Cộng một vector vị trí $\mathbf{p}_t$ vào embedding của token ở vị trí t, rồi lấy mean ngay. Hai câu “A thắng B” và “B thắng A” cho ra biểu diễn thế nào?

A Khác nhau, vì giờ mỗi token mang theo vị trí của nó

B Giống nhau, vì tổng các token và tổng các vị trí đều không đổi

C Khác nhau, vì A và B mang hai ID khác nhau

D Giống nhau, nhưng chỉ khi vector của A và B trùng nhau

RNN đọc theo thứ tự, nhưng phải dừng đúng chỗ

Recurrent neural network (RNN) đọc chuỗi như một vòng lặp có trạng thái, giống duyệt mảng và cập nhật một biến tích lũy trong CP. Với vector token $\mathbf{x}_t$ và trạng thái ẩn (hidden state) $\mathbf{h}_{t-1}$:

$$\mathbf{h}_t = \tanh\left(W_{xh}\mathbf{x}_t + W_{hh}\mathbf{h}_{t-1} + \mathbf{b}\right), \qquad \mathbf{h}_0 = \mathbf{0}.$$

W_{xh} có shape `(H,d)`, W_{hh} shape `(H,H)`, dùng chung cho mọi bước nên một RNN nhận chuỗi dài bao nhiêu cũng được. Trạng thái sau token cuối là một bản tóm tắt có thứ tự: đổi chỗ hai token là đổi thứ tự cập nhật, kết quả khác. `nn.RNN` của PyTorch lưu hai bias `bias_ih`, `bias_hh` (tổng của chúng đóng vai $\mathbf{b}$), nên với $d = 2$, $H = 3$ có $3 \cdot 2 + 3 \cdot 3 + 3 + 3 = 21$ tham số.

Với batch đã pad, RNN vẫn chạy qua mọi cột. Ô PAD có vector 0 nhưng bước cập nhật vẫn là $\tanh(W_{hh}\mathbf{h}_{t-1} + \mathbf{b})$, nên trạng thái tiếp tục đổi. Đọc cột cuối `outputs[:, -1]` là đọc trạng thái **sau** các PAD. Code dưới so cột cuối với trạng thái tại token thật cuối cùng (chỉ số `lengths-1`), và với `pack_padded_sequence`, cách PyTorch cho RNN bỏ hẳn các bước PAD.

Python

```
from torch.nn.utils.rnn import pack_padded_sequence

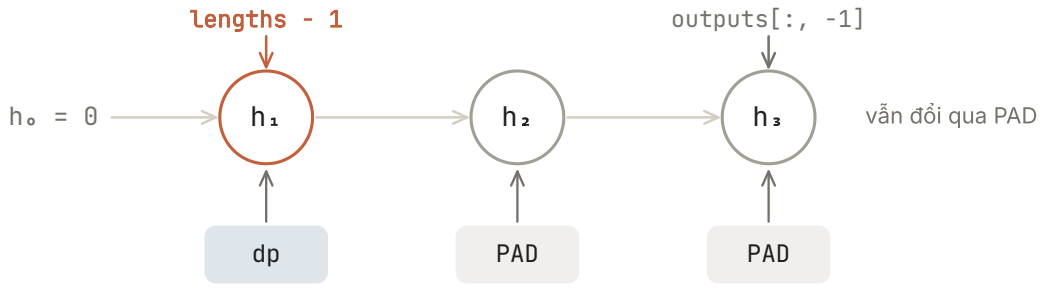
torch.manual_seed(38)
rnn = nn.RNN(input_size=2, hidden_size=3, batch_first=True)
print('RNN parameters:', sum(p.numel() for p in rnn.parameters()))
with torch.no_grad():
    outputs, _ = rnn(vectors)                       # (B, L, H): trạng thái sau từng cột
    lengths = valid_mask.sum(dim=1)
    last_column = outputs[:, -1]                    # cột cuối, có thể nằm sau PAD
    last_valid = outputs[torch.arange(len(ids)), lengths - 1]
    packed = pack_padded_sequence(vectors, lengths, batch_first=True, enforce_sorted=False)
    _, h_packed = rnn(packed)                       # (1, B, H): dừng ở token thật cuối
    swapped = rnn(embedding(pair))[0][:, -1]
print('outputs shape:', tuple(outputs.shape))
print('last column is last token:', torch.isclose(last_column,
last_valid).all(dim=1).tolist())
```

```
print('gather matches packed:', torch.allclose(last_valid, h_packed[0]))
print('RNN same after swapping:', torch.allclose(swapped[0], swapped[1]))
```

KẾT QUẢ

```
RNN parameters: 21
outputs shape: (3, 3, 3)
last column is last token: [False, False, True]
gather matches packed: True
RNN same after swapping: False
```

Dòng `[False, False, True]` cho thấy chỉ câu thứ ba, câu không có PAD, có cột cuối đúng là token thật cuối. Hai câu kia nếu đọc cột cuối sẽ nhận trạng thái đã đi qua một hoặc hai PAD; model vẫn train được, nhưng biểu diễn phụ thuộc lượng PAD, đúng lỗi mà masked mean đã tránh. Lấy theo `lengths-1` khớp với bản packed. Dòng cuối xác nhận RNN phân biệt "đồ_thị dp" với "dp đồ_thị", điều mean pooling không làm được.



Câu "dp" dài 1 trong bảng rộng 3: trạng thái cần đọc là h_1; cột cuối h_3 đã đi qua hai bước PAD và vẫn bị W_hh, bias làm đổi.

HỎI NHANH

Phân loại câu bằng RNN với `batch_first=True`, batch được pad bên phải. Đội A lấy `outputs[:, -1]`, đội B lấy `outputs[i, lengths[i]-1]`. Validation của đội A thấp hơn, và còn đổi khi xáo lại các batch. Vì sao?

A A đọc trạng thái đã chạy qua PAD, mà lượng PAD đổi theo batch

B A đọc trạng thái ở đầu chuỗi, khi chưa thấy các token sau

C B đọc nhầm PAD, vì `lengths` đếm cả token đặc biệt

D Hai cách như nhau, vì vector PAD bằng 0 ở mọi bước

Chuỗi dài: gradient tắt dần và LSTM

RNN nhìn được cả chuỗi về lý thuyết, nhưng có học được quan hệ xa hay không là chuyện gradient. Trải theo L bước, RNN là một mạng sâu L lớp dùng chung W_{hh}, nên gặp đúng vanishing gradient của bài 3.3, chỉ là theo chiều thời gian. Đạo hàm của trạng thái cuối $\mathbf{h}_L$ theo token thứ t đi qua $L - t$ bước, mỗi bước nhân một ma trận Jacobian gồm W_{hh} và đạo hàm tanh (không quá 1). Với số vô hướng $h_t = w\,h_{t-1} + x_t$, ta có $\partial h_L / \partial x_t = w^{L-t}$: $|w| < 1$ thì tắt theo cấp số nhân (vanishing gradient), $|w| > 1$ thì bùng nổ (exploding gradient). Đo trên RNN của mục trước với một chuỗi ngẫu nhiên dài 40:

Python

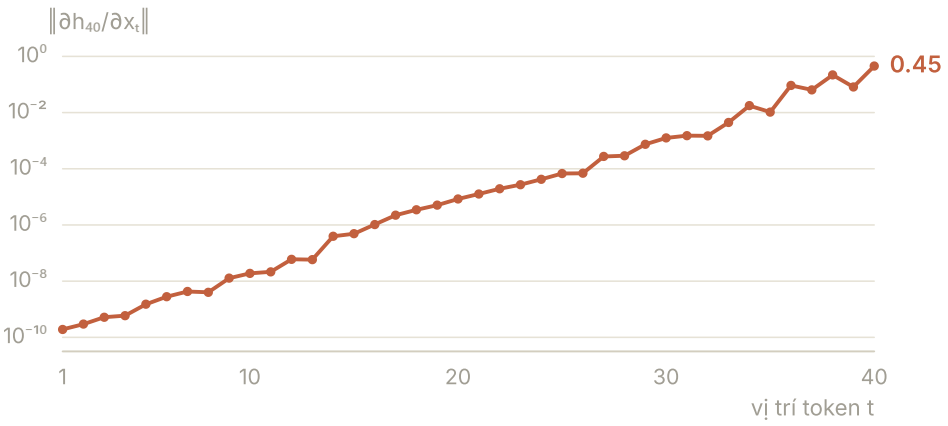
```
torch.manual_seed(0)
long_x = torch.randn(1, 40, 2, requires_grad=True)
_, h_end = rnn(long_x)
h_end.sum().backward()
grad_norm = long_x.grad[0].norm(dim=1)              # độ lớn gradient theo từng token
for t in [40, 30, 20, 10, 1]:
    print(f'token {t:2d}: {grad_norm[t - 1].item():.1e}')
```

KẾT QUẢ

```
token 40: 4.5e-01
token 30: 1.3e-03
```

```
token 20: 8.4e-06
token 10: 1.9e-08
token  1: 1.9e-10
```

Token cuối nhận gradient cỡ 0.45, token thứ 30 còn $1.3 \cdot 10^{-3}$, token đầu chỉ $1.9 \cdot 10^{-10}$: cứ mười bước, gradient giảm hai đến ba bậc. Nếu nhãn phụ thuộc vài token ở đầu một chuỗi dài, tín hiệu sửa trọng số theo các token ấy gần như bằng 0. Đây là lý do chính khiến RNN "quên" đầu chuỗi: trạng thái có thể đủ chỗ chứa điều cần nhớ, nhưng gradient quá nhỏ để dạy model giữ lại nó. Trạng thái kích thước cố định vẫn là một giới hạn thật khi phải nhớ nhiều chi tiết, nhưng tăng hidden size không bỏ được phép nhân lặp. Chiều ngược lại, gradient bùng nổ, được chặn bằng gradient clipping (bài 3.7 dùng nó cùng GradScaler).



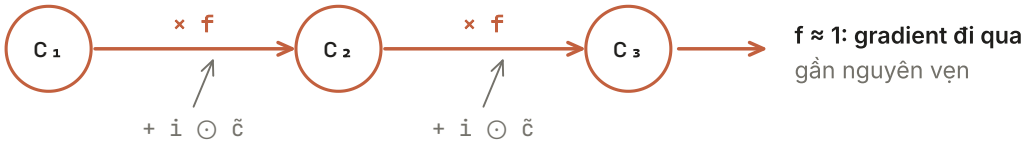
RNN của bài trên chuỗi dài 40 (số từ code): độ lớn gradient của trạng thái cuối theo từng token giảm hai đến ba bậc mỗi mười bước, token đầu chỉ còn cỡ 10^{-10}.

LSTM (long short-term memory) sửa ngay trên đường đi của gradient. Ngoài $\mathbf{h}_t$, LSTM giữ một cell state cập nhật bằng phép cộng có cổng:

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t,$$

với forget gate $\mathbf{f}_t$ và input gate $\mathbf{i}_t$ nằm trong $(0, 1)$, do mạng tự học từ $\mathbf{x}_t$ và $\mathbf{h}_{t-1}$; $\tilde{\mathbf{c}}_t$ là nội dung mới đề xuất. Đường trực tiếp từ $\mathbf{c}_{t-1}$ tới $\mathbf{c}_t$ chỉ nhân với $\mathbf{f}_t$: khi cổng quên gần 1, gradient đi qua nhiều bước mà không bị nhân nhỏ dần, cùng ý với residual connection ở bài 3.6. GRU là biến thể gọn hơn cùng ý tưởng. Trong PyTorch, `nn.LSTM` gọi giống hệt `nn.RNN`, kể cả với `pack_padded_sequence`; chỉ khác là trạng thái cuối trả về dạng cặp

`(h_n, c_n)`. Cổng giúp nhớ xa hơn nhưng vẫn đi tuần tự từng bước; attention ở bài 3.9 nối thẳng mọi cặp vị trí.



đường cell state chỉ nhân với cổng quên, không nhân W_hh và tanh′ mỗi bước

Cell state của LSTM: từ c_1 tới c_3 chỉ nhân với cổng quên f rồi cộng nội dung mới, nên khi f gần 1 gradient đi qua nhiều bước mà không tắt dần.

HỎI NHANH

RNN một chiều số $h_t = w\,h_{t-1} + x_t$, chuỗi dài 30. Đạo hàm $\partial h_{30}/\partial x_1$ bằng bao nhiêu khi $w = 0.5$, và khi $w = 1.5$?

A $0.5 \cdot 29 = 14.5$ và $1.5 \cdot 29 = 43.5$

B Bằng 1 với mọi w, vì x_1 cộng thẳng vào trạng thái

C Khoảng $9.3 \cdot 10^{-10}$ và $1.9 \cdot 10^{5}$

D Khoảng $1.9 \cdot 10^{-9}$ và $1.3 \cdot 10^{5}$

Bẫy cài đặt

Đừng dùng ID ngoài vocabulary làm chỉ số vì nó báo lỗi; ánh xạ UNK rõ trước lookup. Padding bên trái hay bên phải, truncation và token đặc biệt phải nhất quán giữa train và test. Mask trong bài dùng `True` cho token hợp lệ, còn `key_padding_mask` của PyTorch `nn.MultiheadAttention` dùng `True` cho key bị bỏ; khi sang bài attention cần đảo thành `~valid_mask`.

Gom chuỗi độ dài gần nhau vào cùng batch (bucketing) giảm lượng PAD, giống chọn cách lưu để bớt mảng dư. Cái giá là thứ tự mẫu bị xáo: khi train, nhãn phải đi cùng câu; khi dự đoán test, cần giữ chỉ số gốc để trả từng dự đoán về đúng hàng.

HỎI NHANH

Để giảm PAD, một đội sắp các câu test theo độ dài, dự đoán theo batch, rồi ghi lần lượt các dự đoán vào file nộp theo thứ tự `id` ban đầu. Validation 0.86, nhưng điểm public gần mức đoán ngẫu nhiên. Lỗi nằm ở đâu?

A Model overfit validation, cần thêm regularization

B Sắp theo độ dài làm model gặp phân phối khác lúc train

C Dự đoán theo thứ tự đã sắp bị ghép nhầm vào `id` gốc

D Batch có độ dài khác nhau làm masked mean tính sai

Khi đi thi

- **Đọc định dạng đầu vào trước khi chọn model.** Đề cho token ID sẵn, văn bản thô hay chuỗi số theo thời gian; ID là chỉ số cho Embedding, không chuẩn hóa như feature.
- **Lưu vocabulary và quy ước token cùng checkpoint.** PAD, UNK, cách cắt và độ dài tối đa phải giống hệt lúc suy luận; mapping lệch một ID là cả model đọc sai.
- **Chạy baseline masked mean + linear trước.** Vài giây trên CPU cho một mốc để biết RNN hay Transformer đắt hơn có thật sự thắng trên validation; xem riêng các mẫu cần thứ tự.
- **Kiểm bất biến PAD trên một batch.** Thêm vài cột PAD, biểu diễn phải giữ nguyên; với RNN, lấy trạng thái tại `lengths-1` hoặc dùng packed sequence.
- **Đo độ dài trước khi chọn `max_len`.** Xem phân phối độ dài trên train; truncation bỏ dữ liệu thật, bucketing giảm PAD nhưng phải giữ chỉ số gốc khi ghi submission.

Tóm tắt

Embedding tra ID ra vector học được, giữ batch và vị trí. Padding tạo bảng chữ nhật; mask bảo vệ ý nghĩa khi pooling hoặc attention. Masked mean cần cả tổng đúng và số token đúng, phải có quy tắc cho chuỗi rỗng. Mean pooling bỏ thứ tự; RNN giữ thứ tự nhưng phải đọc trạng thái tại token thật cuối, và trên chuỗi dài gradient tắt dần, điều LSTM giảm bớt bằng cell state có cổng. Bài tiếp cho mọi token nhìn thẳng nhau bằng attention.

Kiểm tra cuối bài

CÂU 1

Vocabulary có 20 000 từ. Nếu mỗi từ được biểu diễn bằng one-hot, cosine similarity giữa “giỏi” và “xuất_sắc” bằng bao nhiêu, và một embedding dense đã học thì khác ở chỗ nào?

A Cosine bằng 0 như mọi cặp từ, còn embedding dense đã học có thể đặt hai từ gần nhau

B Cosine bằng 1 vì hai từ cùng nghĩa, còn embedding dense chỉ giúp tiết kiệm bộ nhớ

C Cosine bằng 0.5 vì hai vector cùng độ dài, còn embedding dense luôn cho cosine bằng 1

D Cosine tùy ID của hai từ, còn embedding dense bỏ được nhu cầu phải có vocabulary

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 217

CÂU 2

Train word2vec (skip-gram) từ một bảng ngẫu nhiên, trên nhiều bài tường thuật bóng đá. Train xong, cosine giữa “thắng” và “thua” rất cao. Giải thích nào đúng?

A Train bị lỗi, vì skip-gram phải đẩy hai từ trái nghĩa ra xa nhau

B Hai từ có ID kề nhau, nên khởi tạo đã đặt chúng gần nhau

C Mục tiêu là đoán các từ xung quanh, mà hai từ này có ngữ cảnh rất giống nhau

D Skip-gram học theo nhãn chủ đề, và cả hai từ cùng nhãn thể thao

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 218

CÂU 3

Trong các bài toán sau, bài nào **ít** cần một mô hình chuỗi như RNN nhất?

A Nhận dạng lời nói từ một đoạn ghi âm

B Gợi ý sửa chính tả trong lúc đang gõ phím

C Sáng tác tiếp một đoạn nhạc theo từng nốt

D Nhận diện khuôn mặt từ một ảnh chụp

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q1.5

CÂU 4

UNK là token thật nhưng chưa có trong vocabulary, còn PAD chỉ để ghép batch. Khi masked mean bỏ qua PAD, thì UNK nên được xử lý thế nào?

A Bỏ cả UNK, vì cả hai đều không mang nội dung chữ cụ thể

B Giữ UNK như một token thật, có hàng embedding riêng

C Đổi UNK thành PAD, nhưng vẫn lấy số token gốc làm mẫu số

D Bỏ UNK khỏi tử số, nhưng vẫn đếm nó ở mẫu số

CÂU 5

Ba biến thể RNN, bỏ bias, với trạng thái $\mathbf{s}_t \in \mathbb{R}^m$ và đầu vào $\mathbf{x}_t \in \mathbb{R}^d$. (1) $\mathbf{s}_t = f(W_{ss}\mathbf{s}_{t-1} + W_{sx}\mathbf{x}_t)$. (2) $\mathbf{s}_t = f\big(W_{ssx}[\mathbf{s}_{t-1}; \mathbf{x}_t]\big)$, với W_{ssx} có shape $m \times (m+d)$. (3) $\mathbf{s}_t = f(W_{ss}\mathbf{s}_{t-1}) + f(W_{sx}\mathbf{x}_t)$. Với $f = \tanh$, câu nào đúng?

A Cả ba luôn tương đương, với mọi hàm f

B (1) và (2) tương đương, với $W_{ssx} = [W_{ss}\ W_{sx}]$

C (1) và (3) tương đương, vì tanh là hàm lẻ

D Không cặp nào tương đương, khi f là hàm phi tuyến

PHỎNG THEO MIT 6.036 · Final, Spring 2022 · Q9(a)

CÂU 6

Một RNN thường phân loại các review dài khoảng 400 token. Nhãn thường do câu đầu quyết định, kiểu "Không nên mua: ...", nhưng model chỉ học được tín hiệu từ vài chục token cuối. Nguyên nhân chính là gì, và sửa theo hướng nào?

A Gradient về tới token đầu bị tắt dần qua nhiều bước, nên dùng LSTM, GRU hoặc attention

B Trạng thái ẩn quá nhỏ để chứa 400 token, nên tăng hidden size lên gấp bốn

C Dữ liệu lệch về các token gần cuối, nên cân bằng lại số mẫu của từng nhãn

D Learning rate quá nhỏ cho token đầu, nên tăng riêng learning rate của embedding

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q2.3

CÂU 7

Model chỉ nhận tối đa 512 token. Bài luận trong dữ liệu dài trung bình 1000 token, và điểm phụ thuộc nhiều vào phần kết luận ở cuối. Cách cắt mặc định giữ 512 token đầu. Nên làm thế nào?

A Giữ 512 token đầu, vì mở bài luôn chứa ý chính

B Bỏ giới hạn, pad mọi bài lên 1000 token cho khỏi mất thông tin

C Chia bài thành các đoạn không quá 512 token, dự đoán từng đoạn rồi gộp lại

D Giảm `max_len` xuống 256 cho batch lớn hơn và train nhanh hơn

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q2.2

CÂU 8

Optimizer chứa cả embedding lẫn classifier, nhưng code gọi `classifier(pooled.detach())` trước khi tính loss. Muốn embedding học được từ loss phân loại, phải sửa gì?

A Bỏ `detach`, để gradient đi qua bước gộp về tới embedding

B Giữ `detach`, tăng learning rate riêng cho embedding

C Giữ `detach`, gọi thêm `model.train()` trước khi tính loss

D Chỉ `zero_grad` cho classifier, giữ lại gradient của embedding

CÂU 9

`nn.Embedding(10000, 64)` nối với `nn.RNN(64, 128)`, một lớp, có bias như mặc định. Tổng số tham số là bao nhiêu?

A 24 832

B 656 640

C 664 704

D 664 832

CÂU 10

Để `outputs[:, -1]` luôn rơi vào token thật, một đội đổi sang pad bên **trái**: câu "dp" thành `[0, 0, 3]`. RNN có bias khác 0, và $\mathbf{h}_0 = \mathbf{0}$. Kiểm tính không đổi khi thêm PAD thì cho kết quả gì?

A Đạt, vì PAD có vector 0 nên các bước đầu giữ $\mathbf{h} = \mathbf{0}$

B Không đạt, vì hai bước PAD đã làm đổi $\mathbf{h}$ trước khi gặp "dp"

C Đạt, vì cột cuối là token thật nên mọi PAD đều bị bỏ qua

D Không đạt, vì pad bên trái làm đảo thứ tự các token thật

Đọc thêm

- PyTorch 2.9 — Embedding: tra `padding_idx`, shape và cách cập nhật hàng embedding.
- PyTorch 2.9 — pad_sequence: đọc `batch_first` và padding để tự ghép chuỗi.
- D2L — Word Embedding: xem vì sao mục tiêu học tạo quan hệ giữa các vector token.
- PyTorch 2.9 — pack_padded_sequence: đọc `lengths`, `enforce_sorted` và cách RNN bỏ các bước PAD.
- D2L — Long Short-Term Memory: các cổng của LSTM, viết từ đầu rồi đối chiếu với `nn.LSTM`.