GAN và diffusion

Sinh ảnh mới.

> Ta cần tạo nhiều kiểu biểu tượng sách cho một bài thực hành, thay vì chọn một ảnh đã chụp. Model sinh ảnh học phân phối của ảnh, rồi sinh mẫu mới từ nguồn ngẫu nhiên và có thể thêm điều kiện chữ. Câu hỏi xuyên suốt là: làm sao một tín hiệu ngẫu nhiên thành ảnh có cấu trúc, và vì sao một ảnh trông đẹp chưa đủ để chứng minh model sinh tốt?

MỤC TIÊU SAU BÀI NÀY

- Phân biệt hai vai trò generator/discriminator của GAN.
- Viết một bước cập nhật GAN đúng đường gradient.
- Tính bước thêm nhiễu và mục tiêu dự đoán nhiễu của diffusion.
- Đọc quy trình sinh có điều kiện (sampler, latent, guidance), ước lượng thời gian và so cấu hình bằng seed, prompt cố định.

Sinh mẫu khác với dự đoán nhãn

Classifier ước lượng nhãn theo ảnh. Model sinh cần mô tả sự biến thiên của dữ liệu: những kiểu ảnh nào có thể xuất hiện và xuất hiện với tần suất nào. Nếu luôn trả cùng một ảnh đẹp, model bỏ mất sự đa dạng.

Nguồn noise z không phải lỗi cần xóa: nó cung cấp biến thiên để cùng một prompt cho nhiều mẫu. Seed cố định dãy số ngẫu nhiên, nên hai seed cho hai noise khác nhau, còn cùng seed trong cùng điều kiện cho lại cùng thí nghiệm. “Cùng điều kiện” gồm cả model, sampler, phiên bản thư viện và phần cứng: đổi một thứ, ảnh có thể khác dù seed giữ nguyên.

HỎI NHANH

Một đội giữ nguyên seed 7, prompt và model, chỉ đổi sampler, chạy trên cùng một máy. Ảnh ra khác hẳn. Vì sao?

A Seed chỉ cố định các số ngẫu nhiên, còn sampler đổi cách đi từ noise tới ảnh

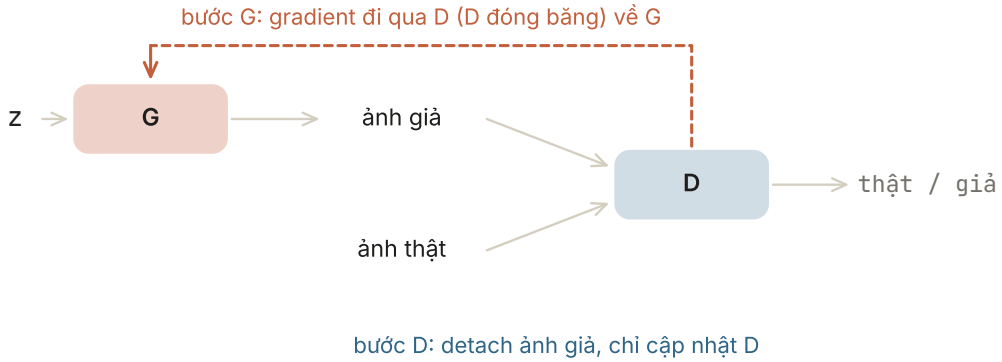
B Đổi sampler làm seed bị bỏ qua, nên noise ban đầu được lấy lại ngẫu nhiên

C Cùng seed thì phải cùng ảnh, nên ảnh khác nghĩa là máy đang tính sai

D Mỗi sampler đi kèm trọng số riêng, nên thực chất model đã bị đổi

GAN: hai mạng có hai mục tiêu

Generator $G(z)$ biến noise thành mẫu giả. Discriminator $D(x)$ học phân biệt mẫu thật với mẫu do generator tạo. Generator được cập nhật để discriminator đánh giá mẫu giả như thật. Hai mạng thay đổi cùng quá trình, nên mục tiêu mà một mạng thấy cũng đang thay đổi.



GAN: bước D học phân biệt ảnh thật với ảnh giả đã detach; bước G giữ D đóng băng nhưng cho gradient đi qua D về generator.

Một cách train thông dụng dùng binary cross-entropy. Discriminator muốn nhãn 1 cho thật, 0 cho giả:

$$L_D = -\mathbb{E}_x \log D(x) - \mathbb{E}_z \log(1 - D(G(z))).$$

Với non-saturating generator loss, generator muốn fake được D chấm 1:

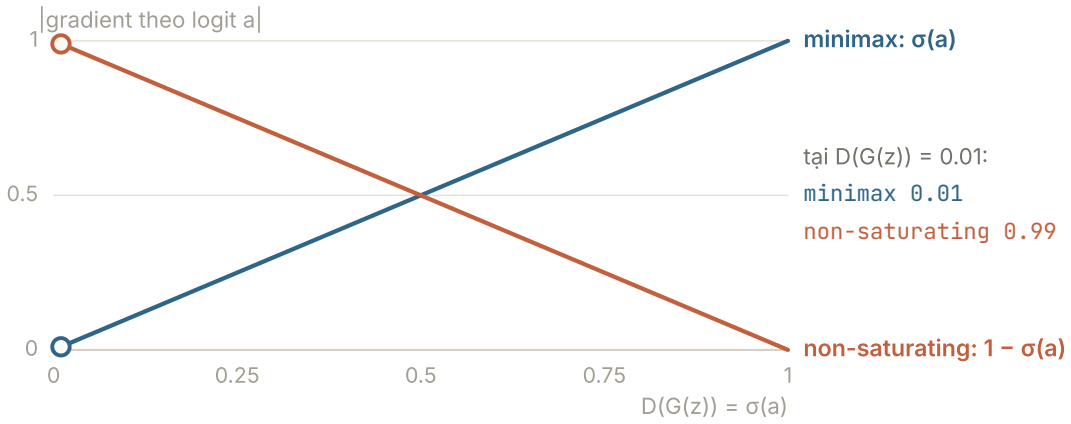
$$L_G = -\mathbb{E}_z \log D(G(z)).$$

Với $D(G(z)) = 0.2$, loss này là $-\log 0.2 \approx 1.609$; nếu G đẩy được điểm lên 0.8 thì loss còn khoảng 0.223.

Cách viết minimax nguyên thủy cho G cực tiểu $\mathbb{E}_z \log(1 - D(G(z)))$. Hai cách cùng hướng đẩy $D(G(z))$ lên, nhưng khác nhau ở độ lớn gradient. Viết $D = \sigma(a)$ với a là logit của fake:

$$\frac{\partial}{\partial a} \log(1 - \sigma(a)) = -\sigma(a), \qquad \frac{\partial}{\partial a} \big(-\log \sigma(a)\big) = -(1 - \sigma(a)).$$

Đầu train, D dễ nhận ra fake nên $D(G(z))$ gần 0. Khi đó cách viết minimax cho gradient gần 0 (bão hòa) và G gần như đứng yên, còn non-saturating cho gradient có độ lớn gần 1. Vì vậy code thực hành dùng $L_G = -\mathbb{E}_z \log D(G(z))$, tức BCE với nhãn "thật" cho fake.



Độ lớn gradient của loss generator theo logit của ảnh giả: khi D(G(z)) = 0.01, minimax chỉ còn 0.01 còn non-saturating còn 0.99.

HỎI NHANH

Đầu train, D dễ nhận ra ảnh giả: $D(G(z)) = 0.01$. Tính theo logit a của ảnh giả, độ lớn gradient của $\log(1 - D)$, tức loss minimax, và của $-\log D$, tức loss non-saturating, lần lượt là bao nhiêu?

A 0.99 và 0.01

B 0.01 và 0.99

C 0.01 và 4.61

D Bằng nhau, vì hai loss cùng đẩy $D(G(z))$ lên

Một bước GAN thật, nhưng trên số một chiều

Trước khi train GAN ảnh, nên kiểm đồ thị gradient trên một bài nhỏ đến mức đọc được từng tham số: dữ liệu thật là bốn số quanh 2, `G` và `D` mỗi mạng là một lớp tuyến tính. Điều cần nhìn là tham số nào đổi ở bước nào; giá trị loss của một bước chưa nói gì về chất lượng sinh.

Python

```
import numpy as np
import torch
from torch import nn

torch.set_num_threads(1)
torch.manual_seed(58)
generator = nn.Linear(1, 1)
discriminator = nn.Linear(1, 1)
optimizer_g = torch.optim.SGD(generator.parameters(), lr=0.1)
optimizer_d = torch.optim.SGD(discriminator.parameters(), lr=0.1)
real = torch.tensor([[1.7], [1.9], [2.1], [2.3]])
noise = torch.tensor([[-1.], [0.], [1.], [2.]])
criterion = nn.BCEWithLogitsLoss()

g_before_d = generator.weight.detach().clone()
```

```
optimizer_d.zero_grad()
fake = generator(noise)
real_logits = discriminator(real)
fake_logits = discriminator(fake.detach())
loss_d = criterion(real_logits, torch.ones_like(real_logits))
loss_d += criterion(fake_logits, torch.zeros_like(fake_logits))
loss_d.backward()
optimizer_d.step()
print("G unchanged during D step:", torch.equal(g_before_d, generator.weight))
print("D loss:", round(loss_d.item(), 4))
```

KẾT QUẢ

```
G unchanged during D step: True
D loss: 1.4571
```

D loss 1.4571 gần $2 \ln 2 \approx 1.386$, mức của một D chấm 0.5 cho mọi mẫu: D mới khởi tạo chưa phân biệt được thật và giả. `detach()` ở fake làm gradient của bước D không đi vào G. Bước tiếp theo giữ trọng số D nhưng vẫn cần đạo hàm của D theo đầu vào:

Python

```python
d_before_g = discriminator.weight.detach().clone()
g_before_g = generator.weight.detach().clone()
for parameter in discriminator.parameters():
    parameter.requires_grad_(False)
optimizer_g.zero_grad()
fake = generator(noise)
fake_logits = discriminator(fake)
loss_g = criterion(fake_logits, torch.ones_like(fake_logits))
loss_g.backward()
optimizer_g.step()
for parameter in discriminator.parameters():
    parameter.requires_grad_(True)
print("D unchanged during G step:", torch.equal(d_before_g, discriminator.weight))
print("G changed during G step:", not torch.equal(g_before_g, generator.weight))
print("G loss:", round(loss_g.item(), 4))
print("hand loss for D(fake)=0.2:", round(-np.log(0.2), 4))
```

KẾT QUẢ

```
D unchanged during G step: True
G changed during G step: True
G loss: 1.0656
hand loss for D(fake)=0.2: 1.6094
```

G loss 1.0656 ứng với trung bình nhân của $D(G(z))$ khoảng $e^{-1.0656} \approx 0.34$: D vẫn nghiêng về "giả", nên G còn tín hiệu để học. Dòng cuối kiểm lại số tính tay ở mục trước.

Không đặt `no_grad()` quanh D trong bước G: như vậy sẽ cắt đường gradient cần về G. Đóng băng parameter D vẫn giữ phép tính theo fake. Ba dòng kiểm tham số phát hiện loại bug này trước khi chạy một GAN lớn.

GAN có thể dao động, discriminator quá mạnh hoặc generator chỉ sinh vài kiểu (mode collapse). Loss G/D không có quy tắc "càng thấp đồng thời càng tốt" giống supervised loss cố định. Cần xem chất lượng, đa dạng và metric phù hợp trên nhiều seed.

HỎI NHANH

Xóa `.detach()` ở bước D rồi chạy lại. Dòng kiểm vẫn in `G unchanged during D step: True`. Ta kết luận được gì?

A Bỏ `detach()` là an toàn, vì phép kiểm đã in True

B Trọng số G không đổi, nhưng `.grad` của G đã bị ghi

C Phép kiểm sai, trọng số G thật ra đã bị cập nhật

D Có detach hay không thì gradient bước D cũng không tới được G

HỎI NHANH

Ở bước G, ta bọc dòng `fake_logits = discriminator(fake)` trong `torch.no_grad()`, còn `fake = generator(noise)` vẫn ở ngoài. Chuyện gì xảy ra?

A G vẫn học, vì `fake` được tạo ngoài khối `no_grad`

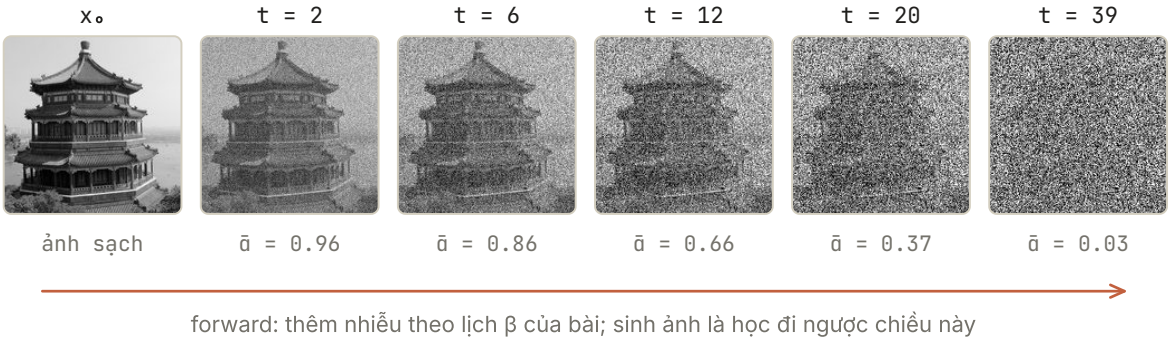
B Code chạy được nhưng chỉ cập nhật D, vì D nằm trong khối

C `loss_g.backward()` báo lỗi, vì loss không còn nối tới G

D G học chậm hơn, vì gradient qua D bị thu nhỏ lại

Diffusion: học sửa ảnh ở nhiều mức nhiễu

Thay vì đối đầu hai mạng, diffusion tạo một nhiệm vụ supervised từ dữ liệu: thêm noise đã biết vào mẫu sạch, rồi học đoán noise hoặc đại lượng tương đương. Lúc sinh, bắt đầu từ noise và làm nhiều bước khử nhiễu theo scheduler đã định nghĩa.

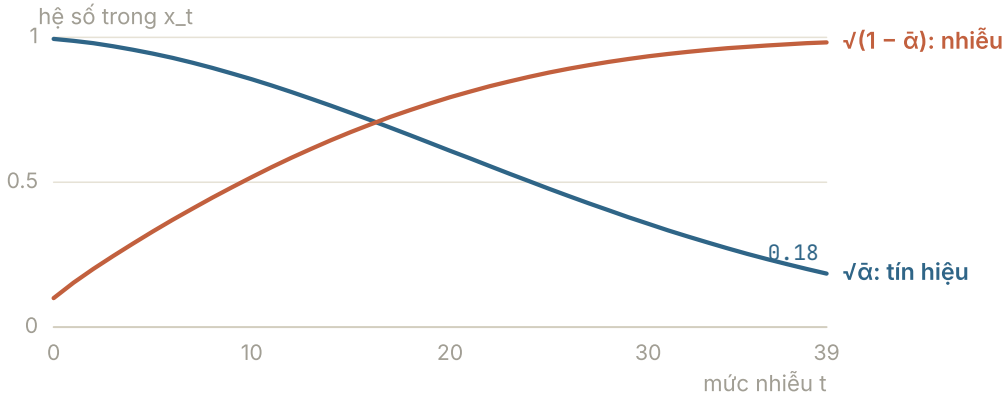


Một ảnh thật đi qua forward diffusion với đúng lịch nhiễu của bài (40 mức, β từ 0.01 đến 0.15): ᾱ giảm dần, đến mức cuối ảnh gần như chỉ còn nhiễu.

Đặt β_t là mức nhiễu mỗi bước, $\alpha_t = 1 - \beta_t$, $\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$. Có thể lấy trực tiếp mẫu nhiễu ở thời điểm t:

$$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1 - \bar{\alpha}_t}\, \epsilon, \qquad \epsilon \sim \mathcal{N}(0, I).$$

x_0 là dữ liệu sạch; t là mức noise, không phải epoch. Hệ số căn bậc hai phân phối phần phương sai cho tín hiệu và noise. Khi $\bar{\alpha}_t$ gần 1, giữ nhiều tín hiệu; gần 0, mẫu gần noise. Noise predictor cần nhận cả x_t và t vì cùng một giá trị nhiễu ở mức khác có ý nghĩa khác.



Hai hệ số của x_t = √ᾱ·x₀ + √(1 − ᾱ)·ε theo lịch nhiễu của bài: hệ số tín hiệu giảm từ gần 1 xuống 0.18 ở mức cuối, hệ số nhiễu tăng lên gần 1.

Ví dụ tính tay

Với $x_0 = 2$, $\bar{\alpha}_t = 0.64$, $\epsilon = 0.5$, ta có $x_t = 0.8 \cdot 2 + 0.6 \cdot 0.5 = 1.9$. Target khi train noise predictor là 0.5, không phải 2. Khi có dự đoán noise $\hat{\epsilon}$, có thể ước lượng sạch bằng $(x_t - \sqrt{1-\bar{\alpha}_t}\hat{\epsilon})/\sqrt{\bar{\alpha}_t}$; đây chưa phải toàn bộ sampler.

Python

```python
clean = 2.0
alpha_bar_example = 0.64
epsilon_example = 0.5
noisy = np.sqrt(alpha_bar_example) * clean
noisy += np.sqrt(1 - alpha_bar_example) * epsilon_example
estimated_clean = (noisy - np.sqrt(1 - alpha_bar_example) * epsilon_example)
estimated_clean /= np.sqrt(alpha_bar_example)
print("noisy:", round(noisy, 4))
print("reconstruction with known noise:", round(estimated_clean, 4))
```

KẾT QUẢ

```
noisy: 1.9
reconstruction with known noise: 2.0
```

Ta dùng noise thật ở dòng khôi phục, nên kết quả 2 là kiểm đại số, **không** phải model đã học khử nhiễu. Ở lúc sinh, ảnh sạch chưa biết và noise phải được model ước lượng.

HỎI NHANH

Trong ví dụ tính tay có $x_0 = 2$, $\bar{\alpha}_t = 0.64$, $\epsilon = 0.5$ và $x_t = 1.9$. Một mẫu train của noise predictor gồm đầu vào và target nào?

A Đầu vào $(x_0 = 2,\ t)$, target $x_t = 1.9$

B Đầu vào $x_t = 1.9$, bỏ t, target $\epsilon = 0.5$

C Đầu vào $(x_t = 1.9,\ t)$, target $x_0 = 2$

D Đầu vào $(x_t = 1.9,\ t)$, target $\epsilon = 0.5$

Train noise predictor trên CPU với dữ liệu một chiều

Thí nghiệm sau train thật một noise predictor trên dữ liệu một chiều: mỗi mẫu sạch nằm quanh -2 hoặc $+2$, mức nhiễu lấy ngẫu nhiên trong 40 mức (chỉ số 0–39), MLP nhận x_t cùng chỉ số mức chia cho 39 và đoán ϵ. Cơ chế giống hệt khi train trên ảnh; chỉ khác là x_0 là một số thay cho tensor ảnh, và mạng là MLP thay cho U-Net.

Loss là MSE giữa ϵ và dự đoán. DDPM xuất phát từ mục tiêu likelihood; sau khi rút gọn, mỗi số hạng thành bình phương sai số giữa ϵ và $\epsilon_\theta(x_t, t)$ nhân một trọng số theo t, và bài báo bỏ trọng số ấy để được MSE đơn giản trên noise.

Python

```
torch.manual_seed(580)
steps = 40
betas = torch.linspace(0.01, 0.15, steps)
alpha_bars = torch.cumprod(1 - betas, dim=0)
denoiser = nn.Sequential(nn.Linear(2, 24), nn.Tanh(), nn.Linear(24, 1))
optimizer = torch.optim.Adam(denoiser.parameters(), lr=0.01)

def make_noisy_batch(count):
    clean = (torch.randint(0, 2, (count, 1)) * 4 - 2).float()
    clean += 0.2 * torch.randn(count, 1)
    times = torch.randint(0, steps, (count,))
    eps = torch.randn(count, 1)
```

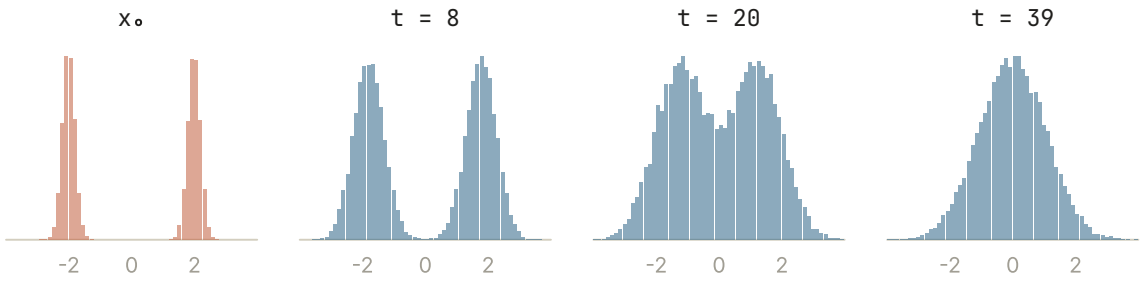
```
    kept = alpha_bars[times, None]
    noisy = kept.sqrt() * clean + (1 - kept).sqrt() * eps
    inputs = torch.cat([noisy, times[:, None] / (steps - 1)], dim=1)
    return inputs, eps

valid_inputs, valid_noise = make_noisy_batch(128)
with torch.no_grad():
    before = nn.functional.mse_loss(denoiser(valid_inputs), valid_noise).item()
for update in range(250):
    inputs, targets = make_noisy_batch(64)
    optimizer.zero_grad()
    loss = nn.functional.mse_loss(denoiser(inputs), targets)
    loss.backward()
    optimizer.step()
with torch.no_grad():
    after = nn.functional.mse_loss(denoiser(valid_inputs), valid_noise).item()
    zero_baseline = valid_noise.square().mean().item()
print("noise MSE before/after:", round(before, 4), round(after, 4))
print("zero predictor MSE:", round(zero_baseline, 4))
print("last alpha_bar:", round(alpha_bars[-1].item(), 4))
```

KẾT QUẢ

```
noise MSE before/after: 0.9092 0.3434
zero predictor MSE: 0.9815
last alpha_bar: 0.0342
```

MSE giảm từ 0.9092 xuống 0.3434, thấp hơn nhiều so với baseline luôn đoán 0 (0.9815): model đã học. Ở mức cuối, $\bar{\alpha} = 0.0342$: tín hiệu chỉ còn hệ số $\sqrt{0.0342} \approx 0.18$, nên mẫu ở mức này đã gần noise chuẩn.



hai cụm quanh ±2 nhòe dần thành một phân phối chuẩn

Dữ liệu một chiều của bài (hai cụm quanh −2 và +2) sau forward diffusion ở các mức nhiễu: hai đỉnh nhòe dần và gộp thành phân phối gần chuẩn ở mức cuối.

MSE không thể về 0, vì cùng một x_t có thể đến từ nhiều cặp (x_0, ϵ). Ở mức nhiễu thấp, noise nhỏ hơn độ lệch tự nhiên của x_0 quanh ± 2 nên không tách được; ở mức giữa, không biết x_t đến từ cụm -2 hay $+2$. Con số này đo việc đoán noise; chất lượng mẫu sinh còn phụ thuộc sampler và cần đánh giá riêng.

HỎI NHANH

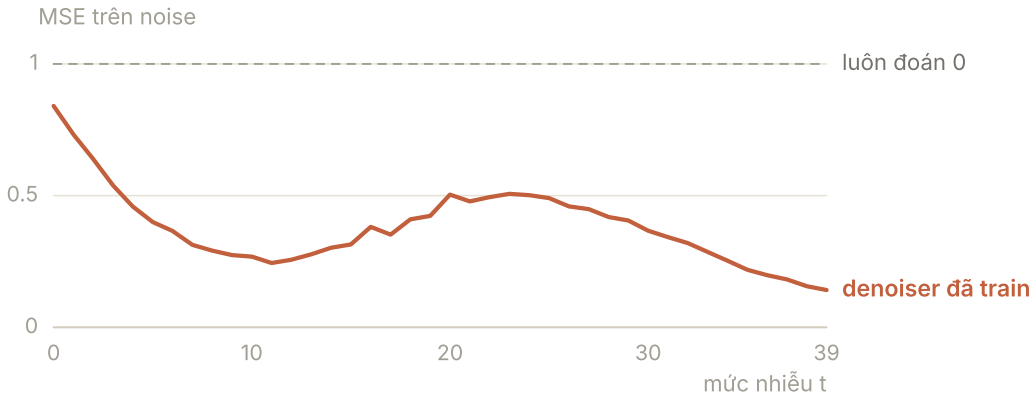
Ở một mức t có $\bar{\alpha}_t = 0.001$, noise predictor đoán ϵ từ x_t dễ hay khó?

A Dễ, vì $x_t \approx \epsilon$, gần như đọc thẳng được noise

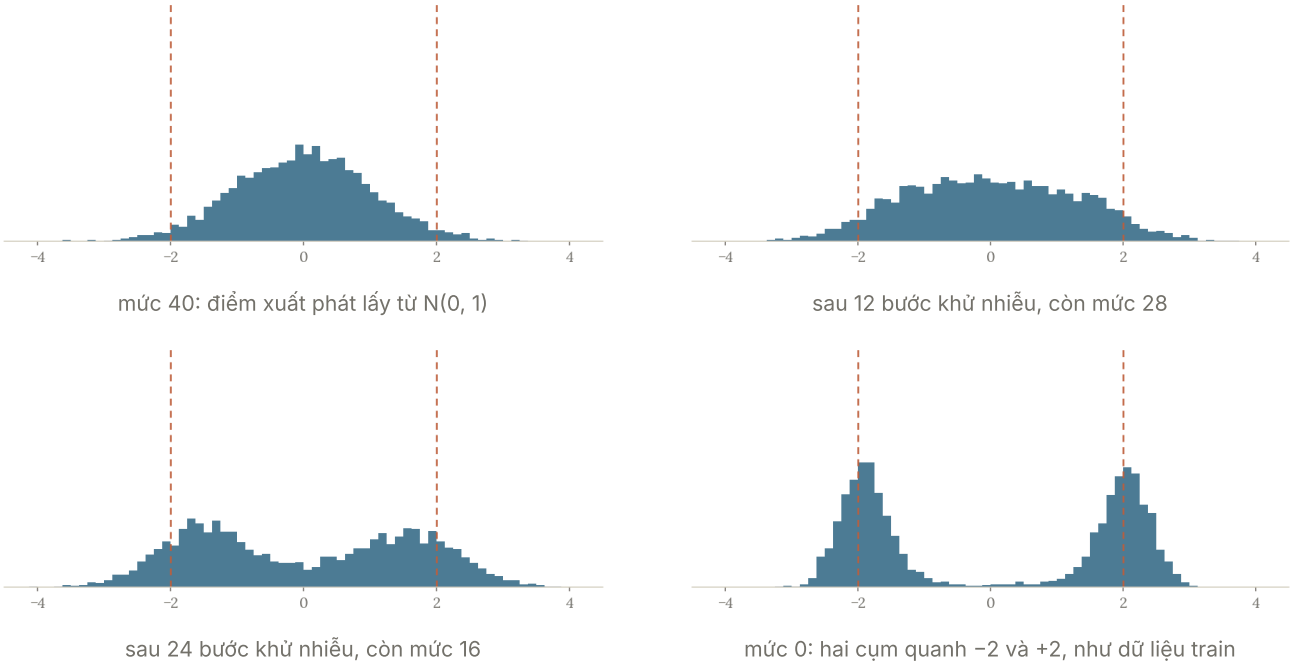
B Khó nhất, vì tín hiệu gần mất hết, không còn gì để dựa vào

C Không xác định, vì phải biết x_0 mới tính được ϵ

D Khó, vì noise lớn nên MSE ở mức này luôn lớn nhất



MSE của noise predictor đã train (code bài) theo từng mức nhiễu: khó ở mức thấp, nơi noise nhỏ hơn độ lệch của x_0, và ở mức giữa, nơi không biết x_t đến từ cụm nào; dễ dần ở mức cao, nơi x_t gần bằng chính noise.



Sampler DDPM dùng noise predictor đã train của bài: 4000 điểm từ noise chuẩn dần tách về hai cụm ±2.

Từ noise predictor đến model sinh có điều kiện

Sampler bắt đầu từ $x_T \sim \mathcal{N}(0, I)$ và dùng dự đoán noise ở từng mức để đi về $x_{T-1}, \ldots, x_0$; tùy scheduler, mỗi bước có thể thêm một lượng noise mới. Lặp công thức khôi phục x_0 ở trên không phải là DDPM: hệ số và phương sai của bước reverse phải khớp lịch nhiễu đã dùng khi train (DDPM §3.2 viết đủ các hệ số này). Mỗi bước là một lần gọi denoiser, và bước sau cần kết quả bước trước: 50 bước là 50 lần forward nối tiếp cho một ảnh, trong khi generator GAN chỉ cần một.

Text-conditioned diffusion đưa embedding của prompt vào denoiser, thường qua cross-attention. Latent diffusion (họ Stable Diffusion) chạy cả quá trình trong latent nén của ảnh: encoder của một autoencoder nén ảnh, khử nhiễu diễn ra trên latent, decoder biến latent cuối thành pixel. Stable Diffusion 1.x dùng latent $64 \times 64 \times 4$ cho ảnh $512 \times 512 \times 3$, nên mỗi lần gọi denoiser rẻ hơn nhiều.

HỎI NHANH

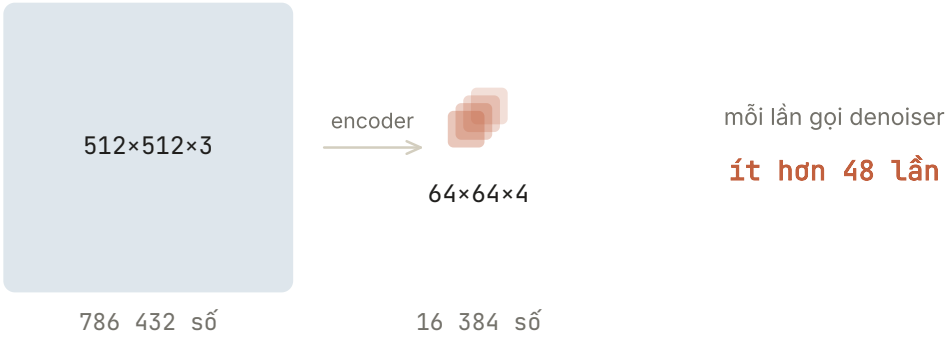
Dùng latent $64 \times 64 \times 4$ thay cho ảnh $512 \times 512 \times 3$. Mỗi lần gọi denoiser xử lý ít hơn bao nhiêu lần số giá trị?

A 8 lần

B 48 lần

C 64 lần

D 192 lần

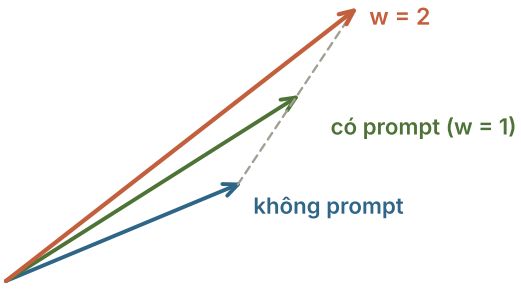


Latent diffusion khử nhiễu trên latent 64×64×4 = 16 384 số thay vì ảnh 512×512×3 = 786 432 số, ít hơn 48 lần mỗi lần gọi denoiser.

Classifier-free guidance (CFG) điều khiển mức bám prompt. Mỗi bước gọi denoiser hai lần, có prompt c và không prompt $\varnothing$, rồi đẩy dự đoán ra xa bản không điều kiện:

$$\hat{\epsilon} = \epsilon_\theta(x_t, t, \varnothing) + w\,\big[\epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_t, t, \varnothing)\big].$$

$w = 1$ là dự đoán có điều kiện thường. w lớn hơn làm ảnh bám prompt hơn, đổi lại đa dạng giảm và màu, chi tiết có thể quá gắt; mỗi bước cũng tốn gấp đôi. Model học cả hai chế độ nhờ khi train bỏ prompt ở một phần mẫu. Số bước, sampler, kích thước, w, seed và prompt đều cần ghi khi so kết quả.



$$\varepsilon\hat{} = \varepsilon\varnothing + w\,(\varepsilon_c - \varepsilon\varnothing)$$

w lớn: bám prompt hơn,
kém đa dạng, tốn gấp đôi

Classifier-free guidance: lấy dự đoán không prompt rồi đi tiếp theo hướng chênh lệch sang dự đoán có prompt, w lần; w = 1 là dự đoán có điều kiện thường.

Recipe diffusion với asset cục bộ đưa quy trình này vào một lệnh: `local_assets.py --task diffusion` kiểm gói diffusers và transformers, thư mục pipeline có `model_index.json`, prompt và đường dẫn ảnh ra; không có `--run` thì chỉ kiểm điều kiện rồi dừng. Với `--run`, recipe nạp pipeline (tokenizer, text encoder, U-Net, VAE, scheduler, weights safetensors) ở chế độ offline trên CPU float32 và sinh một ảnh 256×256 bằng 10 bước với seed 5, không ghi đè ảnh cũ. Một ảnh như vậy xác nhận đường nạp và inference chạy được; so chất lượng hai cấu hình cần cả bộ prompt và seed, như mục sau.

Bẫy cài đặt và đánh giá

KHÔNG ĐÁNH GIÁ BẰNG MỘT ẢNH CHỌN ĐẸP

Lưu prompt/seed/cấu hình cố định, sinh nhiều mẫu rồi đọc cả chất lượng, độ đa dạng và mức đúng điều kiện. Chỉ chọn ảnh đẹp nhất giấu mode collapse, lỗi đếm và lỗi bố cục.

FID so phân phối feature (lấy từ một mạng phân loại pretrained) của ảnh sinh với ảnh thật; nó cần hàng nghìn mẫu và cách tính nhất quán giữa các lần so, nên không có nghĩa trên vài ảnh. Sinh dữ liệu để train classifier cần kiểm nhãn, trùng lặp và mức khớp miền ảnh thật. Model sinh học từ dữ liệu nguồn, có thể lặp nội dung hoặc thiên lệch; ảnh sinh không tự là bằng chứng về thế giới thật.

HỎI NHANH

Ta so hai cấu hình sampler. Cấu hình A cho 4 ảnh đẹp nhất chọn từ 200 lần chạy. Cấu hình B cho 4 ảnh của seed 0 đến 3. A trông đẹp hơn. So thế nào mới công bằng?

A Chọn A, vì ảnh đẹp nhất cho thấy giới hạn trên của cấu hình

B Lấy ảnh đẹp nhất trong 200 lần chạy của cả hai cấu hình rồi so

C Dùng cùng prompt và seed, sinh nhiều mẫu, đo cả chất lượng lẫn đa dạng

D Bỏ ảnh đi, so loss train của hai cấu hình

Khi đi thi

- **Đọc đề để biết thứ được chấm.** Ảnh đầu ra, điểm của một classifier dùng ảnh sinh, hay một đại lượng tính tay; quy định về asset và pretrained quyết định có dùng được pipeline sẵn hay không.
- **Ước lượng thời gian trước khi chạy lớn.** Thời gian $\approx$ số ảnh $\times$ số bước $\times$ thời gian một lần gọi denoiser, gấp đôi khi bật CFG. Đo trên vài ảnh nhỏ rồi mới tăng resolution, batch hoặc số bước.
- **So cấu hình với cùng bộ prompt và seed.** Đổi một thứ mỗi lần (số bước, sampler, w) và ghi đủ cấu hình; xem nhiều mẫu, không chọn ảnh đẹp nhất.
- **Ảnh sinh chỉ vào train.** Validation và test giữ ảnh thật; kiểm nhãn và ảnh trùng của phần sinh thêm.
- **Câu lý thuyết diffusion: viết $x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon$ trước.** Mean, phương sai, giới hạn khi $t \to \infty$ và mục tiêu MSE trên noise đều suy ra từ dòng này.
- **GAN tự viết: chạy ba dòng kiểm tham số trước khi train lâu.** D không đổi ở bước G, G không đổi ở bước D, G có đổi ở bước G.

Tóm tắt

GAN học qua hai mục tiêu cập nhật luân phiên, cần đúng đường gradient và kiểm đa dạng. Diffusion học dự đoán noise ở nhiều mức bằng MSE, rồi sinh bằng nhiều bước reverse có scheduler; latent làm mỗi bước rẻ hơn, guidance đổi đa dạng lấy mức bám prompt. Noise, điều kiện và cấu hình điều khiển sự biến thiên; ảnh đẹp riêng lẻ chưa đủ để đánh giá model.

Kiểm tra cuối bài

CÂU 1

Forward diffusion hai bước: $x_1 = \sqrt{\alpha_1}\, x_0 + \sqrt{1-\alpha_1}\, \epsilon_1$ và $x_2 = \sqrt{\alpha_2}\, x_1 + \sqrt{1-\alpha_2}\, \epsilon_2$, với $\epsilon_1, \epsilon_2 \sim \mathcal{N}(0,1)$ độc lập, $\alpha_1 = 0.9$, $\alpha_2 = 0.8$. Phân phối của x_2 khi biết x_0 có mean và phương sai bao nhiêu?

A Mean $\sqrt{0.72}\, x_0$, phương sai 0.28

B Mean $\sqrt{0.72}\, x_0$, phương sai 0.30

C Mean $0.72\, x_0$, phương sai 0.28

D Mean $0.72\, x_0$, phương sai 0.30

PHỎNG THEO USA-NA-AIO 2026 · Vòng 2 · Ngày 2 · Part 3.1.1

CÂU 2

Lịch nhiễu có $0 < \alpha_t \leq 0.99$ với mọi t. Khi $t \to \infty$, phân phối của x_t khi biết x_0 tiến tới đâu?

A $\mathcal{N}(x_0, 1)$, tín hiệu giữ nguyên và noise cộng thêm vào

B $\mathcal{N}(0, \infty)$, phương sai tăng không giới hạn

C $\mathcal{N}(0, 1)$, không còn phụ thuộc vào x_0

D $\mathcal{N}(0, 0)$, mọi mẫu dồn hết về điểm 0

PHỎNG THEO USA-NA-AIO 2026 · Vòng 2 · Ngày 2 · Part 3.1.3

CÂU 3

KL divergence đo độ khác nhau giữa hai phân phối, và bằng 0 khi chúng trùng nhau. Với hai Gaussian một chiều, $D_{KL}\big(\mathcal{N}(\mu_1, \sigma_1^2) \,\|\, \mathcal{N}(\mu_2, \sigma_2^2)\big) = \ln \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}$. Ở một bước reverse, phân phối đích có mean 1.30, model có mean 1.10, hai bên cùng phương sai 0.04. KL bằng bao nhiêu?

A 0.04

B 0.5

C 1.0

D 2.5

PHỎNG THEO USA-NA-AIO 2026 · Vòng 2 · Ngày 2 · Part 3.2.1–3.2.5

CÂU 4

Noise predictor $\epsilon_\theta(x_t, t)$ cho ảnh là một U-Net. Đầu vào x_t có shape `(B, C, H, W)`, đầu ra cùng shape. Nên đưa bước t vào mạng bằng cách nào?

A Bỏ t, vì mạng đủ sâu sẽ tự đọc mức nhiễu từ độ hạt của x_t

B Train một mạng riêng cho mỗi t, lúc sinh thì chọn mạng theo t

C Cộng t/T vào noise dự đoán ở đầu ra, sau khi mạng chạy xong

D Mã hóa t thành vector rồi cộng vào feature map của các khối

PHỎNG THEO USA-NA-AIO 2026 · Vòng 2 · Ngày 2 · Part 3.3

CÂU 5

Đề cho 30 phút để sinh 600 ảnh trên một GPU. Generator của GAN tạo một ảnh trong 15 ms. Pipeline diffusion dùng 50 bước, mỗi bước gọi U-Net một lần mất 40 ms, không dùng CFG. Diffusion mất bao lâu để sinh xong, và vì sao chậm hơn GAN?

A Khoảng 20 phút, vì mỗi ảnh cần 50 lần gọi mạng nối tiếp nhau

B Khoảng 20 phút, vì model diffusion có nhiều tham số hơn

C Khoảng 24 giây, vì mỗi ảnh chỉ cần một lần gọi U-Net

D Khoảng 24 giây, vì các bước khử nhiễu chạy song song

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 255

CÂU 6

Ở một bước sinh, denoiser cho $\epsilon_\theta(x_t, t, \varnothing) = 0.2$ khi không có prompt, và $\epsilon_\theta(x_t, t, c) = 0.5$ khi có prompt. Với classifier-free guidance $w = 3$, noise dùng cho bước này là bao nhiêu? w lớn có tác dụng gì?

A 1.5, và sampling nhanh hơn vì cần ít bước hơn

B 1.5, và ảnh bám prompt hơn, đổi lại kém đa dạng

C 1.1, và ảnh bám prompt hơn, đổi lại kém đa dạng

D 1.1, và sampling nhanh hơn vì cần ít bước hơn

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 254

CÂU 7

GAN sinh khuôn mặt sắc nét, nhưng 64 mẫu từ 64 seed khác nhau gần như cùng một gương mặt, dù dữ liệu thật rất đa dạng. Điều này nói lên gì?

A Ảnh sắc nét chứng tỏ G đã học được phân phối dữ liệu

B Loss của G vẫn đang giảm, nên train thêm thì hiện tượng sẽ tự hết

C Noise z có quá ít chiều, tăng số chiều của z chắc chắn sửa được

D Đây là dấu hiệu mode collapse, cần đo độ đa dạng và độ phủ của phân phối

CÂU 8

Một đội viết `optimizer_g = torch.optim.SGD(list(generator.parameters()) + list(discriminator.parameters()), lr=0.1)`, và ở bước G không đóng băng D. Phần còn lại giữ như code của bài. Dòng kiểm nào lộ ra lỗi, và D bị đẩy theo hướng nào?

A Không dòng nào lộ, vì `optimizer_g` vẫn chỉ cập nhật G

B `D unchanged during G step` in False, và D bị dạy gọi ảnh giả là thật

C `D unchanged during G step` in False, và D học tách ảnh giả rõ hơn

D `G changed during G step` in False, vì gradient bị chia sang D

CÂU 9

Một noise predictor nhỏ có MSE đoán noise trên batch kiểm tra, cùng quy tắc sinh dữ liệu và cùng lịch nhiễu, giảm từ 1.0 xuống 0.6 sau khi train. Bằng chứng này cho phép kết luận điều gì?

A Model đoán noise tốt hơn trên phân phối và lịch nhiễu đã kiểm

B Ảnh do sampler dùng model này sinh ra đẹp hơn khoảng 40%

C Model dùng được ngay với một lịch nhiễu khác mà không cần train lại

D Sampler hoàn chỉnh đã chạy đúng, vì MSE noise đã giảm

CÂU 10

Đội có 300 ảnh thật có nhãn. Họ sinh thêm 3000 ảnh bằng diffusion theo prompt của từng lớp, trộn tất cả, rồi chia ngẫu nhiên 80/20 thành train và validation. Validation accuracy tăng từ 71% lên 90%. Con số này có đáng tin không?

A Đáng tin, ảnh sinh giúp thêm 19 điểm, nên nộp ngay cấu hình này

B Đáng tin, nên sinh thêm ảnh cho đến khi validation ngừng tăng

C Đáng tin, vì validation có cả ảnh thật lẫn ảnh sinh

D Chưa tin được, phải chấm lại trên validation chỉ gồm ảnh thật

Đọc thêm

- Goodfellow và cộng sự — Generative Adversarial Networks: đọc hai vai trò và phân biệt minimax với loss generator thực hành.
- Ho, Jain, Abbeel — Denoising Diffusion Probabilistic Models: đọc forward noise, noise prediction và reverse sampler.
- Rombach và cộng sự — High-Resolution Image Synthesis with Latent Diffusion Models: đọc vì sao khử nhiễu trong latent và cách đưa prompt vào qua cross-attention.
- Ho, Salimans — Classifier-Free Diffusion Guidance: đọc cách train một model cho cả hai chế độ và đánh đổi giữa mức bám điều kiện với đa dạng.
- Diffusers — Stable Diffusion pipelines: đối chiếu điều kiện, sampler và cách nạp pipeline khi có asset.

Nguồn ảnh: ảnh tháp là ảnh mẫu `china.jpg` kèm scikit-learn (danielbuechele, Flickr, CC BY 2.0).

Tải gói recipe của chương — gồm các module phụ và hướng dẫn chuẩn bị asset.