Pandas và Matplotlib

Từ bảng dữ liệu đến file dự đoán đúng ID

Chương 0 · Bài 0.3

Ba file, nhiều cách ghép sai

- `train.csv` có đặc trưng và điểm cuối kỳ.
- `test.csv` có học sinh cần dự đoán.
- `sample_submission.csv` quy định ID và cột của file nộp.

Bảng lớp nằm riêng; giờ tự học có ô trống.

CÂU HỎI XUYÊN SUỐT

Làm sao tạo file dự đoán đúng học sinh, đúng định dạng và đọc lại kiểm được?

Mục tiêu buổi này

- Kiểm bảng ngay sau khi đọc CSV.
- Lọc, sửa, gộp và ghép mà giữ đúng ý nghĩa dòng.
- Vẽ biểu đồ trả lời một câu hỏi cụ thể.
- Ghép file nộp theo ID, kiểm hữu hạn và đọc lại CSV.

Bốn file, hai khóa

train.csv

id	lop	gio	hk1	diem_toan
1	10A4	0.4	9.1	6.72
…				

lop

lop.csv

lop	chuyen	si_so
10A1	True	38
…		

test.csv

id	lop	gio	hk1
401	10A2	NaN	7.1
…			

id

sample_submission.csv

id	diem_toan
401	0.0
…	

Bốn file của đề và hai khóa ghép: lop và id.

Một DataFrame gồm những gì

index | Series

	id	lop	gio_tu_hoc	diem_hk1	diem_toan	
0	1	10A4	0.4	9.1	6.72	
1	2	10A3	0.6	5.9	6.84	
2	3	10A3	2.8	4.9	4.79	
3	4	10A4	NaN	6.8	6.88	NaN: ô thiếu
	int64	object	float64	float64	float64	dtype

DataFrame: index, các cột Series, mỗi cột một dtype.

Năm việc trước khi tính

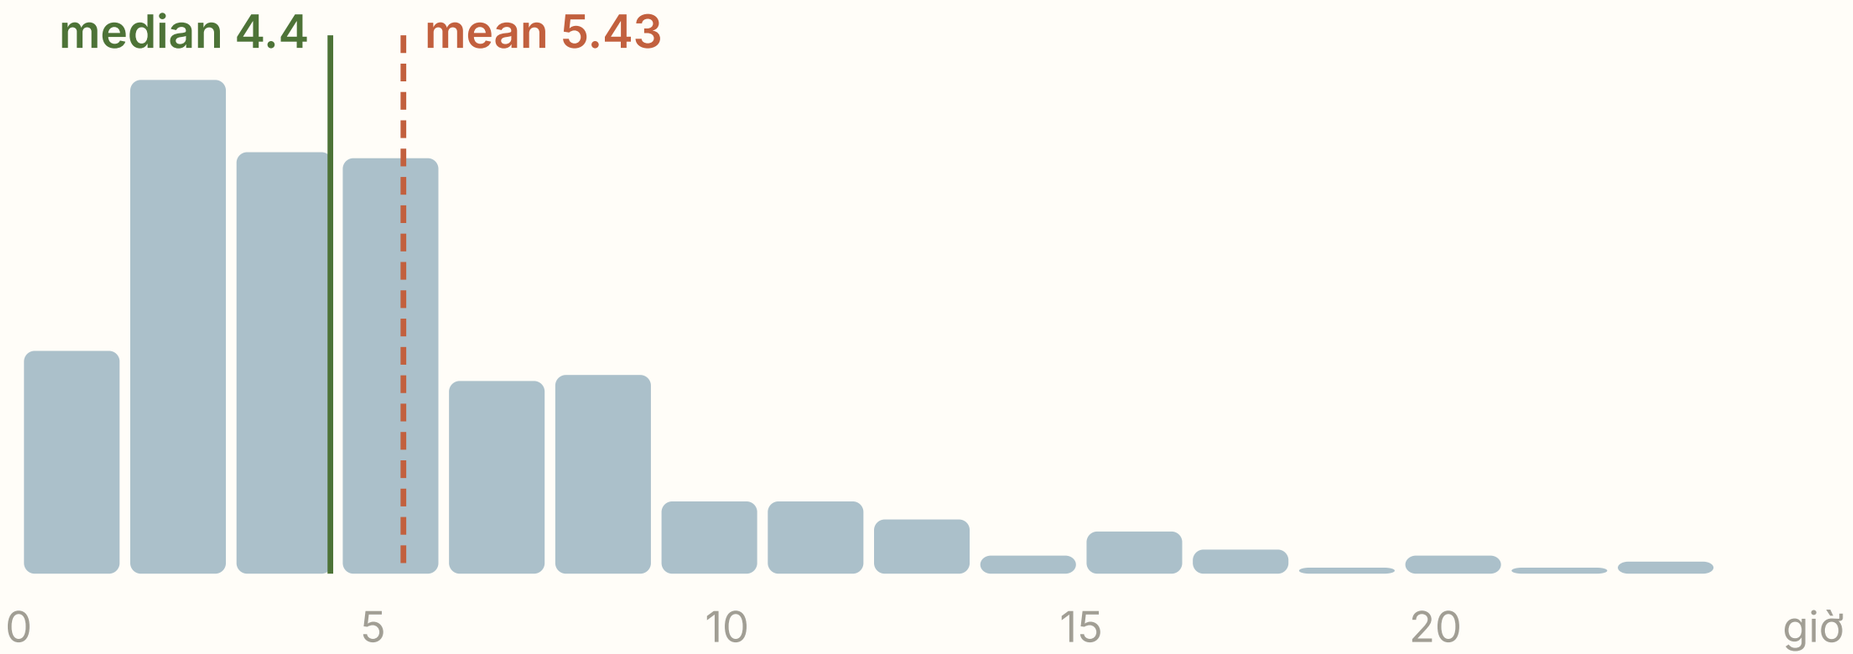
Giả sử ô tạo dữ liệu đã chạy; `data_dir` chứa `train.csv` và `test.csv`.

```
train = pd.read_csv(
    data_dir / "train.csv", encoding="utf-8"
)
print(train.shape)
print(train.head(3))
print(train.dtypes)
print(train.isna().sum())
print(train.describe())
```

Ở bài: train **400 × 5**, test **100 × 4**.

- Nhãn: `diem_toan`.
- Khóa ghép: `id`.
- 23 giá trị giờ tự học bị thiếu.
- Miền nhãn theo đề: 0–10.

Mean lớn hơn median



Giờ tự học lệch phải: đuôi dài kéo mean lên trên median.

HỎI NHANH

Bảng `describe` của cột `gio_tu_hoc` cho mean 5.43, median 4.40 và max 23.0. Phân bố giờ tự học nhiều khả năng có dạng nào?

A Lệch phải, đuôi dài phía giá trị lớn kéo mean lên

B Lệch trái, đuôi dài phía giá trị nhỏ kéo mean xuống

C Gần đối xứng, vì mean và median chỉ chênh một giờ

D Chưa nói được gì nếu chưa vẽ histogram

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 69

Một cột và một bảng khác shape

`train["diem_toan"]`: Series `(400,)`.

`train[["diem_toan"]]`: DataFrame `(400, 1)`.

- ID cần duy nhất, không thiếu.
- Nếu ID là `"001"`, yêu cầu dtype chữ khi đọc.
- Test phải có đúng đặc trưng đề cung cấp.
- Index là nhãn dòng, chưa chắc là ID.

HỎI NHANH

Cột điểm có vài ô ghi `"không rõ"`, nên pandas đọc cả cột thành chữ. Ta nên làm gì?

A Điền mọi ô lạ bằng 0 rồi đổi sang số

B Xem các ô lạ, đổi kiểu, rồi đếm số ô thành `NaN`

C Đổi tên cột để pandas đọc lại thành số

D Bỏ qua, vì giá trị nhìn vẫn giống số

Sửa bằng một lần `loc`

Giả sử `demo = train.copy()`: sửa trên bản sao để giữ nhãn thật.

```
demo.loc[demo["lop"] == "10A1", "diem_toan"] = 0
print((demo["diem_toan"] == 0).sum())
```

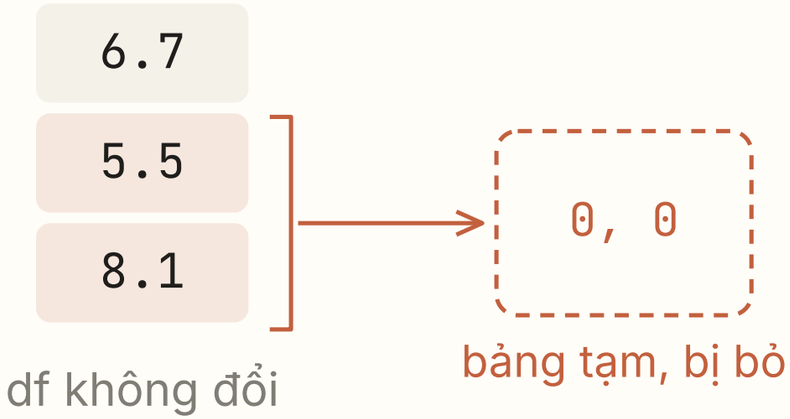
KẾT QUẢ

```
98
```

- Mỗi điều kiện có ngoặc, nối bằng `&` hoặc `|`.
- `loc`: nhãn và tên cột.
- `iloc`: vị trí.
- `df[mask]["col"] = value`: gán vào bảng tạm, bảng gốc không đổi.

Bảng tạm và bảng gốc

```
df[mask]["col"] = 0
```




```
df.loc[mask, "col"] = 0
```



Gán nối chuỗi rơi vào bảng tạm; một lần loc sửa thẳng bảng gốc.

HỎI NHANH

Cần lọc các học sinh lớp 10A1 có điểm HK1 dưới 5. Viết thế nào cho đúng?

A
```
train[train["lop"] == "10A1" and train["diem_hk1"] < 5]
```

B
```
train[train["lop"] == "10A1" & train["diem_hk1"] < 5]
```

C
```
train.loc["10A1", "diem_hk1" < 5]
```

D
```
train[(train["lop"] == "10A1") & (train["diem_hk1"] < 5)]
```

Thiếu dữ liệu khác với số 0

Điền giờ tự học bằng trung vị cùng lớp; lớp mới dùng trung vị chung của train.

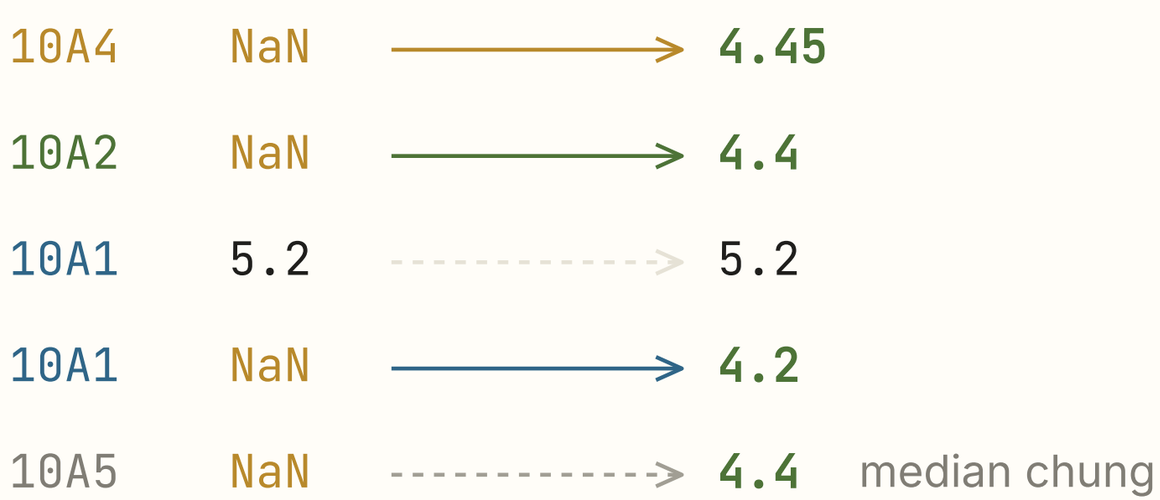
Giả sử `med_lop`, `med_all` đã tính từ train và `result` là bản sao cần biến đổi.

```
group_value = result["lop"].map(med_lop)
result["gio_tu_hoc"] = (
    result["gio_tu_hoc"].fillna(group_value)
    .fillna(med_all)
)
```

- Trung vị chung: **4.4 giờ**.
- Train và test sau điền: **0 ô thiếu**.
- Lớp mới 10A5 cũng nhận 4.4 khi chưa có dữ liệu.

Fit thống kê trên phần train dùng học; validation/test dùng lại thống kê đó.

Mỗi lớp một median



median từ train

10A1	4.2
10A2	4.4
10A3	4.7
10A4	4.45

Ô thiếu nhận median của lớp mình; lớp lạ nhận median chung.

HỎI NHANH

Test có lớp 10A5, lớp này chưa từng có trong train. `map(med_lop)` trả về gì ở các dòng ấy, và code của bài xử lý ra sao?

A Báo `KeyError`, phải thêm 10A5 vào train rồi chạy lại

B Trả `NaN`, rồi `fillna(med_all)` điền median của train

C Tự tính median của 10A5 từ giờ học trong test

D Trả 0, nên lớp mới mang giờ học bằng 0

agg và transform trả lời khác nhau

transform: 400 dòng

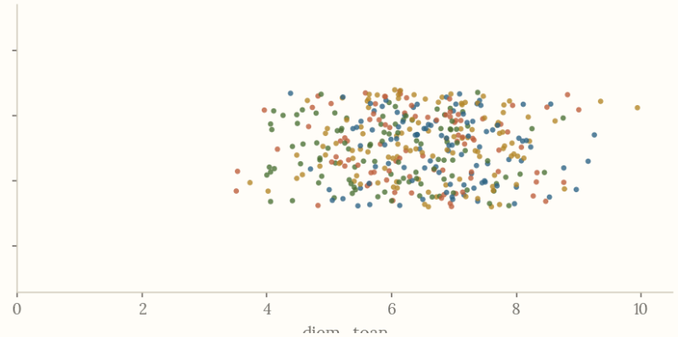
lop	điểm	TB lớp
10A4	6.72	6.58
10A3	6.84	5.96
10A3	4.79	5.96
10A4	6.88	6.58
10A3	6.45	5.96
10A4	8.02	6.58
10A4	7.34	6.58
10A1	5.50	6.79

agg: 4 dòng

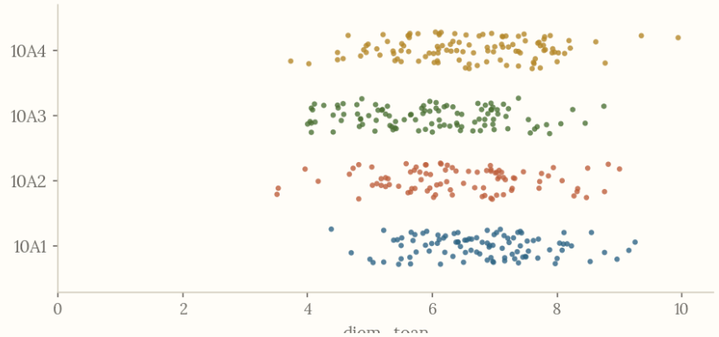
10A1	6.79
10A2	6.41
10A3	5.96
10A4	6.58

transform giữ mọi dòng; agg thu về một dòng mỗi lớp.

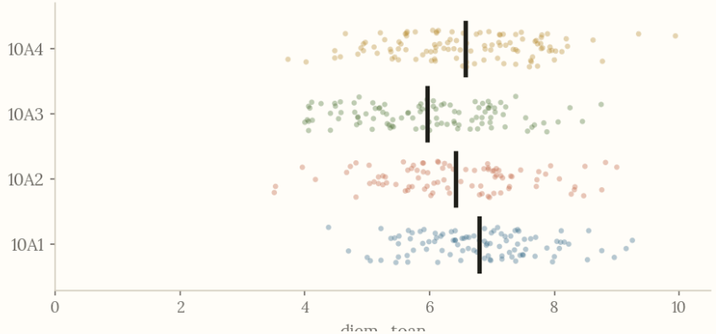
Tách, tính, gộp



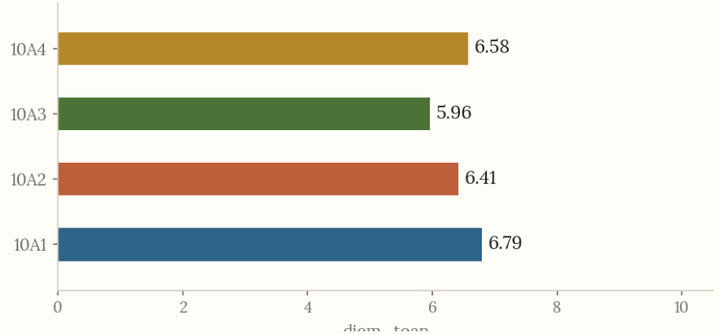
400 dòng của train.csv, mỗi chấm là một học sinh



split: tách các dòng theo cột `lop`



apply: mỗi nhóm lấy trung bình `diem_toan` (vạch đậm)



combine: `df.groupby("lop")["diem_toan"].mean()` thành một dòng mỗi lớp

groupby trên 400 học sinh của bài: tách dòng theo lớp, tính trung bình điểm toán trong từng nhóm, rồi gộp thành một bảng bốn dòng.

Đọc kết quả theo nhóm

Cách gọi	Kết quả
`agg("mean")`	Một giá trị mỗi lớp: `(4,)`
`transform("mean")`	Một giá trị mỗi học sinh: `(400,)`

Trong dữ liệu của bài, trung bình 10A1 là 6.79, 10A3 là 5.96.

`count`: số giá trị không thiếu.

`size`: số dòng của nhóm.

Chênh trung bình gợi giả thuyết, chưa chứng minh nhân quả.

Trung bình nhóm tính từ nhãn chỉ để đọc bảng; chưa đưa vào đặc trưng model.

HỎI NHANH

`train` có 400 dòng, chia thành 4 lớp. `train.groupby("lop")["diem_toan"].transform("max")` có bao nhiêu phần tử?

A 4

B 1

C 1600

D 400

Gán Series ghép theo nhãn index

```
tiny = pd.DataFrame(
    {"id": [101, 102, 103]},
    index=[10, 20, 30],
)
values = pd.Series(
    [6.0, 7.0, 8.0], index=[30, 10, 20]
)
tiny["score"] = values
print(tiny["score"].tolist())
```

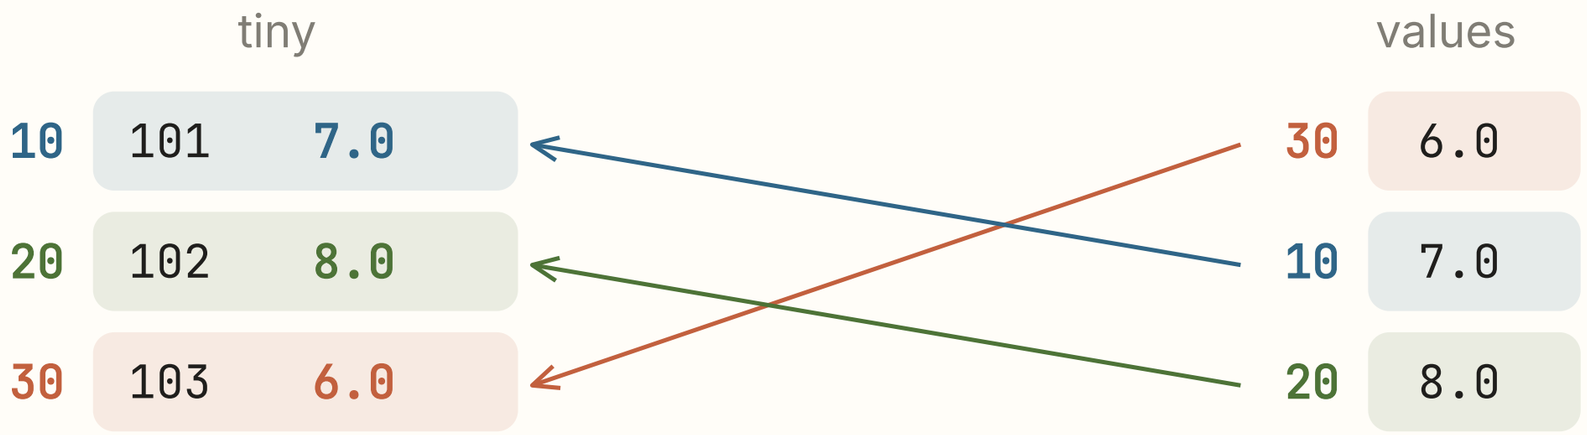
KẾT QUẢ

```
[7.0, 8.0, 6.0]
```

Index 10 nhận 7.0, không nhận phần tử đầu 6.0.

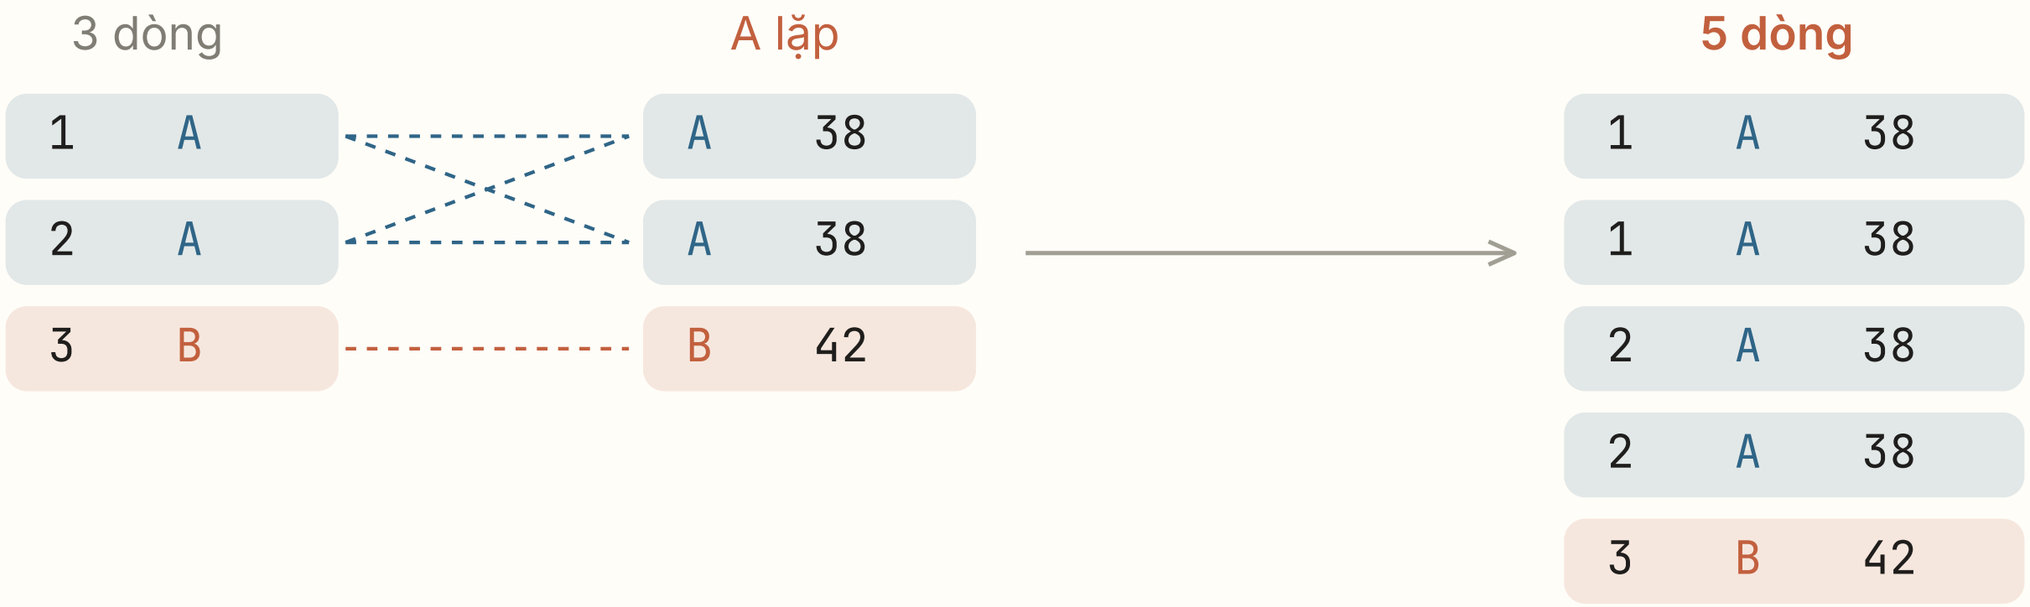
Với ID bài thi, ghép rõ theo khóa bằng `merge`.

Ghép theo nhãn, không theo vị trí



pandas ghép theo nhãn index, không theo vị trí.

`left` vẫn có thể tăng số dòng



Khóa lặp ở bảng phải làm left merge nhân bản dòng.

Kiểm quan hệ ghép

Giả sử `lop_info` có một dòng cho mỗi giá trị `lop`.

```
merged = train.merge(
    lop_info, on="lop", how="left",
    validate="many_to_one",
)
assert len(merged) == len(train)
```

- Nhiều học sinh → một dòng lớp.
- `validate` bắt khóa phải bị trùng.
- `left` giữ khóa trái, không hứa giữ số dòng.
- `inner` có thể mất học sinh không khớp.
- Kiểm thêm các cột mới có giá trị thiếu không.

HỎI NHANH

Bảng trái có ba học sinh lớp A, A, B. Bảng phải có ba dòng thông tin lớp, cũng là A, A, B. Ghép bằng `merge` với `how="left"` theo lớp thì được mấy dòng?

A 3

B 4

C 5

D 9

Chọn hình theo điều cần biết

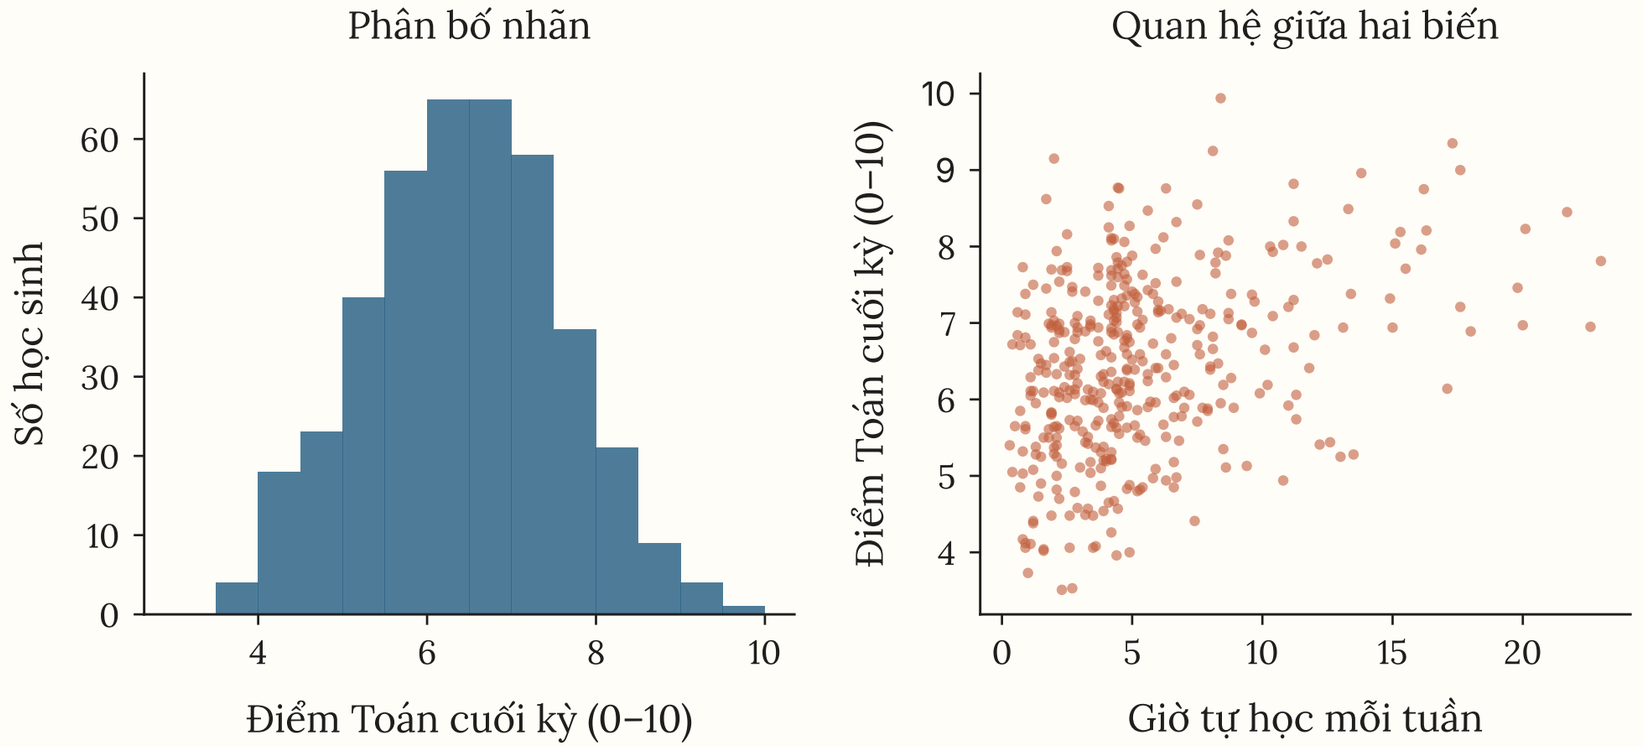
Câu hỏi	Biểu đồ
Một biến phân bố thế nào?	Histogram
Hai biến số liên quan thế nào?	Scatter
Nhóm nào có giá trị cao hơn?	Bar
Thay đổi theo thời gian?	Line

```
fig, (ax1, ax2) = plt.subplots(
    1, 2, figsize=(10, 4)
)
ax2.scatter(
    train["gio_tu_hoc"], train["diem_toan"],
    s=10, alpha=0.6,
)
ax2.set_xlabel("giờ tự học mỗi tuần")
ax2.set_ylabel("điểm Toán cuối kỳ")
```

Cần nhãn, đơn vị và ý nghĩa của thứ tự trục.

Đoạn code giả sử `import matplotlib.pyplot as plt`, `train` đã đọc và cột `gio_tu_hoc` đã xử lý ô thiếu.

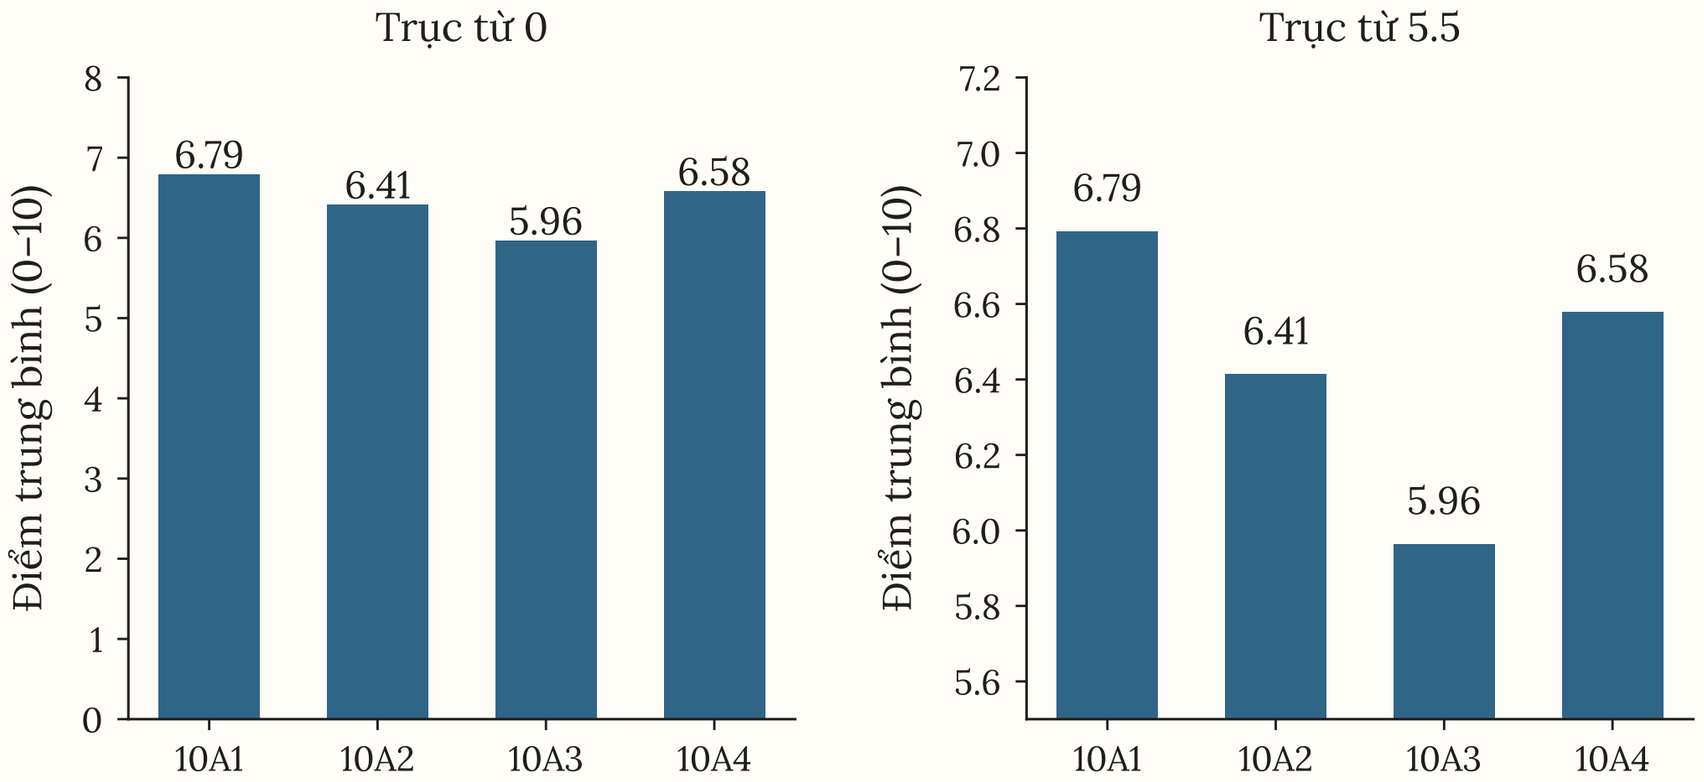
Phân bố và quan hệ



Phân bố điểm và quan hệ giữa giờ tự học với điểm.

Tương quan trong dữ liệu của bài: HK1 với Toán **0.56**, giờ tự học với Toán **0.36**. Đó không phải độ dốc hay bằng chứng nhân quả.

Chiều cao cột cần một mốc đúng



Cùng trung bình, cắt trục y làm chênh lệch trông lớn hơn.

Muốn xem chênh nhỏ chi tiết, có thể dùng biểu đồ điểm có trục ghi rõ.

HỎI NHANH

Muốn xem điểm HK1 và điểm cuối kỳ có đi cùng nhau không, ta nên vẽ gì?

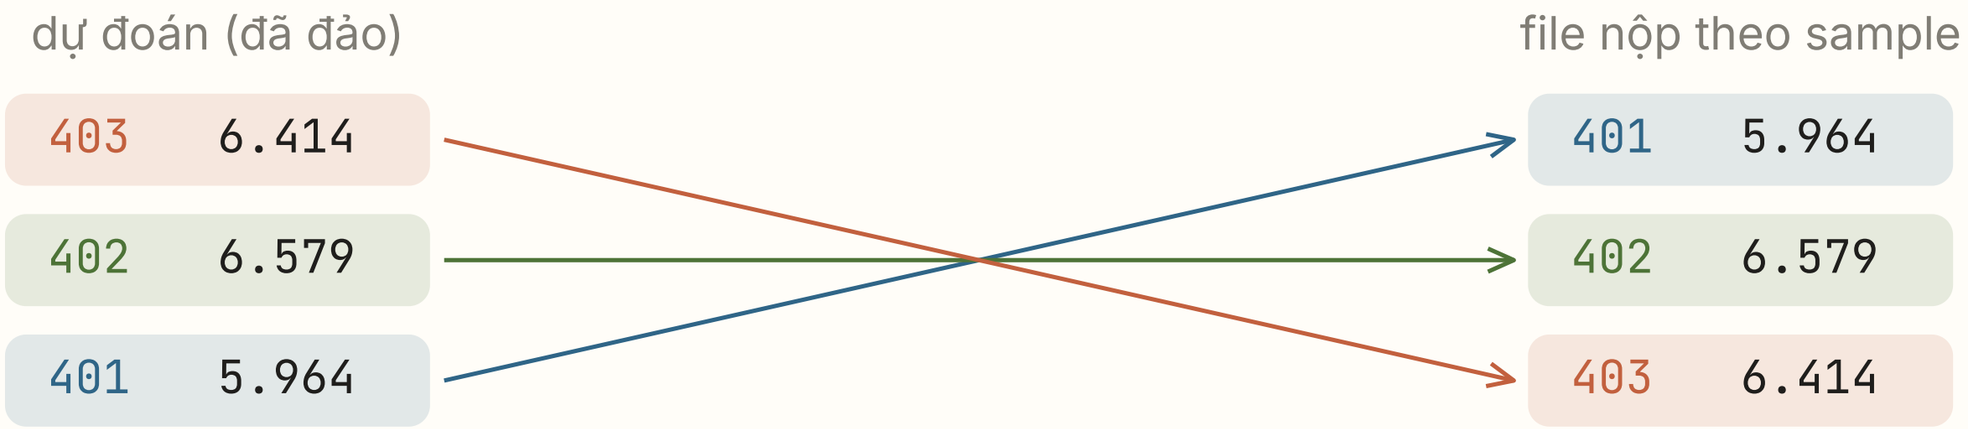
A Histogram của điểm cuối kỳ

B Scatter, mỗi học sinh là một điểm

C Đường nối các học sinh theo ID

D Biểu đồ cột số học sinh từng lớp

Ghép theo khóa, không gán theo vị trí



Ghép theo id vào khung sample: đúng học sinh, đúng thứ tự.

Trong code của bài, bảng dự đoán bị đảo ngược để kiểm điều này.

HỎI NHANH

`pred_table` xếp ID từ 500 về 401, còn `sample` xếp từ 401 tới 500. `sample[["id"]].merge(pred_table, on="id", how="left")` cho ID theo thứ tự nào?

A Từ 500 về 401, theo bảng dự đoán

B Từ 401 tới 500, theo bảng bên trái

C Tăng dần, vì `merge` luôn sắp theo khóa

D Không biết trước, phải tự sắp lại

Kiểm bảng trước khi ghi

Giả sử `sub` đã ghép dự đoán vào `sample`; `sample` giữ đúng ID và cột mà đề yêu cầu.

```
assert sub["id"].equals(sample["id"])
assert np.isfinite(
    sub["diem_toan"].to_numpy()
).all()
assert sub["diem_toan"].between(0, 10).all()
sub.to_csv(
    data_dir / "submission.csv", index=False,
    encoding="utf-8",
)
```

- Đúng số dòng, tên và thứ tự cột.
- Đúng ID và thứ tự mẫu.
- Không NaN, không vô cùng.
- Miền nhãn theo đề.

Đọc lại tệp đã ghi

```
read_back = pd.read_csv(
    data_dir / "submission.csv",
    encoding="utf-8"
)
assert (
    read_back.columns.tolist()
    == sample.columns.tolist()
)
assert read_back["id"].equals(sample["id"])
assert np.isfinite(read_back["diem_toan"]).all()
```

Đọc lại kiểm tệp thật sau `to_csv`, không chỉ bảng còn trong bộ nhớ.

Kết quả: **100 dòng × 2 cột**, đọc lại khớp mẫu.

Tính tay: phải nói rõ mẫu số

Lớp A: $6, 8, 7$. Lớp B: $5, \mathrm{NaN}, 9$, cột float64.

- Trung bình A = 7, B = 7.
- `transform("max")`: $8, 8, 8, 9, 9, 9$.

Tỉ lệ điểm ≥ 7 trên mọi dòng: $3/6 = 0.5$.

Tỉ lệ trong các dòng đã có điểm: $3/5 = 0.6$.

`count` lớp B = 2; `size` lớp B = 3.

Không để mặc định của thư viện quyết định câu hỏi thống kê.

Khi đi thi

- **Năm lệnh đầu tiên**: `shape`, `head`, `dtypes`, `isna().sum()`, `describe()`, cho cả train lẫn test.
- **Vẽ phân bố nhãn** trước khi chọn metric.
- **Ghép có** `validate`, in shape trước và sau.
- **File nộp từ** `sample_submission`, ghép theo `id`, `index=False`, đọc lại.

02

Luyện đề

LUYỆN ĐỀ 1

Bảng `df` có một cột tên `"diem toan"`, có dấu cách ở giữa. Ta chọn cột này thế nào?

A `df.diem toan`

B `df("diem toan")`

C `df.loc["diem toan"]`

D `df["diem toan"]`

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 110

LUYỆN ĐỀ 2

Cột giờ học trên train là `[1, 3, 5]`, trên test là `[2, NaN, 100]`. Ta điền ô thiếu bằng median của train. Ô `NaN` ở test được điền số mấy?

A 51

B 3

C 2

D 5

LUYỆN ĐỀ 3

`train` có 400 dòng. Ghép thêm thông tin lớp bằng `train.merge(info, on="lop", how="left")` thì thành 437 dòng. Nhiều khả năng là do đâu?

A Một số lớp xuất hiện nhiều lần trong `info`

B `how="left"` luôn thêm dòng cho khớp đủ hai bảng

C Có học sinh không khớp lớp nào nên sinh dòng `NaN`

D `merge` tạo thêm dòng khi sắp xếp lại theo khóa

Chốt buổi học

Đọc hợp đồng · nhìn dữ liệu · ghép đúng khóa · kiểm file đã ghi

Một file hợp lệ chưa chứng minh model tốt. Chương tiếp theo sẽ chia dữ liệu và chấm một baseline đúng cách.

Làm **10 câu cuối bài**, chạy lại notebook từ đầu và đối chiếu các bảng nhỏ.