Pandas và Matplotlib

Đọc bảng, làm sạch, ghép, vẽ và ghi file nộp

Chương 0 · Bài 0.3

Dữ liệu của một đề thi

- `train.csv`: dữ liệu có đáp án.
- `test.csv`: dữ liệu cần dự đoán.
- `sample_submission.csv`: mẫu file nộp.

pandas: đọc, làm sạch, ghép bảng.

Matplotlib: vẽ biểu đồ để nhìn dữ liệu.

Đề trong bài: đoán điểm Toán cuối kỳ của học sinh (dữ liệu giả lập).

Mục tiêu

- Đọc CSV, xem shape, kiểu từng cột và số ô trống.
- Lọc dòng, chọn cột, dùng `groupby` và `merge`.
- Vẽ biểu đồ hợp với câu hỏi cần trả lời.
- Ghi file nộp đúng thứ tự, đúng cột và kiểm lại.

Bốn file, hai khóa

train.csv

id	lop	gio	hk1	diem_toan
1	10A4	0.4	9.1	6.72
…				

lop

lop.csv

lop	chuyen	si_so
10A1	True	38
…		

test.csv

id	lop	gio	hk1
401	10A2	NaN	7.1
…			

id

sample_submission.csv

id	diem_toan
401	0.0
…	

Bốn file của đề và hai khóa ghép: lop và id.

Một DataFrame gồm những gì

index | Series

	id	lop	gio_tu_hoc	diem_hk1	diem_toan	
0	1	10A4	0.4	9.1	6.72	
1	2	10A3	0.6	5.9	6.84	
2	3	10A3	2.8	4.9	4.79	
3	4	10A4	NaN	6.8	6.88	NaN: ô thiếu
	int64	object	float64	float64	float64	dtype

DataFrame: index, các cột Series, mỗi cột một dtype.

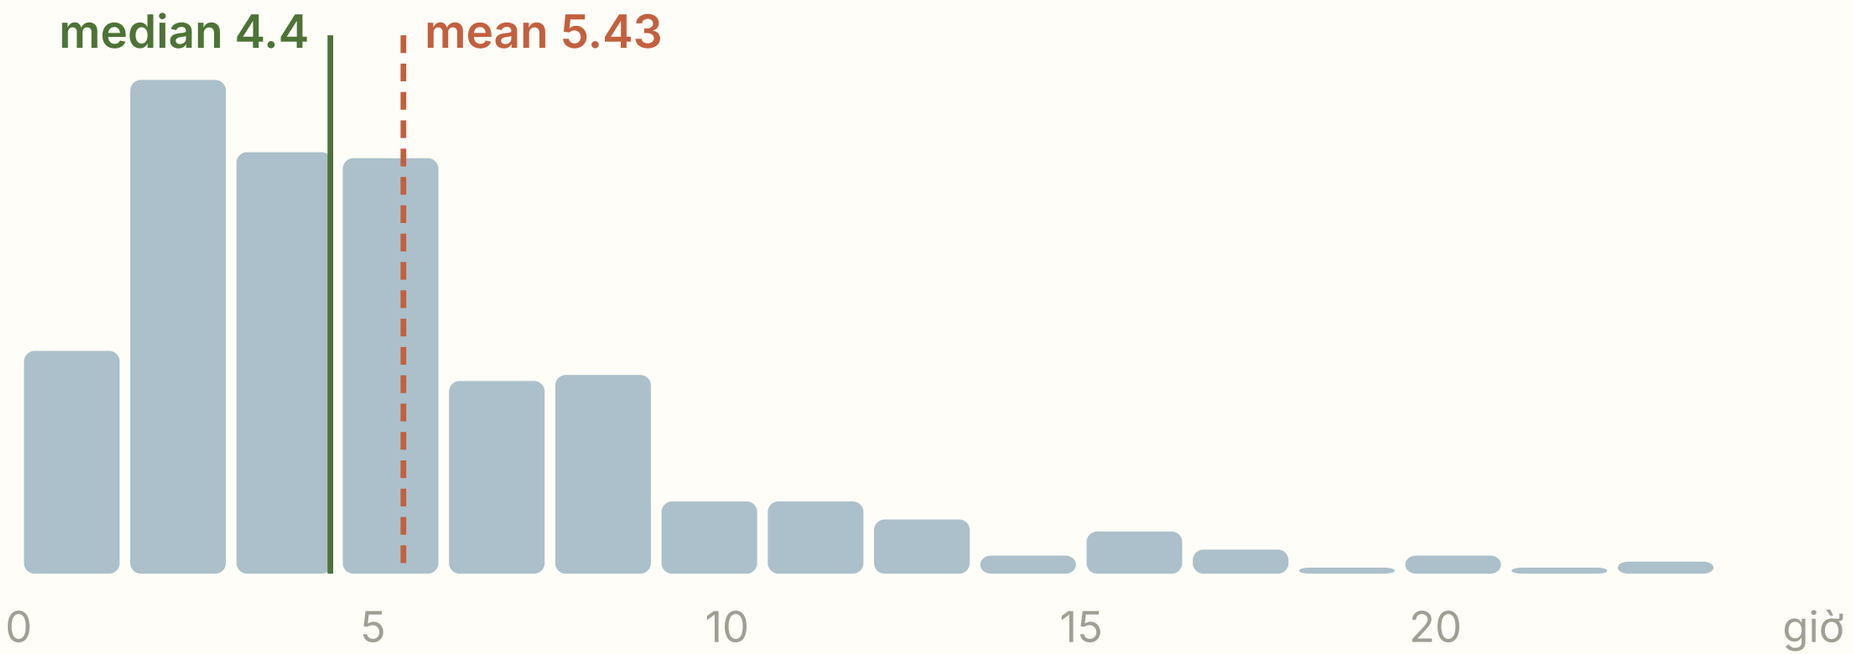
Năm việc trước khi tính

```
train = pd.read_csv(
    data_dir / "train.csv", encoding="utf-8"
)
print(train.shape, test.shape)
print(train.head(3))
print(train.dtypes)
print(train.isna().sum())
print(train.describe().round(2))
```

Ở bài: train **400 × 5**, test **100 × 4**.

- Nhãn: `diem_toan`.
- Khóa ghép: `id`.
- 23 giá trị giờ tự học bị thiếu.
- Đề quy định điểm trong 0–10.

Mean lớn hơn median



Giờ tự học lệch phải: đuôi dài kéo mean lên trên median.

HỎI NHANH

Bảng `describe` của cột `gio_tu_hoc` cho mean 5.43, median 4.40 và max 23.0. Phân bố giờ tự học nhiều khả năng có dạng nào?

A Lệch phải, đuôi dài phía giá trị lớn kéo mean lên

B Lệch trái, đuôi dài phía giá trị nhỏ kéo mean xuống

C Gần đối xứng, vì mean và median chỉ chênh một giờ

D Chưa nói được gì nếu chưa vẽ histogram

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 69

Kiểm điều đề ngầm hứa

```
assert train["id"].is_unique
assert train["diem_toan"].notna().all()
assert not set(train["id"]) & set(test["id"])
```

- `id` không trùng.
- Train không có nhãn trống.
- Không học sinh nào ở cả train lẫn test.
- `id` dạng `"001"`: đọc bằng `dtype={"id": "string"}`.

HỎI NHANH

Cột điểm có vài ô ghi `"không rõ"`, nên pandas đọc cả cột thành chữ. Ta nên làm gì?

A Điền mọi ô lạ bằng 0 rồi đổi sang số

B Xem các ô lạ, đổi kiểu, rồi đếm số ô thành `NaN`

C Đổi tên cột để pandas đọc lại thành số

D Bỏ qua, vì giá trị nhìn vẫn giống số

Sửa bằng một lần `loc`

Giả sử `demo = train.copy()`: sửa trên bản sao để giữ nhãn thật.

```
demo.loc[demo["lop"] == "10A1", "diem_toan"] = 0
print((demo["diem_toan"] == 0).sum())
```

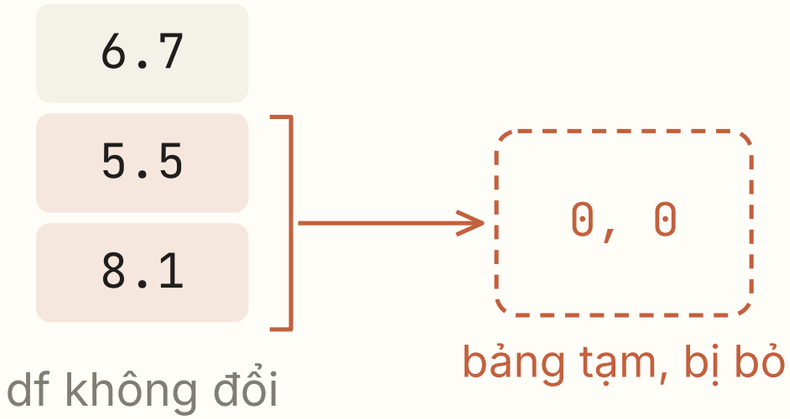
KẾT QUẢ

```
98
```

- Mỗi điều kiện có ngoặc, nối bằng `&` hoặc `|`.
- `loc`: nhãn và tên cột.
- `iloc`: vị trí.
- `df[mask]["col"] = value`: gán vào bảng tạm, bảng gốc không đổi.

Bảng tạm và bảng gốc

```
df[mask]["col"] = 0
```




```
df.loc[mask, "col"] = 0
```



Gán nối chuỗi rơi vào bảng tạm; một lần loc sửa thẳng bảng gốc.

HỎI NHANH

Cần lọc các học sinh lớp 10A1 có điểm HK1 dưới 5. Viết thế nào cho đúng?

A
```
train[train["lop"] == "10A1" and train["diem_hk1"] < 5]
```

B
```
train[train["lop"] == "10A1" & train["diem_hk1"] < 5]
```

C
```
train.loc["10A1", "diem_hk1" < 5]
```

D
```
train[(train["lop"] == "10A1") & (train["diem_hk1"] < 5)]
```

Thiếu dữ liệu khác với số 0

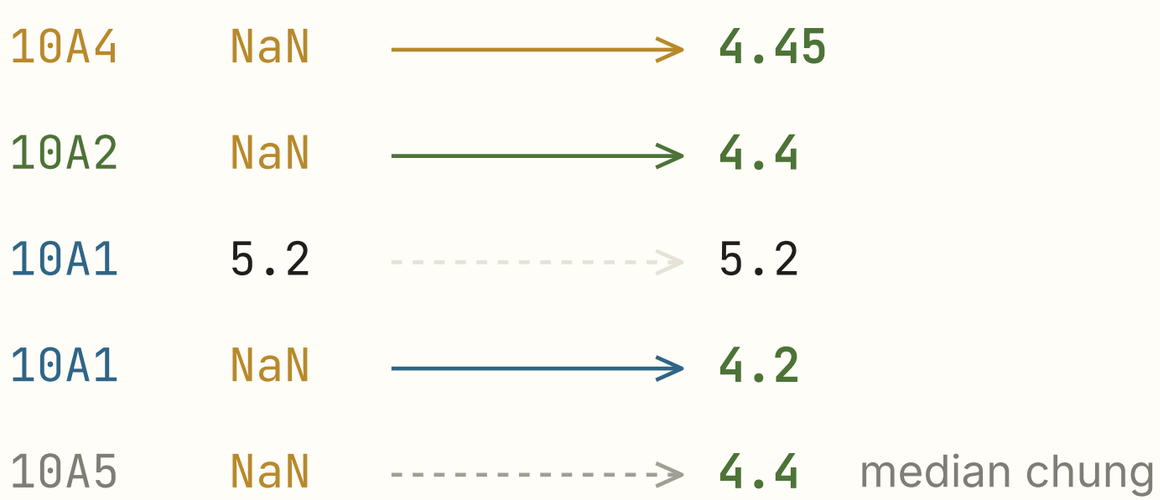
Điền bằng trung vị của lớp; lớp lạ nhận trung vị chung. Cả hai tính trên train.

```
group_value = result["lop"].map(med_lop)
result["gio_tu_hoc"] = (
    result["gio_tu_hoc"].fillna(group_value)
    .fillna(med_all)
)
```

- Trung vị chung: **4.4 giờ**.
- Train và test sau điền: **0 ô thiếu**.
- Lớp lạ 10A5 nhận 4.4.

Không tính lại trên test.

Mỗi lớp một median



median từ train

10A1	4.2
10A2	4.4
10A3	4.7
10A4	4.45

Ô thiếu nhận median của lớp mình; lớp lạ nhận median chung.

HỎI NHANH

Test có lớp 10A5, lớp này chưa từng có trong train. `map(med_lop)` trả về gì ở các dòng ấy, và code của bài xử lý ra sao?

A Báo `KeyError`, phải thêm 10A5 vào train rồi chạy lại

B Trả `NaN`, rồi `fillna(med_all)` điền median của train

C Tự tính median của 10A5 từ giờ học trong test

D Trả 0, nên lớp mới mang giờ học bằng 0

agg và transform trả lời khác nhau

transform: 400 dòng

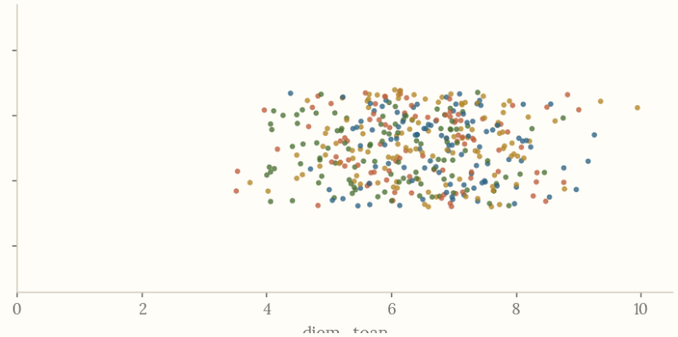
lop	điểm	TB lớp
10A4	6.72	6.58
10A3	6.84	5.96
10A3	4.79	5.96
10A4	6.88	6.58
10A3	6.45	5.96
10A4	8.02	6.58
10A4	7.34	6.58
10A1	5.50	6.79

agg: 4 dòng

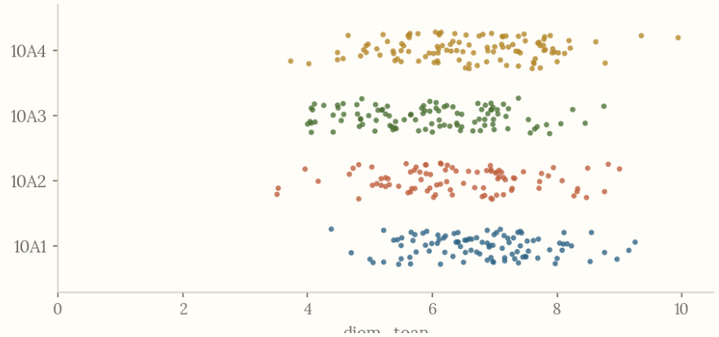
10A1	6.79
10A2	6.41
10A3	5.96
10A4	6.58

transform giữ mọi dòng; agg thu về một dòng mỗi lớp.

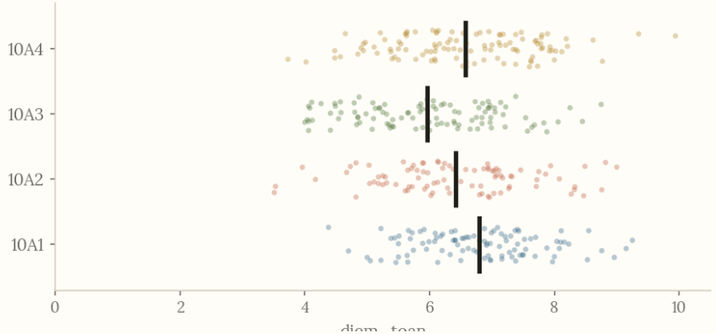
Tách, tính, gộp



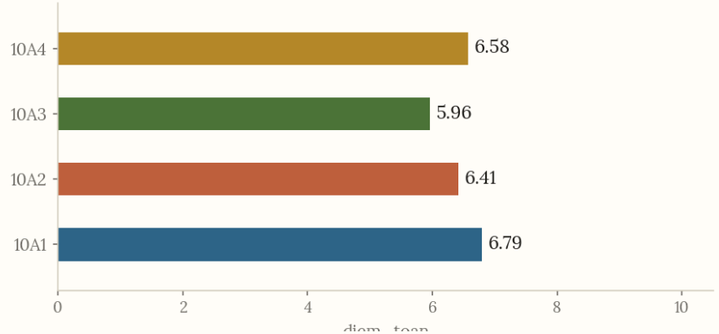
400 dòng của train.csv, mỗi chấm là một học sinh



split: tách các dòng theo cột `lop`



apply: mỗi nhóm lấy trung bình `diem_toan` (vạch đậm)



combine: `df.groupby("lop")["diem_toan"].mean()` thành một dòng mỗi lớp

groupby trên 400 học sinh của bài: tách dòng theo lớp, tính trung bình điểm toán trong từng nhóm, rồi gộp thành một bảng bốn dòng.

Đọc kết quả theo nhóm

Cách gọi	Kết quả
`agg("mean")`	Một giá trị mỗi lớp: `(4,)`
`transform("mean")`	Một giá trị mỗi học sinh: `(400,)`

Trong dữ liệu của bài, trung bình 10A1 là 6.79, 10A3 là 5.96.

`count`: số giá trị không thiếu.

`size`: số dòng của nhóm.

Biết lớp có thể giúp đoán điểm; chưa có nghĩa lớp làm điểm cao lên.

Cột trung bình lớp tính từ nhãn: chỉ để xem, không làm đầu vào cho model.

HỎI NHANH

`train` có 400 dòng, chia thành 4 lớp. `train.groupby("lop")["diem_toan"].transform("max")` có bao nhiêu phần tử?

A 4

B 1

C 1600

D 400

Ô trống khi gộp nhóm

Lớp A: $6, 8, 7$. Lớp B: $5, \mathrm{NaN}, 9$, cột float64.

- Trung bình A = 7, B = 7: `mean` bỏ qua ô trống.

Tỉ lệ điểm ≥ 7 trên mọi dòng: $3/6 = 0.5$.

Tỉ lệ trong các dòng đã có điểm: $3/5 = 0.6$.

`count` lớp B = 2 (không đếm ô trống); `size` lớp B = 3.

Gán Series ghép theo nhãn index

```
tiny = pd.DataFrame(
    {"id": [101, 102, 103]},
    index=[10, 20, 30],
)
values = pd.Series(
    [6.0, 7.0, 8.0], index=[30, 10, 20]
)
tiny["score"] = values
print(tiny["score"].tolist())
```

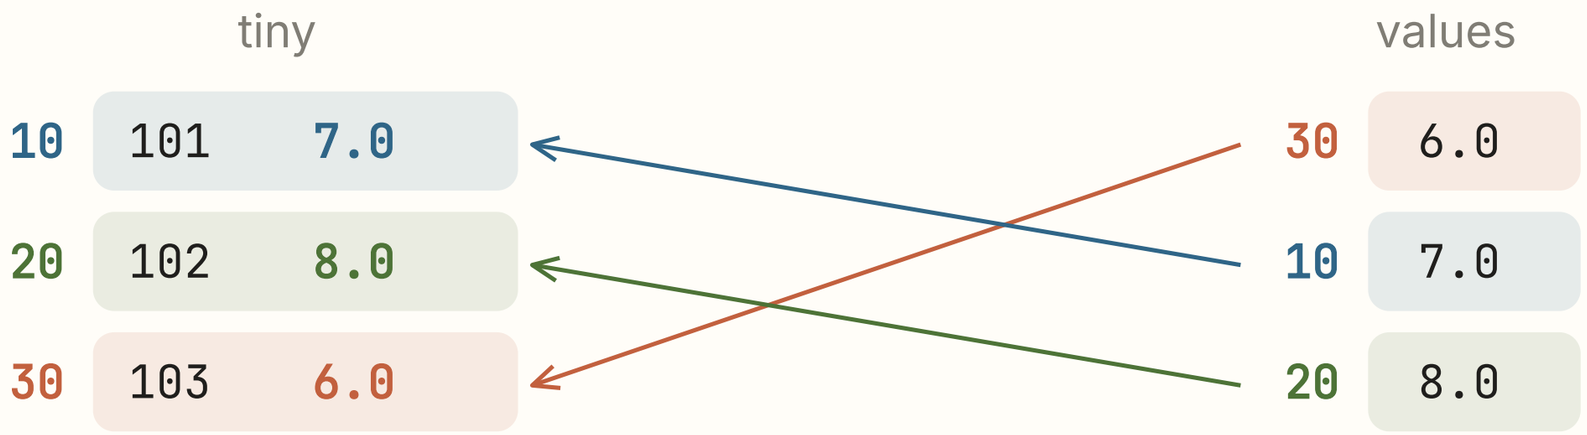
KẾT QUẢ

```
[7.0, 8.0, 6.0]
```

Index 10 nhận 7.0, không nhận phần tử đầu 6.0.

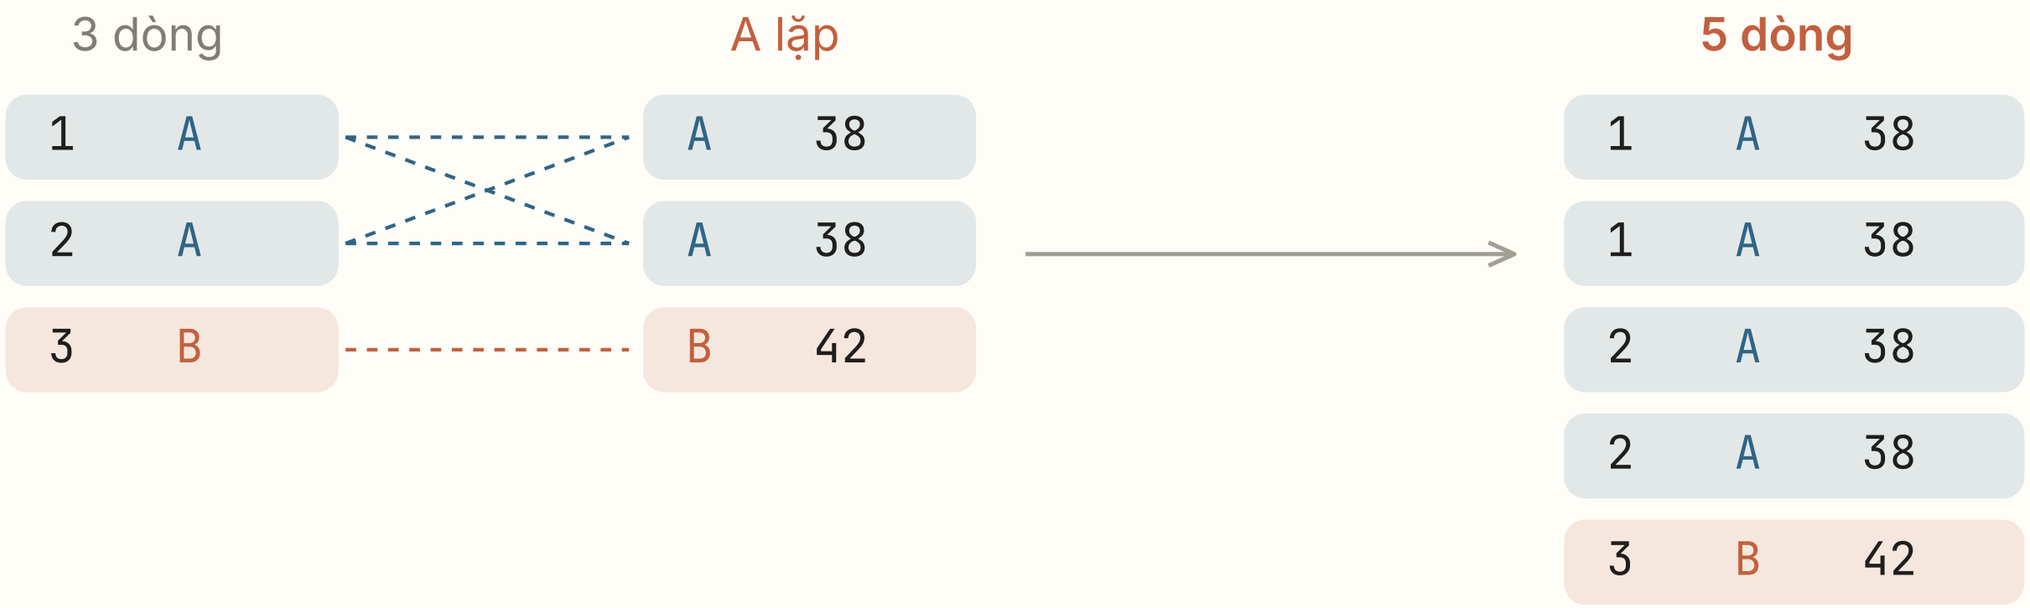
Với ID bài thi, ghép rõ theo khóa bằng `merge`.

Ghép theo nhãn, không theo vị trí



pandas ghép theo nhãn index, không theo vị trí.

`left` vẫn có thể tăng số dòng



Khóa lặp ở bảng phải làm left merge nhân bản dòng.

Kiểm quan hệ ghép

Giả sử `lop_info` có một dòng cho mỗi giá trị `lop`.

```
merged = train.merge(
    lop_info, on="lop", how="left",
    validate="many_to_one",
)
assert len(merged) == len(train)
```

- Nhiều học sinh → một dòng lớp.
- `validate` báo lỗi nếu bảng lớp bị lặp.
- `left` giữ mọi học sinh, nhưng có thể nhân dòng.
- `inner` bỏ học sinh không khớp lớp nào.

HỎI NHANH

Bảng trái có ba học sinh lớp A, A, B. Bảng phải có ba dòng thông tin lớp, cũng là A, A, B. Ghép bằng `merge` với `how="left"` theo lớp thì được mấy dòng?

A 3

B 4

C 5

D 9

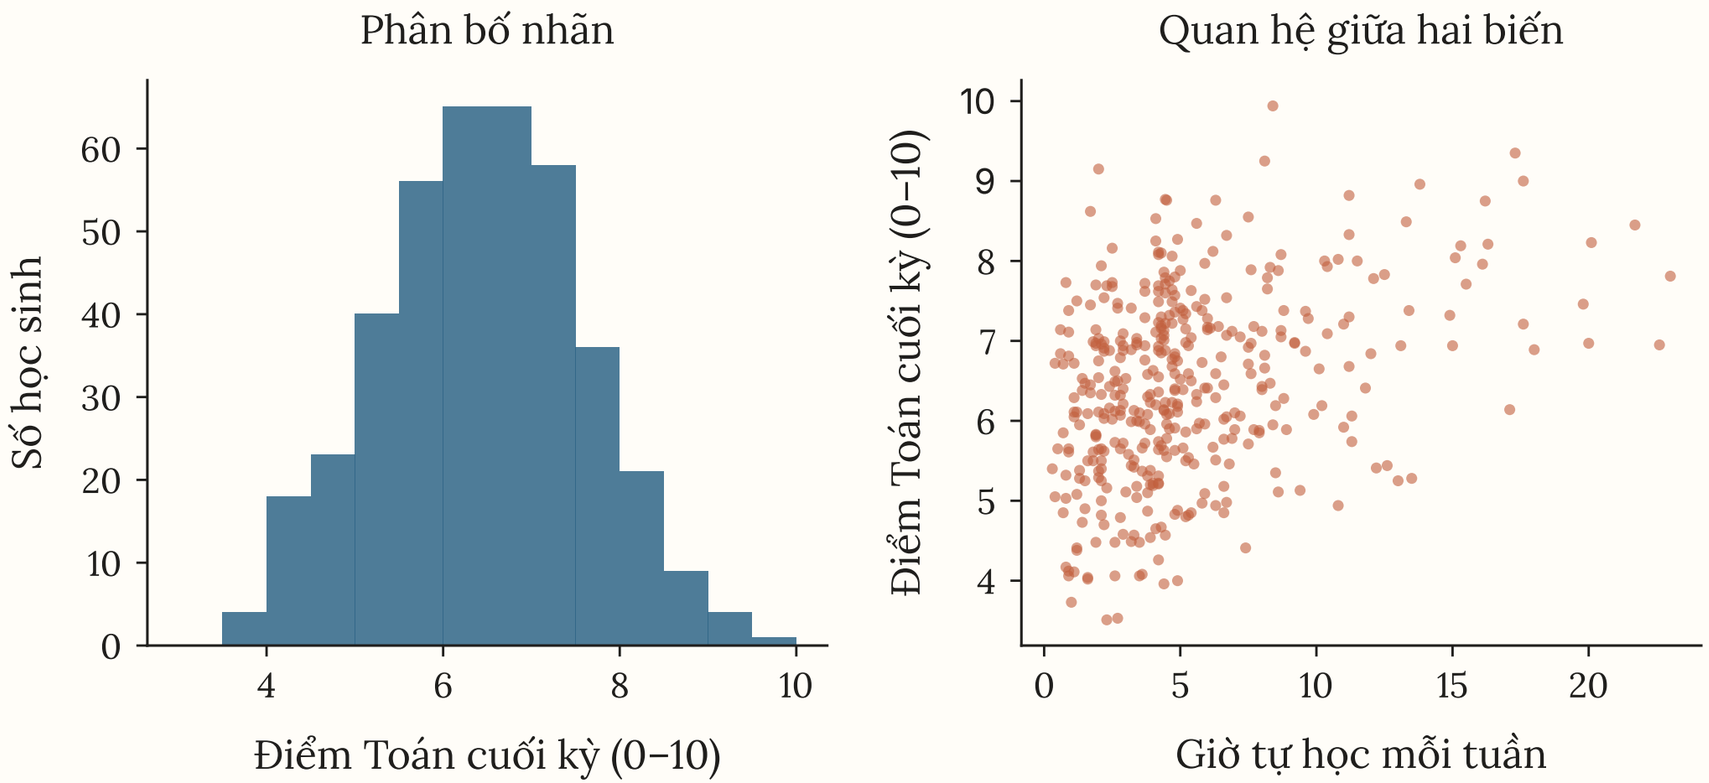
Chọn hình theo điều cần biết

Câu hỏi	Biểu đồ
Một biến phân bố thế nào?	Histogram
Hai biến số liên quan thế nào?	Scatter
Nhóm nào có giá trị cao hơn?	Bar
Thay đổi theo thời gian?	Line

```
fig, (ax1, ax2) = plt.subplots(
    1, 2, figsize=(10, 4)
)
ax2.scatter(
    train["gio_tu_hoc"], train["diem_toan"],
    s=10, alpha=0.6,
)
ax2.set_xlabel("giờ tự học mỗi tuần")
ax2.set_ylabel("điểm Toán cuối kỳ")
```

Mọi biểu đồ cần nhãn trục kèm đơn vị.

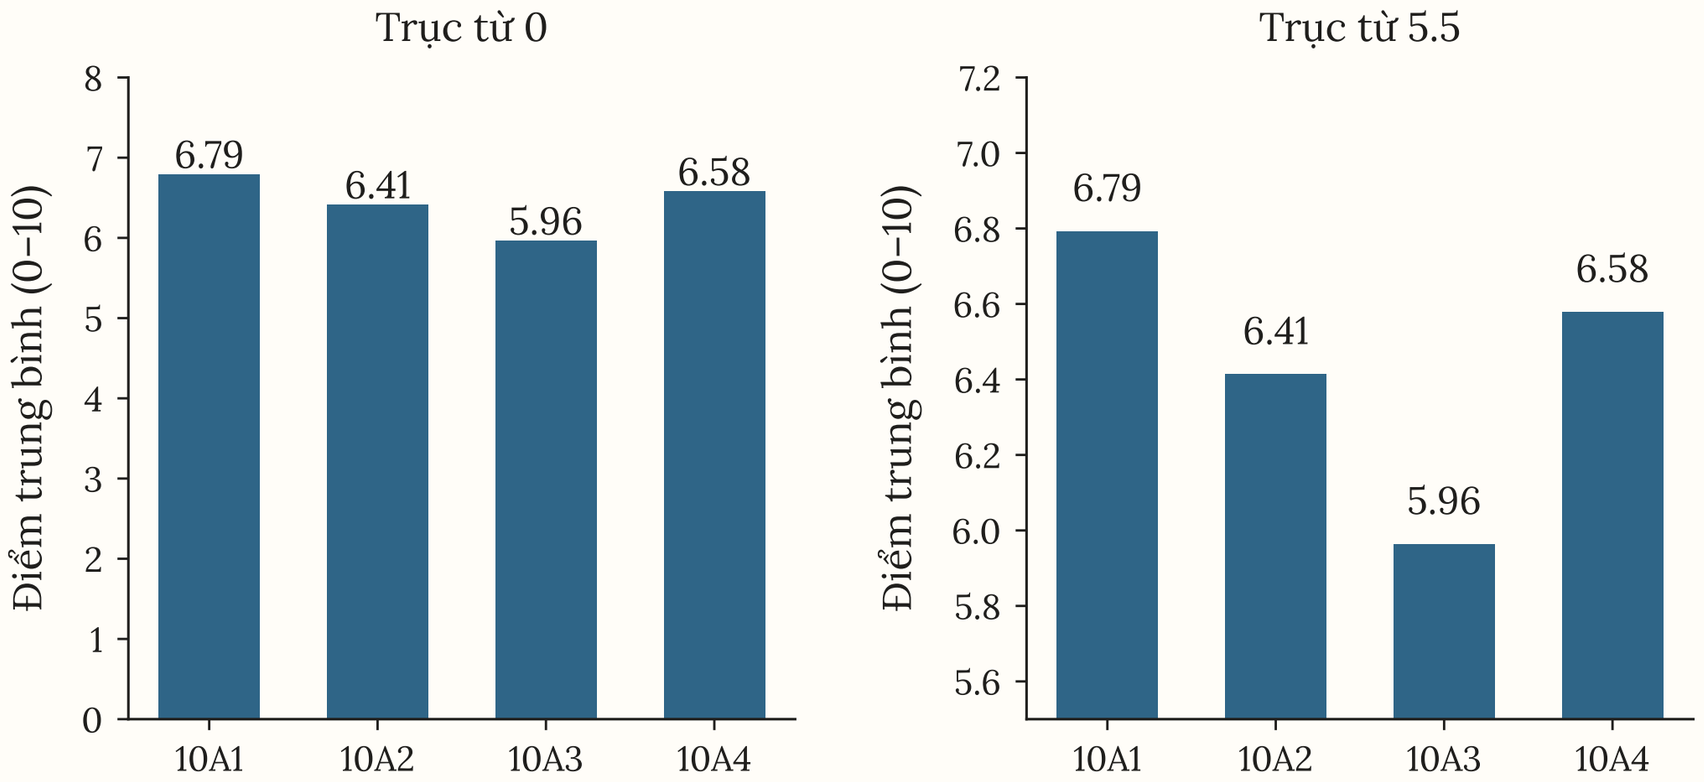
Phân bố và quan hệ



Phân bố điểm và quan hệ giữa giờ tự học với điểm.

Tương quan: HK1 với Toán **0.56**, giờ tự học với Toán **0.36**.

Chiều cao cột cần một mốc đúng



Cùng trung bình, cắt trục y làm chênh lệch trông lớn hơn.

Biểu đồ cột: trục tung bắt đầu từ 0.

HỎI NHANH

Muốn xem điểm HK1 và điểm cuối kỳ có đi cùng nhau không, ta nên vẽ gì?

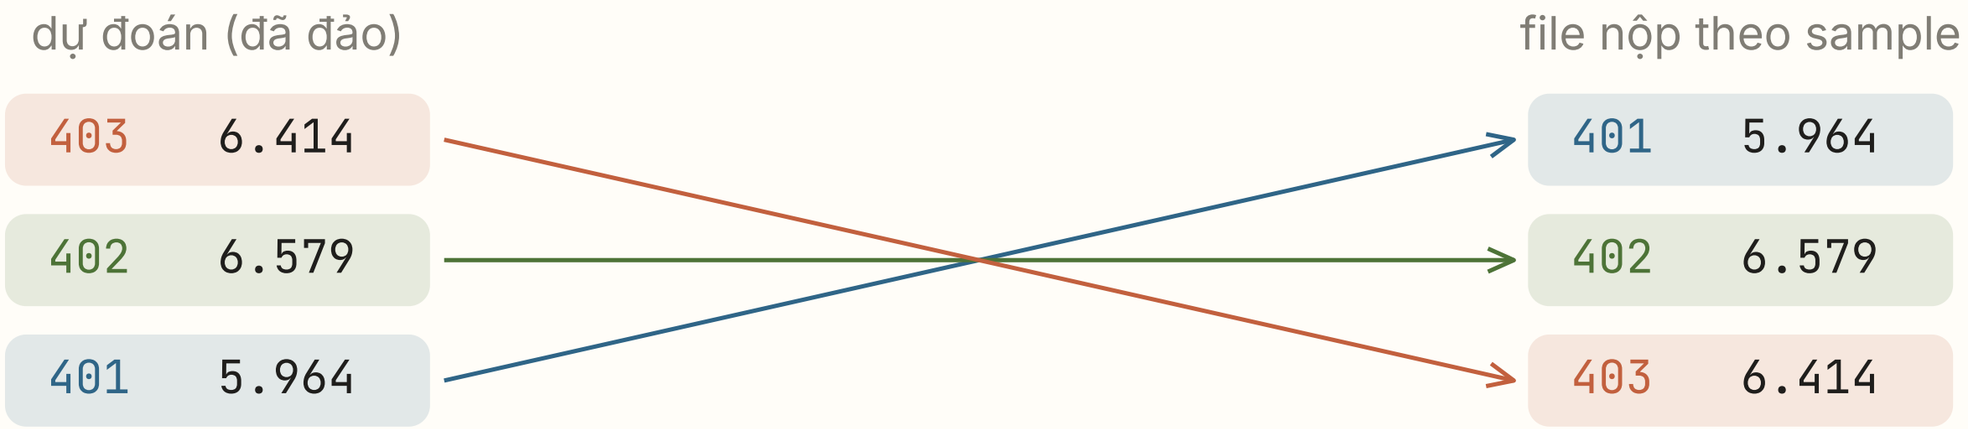
A Histogram của điểm cuối kỳ

B Scatter, mỗi học sinh là một điểm

C Đường nối các học sinh theo ID

D Biểu đồ cột số học sinh từng lớp

Ghép theo khóa, không gán theo vị trí



Ghép theo id vào khung sample: đúng học sinh, đúng thứ tự.

Trong code của bài, bảng dự đoán bị đảo ngược để kiểm điều này.

HỎI NHANH

`pred_table` xếp ID từ 500 về 401, còn `sample` xếp từ 401 tới 500. `sample[["id"]].merge(pred_table, on="id", how="left")` cho ID theo thứ tự nào?

A Từ 500 về 401, theo bảng dự đoán

B Từ 401 tới 500, theo bảng bên trái

C Tăng dần, vì `merge` luôn sắp theo khóa

D Không biết trước, phải tự sắp lại

Kiểm bảng trước khi ghi

```
assert sub["id"].equals(sample["id"])
assert np.isfinite(
    sub["diem_toan"].to_numpy()
).all()
assert sub["diem_toan"].between(0, 10).all()
sub.to_csv(
    data_dir / "submission.csv", index=False,
    encoding="utf-8",
)
```

- Đúng số dòng, tên và thứ tự cột.
- Đúng ID và thứ tự mẫu.
- Không NaN, không vô cùng.
- Điểm trong 0–10.

Đọc lại tệp đã ghi

```
read_back = pd.read_csv(
    data_dir / "submission.csv",
    encoding="utf-8"
)
assert (
    read_back.columns.tolist()
    == sample.columns.tolist()
)
assert read_back["id"].equals(sample["id"])
assert np.isfinite(
    read_back["diem_toan"].to_numpy()
).all()
```

Đọc lại để kiểm chính file sẽ nộp, không chỉ bảng trong bộ nhớ.

Kết quả: **100 dòng × 2 cột**, đọc lại khớp mẫu.

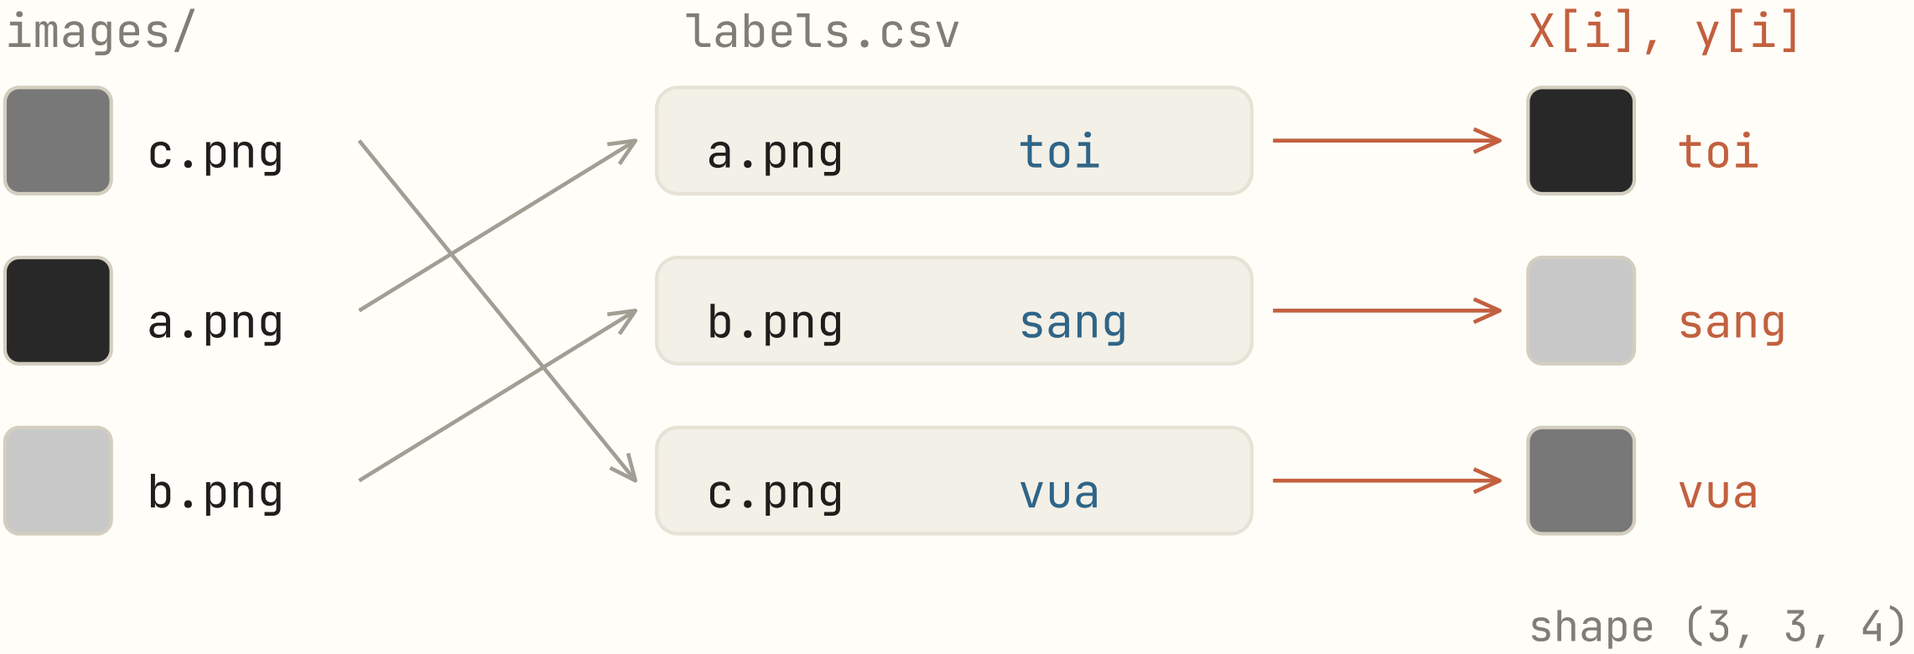
Ngày giờ, chuỗi, thư mục ảnh

- `pd.to_datetime(..., format=...)`: ghi rõ format, vì `03-02` có hai cách đọc.
- `.dt.hour`, `.dt.dayofweek`: lấy giờ, thứ của cả cột.
- `.str.strip().str.upper()`: chuẩn hóa mã trước khi ghép.

Đề ảnh cho một thư mục tệp kèm bảng nhãn.

Đọc ảnh **theo cột tên tệp của bảng nhãn**, để ảnh thứ i đi với nhãn thứ i.

Ảnh đi theo bảng nhãn



Đọc ảnh theo cột file của labels.csv: ảnh thứ i luôn đi với nhãn thứ i.

HỎI NHANH

Đọc ảnh bằng `sorted(Path("images").iterdir())` rồi ghép với cột `label` của `labels.csv` theo vị trí. Vì sao cách này nguy hiểm?

A `iterdir` chỉ đọc được tối đa 1000 tệp

B Ảnh đọc theo cách này luôn thành ảnh xám

C Thứ tự tên tệp sau khi sắp chưa chắc trùng thứ tự dòng trong `labels.csv`

D `sorted` làm đổi tên tệp trên đĩa

Khi đi thi

- `shape`, `dtypes`, `isna().sum()`, `describe()` cho cả train lẫn test.
- Ghép có `validate`, in shape trước và sau.
- File nộp từ `sample_submission`, `index=False`, đọc lại.

02

Luyện đề

LUYỆN ĐỀ 1

Bảng `df` có một cột tên `"diem toan"`, có dấu cách ở giữa. Ta chọn cột này thế nào?

A `df.diem toan`

B `df("diem toan")`

C `df.loc["diem toan"]`

D `df["diem toan"]`

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 110

LUYỆN ĐỀ 2

Cột giờ học trên train là `[1, 3, 5]`, trên test là `[2, NaN, 100]`. Ta điền ô thiếu bằng median của train. Ô `NaN` ở test được điền số mấy?

A 51

B 3

C 2

D 5

LUYỆN ĐỀ 3

`train` có 400 dòng. Ghép thêm thông tin lớp bằng `train.merge(info, on="lop", how="left")` thì thành 437 dòng. Nhiều khả năng là do đâu?

A Một số lớp xuất hiện nhiều lần trong `info`

B `how="left"` luôn thêm dòng cho khớp đủ hai bảng

C Có học sinh không khớp lớp nào nên sinh dòng `NaN`

D `merge` tạo thêm dòng khi sắp xếp lại theo khóa

Chốt ý

Điền ô trống bằng số tính trên train.

Ghép theo khóa có `validate`; đừng tin vị trí.

File nộp dựng từ `sample_submission`, rồi đọc lại.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook: thêm một dòng lặp vào `lop.csv`, xem `validate` bắt lỗi ra sao.