Bài toán học máy

Đặt ghế cho buổi sinh hoạt thứ Bảy

Chương 1 · Bài 1.1

Ta đang dự đoán điều gì?

Chiều thứ Sáu: biết số đăng ký và dự báo mưa.

Thứ Bảy: mới biết số người thật sự đến.

Mỗi hàng = một buổi.

Một dự đoán = một con số người.

Thông tin đầu vào phải có đúng lúc sử dụng.

Mục tiêu buổi này

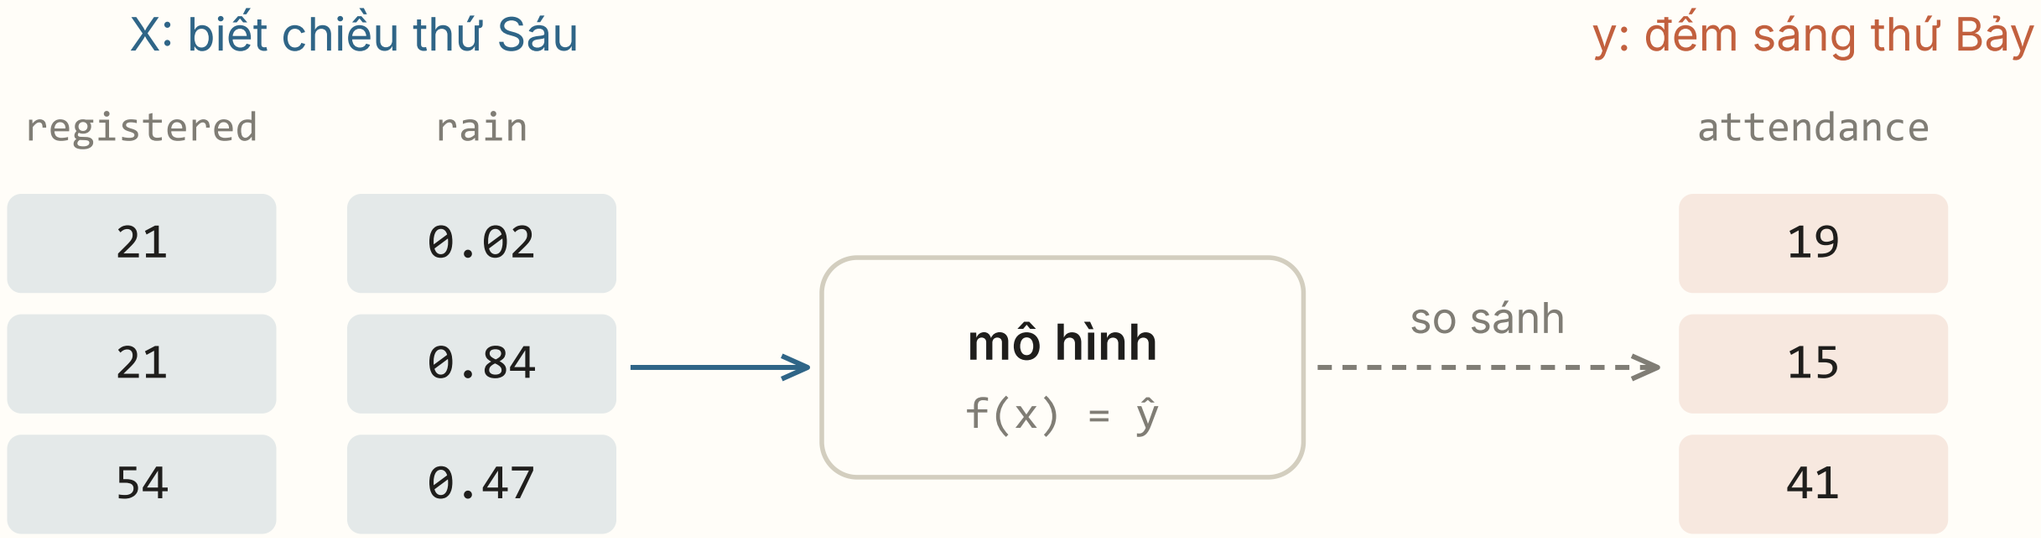
Viết hợp đồng: dự đoán số người đến từ dữ liệu chiều thứ Sáu.

Dựng baseline, đọc MAE theo đơn vị người và kiểm bảng theo ID.

01

Dữ liệu và đầu ra

Feature, target và ID



mỗi hàng là một buổi sinh hoạt

Từ thông tin chiều thứ Sáu, mô hình đoán số người đến; nhãn chỉ có sau buổi.

Ảnh cũng thành một hàng dữ liệu



X: 64 cột, mỗi cột là một điểm ảnh y

ảnh 1: lưới 8 × 8 trải theo từng hàng thành 64 số, nhãn 3



X: 64 cột, mỗi cột là một điểm ảnh y

ảnh 1: lưới 8 × 8 trải theo từng hàng thành 64 số, nhãn 3



X: 64 cột, mỗi cột là một điểm ảnh y

ảnh 3: lưới 8 × 8 trải theo từng hàng thành 64 số, nhãn 0



X: 64 cột, mỗi cột là một điểm ảnh y

4 ảnh thành bảng X shape (4, 64) và vector nhãn y shape (4,)

Ảnh chữ số viết tay thật 8 × 8 trải thành một hàng 64 số: mỗi ảnh là một hàng của X, chữ số đúng là giá trị y.

Kiểu đầu ra của bài toán

Classification

có

không

≥ 30 người?

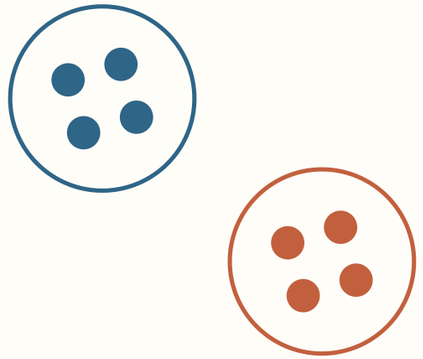
Regression

28.4

một số thực

bao nhiêu người?

Clustering



không có nhãn

Loại bài toán do đầu ra quyết định: một nhãn, một số, hay chưa có nhãn.

Classification hay regression?

Có ít nhất 30 người không?

Classification: một nhãn.

Có bao nhiêu người?

Regression: một giá trị số.

Mã lớp bằng số không tự biến classification thành regression.

HỎI NHANH

Input là ảnh chụp một bài giải. Output là một trong ba nhãn “đúng”, “sai”, “chưa đủ bước”. Đây là loại bài toán nào?

A Regression, vì nhãn mã hóa được thành 0, 1, 2

B Classification có giám sát, với ba lớp

C Clustering, vì cần chia bài giải thành ba nhóm

D Classification nhị phân, đúng hoặc không đúng

HỎI NHANH

Câu lạc bộ muốn chạy mô hình vào chiều thứ Sáu để đoán số người đến buổi sáng thứ Bảy. Cột nào **không** được dùng làm feature?

A Số người đăng ký tính đến chiều thứ Sáu

B Số buổi câu lạc bộ đã tổ chức từ đầu học kỳ

C Dự báo mưa lưu lúc chiều thứ Sáu

D Số người quét mã vào cửa sáng thứ Bảy

Shape trước model

```
X = data[["registered", "rain_forecast"]]
y = data["attendance"]
print(X.shape, y.shape)
print(data.head(3).round(2).to_string(index=False))
```

KẾT QUẢ

```
(120, 2) (120,)
 session_id  registered  rain_forecast  attendance
          0          21           0.02        19.0
          1          21           0.84        15.0
          2          54           0.47        41.0
```

X có 120 hàng và 2 feature. y có 120 phần tử. Mỗi hàng là một buổi.

HỎI NHANH

`session_id` chạy từ 0 đến 119 theo thứ tự thời gian. Vì sao không đưa cột này vào X?

A ID chỉ là mã để ghép, buổi mới có ID chưa từng thấy

B Không sao, mô hình tự bỏ qua cột vô dụng

C Nên đưa vào, miễn là chuẩn hóa trước

D Phải đưa vào để giữ đúng thứ tự các buổi

02

Học, chọn và chấm

Ba phần, ba công việc



Chia theo thứ tự buổi: học trên quá khứ, chọn và chấm trên các buổi sau.

HỎI NHANH

Có hai mô hình, ta cần chọn một. Ta so điểm của chúng trên tập nào?

A Validation

B Train, vì mô hình đã học trên đó

C Test, tập đã giữ riêng từ đầu

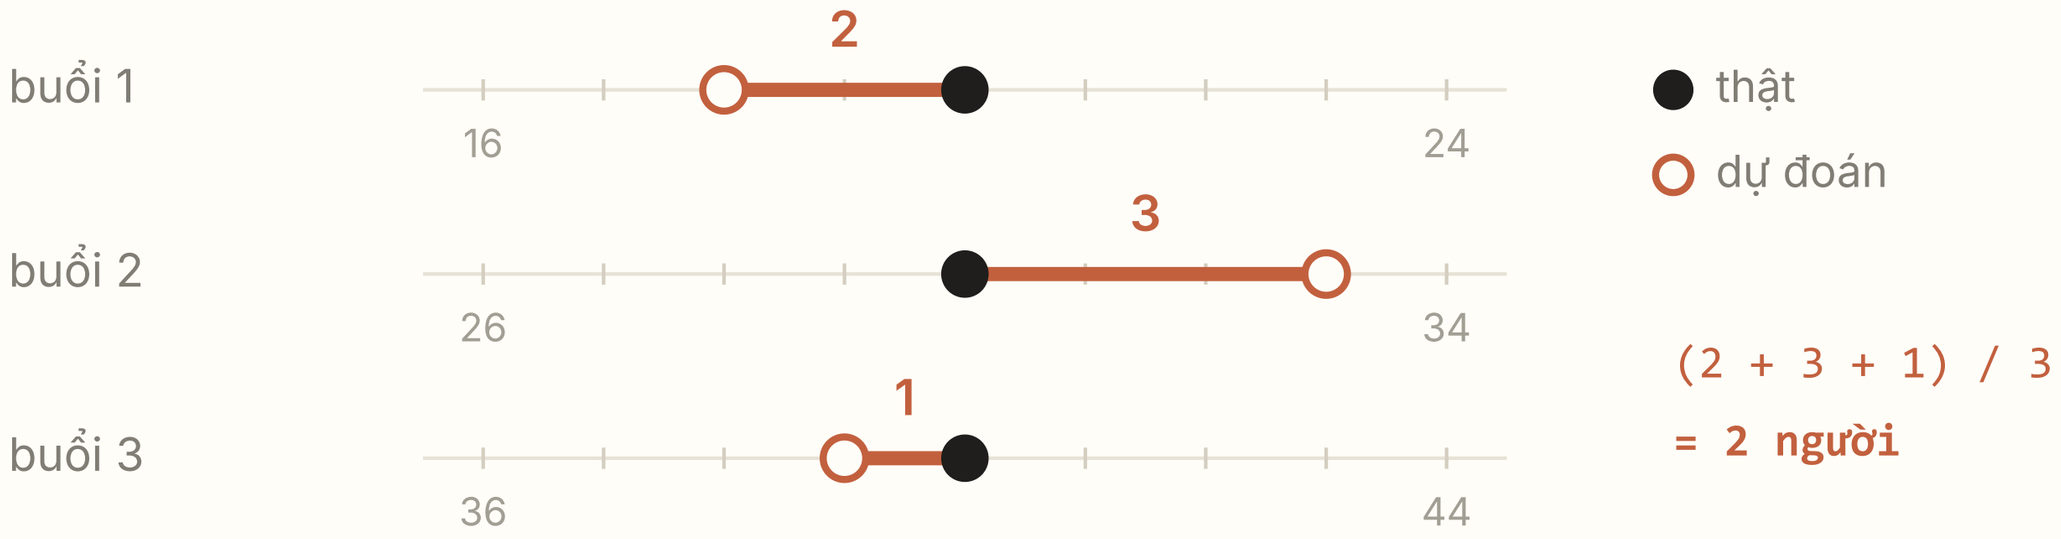
D Gộp train và test lại

MAE có đơn vị người

Với m buổi đang chấm, MAE có đơn vị người.

Càng nhỏ càng tốt. Giá trị này không nói mọi buổi đều sai bằng nhau.

Ví dụ tính tay



MAE là trung bình độ dài các đoạn sai số, tính theo đơn vị người.

Sai cao và sai thấp không triệt tiêu nhau.

Baseline hằng số và linear

```
for name, model in models.items():
    model.fit(X_train, y_train)
    prediction = model.predict(X_valid)
    assert prediction.shape == y_valid.shape
    mae = mean_absolute_error(y_valid, prediction)
    valid_mae[name] = mae
    print(name, f"valid MAE = {mae:.3f}")
chosen_name = min(valid_mae, key=valid_mae.get)
print("Chọn bằng validation:", chosen_name)
```

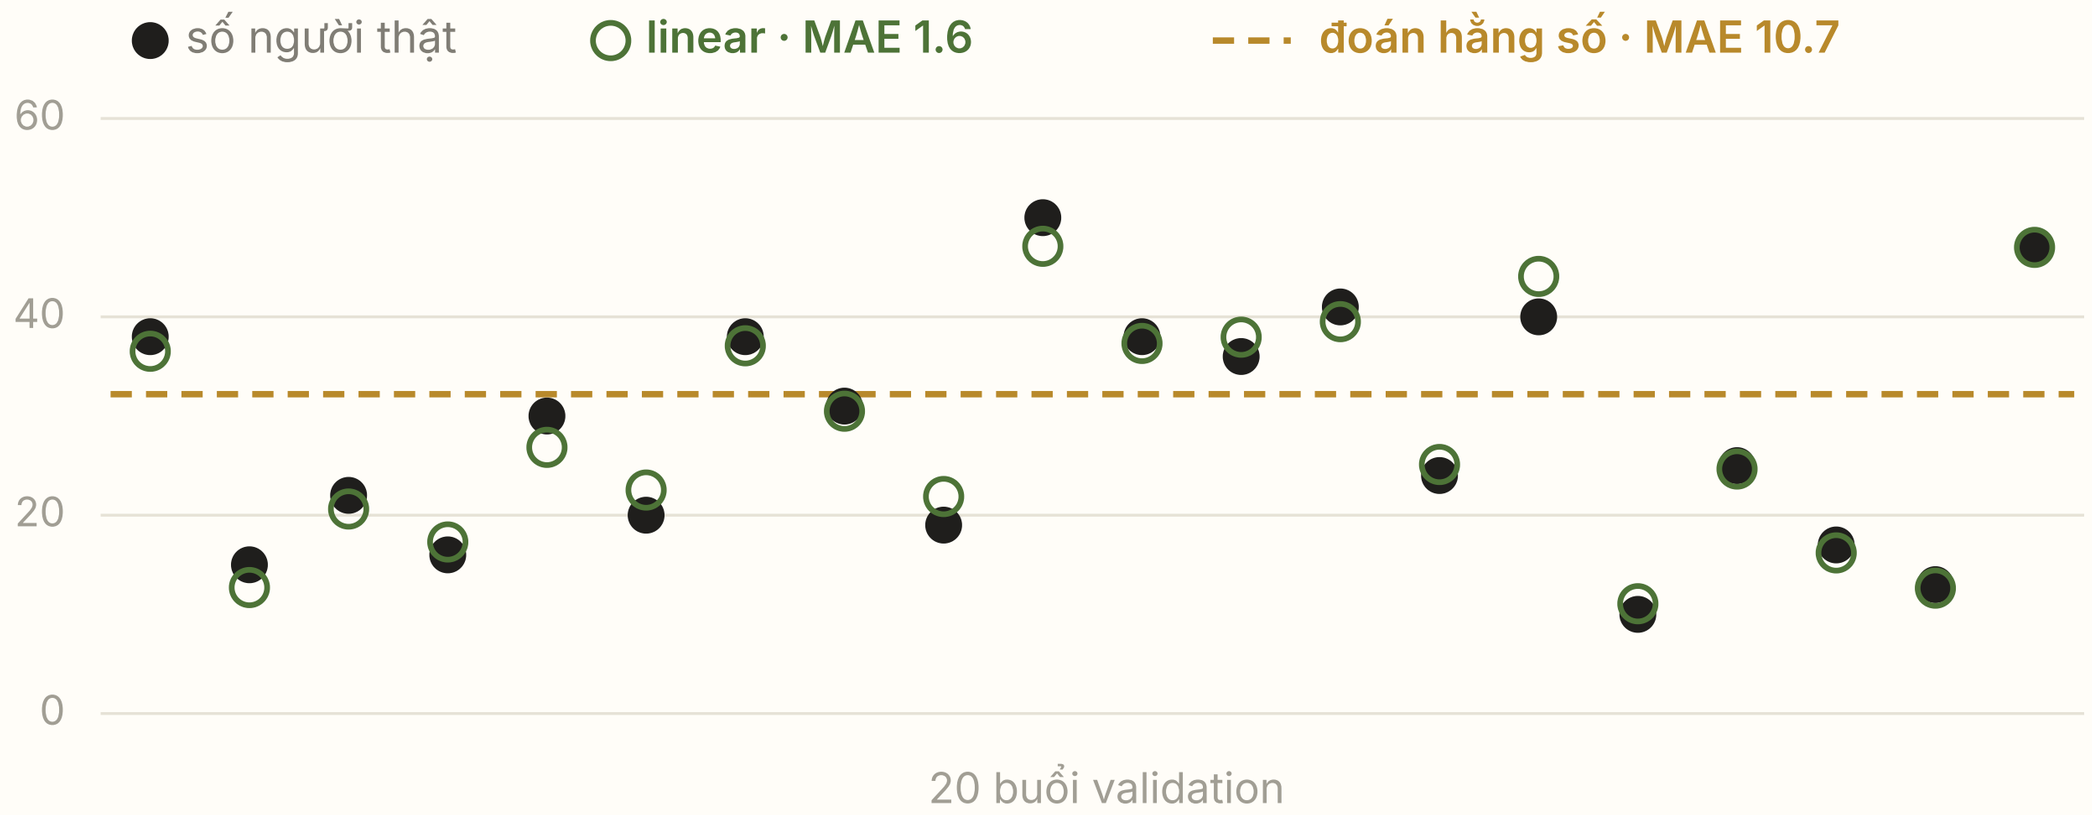
`models` gồm `DummyRegressor(strategy="mean")` và `LinearRegression`; `valid_mae` ban đầu là dict trống. Hai model dùng cùng train/validation.

KẾT QUẢ

```
mean valid MAE = 10.740
linear valid MAE = 1.561
Chọn bằng validation: linear
```

Hằng số sai gần 11 người, linear khoảng 1.6 người trên cùng 20 buổi.

Nhìn từng buổi validation



Trên 20 buổi validation: đường hằng số lệch xa, linear bám sát số người thật.

HỎI NHANH

Trên cùng 20 buổi validation, một mô hình mới có MAE 11.5 người, còn baseline đoán hằng số có MAE 10.74. Ta nên làm gì tiếp?

A Giữ mô hình mới, vì nó dùng nhiều thông tin hơn

B Bỏ baseline đi, vì đoán hằng số không phải mô hình

C Tìm lỗi trong dữ liệu hoặc trong cách tính điểm

D Tính thêm điểm trên test để có thêm ý kiến

Chốt rồi chấm

```
final_model = models[chosen_name]
final_model.fit(X.iloc[:100], y.iloc[:100])
test_prediction = final_model.predict(X_test)
print(f"Test MAE = {mean_absolute_error(y_test, test_prediction):.3f}")
```

KẾT QUẢ

```
Test MAE = 1.317
```

Fit lại trên train và validation. Test MAE là 1.317 người.

Sau khi xem test, không chỉnh rồi gọi cùng điểm là độc lập.

03

Bảng dự đoán

Kiểm bảng CSV

Một hàng cho mỗi ID.

Đúng tên cột, đúng thứ tự, số hữu hạn.

Dùng `index=False`.

KẾT QUẢ

```
 session_id  attendance
        100       16.19
        101       26.21
        102       42.31
Số hàng: 20
```

HỎI NHANH

Một bạn sắp xếp cột dự đoán từ nhỏ đến lớn nhưng để nguyên cột ID. File nộp còn đúng không?

A Đúng, vì số hàng và số cột vẫn khớp với đề

B Đúng, vì MAE không phụ thuộc thứ tự hàng

C Sai, vì phải sắp theo ID tăng dần

D Sai, vì dự đoán đã bị ghép nhầm sang mẫu khác

Khi đi thi

- Viết hợp đồng: mẫu, nhãn, metric, output, ID, thời điểm.
- Nộp baseline sớm để kiểm đường đi tới file nộp.
- Gọi metric của đề tường minh.
- Quy định môi trường đọc từ thông báo cuộc thi.

04

Luyện đề

LUYỆN ĐỀ 1

Bảng chỉ có feature của từng buổi, không có cột nhãn. Ta muốn gom các buổi giống nhau thành từng nhóm. Đây là loại bài toán nào?

A Học không giám sát, chẳng hạn clustering

B Học có giám sát, vì feature đã là số

C Classification có giám sát

D Regression có giám sát

PHỎNG THEO USA-NA-AIO 2026 · Vòng 1 · Part 1.1

LUYỆN ĐỀ 2

Một mô hình được huấn luyện và kiểm trên dữ liệu năm 2023: đúng 99.8% trên train, 92% trên validation. Đem dùng cho dữ liệu năm 2025 thì chỉ còn đúng 64%. Vấn đề chính nằm ở đâu?

A Validation cùng năm với train nên con số 92% là ảo

B Dữ liệu năm 2025 bị gán nhãn sai nên điểm thấp giả tạo

C Dữ liệu năm 2025 đã khác dữ liệu năm 2023

D Mô hình quá yếu, dù đúng tới 99.8% trên train

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 286

Chốt ý

Train học tham số. Validation chọn phương án. Test báo cáo sau khi đã chốt.

Kiểm tra cuối bài có 10 câu, gồm cả shape, metric và định dạng output.