Generalization

Đúng trên dữ liệu đã nhớ có đủ không?

Buổi tuần sau là một mẫu mới

Lưu nguyên các buổi cũ rồi tra bảng: lỗi train bằng 0.

Nhưng buổi tuần sau chưa có trong bảng.

Cần: đoán tốt cả buổi chưa thấy. Gọi là **tổng quát hóa** (generalization).

Đo bằng validation, chia giống lúc dùng thật.

Mục tiêu

- Phân biệt lỗi trên train với lỗi trên dữ liệu mới.
- Nhận ra underfitting và overfitting.
- Đọc learning curve.
- Chọn việc làm tiếp dựa trên các dấu hiệu đó.

01

Độ linh hoạt và nhiễu

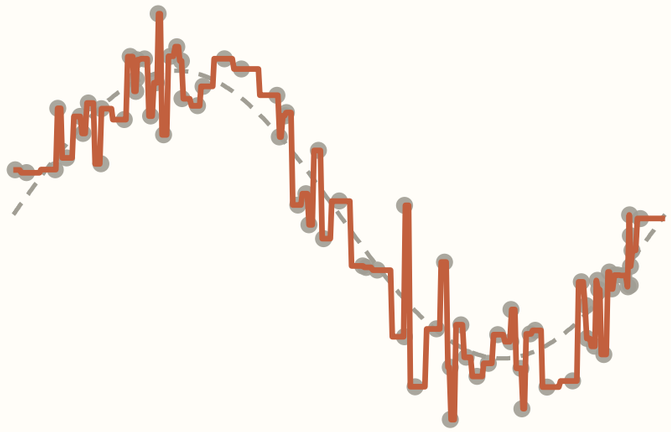
Một cơ chế sinh biết trước

x được tự sinh đều trong $[0,1]$. Nhiễu ε có kỳ vọng 0 và độ lệch chuẩn 0.25.

Dữ liệu tự sinh nên biết đâu là quy luật, đâu là nhiễu.

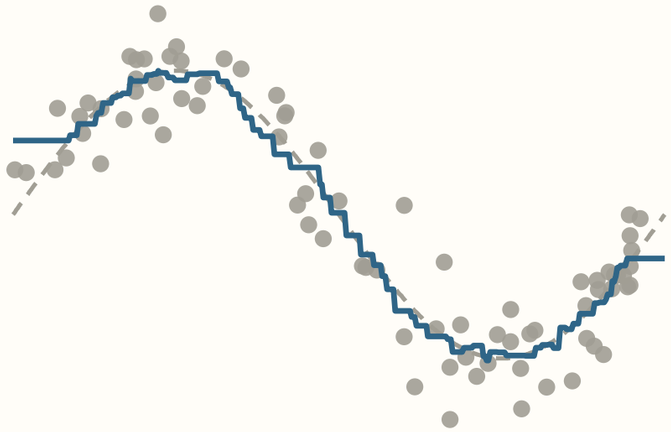
Ba đường cùng train

k = 1



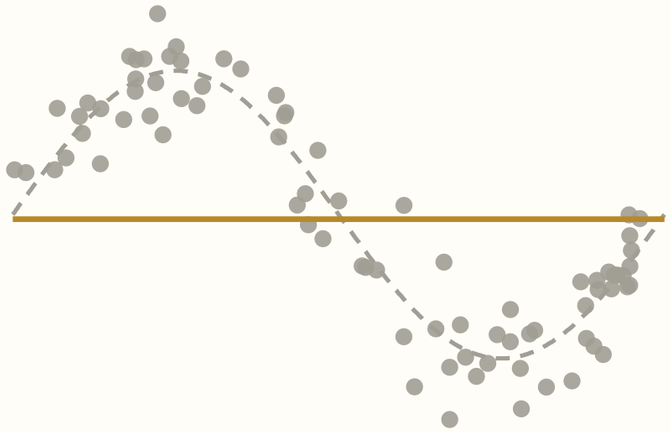
valid MSE 0.101

k = 10



valid MSE 0.082

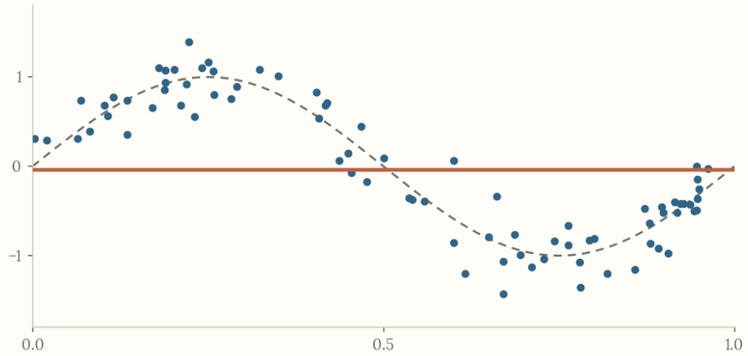
k = 80



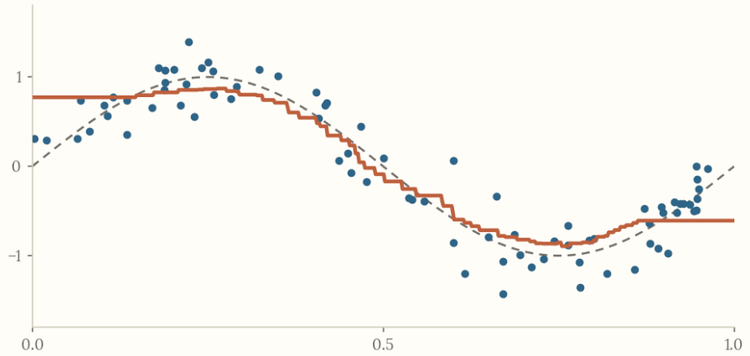
valid MSE 0.565

k = 1 bám nhiễu, k = 80 san phẳng, k = 10 vừa đủ.

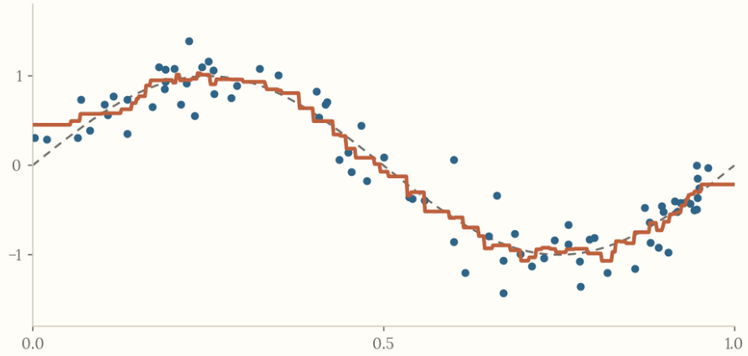
Giảm dần k



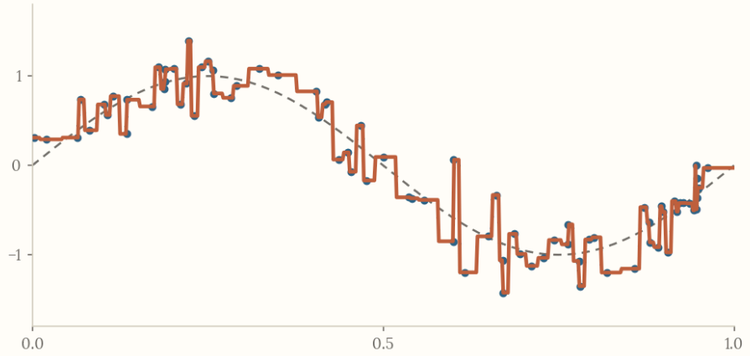
k = 80: train MSE 0.5861, validation MSE 0.5654



k = 25: train MSE 0.0841, validation MSE 0.1360



k = 6: train MSE 0.0529, validation MSE 0.0771



k = 1: train MSE 0.0000, validation MSE 0.1011

kNN hồi quy trên 80 điểm train của bài khi giảm k từ 80 về 1: đường cam đi từ quá phẳng tới bám từng điểm nhiễu; nét đứt là quy luật thật.

HỎI NHANH

Mô hình đoán đúng mọi nhãn trên tập train. Điều đó chứng minh được gì?

A Nó khớp các mẫu đã học, còn mẫu mới thì chưa biết

B Nó chắc chắn đã tìm ra quy luật thật

C Dữ liệu train chắc chắn không có nhãn nhiễu

D Nó sẽ đúng ít nhất 90% trên dữ liệu mới

kNN ở mức cần dùng hôm nay

Tìm k điểm train gần nhất.

Lấy trung bình nhãn.

`k` nhỏ dùng ít hàng xóm nên đường linh hoạt hơn.

`k` lớn lấy trung bình trên vùng rộng hơn nên đường trơn hơn.

`k = 1` tại một điểm train trả đúng nhãn của chính điểm đó, kể cả nhiễu.

Đọc hai cột lỗi

```
print(X_train.shape, y_train.shape)
for k in [80, 10, 1]:
    model = KNeighborsRegressor(n_neighbors=k).fit(X_train, y_train)
    train_mse = mean_squared_error(y_train, model.predict(X_train))
    valid_mse = mean_squared_error(y_valid, model.predict(X_valid))
    print(f"k={k:2d}: train={train_mse:.4f}, valid={valid_mse:.4f}")
```

KẾT QUẢ

```
(80, 1) (80,)
k=80: train=0.5861, valid=0.5654
k=10: train=0.0574, valid=0.0820
k= 1: train=0.0000, valid=0.1011
```

`k=1`: train bằng 0. `k=10`: validation thấp nhất.

HỎI NHANH

Phương án A có MSE 0.01 trên train, 0.30 trên validation. Phương án B có MSE 0.08 trên train, 0.12 trên validation. Chọn theo validation thì chọn phương án nào?

A A, vì MSE trên train nhỏ hơn

B A, vì chênh lệch lớn cho thấy nó học nhiều hơn

C B, vì MSE trên validation nhỏ hơn

D Chưa chọn được, phải xem điểm test của cả hai

Underfit và overfit

Underfit: model quá đơn giản.

Train và validation cùng lỗi cao.

Chữa: model mạnh hơn, đặc trưng tốt hơn.

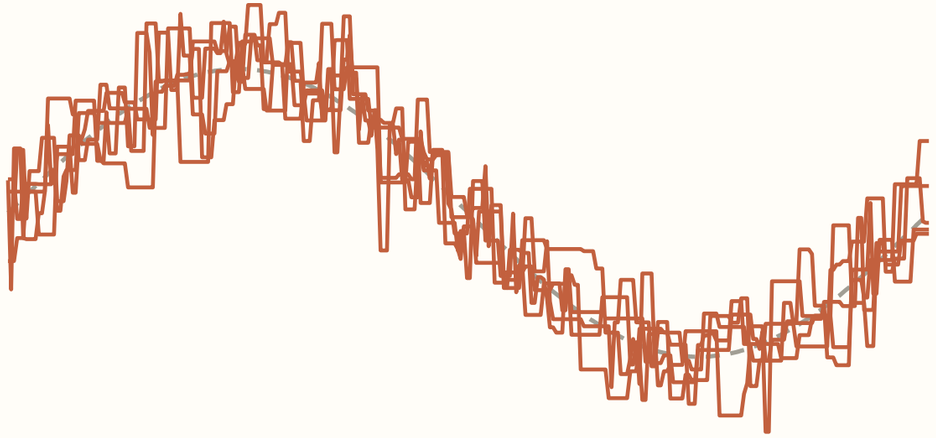
Overfit: model học thuộc cả nhiễu.

Train lỗi thấp, validation cao hơn hẳn.

Chữa: giảm độ linh hoạt, regularization, thêm dữ liệu.

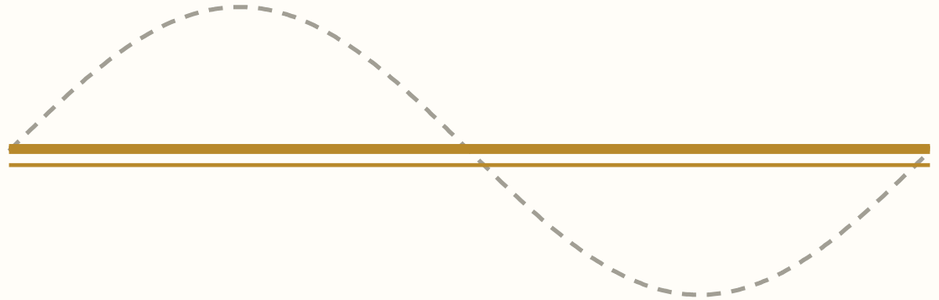
Đổi bộ train, mô hình đổi bao nhiêu?

k = 1



variance cao: mỗi bộ train một đường

k = 80



bias cao: sai giống nhau mọi lần

Năm bộ train: k = 1 đổi theo từng bộ, k = 80 lần nào cũng sai như nhau.

HỎI NHANH

Mô hình phân loại review phim có 2.4 triệu tham số, học trên 5000 review. Nó đúng 98.5% trên train, 72.3% trên validation, 71.8% trên test. Vấn đề là gì?

A Lộ dữ liệu, vì validation gần bằng test

B Underfitting, vì 72% là thấp

C Overfitting, vì train vượt xa validation

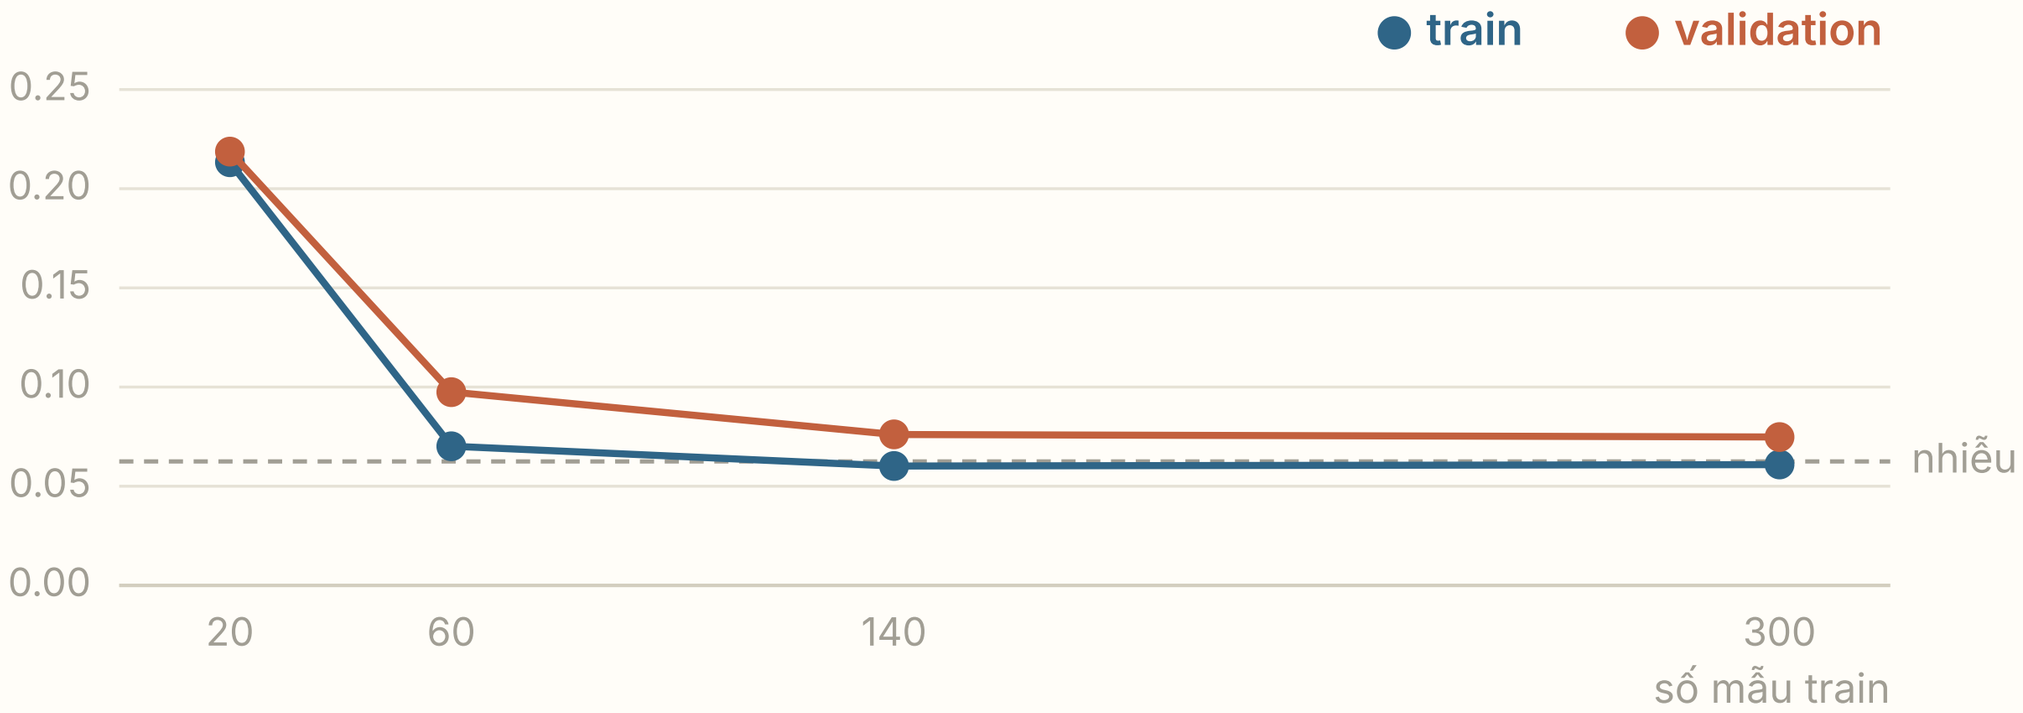
D Dữ liệu thay đổi, vì test thấp

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 272

02

Thêm dữ liệu có ích không?

Learning curve



Thêm mẫu, hai đường lỗi gần nhau và sát mức nhiễu.

Đọc learning curve

KẾT QUẢ

```
n= 20: train MSE=0.2133, valid MSE=0.2187
n= 60: train MSE=0.0701, valid MSE=0.0974
n=140: train MSE=0.0602, valid MSE=0.0761
n=300: train MSE=0.0610, valid MSE=0.0748
```

Validation giảm từ 0.2187 xuống 0.0748.

Tăng mẫu giúp vùng hàng xóm hẹp hơn.

Từ 140 mẫu trở đi gần như không giảm nữa.

Hai đường sát nhau, cùng cao: underfit. Cách xa: overfit hoặc còn thiếu dữ liệu.

Đừng nhầm hai trục ngang

Learning curve: số mẫu train.

Đường tối ưu: epoch / số bước.

Mỗi đường trả lời một câu hỏi.

HỎI NHANH

Tăng train từ 200 lên 800 rồi 2000 mẫu. MSE trên train là 0.42, 0.43, 0.43. MSE trên validation là 0.46, 0.45, 0.45. Ta nên thử gì trước?

A Giữ nguyên mọi thứ, chỉ thu thêm mẫu

B Thêm feature hoặc dùng mô hình mạnh hơn

C Giảm độ phức tạp để thu hẹp khoảng cách

D Đổi seed chia dữ liệu tới khi validation thấp hơn

PHỎNG THEO CMU 10-601 · Practice Problems, Exam 1 · Q3.1

Phần nhiễu còn lại

Kể cả biết đúng quy luật, lỗi vẫn còn 0.0625: không model nào đoán được nhiễu.

Validation 0.0748 đã gần mốc này.

03

Generalization cho ai?

HỎI NHANH

Ta cần dự báo cho tháng sau. Chia dữ liệu ngẫu nhiên thì MAE là 2. Giữ riêng tháng cuối làm validation thì MAE là 5. Nên tin con số nào?

A Bỏ tháng cuối khỏi dữ liệu cho phép đánh giá ổn hơn

B Tin số 2, vì MAE thấp hơn là tốt hơn

C Lấy trung bình 3.5 làm MAE cuối cùng

D Tin số 5, rồi tìm hiểu vì sao tháng cuối khó hơn

Trở lại câu lạc bộ

Dịp hè khác năm học: đăng ký, lịch học đều đổi (distribution shift).

Model chỉ đáng tin trong vùng dữ liệu đã học.

Đoán buổi sau của cùng trường khác đoán cho trường mới.

Chia validation theo đúng trường hợp sẽ dùng (bài 1.3).

Khi đi thi

- Ghi cả lỗi train lẫn validation.
- Train tốt, validation kém: giảm linh hoạt. Cả hai kém: model mạnh hơn.
- Chia validation giống lúc dùng thật.

04

Luyện đề

LUYỆN ĐỀ 1

Khi tăng độ phức tạp của mô hình, chẳng hạn tăng bậc đa thức, bias và variance thường thay đổi thế nào?

A Cả hai cùng tăng

B Cả hai cùng giảm

C Cả hai không đổi

D Bias giảm, variance tăng

E Bias tăng, variance giảm

ĐỀ THI USA-NA-AIO 2026 · Vòng 1 · Part 1.3

LUYỆN ĐỀ 2

Bài phân loại 10 lớp, 5000 mẫu. Tỉ lệ đúng trên train và validation: A rất đơn giản, 68% và 67%. B rất lớn, 99% và 71%. C vừa phải, có regularization, 85% và 83%. Chẩn đoán nào đúng?

A A underfit, B overfit, C cân bằng

B A ổn, B bias cao, C variance cao

C A variance cao, B ổn, C bias cao

D Cả ba do dữ liệu bẩn, cần làm sạch

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 277

Chốt ý

Xem cả lỗi train lẫn lỗi validation trước khi chẩn đoán.

Validation phải chia giống lúc dùng thật.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook: đổi độ lệch chuẩn của nhiễu, xem tốt nhất dịch đi đâu.