Generalization

Đúng trên dữ liệu đã nhớ có đủ không?

Buổi tuần sau là một mẫu mới

Lưu nguyên nhãn cũ có thể cho lỗi train bằng 0.

Mục tiêu: dự đoán tốt ở buổi chưa thấy.

Cần validation mô phỏng đúng tình huống mới.

01

Độ linh hoạt và nhiễu

Một cơ chế sinh biết trước

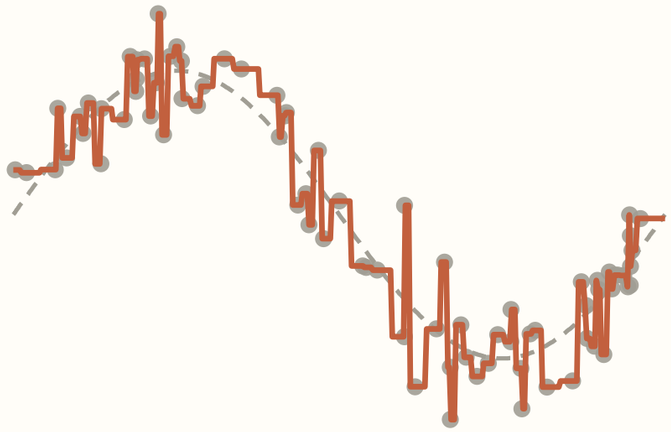
$$y = \sin(2\pi x) + \varepsilon.$$

x được tự sinh đều trong `[0,1]`. Nhiễu ε có kỳ vọng 0 và độ lệch chuẩn 0.25.

Dữ liệu tự sinh nên biết đâu là quy luật, đâu là nhiễu.

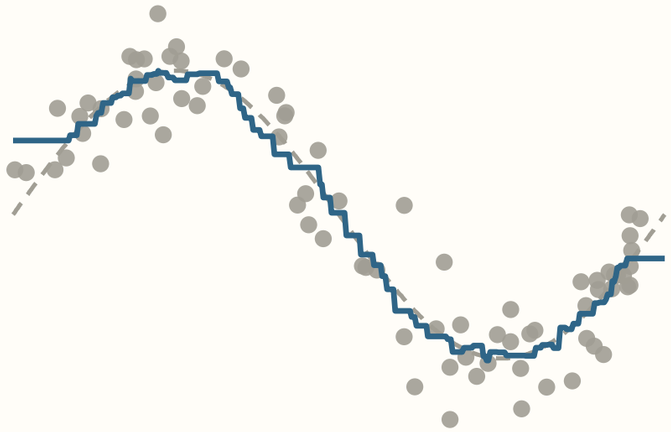
Ba đường cùng train

k = 1



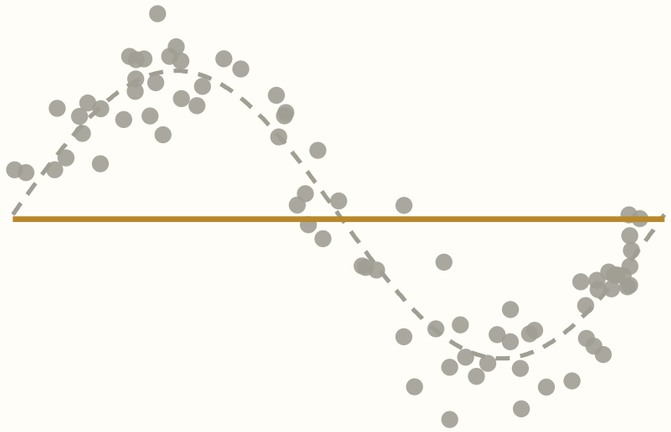
valid MSE 0.101

k = 10



valid MSE 0.082

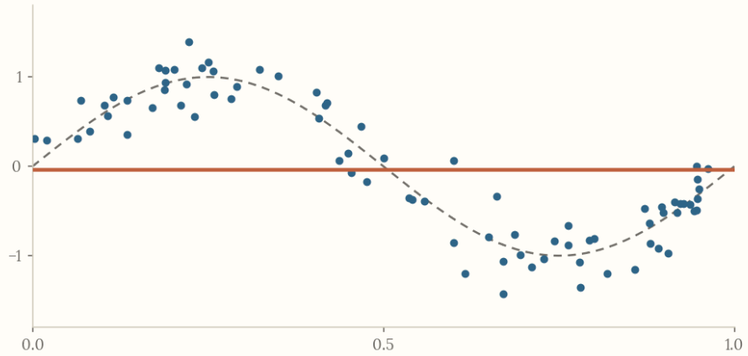
k = 80



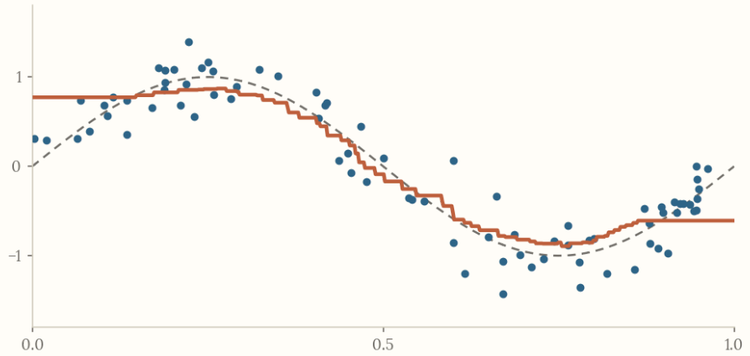
valid MSE 0.565

k = 1 bám nhiễu, k = 80 san phẳng, k = 10 vừa đủ.

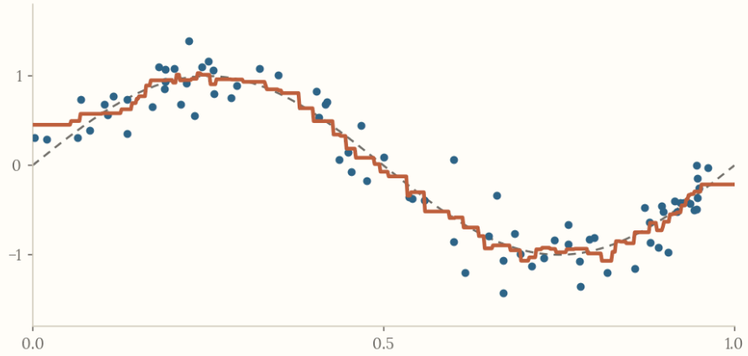
Giảm dần k



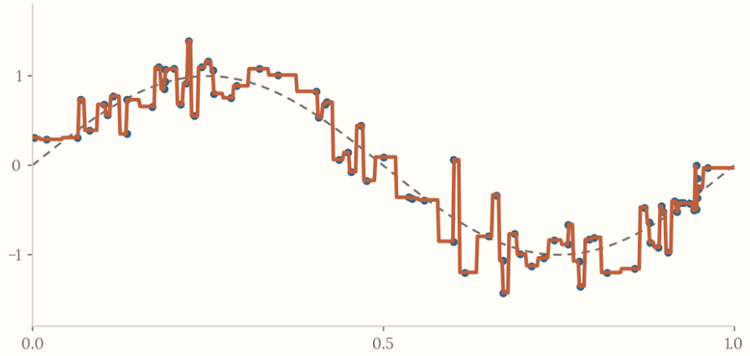
k = 80: train MSE 0.5861, validation MSE 0.5654



k = 25: train MSE 0.0841, validation MSE 0.1360



k = 6: train MSE 0.0529, validation MSE 0.0771



k = 1: train MSE 0.0000, validation MSE 0.1011

kNN hồi quy trên 80 điểm train của bài khi giảm k từ 80 về 1: đường cam đi từ quá phẳng tới bám từng điểm nhiễu; nét đứt là quy luật thật.

HỎI NHANH

Mô hình đoán đúng mọi nhãn trên tập train. Điều đó chứng minh được gì?

A Nó khớp các mẫu đã học, còn mẫu mới thì chưa biết

B Nó chắc chắn đã tìm ra quy luật thật

C Dữ liệu train chắc chắn không có nhãn nhiễu

D Nó sẽ đúng ít nhất 90% trên dữ liệu mới

kNN ở mức cần dùng hôm nay

Tìm k điểm train gần nhất.

Lấy trung bình nhãn.

k nhỏ dùng ít hàng xóm nên đường linh hoạt hơn.

k lớn lấy trung bình trên vùng rộng hơn nên đường trơn hơn.

Trong dữ liệu của bài, các giá trị x khác nhau; tại điểm train, k=1 trả đúng nhãn kể cả nhiễu.

Đọc hai cột lỗi

```
print(X_train.shape, y_train.shape)
for k in [80, 10, 1]:
    model = KNeighborsRegressor(n_neighbors=k).fit(X_train, y_train)
    train_mse = mean_squared_error(y_train, model.predict(X_train))
    valid_mse = mean_squared_error(y_valid, model.predict(X_valid))
    print(f"k={k:2d}: train={train_mse:.4f}, valid={valid_mse:.4f}")
```

KẾT QUẢ

```
(80, 1) (80,)
k=80: train=0.5861, valid=0.5654
k=10: train=0.0574, valid=0.0820
k= 1: train=0.0000, valid=0.1011
```

k=1 có train MSE bằng 0. k=10 có validation MSE thấp nhất trong ba lựa chọn.

HỎI NHANH

Phương án A có MSE 0.01 trên train, 0.30 trên validation. Phương án B có MSE 0.08 trên train, 0.12 trên validation. Chọn theo validation thì chọn phương án nào?

A A, vì MSE trên train nhỏ hơn

B A, vì chênh lệch lớn cho thấy nó học nhiều hơn

C B, vì MSE trên validation nhỏ hơn

D Chưa chọn được, phải xem điểm test của cả hai

Underfit và overfit

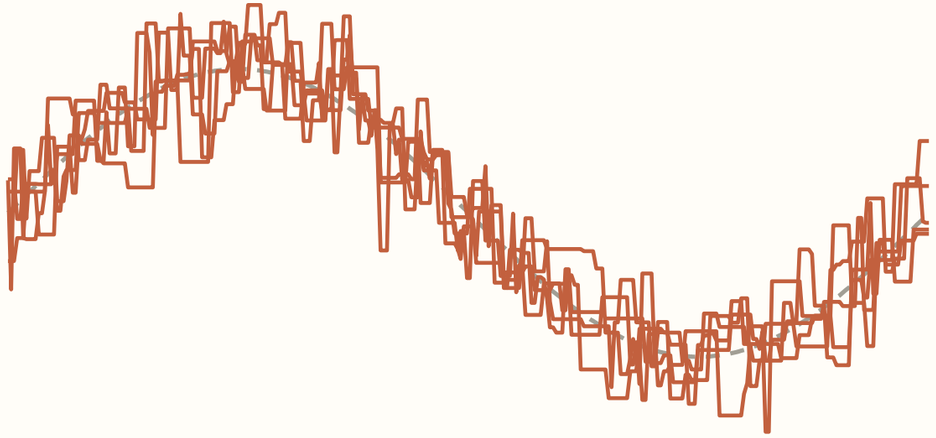
Underfit: thiếu khả năng biểu diễn hoặc học chưa đạt.

Overfit: chi tiết train không ổn định trên mẫu mới.

Kiểm split, metric và dữ liệu trước khi đổi model.

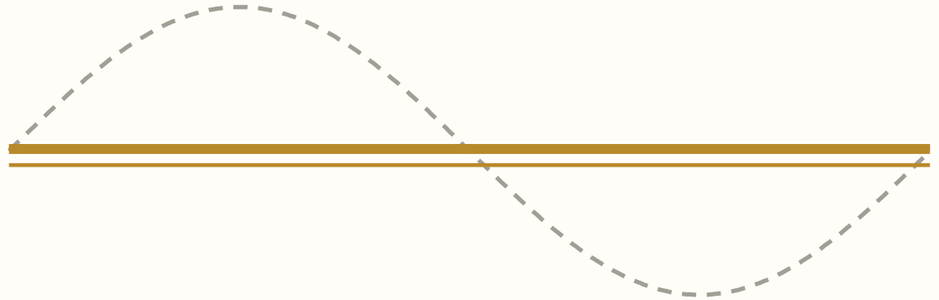
Đổi bộ train, mô hình đổi bao nhiêu?

k = 1



variance cao: mỗi bộ train một đường

k = 80



bias cao: sai giống nhau mọi lần

Năm bộ train: k = 1 đổi theo từng bộ, k = 80 lần nào cũng sai như nhau.

HỎI NHANH

Mô hình phân loại review phim có 2.4 triệu tham số, học trên 5000 review. Nó đúng 98.5% trên train, 72.3% trên validation, 71.8% trên test. Vấn đề là gì?

A Lộ dữ liệu, vì validation gần bằng test

B Underfitting, vì 72% là thấp

C Overfitting, vì train vượt xa validation

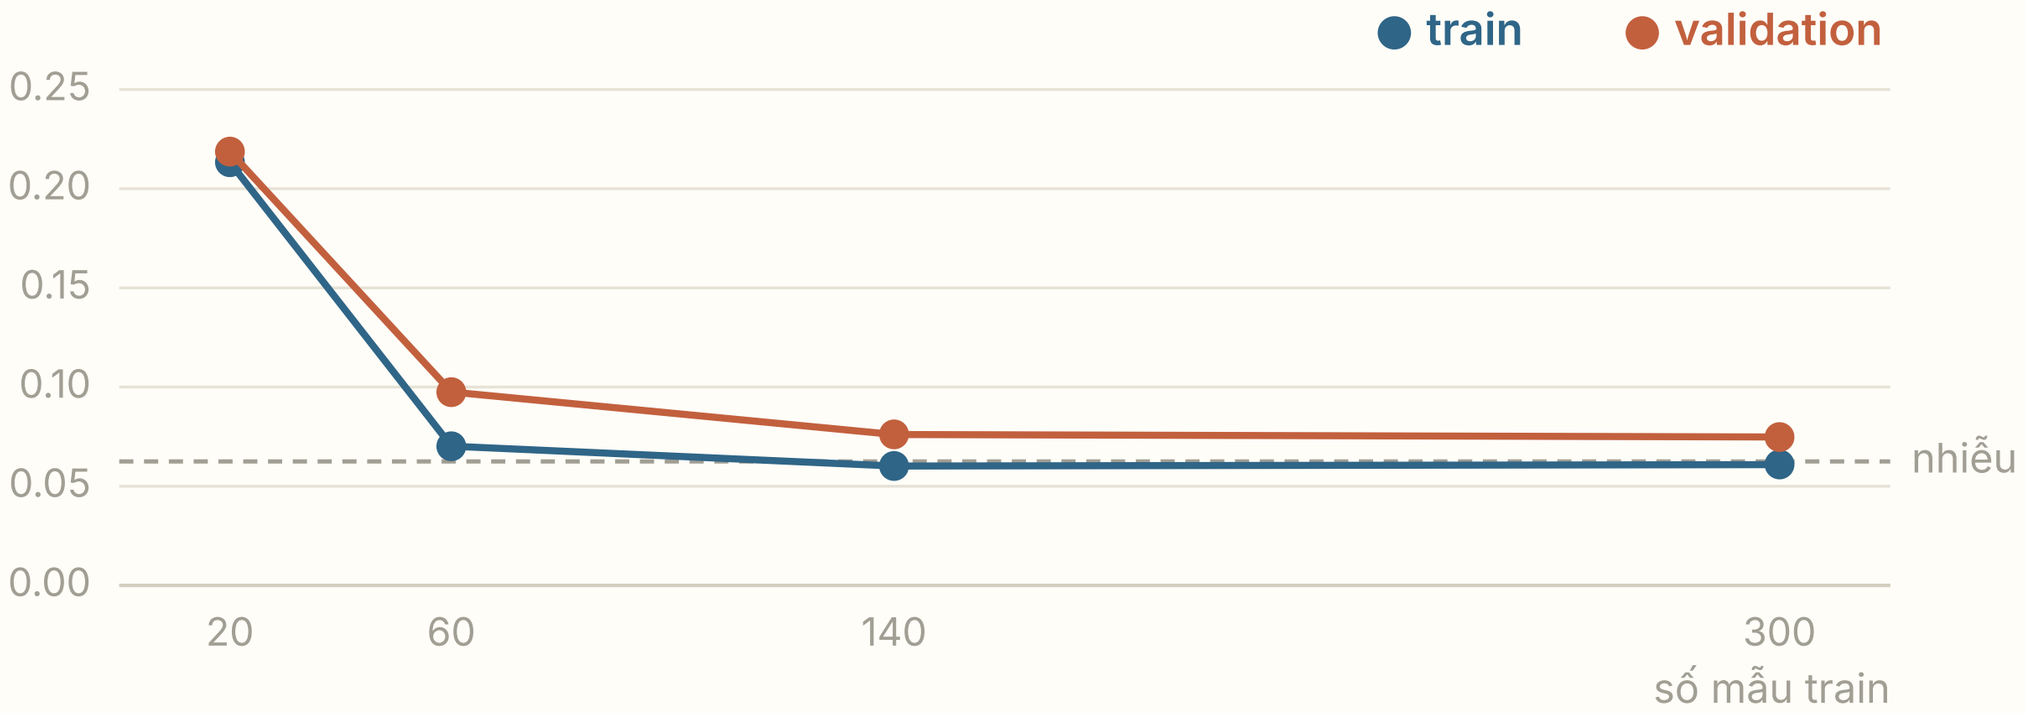
D Dữ liệu thay đổi, vì test thấp

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 272

02

Thêm dữ liệu có ích không?

Learning curve



Thêm mẫu, hai đường lỗi gần nhau và sát mức nhiễu.

Đọc learning curve

KẾT QUẢ

```
n= 20: train MSE=0.2133, valid MSE=0.2187
n= 60: train MSE=0.0701, valid MSE=0.0974
n=140: train MSE=0.0602, valid MSE=0.0761
n=300: train MSE=0.0610, valid MSE=0.0748
```

Validation giảm từ 0.2187 xuống 0.0748.

Tăng mẫu giúp vùng hàng xóm hẹp hơn.

Sau đó cải thiện chậm dần.

Đừng nhầm hai trục ngang

Learning curve: số mẫu train.

Đường tối ưu: epoch / số bước.

Mỗi đường trả lời một câu hỏi.

HỎI NHANH

Tăng train từ 200 lên 800 rồi 2000 mẫu. MSE trên train là 0.42, 0.43, 0.43. MSE trên validation là 0.46, 0.45, 0.45. Ta nên thử gì trước?

A Giữ nguyên mọi thứ, chỉ thu thêm mẫu

B Thêm feature hoặc dùng mô hình mạnh hơn

C Giảm độ phức tạp để thu hẹp khoảng cách

D Đổi seed chia dữ liệu tới khi validation thấp hơn

PHỎNG THEO CMU 10-601 · Practice Problems, Exam 1 · Q3.1

Ví dụ tính tay

k=2. Hai nhãn hàng xóm là 1 và 3 nên dự đoán bằng 2.

Nếu nhãn thật là 4 thì lỗi bình phương tại điểm đó là $(2-4)^2 = 4$.

Thật (1,3,5), đoán (2,3,4):

MSE = (1+0+1)/3 = 2/3.

Phần nhiễu còn lại

$$\mathbb{E}[\varepsilon^2] = 0.25^2 = 0.0625.$$

Đây là mức nhiễu kỳ vọng của cơ chế giả lập khi ε có kỳ vọng 0.

Validation hữu hạn có thể nằm thấp hơn do ngẫu nhiên.

03

Generalization cho ai?

HỎI NHANH

Ta cần dự báo cho tháng sau. Chia dữ liệu ngẫu nhiên thì MAE là 2. Giữ riêng tháng cuối làm validation thì MAE là 5. Nên tin con số nào?

A Bỏ tháng cuối khỏi dữ liệu cho phép đánh giá ổn hơn

B Tin số 2, vì MAE thấp hơn là tốt hơn

C Lấy trung bình 3.5 làm MAE cuối cùng

D Tin số 5, rồi tìm hiểu vì sao tháng cuối khó hơn

Trở lại câu lạc bộ

Tuần tương lai có thể khác mùa, lịch học hoặc quy mô.

Trường mới khác với buổi mới ở cùng trường.

Split phải mô phỏng nhiệm vụ, không chọn theo điểm đẹp.

Khi đi thi

- Ghi cả train và validation, kèm cách chia.
- Thua baseline: kiểm dữ liệu trước.
- Train tốt, validation kém: giảm linh hoạt, regularization.
- Cả hai kém: feature hoặc mô hình mạnh hơn.

04

Luyện đề

LUYỆN ĐỀ 1

Khi tăng độ phức tạp của mô hình, chẳng hạn tăng bậc đa thức, bias và variance thường thay đổi thế nào?

A Cả hai cùng tăng

B Cả hai cùng giảm

C Cả hai không đổi

D Bias giảm, variance tăng

E Bias tăng, variance giảm

ĐỀ THI USA-NA-AIO 2026 · Vòng 1 · Part 1.3

LUYỆN ĐỀ 2

Bài phân loại 10 lớp, 5000 mẫu. Tỉ lệ đúng trên train và validation: A rất đơn giản, 68% và 67%. B rất lớn, 99% và 71%. C vừa phải, có regularization, 85% và 83%. Chẩn đoán nào đúng?

A A underfit, B overfit, C cân bằng

B A ổn, B bias cao, C variance cao

C A variance cao, B ổn, C bias cao

D Cả ba do dữ liệu bẩn, cần làm sạch

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 277

Chốt ý

Đọc train + validation, kiểm điều kiện split, rồi chọn cách xử lý.

Làm 10 câu cuối bài.