Data split và cross-validation

Mẫu mới là một hàng, một người hay một thời điểm?

Ba bài làm của một học sinh

Chia theo hàng có thể đưa cùng người vào train và validation.

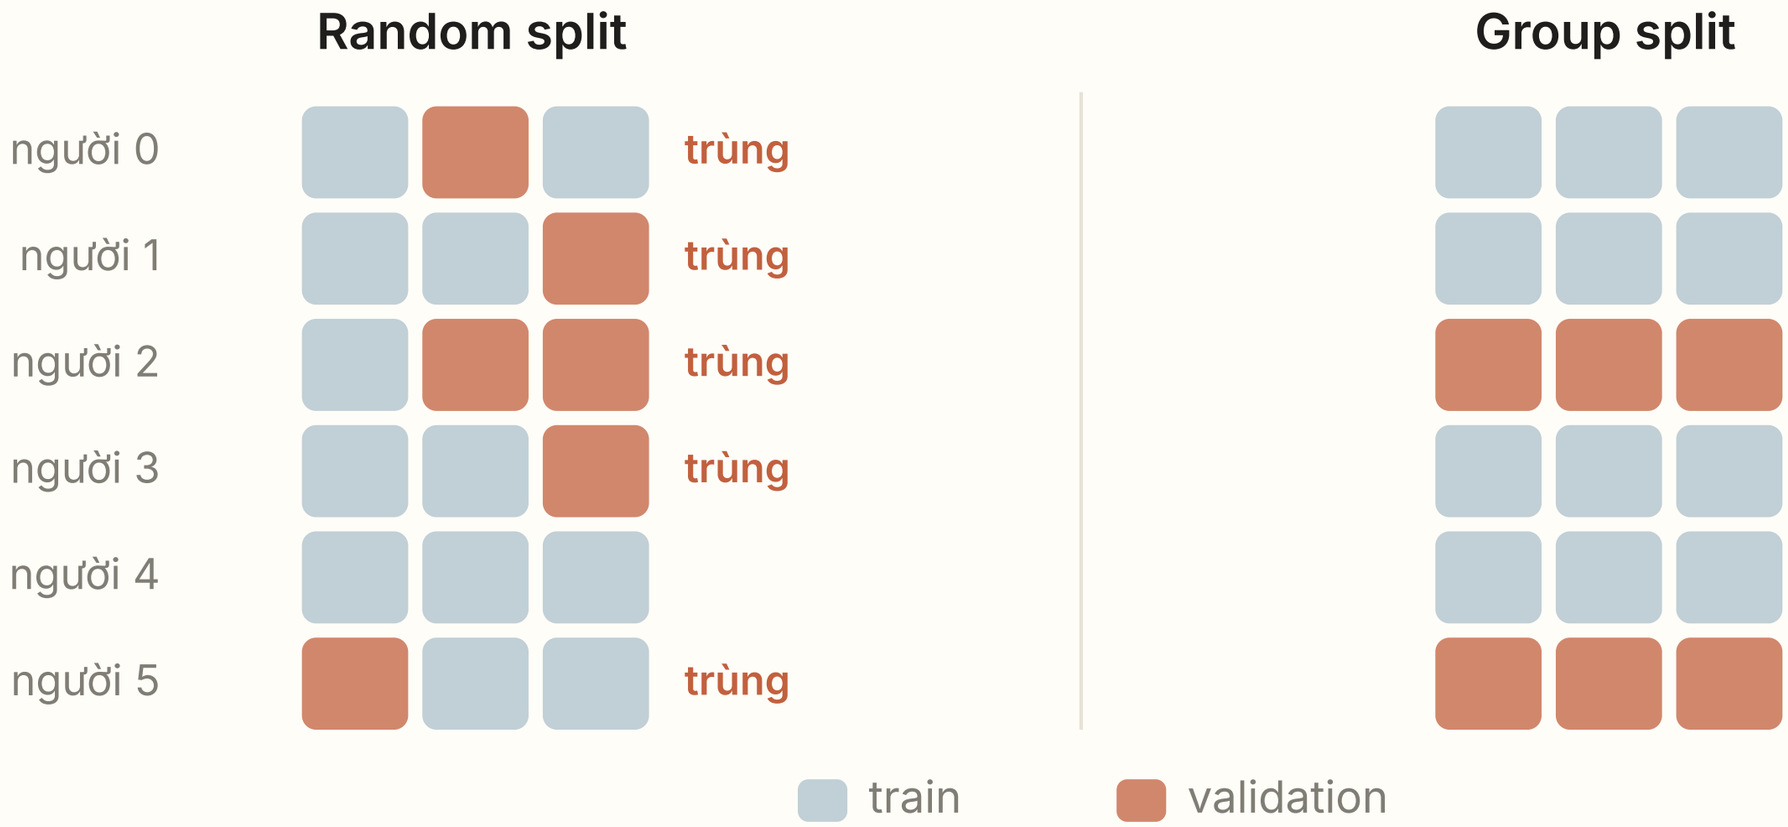
Đích sử dụng: dự đoán cho người ở trường mới.

Phải giữ đơn vị chưa thấy ra khỏi train.

01

Chọn split từ nhiệm vụ

Hàng khác nhưng người trùng



Chia ngẫu nhiên: năm người có mặt ở cả hai phía. Group split: mỗi người một phía.

HỎI NHANH

Mô hình sẽ dùng cho những trường chưa có trong train. Mỗi học sinh có nhiều bản ghi. Ta để riêng validation theo đơn vị nào?

A Theo trường

B Theo học sinh, các trường vẫn trộn ở hai phía

C Theo từng bản ghi, có giữ tỉ lệ nhãn

D Theo thời gian, để riêng tháng cuối của mọi trường

Stratified giữ nhãn

KẾT QUẢ

```
Số mẫu train/valid: 9 3
Số nhãn 1 train/valid: 2 1
Trùng hàng: 0
```

12 mẫu, ba dương.

Valid ba mẫu không thể giữ đúng tỉ lệ 25%.

Stratified không tự giữ người hoặc thời gian.

HỎI NHANH

Mỗi học sinh có nhiều bài làm. Ta dùng stratified split. Cách chia này bảo đảm được điều gì?

A Không học sinh nào có bài ở cả hai phía

B Bài trong validation đều làm muộn hơn train

C Tỉ lệ nhãn ở hai phía gần nhau, và chỉ có vậy

D Mỗi học sinh có đúng một bài trong validation

Kiểm group giao nhau

KẾT QUẢ

```
Random split, người trùng: [0, 1, 2, 3, 5]
Fold 1: valid groups=[2, 5], trùng=0
Fold 2: valid groups=[1, 4], trùng=0
Fold 3: valid groups=[0, 3], trùng=0
```

Không chỉ kiểm chỉ số hàng.

Khi đánh giá group mới, giao của các group train và valid phải rỗng.

$$G_{\text{train}} \cap G_{\text{valid}} = \varnothing.$$

HỎI NHANH

Nhiều ảnh là bản cắt, bản xoay, hay bản chụp lại từ cùng một tờ giấy. Chia ngẫu nhiên theo ảnh thì validation đúng 99%, gặp bài lớp khác chỉ đúng 80%. Sửa cách chia thế nào?

A Giữ tỉ lệ nhãn ở hai phía bằng nhau

B Gom ảnh cùng tờ giấy thành nhóm, rồi chia theo nhóm

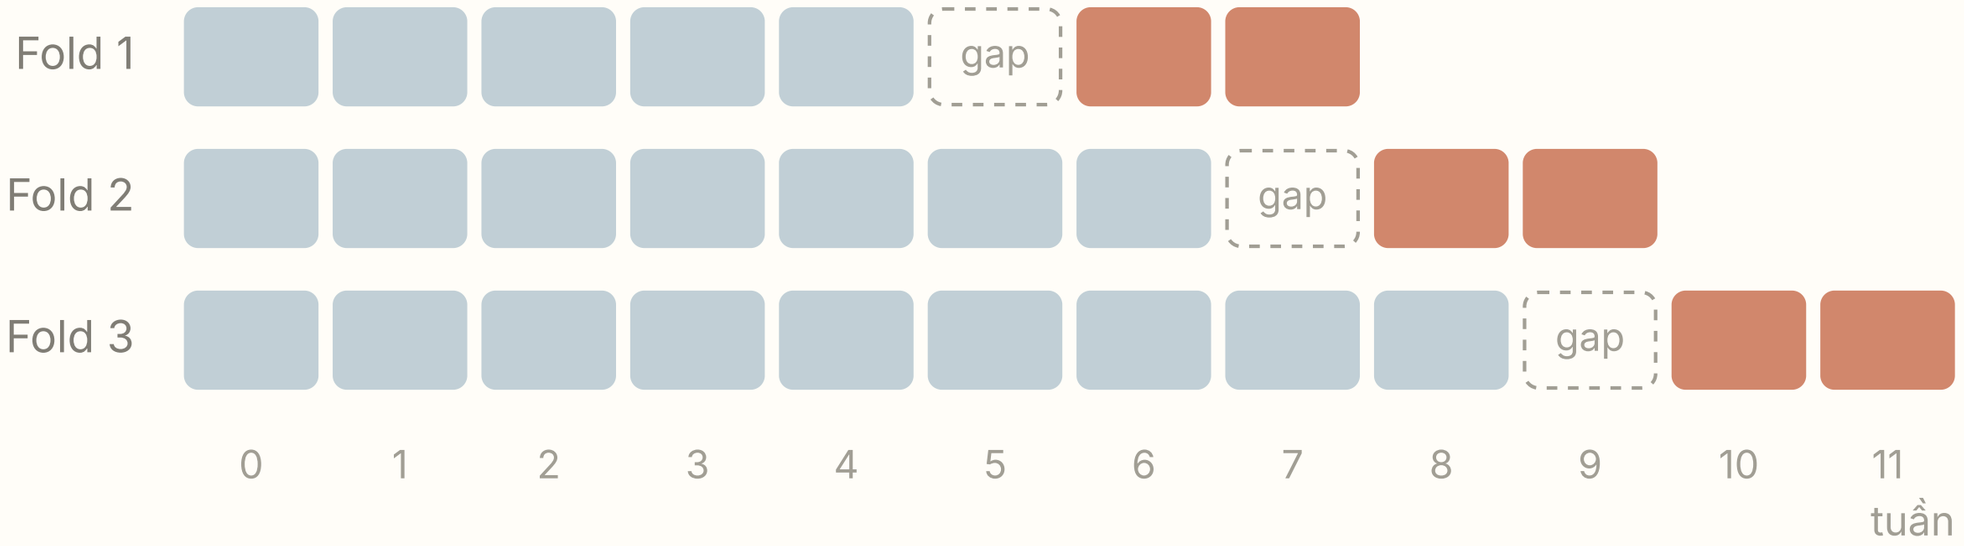
C Chia lại với seed khác cho điểm ổn định

D Bỏ ảnh cắt khỏi validation, giữ trong train

02

Dự đoán tương lai

Train đứng trước validation



Train luôn đứng trước; bỏ một tuần sát ranh giới rồi chấm hai tuần sau.

Các chỉ số đã chạy

KẾT QUẢ

```
Fold 1: train=[0, 1, 2, 3, 4], valid=[6, 7]
Fold 2: train=[0, 1, 2, 3, 4, 5, 6], valid=[8, 9]
Fold 3: train=[0, 1, 2, 3, 4, 5, 6, 7, 8], valid=[10, 11]
```

Sắp theo thời gian trước. Gap=1 chỉ là minh họa; dữ liệu thật cần gap theo thời điểm biết nhãn.

HỎI NHANH

Nhãn của mỗi hàng là tổng số người đến trong ba tuần tiếp theo. Ta chỉ bảo đảm ngày bắt đầu của mọi hàng train sớm hơn validation. Như vậy đủ chưa?

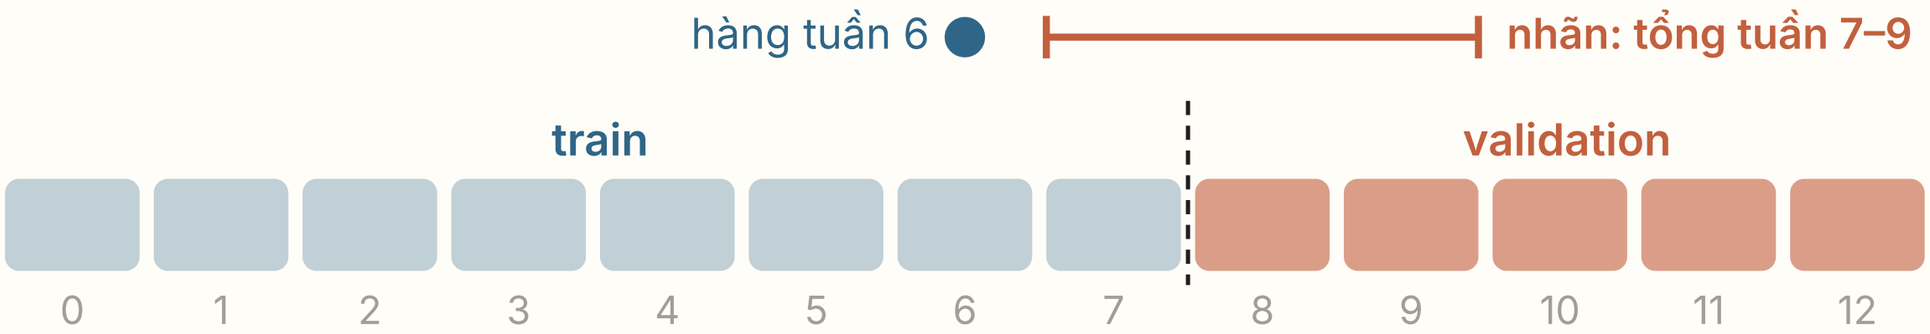
A Đủ, vì ngày bắt đầu đã đúng thứ tự

B Đủ, nếu giữ thêm tỉ lệ nhãn

C Chưa, phải bỏ hẳn cột ngày khỏi feature

D Chưa, vì nhãn của train có thể tính cả tuần thuộc validation

Nhãn nhìn vào tương lai



Nhãn là tổng ba tuần sau, nên hàng train sát ranh giới đã nhìn vào validation.

03

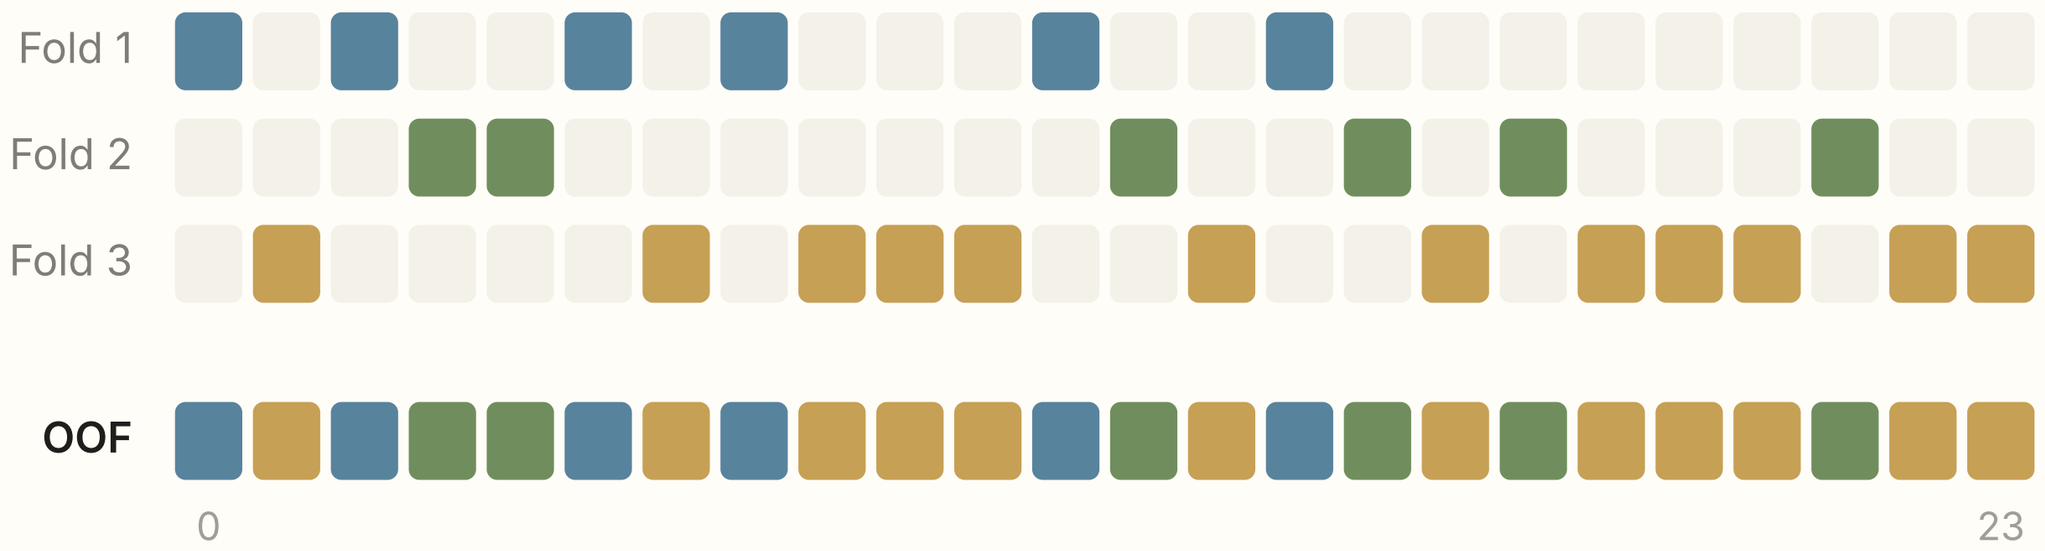
K-fold và OOF

Mỗi mẫu được chấm khi nó ở ngoài train

$$\bar{s} = \frac{1}{K} \sum_{k=1}^{K} s_k .$$

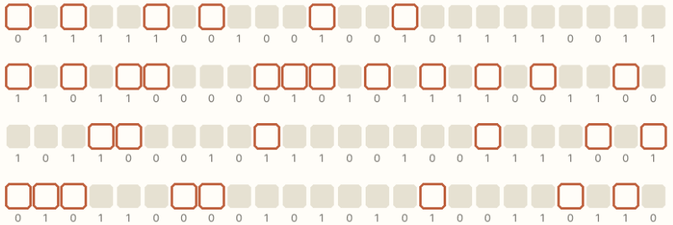
s_k là metric của fold k. Điểm trung bình fold và metric gộp không luôn giống nhau.

Ghi OOF về vị trí gốc

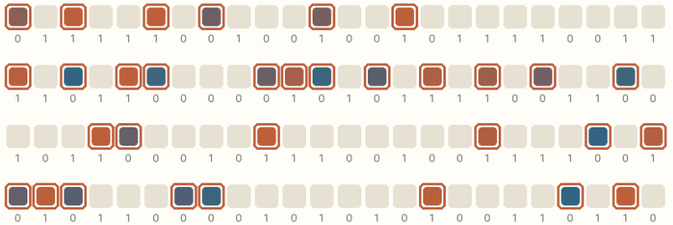


Mỗi fold chấm một phần; OOF ghép về đúng vị trí, mỗi mẫu một lần.

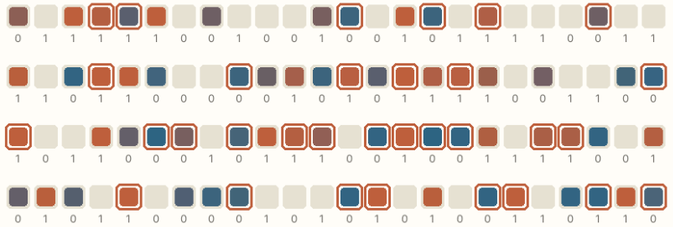
Lấp đầy cột OOF



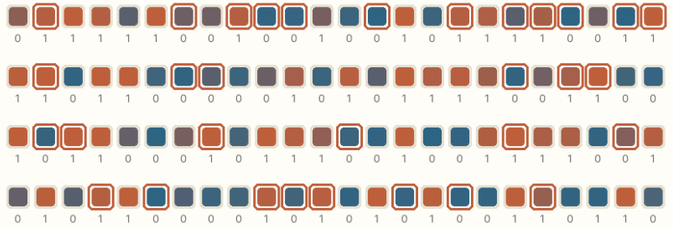
fold 1: train trên 64 mẫu, giữ 32 mẫu viền cam



fold 1: dự đoán ghi về đúng vị trí gốc, accuracy fold 0.969



fold 2: dự đoán ghi về đúng vị trí gốc, accuracy fold 0.906



fold 3: dự đoán ghi về đúng vị trí gốc, accuracy fold 0.906; OOF đủ 96 ô, accuracy gộp 0.927

StratifiedKFold 3 fold của bài trên 96 mẫu: mỗi fold, model chưa thấy các ô viền cam sẽ đoán chúng; xác suất (xanh 0, cam 1) ghi về đúng vị trí cho đủ cột OOF.

Kiểm các hàng được chấm

```
# Trong mỗi fold:
oof_probability[valid_ids] = probability
times_scored[valid_ids] += 1
# Sau khi hoàn tất tất cả fold:
assert np.all(times_scored == 1)
assert np.isfinite(oof_probability).all()
```

KẾT QUẢ

```
Fold 1: n=32, accuracy=0.969
Fold 2: n=32, accuracy=0.906
Fold 3: n=32, accuracy=0.906
OOF shape: (96,)
Mean fold accuracy=0.927
Pooled OOF accuracy=0.927
```

Ở K-fold, mỗi hàng được chấm đúng một lần.

Ba fold cùng 32 mẫu, nên mean fold accuracy trùng accuracy gộp trong ví dụ này.

TimeSeriesSplit có hàng đầu chưa từng làm validation: cần mask, không điền bằng nhãn.

HỎI NHANH

Một đội dùng điểm OOF để chọn feature, rồi lại dùng nó để chọn mô hình. Điểm OOF của phương án thắng còn được coi là điểm test độc lập không?

A Còn, vì mỗi mẫu không nằm trong train của fold chấm nó

B Còn, nếu mọi hàng đều được chấm đúng một lần

C Không, vì các lựa chọn đều đã dựa vào điểm OOF

D Còn, nếu tăng số fold để bớt nhiễu

Tính tay: validation thiếu lớp

$\binom{12}{3} = 220$ bộ ba.

Có 9 mẫu âm, nên $\binom{9}{3} = 84$ bộ ba không có mẫu dương.

Xác suất 84/220 ≈ 0.382.

Kiểm số mẫu lớp trong từng fold.

Bẫy cài đặt

OOF không được nối theo thứ tự fold rồi coi là thứ tự gốc.

Feature, nhãn và group dùng cùng chỉ số.

Fit preprocessing trong từng fold.

Dùng OOF để chọn nhiều phương án vẫn cần test ngoài hoặc nested CV.

Khi đi thi

- Hỏi “mẫu mới là ai” trước khi chọn split.
- Cố định fold, dùng chung cho mọi phương án.
- In số mẫu, tỉ lệ lớp, giao group, khoảng thời gian mỗi fold.
- Split khó mà đúng hơn split dễ mà sai.

04

Luyện đề

LUYỆN ĐỀ 1

A chia 70/30, chỉnh mô hình theo test 50 vòng, báo điểm test cao nhất **94.2%**. B chia 60/20/20, chỉnh theo validation, chấm test một lần được **91.8%**. Con số nào đáng tin hơn?

A Của A, vì train nhiều hơn và tìm kỹ hơn

B Của A, vì xem test 50 lần thì ổn định hơn

C Của B, vì test không tham gia việc chọn

D Như nhau, vì hai tập test gần bằng nhau

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 303

LUYỆN ĐỀ 2

Câu nào mô tả đúng K-fold cross-validation cho linear regression với một feature x?

A Sắp theo x, cắt thành K khối liền nhau, lần lượt giữ một khối

B Học một lần trên toàn bộ dữ liệu, rồi chấm K lần

C Học trên mọi tập con cỡ K, lấy trung bình lỗi trên test riêng

D Chia ngẫu nhiên thành K phần, mỗi vòng giữ lại một phần để chấm

PHỎNG THEO CMU 10-601 · Practice Problems, Exam 1 · Q3.4

Chốt ý

Random phù hợp khi các mẫu độc lập. Stratified giữ tỉ lệ lớp.

Group giữ đơn vị mới. Split theo thời gian giữ tương lai ở ngoài train.

Làm 10 câu cuối bài.