Pipeline và data leakage

Tiền xử lý cũng là một phần được học

Một bảng có số, chữ và ô thiếu

Điền thiếu, scale và encode đều là bước trước model.

Nếu xử lý cả bảng rồi mới split, validation đã ảnh hưởng việc học.

Mục tiêu

- Phân biệt bước xử lý cố định với bước phải học từ train.
- Viết Pipeline và ColumnTransformer cho bảng có cột số, cột chữ và ô trống.
- Kiểm các bước xử lý được học lại trong mỗi fold.
- Nhận ra các kiểu data leakage hay gặp.

01

Fit ở đâu?

Chuẩn hóa theo train

Train gồm 10 và 20. Mean bằng 15, độ lệch chuẩn dùng trong ví dụ bằng 5.

Valid là 30 nên dùng scaler của train:

.

KẾT QUẢ

```
Train: [-1.  1.]
Valid dùng scaler train: [3.]
Valid fit riêng, cách sai: [0.]
```

HỎI NHANH

Ta cần điền các ô thiếu ở validation bằng median. Median ấy phải tính từ đâu?

A Từ chính các hàng validation

B Từ train của lần học đang đánh giá

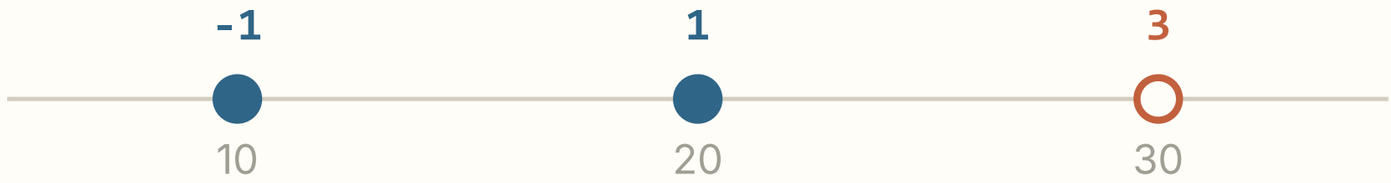
C Từ train và validation gộp lại, trước khi chia

D Từ test, vì test giống lúc dùng thật nhất

Giữ cùng hệ tọa độ

Dùng scaler train

μ = 15, σ = 5



Fit riêng valid

chỉ có một giá trị



Validation phải dùng μ, σ học từ train; fit riêng biến buổi đông nhất thành 0.

Biến đổi cố định và được học

Đổi cm sang m (chia 100): biến đổi cố định, không học gì.

Median, mean/std, danh sách danh mục: học từ dữ liệu.

Phần học từ dữ liệu chỉ được học trên train của mỗi lần đánh giá.

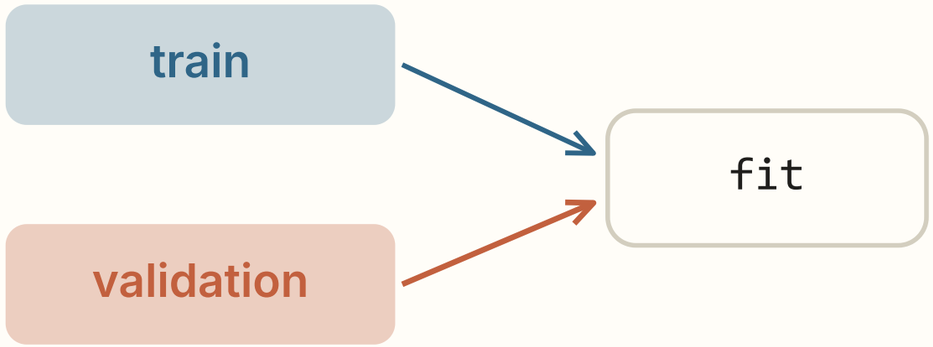
Rồi giữ nguyên khi biến đổi mẫu mới.

02

Những đường rò rỉ

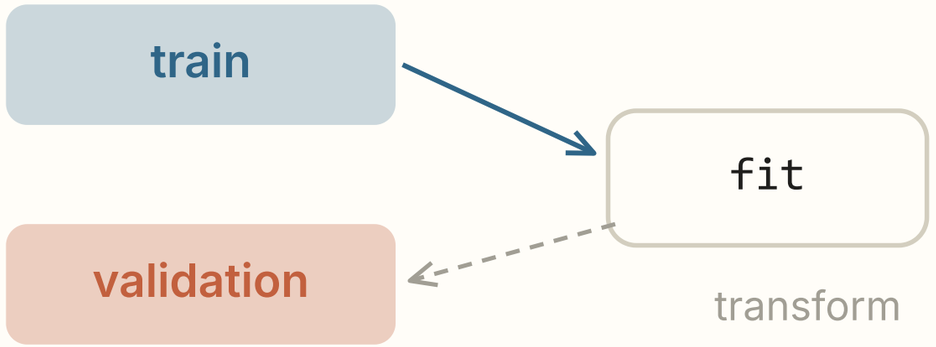
Pipeline không hiểu thời điểm cột

Fit trên toàn bảng



median, μ, σ đã thấy validation

Fit trong Pipeline



validation chỉ được transform

Fit trên toàn bảng để validation lọt vào tiền xử lý; Pipeline chỉ fit trên train.

HỎI NHANH

Cột `final_attendance` chỉ có sau khi buổi sinh hoạt kết thúc. Đặt cột này vào Pipeline thì nó có thành feature hợp lệ không?

A Không, lúc dự đoán vẫn chưa có cột này

B Có, vì Pipeline tự chặn mọi kiểu rò rỉ

C Có, miễn là không gọi `fit` trên test

D Không, vì Pipeline chỉ nhận cột số

Điểm hoàn hảo nhưng vô dụng

Train , validation 40, thêm cột đếm người vào cửa ghi sau buổi.

: lỗi 0 trên cả ba hàng.

Vô dụng: chiều thứ Sáu chưa có cột ấy.

Bảng của bài: số, chữ và ô thiếu

Số ô thiếu theo cột: dòng đầu là train, dòng sau là validation.

KẾT QUẢ

```
{'registered': 3, 'rain': 2, 'slot': 0}
{'registered': 1, 'rain': 1, 'slot': 0}
```

Có 80 buổi. Train gồm 60, valid gồm 20.

Missing không mặc nhiên bằng 0.

Slot sáng/chiều dùng one-hot.

HỎI NHANH

Thay vì one-hot, ta mã hóa `slot` thành sáng = 0, chiều = 1, tối = 2, rồi đưa vào `LinearRegression`. Làm vậy là ngầm giả định điều gì?

A Không giả định gì, vì số chỉ là tên của từng buổi

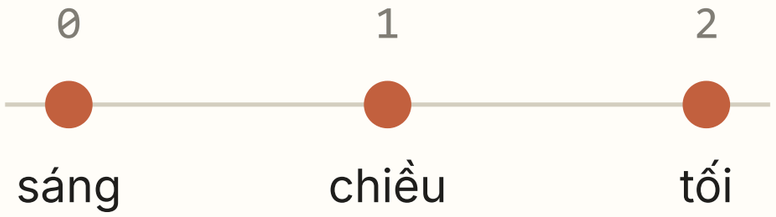
B Đủ dữ liệu thì mô hình sẽ tự học ra thứ tự đúng

C Cách mã hóa chỉ ảnh hưởng khi cột có ô thiếu

D Sáng, chiều, tối nằm trên một đường thẳng, cách đều nhau

Mã số hay one-hot

Mã số 0, 1, 2



tối bị ép = 2 × chiều

One-hot

sáng	1	0	0
chiều	0	1	0
tối	0	0	1

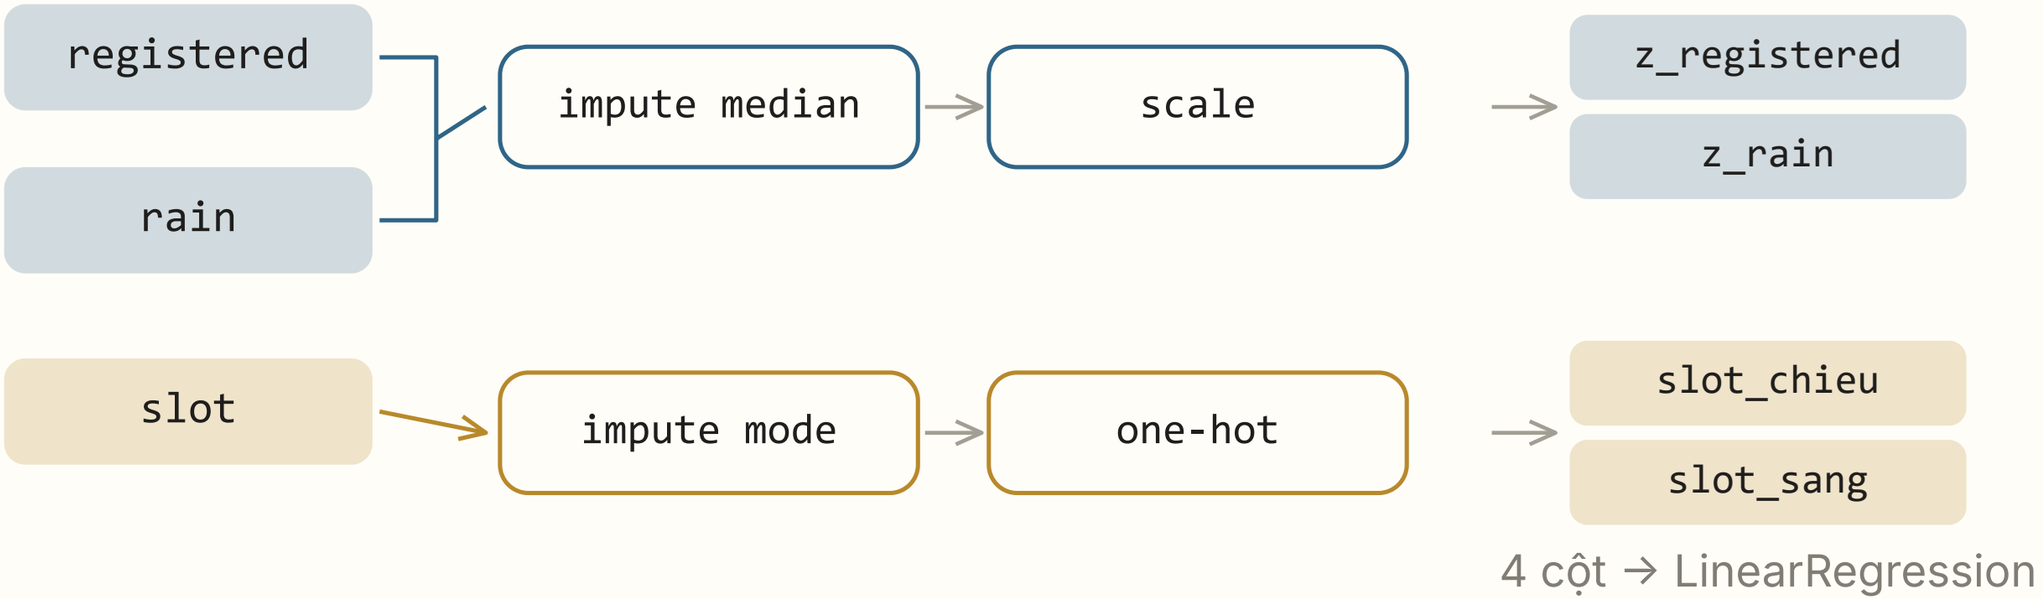
mỗi buổi một hệ số riêng

Mã số áp một thứ tự cách đều; one-hot cho mỗi danh mục một cột riêng.

03

ColumnTransformer + Pipeline

Mỗi nhóm cột một nhánh



Cột số và cột chữ đi hai nhánh riêng rồi ghép thành 4 cột.

ColumnTransformer ghép hai nhánh; Pipeline ngoài nối tiền xử lý với regressor.

Sáu hàng đi qua Pipeline

registered	rain	slot
58.00	0.08	chieu
61.00	0.15	chieu
20.00	0.26	chieu
52.00	0.08	chieu
—	0.99	chieu
23.00	—	sang

6 hàng validation thô: có ô trống (—) và cột chữ slot

registered	rain	slot
58.00	0.08	chieu
61.00	0.15	chieu
20.00	0.26	chieu
52.00	0.08	chieu
40.00	0.99	chieu
23.00	0.46	sang

SimpleImputer: ô trống thay bằng trung vị học từ train (40.0 và 0.46)

z_registered	z_rain	chieu	sang
+1.30	-1.41	1	0
+1.51	-1.14	1	0
-1.28	-0.78	1	0
+0.89	-1.41	1	0
+0.08	+1.75	1	0
-1.08	-0.07	0	1

OneHotEncoder: slot thành hai cột 0/1

z_registered	z_rain	chieu	sang	dự đoán
+1.30	-1.41	1	0	49.9
+1.51	-1.14	1	0	51.5
-1.28	-0.78	1	0	22.5
+0.89	-1.41	1	0	45.8
+0.08	+1.75	1	0	31.8
-1.08	-0.07	0	1	18.8

LinearRegression đọc 4 cột và cho dự đoán

Sáu hàng validation của bài đi qua Pipeline đã fit trên train: điền trung vị, chuẩn hóa, one-hot, rồi model dự đoán; mọi con số dùng thống kê của train.

Fit toàn quy trình

```
model.fit(X_train, y_train)
prediction = model.predict(X_valid)
print('Sau biến đổi:', model.named_steps['preprocess'].transform(X_valid).shape)
print(f'Validation MAE={mean_absolute_error(y_valid, prediction):.3f}')
```

KẾT QUẢ

```
Sau biến đổi: (20, 4)
Validation MAE=1.707
```

Có 20 hàng và 4 cột sau biến đổi. MAE validation là 1.707.

Tên bước `preprocess` dùng để tra trạng thái đã học.

HỎI NHANH

Imputer nằm trong Pipeline, nhưng median đã được tính sẵn từ toàn bảng rồi truyền cố định vào. Chạy cross-validation thì còn sai ở đâu?

A Median ấy đã tính cả các hàng validation của từng fold

B Chỉ sai khi mô hình phía sau không tuyến tính

C Không sai, vì mỗi fold vẫn gọi `fit` trên Pipeline

D Phải dùng mean thay cho median thì mới đúng

Đọc trạng thái đã học

KẾT QUẢ

```
Median đã học: [40.     0.462]
Median tính từ train: [40.     0.462]
Cột one-hot của danh mục chưa thấy: [0. 0.]
Dự đoán buổi mới: [27.493]
```

Median lưu khớp train.

Danh mục buổi tối chưa từng thấy được mã hóa thành toàn 0 khi encoder bỏ qua danh mục lạ.

Chạy được chưa bảo đảm model hiểu buổi tối.

HỎI NHANH

Buổi “toi” chưa từng có trong train, nên nhận one-hot `[0, 0]` và được dự đoán 27.49 người. Đây thực chất là dự đoán cho cái gì?

A Mô hình đã học được buổi tối

B Một buổi không sáng, không chiều

C Buổi tối được coi như buổi chiều

D Không có nghĩa gì, lẽ ra phải báo lỗi

CV nhận toàn Pipeline

```
scores = cross_val_score(
    model, X_train, y_train, cv=cv,
    scoring='neg_mean_absolute_error', n_jobs=1,
)
print('Fold MAE:', np.round(-scores, 3))
print(f'Mean CV MAE={-scores.mean():.3f}')
```

KẾT QUẢ

```
Fold MAE: [1.087 1.995 1.314]
Mean CV MAE=1.465
```

Mỗi fold fit lại imputer, scaler, encoder và model.

`neg_mean_absolute_error` trả ; đổi dấu để đọc.

HỎI NHANH

Muốn cross-validation không bị rò rỉ qua bước điền median, ta đưa gì vào `cross_val_score`?

A Bảng đã điền median tính từ mọi hàng

B Chỉ regressor, còn scaler đã fit trên toàn bảng

C Bảng mà mỗi fold validation tự điền median của nó

D Pipeline gồm imputer, scaler và regressor

Khi đi thi

- Lúc dự đoán đã có cột này chưa?
- Mọi bước học từ dữ liệu nằm trong Pipeline.
- Điểm tăng vọt: kiểm cột vừa thêm.

04

Luyện đề

LUYỆN ĐỀ 1

Chọn 10 feature bằng `SelectKBest` trên **toàn bộ** dữ liệu rồi mới chạy 5-fold cross-validation thì được 92%. Chọn feature **bên trong** từng fold thì được 78%. Con số nào đáng tin?

A 92%, vì chọn trên toàn bộ dữ liệu thì ổn định hơn

B 78%, vì cách đầu đã nhìn nhãn của validation

C Cả hai, vì hai cách đo hai thứ khác nhau

D Không con số nào, cần một tập riêng để chọn

ĐỀ THI NOAI 2026 Singapore · Chung kết · Câu 4

LUYỆN ĐỀ 2

Bảng dữ liệu cho vay có cột số và cột chữ, 15% số dòng có ô thiếu, cột thu nhập có vài giá trị cực lớn. Chuỗi tiền xử lý nào hợp lý nhất?

A Xóa dòng thiếu, đưa cột số về 0 đến 1, đổi chữ thành 0, 1, 2...

B Điền 0, xóa dòng thu nhập quá lớn, đổi chữ thành 0, 1, 2...

C Điền median và giá trị hay gặp nhất, chặn giá trị cực lớn, chuẩn hóa, one-hot

D Giữ ô thiếu, chuẩn hóa, one-hot, đưa thẳng vào `LinearRegression`

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 304

Chốt ý

Bước nào học từ dữ liệu thì chỉ học trên train, nằm trong Pipeline.

Pipeline lo chỗ gọi `fit`; cột nào có sẵn lúc dự đoán thì phải tự kiểm.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook: fit scaler trên toàn bảng rồi so điểm CV với bản dùng Pipeline.