Linear regression

Định giá căn hộ từ diện tích và khoảng cách

Chương 2 · Bài 2.1

Giá này cao hay thấp?

Một căn hộ **70 m²**, cách trung tâm **8 km**, rao bán **4,2 tỷ**.

Có giá của **200 căn** đã bán quanh đó (dữ liệu giả lập).

Căn rộng hơn thì đắt hơn, xa trung tâm thì rẻ hơn.

Linear regression viết cách ước lượng ấy thành công thức và tìm hệ số từ dữ liệu.

Mục tiêu

- Hiểu model tuyến tính và ý nghĩa từng hệ số.
- Tìm hệ số bằng công thức nghiệm và bằng gradient descent.
- Biết vì sao learning rate quá lớn làm loss tăng vọt, và vì sao cần chuẩn hóa đặc trưng.
- Dùng scikit-learn và tự cài lại bằng NumPy.

01

Dữ liệu và mô hình

Mô hình tuyến tính

Mỗi đặc trưng đóng góp một lượng tỉ lệ với nó, rồi cộng lại:

: dự đoán tăng bao nhiêu khi tăng 1 đơn vị **và các đặc trưng khác giữ nguyên**.

Cho cả mẫu cùng lúc:

Ký hiệu	Shape
	`(n, d)`
	`(d,)`
,	`(n,)`

Dữ liệu của buổi học

Tự sinh 200 căn theo một công thức biết trước, cộng nhiễu:

Biết trước đáp án thì kiểm tra được mô hình học đúng hay sai.

```
rng = np.random.default_rng(0)
n = 200
area = rng.uniform(30, 120, n)
dist = rng.uniform(1, 15, n)
y = 0.05 * area - 0.15 * dist + 1.0 \
    + rng.normal(0, 0.3, n)
X = np.column_stack([area, dist])
print(X.shape, y.shape)
```

KẾT QUẢ

```
(200, 2) (200,)
```

HỎI NHANH

`X` có shape `(200, 2)`, `w` có shape `(2,)`. `X @ w + b` có shape gì?

A `(200,)`

B `(2,)`

C `(200, 2)`

D `(200, 1)`

02

Hàm mất mát

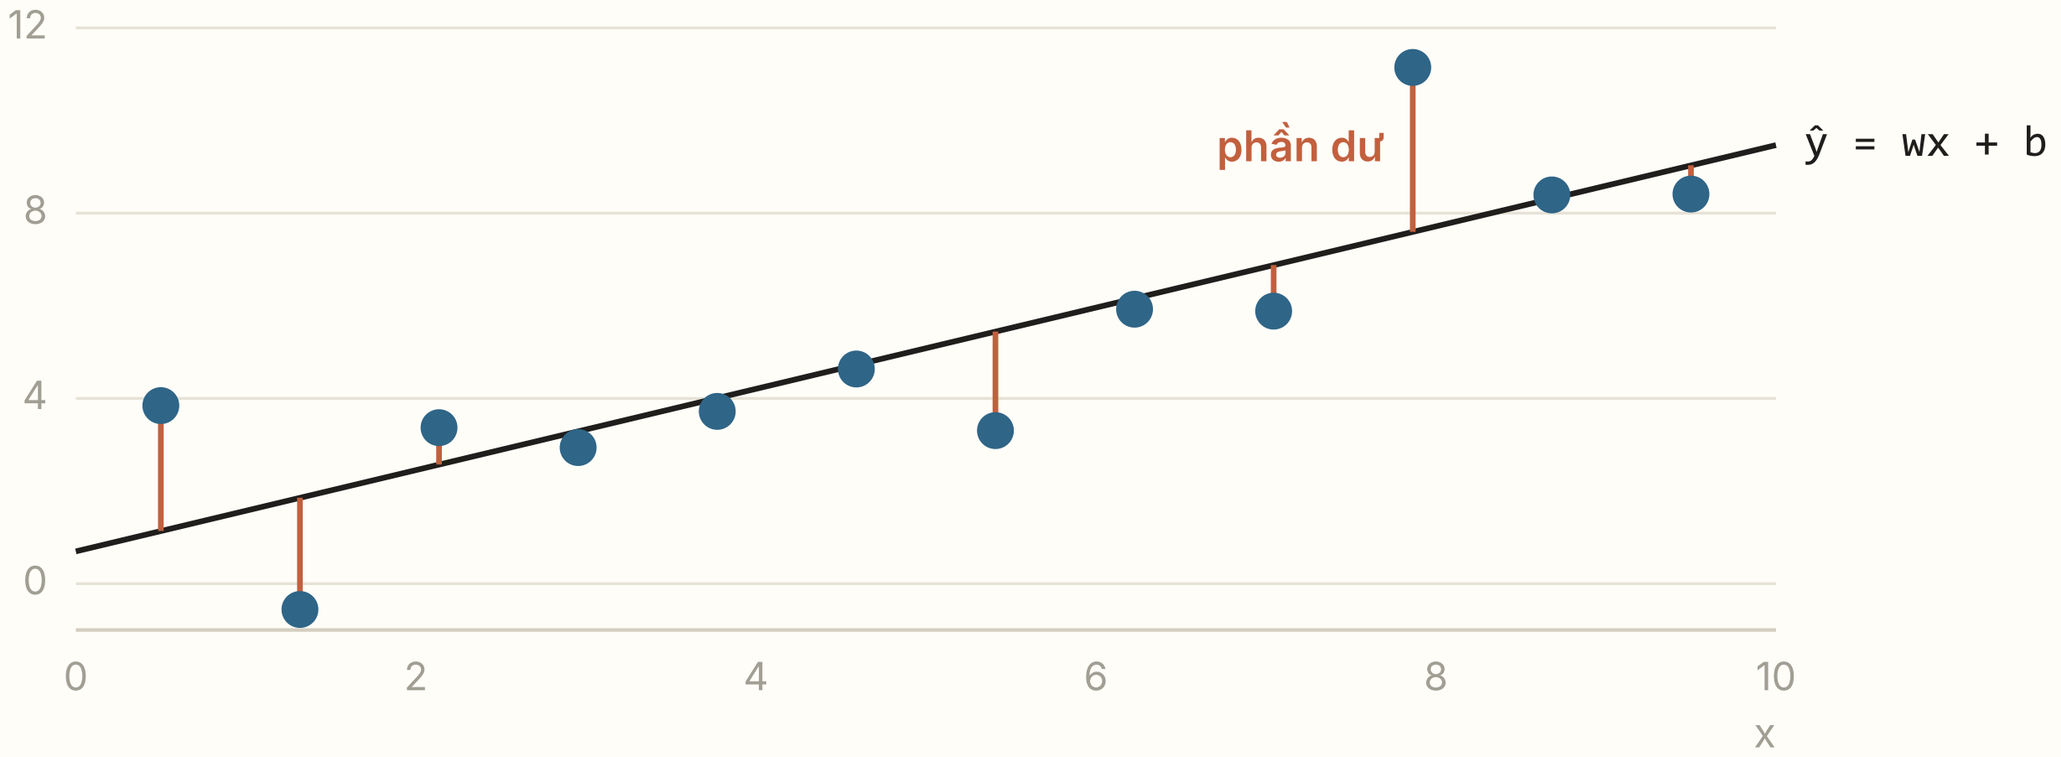
Mean squared error

Vì sao bình phương?

- Trơn, đạo hàm được ở mọi điểm.
- Phạt lỗi lớn nặng hơn: sai 10 bị phạt gấp 4 lần sai 5.
- Nếu phần nhiễu độc lập, trung bình bằng 0 và có cùng phương sai theo điều kiện trên đặc trưng, MSE tương ứng với maximum likelihood dưới giả định Gaussian.

Nhược điểm: nhạy với outlier.

Phần dư trên một đường thẳng



Phần dư là đoạn thẳng đứng từ điểm dữ liệu tới đường dự đoán.

Mốc so sánh

Mô hình đoán mọi căn bằng giá trung bình có

Trên cùng tập chấm, mô hình có MSE lớn hơn mốc này chưa cải thiện sai số so với dự đoán hằng số.

: ngang mốc · : đoán trúng hết

HỎI NHANH

Đổi đơn vị giá từ tỷ đồng sang triệu đồng, tức nhân mọi với 1000. MSE thay đổi thế nào?

A Không đổi

B Tăng 1000 lần

C Tăng lần

D Giảm 1000 lần

03

Nghiệm đóng

Phương trình chuẩn

Thêm cột 1 vào : , gộp , khi đó .

Cực tiểu của là nơi gradient bằng 0:

—

Nếu các cột của độc lập, hệ có nghiệm duy nhất và có thể giải bằng `np.linalg.solve`. Với hệ suy biến hoặc điều kiện kém, dùng `lstsq`/QR/SVD thay cho nghịch đảo ma trận.

Giải trên dữ liệu căn hộ

```
Xb = np.column_stack([X, np.ones(n)])
theta = np.linalg.solve(Xb.T @ Xb, Xb.T @ y)
w_cf, b_cf = theta[:2], theta[2]
print(w_cf.round(4), round(b_cf, 4))
print(mse(predict(X, w_cf, b_cf), y))
print(predict(np.array([70, 8]), w_cf, b_cf))
```

KẾT QUẢ

```
[ 0.0499 -0.1453] 0.9809
0.08807615180405967
3.309815169606732
```

- Hệ số : khôi phục đúng công thức sinh dữ liệu.
- MSE : nhiễu độc lập không dự đoán được cho căn mới; train noise vẫn có thể bị học thuộc.
- Căn 70 m², 8 km: mô hình định giá **3,3 tỷ**. Rao 4,2 tỷ là cao hơn 0,9 tỷ.

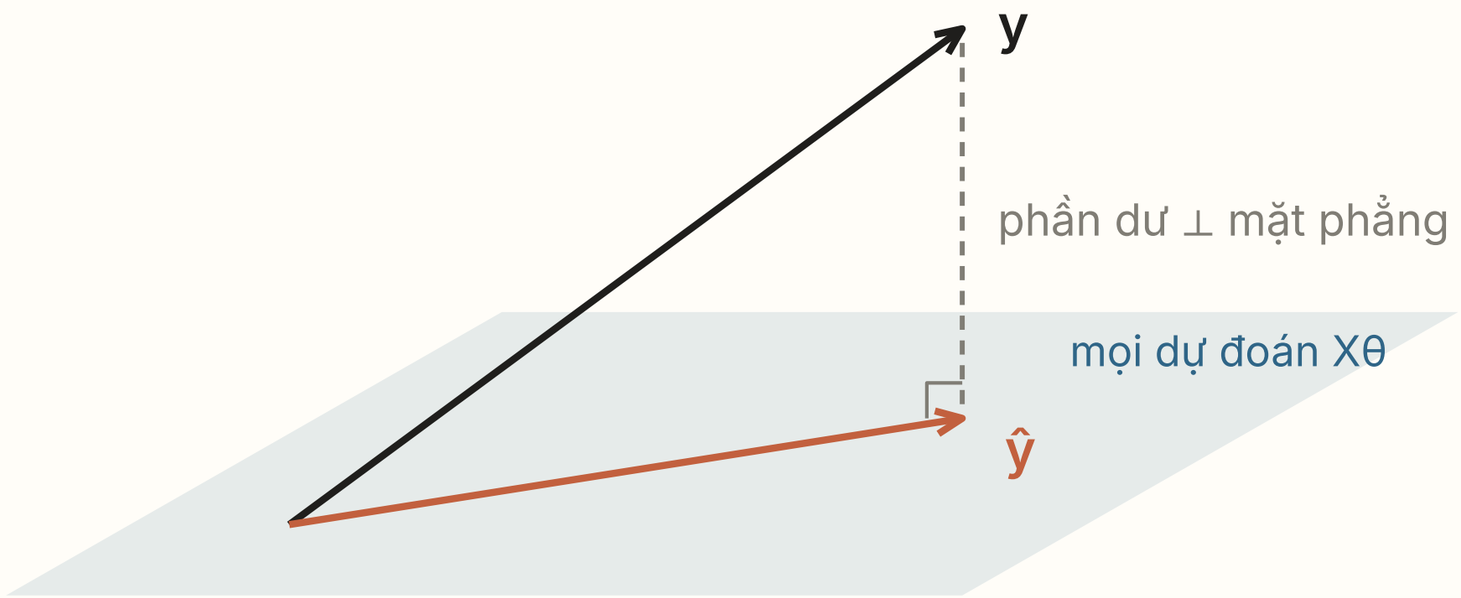
Cách nhìn hình học

là một vector trong không gian chiều. Mọi dự đoán nằm trên mặt phẳng sinh bởi các cột của .

Least squares chọn **hình chiếu vuông góc** của lên mặt phẳng đó.

Phần dư vuông góc với mọi cột, kể cả cột số 1, nên tổng phần dư bằng 0.

Hình chiếu vuông góc



Least squares chiếu y vuông góc xuống mặt phẳng các dự đoán.

HỎI NHANH

Thêm vào X một cột “diện tích tính bằng dm^2”, đúng bằng 100 lần cột diện tích. Nghiệm đóng sẽ ra sao?

A Chính xác hơn, vì có thêm một cột thông tin

B Không đổi gì, cột mới chỉ nhận hệ số 0

C Ma trận suy biến, hệ số có thể rất lớn và trái dấu

D Chỉ chạy chậm hơn một chút vì thêm một cột

04

Gradient descent

Đi xuống trong sương mù

Không thấy đáy, chỉ cảm nhận độ dốc dưới chân: bước một bước nhỏ về phía dốc xuống, rồi lặp lại.

Với :

```
def grad(theta, X, y):
    weights = theta[:-1]
    bias = theta[-1]
    residual = predict(X, weights, bias) - y
    grad_weights = 2 * (X.T @ residual) / len(y)
    grad_bias = 2 * residual.mean()
    return np.append(grad_weights, grad_bias)
```

`gd` lặp: ghi loss, rồi `theta -= lr * grad(...)`.

HỎI NHANH

Đặt `r = y_hat - y`. Dòng nào cập nhật bias đúng?

A `b -= lr * 2 * r.mean()`

B `b += lr * 2 * r.mean()`

C `b -= lr * 2 * r.sum()`

D `b -= lr * r`

Bài tập trên lớp: ba điểm

Ba điểm , , .

1. Tìm đường least squares .
2. Từ , , làm một bước gradient descent.

Công thức cho một đặc trưng:

$$_____$$

Lời giải

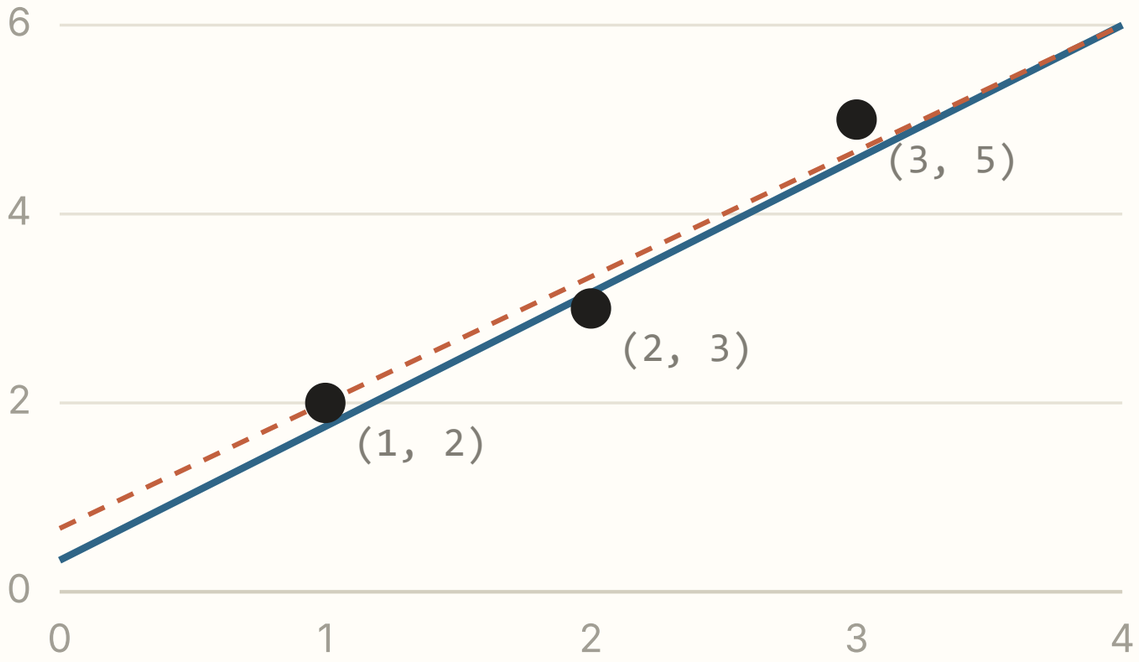
Tại : ,

, , tử số , mẫu số : ___ ___ ___ ___

_

Sau một bước: , , loss từ xuống .

Một bước đã gần nghiệm đóng



$\hat{y} = 1.5x + 1/3$

nghiệm least squares, J = 0.056

$\hat{y} = 1.53x + 0.67$

sau 1 bước GD từ 0, J = 0.22

Ba điểm: nghiệm đóng và đường sau một bước gradient descent.

Kiểm tra gradient

Xấp xỉ đạo hàm chỉ bằng hàm loss, như viết code trâu để đối chiếu:

Sai số , chọn .

Phiên bản `grad`	Sai số tương đối
Đúng	
Quên hệ số 2	

Sai số nhỏ xác nhận đạo hàm tại điểm đã kiểm. Kiểm vài điểm và thang bước sai phân; bước quá nhỏ có thể tăng sai số số học.

HỎI NHANH

Vì sao ta dùng sai phân trung tâm _____ thay vì _____?

A Vì tính nhanh hơn

B Vì sai số là thay vì

C Vì không phải chọn

D Vì sai phân một phía có thể ra số âm

05

Learning rate và chuẩn hóa

Thử ba learning rate

```python
for lr in [1e-3, 2e-4, 1e-4]:
    theta_gd, hist = gd(X, y, lr, 1000)
    print(f"lr = {lr:g}: loss sau 1000 vòng = {hist[-1]:.4g}")
```

KẾT QUẢ

```
lr = 0.001: loss sau 1000 vòng = nan
lr = 0.0002: loss sau 1000 vòng = inf
lr = 0.0001: loss sau 1000 vòng = 0.1541
```

- Hai giá trị đầu: loss nổ tung.
- : hội tụ nhưng rất chậm; sau 1000 vòng, mới đi được trên đường tới .

Có đoán trước được không?

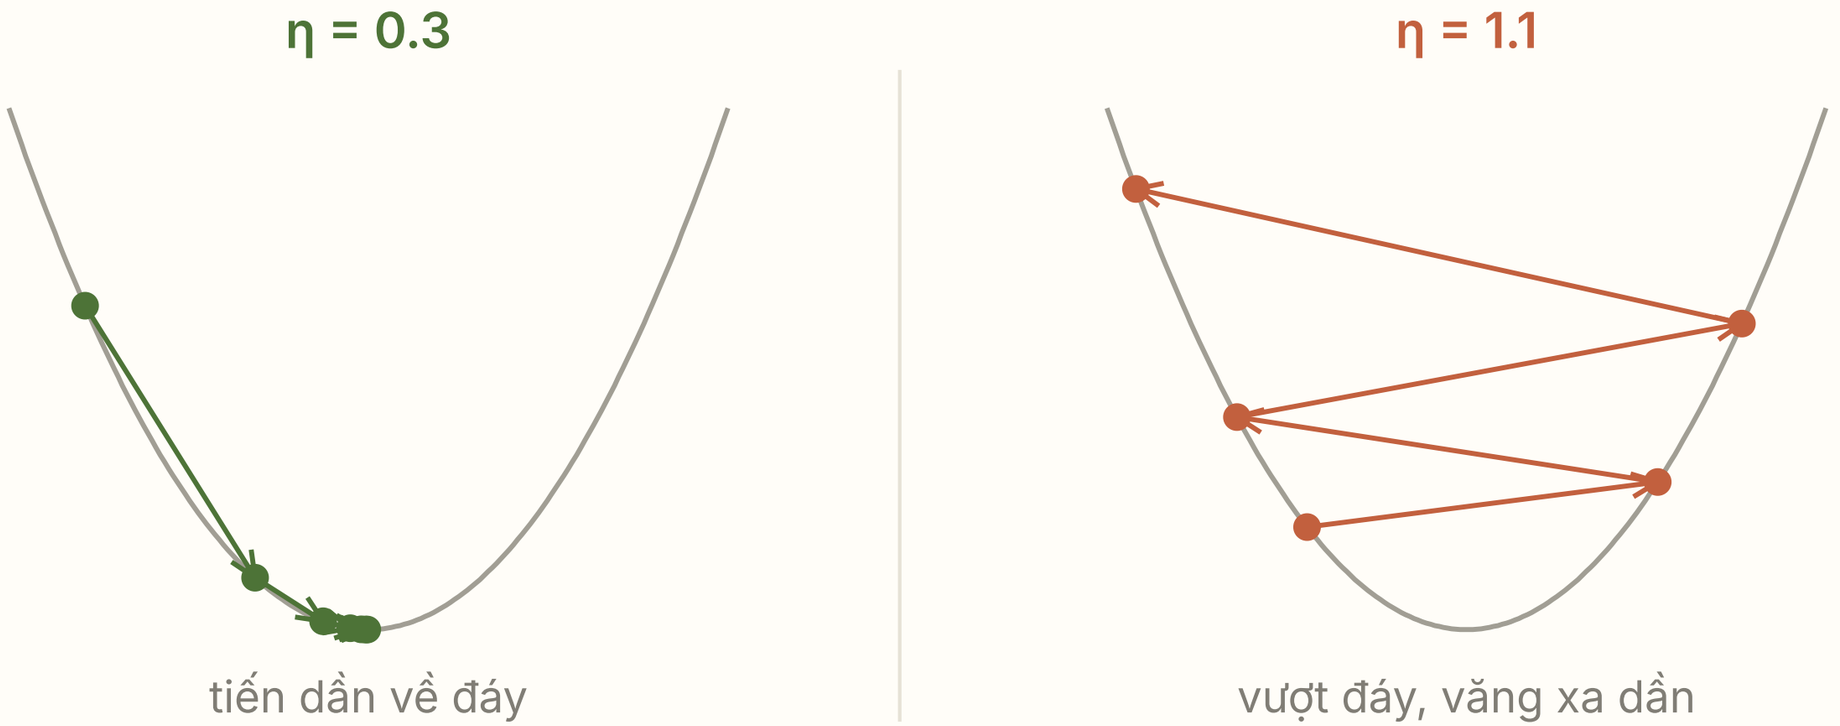
Ngưỡng của learning rate

Hessian của là hằng số – . Mỗi bước nhân sai số theo hướng ứng với trị riêng với , nên cần

---

Dữ liệu căn hộ: ngưỡng , số điều kiện .

Bước vừa phải và bước quá lớn



Bước vừa phải đi dần về đáy; bước quá lớn vượt đáy rồi văng xa dần.

HỎI NHANH

Linear regression tối ưu MSE, loss qua các vòng là 15.9, 41.2, 260, 17 000, rồi NaN. Shape và công thức gradient đều đã kiểm. Ta nên thử gì trước?

A Tăng learning rate để vượt qua vùng loss cao

B Giữ learning rate, chỉ đổi seed vài lần

C Giảm learning rate, và kiểm thang đo của các feature

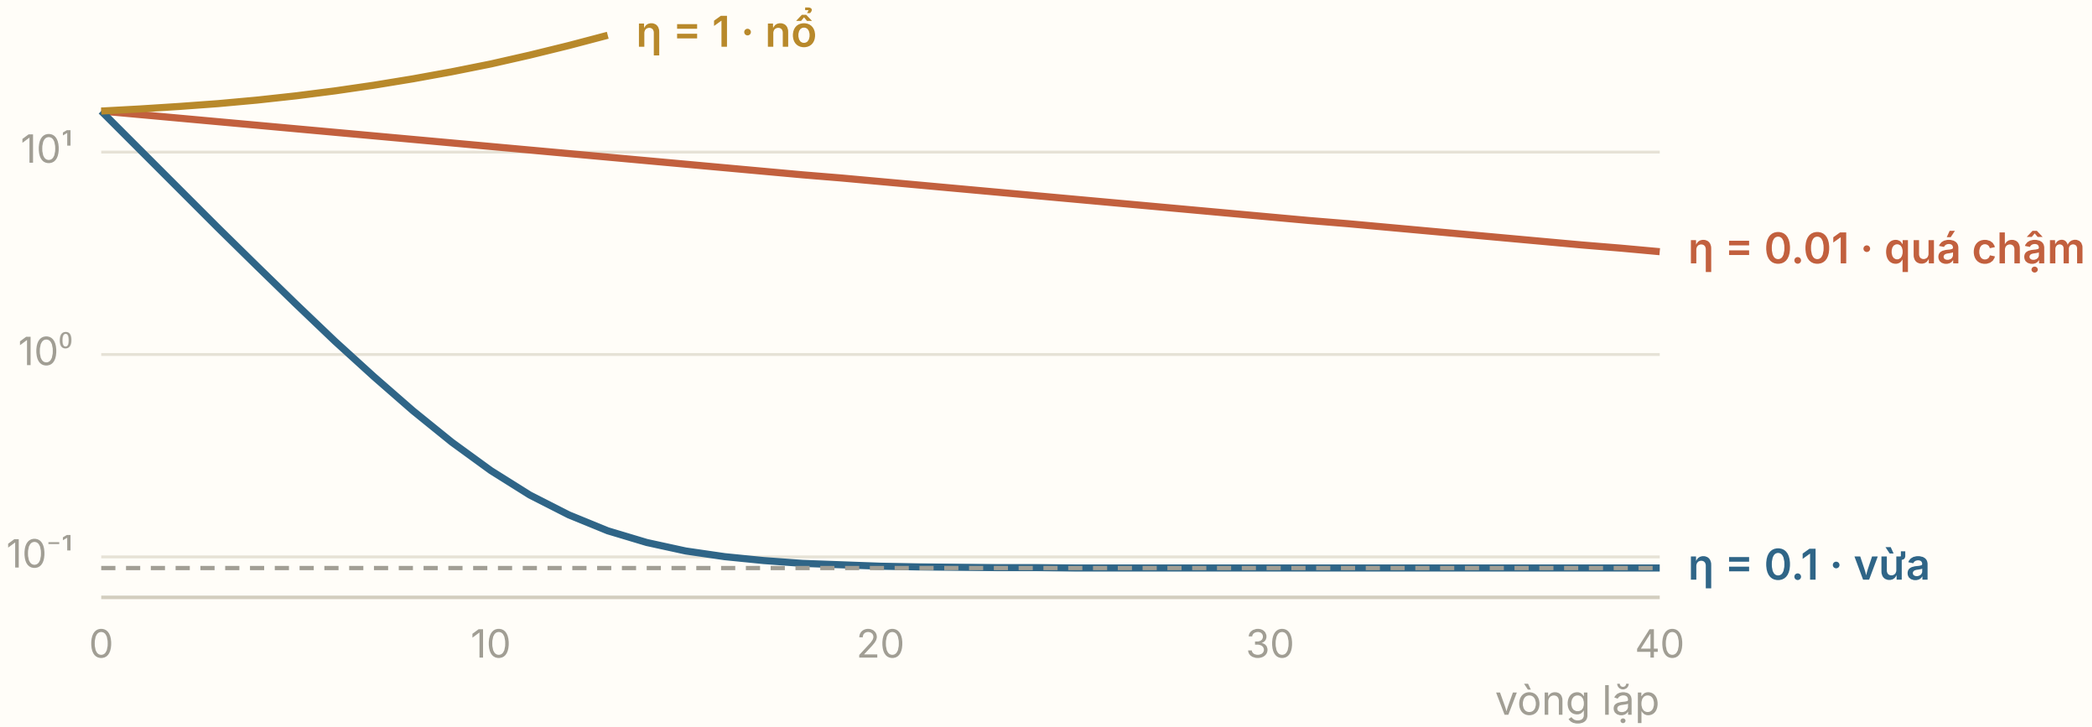
D Tăng số vòng để loss có thời gian ổn định

Chuẩn hóa đặc trưng

	Dữ liệu gốc	Đã chuẩn hóa
Số điều kiện		
Ngưỡng		
Số vòng tới sát đáy	~180 000	28

tính trên tập train, dùng lại cho test.

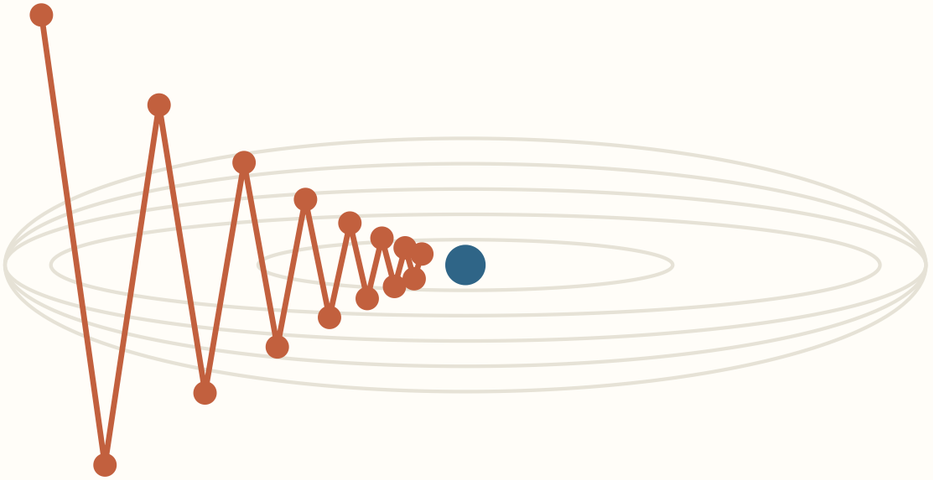
Sau chuẩn hóa: ba learning rate



Loss theo vòng lặp (thang log) với ba learning rate.

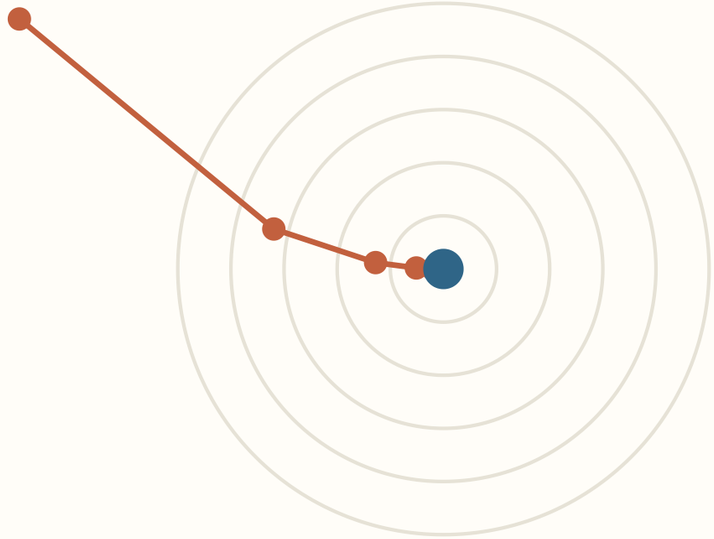
Thung lũng hẹp thành cái bát tròn

chưa chuẩn hóa



zigzag trong thung lũng hẹp

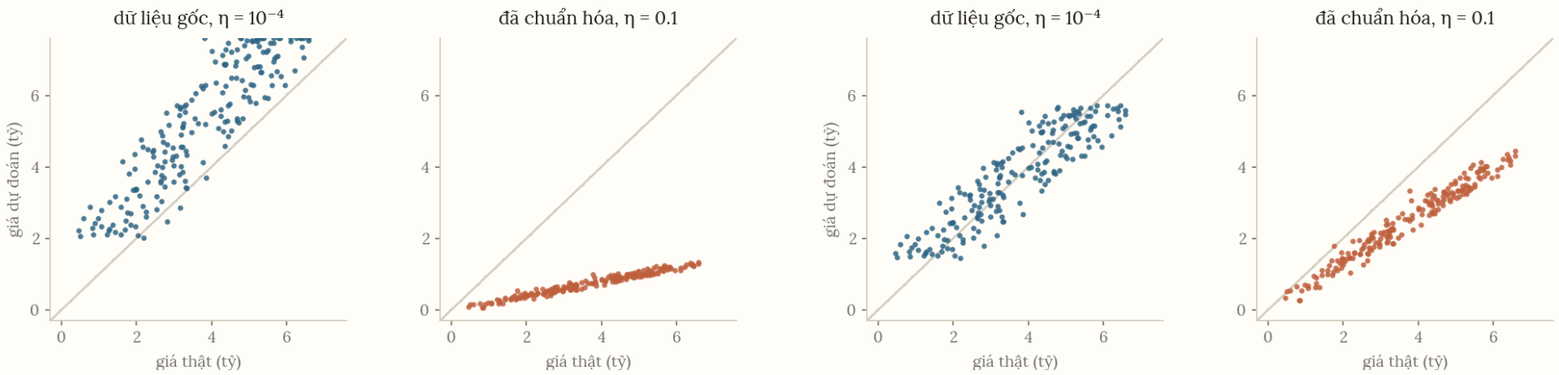
đã chuẩn hóa



đi gần thẳng về đáy

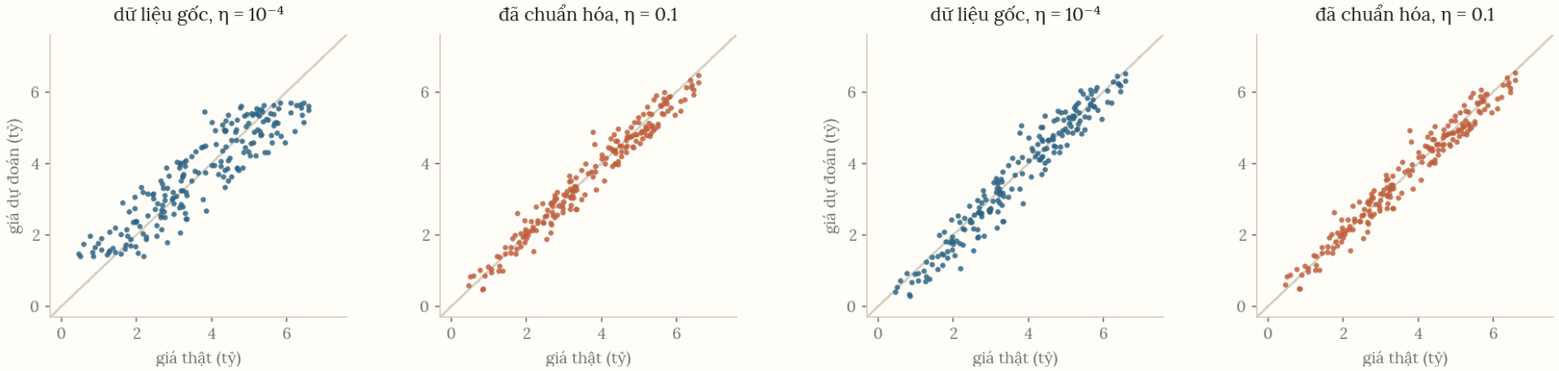
Chênh thang đo tạo thung lũng hẹp; chuẩn hóa đưa về gần tròn.

Cùng gradient descent, hai thang đo



vòng 1: MSE gốc 2.87, đã chuẩn hóa 10.2

vòng 5: MSE gốc 0.451, đã chuẩn hóa 1.77



vòng 20: MSE gốc 0.41, đã chuẩn hóa 0.0901

vòng 1000: MSE gốc 0.154, đã chuẩn hóa 0.0881

Cùng gradient descent trên 200 căn hộ: dữ liệu gốc tiến nhanh vài vòng đầu rồi gần như đứng yên; dữ liệu đã chuẩn hóa về sát đường chéo sau khoảng 20 vòng.

HỎI NHANH

Chuẩn hóa feature rồi học lại cho tới khi MSE chạm đáy. So với mô hình học trên dữ liệu gốc, cái gì thay đổi?

A Dự đoán chính xác hơn, vì thang đo tốt hơn

B Trọng số giữ nguyên, chỉ bias đổi theo trung bình

C Dự đoán y hệt, chỉ cách viết trọng số và tốc độ của gradient descent đổi

D `LinearRegression` của scikit-learn cũng hội tụ nhanh hơn

06

Thực hành và đọc kết quả

Dùng scikit-learn

```
X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.2, random_state=0)
model = LinearRegression().fit(X_tr, y_tr)
print(model.score(X_tr, y_tr),
      model.score(X_te, y_te))
```

KẾT QUẢ

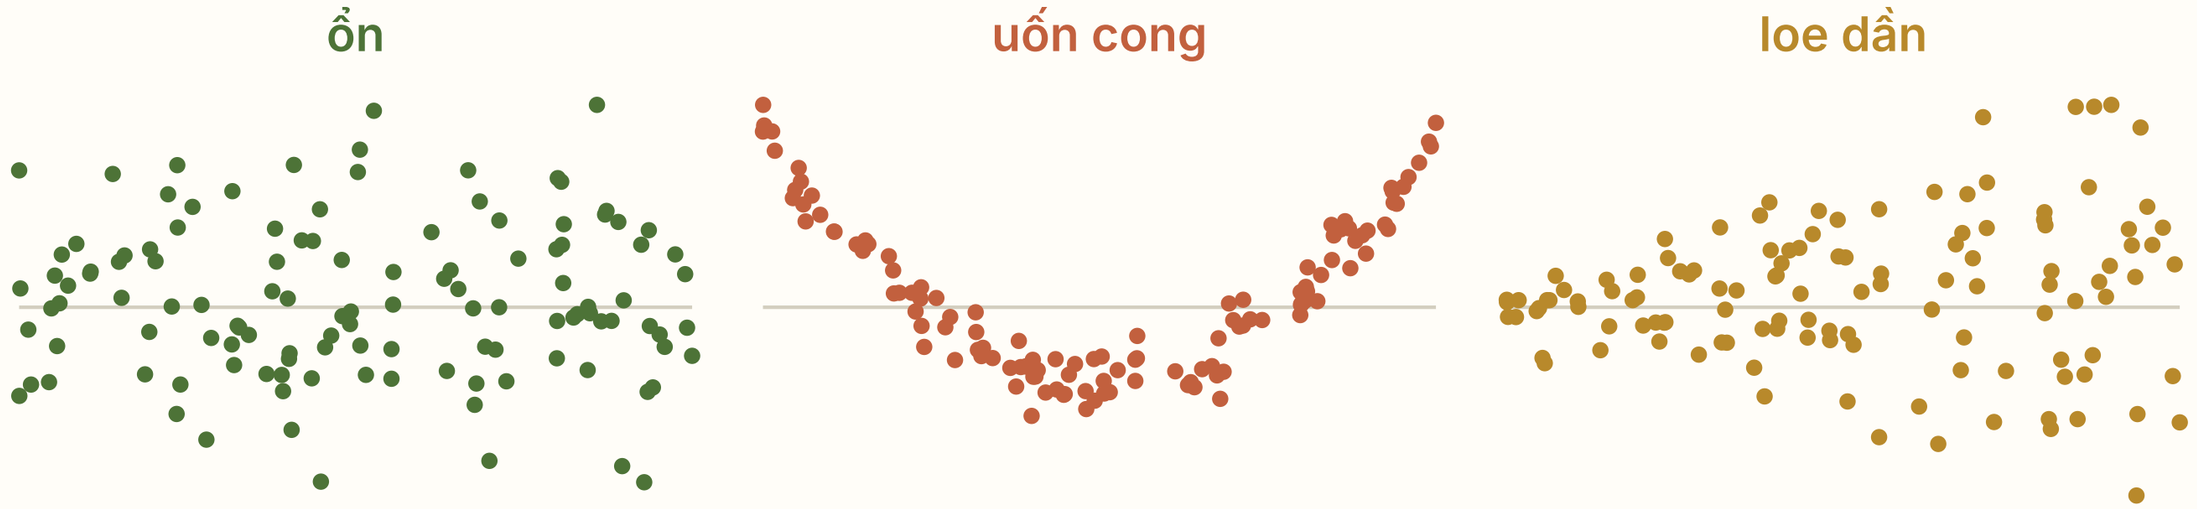
```
0.9604123189943734 0.9689505848749018
```

Hai số là train và test; hệ số trùng code tự viết.

Đọc hệ số cho đúng:

- Hệ số phụ thuộc đơn vị; muốn so sánh thì chuẩn hóa trước.
- Hệ số là mối liên hệ khi giữ các biến khác cố định, **không phải nhân quả**.
- Luôn vẽ phần dư theo dự đoán.

Đồ thị phần dư



Phần dư tốt rải đều quanh 0; uốn cong hay loe dần là có vấn đề.

HỎI NHANH

Linear regression cho hệ số dương giữa số kem bán ra và số vụ đuối nước mỗi tuần. Chỉ từ kết quả này, ta kết luận được gì?

A Giảm bán kem sẽ giảm số vụ đuối nước đúng theo hệ số

B Ăn kem làm tăng nguy cơ đuối nước khi bơi

C Nhiệt độ chắc chắn là nguyên nhân duy nhất của cả hai

D Hai đại lượng cùng tăng, còn tác động của kem thì chưa biết

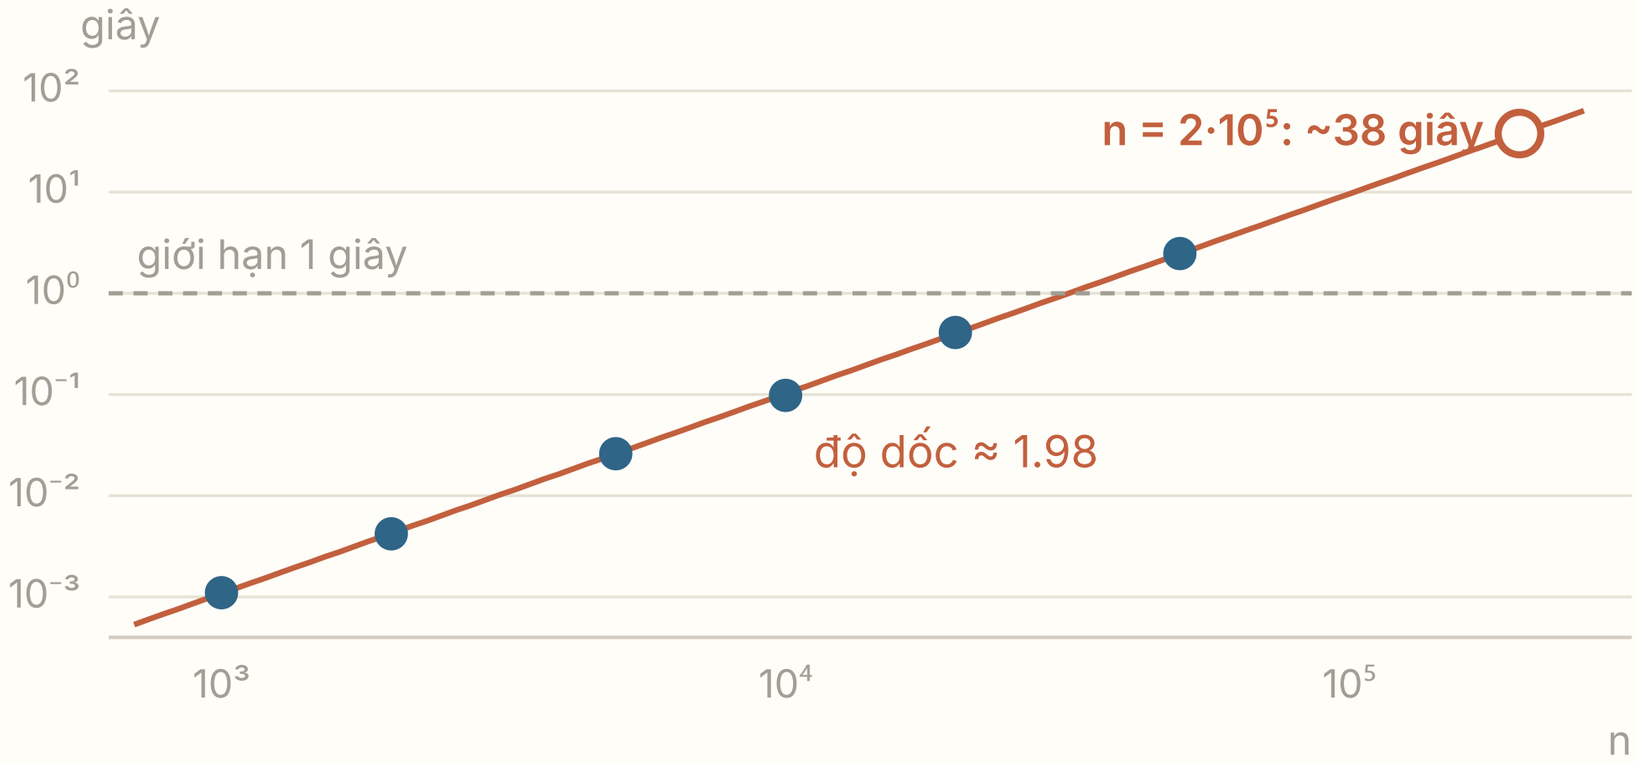
Đoán độ phức tạp trước khi nộp

“Tuyến tính” là theo tham số; đặc trưng có thể là , , .

Nếu thì

Hồi quy trên trục log–log: hệ số góc , gợi tăng gần bậc hai trong miền đo. Với : ngoại suy khoảng 38 giây; chưa là chứng minh Big-O.

Độ dốc trên trục log–log



Trục log–log: độ dốc gần 2 nghĩa là thời gian tăng theo n^2.

HỎI NHANH

Sau khi tạo thêm feature, mô hình nào **không** giải được bằng code linear regression của bài này?

A

B

C

D

Khi đi thi

- `LinearRegression` trước để có mốc.
- Loss nổ: chuẩn hóa trước, chỉnh learning rate sau.
- Tự viết gradient thì kiểm sai phân.

07

Luyện đề

LUYỆN ĐỀ 1

Với , gradient theo là gì?

A —

B —

C —

D —

ĐỀ THI USA-NA-AIO 2026 · Vòng 1 · Part 4.2

LUYỆN ĐỀ 2

Công thức nghiệm dùng được khi nào?

A Luôn luôn, với mọi ma trận dữ liệu

B Khi vuông, tức số mẫu bằng số cột

C Khi các cột của độc lập tuyến tính

D Khi đối xứng qua đường chéo

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 34

LUYỆN ĐỀ 3

Hệ phương trình chuẩn của một bộ dữ liệu có số điều kiện cỡ . Vì sao điều này đáng lo khi giải bằng máy?

A Ma trận chắc chắn suy biến, nên hệ vô nghiệm

B Định thức cỡ nên phép tính bị tràn số

C Ma trận có quá nhiều phần tử khác 0 nên chạy chậm

D Sai số nhỏ ở dữ liệu có thể thành sai số lớn ở nghiệm

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 35

Chốt ý

Linear regression cực tiểu MSE; nghiệm đóng là phép chiếu vuông góc.

Gradient descent cần ; chuẩn hóa đặc trưng làm bài toán dễ hơn nhiều.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook: đổi learning rate, thử bỏ bước chuẩn hóa, xem kết quả đổi ra sao.