Regularization

Khi mô hình học thuộc thay vì học quy luật

Chương 2 · Bài 2.2

Bảng dữ liệu rộng hơn

Vẫn định giá căn hộ, nhưng thêm **30 cột** kiểu số chữ cái trong tên chủ nhà: không cột nào liên quan tới giá.

Chỉ có **40 căn** để học, 60 căn để kiểm tra.

Linear regression sẽ dùng 30 cột rác này thế nào?

Và làm sao bắt nó bỏ qua chúng?

Mục tiêu

- Nhận ra overfitting qua chênh lệch điểm train và test.
- Dùng Ridge và Lasso; chọn mức phạt bằng cross-validation.
- Biết vì sao Lasso đưa được trọng số về 0 còn Ridge thì không.
- Đọc tham số `alpha`, `C` trong scikit-learn.

01

Khi mô hình học thuộc

Linear regression trên 40 căn

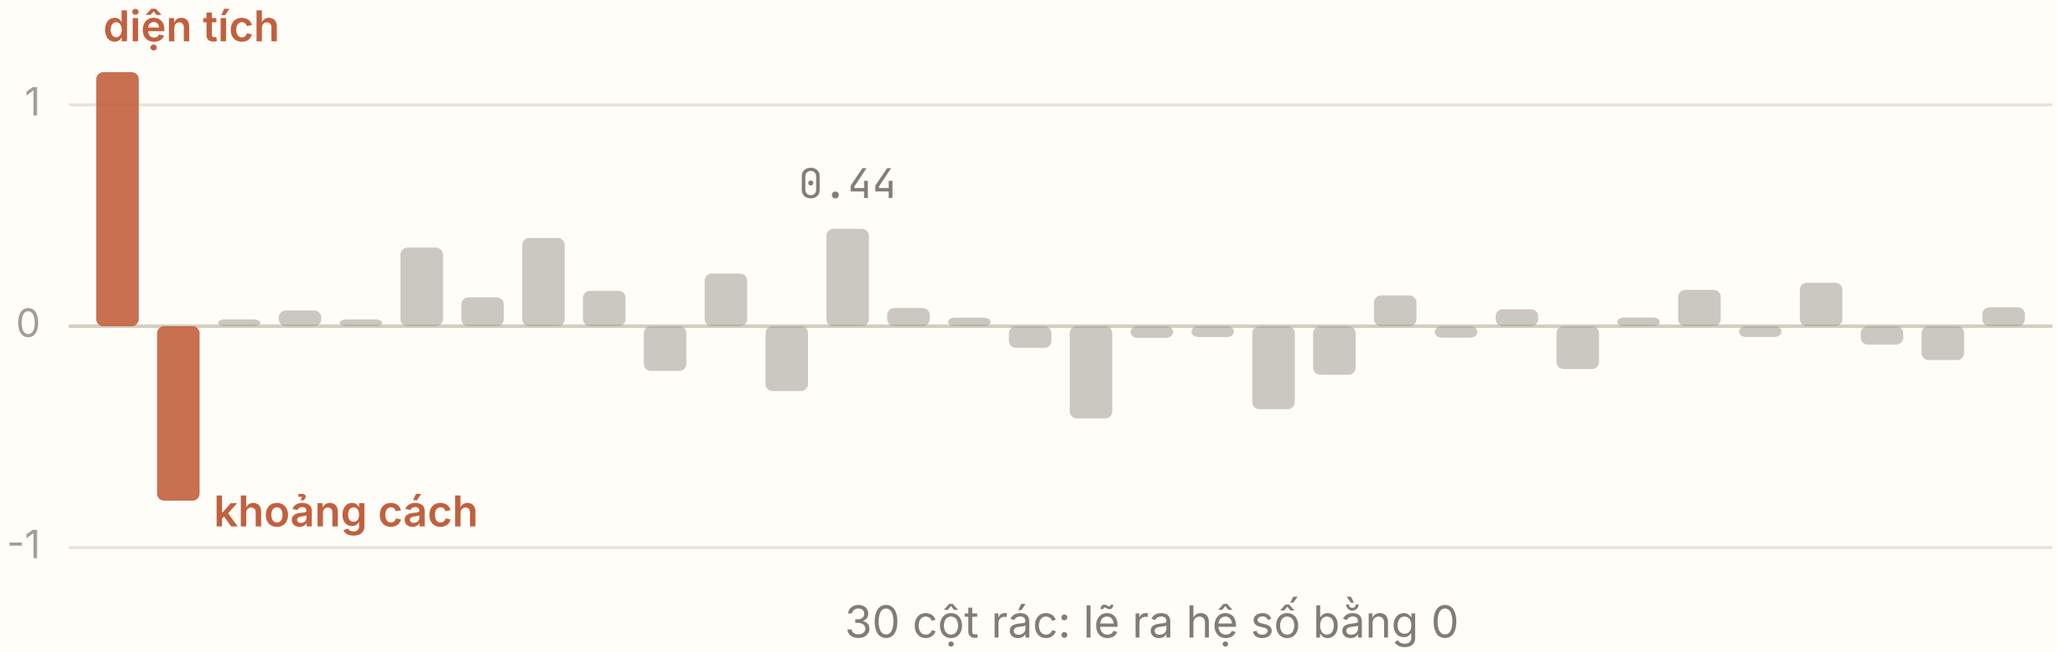
```
w, b = fit_ols(A_tr, y_tr)
print("R2 train:", round(r2(A_tr @ w + b, y_tr), 3),
      " R2 test:", round(r2(A_te @ w + b, y_te), 3))
print("2 hệ số thật:", w[:2].round(2),
      " |hệ số rác| lớn nhất:",
      np.abs(w[2:]).max().round(2))
```

KẾT QUẢ

```
R2 train: 0.985  R2 test: 0.349
2 hệ số thật: [ 1.15 -0.79]  |hệ số rác| lớn nhất: 0.44
```

- Train gần hoàn hảo, test tệ: **overfitting**.
- Cột rác nhận hệ số tới 0.44, cỡ một nửa hệ số của khoảng cách.
- 33 tham số cho 40 mẫu: đủ chỗ để khớp cả phần nhiễu của tập train.

Hệ số của 32 cột



Hệ số least squares trên 40 căn: cột rác cũng nhận trọng số đáng kể.

HỎI NHANH

Giữ nguyên 40 căn train, nhưng tăng số cột rác từ 30 lên 37. Khi đó có 39 hệ số cộng thêm bias, tức là 40 ẩn cho 40 căn. Không cần chạy code, R^2 trên train của least squares sẽ là bao nhiêu?

A Vẫn khoảng 0.985, vì cột rác không mang thông tin về giá

B Thấp hơn 0.985, vì thêm cột rác là thêm nhiễu

C Đúng bằng 1

D Chưa đoán được khi chưa biết giá trị các cột rác

02

Phạt độ lớn trọng số

Lỗi cộng phạt

$$J(\mathbf{w}, b) = \underbrace{\sum_i \left(\mathbf{w}^\top \mathbf{x}_i + b - y_i\right)^2}_{\text{khớp dữ liệu}} + \underbrace{\lambda\, \Omega(\mathbf{w})}_{\text{phạt độ lớn}}$$

Đặc trưng cùng thang đo: trọng số lớn làm dự đoán nhạy với dao động nhỏ, tức variance cao.

$\lambda = 0$: least squares · $\lambda \to \infty$: chỉ còn đoán trung bình · bias b không bị phạt

Ridge và Lasso

	Ridge (L2)	Lasso (L1)
Khoản phạt	$\sum_j w_j^2$	$\sum_j \lvert w_j \rvert$
Tác dụng	Co mọi trọng số về gần 0	Đưa nhiều trọng số về **đúng** 0
Hợp khi	Nhiều đặc trưng cùng có ích, có tương quan	Chỉ ít đặc trưng thật sự quan trọng

HỎI NHANH

Ridge có intercept không bị phạt. Giữ nguyên dữ liệu train và tăng mức phạt λ lên rất lớn. Dự đoán sẽ tiến dần về giá trị nào?

A Trung vị của `y_train`

B Giá trị hay gặp nhất của `y_train`

C Trung bình của `y_train`

D 0

03

Ridge

Nghiệm đóng

Trừ trung bình khỏi X và $\mathbf{y}$ để không phạt b:

$$\mathbf{w}^* = \left(X_c^\top X_c + \lambda I\right)^{-1} X_c^\top \mathbf{y}_c$$

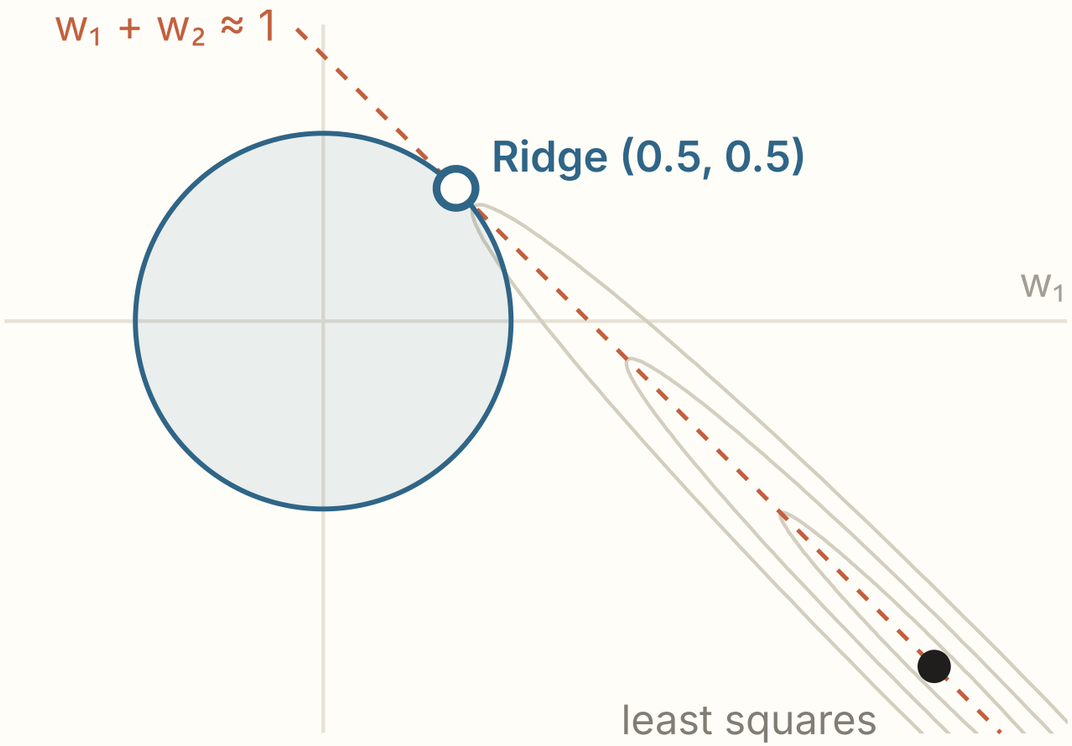
$$b = \bar{y} - \bar{\mathbf{x}}^\top \mathbf{w}$$

λI làm ma trận khả nghịch khi $\lambda > 0$: hai đặc trưng gần trùng nhau không còn cho $+500$ và -499.

```
def fit_ridge(A, y, lam):
    a_mean, y_mean = A.mean(axis=0), y.mean()
    Ac, yc = A - a_mean, y - y_mean
    w = np.linalg.solve(
        Ac.T @ Ac + lam * np.eye(A.shape[1]),
        Ac.T @ yc)
    return w, y_mean - a_mean @ w
```

Trùng `Ridge(alpha=lam)` của scikit-learn.

Hai cột gần trùng nhau



Hai đặc trưng gần trùng nhau: Ridge chọn điểm gần gốc nhất trên rãnh.

HỎI NHANH

Lấy nghiệm Ridge với $\lambda = 3$ làm điểm xuất phát, rồi chạy gradient descent của bài 2.1 trên tổng bình phương lỗi **không** có khoản phạt, với bước nhỏ và chạy đủ lâu. Trọng số sẽ đi về đâu?

A Đứng yên, vì nghiệm Ridge đã là điểm tối ưu

B Dịch dần về nghiệm least squares

C Dao động mãi quanh nghiệm Ridge

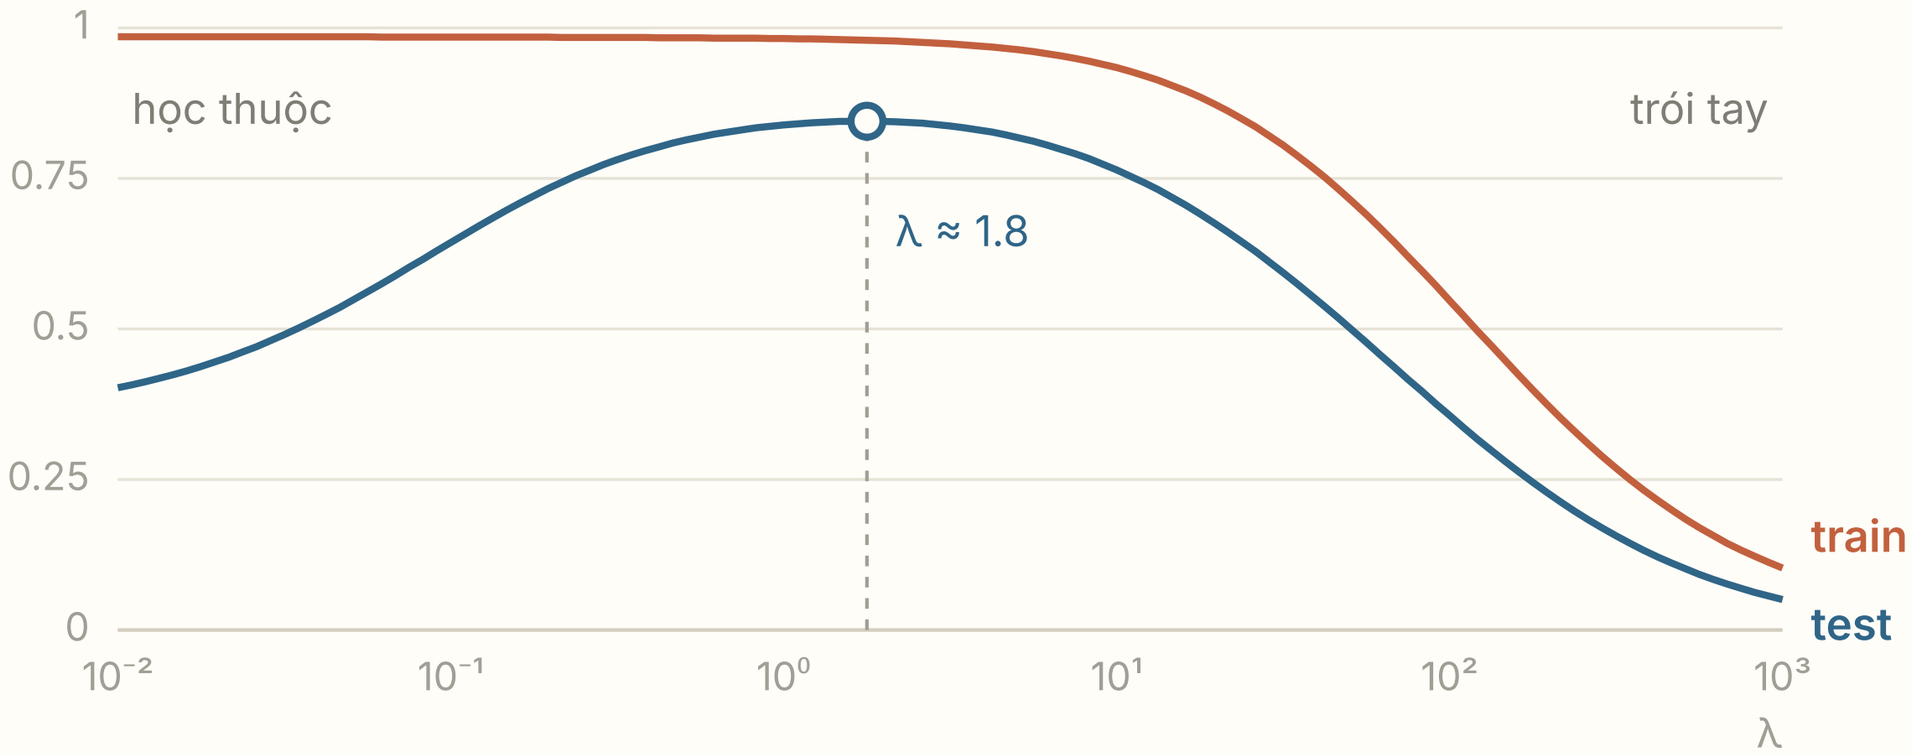
D Co dần về 0

PHỎNG THEO MIT 6.036 · Final, Spring 2022 · Q4(a), (d)

Thử nhiều mức phạt

λ	R^2 train	R^2 test
0	0.985	0.349
0.1	0.985	0.644
1	0.982	**0.839**
3	0.974	**0.839**
10	0.934	0.764
30	0.814	0.603
100	0.547	0.356

Đỉnh của R^2 test



Tăng λ thì R^2 train giảm đều; R^2 test lên đỉnh ở khoảng giữa rồi giảm.

HỎI NHANH

Ở dòng $\lambda = 100$ của bảng, R^2 trên train là 0.547, trên test là 0.356. Mô hình đang gặp vấn đề gì?

A Variance cao, vì vẫn còn học thuộc tập train

B Bias cao, vì phạt quá mạnh nên khớp không nổi cả tập train

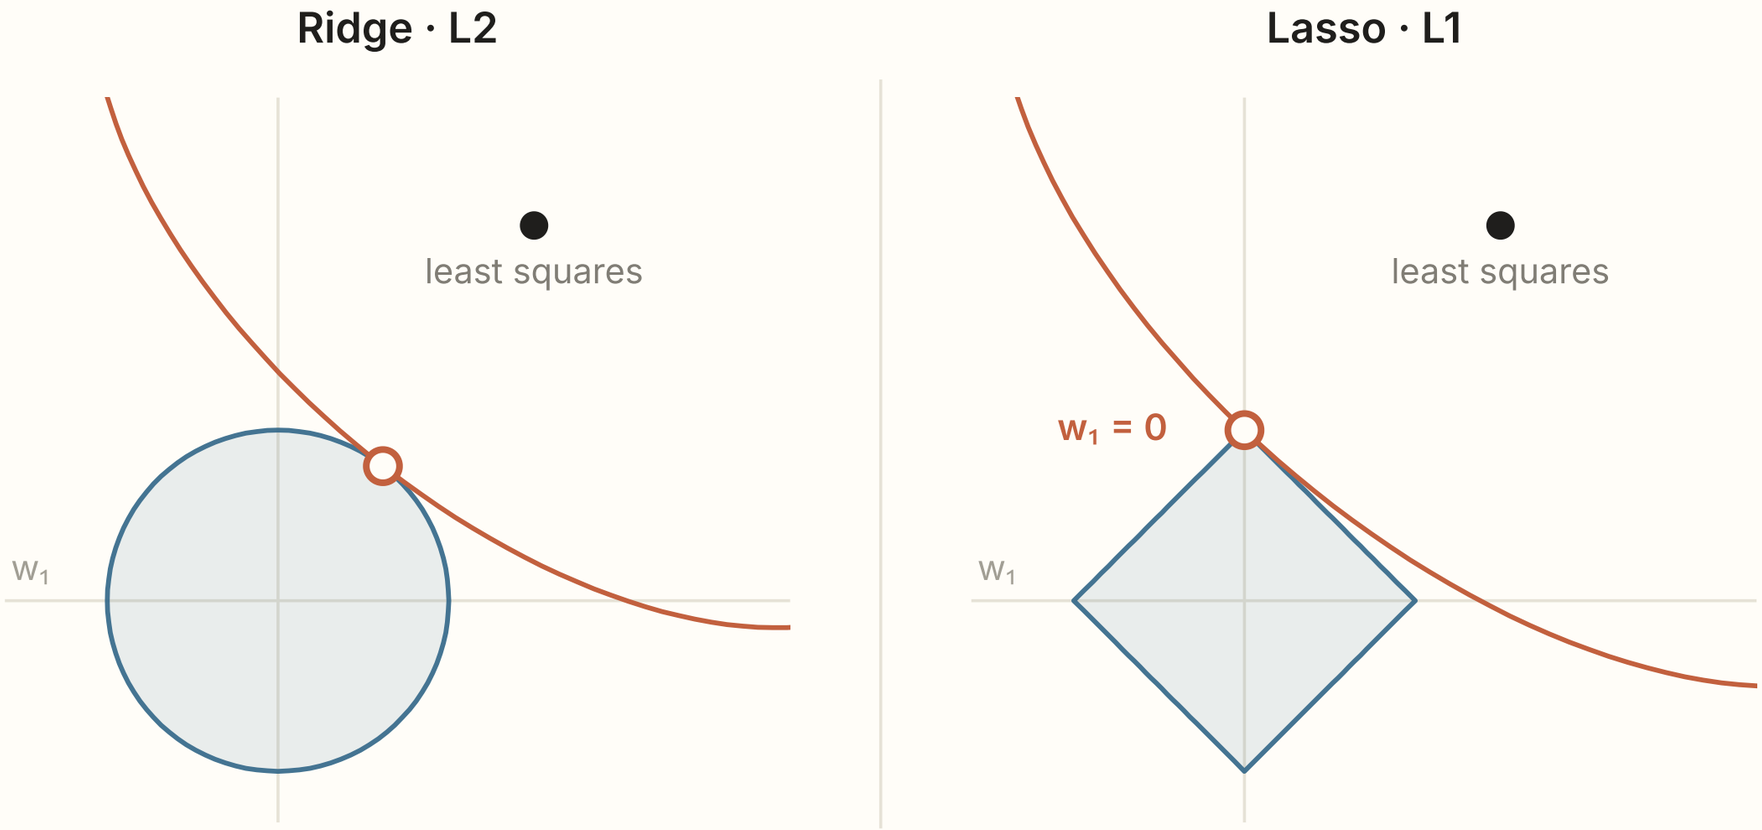
C Không có vấn đề gì, vì khoảng cách train và test đã nhỏ hơn ở $\lambda = 0$

D Dữ liệu test bị lỗi, vì điểm test thấp hơn ở $\lambda = 3$

04

Lasso

Vì sao L1 cho số 0: hình học



Đường đồng mức chạm hình thoi ở góc, nơi $w_1 = 0$.

Vì sao L1 cho số 0: tính thẳng

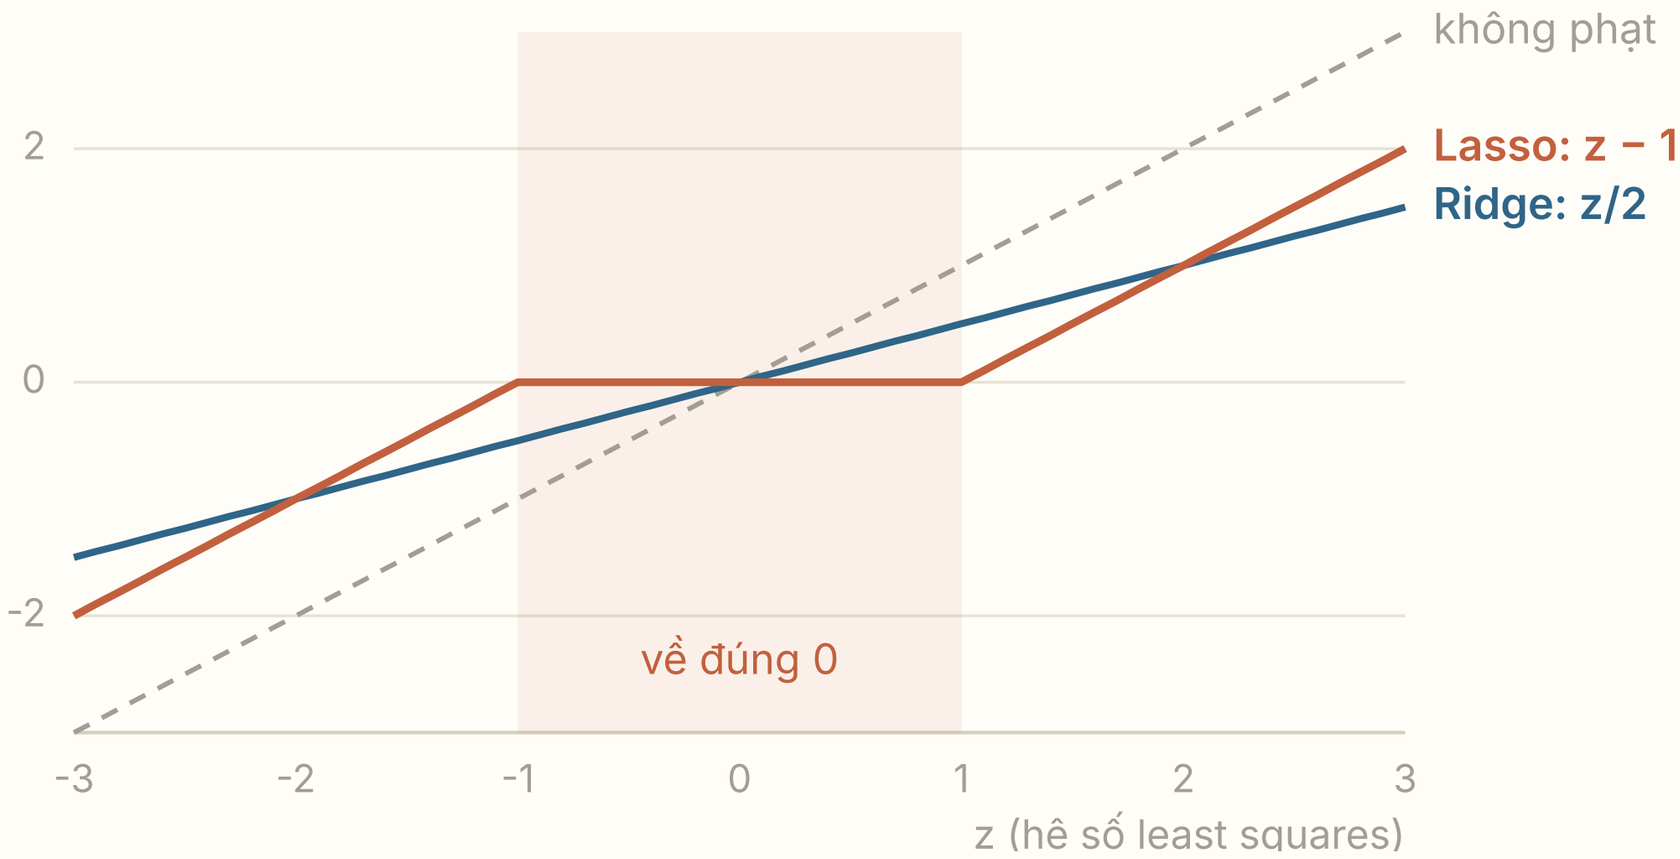
Các cột trực chuẩn, z_j là hệ số least squares. Lasso viết với $\frac{1}{2}$ trước phần lỗi:

$$w_j^{\text{ridge}} = \frac{z_j}{1+\lambda}$$

$$w_j^{\text{lasso}} = \text{sign}(z_j)\max\left(|z_j| - \lambda,\ 0\right)$$

Ridge co theo tỉ lệ. Lasso trừ đi λ rồi cắt về 0: **soft-thresholding**.

Soft-thresholding



Với λ = 1, Ridge chia đôi mọi hệ số; Lasso trừ 1 rồi cắt về 0 khi |z| ≤ 1.

HỎI NHANH

Lasso dùng hàm $\frac{1}{2}\|y - Xw\|^2 + \lambda\|w\|_1$, với $X^\top X = I$. Một hệ số least squares bằng $z = 0.8$, và $\lambda = 1$. Hệ số Lasso tương ứng bằng bao nhiêu?

A 0

B 0.8

C 0.4

D -0.2

Bài tập trên lớp

$\mathbf{z} = (3,\ 0.5,\ -1.2)$, $\lambda = 1$, các cột trực chuẩn.

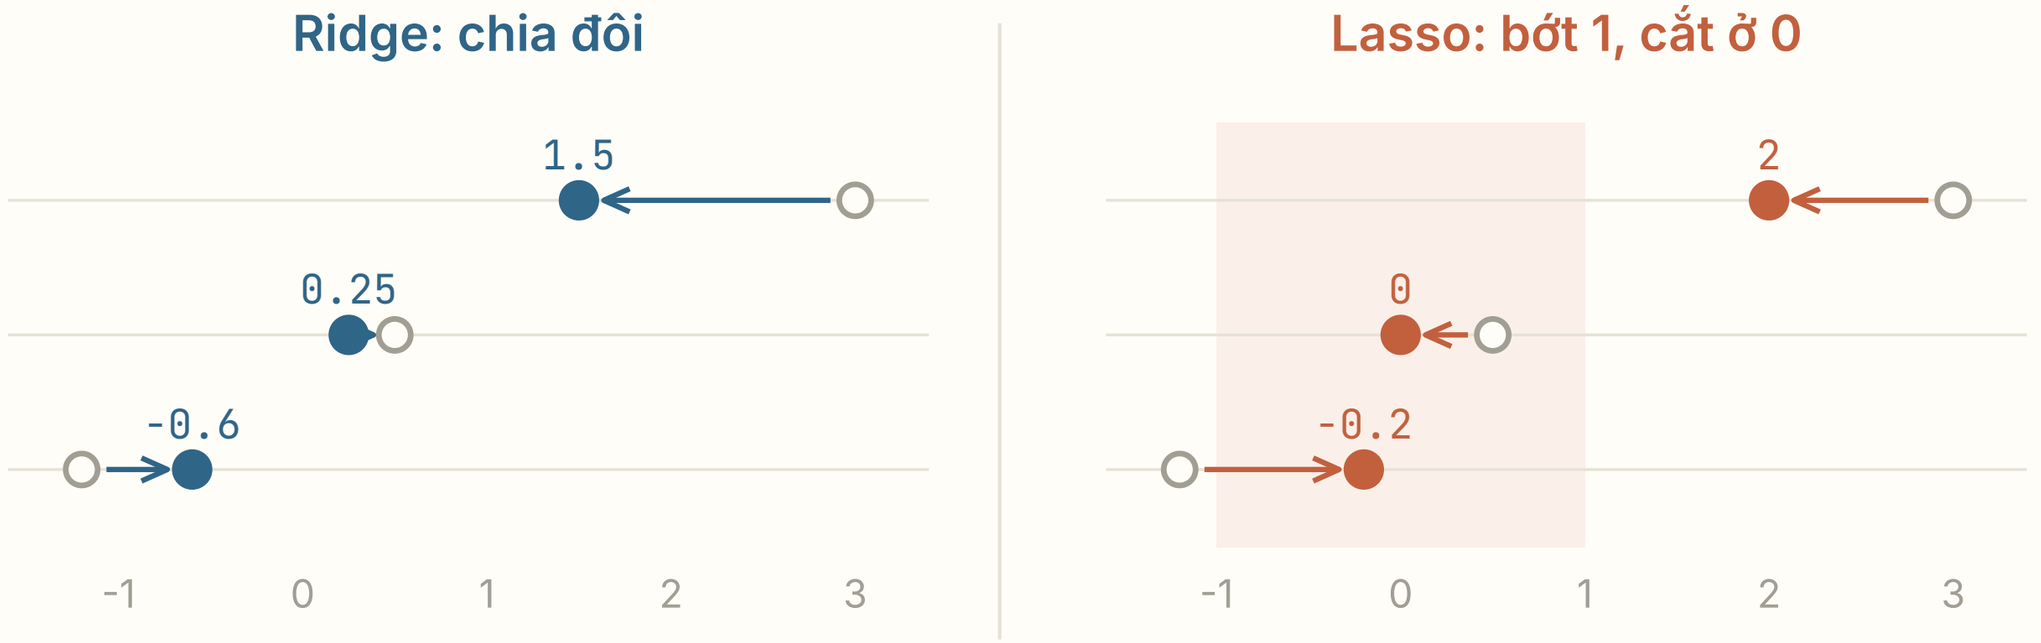
Tính hệ số Ridge và Lasso.

Ridge: $\mathbf{w} = (1.5,\ 0.25,\ -0.6)$

Lasso: $\mathbf{w} = (2,\ 0,\ -0.2)$

Ridge giảm mọi hệ số một nửa. Lasso loại đặc trưng thứ hai, hai đặc trưng còn lại mất đúng 1 đơn vị.

Đáp án trên trục số



Vòng rỗng là z, chấm đặc là hệ số sau khi phạt.

HỎI NHANH

Vẫn $\mathbf{z} = (3,\ 0.5,\ -1.2)$, các cột trực chuẩn. Với Lasso, λ nhỏ nhất bằng bao nhiêu thì **cả ba** hệ số đều bằng 0?

A 0.5

B 1.2

C 3

D Không có, vì Lasso luôn giữ ít nhất một feature

Coordinate descent

Lần lượt tối ưu từng w_j; mỗi bước là một phép soft-thresholding.

```
for j in range(len(w)):
    r_j = yc - Ac @ w + Ac[:, j] * w[j]
    w[j] = soft(Ac[:, j] @ r_j, lam) / col_sq[j]
```

Với $\lambda = 8$ trên dữ liệu căn hộ:

KẾT QUẢ

```
giữ lại các cột: [0 1]  hệ số: [ 1.037 -0.408]
R2 test: 0.891
```

Giữ đúng diện tích và khoảng cách, loại cả 30 cột rác. Không ai nói cho nó biết cột nào là rác.

05

Chọn mức phạt và chuẩn hóa

Cross-validation trên lưới log

Bảng λ ở mục Ridge đã nhìn tập test: chỉ để quan sát. Muốn chọn thật thì dùng CV trên tập train; scaler nằm trong Pipeline nên được fit lại trong từng fold.

```
# estimator: Ridge() hoặc Lasso(max_iter=10000)
pipeline = make_pipeline(StandardScaler(), estimator)
search = GridSearchCV(pipeline, {step_name + "__alpha": alpha_grid}, cv=5)
search.fit(X_tr, y_tr)
```

KẾT QUẢ

```
Ridge: alpha = 3.162  R2 test = 0.837  số hệ số khác 0 = 32
Lasso: alpha = 0.03162  R2 test = 0.925  số hệ số khác 0 = 14
```

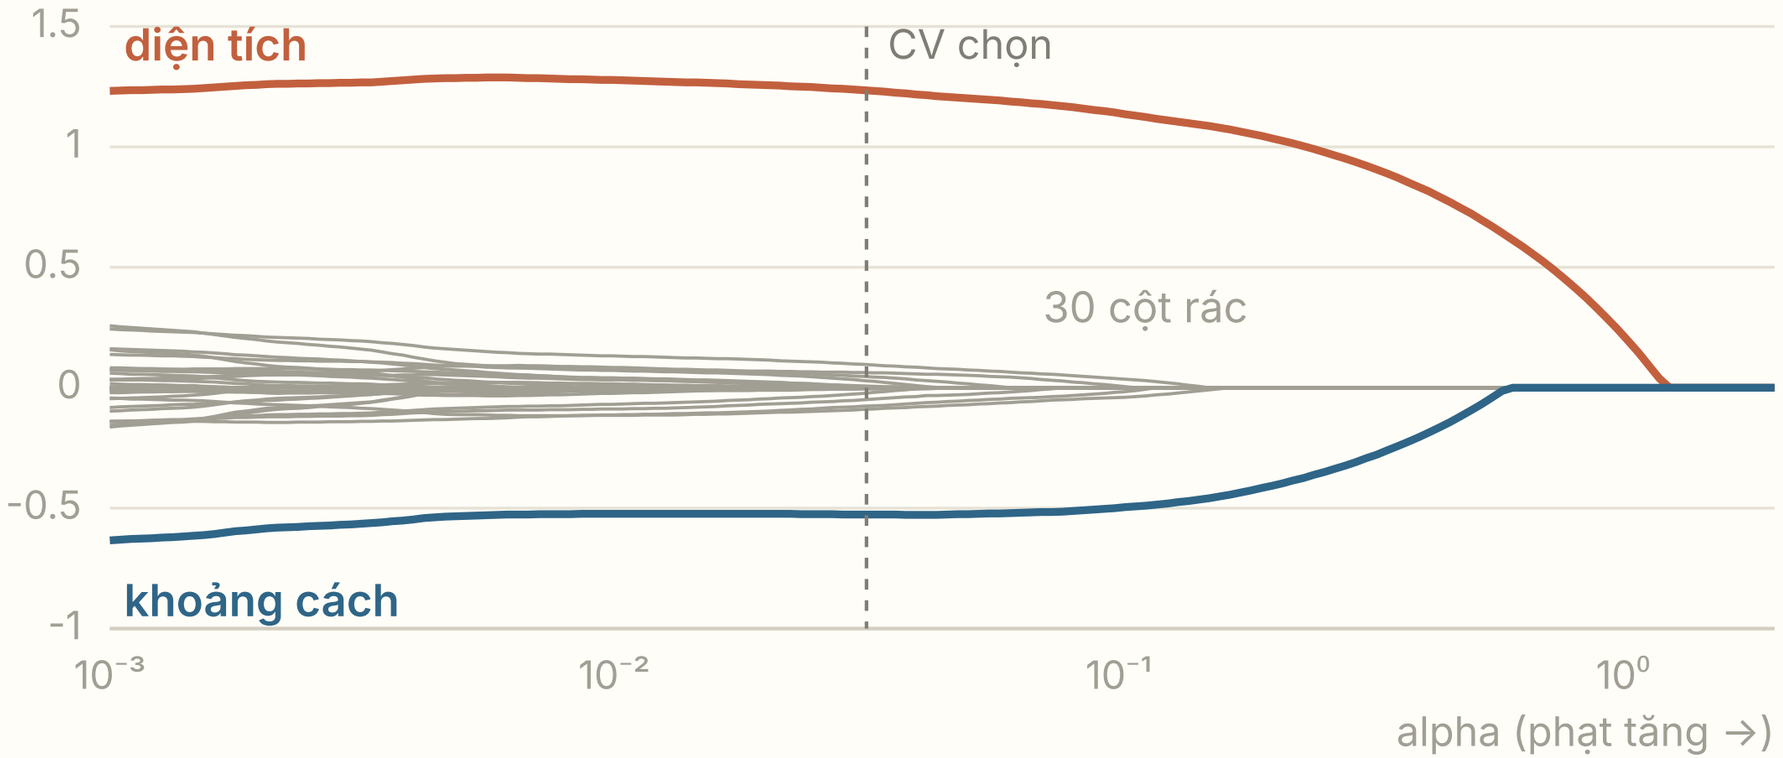
Ridge chọn đúng vùng λ từ 1 đến 3, lần này không cần nhìn test.

Loại sạch rác chưa chắc tốt nhất

	Lasso λ = 8	Lasso do CV chọn
Cột rác giữ lại	0	12, đều dưới 0.1
Hai hệ số thật	1.037 và −0.408	1.234 và −0.527
R^2 test	0.891	**0.925**

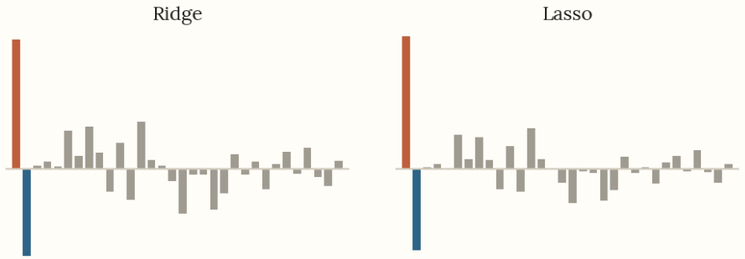
Một λ chung phạt mọi hệ số như nhau: muốn ép hết rác về 0 thì hệ số thật cũng bị co. Cross-validation tối ưu điểm dự đoán, không cam kết tìm đúng tập đặc trưng thật.

Regularization path

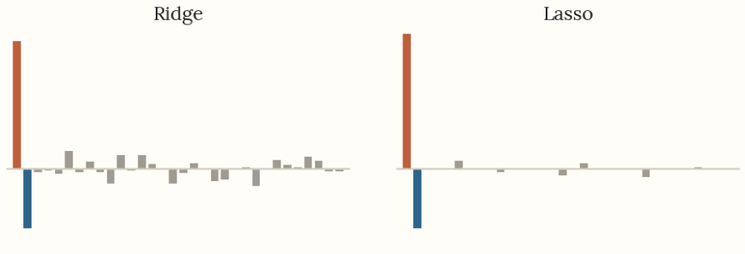


Phạt càng mạnh, cột rác về 0 trước, hai cột thật về 0 sau cùng.

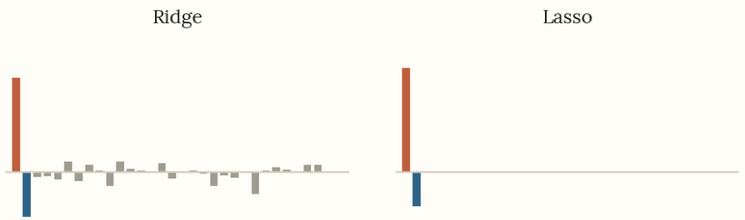
Ridge co, Lasso cắt



λ = 0.01: R^2 test Ridge 0.40, Lasso 0.59; Lasso còn 31/32 hệ số khác 0



λ = 2: R^2 test Ridge 0.84, Lasso 0.93; Lasso còn 8/32 hệ số khác 0



λ = 12: R^2 test Ridge 0.74, Lasso 0.84; Lasso còn 2/32 hệ số khác 0



λ = 80: R^2 test Ridge 0.40, Lasso -0.01; Lasso còn 0/32 hệ số khác 0

Hệ số của Ridge và Lasso khi λ tăng (cam: diện tích, xanh: khoảng cách, xám: 30 cột rác): Ridge co đều, Lasso đưa từng hệ số về đúng 0.

HỎI NHANH

Lasso với $\lambda = 8$ loại sạch 30 cột rác, còn Lasso do cross-validation chọn vẫn giữ 12 cột rác. Vậy mà bản thứ hai lại dự đoán tốt hơn trên test, 0.925 so với 0.891. Vì sao?

A Vì phạt mạnh cũng co cả hai hệ số thật, gây bias lớn

B Vì 12 cột rác ấy thật ra có liên quan đến giá

C Vì cross-validation đã nhìn thấy tập test

D Vì mô hình có nhiều feature hơn luôn dự đoán tốt hơn

Chuẩn hóa trước khi phạt

Đổi khoảng cách từ km sang m: hệ số nhỏ đi 1000 lần, khoản phạt w^2 nhỏ đi 10^6 lần.

KẾT QUẢ

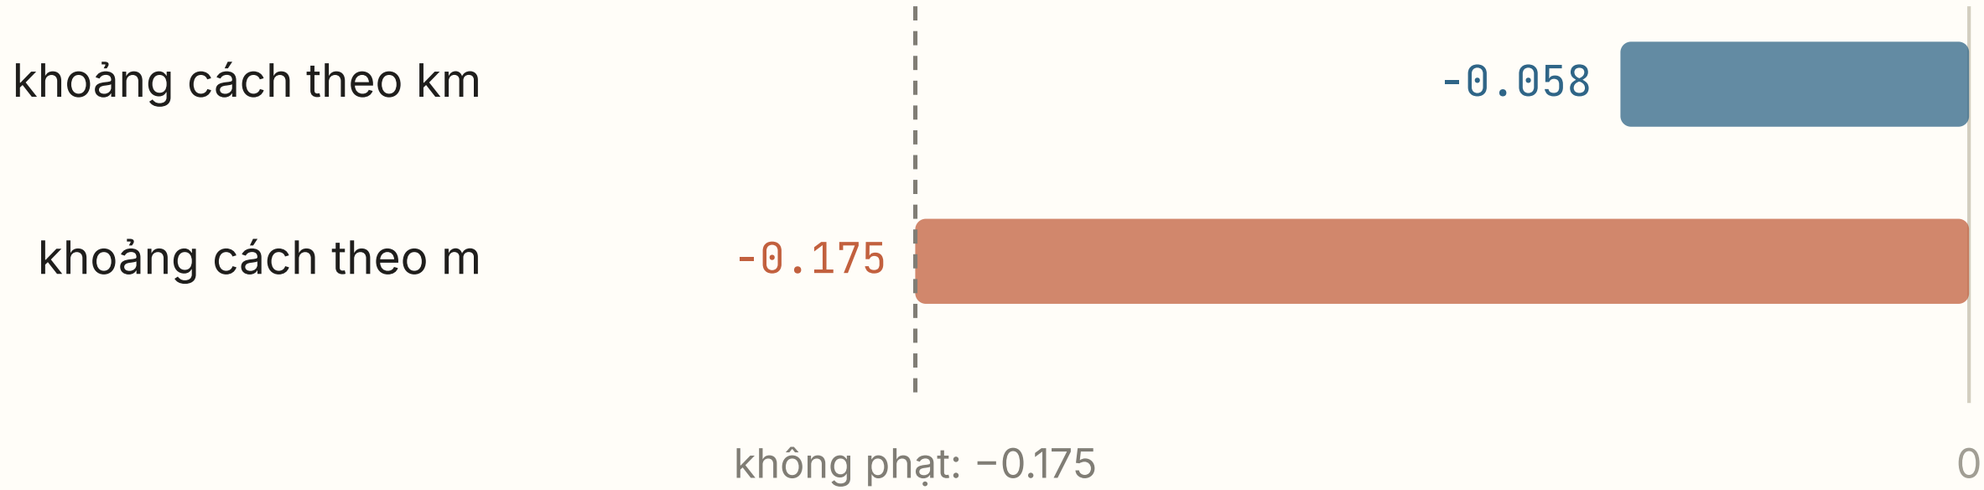
```
khoảng cách theo km: hệ số quy về mỗi km = -0.058
khoảng cách theo  m: hệ số quy về mỗi km = -0.175
```

Cùng dữ liệu, cùng λ, chỉ đổi đơn vị.

Mức phạt phụ thuộc đơn vị, không phụ thuộc mức quan trọng.

`make_pipeline(StandardScaler(), Ridge())` để cross-validation chuẩn hóa đúng trên từng fold.

Cùng λ, khác đơn vị



Cùng Ridge, chỉ đổi km sang m: hệ số gần như không còn bị phạt.

HỎI NHANH

Đổi một feature từ km sang m mà vẫn giữ nguyên dự đoán, thì hệ số của feature ấy giảm 1000 lần. Nếu giữ nguyên λ, khoản phạt L2 trên riêng hệ số này thay đổi thế nào?

A Giảm 1000 lần

B Tăng 1 000 000 lần

C Không đổi

D Giảm 1 000 000 lần

Tên gọi trong scikit-learn

Lớp	Hàm mất mát	Tham số phạt
`Ridge`	$\sum r_i^2 + \alpha \lVert \mathbf{w} \rVert_2^2$	`alpha` $= \lambda$
`Lasso`	$\frac{1}{2n} \sum r_i^2 + \alpha \lVert \mathbf{w} \rVert_1$	`alpha` $= \lambda / n$
`LogisticRegression`, `SVC`	$C \sum \text{loss}_i + \frac{1}{2} \lVert \mathbf{w} \rVert_2^2$	`C` tỉ lệ nghịch với λ

Dòng `Lasso` so với quy ước $\frac{1}{2} \sum r_i^2 + \lambda \lVert \mathbf{w} \rVert_1$ của bài. Chép `alpha` từ `Ridge` sang `Lasso` là sai thang đo.

HỎI NHANH

So `LogisticRegression(C=0.01)` với `LogisticRegression(C=100)`. Khác nhau thế nào?

A `C=0.01` phạt mạnh hơn, trọng số nhỏ hơn

B `C=0.01` phạt yếu hơn, trọng số lớn hơn

C Như nhau, vì `C` chỉ ảnh hưởng tốc độ

D `C` là số vòng lặp

06

Mở rộng và tổng kết

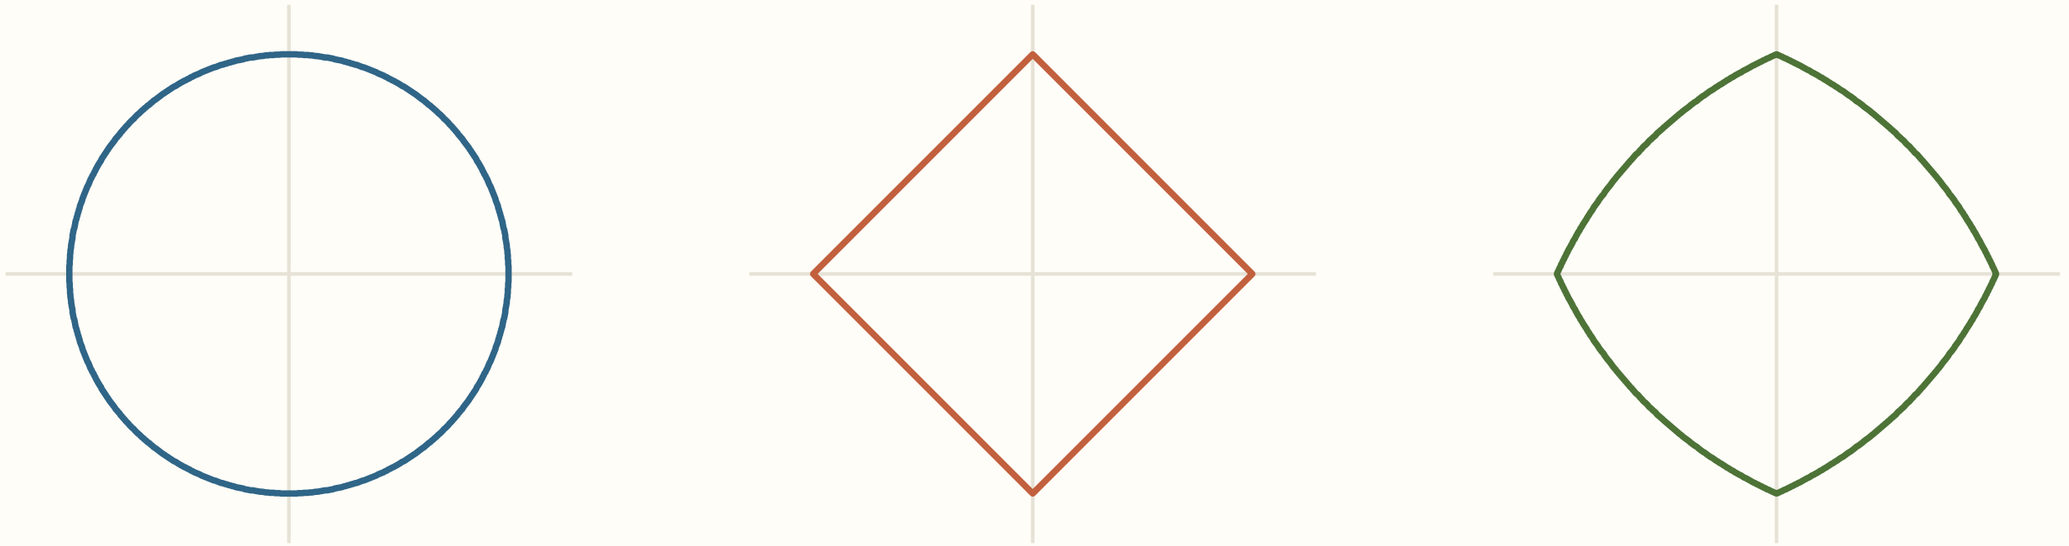
Elastic Net

$$\lambda \left(\rho \|\mathbf{w}\|_1 + \frac{1-\rho}{2} \|\mathbf{w}\|_2^2 \right)$$

Vẫn thưa như L1, nhưng phần L2 giữ được cả nhóm đặc trưng tương quan.

$\rho = 1$: Lasso · $\rho = 0$: Ridge · trong scikit-learn, ρ là `l1_ratio`

Ba vùng ràng buộc



Elastic Net có góc như Lasso, cạnh cong như Ridge.

HỎI NHANH

Có ba cột gần trùng nhau, cùng đo một thứ và cùng có ích, cộng thêm vài cột nhiễu. Elastic Net với `l1_ratio=0.5` thường làm gì với ba cột ấy?

A Bỏ cả ba, vì phạt L1 cộng L2 mạnh hơn Lasso

B Giữ đúng một cột như Lasso, vì vẫn còn phần L1

C Giữ cả ba, với hệ số lớn hơn của least squares

D Giữ cả ba, với hệ số chia gần đều cho nhau

Regularization ở khắp nơi

- C trong logistic regression (2.3) và SVM (2.8).
- Độ sâu tối đa, số mẫu tối thiểu ở lá của decision tree (2.5).
- Phạt L1, L2 trên giá trị lá trong XGBoost, LightGBM (2.7).
- Weight decay, dropout, early stopping trong mạng neural (3.6).

Khi đi thi

- `alpha`, `C` trên thang log.
- Chuẩn hóa và model chung một Pipeline.
- Nhiều cột rác: Lasso xem cột nào còn lại.

07

Luyện đề

LUYỆN ĐỀ 2

Một bộ dữ liệu y khoa có 50 bệnh nhân, mỗi người đo 100 chỉ số. Một mô hình phân loại tuyến tính đúng 98% trên train, tức 49/50, nhưng chỉ đúng 62% trên validation, và gần như mọi trọng số đều khác 0. Đâu là chẩn đoán đúng nhất?

A Underfitting, vì 50 mẫu quá ít để mô hình nào học được

B Lệch lớp, nên mô hình chỉ đoán lớp đông hơn

C Các chỉ số khác đơn vị nên thuật toán không hội tụ

D Overfitting, vì 100 trọng số cho 50 mẫu là đủ chỗ học thuộc

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 269

LUYỆN ĐỀ 3

Một bạn học Ridge, thử $\lambda = 0.01, 0.1, 1, 10$, so lỗi trên train, validation và test, rồi chọn $\lambda = 0.01$ vì lỗi **test** thấp nhất. Thấy lỗi test tăng dần từ $\lambda = 0.01$ đến 10, bạn ấy định thử thêm $\lambda = 0.0001$ và 0.001 để tìm mô hình tốt hơn. Nhận xét nào đúng nhất?

A Hợp lý, vì lỗi test đang giảm về phía λ nhỏ

B Mở rộng thì được, nhưng phải chọn bằng lỗi validation

C Không cần thử, vì λ dưới 0.01 chắc chắn overfit

D Nên thử λ lớn hơn 10, vì phạt mạnh luôn an toàn hơn

PHỎNG THEO CMU 10-601 · Practice Problems, Exam 2 · Q3.3

LUYỆN ĐỀ 4

Một đội đã giải nhiều bài cùng dạng và thấy trọng số tốt nhất thường nằm gần $\mathbf{w}_0 = (1, 1, \ldots, 1)$. Bài mới chỉ có rất ít dữ liệu. Hàm mục tiêu nào tận dụng kinh nghiệm ấy hợp lý nhất?

A $\sum_i (\mathbf{w}^\top \mathbf{x}_i - y_i)^2 + \lambda \|\mathbf{w} - \mathbf{w}_0\|_2^2$

B $\sum_i (\mathbf{w}^\top \mathbf{x}_i - y_i)^2 + \lambda \|\mathbf{w}\|_2^2$

C $\sum_i (\mathbf{w}^\top \mathbf{x}_i - y_i)^2$, vì kinh nghiệm cũ không đưa vào mô hình được

D $\sum_i (\mathbf{w}^\top \mathbf{x}_i - y_i)^2 + \lambda \|\mathbf{w}\|_1$

PHỎNG THEO MIT 6.036 · Final, Spring 2022 · Q4(e)

Chốt ý

Phạt độ lớn trọng số để mô hình bớt học thuộc; chọn λ bằng cross-validation trên thang log.

Ridge co mọi hệ số; Lasso cắt hệ số nhỏ về đúng 0. Chuẩn hóa trước khi phạt.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook: tăng số cột rác lên 100, xem Ridge và Lasso thay đổi thế nào.