Decision tree

Tính Gini và mức giảm tạp chất của một phép chia.

Học ra câu hỏi

“Điểm cơ bản ≤6?” → nhánh trái hoặc phải.

“Điểm đồ thị ≤8?” → câu hỏi kế tiếp.

Ta đã biết duyệt cây.

Phần mới: chọn đặc trưng và ngưỡng từ dữ liệu, rồi quyết định khi nào dừng.

01

Một phép chia tốt

Gini

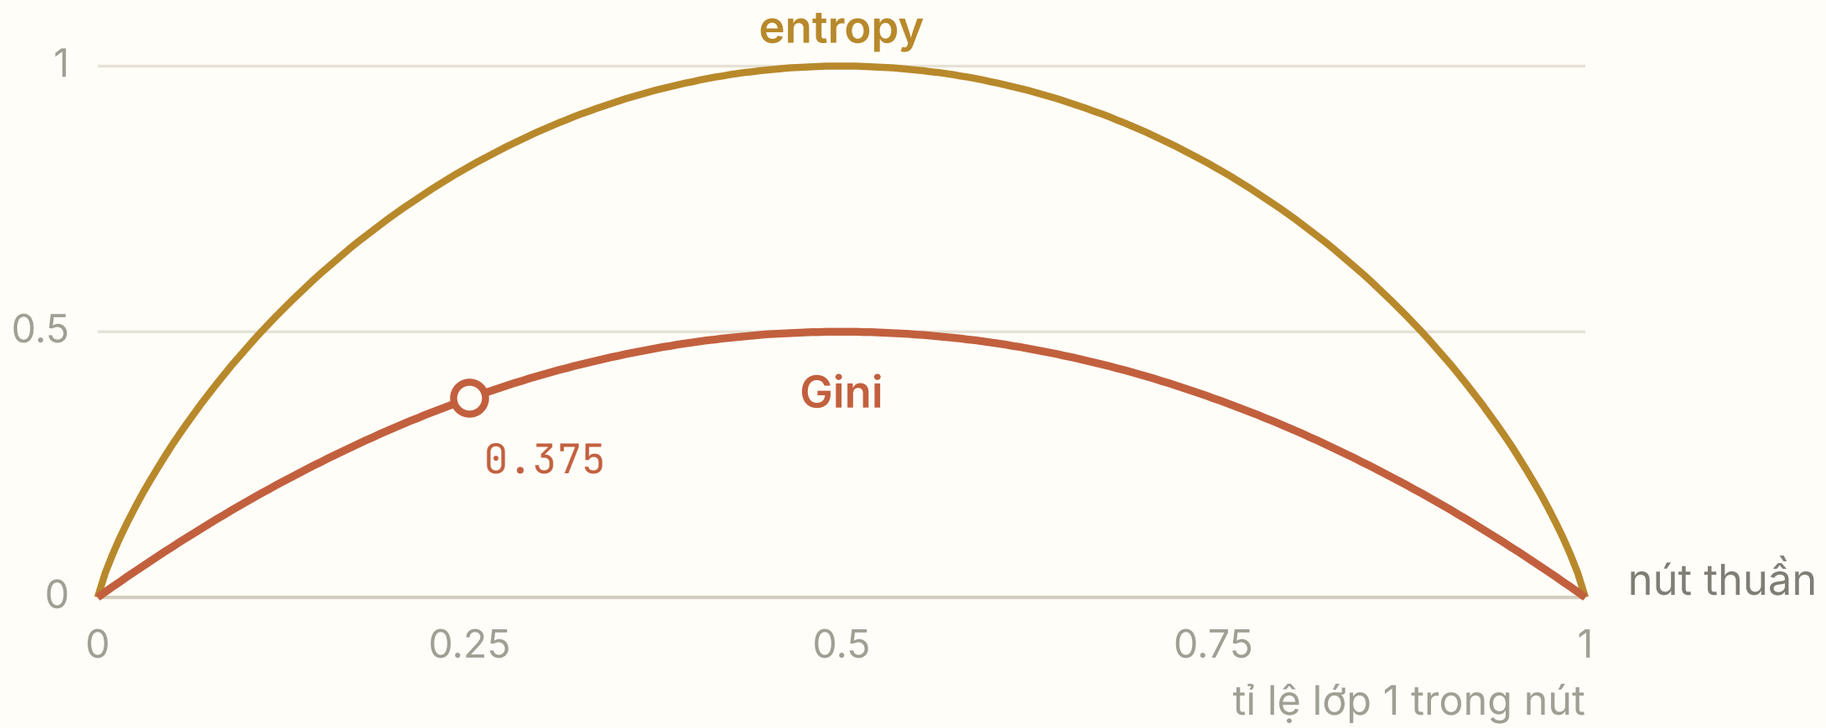
$$G = 1 - \sum_k p_k^2$$

Nút thuần: $G = 0$.

Hai lớp đều: $G = 0.5$.

Gini là xác suất sai khi chọn nhãn ngẫu nhiên theo tỉ lệ lớp. Entropy $H = -\sum_k p_k \log_2 p_k$ đo lượng thông tin; hai tiêu chí thường chọn các phép chia gần nhau.

Gini và entropy



Gini và entropy của nút hai lớp: bằng 0 khi nút thuần, lớn nhất khi hai lớp chia đều; 3 mẫu lớp 0, 1 mẫu lớp 1 cho Gini 0.375.

HỎI NHANH

Một nút có 3 mẫu lớp 0 và 1 mẫu lớp 1. Gini của nút bằng bao nhiêu?

A 0.25

B 0.5

C 0.375

D 0.75

So hai phép chia

Cha: 5 dương, 5 âm, Gini=0.5.

A: hai lá (4 dương, 1 âm) và (1 dương, 4 âm) → sau chia 0.32.

B: một lá 5–3, lá kia 0–2 → sau chia 0.375.

A giảm Gini 0.18.

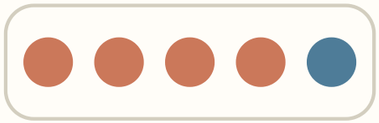
B giảm Gini 0.125.

Có một lá thuần chưa đủ để phép chia thắng.

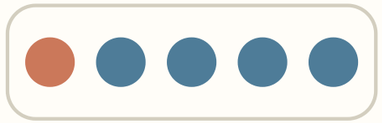
Hai cách chia

cha: 5+, 5−, Gini 0.5

A



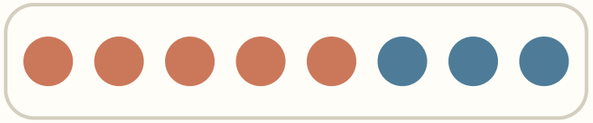
Gini 0.32



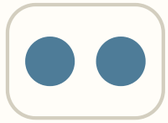
Gini 0.32

Δ = 0.18

B



Gini 0.469

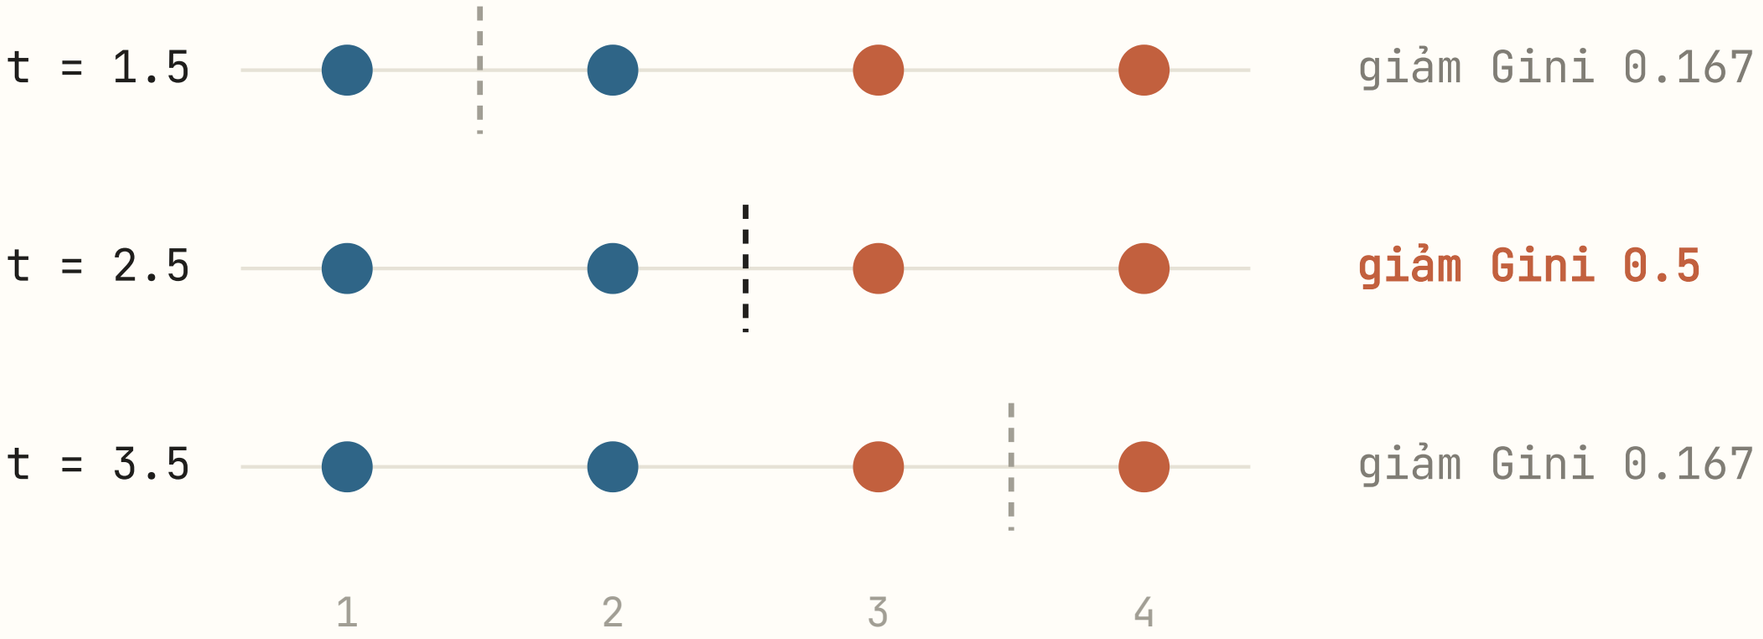


Gini 0

Δ = 0.125

Hai cách chia cùng nút 5+, 5−: B có một lá thuần nhưng chỉ 2 mẫu; A giảm Gini nhiều hơn.

Ngưỡng nào thắng?



Ba ngưỡng trên bốn mẫu x = 1, 2, 3, 4 (nhãn 0, 0, 1, 1): chỉ t = 2.5 cho hai lá thuần.

Lấy trung bình có trọng số

$$G_{sau} = \frac{n_L}{n} G_L + \frac{n_R}{n} G_R$$

Một lá nhỏ thuần không được tính ngang tiếng nói với lá lớn còn lẫn.

HỎI NHANH

Sau một phép chia, lá trái có 2 mẫu với Gini bằng 0, lá phải có 18 mẫu với Gini bằng 0.5. Gini có trọng số sau khi chia bằng bao nhiêu?

A 0.25

B 0.45

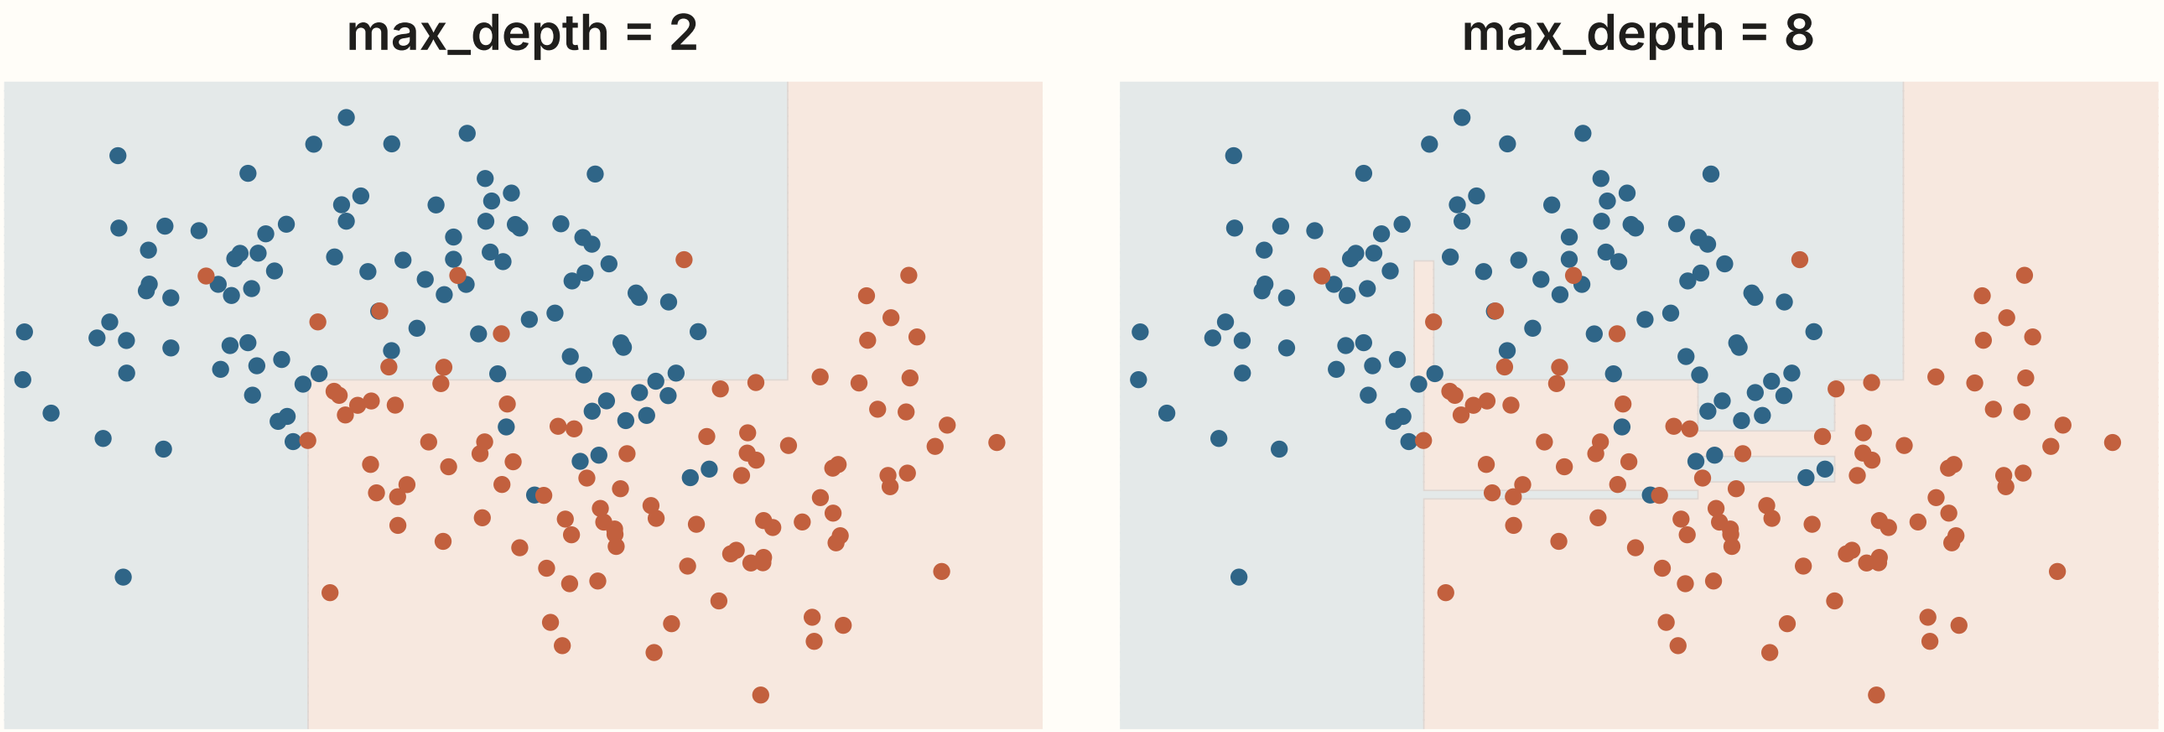
C 0.5

D 0.9

02

Từ stump tới cây

Cây chia không gian theo trục



Cây chia mặt phẳng thành các hộp có cạnh song song với trục; sâu 8 thì hộp nhỏ dần để ôm từng điểm nhiễu.

HỎI NHANH

Hai lớp được tách đúng bởi đường chéo $x_1 = x_2$. Cây quyết định chỉ dùng phép chia dạng $x_j \le t$ thì biểu diễn ranh giới này thế nào?

A Một phép chia $x_1 \le x_2$ ở gốc là đủ

B Hai phép chia, mỗi trục một lần, là vừa khít

C Không biểu diễn được, dù cây sâu đến đâu

D Bằng một bậc thang, cần nhiều phép chia

CART là tham lam

Tại mỗi nút, chọn phép chia tốt nhất hiện tại, rồi đệ quy.

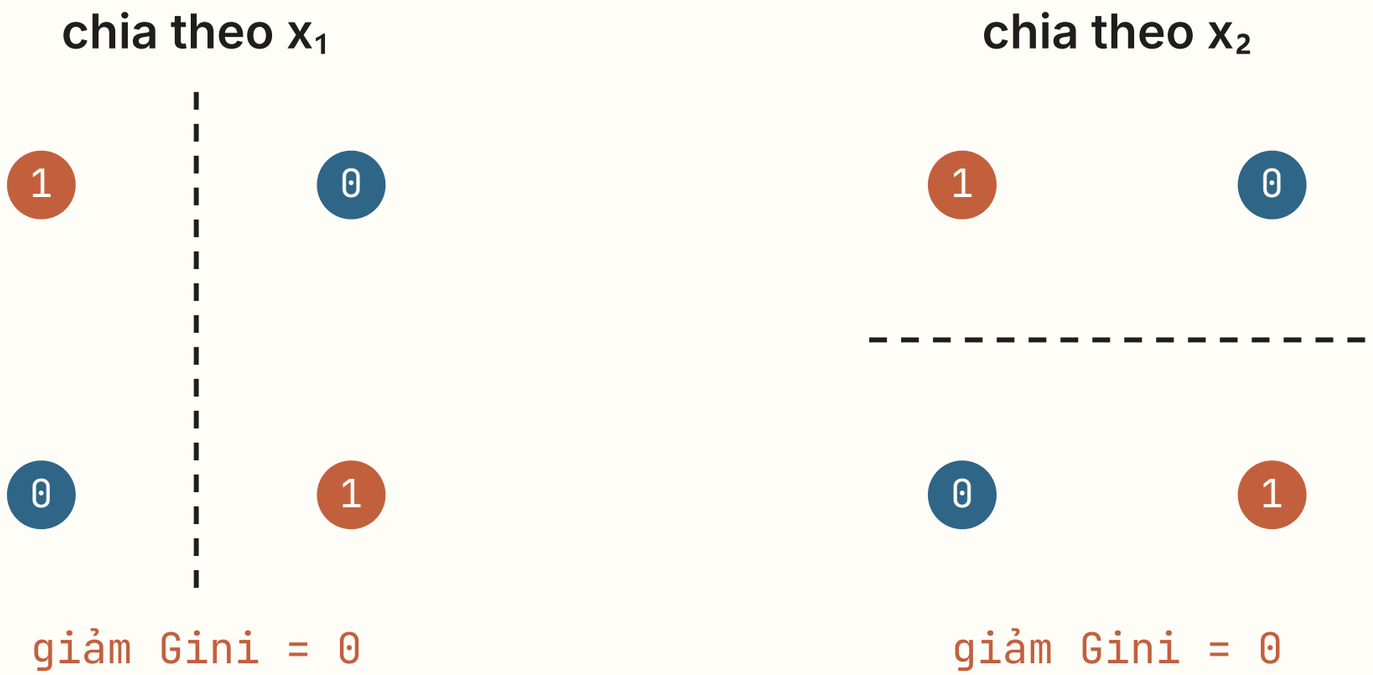
Không thử mọi cây tương lai.

XOR: gain đầu tiên có thể bằng 0, nhưng tầng sau mới lộ tương tác.

Khả năng biểu diễn ≠ bảo đảm thuật toán học ra.

Với một cột, chỉ cần xét ngưỡng giữa hai giá trị liên tiếp khác nhau. Ở một nút, chi phí chính là sắp xếp mẫu, khoảng $O(dn \log n)$.

XOR ở gốc



XOR: chia ở gốc theo x_1 hay x_2 đều để mỗi bên một mẫu mỗi lớp, nên giảm Gini bằng 0 dù tầng sau tách được hết.

HỎI NHANH

Bốn điểm XOR: $(0,0) \to 0$, $(0,1) \to 1$, $(1,0) \to 1$, $(1,1) \to 0$. Ở gốc, chia theo x_1 thì Gini giảm được bao nhiêu?

A 0

B 0.25

C 0.5

D 1

HỎI NHANH

Một feature có 1000 mẫu nhưng chỉ có 7 giá trị khác nhau, là các điểm từ 4 đến 10. Ở một nút chứa đủ cả 7 giá trị, CART cần thử bao nhiêu ngưỡng cho feature này?

A 999

B 1000

C 6

D 7

Cây sâu cần phanh

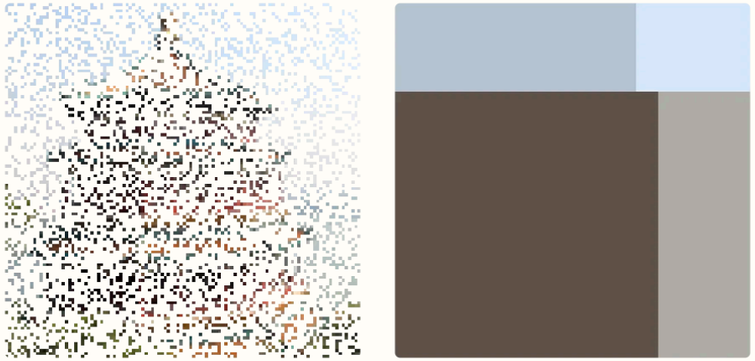
Không có ràng buộc dừng, các lá có thể thuần và train error bằng 0, kể cả khi cây đã học nhiễu.

`max_depth` giới hạn số tầng.

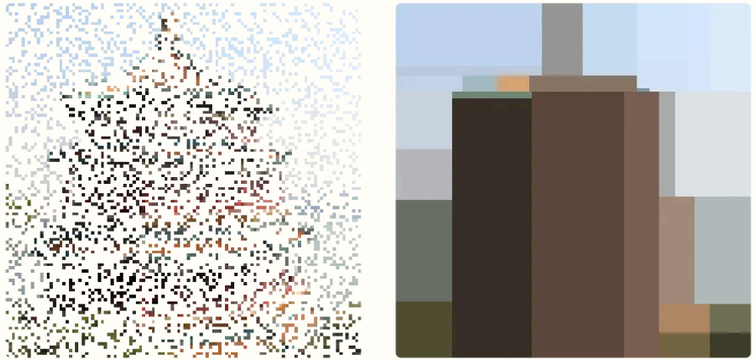
`min_samples_leaf` buộc mỗi lá có đủ mẫu; `min_impurity_decrease` bỏ phép chia quá nhỏ. Pruning tối ưu lỗi cộng phí theo số lá.

Đọc validation, không suy từ train accuracy một mình.

Độ sâu trên một ảnh thật



độ sâu 2: 4 lá, RMSE train 54.0, RMSE điểm chưa thấy 54.6



độ sâu 5: 32 lá, RMSE train 35.7, RMSE điểm chưa thấy 36.9



độ sâu 10: 663 lá, RMSE train 18.5, RMSE điểm chưa thấy 27.6

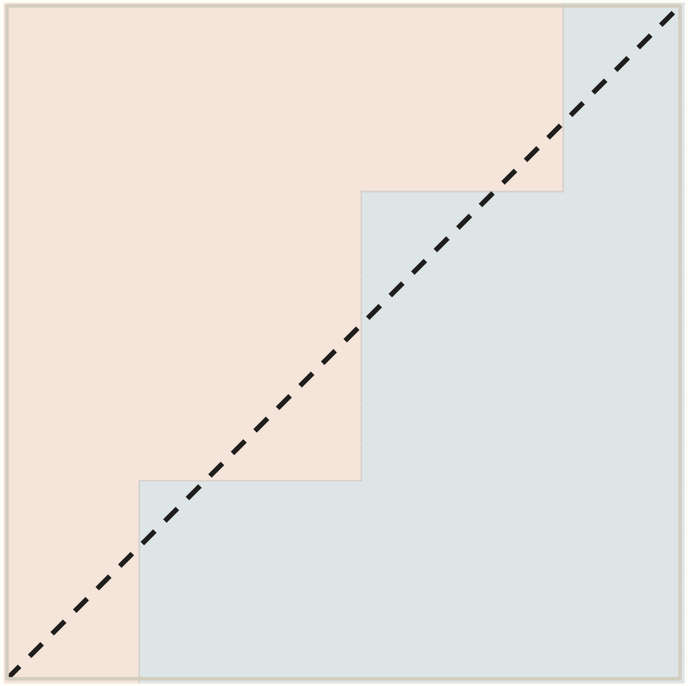


độ sâu 24: 3024 lá, RMSE train 0.1, RMSE điểm chưa thấy 25.5

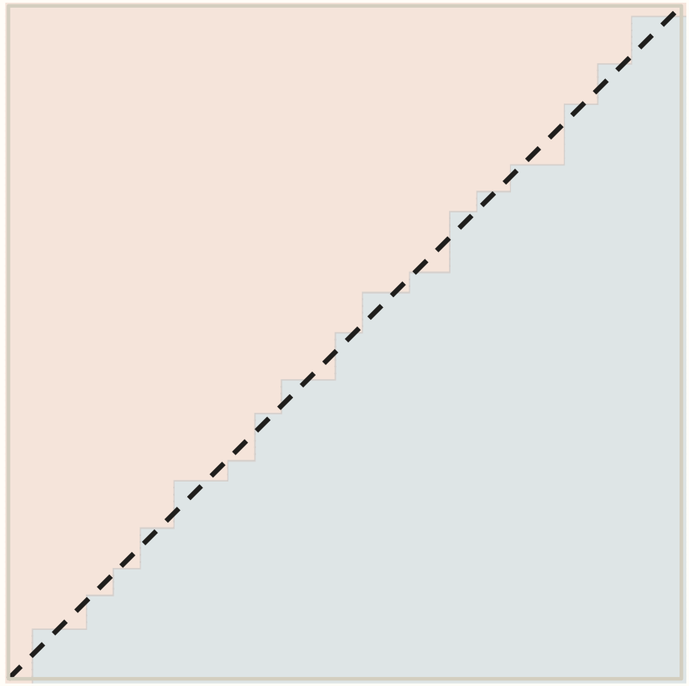
Decision tree đoán màu theo tọa độ, học từ 25% điểm ảnh (trái): mỗi lá là một hình chữ nhật một màu; càng sâu càng thuộc điểm train, còn điểm chưa thấy dừng ở mức sai cỡ 25.

Đường chéo thành bậc thang

max_depth = 3 · 8 lá



max_depth = 8 · 42 lá



Ranh giới thật là đường chéo $x_2 = x_1$ (nét đứt): cây chỉ xấp xỉ được bằng bậc thang, càng sát càng nhiều lá.

HỎI NHANH

Cost-complexity pruning chọn cây con có lỗi train + $\alpha \cdot$ (số lá) nhỏ nhất. Tăng α thì cây sau khi tỉa thay đổi thế nào?

A Nhiều lá hơn, vì α thưởng cho mỗi lá

B Ít lá hơn, và lỗi train không giảm

C Không đổi, vì α chỉ ảnh hưởng tới validation

D Sâu hơn, nhưng mỗi tầng ít lá hơn

HỎI NHANH

Bỏ ngẫu nhiên 5 trong 500 mẫu train rồi học lại. Cây sâu đổi hẳn phép chia ở gốc, và dự đoán trên validation thay đổi nhiều. Điều này cho thấy gì?

A 5 mẫu bị bỏ đi là những mẫu bị gán nhãn sai

B Variance cao: dữ liệu đổi ít mà cây đổi nhiều

C Cây có bias cao, cần mọc sâu hơn nữa

D Phải chuẩn hóa feature trước khi học cây

Đối chiếu trên máy

Đọc cây bằng thư viện

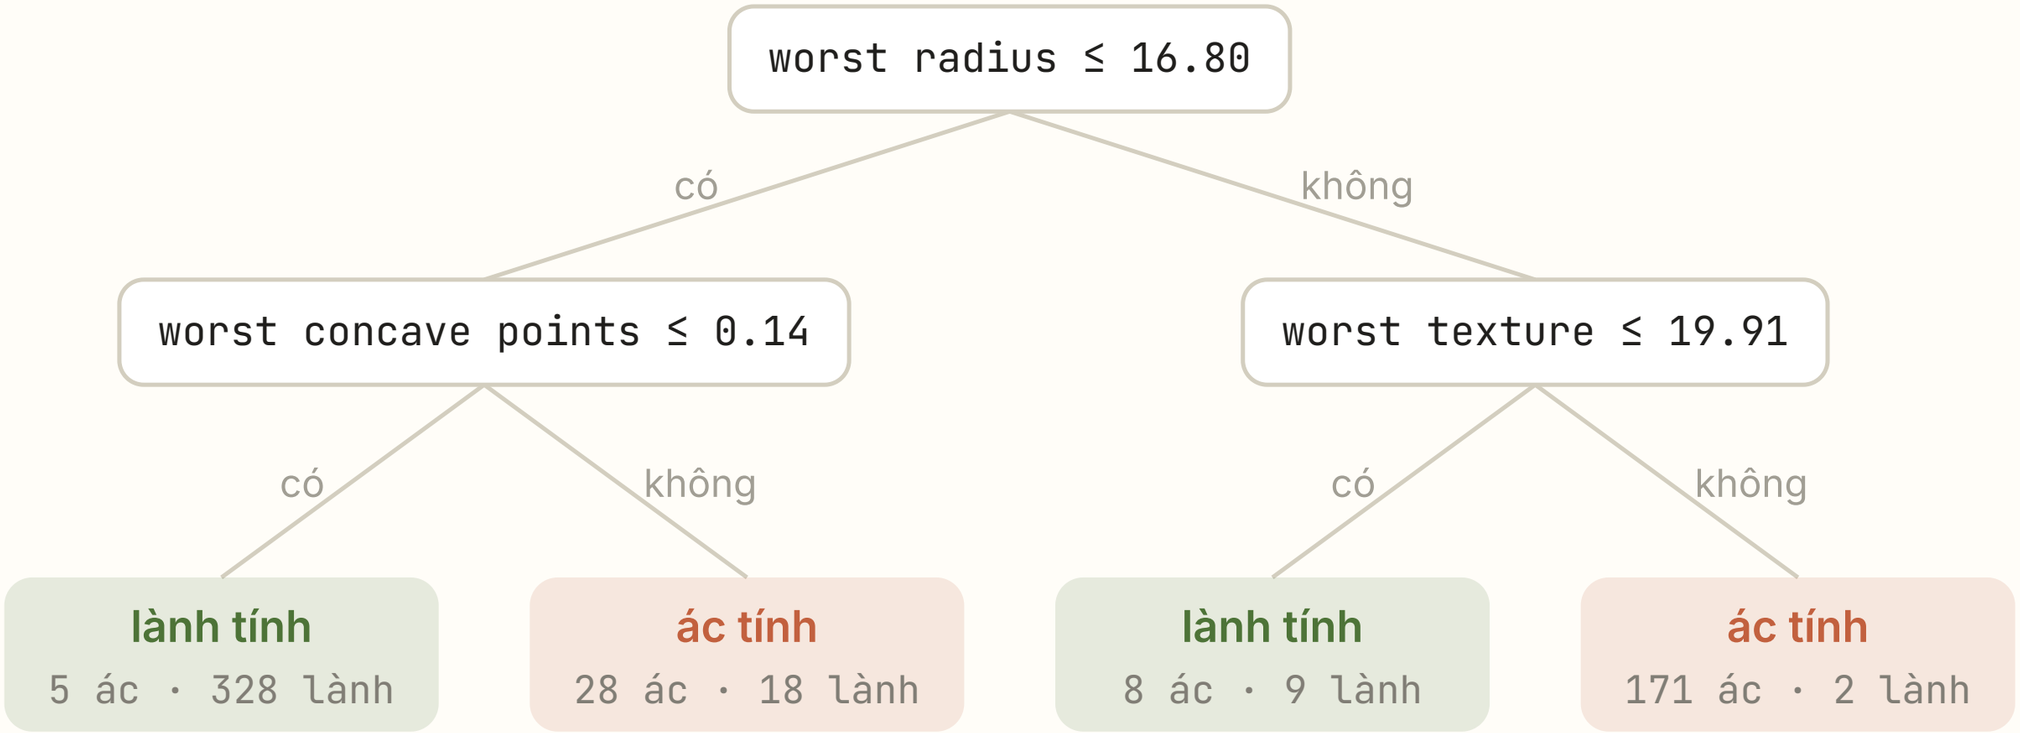
KẾT QUẢ

```
1 0.9
3 0.917
5 0.916
None 0.917
```

Trong thí nghiệm `breast_cancer`, cây sâu hơn không thắng rõ. `export_text` giúp đọc ngưỡng, nhưng feature importance theo impurity không chứng minh nhân quả; khi cần, đối chiếu permutation importance trên validation.

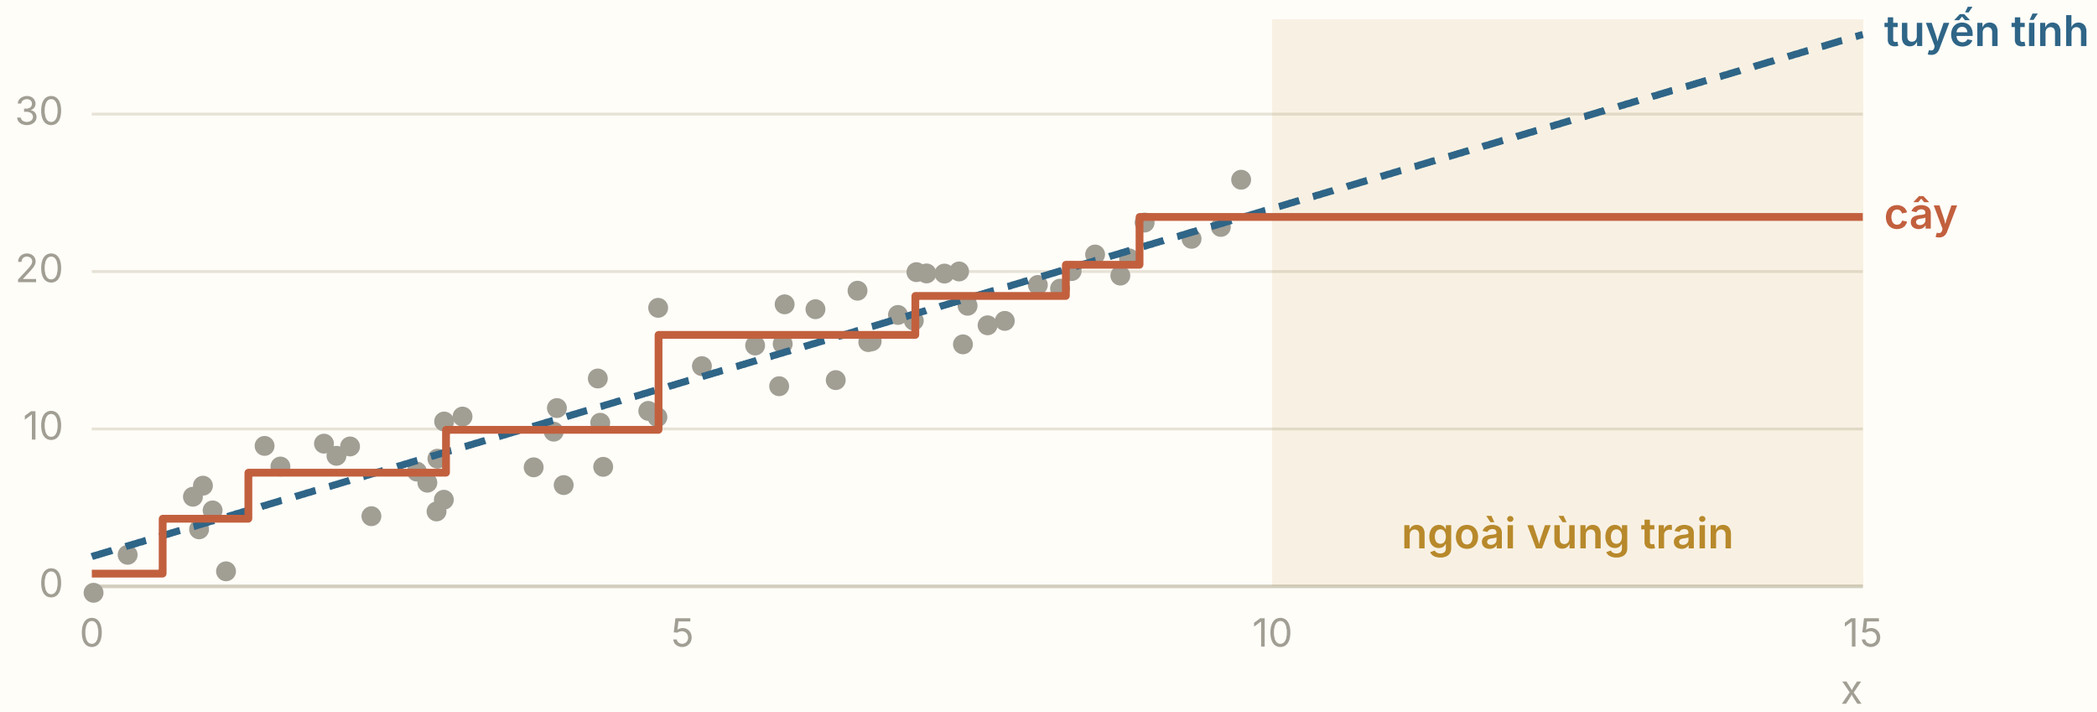
Một cây hồi quy dự đoán trung bình target của lá. Vì vậy nó không kéo xu hướng ra ngoài miền train như linear regression; luôn kiểm ngoại suy theo giao thức của dữ liệu.

Cây độ sâu 2



Cây độ sâu 2 học trên bộ breast cancer (569 mẫu): mỗi lá ghi số mẫu ác tính và lành tính rơi vào đó.

Cây không ngoại suy



Cây hồi quy là hằng số từng khúc: ra ngoài vùng train nó giữ nguyên giá trị lá cuối, còn đường thẳng kéo dài xu hướng.

HỎI NHANH

Cross-validation cho độ sâu 1, 3, 5 và không giới hạn lần lượt được 0.900, 0.917, 0.916 và 0.917. Ta nên chọn gì, vì sao?

A Độ sâu 3, vì ngang điểm cao nhất mà đơn giản hơn

B Không giới hạn, vì điểm cao nhất và khỏi phải chọn

C Độ sâu 1, vì đơn giản nhất và chỉ kém 1.7 điểm

D Độ sâu 5, vì nằm giữa nên an toàn nhất

HỎI NHANH

Lỡ để cột `row_id` trong feature, mỗi dòng một số khác nhau. Cây sâu cho cột này impurity importance cao, nhưng permutation importance trên validation thì gần bằng 0. Hiểu thế nào?

A `row_id` thật sự quan trọng, phải giữ lại

B Permutation importance tính sai, nên tin impurity importance

C Hai cách đo luôn cho kết quả trái ngược nhau

D Cây dùng `row_id` để học thuộc train

Khi đi thi

- Hiếm khi nộp một cây đơn; cây nông 2–4 tầng để hiểu dữ liệu.
- Cây độ sâu 1 đạt 99%: nghi một cột lộ đáp án.
- Đọc quy ước <=/<, phá hòa, nút rỗng trong đề cài đặt.
- Test ở tương lai: cây không ngoại suy.

03

Luyện đề

LUYỆN ĐỀ 1

Trên cùng tập train D, ta học hai cây. Một cây chọn phép chia theo information gain, cây kia theo tỉ lệ lỗi trên train. Cả hai đều mọc cho tới khi lỗi train bằng 0. Điều nào **chắc chắn** đúng?

A Hai cây chia theo cùng một feature ở gốc

B Hai cây có cùng độ sâu và cùng số lá

C Hai cây dùng hết mọi feature của D

D Hai cây dự đoán giống nhau trên mọi mẫu của D

PHỎNG THEO CMU 10-601 · Exam 1 Practice · Q1.2

LUYỆN ĐỀ 2

Dữ liệu dự đoán khách bỏ dịch vụ có 10 000 mẫu và 20 feature. Có 15% số ô bị thiếu, rải ngẫu nhiên. Trong bốn đề xuất sau, lập luận nào chính xác nhất?

A Dùng mô hình dạng cây, vì nhiều thư viện cây tự học hướng đi cho ô thiếu

B kNN cần đủ mọi ô, nên bỏ hết mẫu bị thiếu là cách duy nhất

C Linear regression với ô thiếu điền bằng trung bình là cách tối ưu về thống kê

D Dùng một mô hình tuyến tính, sau khi điền ô thiếu bằng giá trị của dòng phía trên

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 270

LUYỆN ĐỀ 3

Thuật toán học cây kiểu ID3 hay CART có bảo đảm tìm ra cây đạt lỗi train 0 với **ít phép chia nhất** không?

A Có, vì ở mỗi nút đều thử mọi feature và mọi ngưỡng

B Có, nếu dùng entropy thay cho Gini

C Không, vì nó chỉ chọn phép chia tốt nhất tại từng nút

D Không, vì cây không bao giờ đạt được lỗi train 0

PHỎNG THEO CMU 10-601 · Exam 1 Practice · Q1.3

Chốt ba điều

Công thức Gini và trung bình có trọng số quyết định phép chia.

CART chọn tham lam từng nút; cây sâu có thể học thuộc.

Đọc độ sâu, số mẫu ở lá và validation để kiểm soát overfitting; cây không ngoại suy.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook từ đầu; đổi `max_depth` hoặc `min_samples_leaf`, dự đoán khoảng cách train/validation, rồi kiểm bằng output.