Cây quyết định

Chuỗi câu hỏi if–else học từ dữ liệu

Chương 2 · Bài 2.5

Học ra câu hỏi

“Điểm cơ bản ≤6?” → nhánh trái hoặc phải.

“Điểm đồ thị ≤8?” → câu hỏi kế tiếp.

Ta đã biết duyệt cây.

Phần mới: chọn đặc trưng và ngưỡng từ dữ liệu, rồi quyết định khi nào dừng.

Mục tiêu

- Tính Gini và chọn ngưỡng chia tốt nhất ở một nút.
- Duyệt cây để ra dự đoán.
- Giới hạn độ sâu và số lá để tránh overfitting.

01

Một phép chia tốt

Gini

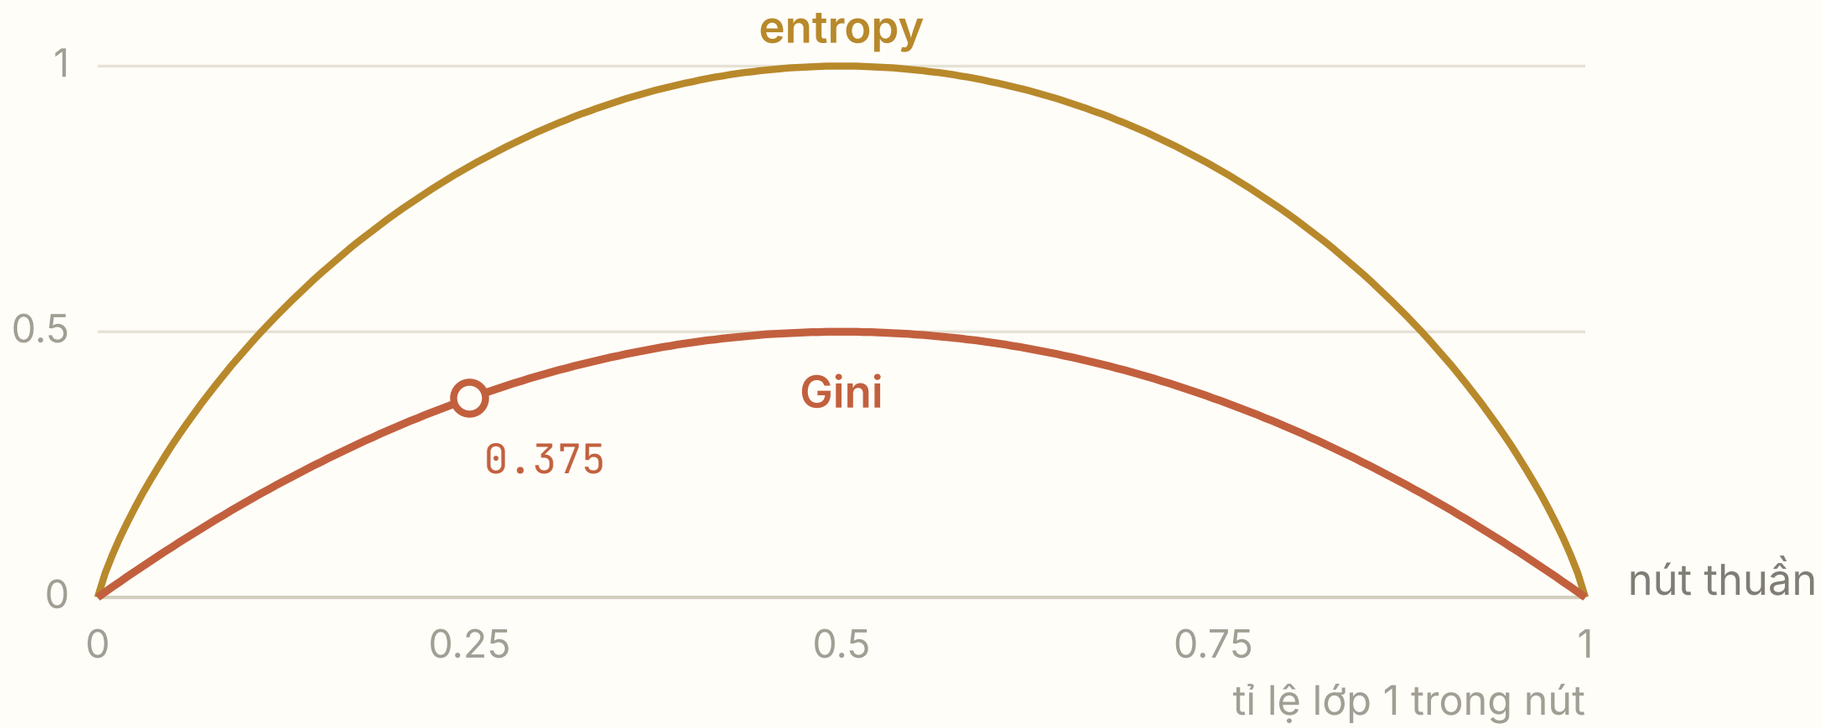
$$G = 1 - \sum_k p_k^2$$

Nút thuần: $G = 0$.

Hai lớp đều: $G = 0.5$.

Gini là xác suất sai khi chọn nhãn ngẫu nhiên theo tỉ lệ lớp. Entropy $H = -\sum_k p_k \log_2 p_k$ đo lượng thông tin; hai tiêu chí thường chọn các phép chia gần nhau.

Gini và entropy



Gini và entropy bằng 0 khi nút thuần, lớn nhất khi hai lớp chia đều.

HỎI NHANH

Một nút có 3 mẫu lớp 0 và 1 mẫu lớp 1. Gini của nút bằng bao nhiêu?

A 0.25

B 0.5

C 0.375

D 0.75

So hai phép chia

Cha: 5 dương, 5 âm, Gini=0.5.

A: hai lá (4 dương, 1 âm) và (1 dương, 4 âm) → sau chia 0.32.

B: một lá 5–3, lá kia 0–2 → sau chia 0.375.

A giảm Gini 0.18.

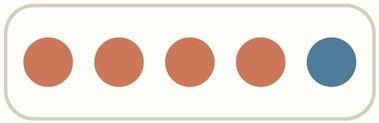
B giảm Gini 0.125.

Có một lá thuần chưa đủ để phép chia thắng.

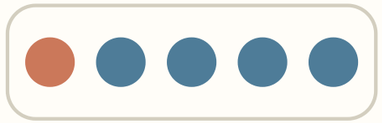
Hai cách chia

cha: 5+, 5−, Gini 0.5

A



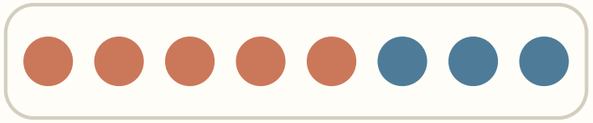
Gini 0.32



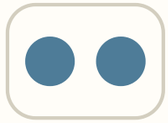
Gini 0.32

Δ = 0.18

B



Gini 0.469

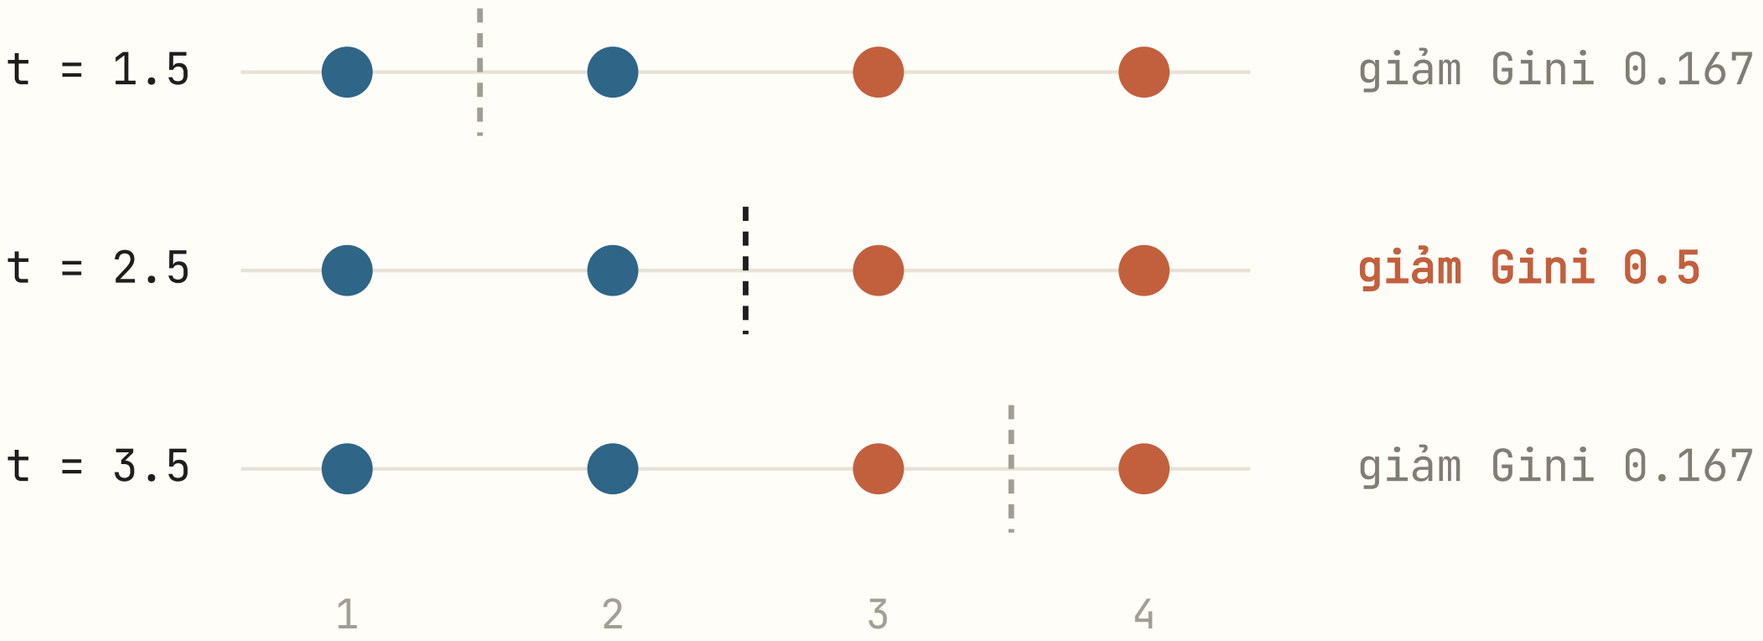


Gini 0

Δ = 0.125

B có một lá thuần nhưng chỉ 2 mẫu; A giảm Gini nhiều hơn.

Ngưỡng nào thắng?



Trong ba ngưỡng, chỉ t = 2.5 cho hai lá thuần.

Lấy trung bình có trọng số

$$G_{sau} = \frac{n_L}{n} G_L + \frac{n_R}{n} G_R$$

Một lá nhỏ thuần không được tính ngang tiếng nói với lá lớn còn lẫn.

HỎI NHANH

Sau một phép chia, lá trái có 2 mẫu với Gini bằng 0, lá phải có 18 mẫu với Gini bằng 0.5. Gini có trọng số sau khi chia bằng bao nhiêu?

A 0.25

B 0.45

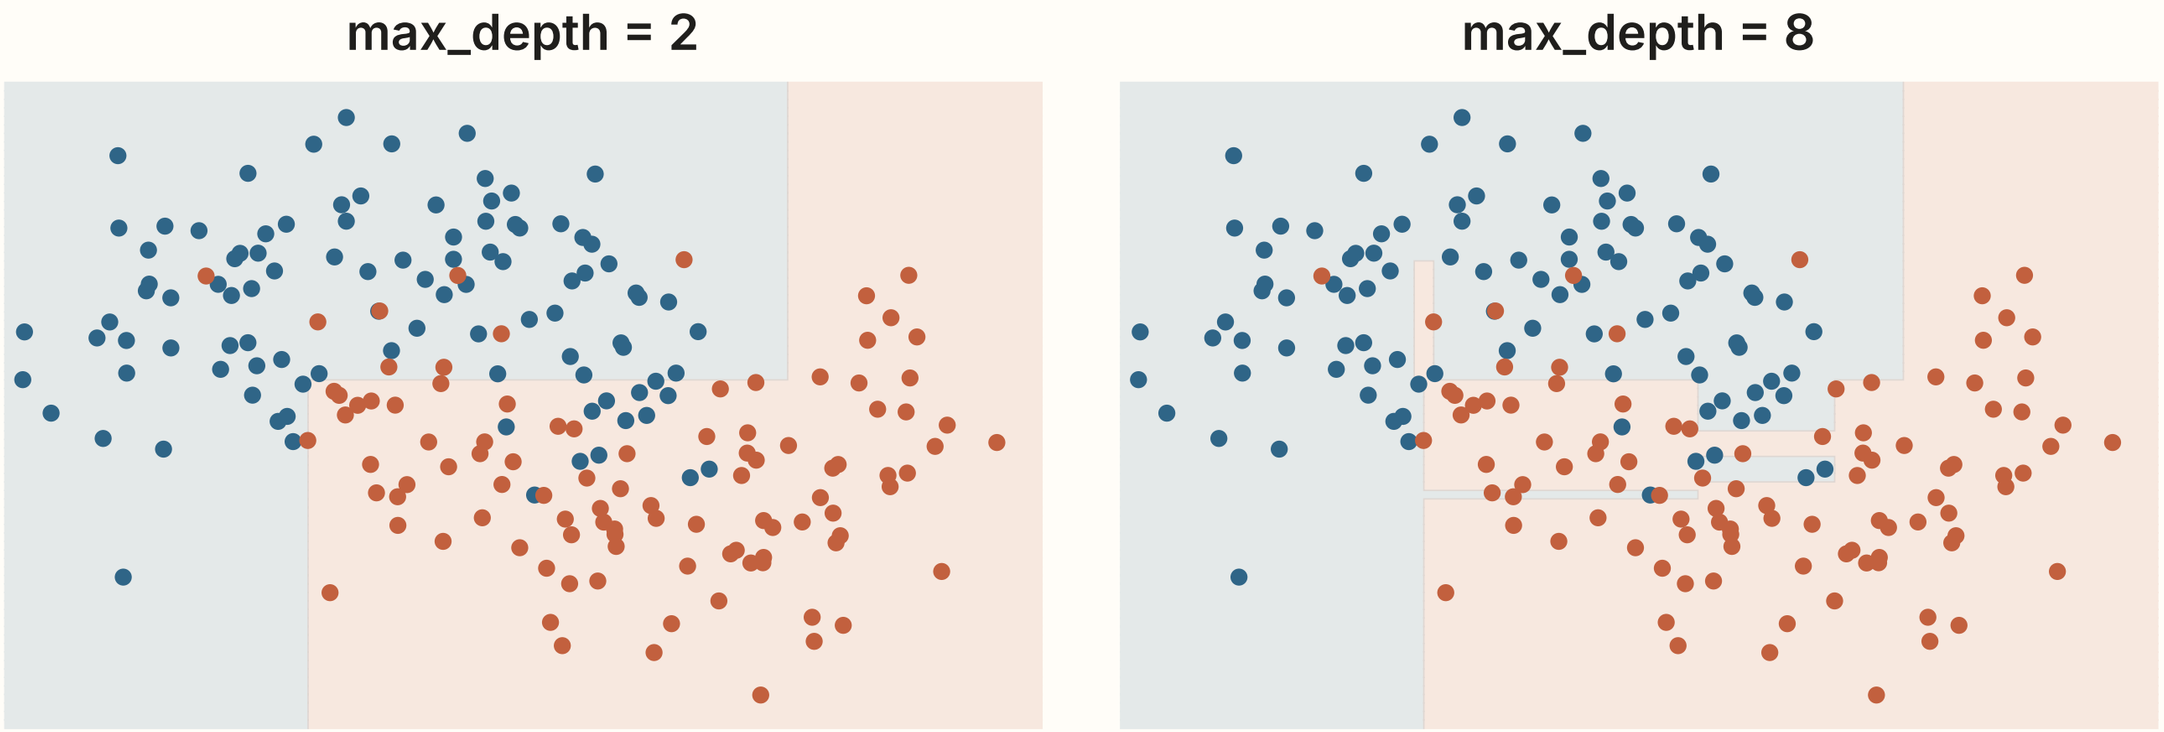
C 0.5

D 0.9

02

Từ stump tới cây

Cây chia không gian theo trục



Cây chia mặt phẳng thành các hộp; càng sâu, hộp càng ôm từng điểm nhiễu.

HỎI NHANH

Hai lớp được tách đúng bởi đường chéo $x_1 = x_2$. Cây quyết định chỉ dùng phép chia dạng $x_j \le t$ thì biểu diễn ranh giới này thế nào?

A Một phép chia $x_1 \le x_2$ ở gốc là đủ

B Hai phép chia, mỗi trục một lần, là vừa khít

C Không biểu diễn được, dù cây sâu đến đâu

D Bằng một bậc thang, cần nhiều phép chia

CART là tham lam

Tại mỗi nút, chọn phép chia tốt nhất hiện tại, rồi đệ quy.

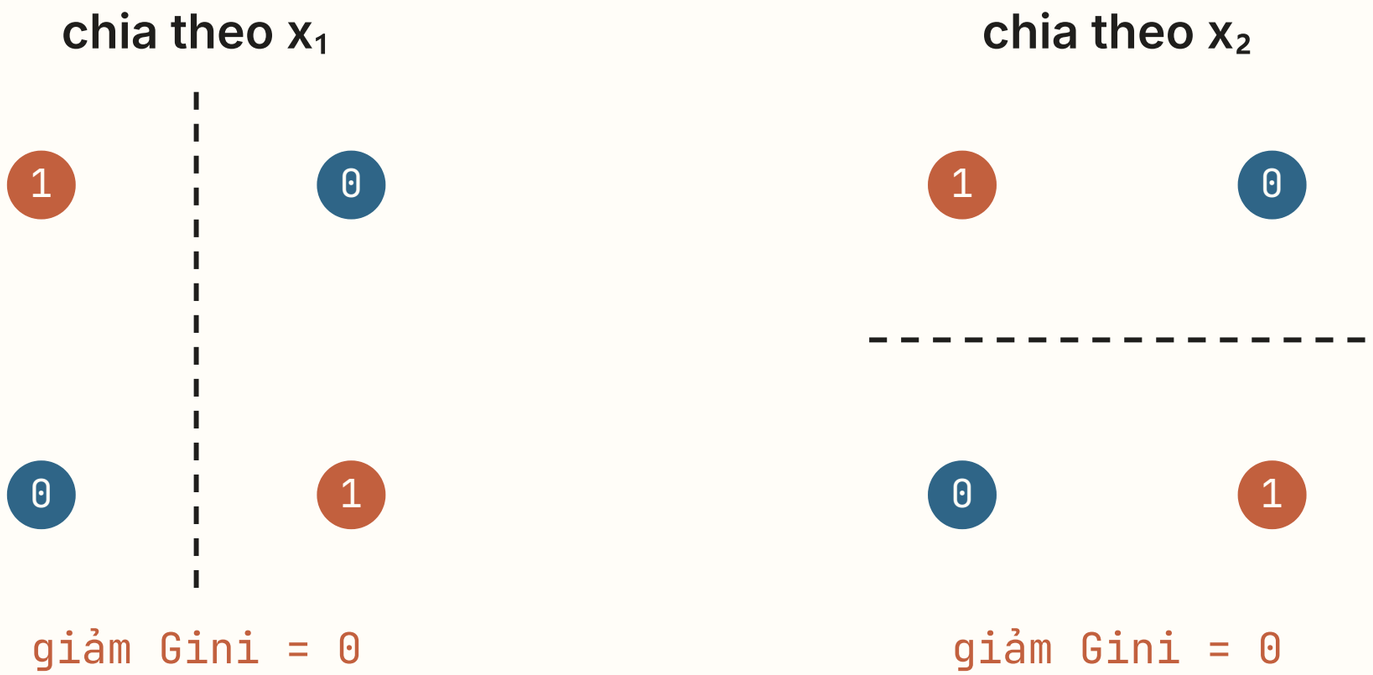
Không thử mọi cây tương lai.

XOR: chia ở gốc thì Gini không giảm, dù tầng sau tách được hết.

Cây biểu diễn được không có nghĩa là thuật toán tham lam học ra.

Mỗi cột chỉ cần xét ngưỡng giữa hai giá trị liên tiếp khác nhau.

XOR ở gốc



XOR: chia ở gốc theo trục nào Gini cũng không giảm.

HỎI NHANH

Bốn điểm XOR: $(0,0) \to 0$, $(0,1) \to 1$, $(1,0) \to 1$, $(1,1) \to 0$. Ở gốc, chia theo x_1 thì Gini giảm được bao nhiêu?

A 0

B 0.25

C 0.5

D 1

HỎI NHANH

Một feature có 1000 mẫu nhưng chỉ có 7 giá trị khác nhau, là các điểm từ 4 đến 10. Ở một nút chứa đủ cả 7 giá trị, CART cần thử bao nhiêu ngưỡng cho feature này?

A 999

B 1000

C 6

D 7

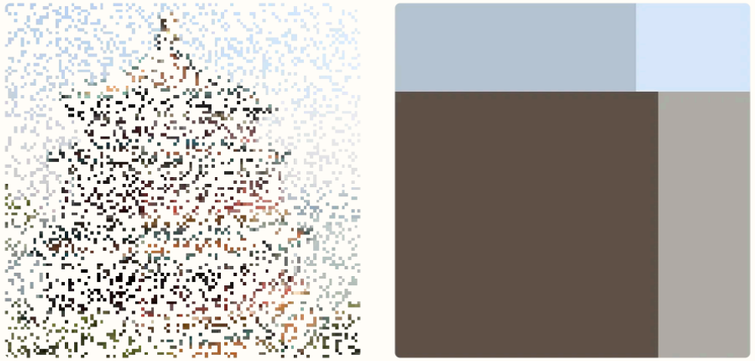
Cây sâu cần phanh

Không có ràng buộc dừng, các lá có thể thuần và train error bằng 0, kể cả khi cây đã học nhiễu.

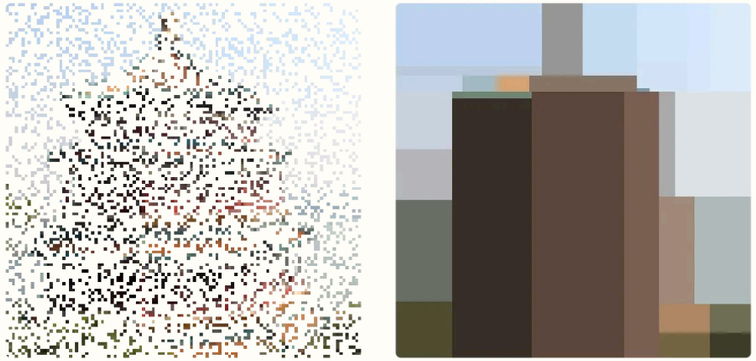
- `max_depth`: giới hạn số tầng.
- `min_samples_leaf`: mỗi lá đủ mẫu.
- Pruning: tỉa theo lỗi cộng phí số lá.

Chọn bằng validation, không bằng train accuracy.

Độ sâu trên một ảnh thật



độ sâu 2: 4 lá, RMSE train 54.0, RMSE điểm chưa thấy 54.6



độ sâu 5: 32 lá, RMSE train 35.7, RMSE điểm chưa thấy 36.9



độ sâu 10: 663 lá, RMSE train 18.5, RMSE điểm chưa thấy 27.6

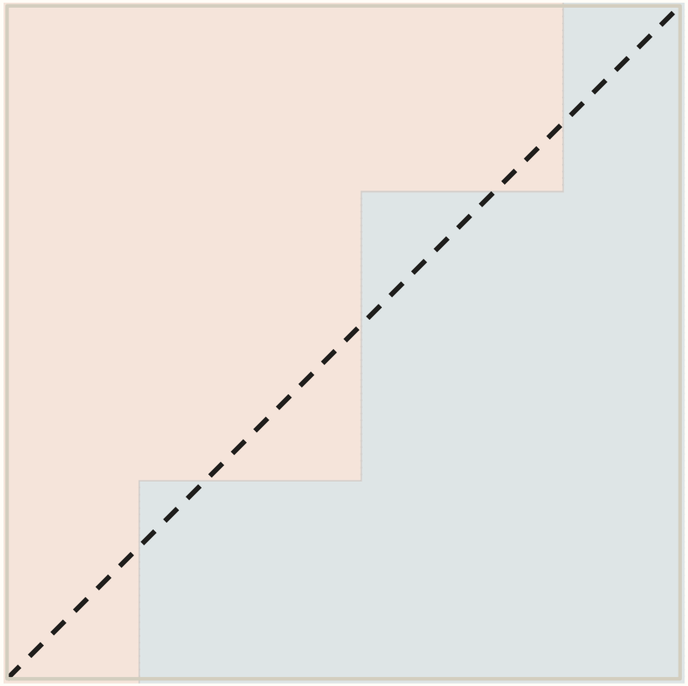


độ sâu 24: 3024 lá, RMSE train 0.1, RMSE điểm chưa thấy 25.5

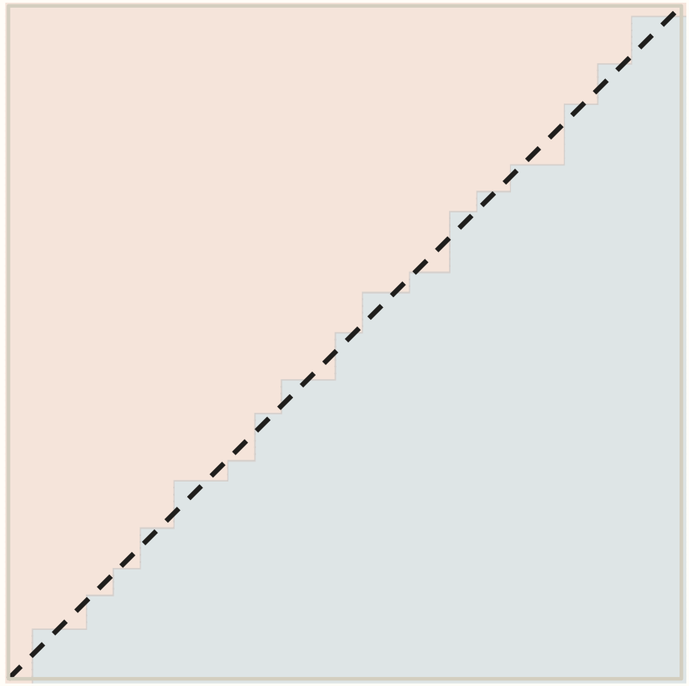
Decision tree đoán màu theo tọa độ, học từ 25% điểm ảnh (trái): mỗi lá là một hình chữ nhật một màu; càng sâu càng thuộc điểm train, còn điểm chưa thấy dừng ở mức sai cỡ 25.

Đường chéo thành bậc thang

max_depth = 3 · 8 lá



max_depth = 8 · 42 lá



Cây chỉ xấp xỉ được đường chéo bằng bậc thang.

HỎI NHANH

Cost-complexity pruning chọn cây con có lỗi train + $\alpha \cdot$ (số lá) nhỏ nhất. Tăng α thì cây sau khi tỉa thay đổi thế nào?

A Nhiều lá hơn, vì α thưởng cho mỗi lá

B Ít lá hơn, và lỗi train không giảm

C Không đổi, vì α chỉ ảnh hưởng tới validation

D Sâu hơn, nhưng mỗi tầng ít lá hơn

HỎI NHANH

Bỏ ngẫu nhiên 5 trong 500 mẫu train rồi học lại. Cây sâu đổi hẳn phép chia ở gốc, và dự đoán trên validation thay đổi nhiều. Điều này cho thấy gì?

A 5 mẫu bị bỏ đi là những mẫu bị gán nhãn sai

B Variance cao: dữ liệu đổi ít mà cây đổi nhiều

C Cây có bias cao, cần mọc sâu hơn nữa

D Phải chuẩn hóa feature trước khi học cây

Đối chiếu trên máy

Bốn điểm 1, 2, 3, 4 với nhãn 0, 0, 1, 1.

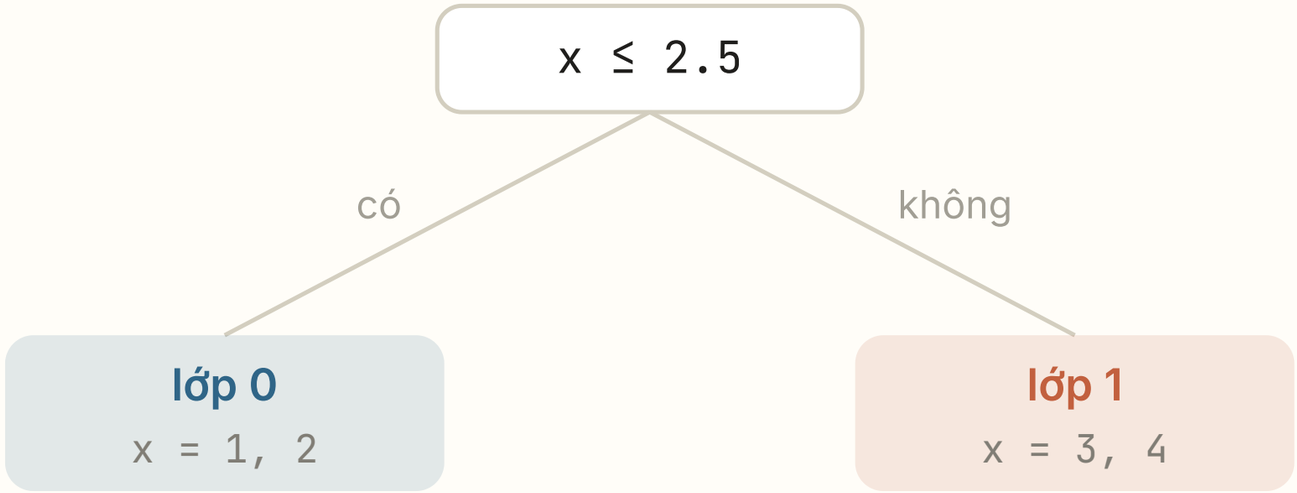
```
best = None
for threshold in [1.5, 2.5, 3.5]:
    left = x_small <= threshold
    right = ~left
    after = (
        left.mean() * gini(y_small[left])
        + right.mean() * gini(y_small[right])
    )
    gain = gini(y_small) - after
    if best is None or gain > best[0]:
        best = (gain, threshold)
print("ngưỡng:", best[1])
```

KẾT QUẢ

```
ngưỡng: 2.5
```

Chia ở 2.5 tạo hai lá thuần: Gini giảm từ 0.5 về 0.

Một stump, hai lá thuần



Decision stump ngưỡng 2.5: hai lá thuần, Gini sau chia bằng 0.

Đọc cây bằng thư viện

KẾT QUẢ

```
1 0.9
3 0.917
5 0.916
None 0.917
```

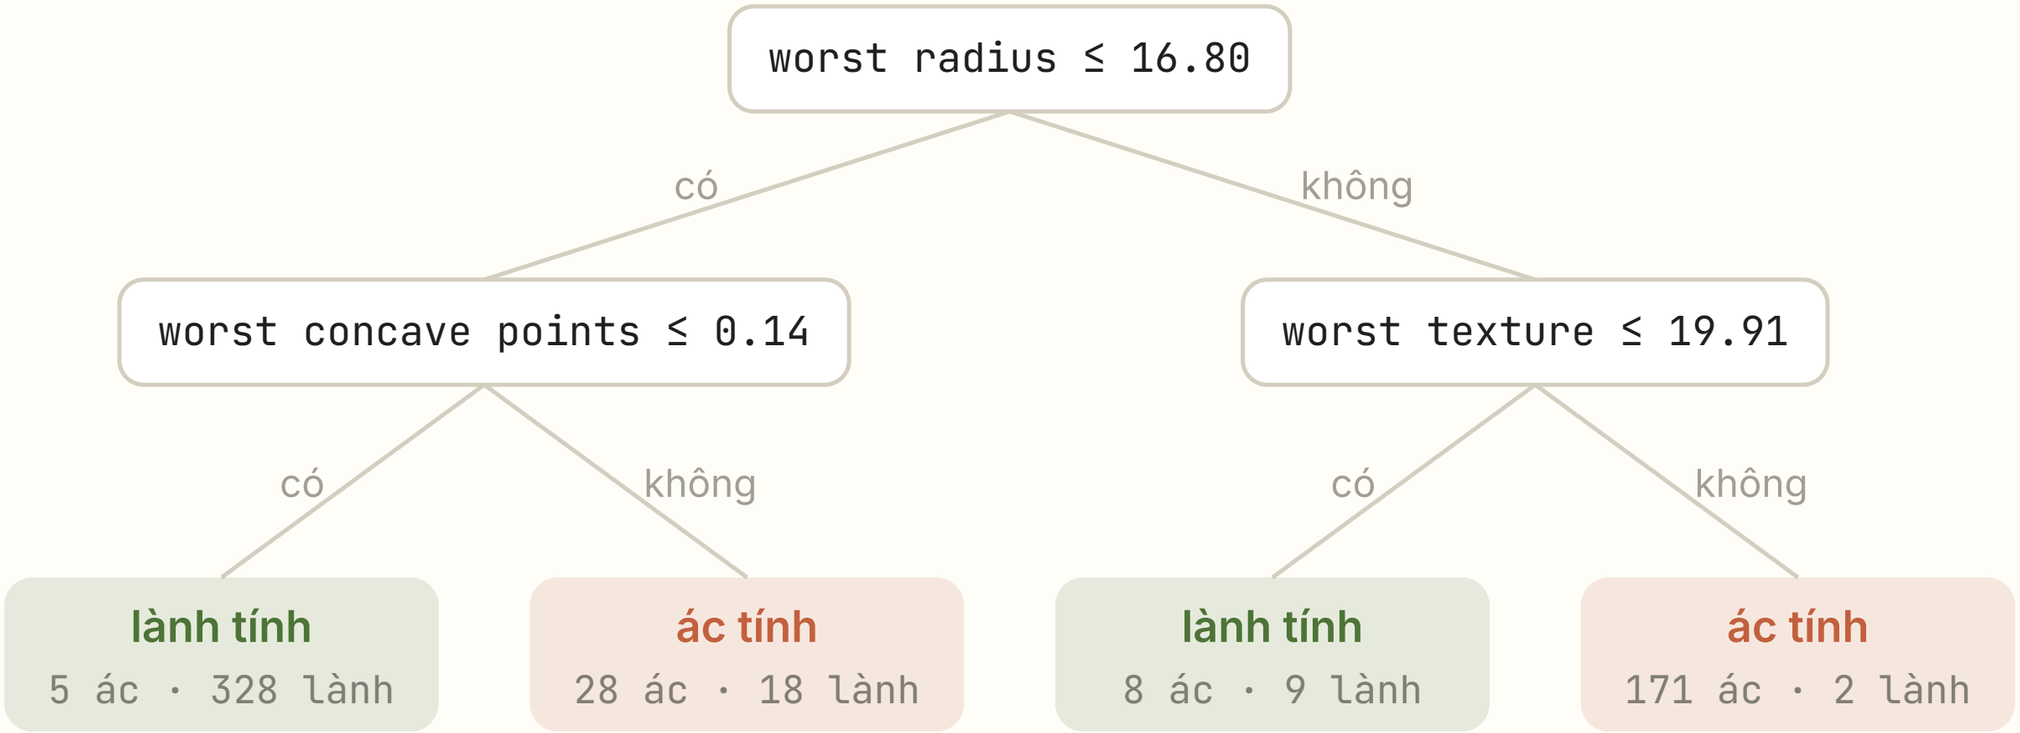
Trên `breast_cancer`, cây sâu hơn không thắng rõ.

`export_text` in các ngưỡng để đọc.

Importance theo impurity không chứng minh nhân quả; đối chiếu permutation importance trên validation.

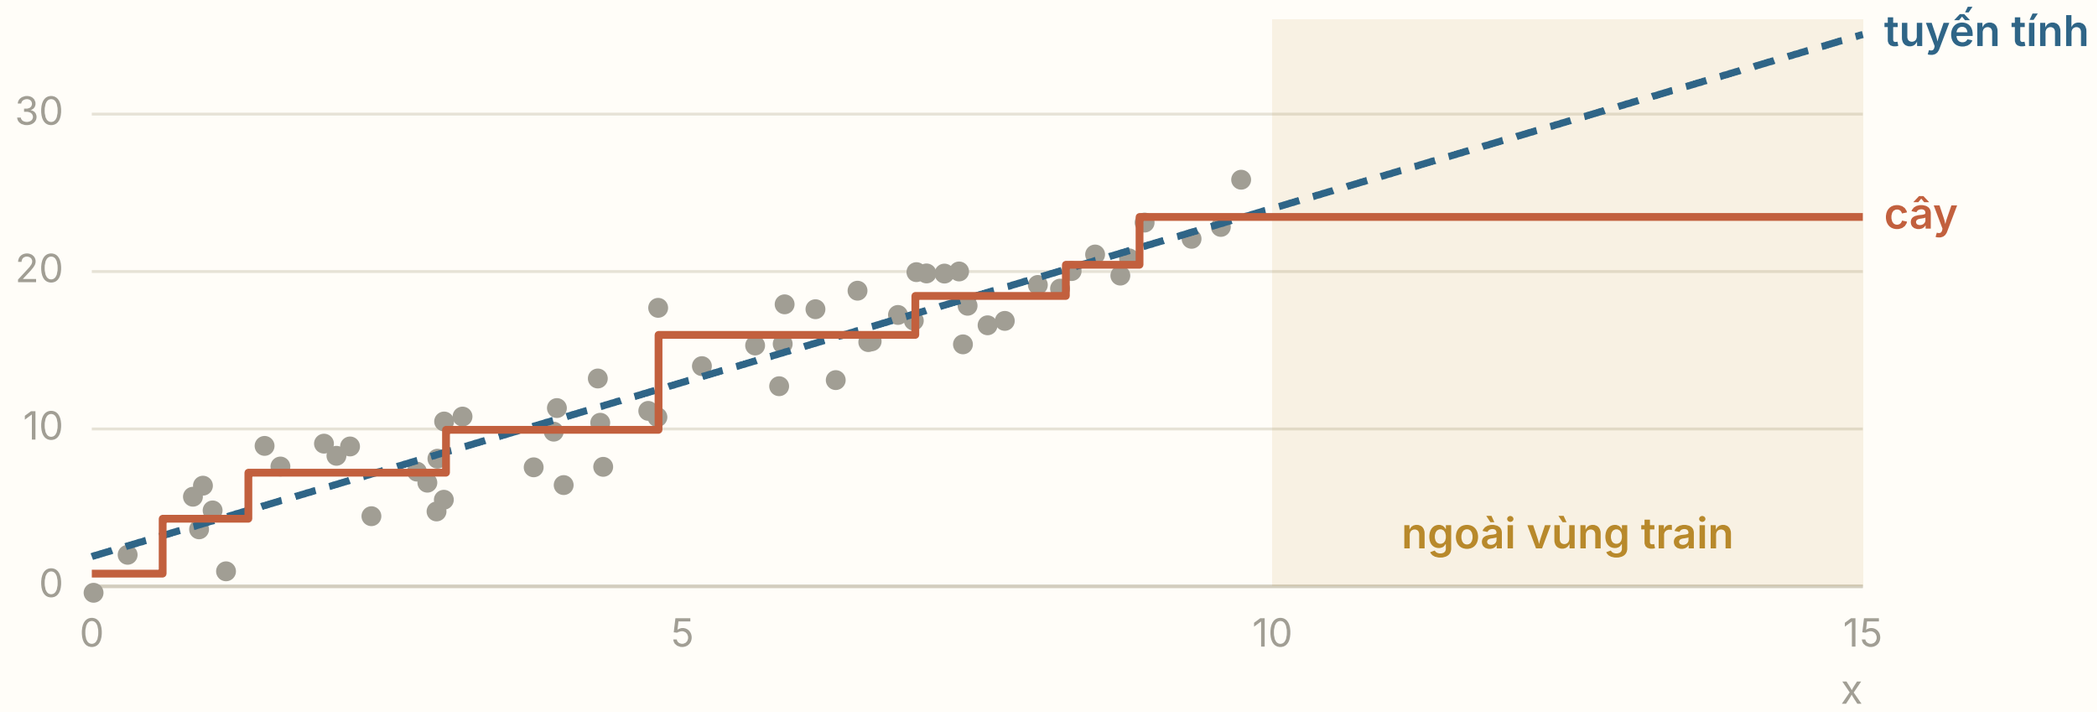
Cây hồi quy đoán trung bình của lá, nên không ngoại suy.

Cây độ sâu 2



Cây độ sâu 2 trên bộ breast cancer; mỗi lá ghi số mẫu ác tính, lành tính.

Cây không ngoại suy



Ngoài vùng train, cây giữ nguyên giá trị lá cuối; đường thẳng kéo dài xu hướng.

HỎI NHANH

Cross-validation cho độ sâu 1, 3, 5 và không giới hạn lần lượt được 0.900, 0.917, 0.916 và 0.917. Ta nên chọn gì, vì sao?

A Độ sâu 3, vì ngang điểm cao nhất mà đơn giản hơn

B Không giới hạn, vì điểm cao nhất và khỏi phải chọn

C Độ sâu 1, vì đơn giản nhất và chỉ kém 1.7 điểm

D Độ sâu 5, vì nằm giữa nên an toàn nhất

HỎI NHANH

Lỡ để cột `row_id` trong feature, mỗi dòng một số khác nhau. Cây sâu cho cột này impurity importance cao, nhưng permutation importance trên validation thì gần bằng 0. Hiểu thế nào?

A `row_id` thật sự quan trọng, phải giữ lại

B Permutation importance tính sai, nên tin impurity importance

C Hai cách đo luôn cho kết quả trái ngược nhau

D Cây dùng `row_id` để học thuộc train

Khi đi thi

- Cây nông 2–4 tầng để hiểu dữ liệu; độ sâu 1 đạt 99%: nghi lộ đáp án.
- Tự cài cây: đọc quy ước <=/<, phá hòa.
- Test ở tương lai: cây không ngoại suy.

03

Luyện đề

LUYỆN ĐỀ 1

Trên cùng tập train D, ta học hai cây. Một cây chọn phép chia theo information gain, cây kia theo tỉ lệ lỗi trên train. Cả hai đều mọc cho tới khi lỗi train bằng 0. Điều nào **chắc chắn** đúng?

A Hai cây chia theo cùng một feature ở gốc

B Hai cây có cùng độ sâu và cùng số lá

C Hai cây dùng hết mọi feature của D

D Hai cây dự đoán giống nhau trên mọi mẫu của D

PHỎNG THEO CMU 10-601 · Exam 1 Practice · Q1.2

LUYỆN ĐỀ 2

Dữ liệu dự đoán khách bỏ dịch vụ có 10 000 mẫu và 20 feature. Có 15% số ô bị thiếu, rải ngẫu nhiên. Trong bốn đề xuất sau, lập luận nào chính xác nhất?

A Dùng mô hình dạng cây, vì nhiều thư viện cây tự học hướng đi cho ô thiếu

B kNN cần đủ mọi ô, nên bỏ hết mẫu bị thiếu là cách duy nhất

C Linear regression với ô thiếu điền bằng trung bình là cách tối ưu về thống kê

D Dùng một mô hình tuyến tính, sau khi điền ô thiếu bằng giá trị của dòng phía trên

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 270

LUYỆN ĐỀ 3

Thuật toán học cây kiểu ID3 hay CART có bảo đảm tìm ra cây đạt lỗi train 0 với **ít phép chia nhất** không?

A Có, vì ở mỗi nút đều thử mọi feature và mọi ngưỡng

B Có, nếu dùng entropy thay cho Gini

C Không, vì nó chỉ chọn phép chia tốt nhất tại từng nút

D Không, vì cây không bao giờ đạt được lỗi train 0

PHỎNG THEO CMU 10-601 · Exam 1 Practice · Q1.3

Chốt ý

Phép chia tốt là phép làm Gini có trọng số giảm nhiều nhất.

CART chọn tham lam từng nút; cây sâu học thuộc, cần phanh và validation. Cây không ngoại suy.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook: đổi `max_depth` hoặc `min_samples_leaf`, đoán trước khoảng cách train–validation rồi kiểm lại.