Random forest

Giải thích bootstrap và chọn tập con đặc trưng ở từng nút.

Một cây đổi ý

Đổi vài mẫu train, cây có thể đổi ngưỡng từ gốc.

Ta muốn dự đoán bớt phụ thuộc một lượt dữ liệu.

Cho nhiều cây học hơi khác nhau rồi gộp.

Một nghìn cây giống nhau không thêm thông tin.

01

Tạo sự khác nhau

Hai nguồn ngẫu nhiên

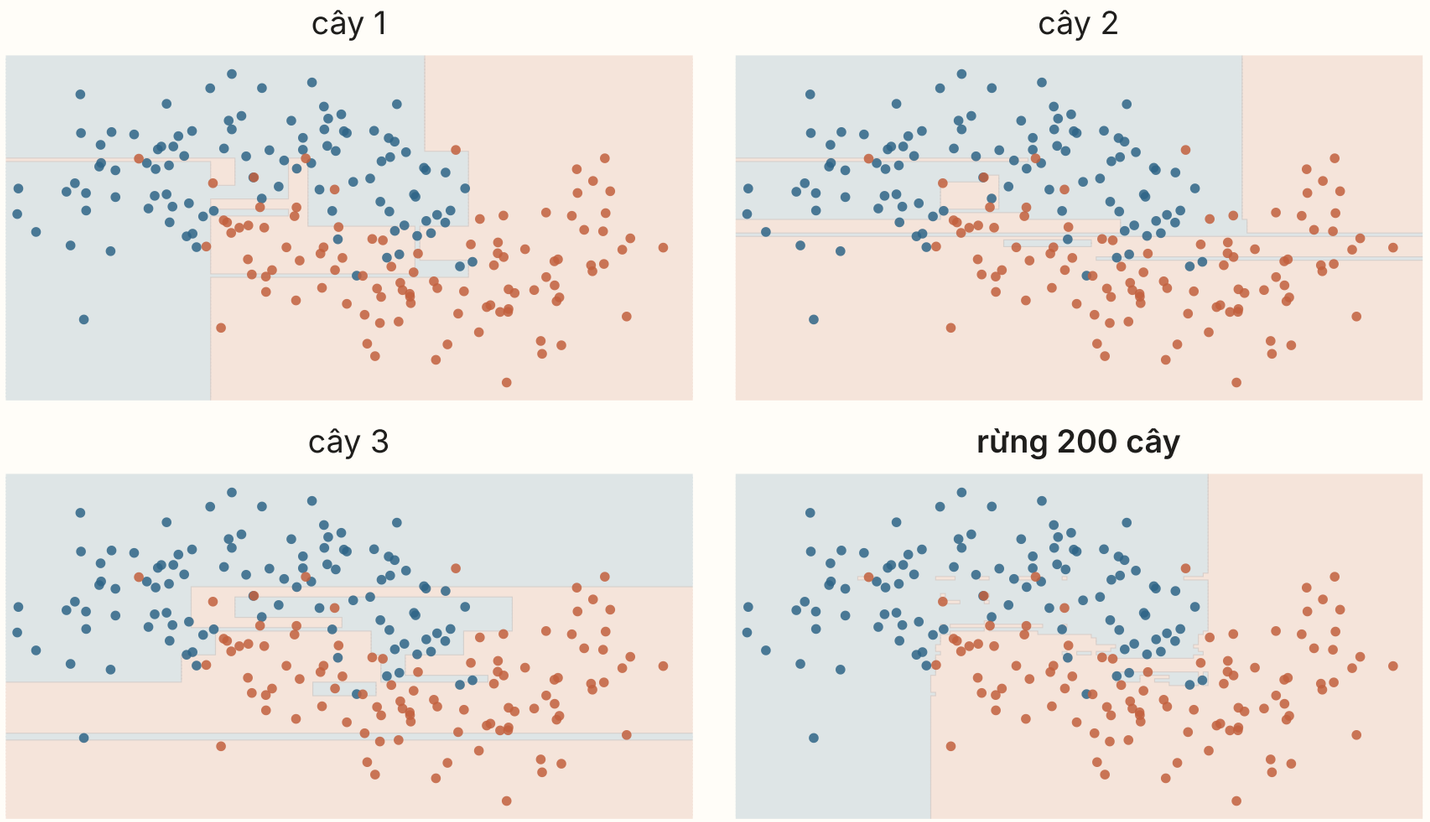
Bootstrap: rút n lần có hoàn lại.

Ở mỗi nút: xét tập con đặc trưng ngẫu nhiên.

Bootstrap đổi mẫu mỗi cây.

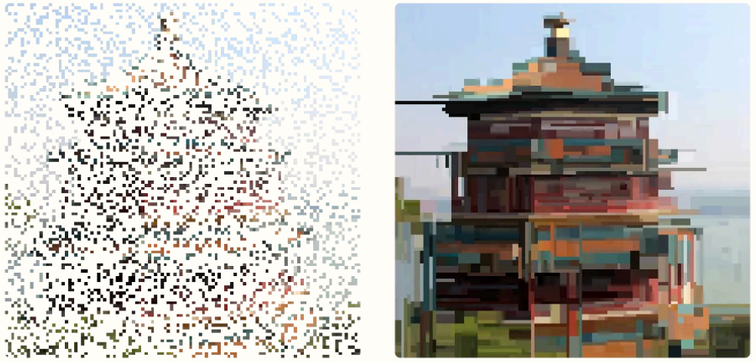
Chọn cột tại nút giảm việc mọi cây đều dùng cùng một cột mạnh.

Ba cây và cả rừng



Ba cây trong cùng một rừng, mỗi cây học một tập bootstrap nên ranh giới khác nhau; trung bình 200 cây cho ranh giới mượt hơn.

Trung bình nhiều cây trên ảnh thật



trung bình 1 cây: RMSE điểm chưa thấy 33.3 (một cây sâu không bootstrap: 25.5)



trung bình 5 cây: RMSE điểm chưa thấy 24.0



trung bình 20 cây: RMSE điểm chưa thấy 22.1



trung bình 100 cây: RMSE điểm chưa thấy 21.5

Random forest trên cùng bài đoán màu: mỗi cây học một mẫu bootstrap nên sai theo kiểu riêng; lấy trung bình nhiều cây thì ảnh mượt hơn và sai số trên điểm chưa thấy giảm.

HỎI NHANH

“Bootstrap n mẫu từ n mẫu gốc” nghĩa là gì?

A Rút n lần không hoàn lại, tức là xáo trộn thứ tự

B Rút n lần có hoàn lại từ n mẫu gốc

C Giữ mỗi mẫu đúng một lần, chỉ đổi trọng số

D Rút ngẫu nhiên $n/2$ mẫu, không lặp lại

HỎI NHANH

Muốn từng cây chính xác hơn, một bạn đặt `max_features` bằng toàn bộ d feature. Lỗi tổng quát của rừng có xu hướng thế nào?

A Giảm, vì từng cây có lỗi tổng quát thấp hơn

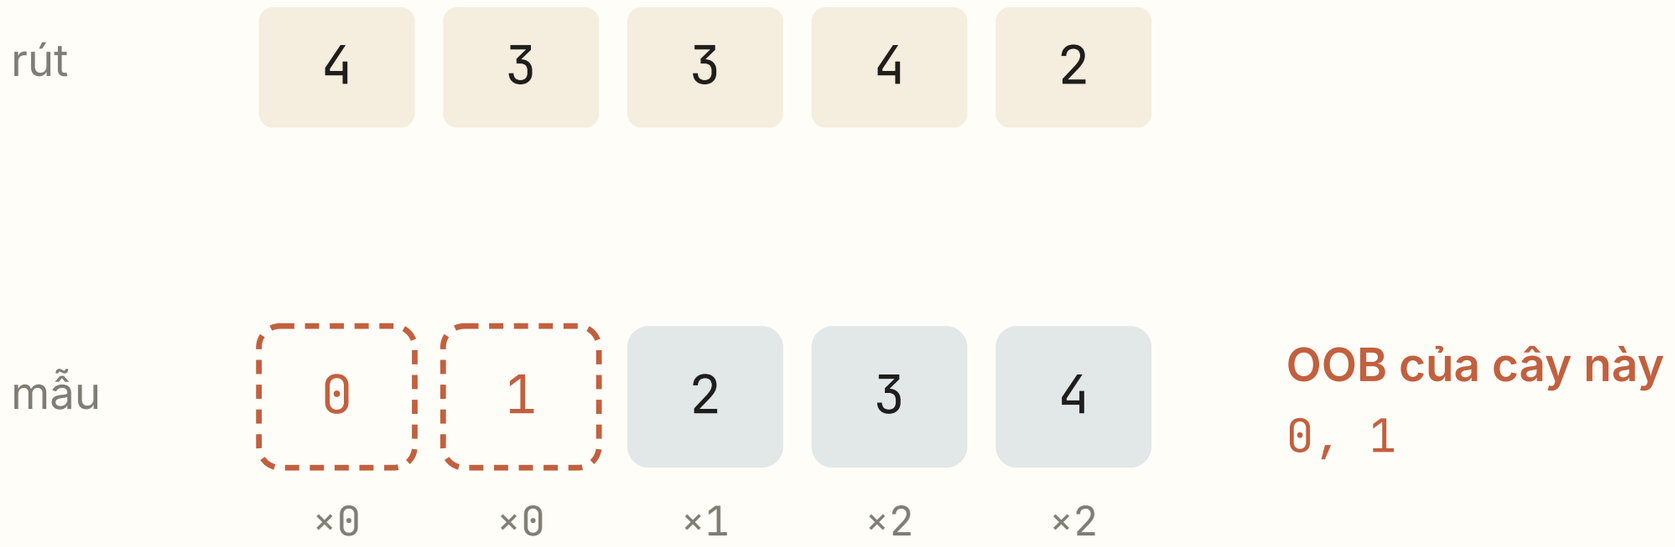
B Tăng, vì mỗi cây không có đủ dữ liệu train

C Tăng, vì các cây trở nên rất giống nhau

D Không đổi, vì bootstrap đã đủ tạo khác biệt

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q6.2(c)

Bootstrap không phải subset



Một lượt bootstrap từ code bài: rút 4, 3, 3, 4, 2; mẫu 3 và 4 lặp hai lần, mẫu 0 và 1 không được rút nên là OOB.

HỎI NHANH

Một cây có tập bootstrap gồm các chỉ số [0, 0, 2, 3, 3], lấy từ dữ liệu có 5 mẫu. Những mẫu nào là OOB?

A Mẫu 0 và 3, vì bị rút lặp

B Mẫu 1 và 4

C Chỉ mẫu 4, vì mẫu cuối không được rút

D Không có, vì đã rút đủ 5 lần

Đếm trên giấy

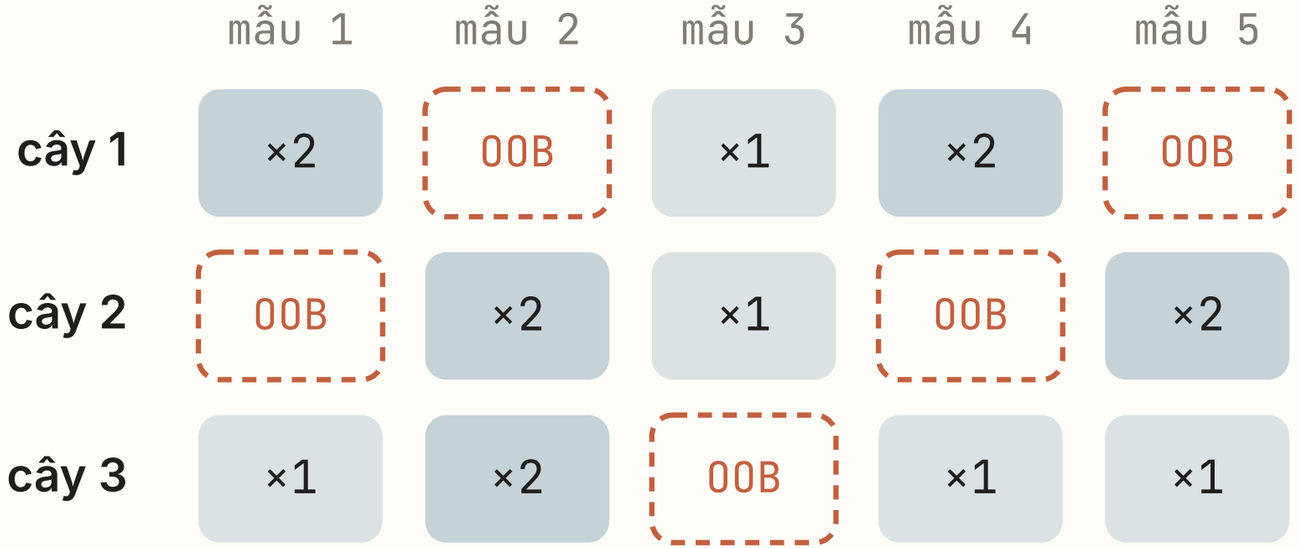
Một lượt rút [0,0,2,3,3] từ 5 mẫu.

Đã thấy: 0,2,3.

OOB: 1,4.

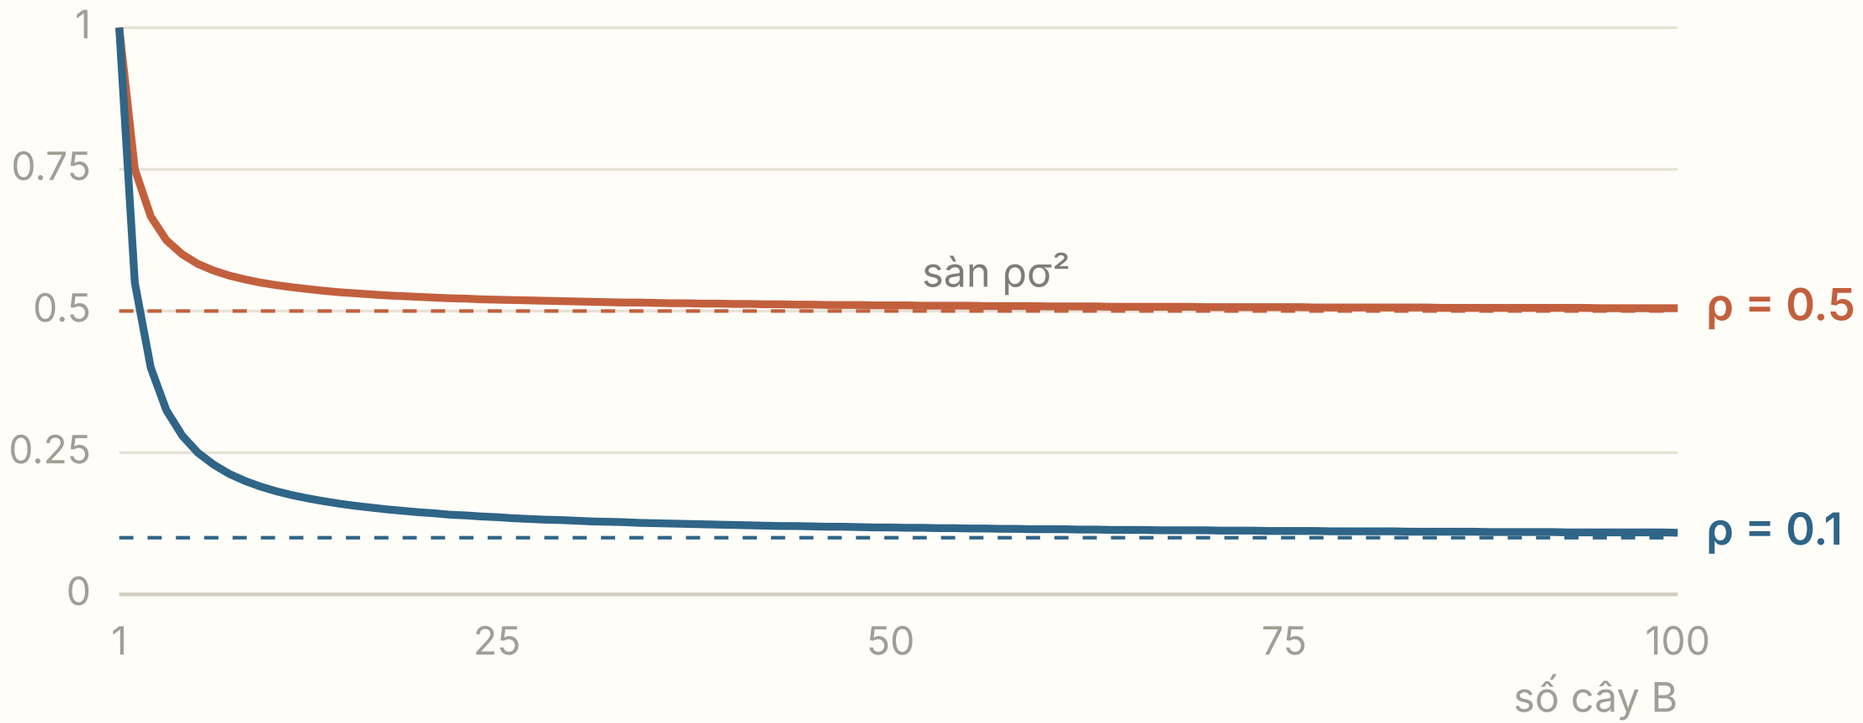
Mẫu 1 chỉ được dự đoán OOB bằng những cây không thấy nó.

Ba cây, năm mẫu



Ví dụ tính tay: ba tập bootstrap trên 5 mẫu; ô nét đứt là mẫu cây đó chưa thấy, dùng để chấm OOB.

Trung bình có giới hạn



Phương sai của trung bình B cây ($\sigma^2 = 1$): thêm cây chỉ kéo về mức sàn $\rho\sigma^2$; giảm tương quan mới hạ được sàn.

HỎI NHANH

Lấy $\sigma^2 = 1$. Rừng A có 50 cây, $\rho = 0.1$. Rừng B có 500 cây, $\rho = 0.4$. Theo công thức trên, rừng nào có phương sai của trung bình nhỏ hơn?

A A, vì tương quan thấp quan trọng hơn số cây

B B, vì nhiều cây gấp mười lần

C Bằng nhau, vì cả hai đều đã đủ nhiều cây

D Chưa so được khi chưa biết σ^2 thật

Giả định của phép tính

$$\mathrm{Var}(\bar{f}) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

Các mô hình phải có cùng phương sai và mọi cặp cùng tương quan. Đây là mô hình giải thích tác dụng của đa dạng, không phải dự báo chính xác metric của một rừng thật.

Khi $B \to \infty$, phần $(1-\rho)/B$ mất đi nhưng $\rho\sigma^2$ còn lại.

$\rho = 1$ thì thêm cây không giảm phương sai; giảm tương quan thường có ích hơn chỉ tăng số cây.

Với $B = 10$ cây, $\sigma^2 = 1$, $\rho = 0.2$: phương sai trung bình bằng $0.2 + 0.8/10 = 0.28$.

HỎI NHANH

100 cây được học với 100 seed khác nhau. Có thể coi dự đoán của chúng là độc lập, tức $\rho = 0$, để tính phương sai theo công thức trên không?

A Được, vì seed khác nhau thì bootstrap khác nhau

B Được, nếu `max_features` đủ nhỏ

C Không được, vì seed không ảnh hưởng gì tới cây

D Không được, vì các cây học chung dữ liệu và chung những tín hiệu mạnh

02

Gộp và kiểm

Phiếu và xác suất không luôn đồng ý

Ba cây: p=0.9,0.4,0.4.

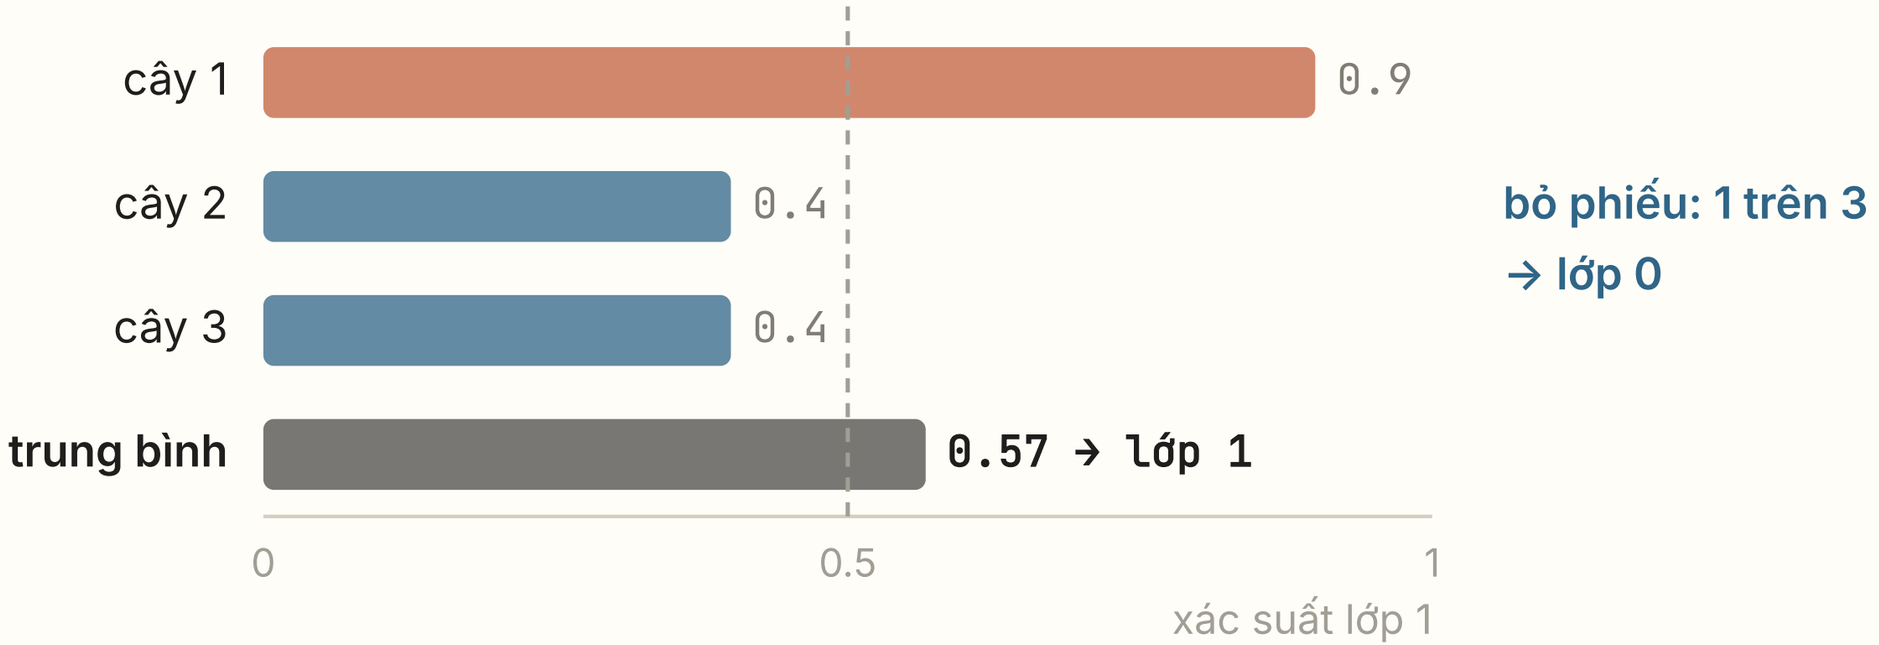
Đa số nhãn chọn 0.

Trung bình p≈0.567 → chọn 1.

sklearn dùng trung bình xác suất; đọc classes_ để biết cột lớp.

Một cây rất chắc chắn có thể thắng hai cây lưỡng lự. Vì vậy phải biết metric đang cần nhãn cắt ngưỡng hay xác suất để tính log loss/AUC.

Trung bình và bỏ phiếu



Ba cây cho xác suất 0.9, 0.4, 0.4: trung bình xác suất chọn lớp 1, bỏ phiếu chọn lớp 0.

Đối chiếu trên máy

Máy rút một lượt khác: 5 lần từ 5 mẫu.

```
seen = np.unique(draw)
oob = np.setdiff1d(np.arange(5), seen)
print("rút:", draw.tolist())
print("OOB:", oob.tolist())
```

KẾT QUẢ

```
rút: [4, 3, 3, 4, 2]
OOB: [0, 1]
```

Đếm “đã thấy” và OOB y như cách làm trên giấy.

OOB là phần dữ liệu chưa thấy

Xác suất một mẫu không xuất hiện trong n lượt rút có hoàn lại:

$$\left(1 - \frac{1}{n}\right)^n \to e^{-1} \approx 0.368.$$

Mỗi cây để ngoài khoảng 37% mẫu. OOB dự đoán mẫu bằng những cây không thấy mẫu đó.

OOB tiện cho mẫu độc lập cùng phân phối. Với nhiều hàng của cùng người hoặc dữ liệu tương lai, OOB theo hàng không thay thế `GroupKFold` hay time split.

HỎI NHANH

Train có 1000 mẫu. Với một cây trong rừng, khoảng bao nhiêu mẫu nằm ngoài tập bootstrap của nó, và trong tập ấy có khoảng bao nhiêu mẫu **khác nhau**?

A 0 mẫu nằm ngoài, 1000 mẫu khác nhau

B 500 mẫu nằm ngoài, 500 mẫu khác nhau

C Khoảng 632 mẫu nằm ngoài, khoảng 368 mẫu khác nhau

D Khoảng 368 mẫu nằm ngoài, khoảng 632 mẫu khác nhau

Một cây, một rừng, OOB

KẾT QUẢ

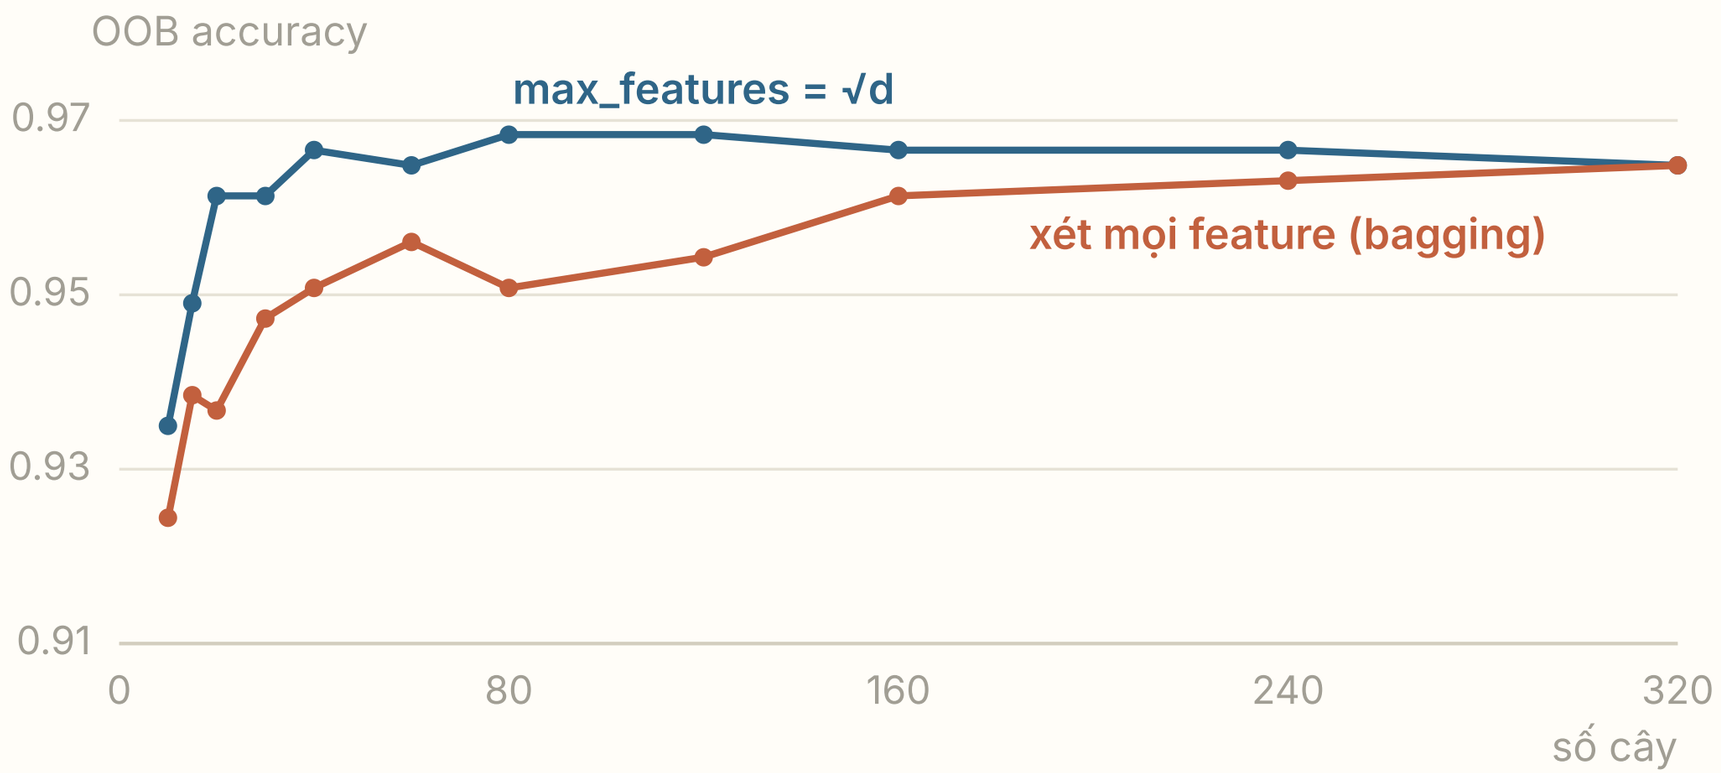
```
một cây: 0.917
rừng:    0.963
OOB:     0.968
```

Đây là một lần chạy `breast_cancer` với 80 cây và `n_jobs=1`. OOB gần điểm CV trong thí nghiệm này, nhưng không phải bảo đảm cho split nhóm hoặc thời gian.

`n_estimators` tăng thường làm trung bình ổn định hơn.

`max_features` giảm tương quan giữa cây; `min_samples_leaf` làm mỗi cây mượt hơn. Đổi tham số phải đo cả điểm, RAM và thời gian.

OOB theo số cây



Breast cancer: OOB accuracy theo số cây. Với √d feature mỗi nút, sau khoảng 80 cây đường gần như đứng yên; bagging thuần cần nhiều cây hơn mới bắt kịp.

HỎI NHANH

Điểm OOB của rừng là 0.968, còn cross-validation 5 fold cho 0.963. Hiểu chênh lệch này thế nào?

A OOB bị rò rỉ, vì cao hơn CV

B CV sai, vì OOB dùng nhiều dữ liệu hơn

C Hai cách lấy mẫu khác nhau, chênh nhỏ như vậy là bình thường

D Phải chọn số cây sao cho hai con số bằng nhau

HỎI NHANH

Mỗi bệnh nhân có 4 bản ghi, và mục tiêu là dự đoán cho bệnh nhân mới. Nhưng OOB tính theo hàng vẫn để một bản ghi được chấm bởi những cây đã học các bản ghi khác của cùng người. Ta nên đánh giá bổ sung thế nào?

A Để riêng theo bệnh nhân, rồi chấm cả quy trình

B Chỉ cần tăng số cây, để hàng nào cũng có nhiều dự đoán OOB hơn

C Chỉ cần tăng `min_samples_leaf`, để cấm trùng bệnh nhân

D Dùng StratifiedKFold theo từng hàng thay cho chia theo nhóm

Khi đi thi

- Random forest: baseline khó hỏng trong 15 phút đầu bài dữ liệu bảng.
- OOB chỉ hợp khi các hàng độc lập; dữ liệu nhóm, thời gian thì dùng split riêng.
- Đọc `classes_` trước khi lấy xác suất.
- Validation đứng yên khi thêm cây: thử `max_features`, feature, dữ liệu.

03

Luyện đề

LUYỆN ĐỀ 1

Rừng 5 cây học trên 7 mẫu, gộp bằng đa số phiếu. Bảng ghi phiếu OOB (C là Có, K là Không). Lỗi OOB của rừng bằng bao nhiêu?

Mẫu	1	2	3	4	5	6	7
Thật	K	K	C	C	K	C	C
Phiếu OOB	K	K, C, C	C	C	K	K	K, K

A $5/10$

B $3/7$

C $2/7$

D $4/7$

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q6.2(a)

LUYỆN ĐỀ 2

Trong bảng của câu trước, có một cây đúng mọi mẫu OOB của nó, và một cây khác sai mọi mẫu. Khi dự đoán một mẫu mới, random forest chuẩn cho cây nào trọng số cao nhất?

A Cây đúng mọi mẫu OOB

B Cây có nhiều mẫu OOB nhất

C Không cây nào, các cây góp phần ngang nhau

D Cây sai mọi mẫu, nhưng đảo ngược dự đoán của nó

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q6.2(b)

LUYỆN ĐỀ 3

Tăng `n_estimators` từ 100 lên 1000. Accuracy trên train tăng từ 99.2% lên 99.8%, trên validation vẫn đứng ở 87.3%, còn thời gian chạy tăng gấp 10. Nhận định nào phù hợp?

A Validation đứng yên chứng tỏ phải tăng độ sâu của cây

B Cứ tăng số cây tới khi train đạt 100%, rồi chọn theo train

C Train tăng 0.6 điểm, nên sau này validation cũng sẽ tăng

D Lợi ích của việc thêm cây đã bão hòa, nên thử yếu tố khác

PHỎNG THEO NOAI 2026 Singapore · Chung kết · Câu 2

Chốt ba điều

Bootstrap đổi mẫu; `max_features` đổi cột được xét tại mỗi nút.

OOB dùng các cây chưa thấy mẫu; bỏ phiếu và trung bình xác suất có thể khác nhau.

Kiểm soát độ phức tạp, chi phí và điều kiện của feature importance.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook từ đầu; đổi `max_features` hoặc `min_samples_leaf`, dự đoán độ đa dạng và điểm OOB, rồi kiểm bằng output.