Random forest

Gộp nhiều cây khác nhau để dự đoán ổn định hơn

Một cây đổi ý

Đổi vài mẫu train, cây có thể đổi ngưỡng từ gốc.

Ta muốn dự đoán bớt phụ thuộc một lượt dữ liệu.

Cho nhiều cây học hơi khác nhau rồi gộp.

Một nghìn cây giống nhau không thêm thông tin.

Mục tiêu

- Hiểu bootstrap và việc chọn ngẫu nhiên đặc trưng ở mỗi nút.
- Tính điểm OOB.
- Chọn số cây, độ sâu; đọc feature importance.

01

Tạo sự khác nhau

Hai nguồn ngẫu nhiên

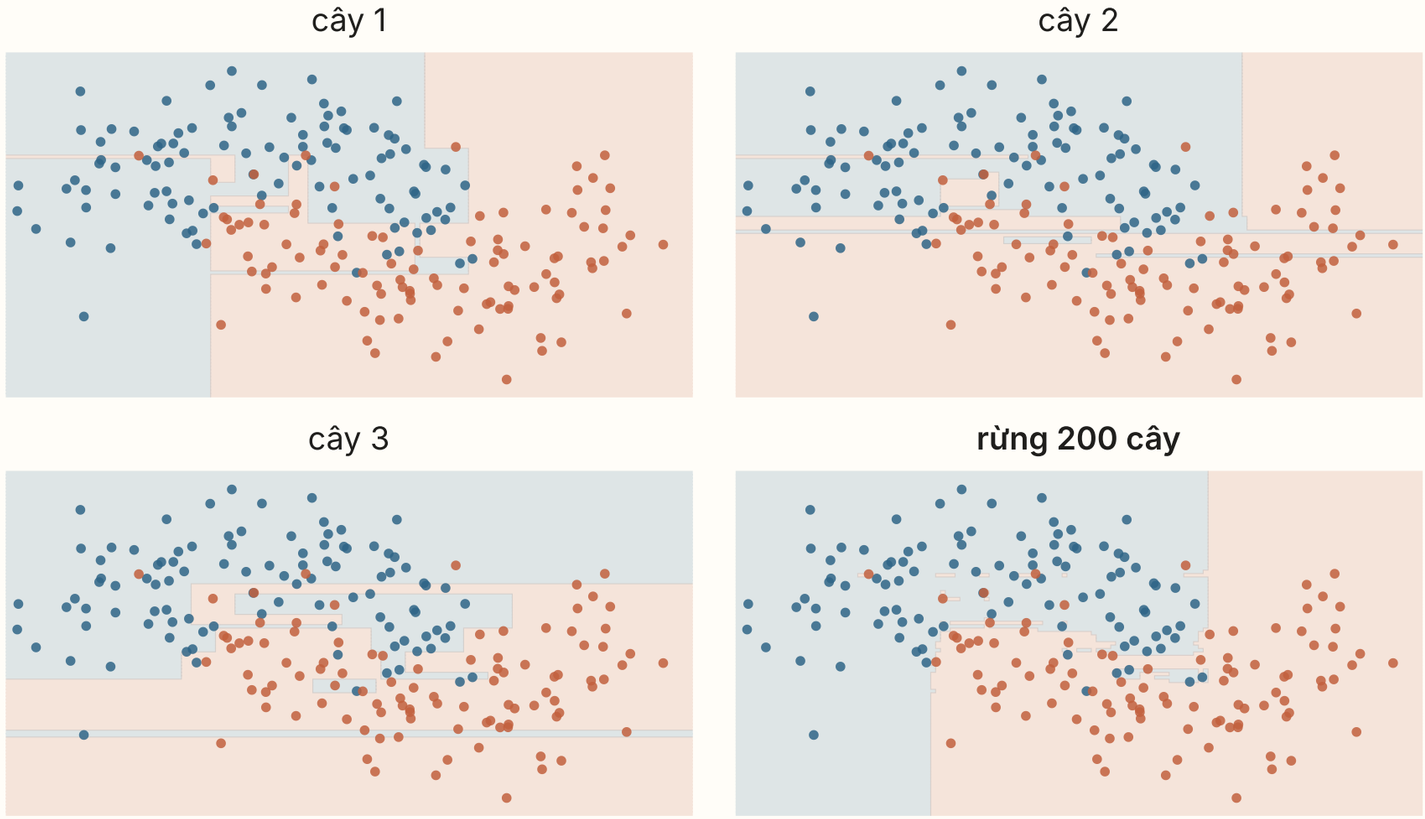
Bootstrap: rút n lần có hoàn lại.

Ở mỗi nút: xét tập con đặc trưng ngẫu nhiên.

Bootstrap đổi mẫu mỗi cây.

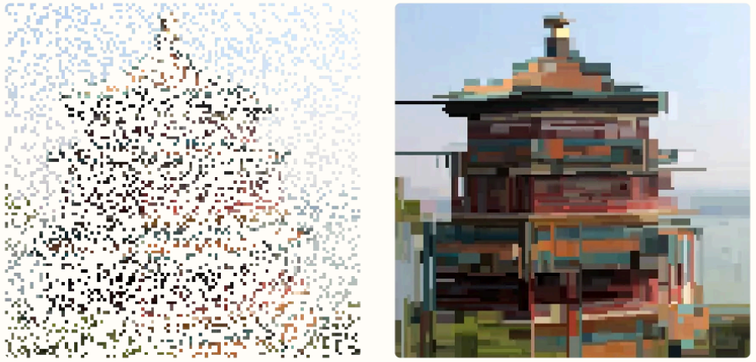
Chọn cột tại nút giảm việc mọi cây đều dùng cùng một cột mạnh.

Ba cây và cả rừng



Mỗi cây học một tập bootstrap nên ranh giới khác nhau; trung bình 200 cây mượt hơn.

Trung bình nhiều cây trên ảnh thật



trung bình 1 cây: RMSE điểm chưa thấy 33.3 (một cây sâu không bootstrap: 25.5)



trung bình 5 cây: RMSE điểm chưa thấy 24.0



trung bình 20 cây: RMSE điểm chưa thấy 22.1



trung bình 100 cây: RMSE điểm chưa thấy 21.5

Random forest trên cùng bài đoán màu: mỗi cây học một mẫu bootstrap nên sai theo kiểu riêng; lấy trung bình nhiều cây thì ảnh mượt hơn và sai số trên điểm chưa thấy giảm.

HỎI NHANH

“Bootstrap n mẫu từ n mẫu gốc” nghĩa là gì?

A Rút n lần không hoàn lại, tức là xáo trộn thứ tự

B Rút n lần có hoàn lại từ n mẫu gốc

C Giữ mỗi mẫu đúng một lần, chỉ đổi trọng số

D Rút ngẫu nhiên $n/2$ mẫu, không lặp lại

HỎI NHANH

Muốn từng cây chính xác hơn, một bạn đặt `max_features` bằng toàn bộ d feature. Lỗi tổng quát của rừng có xu hướng thế nào?

A Giảm, vì từng cây có lỗi tổng quát thấp hơn

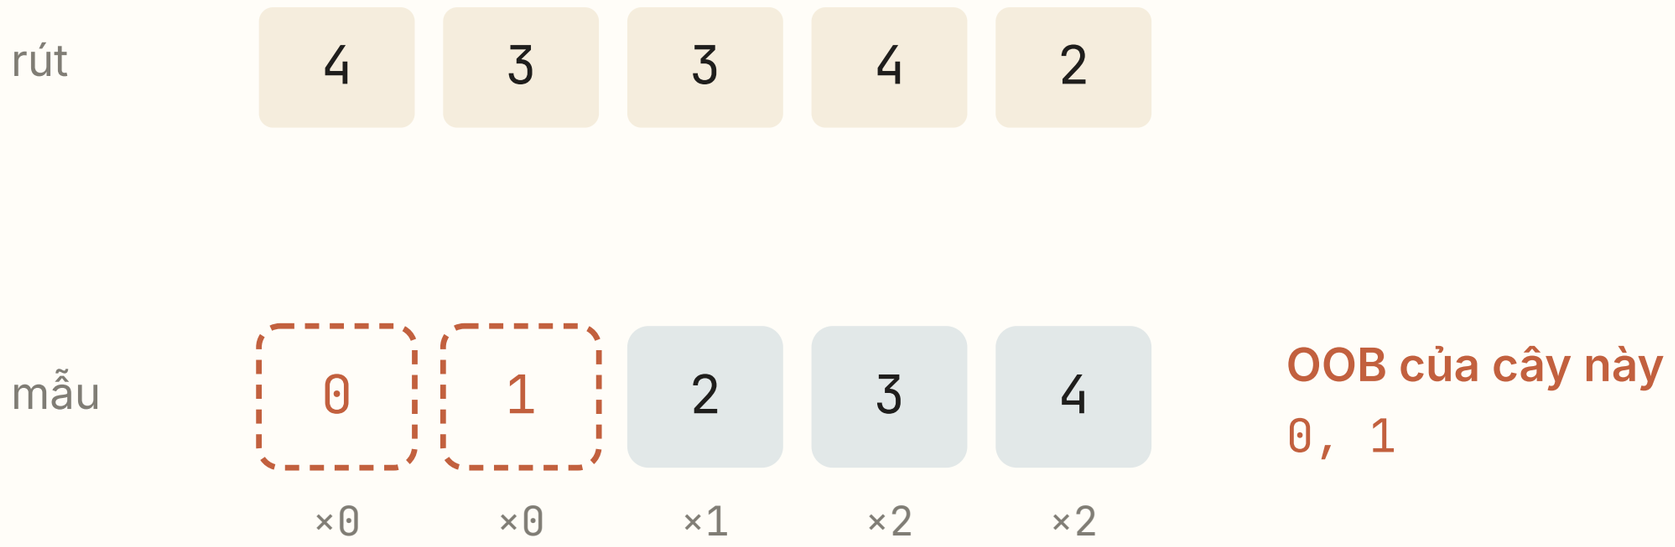
B Tăng, vì mỗi cây không có đủ dữ liệu train

C Tăng, vì các cây trở nên rất giống nhau

D Không đổi, vì bootstrap đã đủ tạo khác biệt

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q6.2(c)

Bootstrap không phải subset



Một lượt bootstrap: mẫu 3, 4 lặp hai lần; mẫu 0, 1 không được rút nên là OOB.

HỎI NHANH

Một cây có tập bootstrap gồm các chỉ số [0, 0, 2, 3, 3], lấy từ dữ liệu có 5 mẫu. Những mẫu nào là OOB?

A Mẫu 0 và 3, vì bị rút lặp

B Mẫu 1 và 4

C Chỉ mẫu 4, vì mẫu cuối không được rút

D Không có, vì đã rút đủ 5 lần

Đếm trên giấy

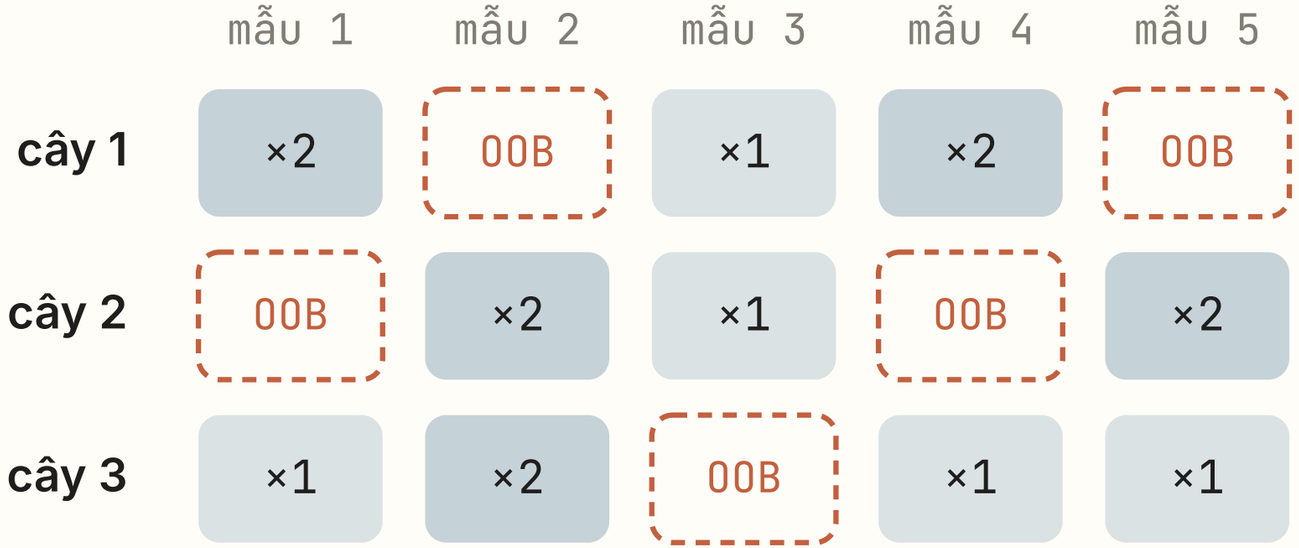
Một lượt rút [0,0,2,3,3] từ 5 mẫu.

Đã thấy: 0,2,3.

OOB: 1,4.

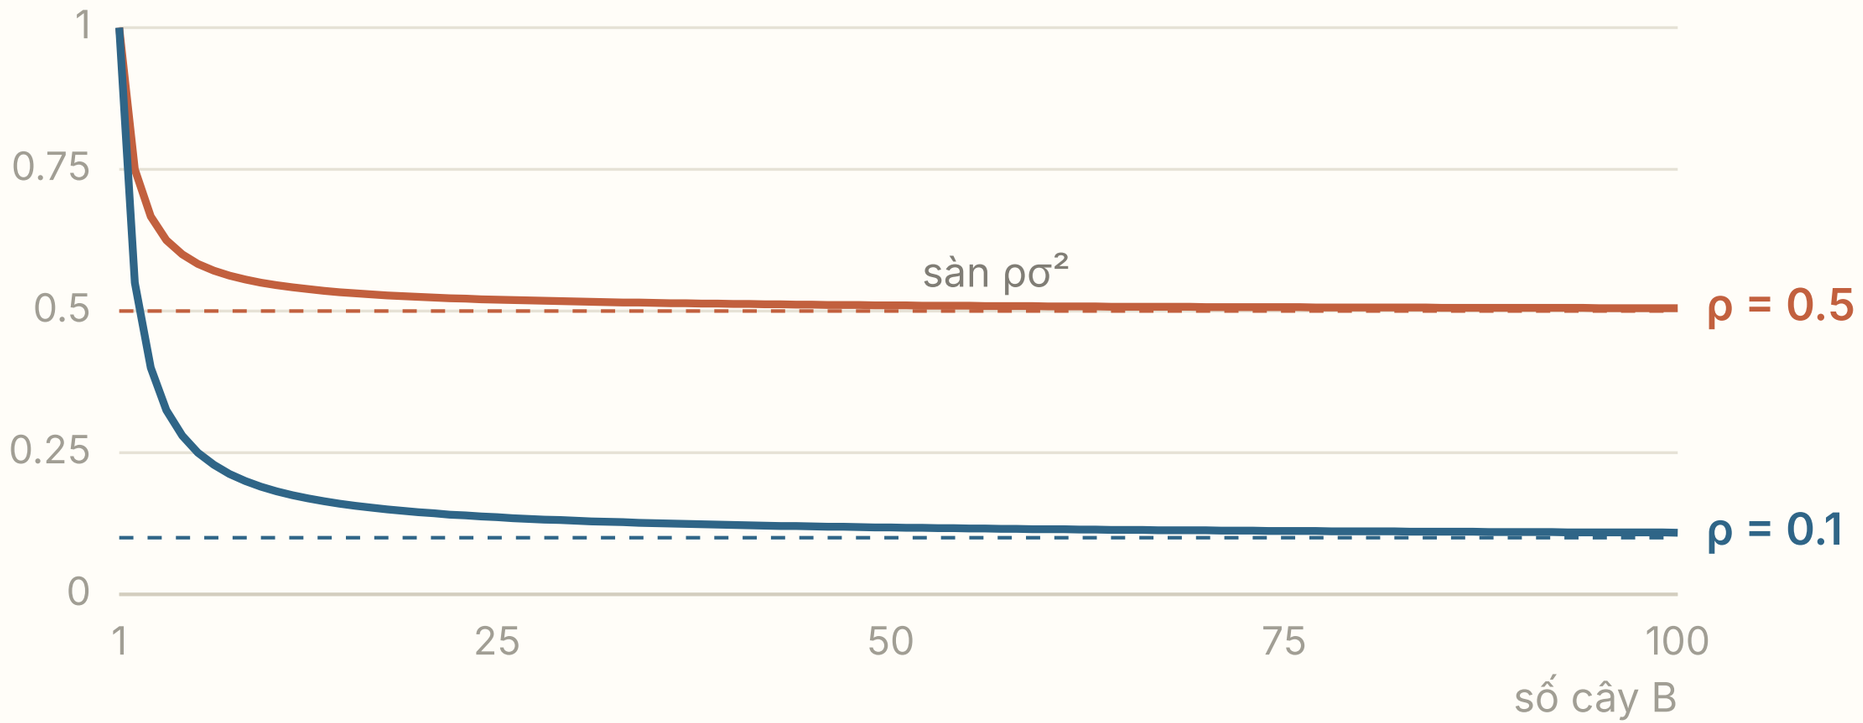
Mẫu 1 chỉ được dự đoán OOB bằng những cây không thấy nó.

Ba cây, năm mẫu



Ô nét đứt là mẫu cây đó chưa thấy, dùng để chấm OOB.

Trung bình có giới hạn



Thêm cây chỉ kéo phương sai về mức sàn $\rho\sigma^2$; giảm tương quan mới hạ được sàn.

HỎI NHANH

Lấy $\sigma^2 = 1$. Rừng A có 50 cây, $\rho = 0.1$. Rừng B có 500 cây, $\rho = 0.4$. Theo công thức trên, rừng nào có phương sai của trung bình nhỏ hơn?

A A, vì tương quan thấp quan trọng hơn số cây

B B, vì nhiều cây gấp mười lần

C Bằng nhau, vì cả hai đều đã đủ nhiều cây

D Chưa so được khi chưa biết σ^2 thật

Giả định của phép tính

$$\mathrm{Var}(\bar{f}) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

Giả định: mọi cây cùng phương sai σ^2, mọi cặp cùng tương quan ρ.

$B \to \infty$: phần $(1-\rho)/B$ mất đi, phần $\rho\sigma^2$ còn nguyên.

Ví dụ $B = 10$, $\sigma^2 = 1$, $\rho = 0.2$: $0.2 + 0.8/10 = 0.28$.

HỎI NHANH

100 cây được học với 100 seed khác nhau. Có thể coi dự đoán của chúng là độc lập, tức $\rho = 0$, để tính phương sai theo công thức trên không?

A Được, vì seed khác nhau thì bootstrap khác nhau

B Được, nếu `max_features` đủ nhỏ

C Không được, vì seed không ảnh hưởng gì tới cây

D Không được, vì các cây học chung dữ liệu và chung những tín hiệu mạnh

02

Gộp và kiểm

Phiếu và xác suất không luôn đồng ý

Ba cây: p=0.9,0.4,0.4.

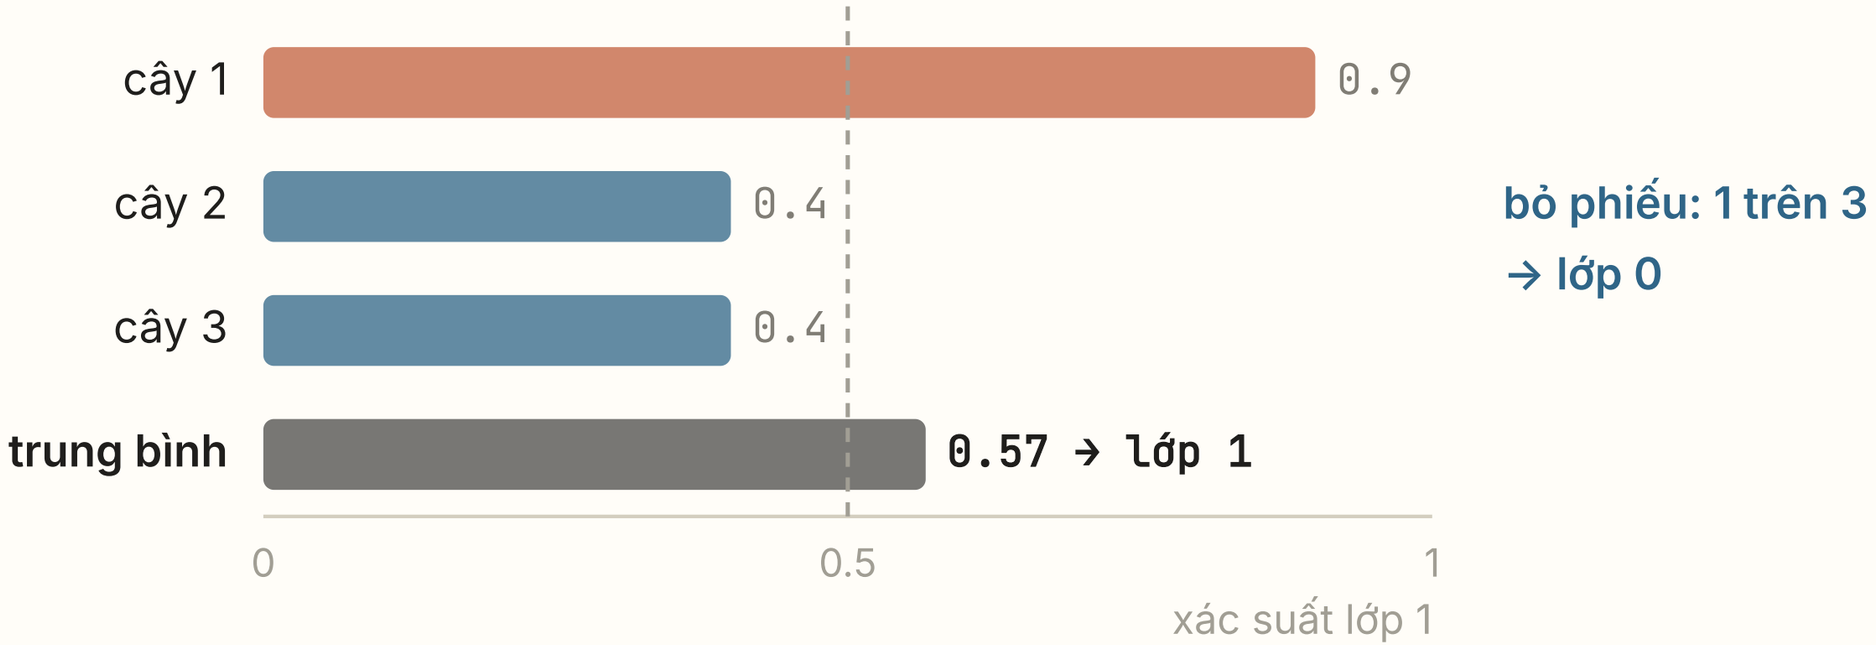
Đa số nhãn chọn 0.

Trung bình $p \approx 0.567$ → chọn 1.

Một cây rất chắc chắn thắng hai cây lưỡng lự.

scikit-learn lấy trung bình xác suất; cần xác suất cho log loss hay AUC thì dùng cách này.

Trung bình và bỏ phiếu



Trung bình xác suất chọn lớp 1; bỏ phiếu chọn lớp 0.

Đối chiếu trên máy

Máy rút một lượt khác: 5 lần từ 5 mẫu.

```
seen = np.unique(draw)
oob = np.setdiff1d(np.arange(5), seen)
print("rút:", draw.tolist())
print("đã thấy:", seen.tolist(), "OOB:", oob.tolist())
```

KẾT QUẢ

```
rút: [4, 3, 3, 4, 2]
đã thấy: [2, 3, 4] OOB: [0, 1]
```

Đếm “đã thấy” và OOB y như cách làm trên giấy.

OOB là phần dữ liệu chưa thấy

Xác suất một mẫu không xuất hiện trong n lượt rút có hoàn lại:

$$\left(1 - \frac{1}{n}\right)^n \to e^{-1} \approx 0.368.$$

Mỗi cây để ngoài khoảng 37% mẫu; mỗi mẫu được chấm bởi các cây không thấy nó.

OOB hợp khi các hàng độc lập.

Nhiều hàng của cùng người, hay dữ liệu theo thời gian: vẫn cần `GroupKFold` hoặc chia theo thời gian.

HỎI NHANH

Train có 1000 mẫu. Với một cây trong rừng, khoảng bao nhiêu mẫu nằm ngoài tập bootstrap của nó, và trong tập ấy có khoảng bao nhiêu mẫu **khác nhau**?

A 0 mẫu nằm ngoài, 1000 mẫu khác nhau

B 500 mẫu nằm ngoài, 500 mẫu khác nhau

C Khoảng 632 mẫu nằm ngoài, khoảng 368 mẫu khác nhau

D Khoảng 368 mẫu nằm ngoài, khoảng 632 mẫu khác nhau

Một cây, một rừng, OOB

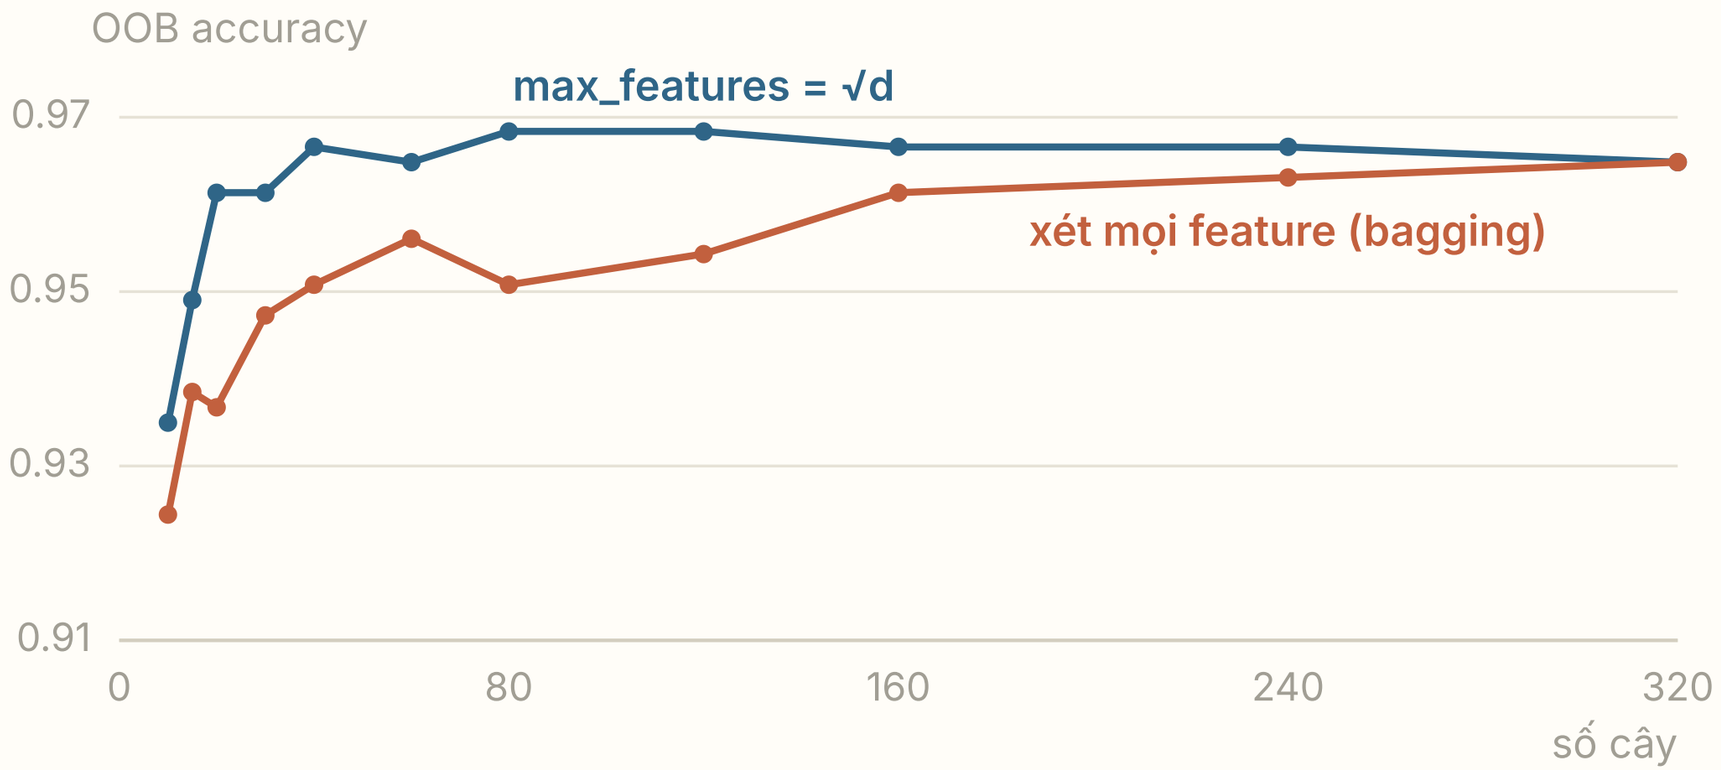
KẾT QUẢ

```
một cây: 0.917
rừng:    0.963
OOB:     0.968
```

`breast_cancer`, 80 cây: OOB gần điểm CV.

- `n_estimators`: nhiều cây thì ổn định hơn, tới lúc bão hòa.
- `max_features`: nhỏ thì các cây ít giống nhau.
- `min_samples_leaf`: lớn thì mỗi cây mượt hơn.

OOB theo số cây



OOB accuracy theo số cây: sau khoảng 80 cây gần như đứng yên.

HỎI NHANH

Điểm OOB của rừng là 0.968, còn cross-validation 5 fold cho 0.963. Hiểu chênh lệch này thế nào?

A OOB bị rò rỉ, vì cao hơn CV

B CV sai, vì OOB dùng nhiều dữ liệu hơn

C Hai cách lấy mẫu khác nhau, chênh nhỏ như vậy là bình thường

D Phải chọn số cây sao cho hai con số bằng nhau

HỎI NHANH

Mỗi bệnh nhân có 4 bản ghi, và mục tiêu là dự đoán cho bệnh nhân mới. Nhưng OOB tính theo hàng vẫn để một bản ghi được chấm bởi những cây đã học các bản ghi khác của cùng người. Ta nên đánh giá bổ sung thế nào?

A Để riêng theo bệnh nhân, rồi chấm cả quy trình

B Chỉ cần tăng số cây, để hàng nào cũng có nhiều dự đoán OOB hơn

C Chỉ cần tăng `min_samples_leaf`, để cấm trùng bệnh nhân

D Dùng StratifiedKFold theo từng hàng thay cho chia theo nhóm

Khi đi thi

- Random forest làm baseline sớm cho dữ liệu bảng.
- OOB chỉ hợp khi các hàng độc lập.
- Validation đứng yên: thử `max_features`, feature mới.

03

Luyện đề

LUYỆN ĐỀ 1

Rừng 5 cây học trên 7 mẫu, gộp bằng đa số phiếu. Bảng ghi phiếu OOB (C là Có, K là Không). Lỗi OOB của rừng bằng bao nhiêu?

Mẫu	1	2	3	4	5	6	7
Thật	K	K	C	C	K	C	C
Phiếu OOB	K	K, C, C	C	C	K	K	K, K

A $5/10$

B $3/7$

C $2/7$

D $4/7$

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q6.2(a)

LUYỆN ĐỀ 2

Trong bảng của câu trước, có một cây đúng mọi mẫu OOB của nó, và một cây khác sai mọi mẫu. Khi dự đoán một mẫu mới, random forest chuẩn cho cây nào trọng số cao nhất?

A Cây đúng mọi mẫu OOB

B Cây có nhiều mẫu OOB nhất

C Không cây nào, các cây góp phần ngang nhau

D Cây sai mọi mẫu, nhưng đảo ngược dự đoán của nó

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q6.2(b)

LUYỆN ĐỀ 3

Tăng `n_estimators` từ 100 lên 1000. Accuracy trên train tăng từ 99.2% lên 99.8%, trên validation vẫn đứng ở 87.3%, còn thời gian chạy tăng gấp 10. Nhận định nào phù hợp?

A Validation đứng yên chứng tỏ phải tăng độ sâu của cây

B Cứ tăng số cây tới khi train đạt 100%, rồi chọn theo train

C Train tăng 0.6 điểm, nên sau này validation cũng sẽ tăng

D Lợi ích của việc thêm cây đã bão hòa, nên thử yếu tố khác

PHỎNG THEO NOAI 2026 Singapore · Chung kết · Câu 2

Chốt ý

Bootstrap và `max_features` làm các cây khác nhau; trung bình nhiều cây bớt dao động.

Tương quan giữa các cây chặn mức lợi; OOB là validation miễn phí khi các hàng độc lập.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook: đổi `max_features`, xem điểm OOB và độ khác nhau giữa các cây.