SVM

Tính signed score, khoảng cách và hinge loss của một điểm.

Vạch nào an toàn hơn?

Nhiều vạch tách được hai đội.

Ta muốn còn khoảng trống ở hai bên.

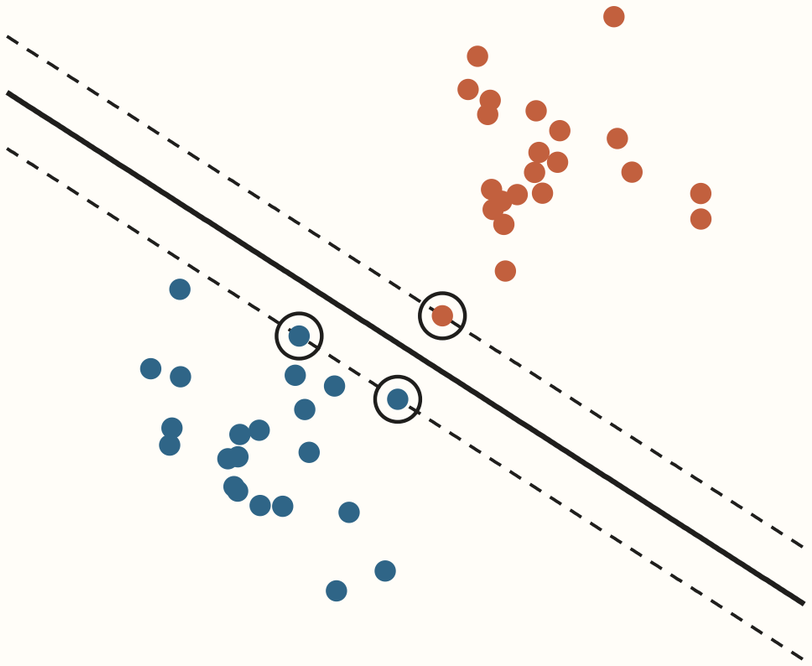
Lề rộng giúp mô hình bớt nhạy với điểm hơi lệch.

Cần phân biệt score và khoảng cách.

01

Lề và hinge loss

Các điểm sát biên



SVM lề cứng: vạch f = 0 nằm giữa hai đường lề; chỉ các điểm khoanh tròn trên lề quyết định vị trí vạch.

Hard margin chuẩn hóa lề bằng $y_i f(x_i) \geq 1$ và tối thiểu $\frac{1}{2}\|w\|^2$. Hai biên là $f(x) = \pm 1$, nên độ rộng giữa chúng là $2/\|w\|$.

HỎI NHANH

Sau khi chuẩn hóa, hai biên lề $f(\mathbf{x}) = \pm 1$ cách nhau đúng 1 đơn vị. $\|\mathbf{w}\|$ bằng bao nhiêu?

A 0.5

B 1

C 4

D 2

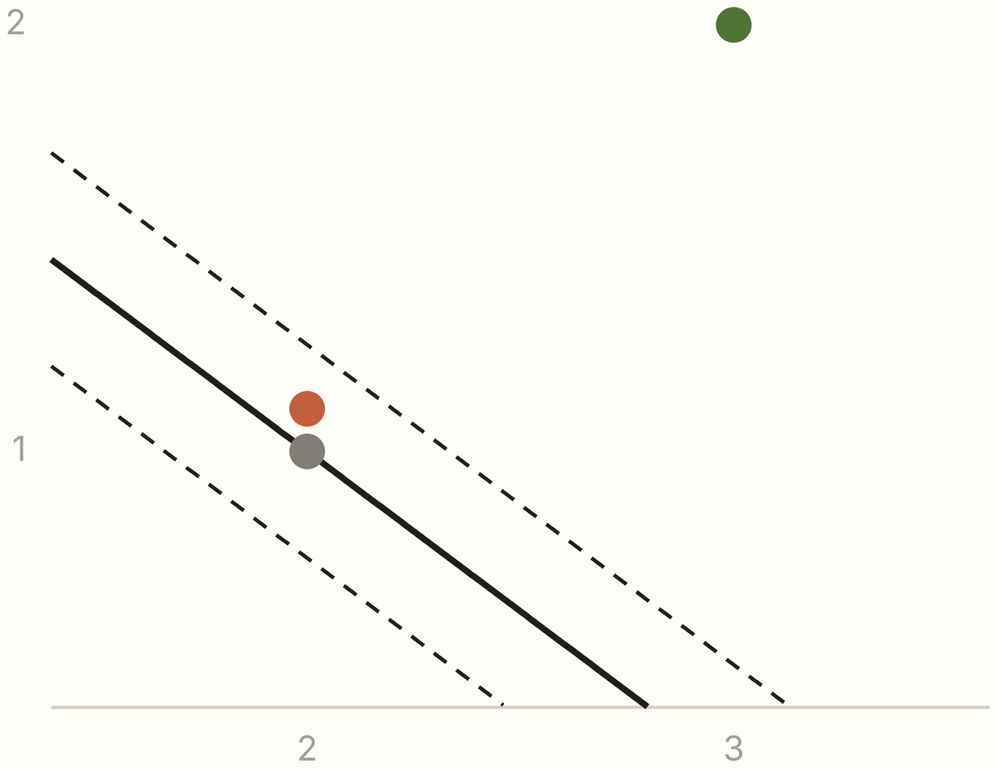
Score và khoảng cách

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b, \qquad d = \frac{|f(\mathbf{x})|}{\|\mathbf{w}\|}.$$

$$\mathbf{w} = (3, 4),\ b = -10 \rightarrow \|\mathbf{w}\| = 5.$$

$f = 7$ → khoảng cách 1.4, chưa phải xác suất.

Ba điểm quanh vạch



`w = (3, 4), b = -10`

`lề = 2/5 = 0.4`

(3, 2): ngoài lề, hinge 0

(2, 1.1): trong lề, hinge 0.6

(2, 1): ngay trên vạch

Ví dụ tính tay: vạch $3x_1 + 4x_2 = 10$ và hai đường lề; điểm (2, 1.1) đúng phía nhưng nằm trong lề nên vẫn chịu hinge 0.6.

Hinge dùng nhãn có dấu

$$\ell = \max(0, 1 - y f(x)), \quad y \in \{-1, +1\}$$

$$y = 1,\ f = 0.4 \rightarrow \text{loss} = 0.6.$$

Soft margin tối thiểu hóa

$$\frac{1}{2}\|w\|^2 + C \sum_i \max(0, 1 - y_i f(x_i)).$$

C lớn phạt vi phạm nặng hơn, thường cho lề hẹp hơn; C nhỏ ưu tiên mô hình đơn giản hơn.

HỎI NHANH

Một mẫu có $y = -1$ và $f(\mathbf{x}) = -0.2$. Hinge loss bằng bao nhiêu?

A 1.2

B 0.8

C 0

D 0.2

HỎI NHANH

Cho C tiến dần về 0 trong bài toán lề mềm. Nghiệm có xu hướng thế nào?

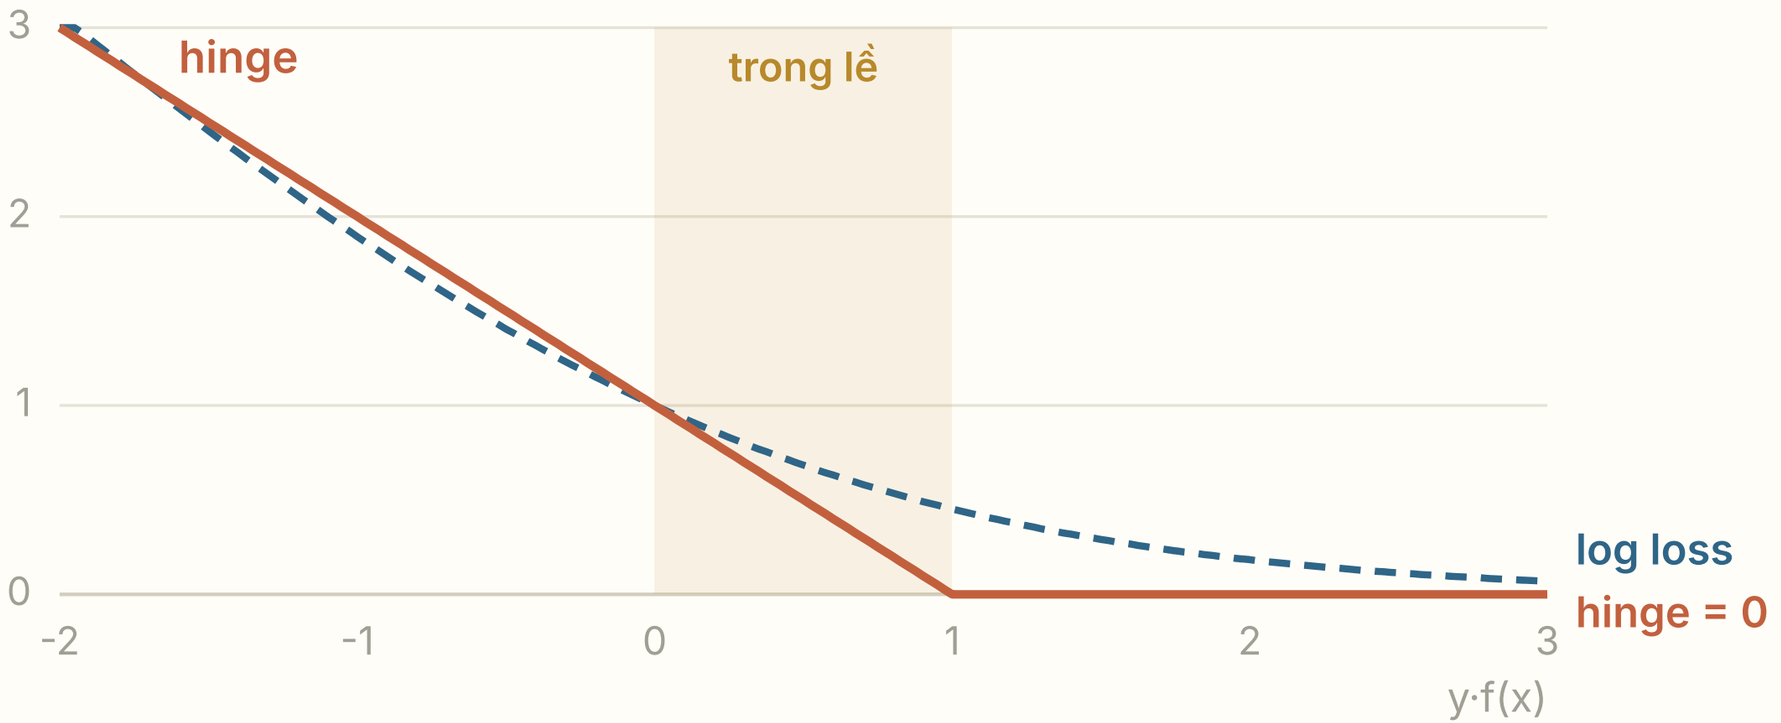
A Lề hẹp lại, cố phân loại đúng mọi điểm train

B $\mathbf{w}$ về gần 0, lề rất rộng, bỏ qua các vi phạm

C Không đổi, vì C chỉ ảnh hưởng tốc độ tối ưu

D Trở thành SVM lề cứng, không chấp nhận vi phạm

Đúng phía nhưng chưa an toàn



Hinge loss bằng đúng 0 khi y·f(x) ≥ 1; log loss (chia ln 2 để cùng mốc) thì luôn dương, nên mọi điểm đều có tiếng nói.

02

Kernel và tham số

Không phải dựng mọi đặc trưng

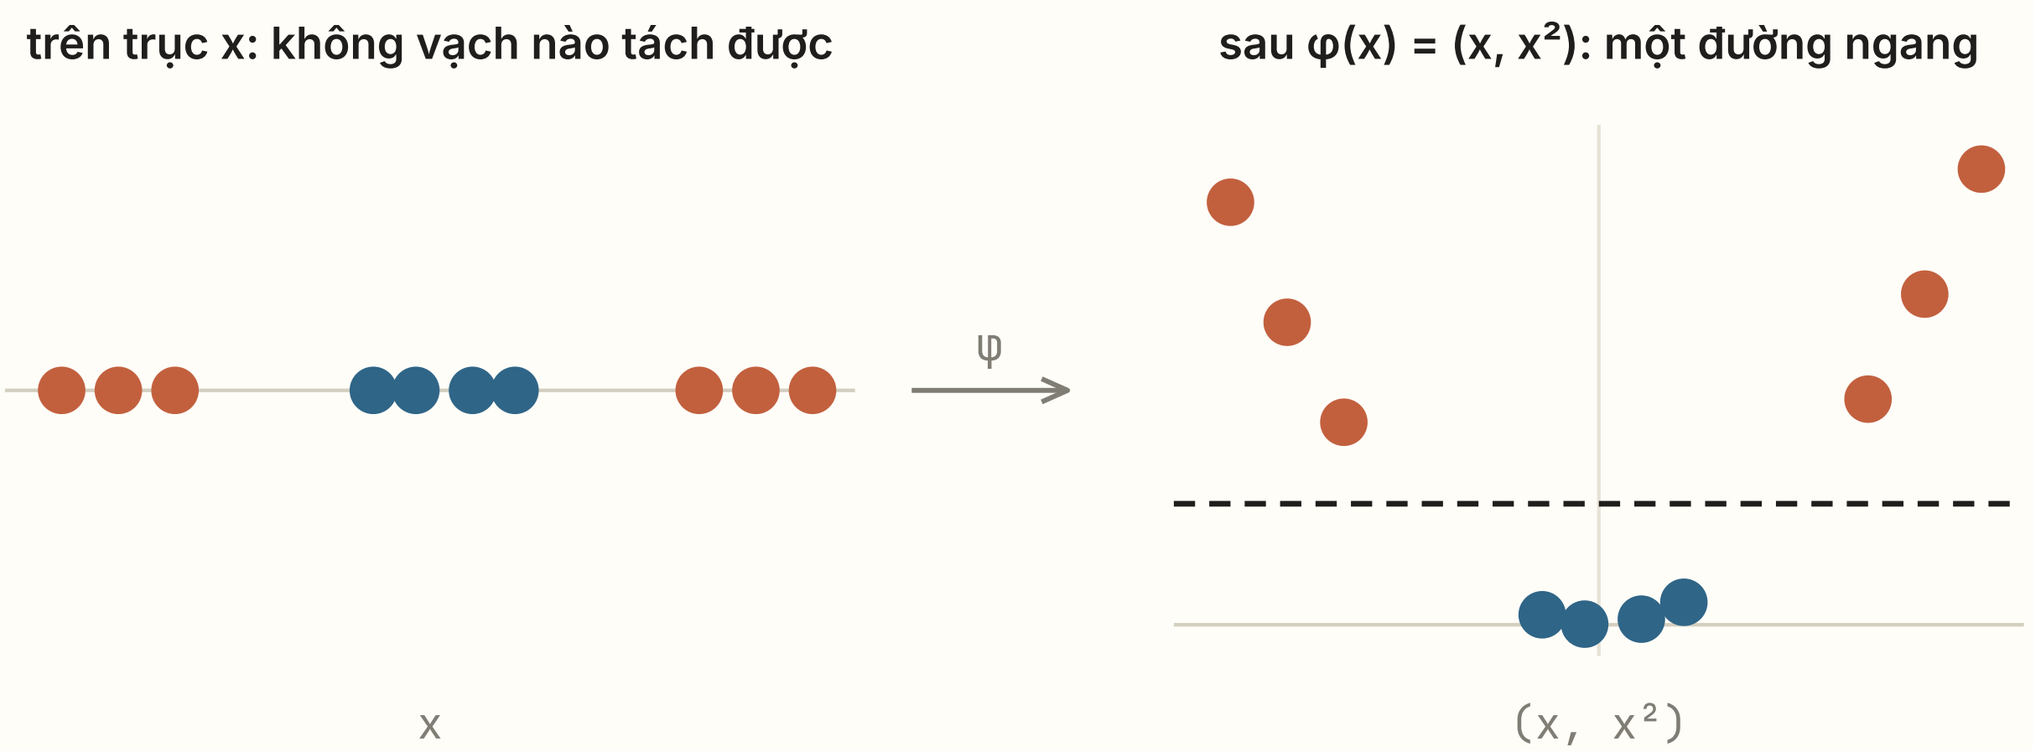
$k(x, z) = \phi(x)^\top \phi(z)$
Tính dot trong không gian mới qua kernel.

Polynomial: $(\mathbf{x}^\top \mathbf{z})^2$.

x=(1,2),z=(3,4) → dot=11, kernel=121.

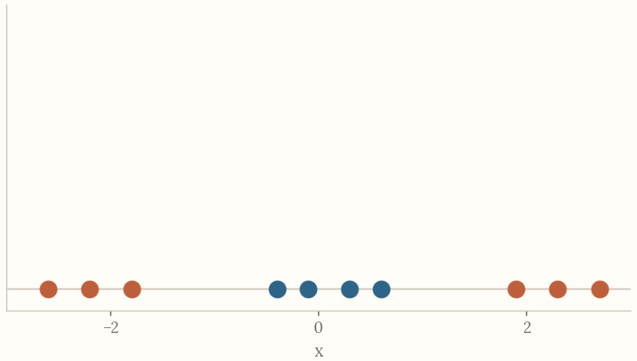
RBF dùng $k(x, z) = \exp(-\gamma \|x - z\|^2)$.
Hàm độ giống tùy tiện chưa chắc là kernel hợp lệ.

Thêm một chiều để tách

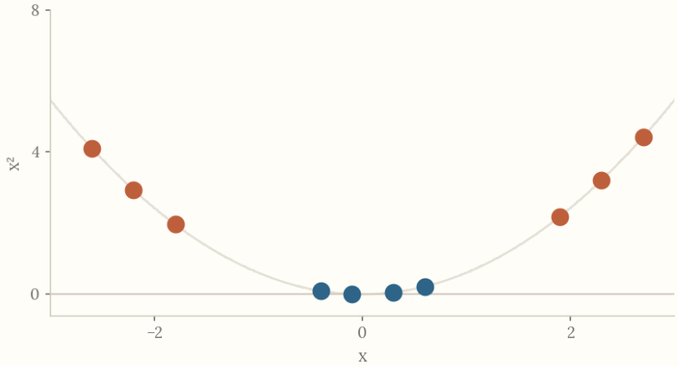


Hai lớp xen kẽ trên một trục không tách được bằng một ngưỡng; thêm tọa độ x^2 thì một đường thẳng tách được ngay.

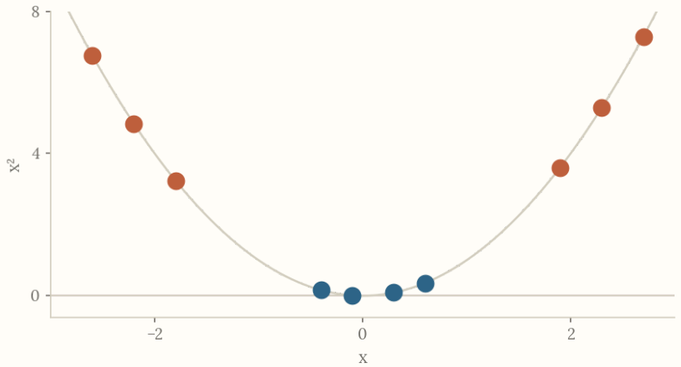
Nâng điểm lên một chiều mới



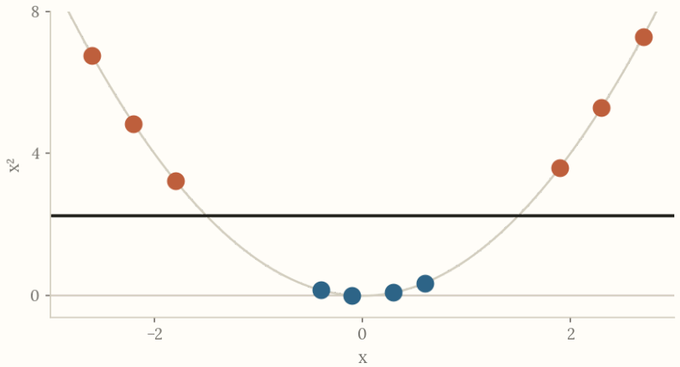
trên trục x: lớp cam nằm hai đầu, lớp xanh ở giữa



nâng mỗi điểm lên độ cao x^2



nâng mỗi điểm lên độ cao x^2



đường ngang $x^2 = 2.25$ tách hai lớp

Nâng mười điểm từ trục x lên (x, x^2): hai lớp không tách được bằng một ngưỡng trên trục lại tách được bằng một đường thẳng.

HỎI NHANH

Với $\mathbf{x} \in \mathbb{R}^{1000}$, kernel $(\mathbf{x}^\top \mathbf{z})^2$ ứng với một ϕ có khoảng bao nhiêu chiều? Tính thẳng kernel thì tốn khoảng bao nhiêu phép nhân?

A 2000 chiều, khoảng 2000 phép nhân

B 1 000 000 chiều, khoảng 1 000 000 phép nhân

C 500 500 chiều, khoảng 500 500 phép nhân

D 500 500 chiều, khoảng 1000 phép nhân

HỎI NHANH

$k(\mathbf{x}, \mathbf{z}) = \mathbf{x}^\top \mathbf{z} + 1$ có phải là một kernel hợp lệ không?

A Không, vì cộng hằng số làm mất tích vô hướng

B Có, nhưng chỉ khi $\mathbf{x}$ và $\mathbf{z}$ không âm

C Không, vì kernel phải nằm trong đoạn $[0, 1]$

D Có, với $\phi(\mathbf{x}) = (\mathbf{x}, 1)$

Hai núm C và gamma

C lớn: phạt vi phạm nặng hơn so với norm.

Gamma lớn: RBF ảnh hưởng vùng nhỏ hơn.

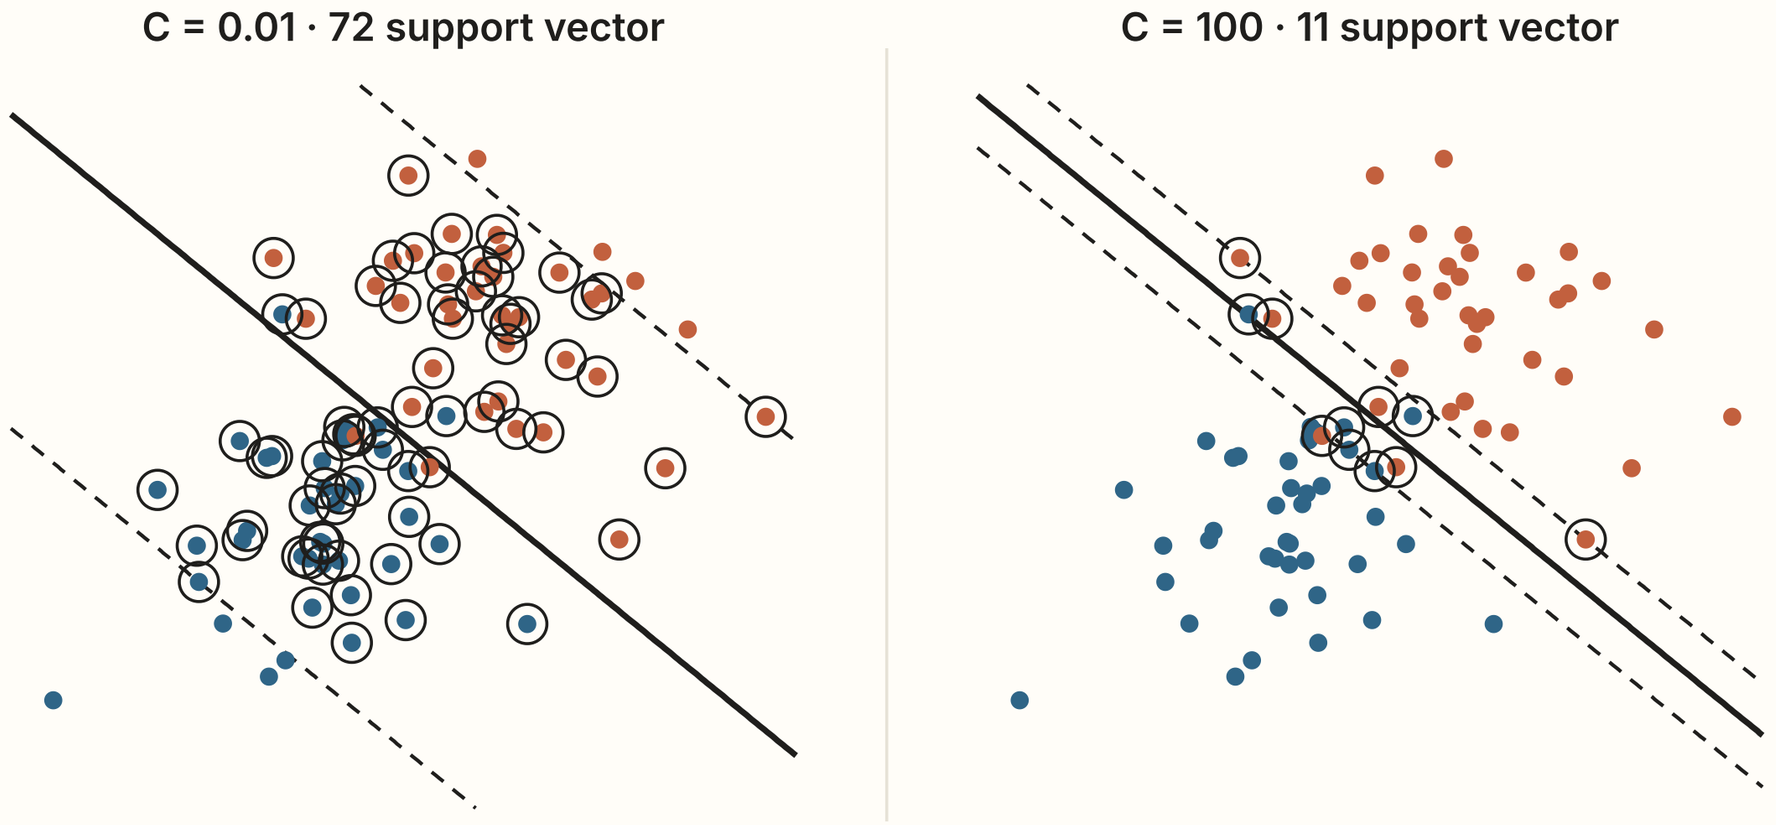
Dò trên thang log trong Pipeline.

Chuẩn hóa khi các đơn vị không so sánh được.

Đo thời gian trên subset trước khi fit lớn.

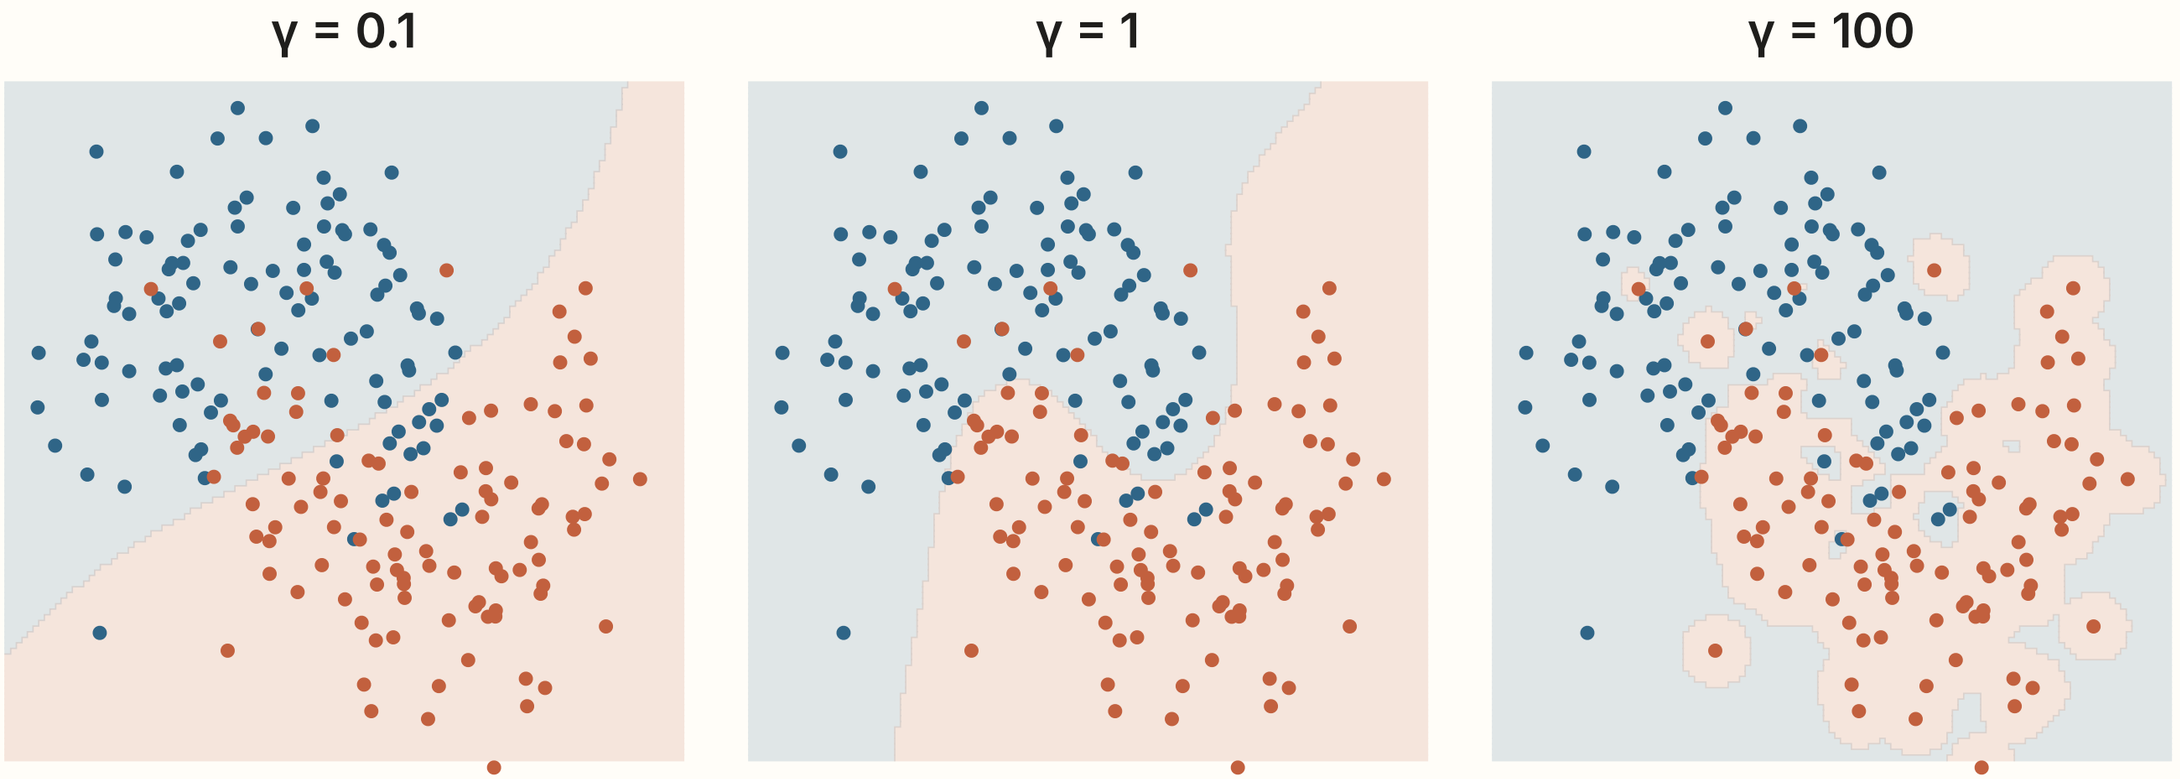
Với γ lớn, $\exp(-\gamma d^2)$ giảm nhanh theo d, nên vùng ảnh hưởng hẹp. Kernel SVM có chi phí tăng mạnh theo số mẫu; dữ liệu văn bản thưa thường hợp với `LinearSVC` hơn.

C nhỏ và C lớn



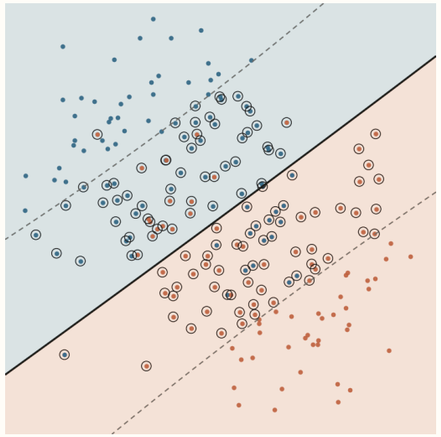
Cùng dữ liệu chồng nhau: C nhỏ chịu nhiều vi phạm, lề rộng, nhiều support vector; C lớn ép lề hẹp quanh vùng chồng lấn.

Ba mức gamma

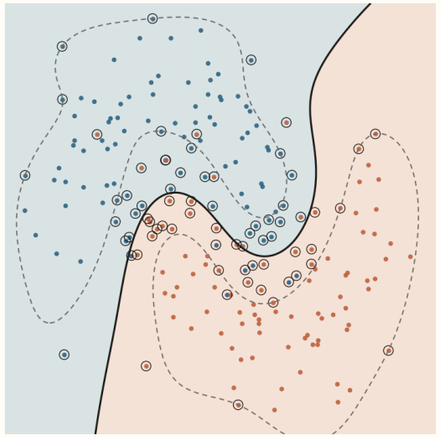


SVM RBF, C = 1: γ nhỏ cho ranh giới gần thẳng; γ = 1 theo dáng hai mặt trăng; γ = 100 khoanh từng điểm, dấu hiệu overfit.

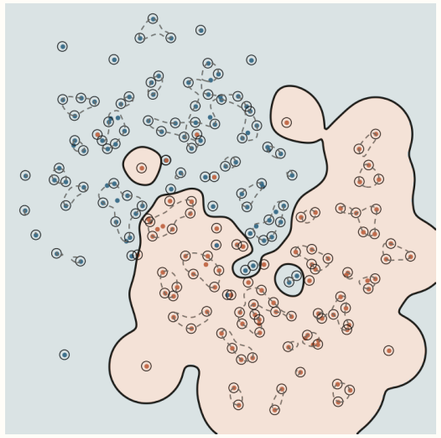
Tăng dần γ



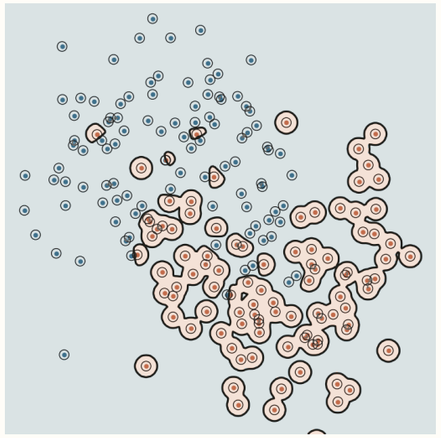
γ = 0.01: 123 support vector, accuracy 5-fold CV 0.830



γ = 1: 72 support vector, accuracy 5-fold CV 0.890



γ = 30: 177 support vector, accuracy 5-fold CV 0.845



γ = 300: 200 support vector, accuracy 5-fold CV 0.640

SVM kernel RBF, C = 1, trên dữ liệu trăng khuyết: tăng γ thì vùng ảnh hưởng của mỗi điểm hẹp lại, ranh giới uốn theo từng điểm (vòng tròn là support vector).

HỎI NHANH

SVM với kernel RBF, $\gamma = 100$, đúng 100% trên train nhưng cross-validation chỉ được 70%. Ta nên thử gì trước?

A Tăng γ lên 1000 cho ranh giới khít hơn

B Tăng C để phạt vi phạm nặng hơn nữa

C Giảm γ, và thử cả C nhỏ hơn

D Bỏ chuẩn hóa để giữ đơn vị gốc của dữ liệu

HỎI NHANH

Cần phân loại 2 triệu bình luận, mỗi bình luận là một vector TF-IDF 100 000 chiều, rất thưa. Nên thử mô hình nào trước?

A `LinearSVC` hoặc logistic regression tuyến tính

B `SVC(kernel="rbf")`, vì ranh giới cong thì mạnh hơn

C `SVC(kernel="poly", degree=5)` cho đủ phức tạp

D kNN với $k = 1$ trên toàn bộ vector TF-IDF

Đối chiếu trên máy

Ba điểm và siêu phẳng $\mathbf{w} = (3, 4)$, $b = -10$ của ví dụ tính tay.

```
scores = points_margin @ w_margin + b_margin
distances = (
    np.abs(scores) / np.linalg.norm(w_margin)
)
hinge = np.maximum(
    0., 1. - labels_signed * scores
)
print("hinge:", hinge.round(3).tolist())
```

KẾT QUẢ

```
hinge: [1.0, 0.0, 0.6]
```

Đối chiếu từng bước với phép tính tay.

Dùng SVC trên dữ liệu cong

KẾT QUẢ

```
{'svc__C': 1, 'svc__gamma': 10} 0.936
số vector hỗ trợ: 221 trên 500
```

Đây là `make_moons` với `StandardScaler`, RBF và CV 5-fold. 221 support vectors cho biết nhiều mẫu còn tham gia hàm quyết định; không biến con số này thành xác suất hay quy luật chung.

`decision_function` là score có dấu. `probability=True` cần calibration thêm, nên chậm và phải kiểm validation riêng.

HỎI NHANH

Mô hình tốt nhất dùng 221 trên 500 điểm làm vector hỗ trợ. Con số này nói lên điều gì?

A Mô hình học thuộc 221 điểm nên chắc chắn overfit

B 279 điểm còn lại bị bỏ đi vì gán nhãn sai

C Hai lớp chồng lên nhau, nhiều điểm nằm trong lề

D Lề cứng đã tách được hoàn toàn hai lớp

Bẫy cần nhớ

Bài hard-margin là tối ưu lồi nhưng chỉ dùng khi dữ liệu khả thi. Soft margin có thể coi điểm trong lề hoặc điểm sai là support vector. `decision_function` chưa phải xác suất.

Khi đi thi

- Dữ liệu vừa, đặc trưng tốt (nhất là embedding): SVM RBF là ứng viên mạnh.
- Văn bản: TF-IDF + `LinearSVC` là baseline khó vượt.
- Scale trong fold; dò `C`, `gamma` trên thang log; đo fit trên subset trước.
- Metric cần xác suất: logistic regression, hoặc hiệu chỉnh SVM trên validation.

03

Luyện đề

LUYỆN ĐỀ 1

Một bài phân loại có vài điểm bị gán nhãn nhầm, nằm sâu trong vùng của lớp kia. SVM lề cứng và SVM lề mềm xử lý thế nào?

A Lề cứng tự bỏ qua các điểm nhầm, lề mềm thì không

B Hai cách cho cùng một siêu phẳng

C Lề cứng vô nghiệm, còn lề mềm chịu phạt các điểm nhầm theo C

D Lề mềm không dùng được với kernel, nên phải dùng lề cứng

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 171

LUYỆN ĐỀ 2

Nhà máy có 10 000 bản ghi máy chạy bình thường, và gần như không có bản ghi máy hỏng. Vì sao one-class SVM hợp với việc phát hiện bất thường ở đây?

A Vì nó cần đủ cả mẫu bình thường lẫn mẫu hỏng để học

B Vì nó chỉ dùng được cho bài phân loại hai lớp

C Vì nó là thuật toán nhanh nhất trên dữ liệu lớn

D Vì nó chỉ cần học vùng của dữ liệu bình thường

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 170

LUYỆN ĐỀ 3

Kernel $k(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^\top \mathbf{z} + 1)^2$ với $\mathbf{x} \in \mathbb{R}^2$ ứng với một ánh xạ ϕ sang không gian bao nhiêu chiều?

A 3

B 4

C 6

D 9

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 161

Chốt ba điều

Signed score cho biết phía; $|f|/\|w\|$ cho khoảng cách; hinge dùng $y \in \{-1, +1\}$.

C cân bằng vi phạm với độ lớn w; γ điều khiển tầm ảnh hưởng của RBF; chuẩn hóa giữ khoảng cách có nghĩa.

Dùng Pipeline/CV với SVC và tách score, khoảng cách hình học, xác suất.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook từ đầu; đổi `C` hoặc `gamma`, dự đoán số support vector và score CV, rồi kiểm lại bằng output.