SVM

Đường phân chia có lề rộng nhất

Vạch nào an toàn hơn?

Nhiều vạch tách được hai đội.

Ta muốn còn khoảng trống ở hai bên.

Lề rộng giúp mô hình bớt nhạy với điểm hơi lệch.

Cần phân biệt score và khoảng cách.

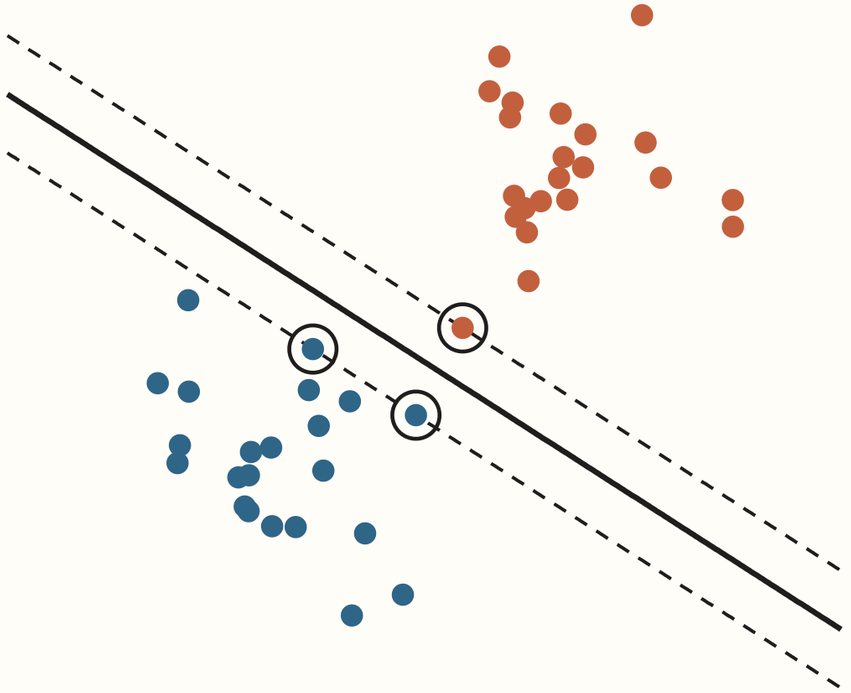
Mục tiêu

- Tính khoảng cách tới đường phân chia và hinge loss.
- Hiểu tham số C, gamma và vì sao cần chuẩn hóa.
- Dùng SVC với Pipeline và cross-validation.

01

Lề và hinge loss

Các điểm sát biên



f(x) = 0

f(x) = ±1 (nét đứt)

khoanh: support vector

`lề = 2/‖w‖ = 0.62`

Chỉ các điểm nằm trên lề (khoanh tròn) quyết định vị trí vạch.

Hai biên lề là $f(\mathbf{x}) = \pm 1$, cách nhau $2/\|\mathbf{w}\|$: lề rộng nhất là $\|\mathbf{w}\|$ nhỏ nhất.

HỎI NHANH

Sau khi chuẩn hóa, hai biên lề $f(\mathbf{x}) = \pm 1$ cách nhau đúng 1 đơn vị. $\|\mathbf{w}\|$ bằng bao nhiêu?

A 0.5

B 1

C 4

D 2

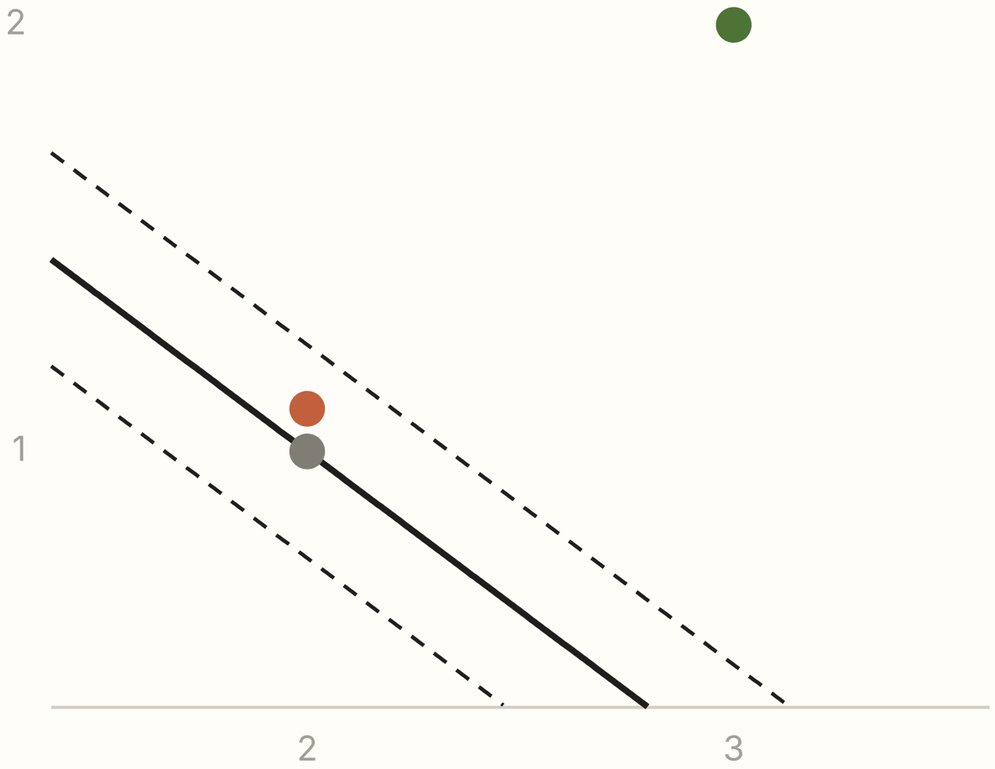
Score và khoảng cách

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b, \qquad d = \frac{|f(\mathbf{x})|}{\|\mathbf{w}\|}.$$

$$\mathbf{w} = (3, 4),\ b = -10 \rightarrow \|\mathbf{w}\| = 5.$$

$f = 7$ → khoảng cách 1.4, chưa phải xác suất.

Ba điểm quanh vạch



`w = (3, 4), b = -10`

`lề = 2/5 = 0.4`

(3, 2): ngoài lề, hinge 0

(2, 1.1): trong lề, hinge 0.6

(2, 1): ngay trên vạch

Điểm (2, 1.1) đúng phía nhưng nằm trong lề nên vẫn chịu hinge 0.6.

Hinge dùng nhãn có dấu

$$\ell = \max(0, 1 - y f(x)), \quad y \in \{-1, +1\}$$

$$y = 1,\ f = 0.4 \rightarrow \text{loss} = 0.6.$$

Soft margin tối thiểu hóa

$$\frac{1}{2}\|w\|^2 + C \sum_i \max(0, 1 - y_i f(x_i)).$$

C lớn phạt vi phạm nặng hơn, thường cho lề hẹp hơn; C nhỏ ưu tiên mô hình đơn giản hơn.

HỎI NHANH

Một mẫu có $y = -1$ và $f(\mathbf{x}) = -0.2$. Hinge loss bằng bao nhiêu?

A 1.2

B 0.8

C 0

D 0.2

HỎI NHANH

Cho C tiến dần về 0 trong bài toán lề mềm. Nghiệm có xu hướng thế nào?

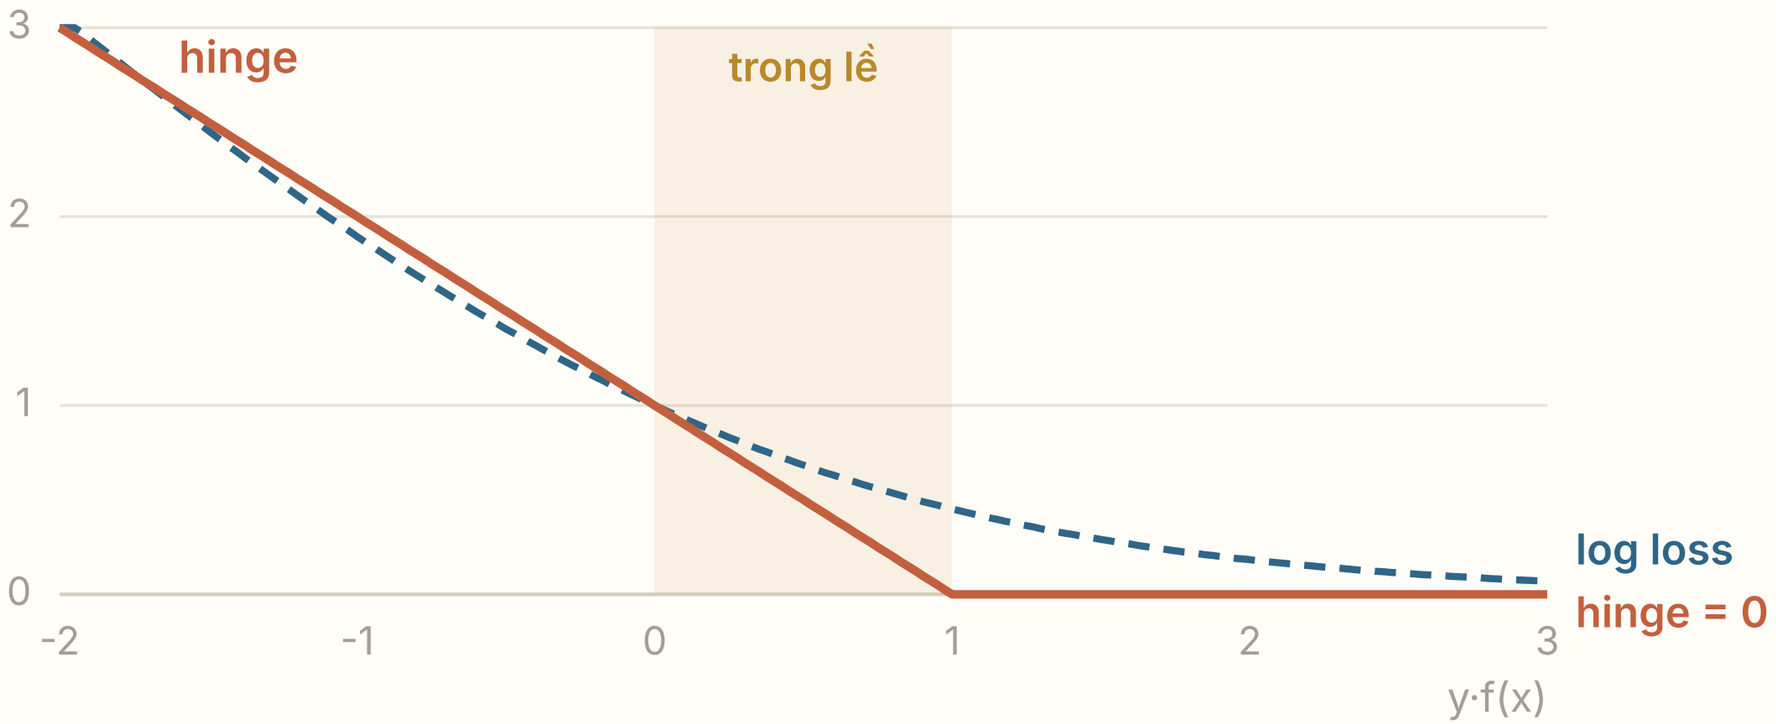
A Lề hẹp lại, cố phân loại đúng mọi điểm train

B $\mathbf{w}$ về gần 0, lề rất rộng, bỏ qua các vi phạm

C Không đổi, vì C chỉ ảnh hưởng tốc độ tối ưu

D Trở thành SVM lề cứng, không chấp nhận vi phạm

Đúng phía nhưng chưa an toàn



Hinge loss bằng 0 khi y·f(x) ≥ 1; log loss thì luôn dương.

02

Kernel và tham số

Không phải dựng mọi đặc trưng

$k(x, z) = \phi(x)^\top \phi(z)$

Tính dot trong không gian mới qua kernel.

Polynomial: $(\mathbf{x}^\top \mathbf{z})^2$.

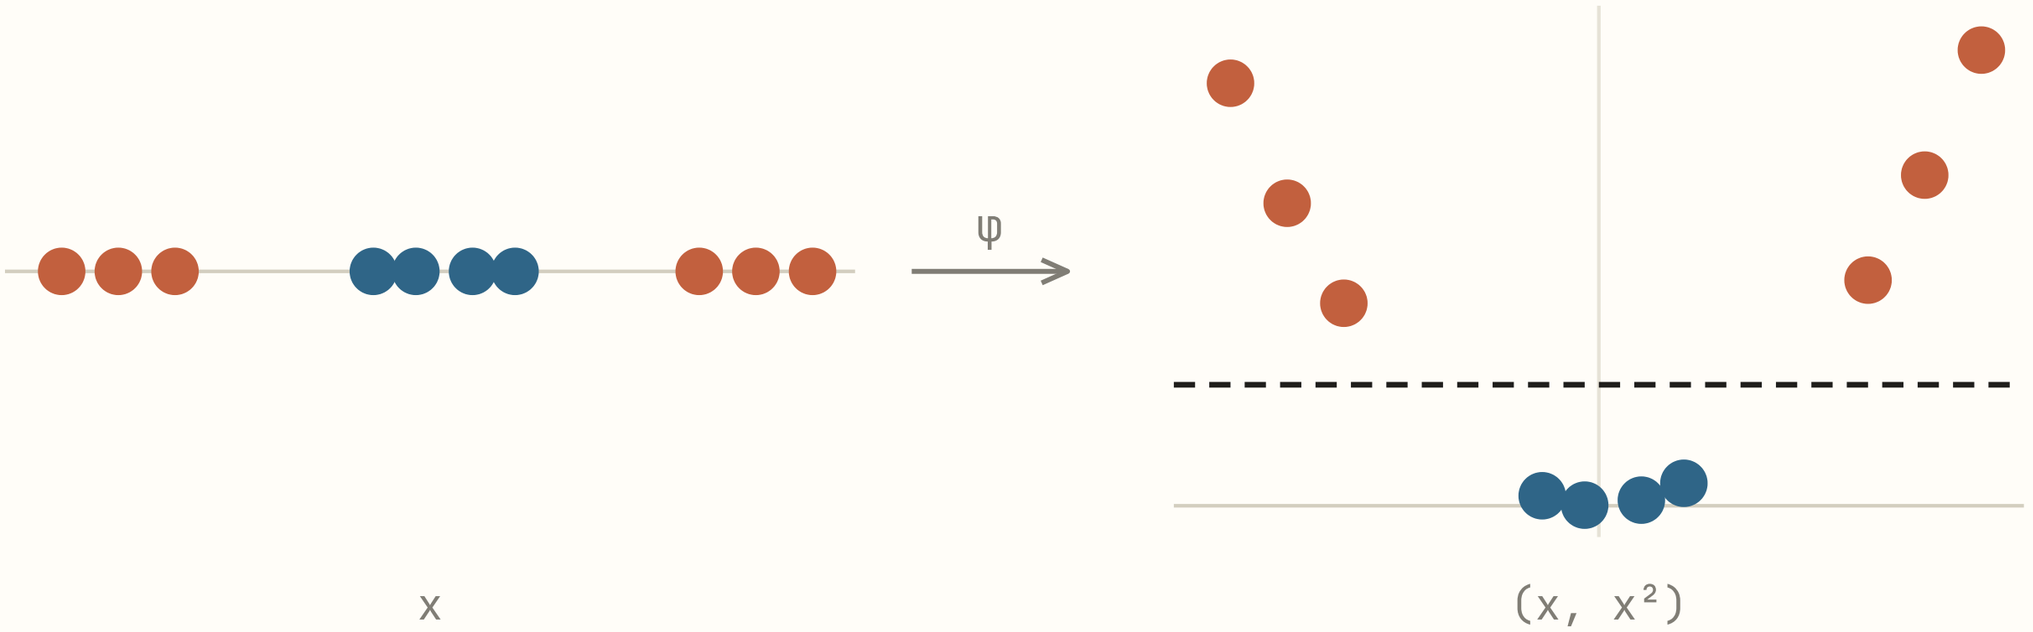
$\mathbf{x} = (1, 2)$, $\mathbf{z} = (3, 4)$: tích vô hướng 11, kernel 121.

RBF: $k(\mathbf{x}, \mathbf{z}) = \exp(-\gamma \|\mathbf{x} - \mathbf{z}\|^2)$.

Thêm một chiều để tách

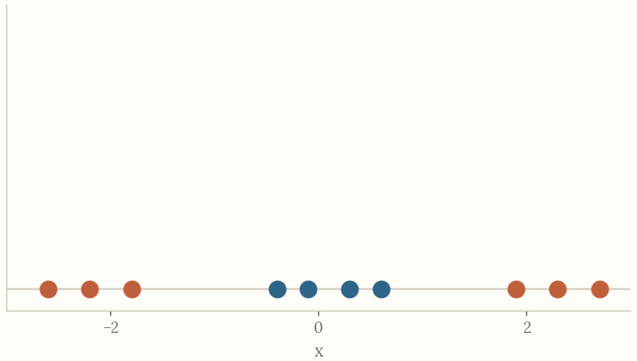
trên trục x: không vạch nào tách được

sau φ(x) = (x, x²): một đường ngang

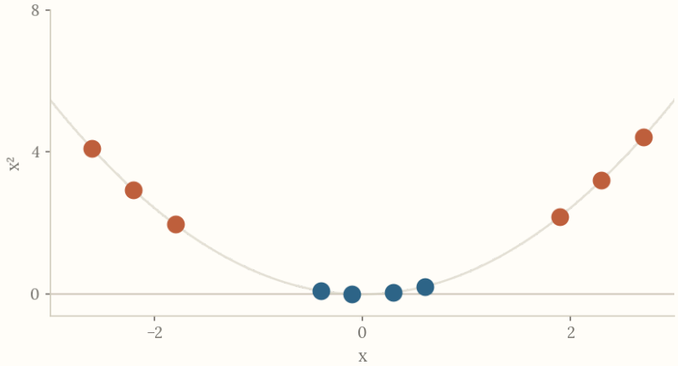


Thêm tọa độ x^2 thì một đường thẳng tách được hai lớp.

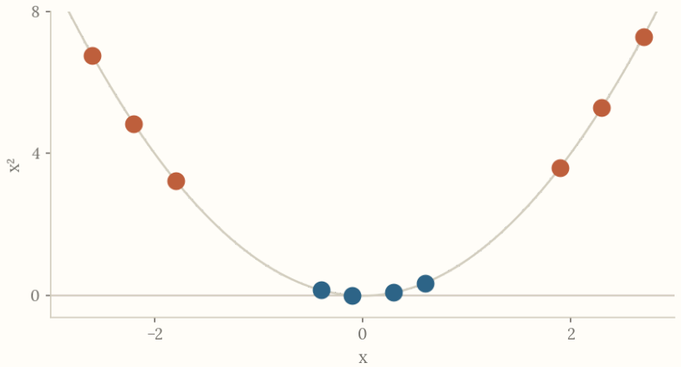
Nâng điểm lên một chiều mới



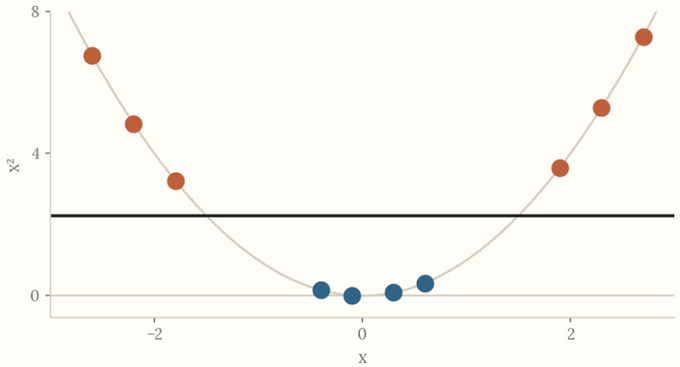
trên trục x: lớp cam nằm hai đầu, lớp xanh ở giữa



nâng mỗi điểm lên độ cao x^2



nâng mỗi điểm lên độ cao x^2



đường ngang $x^2 = 2.25$ tách hai lớp

Nâng mười điểm từ trục x lên (x, x^2): hai lớp không tách được bằng một ngưỡng trên trục lại tách được bằng một đường thẳng.

HỎI NHANH

Với $\mathbf{x} \in \mathbb{R}^{1000}$, kernel $(\mathbf{x}^\top \mathbf{z})^2$ ứng với một ϕ có khoảng bao nhiêu chiều? Tính thẳng kernel thì tốn khoảng bao nhiêu phép nhân?

A 2000 chiều, khoảng 2000 phép nhân

B 1 000 000 chiều, khoảng 1 000 000 phép nhân

C 500 500 chiều, khoảng 500 500 phép nhân

D 500 500 chiều, khoảng 1000 phép nhân

Hai núm C và gamma

C lớn: phạt vi phạm nặng hơn so với norm.

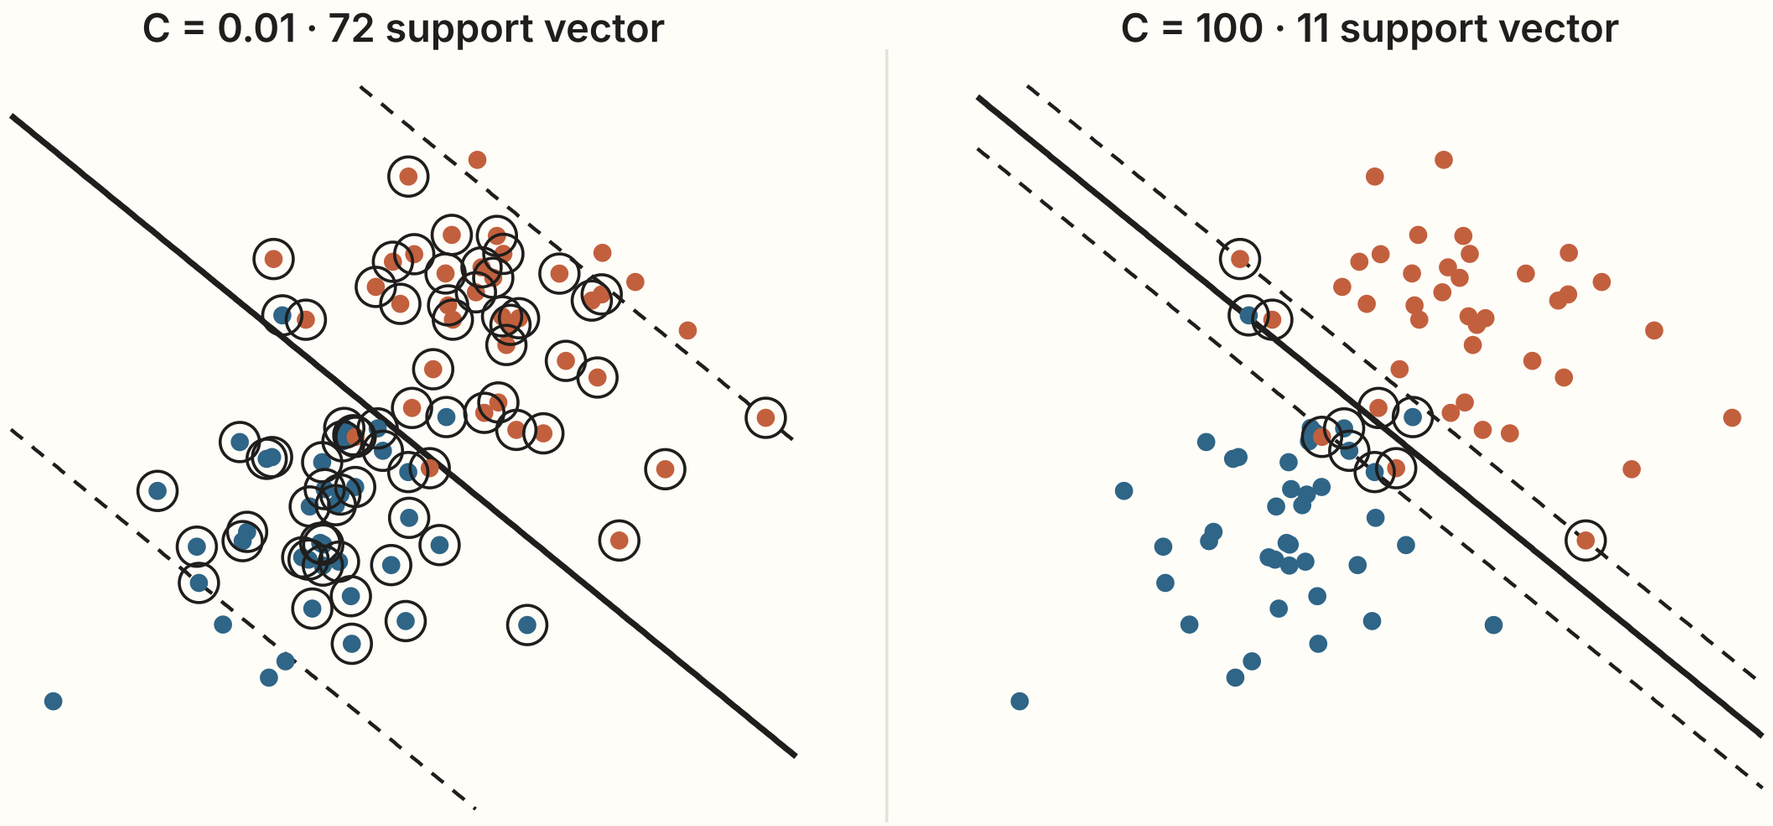
Gamma lớn: RBF ảnh hưởng vùng nhỏ hơn.

Dò cả hai trên thang log, trong Pipeline có scaler.

Kernel SVM chậm dần rất nhanh khi số mẫu tăng: đo trên một phần dữ liệu trước.

Văn bản thưa, nhiều mẫu: `LinearSVC`.

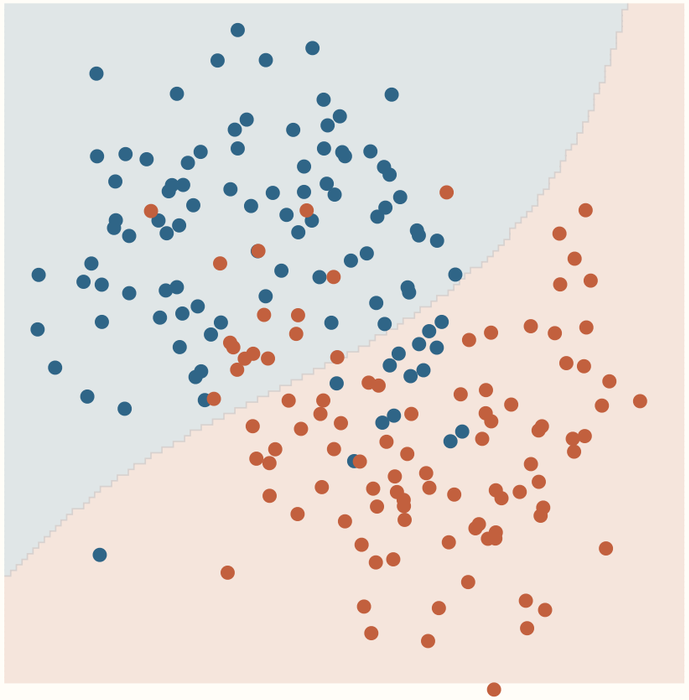
C nhỏ và C lớn



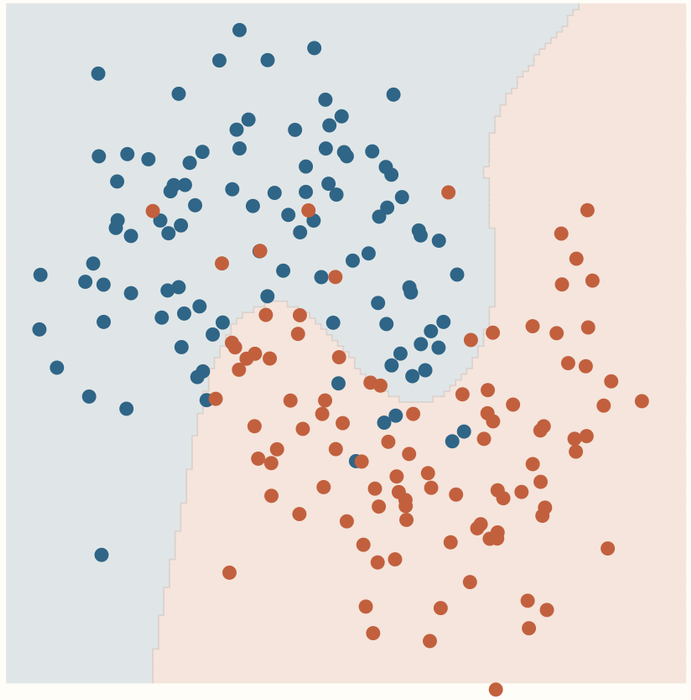
C nhỏ: lề rộng, chịu nhiều vi phạm. C lớn: lề hẹp.

Ba mức gamma

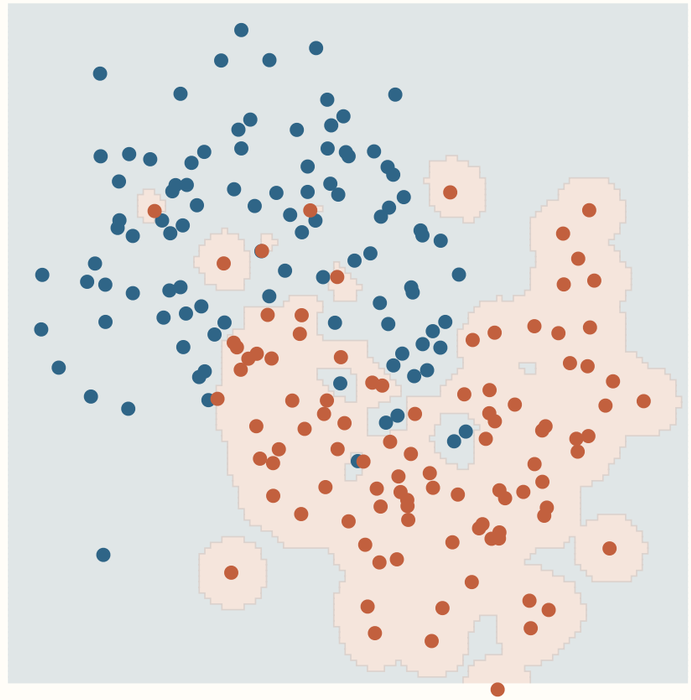
γ = 0.1



γ = 1

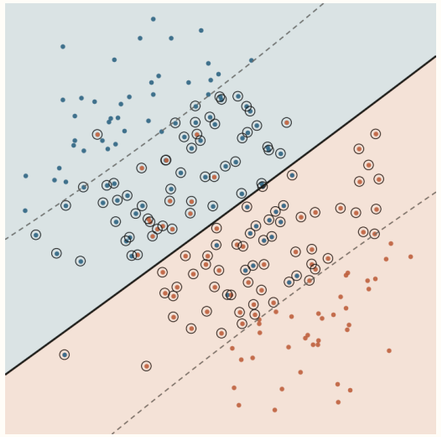


γ = 100

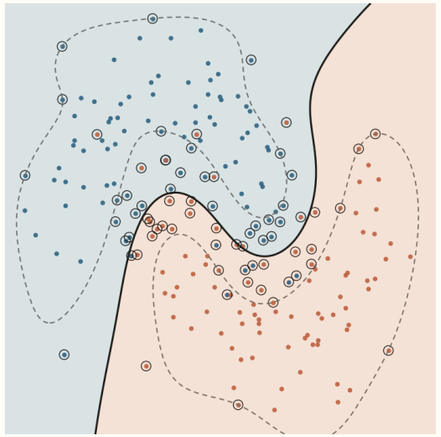


γ nhỏ: gần thẳng; γ = 1: theo dáng dữ liệu; γ = 100: khoanh từng điểm.

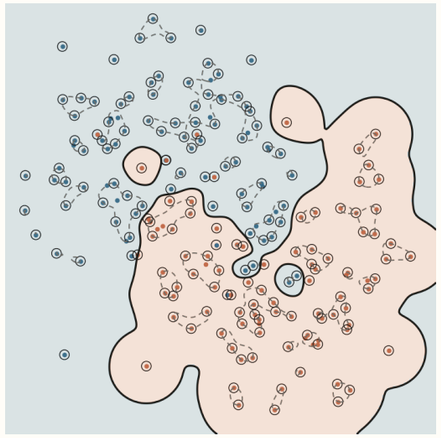
Tăng dần γ



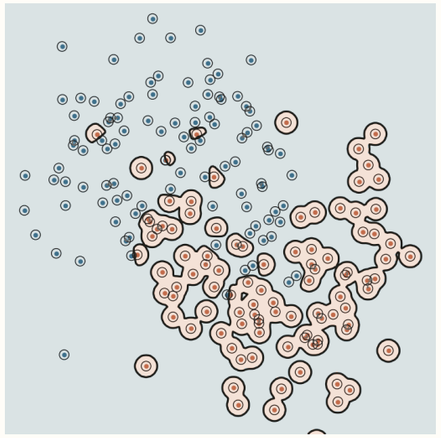
γ = 0.01: 123 support vector, accuracy 5-fold CV 0.830



γ = 1: 72 support vector, accuracy 5-fold CV 0.890



γ = 30: 177 support vector, accuracy 5-fold CV 0.845



γ = 300: 200 support vector, accuracy 5-fold CV 0.640

SVM kernel RBF, C = 1, trên dữ liệu trăng khuyết: tăng γ thì vùng ảnh hưởng của mỗi điểm hẹp lại, ranh giới uốn theo từng điểm (vòng tròn là support vector).

HỎI NHANH

SVM với kernel RBF, $\gamma = 100$, đúng 100% trên train nhưng cross-validation chỉ được 70%. Ta nên thử gì trước?

A Tăng γ lên 1000 cho ranh giới khít hơn

B Tăng C để phạt vi phạm nặng hơn nữa

C Giảm γ, và thử cả C nhỏ hơn

D Bỏ chuẩn hóa để giữ đơn vị gốc của dữ liệu

HỎI NHANH

Cần phân loại 2 triệu bình luận, mỗi bình luận là một vector TF-IDF 100 000 chiều, rất thưa. Nên thử mô hình nào trước?

A `LinearSVC` hoặc logistic regression tuyến tính

B `SVC(kernel="rbf")`, vì ranh giới cong thì mạnh hơn

C `SVC(kernel="poly", degree=5)` cho đủ phức tạp

D kNN với $k = 1$ trên toàn bộ vector TF-IDF

Đối chiếu trên máy

Ba điểm và siêu phẳng $\mathbf{w} = (3, 4)$, $b = -10$ của mục lề mềm.

```
scores = points_margin @ w_margin + b_margin
distances = (
    np.abs(scores) / np.linalg.norm(w_margin)
)
hinge = np.maximum(
    0., 1. - labels_signed * scores
)
print("hinge:", hinge.round(3).tolist())
```

KẾT QUẢ

```
hinge: [1.0, 0.0, 0.6]
```

Điểm nằm trên vạch chịu hinge 1; điểm đúng phía nhưng trong lề chịu 0.6.

Dùng SVC trên dữ liệu cong

KẾT QUẢ

```
{'svc__C': 1, 'svc__gamma': 10} 0.936
số vector hỗ trợ: 221 trên 500
```

`make_moons`, `StandardScaler`, RBF, CV 5-fold.

`decision_function` là score có dấu, chưa phải xác suất.

`probability=True` hiệu chỉnh thêm, chậm hơn, cần kiểm riêng.

HỎI NHANH

Mô hình tốt nhất dùng 221 trên 500 điểm làm vector hỗ trợ. Con số này nói lên điều gì?

A Mô hình học thuộc 221 điểm nên chắc chắn overfit

B 279 điểm còn lại bị bỏ đi vì gán nhãn sai

C Hai lớp chồng lên nhau, nhiều điểm nằm trong lề

D Lề cứng đã tách được hoàn toàn hai lớp

Khi đi thi

- Scaler trong fold; `C`, `gamma` trên thang log.
- Văn bản: TF-IDF + `LinearSVC`.
- Cần xác suất: logistic regression hoặc hiệu chỉnh SVM.

03

Luyện đề

LUYỆN ĐỀ 1

Một bài phân loại có vài điểm bị gán nhãn nhầm, nằm sâu trong vùng của lớp kia. SVM lề cứng và SVM lề mềm xử lý thế nào?

A Lề cứng tự bỏ qua các điểm nhầm, lề mềm thì không

B Hai cách cho cùng một siêu phẳng

C Lề cứng vô nghiệm, còn lề mềm chịu phạt các điểm nhầm theo C

D Lề mềm không dùng được với kernel, nên phải dùng lề cứng

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 171

LUYỆN ĐỀ 2

Nhà máy có 10 000 bản ghi máy chạy bình thường, và gần như không có bản ghi máy hỏng. Vì sao one-class SVM hợp với việc phát hiện bất thường ở đây?

A Vì nó cần đủ cả mẫu bình thường lẫn mẫu hỏng để học

B Vì nó chỉ dùng được cho bài phân loại hai lớp

C Vì nó là thuật toán nhanh nhất trên dữ liệu lớn

D Vì nó chỉ cần học vùng của dữ liệu bình thường

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 170

LUYỆN ĐỀ 3

Kernel $k(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^\top \mathbf{z} + 1)^2$ với $\mathbf{x} \in \mathbb{R}^2$ ứng với một ánh xạ ϕ sang không gian bao nhiêu chiều?

A 3

B 4

C 6

D 9

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 161

Chốt ý

SVM chọn vạch có lề rộng nhất; hinge loss chỉ phạt điểm sai phía hoặc nằm trong lề.

Kernel cho ranh giới cong; C và γ dò trên thang log, sau khi chuẩn hóa.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook: đổi `C` hoặc `gamma`, đoán trước số vector hỗ trợ rồi kiểm lại.