Dimensionality reduction

Center dữ liệu, tính một thành phần PCA bằng SVD và tái tạo.

Nén một đám mây

Hai loại điểm bài tập tăng giảm cùng nhau.

Các điểm nằm gần đường chéo.

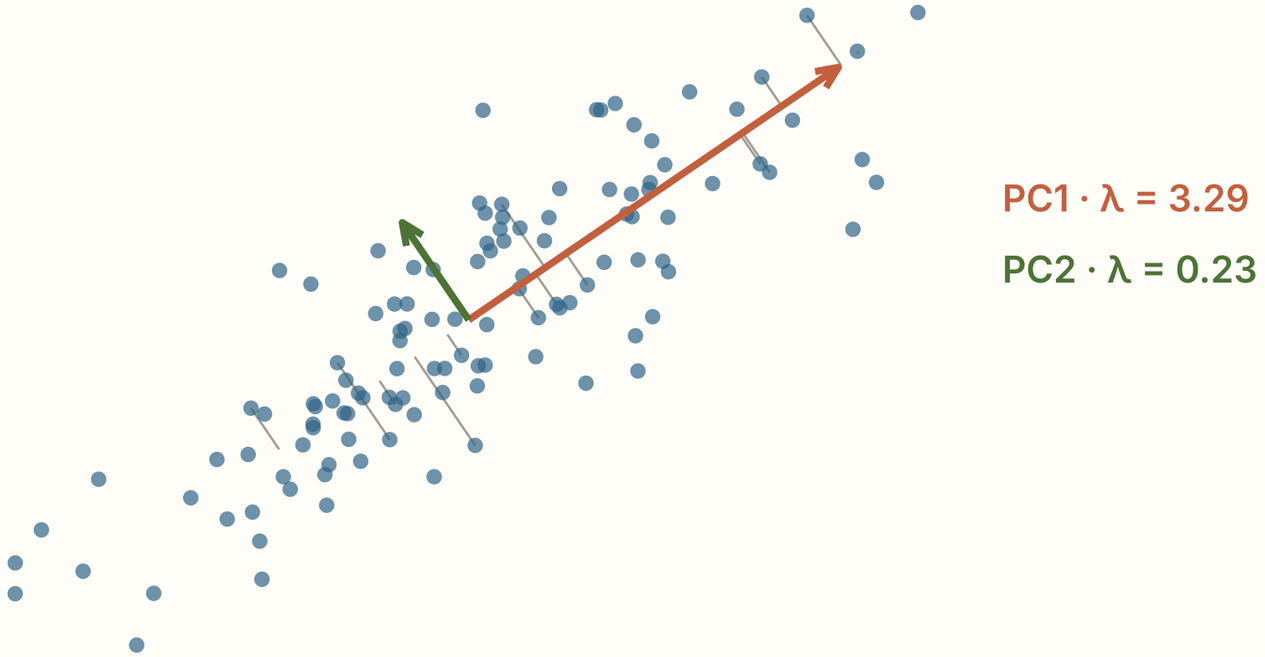
Lưu vị trí trên đường thay cho hai tọa độ.

Phần ít biến thiên bị bỏ có chứa nhãn không?

01

PCA và tái tạo

Chọn hướng trải rộng



Đám mây đã trừ trung bình: PC1 theo hướng trải dài nhất, PC2 vuông góc; nét mảnh là phép chiếu xuống PC1.

PCA trừ trung bình từng cột trước. PC1 là hướng có phương sai chiếu lớn nhất; PC2 vuông góc với PC1 và giải quyết phần còn lại.

HỎI NHANH

Dữ liệu hai chiều đã trừ trung bình có ma trận hiệp phương sai Σ với hai trị riêng 4 và 1. Chiếu lên PC1 thì giữ được bao nhiêu phần phương sai, và tọa độ trên PC1 có độ lệch chuẩn bao nhiêu?

A 80%, độ lệch chuẩn 4

B 80%, độ lệch chuẩn 2

C 50%, độ lệch chuẩn 2

D 75%, độ lệch chuẩn 4

Shape của phép chiếu

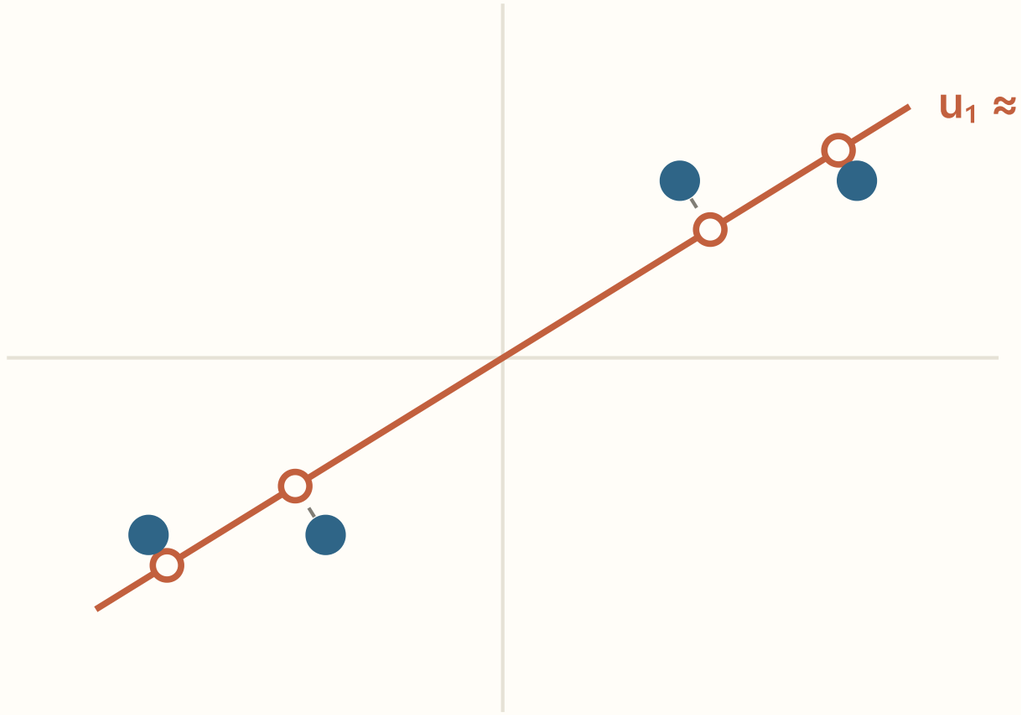
`X`: `(n, d)`; mean: `(d,)`; `X_centered`: `(n, d)`.

Giữ k hàng đầu của `Vt` trong SVD.

`components`: `(d, k)`.

`coordinates = X_centered @ components`: `(n, k)`.

Bốn điểm, một trục



$\lambda_1 \approx 3.427 \cdot \lambda_2 \approx 0.073$

PC1 giữ 97.9%

vòng rỗng: điểm tái tạo

Ví dụ tính tay: bốn điểm gần một đường thẳng; chiếu xuống PC1 rồi tái tạo, mỗi điểm chỉ lệch một đoạn ngắn.

Giữ phương sai bao nhiêu?

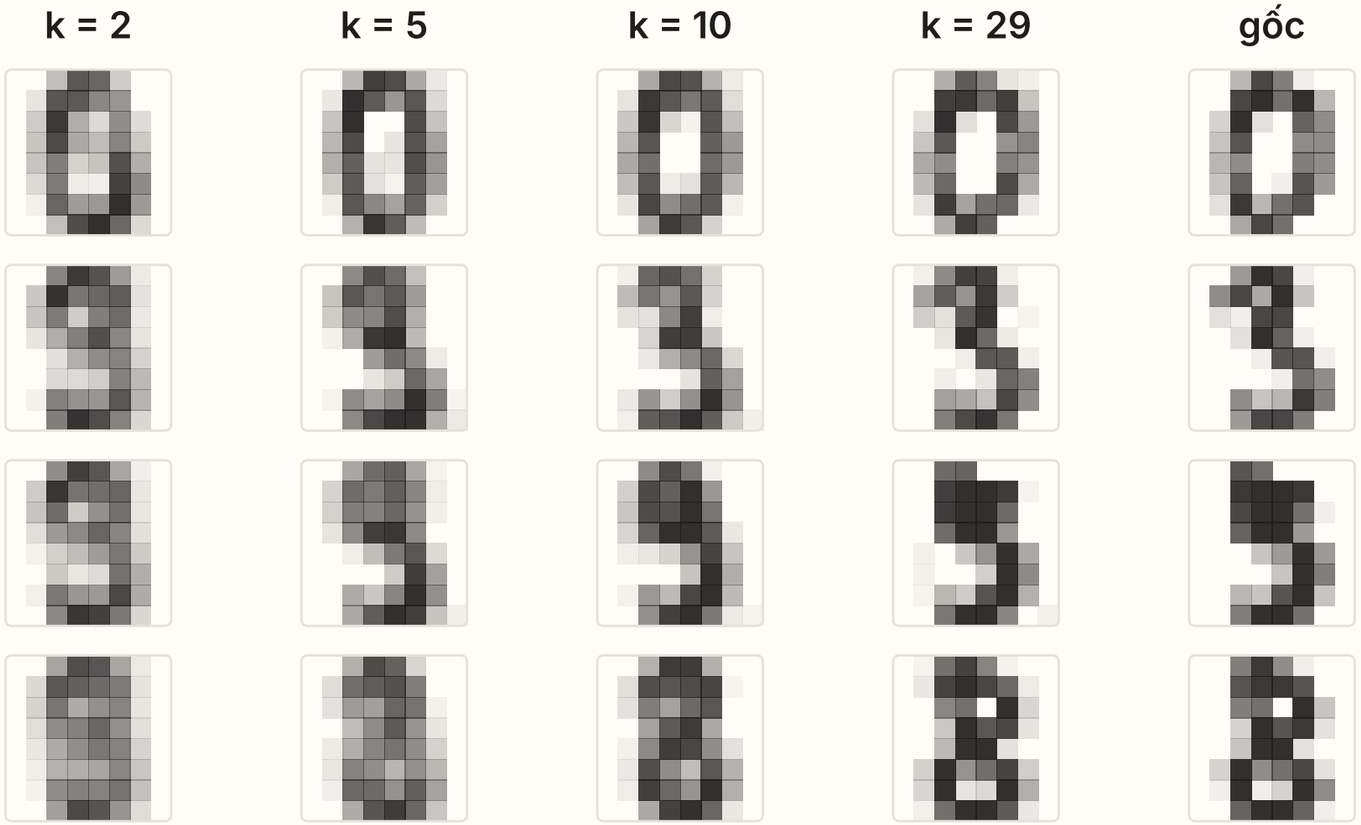
$$r_k = \frac{\lambda_1 + \cdots + \lambda_k}{\lambda_1 + \cdots + \lambda_d}$$

Trị riêng $\lambda_i = s_i^2/n$ khi tính bằng SVD.

Đây là phương sai, không phải phần trăm accuracy hay mọi loại thông tin.

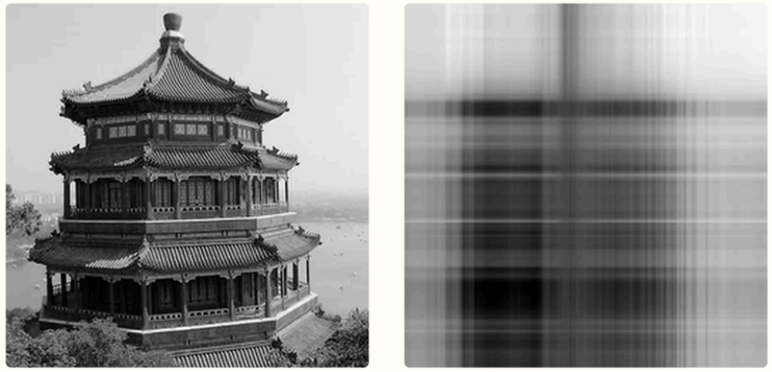
Nếu mục tiêu là phân loại, vẫn phải kiểm accuracy hoặc metric của nhiệm vụ sau đó.

Ảnh tái tạo từ k thành phần



Ảnh chữ số 8 × 8 tái tạo từ k thành phần chính: 2 thành phần chỉ còn vệt mờ, 10 đã đọc được, 29 gần như ảnh gốc.

PCA trên các hàng của một ảnh



giữ 1 thành phần: 769 số thay cho 65 536; phương sai giữ lại 54.8%



giữ 8 thành phần: 4 360 số thay cho 65 536; phương sai giữ lại 84.7%



giữ 20 thành phần: 10 516 số thay cho 65 536; phương sai giữ lại 92.3%



giữ 80 thành phần: 41 296 số thay cho 65 536; phương sai giữ lại 98.9%

PCA trên 256 hàng của ảnh tháp (tính bằng SVD): ảnh gốc và ảnh dựng lại từ k thành phần đầu.

HỎI NHANH

SVD của dữ liệu đã trừ trung bình cho các giá trị kỳ dị $s = (6, 3, 1)$. Giữ hai thành phần đầu thì giữ được bao nhiêu phần phương sai?

A khoảng 0.90

B khoảng 0.60

C khoảng 0.75

D khoảng 0.978

HỎI NHANH

Có hai cột: thu nhập tính bằng đồng, độ lệch chuẩn cỡ 10^7, và tuổi, độ lệch chuẩn cỡ 10. Chạy PCA mà không chuẩn hóa. PC1 gần như là hướng nào?

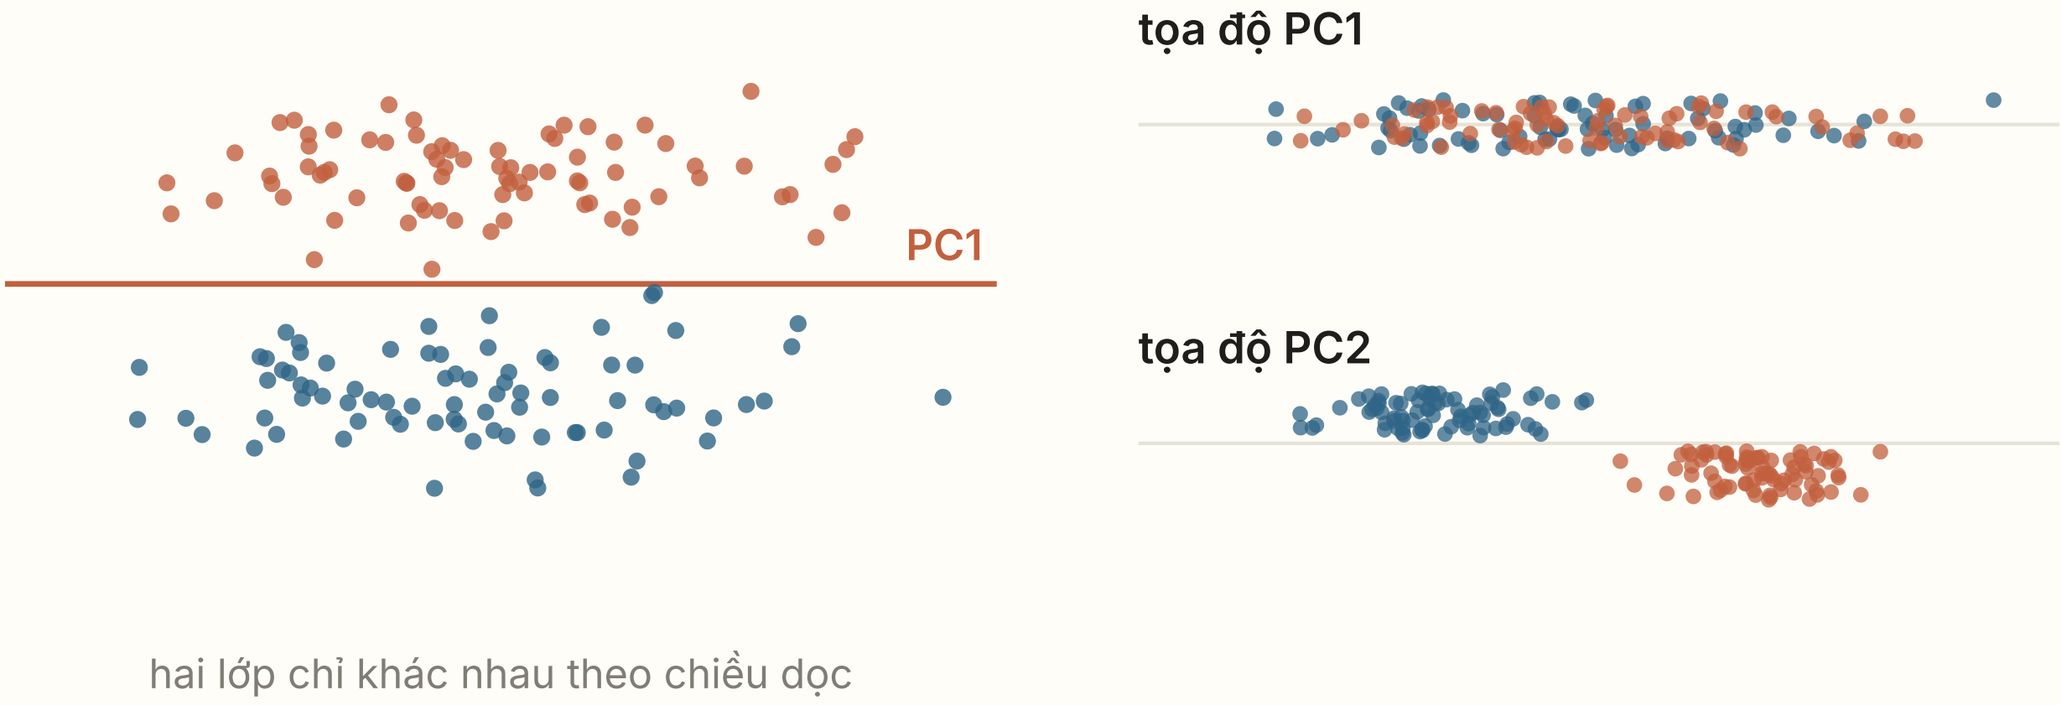
A Trung bình cộng của hai cột

B Gần như trùng với trục thu nhập

C Gần như trùng với trục tuổi

D Đường chéo $45°$ giữa hai cột

Phương sai nhỏ vẫn có thể cần



hai lớp chỉ khác nhau theo chiều dọc

PCA không biết nhãn: PC1 chọn hướng nhiễu trải rộng nên hai lớp trộn lẫn; hướng phương sai nhỏ PC2 mới tách được chúng.

HỎI NHANH

Hai lớp chỉ khác nhau ở một cột có biến thiên rất nhỏ. Cột còn lại là nhiễu, biên độ lớn. PCA không dùng nhãn sẽ ưu tiên giữ hướng nào?

A Hướng có phương sai lớn, dù với bài này đó là nhiễu

B Hướng chứa thông tin về nhãn, vì nó tách hai lớp rõ nhất

C Cả hai hướng, vì PCA giữ mọi thông tin

D Một hướng ngẫu nhiên, tùy seed của thuật toán

02

Kiểm phép biến đổi

Dấu trục không phải lỗi

$\mathbf{u}$ và $-\mathbf{u}$ là cùng một đường.

Tọa độ đổi dấu; tái tạo giữ nguyên.

So không gian chiếu hoặc tái tạo, không ép mọi hệ số trùng đúng dấu.

Vector chỉ phương của PCA có chuẩn 1. Với vector khác 0, chuẩn hóa bằng $\mathbf{v}/\|\mathbf{v}\|$.

HỎI NHANH

Trên hình t-SNE, cụm A nằm rất xa cụm B, còn A thì sát C. Ta được phép kết luận gì?

A Chỉ quan hệ láng giềng bên trong cụm là đáng tin

B Trong không gian gốc, A gần C hơn hẳn so với B

C Cụm A to gấp đôi cụm C nên có gấp đôi số điểm

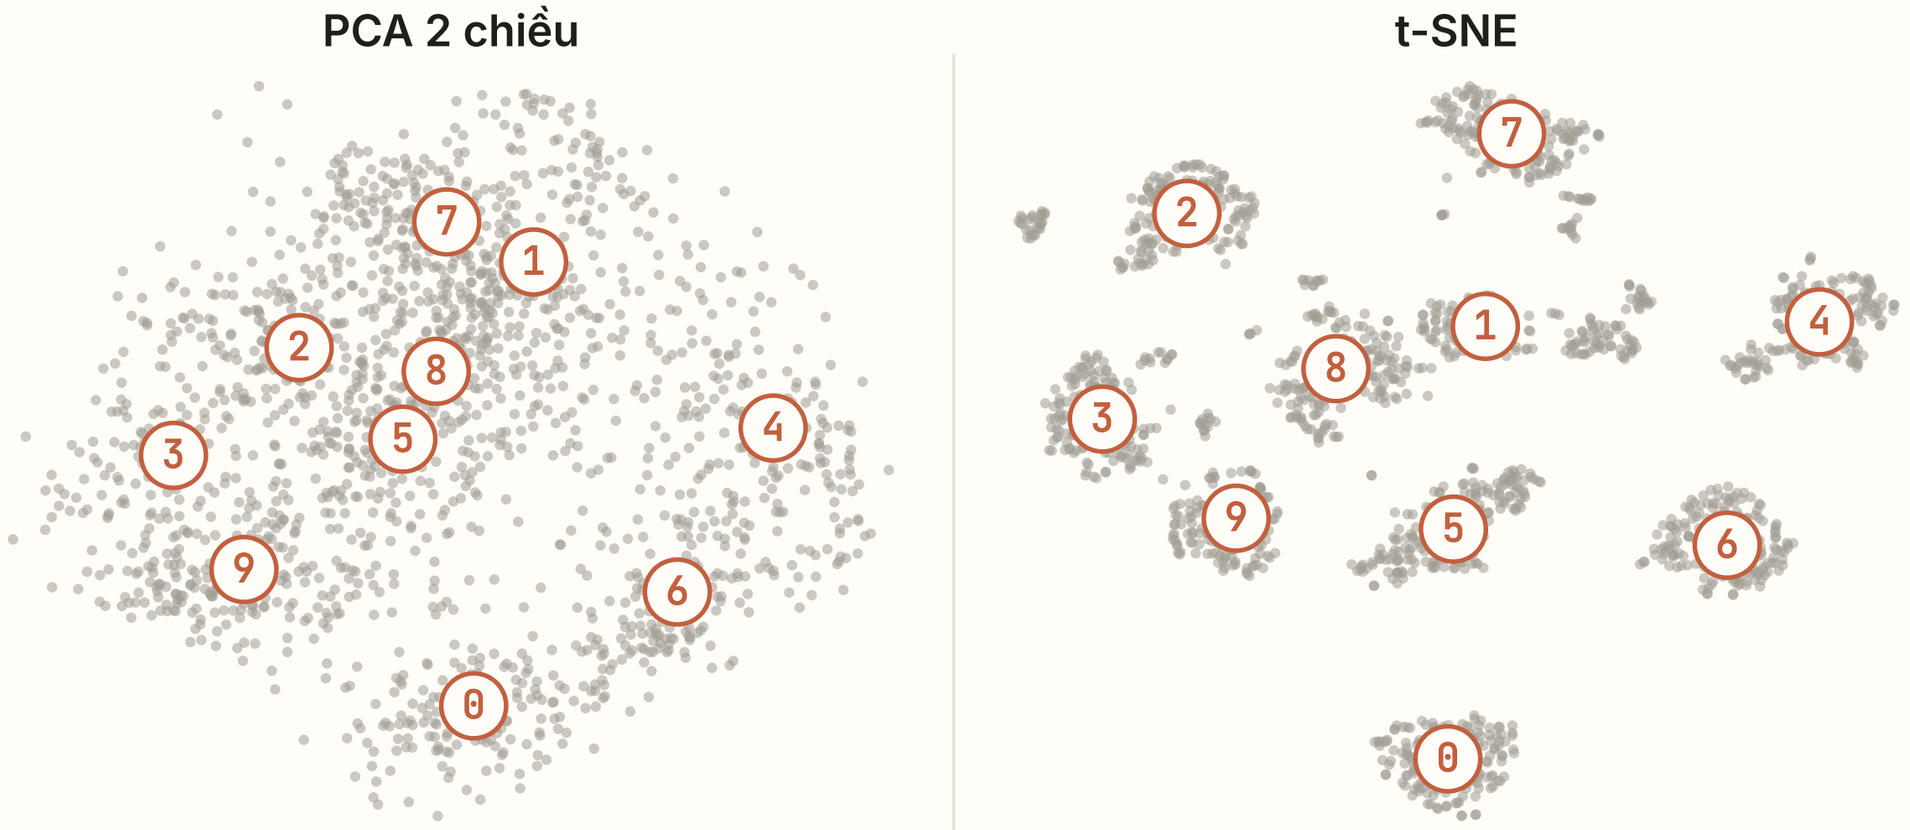
D Phải có đúng ba lớp, vì hình có ba cụm

PCA, TruncatedSVD, t-SNE

	Center	Áp mẫu mới	Mục đích chính
PCA	Có	Có	Nén tuyến tính, tiền xử lý
TruncatedSVD	Không	Có	TF-IDF thưa
t-SNE	Có cách xử lý riêng	Không trong sklearn	Trực quan hóa

Khoảng cách giữa các cụm t-SNE không phải thước đo của dữ liệu gốc; kiểm vài seed và vài cấu hình trước khi kết luận.

PCA và t-SNE trên digits



Digits xuống 2 chiều: PCA để các chữ số chồng lên nhau, t-SNE tách thành cụm; khoảng cách giữa các cụm t-SNE không mang nghĩa.

Đối chiếu trên máy

Bốn điểm của ví dụ tính tay.

```
X_centered = X_pca - X_pca.mean(axis=0)
U, s, Vt = np.linalg.svd(
    X_centered, full_matrices=False
)
components = Vt[:1].T
coordinates = X_centered @ components
print(components.shape, coordinates.shape)
print(round(float(s[0] ** 2 / sum(s ** 2)), 4))
reconstructed = coordinates @ components.T
error = np.mean((reconstructed - X_centered) ** 2)
print(round(float(error), 6))
```

KẾT QUẢ

```
(2, 1) (4, 1)
0.9792
0.036475
```

Đối chiếu từng bước với phép tính tay. Dấu của component có thể đảo mà vẫn là cùng một trục; đối chiếu tái tạo thay vì ép dấu.

Chuẩn hóa ảnh: cần nhiều chiều hơn

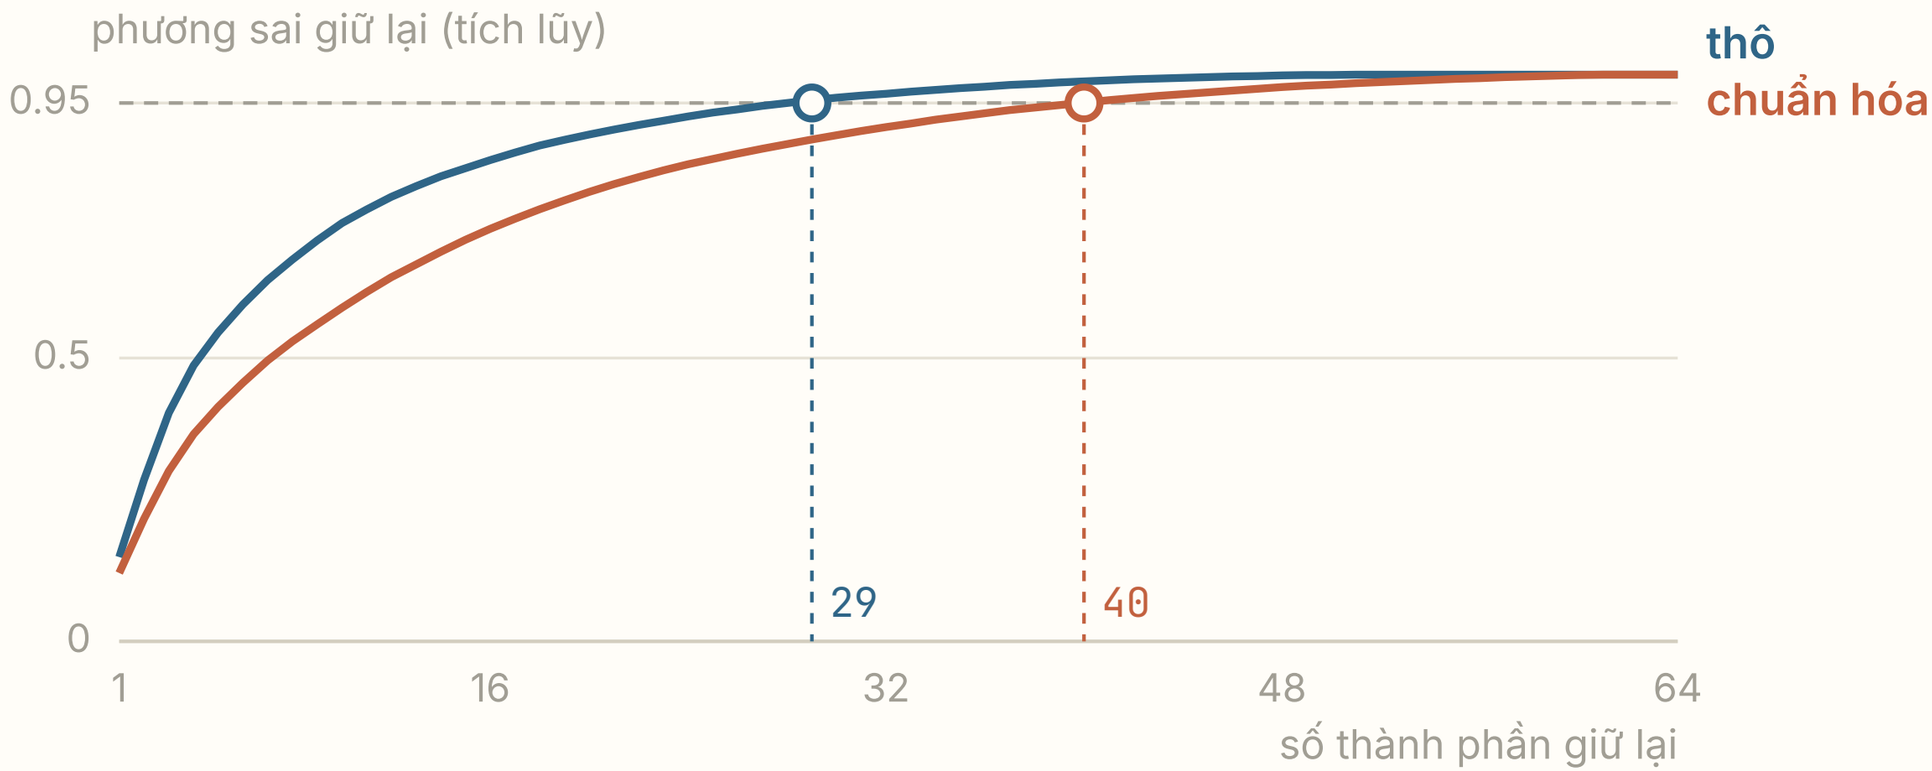
KẾT QUẢ

```
thô: cần 29 trên 64 thành phần để giữ 95% phương sai
chuẩn hóa: cần 40 trên 64 thành phần để giữ 95% phương sai
```

Pixel viền gần như hằng bị phóng lên phương sai 1.

Ảnh đã cùng đơn vị: chuẩn hóa không bắt buộc, kiểm bằng validation.

Phương sai tích lũy



Digits: giữ 95% phương sai cần 29 thành phần trên dữ liệu thô nhưng 40 sau khi chuẩn hóa từng pixel.

HỎI NHANH

Với bộ digits, dữ liệu thô cần 29 thành phần để giữ 95% phương sai, còn dữ liệu đã chuẩn hóa cần tới 40. Vì sao chuẩn hóa lại cần nhiều hơn?

A Chuẩn hóa làm mất thông tin, nên phải bù thêm chiều

B Các pixel ở viền gần như không đổi bị đẩy lên phương sai 1

C Chuẩn hóa làm dữ liệu thưa hơn nên khó nén

D Đó là sai số ngẫu nhiên của thuật toán SVD

Khi đi thi

- Embedding 768–1024 chiều: PCA xuống 64–256 trước kNN hoặc boosting, giữ nếu validation không tụt.
- Văn bản: TF-IDF rồi `TruncatedSVD` vài trăm chiều.
- Vẽ PCA/UMAP train và test chung một hình để soi lệch phân phối.
- Fit scaler/PCA trên train của fold; không đưa tọa độ t-SNE làm feature.

03

Luyện đề

LUYỆN ĐỀ 1

Với $v = (1, -2, 3)$, vector đơn vị cùng hướng với v là gì?

A $v/14$

B $-v/\sqrt{14}$

C $v/\sqrt{14}$

D $v/\sqrt{6}$

ĐỀ THI USA-NA-AIO 2026 · Vòng 1 · Part 2.1

LUYỆN ĐỀ 2

UMAP vẽ một bản đồ 2 chiều cho các embedding. Khi đọc khoảng cách trên hình, câu nào đúng với điều UMAP ưu tiên?

A Mọi khoảng cách giữa hai điểm trong không gian gốc được giữ đúng tỉ lệ

B Phép chiếu luôn tuyến tính, nên đổi seed không làm đổi hình

C Nó tìm lỗi tái tạo nhỏ nhất, giống PCA

D Nó ưu tiên giữ láng giềng gần hơn là khoảng cách toàn cục

ĐỀ THI USA-NA-AIO 2026 · Vòng 1 · Part 1.5

Chốt ba điều

Center dữ liệu, tính component bằng SVD và tái tạo bằng cùng phép chiếu.

Explained variance đo phương sai giữ lại, không đo trực tiếp chất lượng nhãn.

Fit phép biến đổi trên train và đọc hình t-SNE/UMAP thận trọng.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook từ đầu; đổi số component, dự đoán shape và MSE tái tạo, rồi kiểm lại bằng output.