Clustering

Tính một vòng gán/cập nhật K-Means và inertia.

Nhóm nào có ý nghĩa?

Có hồ sơ học nhưng chưa có nhãn nhóm.

Thuật toán gợi một cách chia; con người kiểm và đặt tên.

Chọn clustering là chọn định nghĩa “cụm”.

Hai thuật toán có thể đúng theo hai giả định khác nhau.

01

K-Means

K-Means tối ưu điều gì?

Giả sử có K tâm $\boldsymbol{\mu}_k$. Inertia là tổng bình phương khoảng cách đến tâm gần nhất:

$$J = \sum_{i} \min_{k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2.$$

Lloyd lặp gán điểm rồi cập nhật tâm. Mỗi bước không làm J tăng, nhưng khởi tạo khác có thể dừng ở cực tiểu địa phương.

`k-means++` chọn tâm kế tiếp với xác suất tỉ lệ bình phương khoảng cách đến tâm gần nhất; `n_init` giữ nghiệm có inertia nhỏ nhất.

HỎI NHANH

Có ba điểm trên trục số: 0, 1 và 10. k-means++ đã chọn tâm đầu tiên là 0. Xác suất điểm 10 được chọn làm tâm thứ hai là bao nhiêu?

A khoảng 0.33

B khoảng 0.91

C khoảng 0.99

D khoảng 0.01

HỎI NHANH

Tăng K lên bằng số điểm n, mỗi điểm có một tâm riêng. Inertia tối ưu khi ấy bằng bao nhiêu?

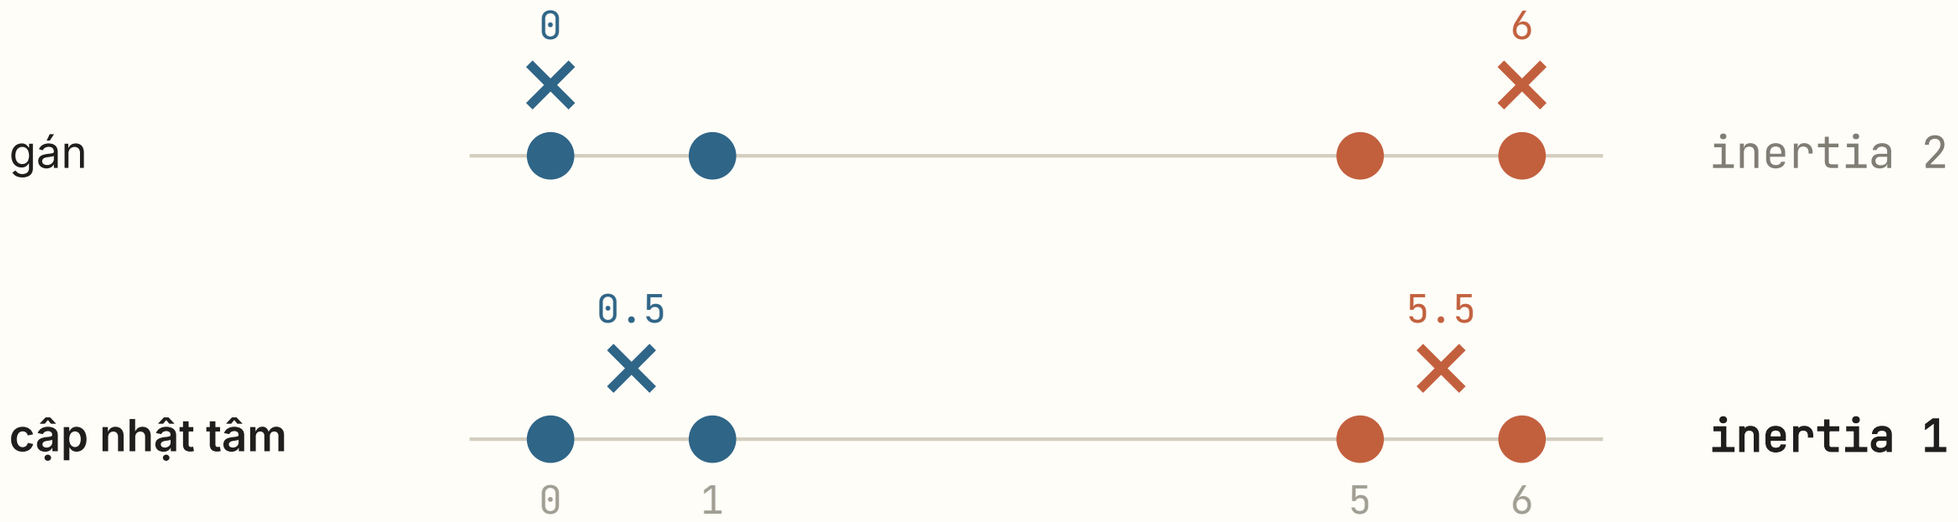
A Bằng phương sai của dữ liệu

B 0

C Bằng n

D Không xác định, vì cụm quá nhỏ

Gán điểm rồi cập nhật tâm



Một vòng Lloyd trên bốn điểm 0, 1, 5, 6: gán theo tâm gần nhất, rồi dời tâm (dấu ×) về trung bình nhóm; inertia từ 2 xuống 1.

Một vòng trên giấy

Điểm: 0,1,5,6. Tâm đầu: 0,6.

Gán: [0,0,1,1].

Tâm mới: 0.5,5.5.

Inertia: 2 → 1.

Gán xong mới cập nhật; mean là điểm làm tổng bình phương khoảng cách nhỏ nhất.

Đối chiếu trên máy

Bốn điểm 0, 1, 5, 6 và hai tâm ban đầu 0, 6 của ví dụ tính tay.

```
delta = (
    values[:, None, :] - centers[None, :, :]
)
distance2 = np.sum(delta ** 2, axis=2)
assigned = np.argmin(distance2, axis=1)
new_centers = np.array([
    values[assigned == k].mean(axis=0)
    for k in range(2)
])
print(assigned.tolist())
print(new_centers.ravel().tolist())
```

KẾT QUẢ

```
[0, 0, 1, 1]
[0.5, 5.5]
```

Đối chiếu từng bước với phép tính tay.

HỎI NHANH

Tự cài Lloyd bằng NumPy, tới một vòng thì có một cụm không được gán điểm nào. Xử lý thế nào là hợp lý?

A Coi tâm NaN là 0 rồi chạy tiếp

B Đặt lại tâm theo một quy tắc được ghi rõ

C Lấy bớt vài điểm của cụm khác chia sang

D Chia tổng tọa độ cho K thay vì cho số điểm

Khởi tạo tệ: tự sửa hay kẹt?

Điểm $1, 2, 9, 10, 11$; tâm đầu $1, 2$.

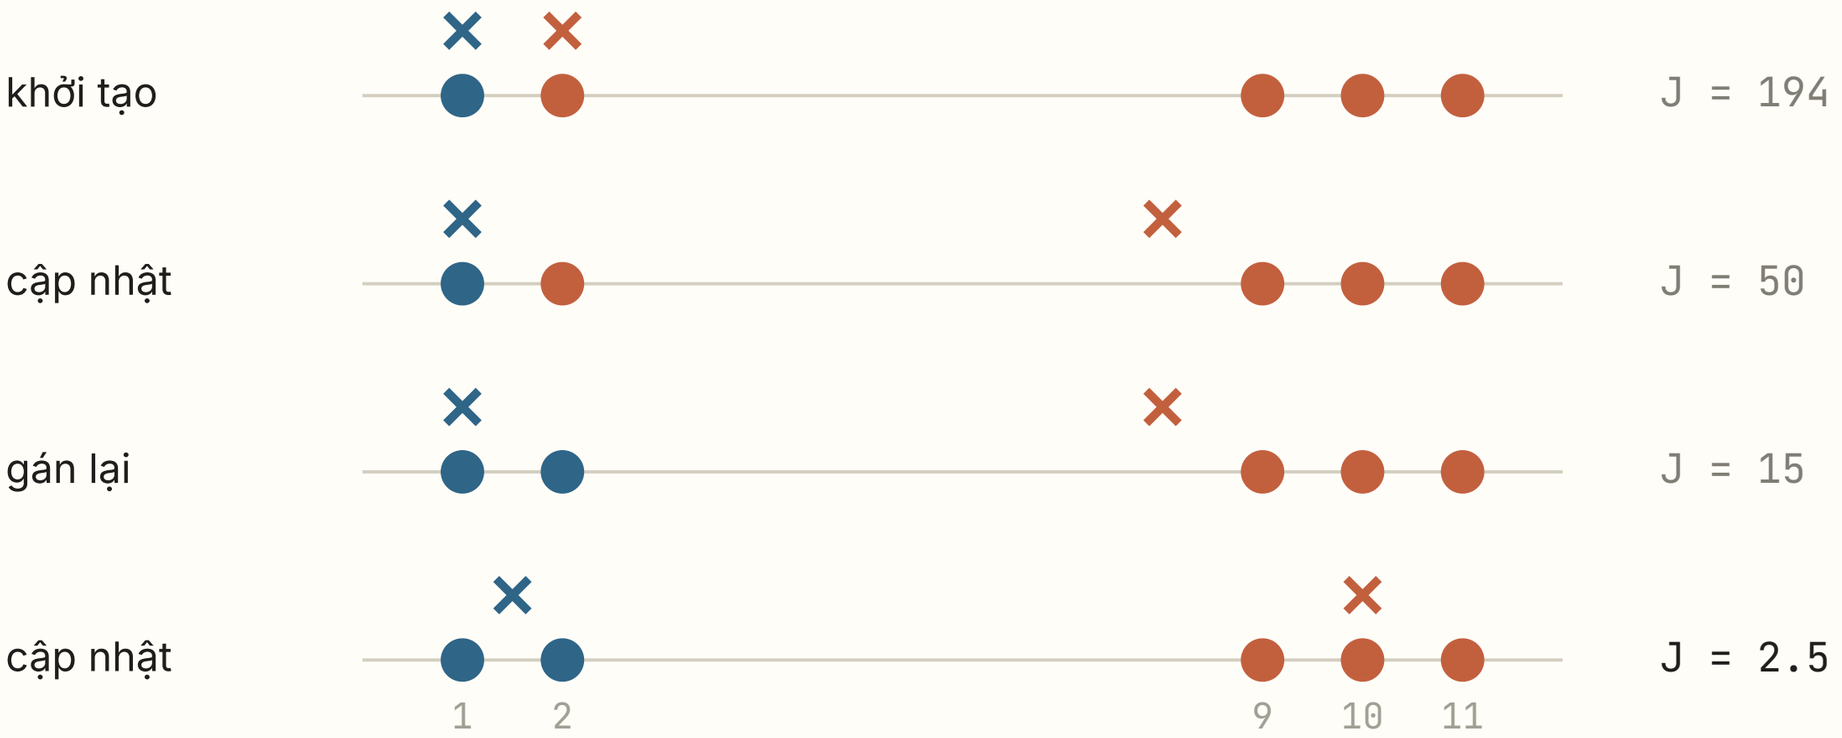
Điểm 2 chuyển cụm ở vòng hai; dừng ở $\{1, 2\}, \{9, 10, 11\}$.

J: $194 \to 50 \to 15 \to 2.5$.

Đổi điểm 2 thành 5 thì may mắn biến mất.

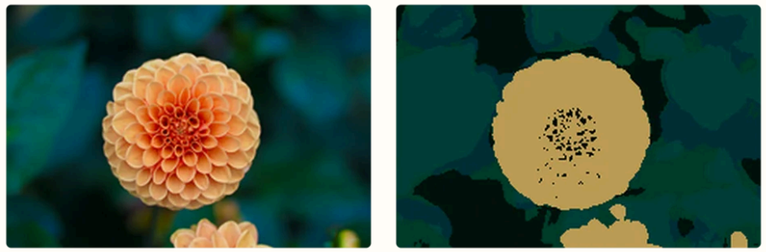
Lloyd luôn dừng, nhưng không hứa dừng ở nghiệm tốt nhất.

Bốn bước của Lloyd

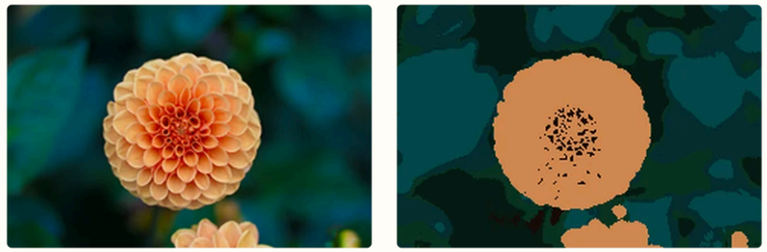


Ví dụ tính tay với khởi tạo tệ (tâm 1 và 2): sau hai vòng điểm 2 đổi cụm, J giảm 194 → 50 → 15 → 2.5.

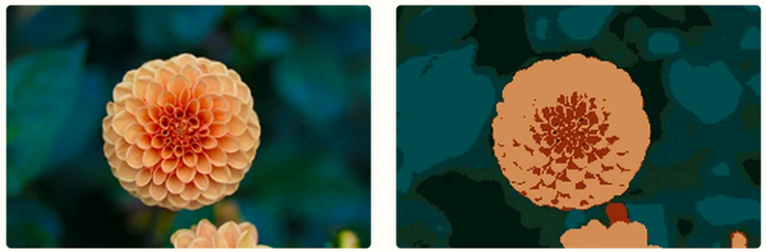
Lloyd gom màu của ảnh thật



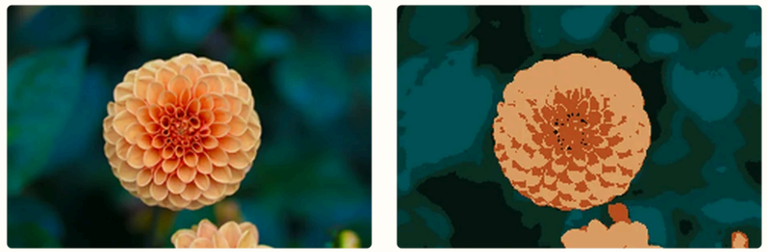
vòng 0: inertia 68.8 triệu (tâm là 6 điểm ảnh lấy ngẫu nhiên)



vòng 1: inertia 50.9 triệu



vòng 3: inertia 31.0 triệu



vòng 11: inertia 25.6 triệu; tâm không đổi nữa, dừng

K-Means gom các màu của ảnh hoa thành 6 cụm: sau mỗi vòng gán rồi lấy trung bình, mỗi điểm ảnh được tô bằng màu tâm cụm của nó.

HỎI NHANH

Giữ khởi tạo $\mu_1 = 1$, $\mu_2 = 2$, nhưng đổi điểm 2 thành 5, tức dữ liệu là 1, 5, 9, 10, 11. Thuật toán Lloyd dừng ở cách chia nào?

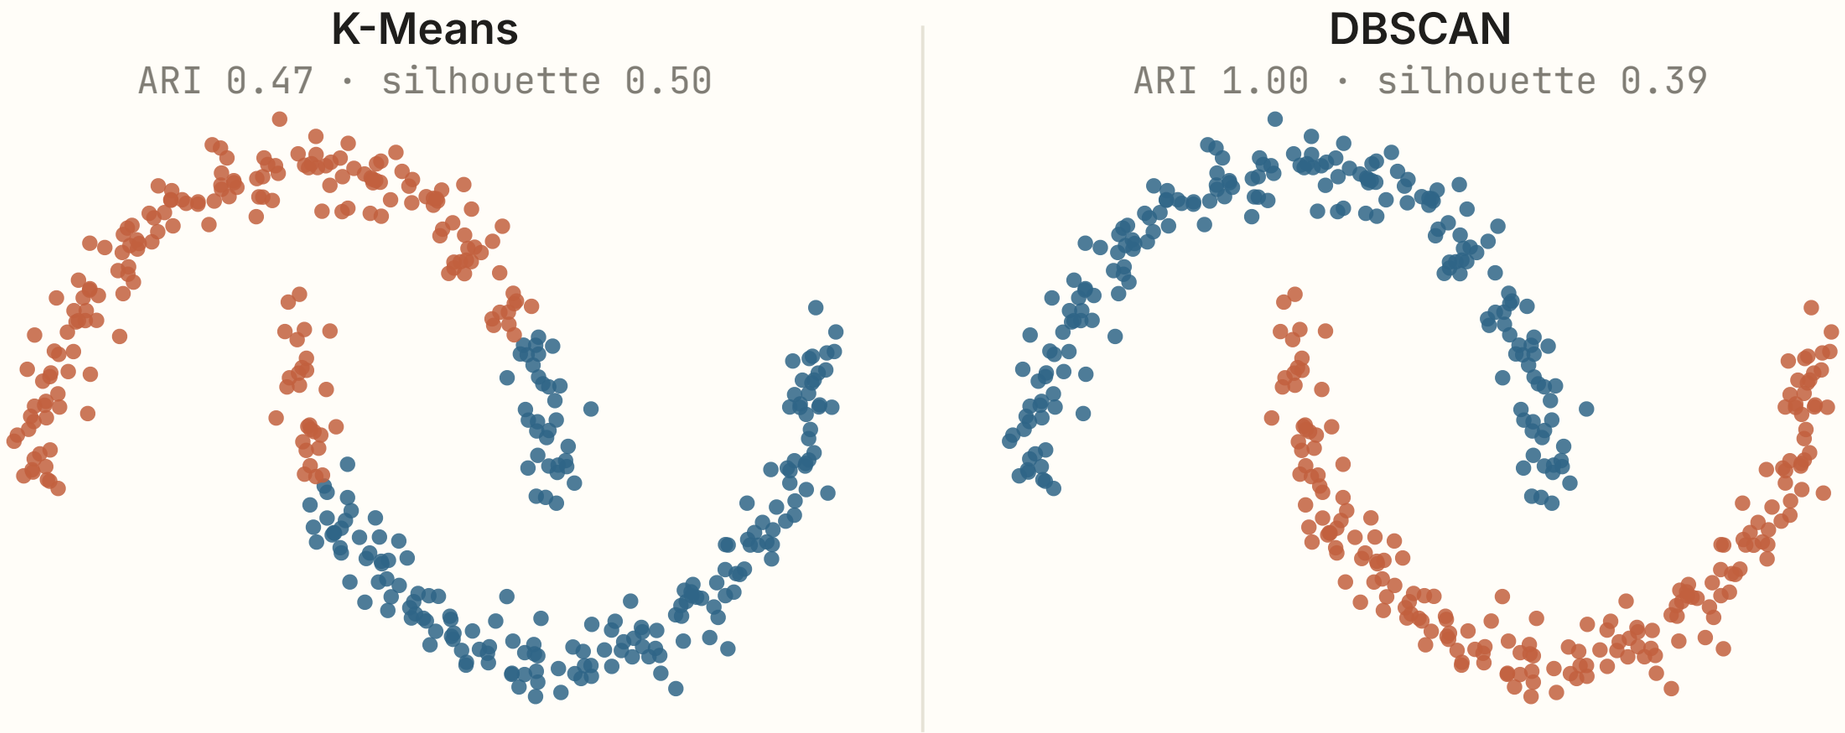
A $\{1, 5\}$ và $\{9, 10, 11\}$

B $\{1\}$ và $\{5, 9, 10, 11\}$

C $\{1, 5, 9\}$ và $\{10, 11\}$

D Không dừng, các tâm dao động mãi

Cụm tròn hay cụm cong?



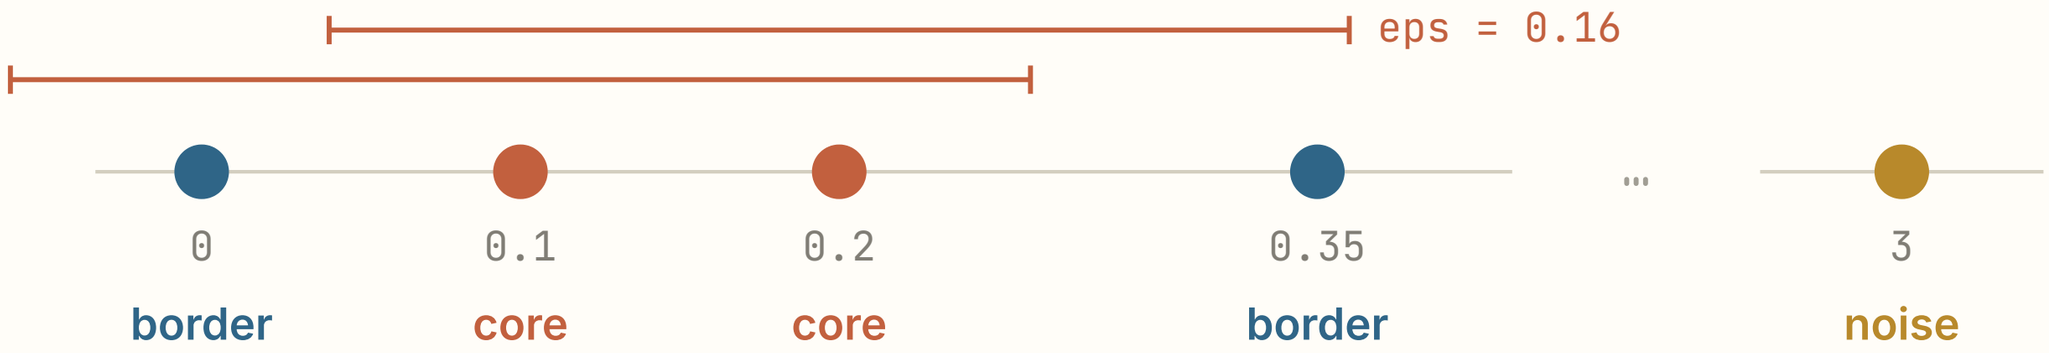
Hai trăng khuyết (code bài): K-Means cắt theo tâm nên trộn hai trăng; DBSCAN theo mật độ tách đúng, dù silhouette chấm thấp hơn.

K-Means thích cụm tròn, kích thước gần nhau. Trên hai nửa hình trăng, DBSCAN có thể theo mật độ còn K-Means chia theo vùng gần tâm.

02

DBSCAN

Core, border và noise



eps = 0.16, min_samples = 3: 0.1 và 0.2 là core (đoạn ngang là bán kính quanh chúng); 0 và 0.35 là border, vẫn vào cụm; 3 là noise.

`eps` là bán kính lân cận; `min_samples` là số điểm tối thiểu trong bán kính, tính cả chính điểm xét theo quy ước sklearn. Core nối thành cụm; border được nối từ core; noise nhận nhãn `-1`.

HỎI NHANH

Dữ liệu có hai cụm. Cụm A dày, các láng giềng thường cách nhau 0.1. Cụm B thưa, các láng giềng thường cách nhau 0.8. Với `eps=0.2`, DBSCAN dễ cho ra kết quả nào?

A Cả hai cụm đều được tìm đúng

B B thành cụm, còn phần lớn A thành noise

C A thành cụm, còn phần lớn B thành noise

D A và B bị gộp thành một cụm

Đọc output

Điểm: 0,0.1,0.2,0.35,3.

eps=0.16, min_samples=3.

Core: chỉ số 1,2.

Điểm 0 và 0.35 là border.

Giá trị 3 là noise (nhãn −1).

Điểm 0 chỉ có hai điểm trong lân cận nhưng vẫn vào cụm vì nối được với core 0.1.

HỎI NHANH

Giữ `eps=0.16` như ví dụ trên, nhưng đặt `min_samples=1`. Điểm 3 nhận nhãn gì?

A −1, vì vẫn ở xa mọi điểm khác

B Cụm 0, cùng với bốn điểm còn lại

C Báo lỗi, vì `min_samples` quá nhỏ

D Một cụm riêng, chỉ có mình nó

03

Phân cấp và spectral

Gộp dần hay cắt đồ thị?

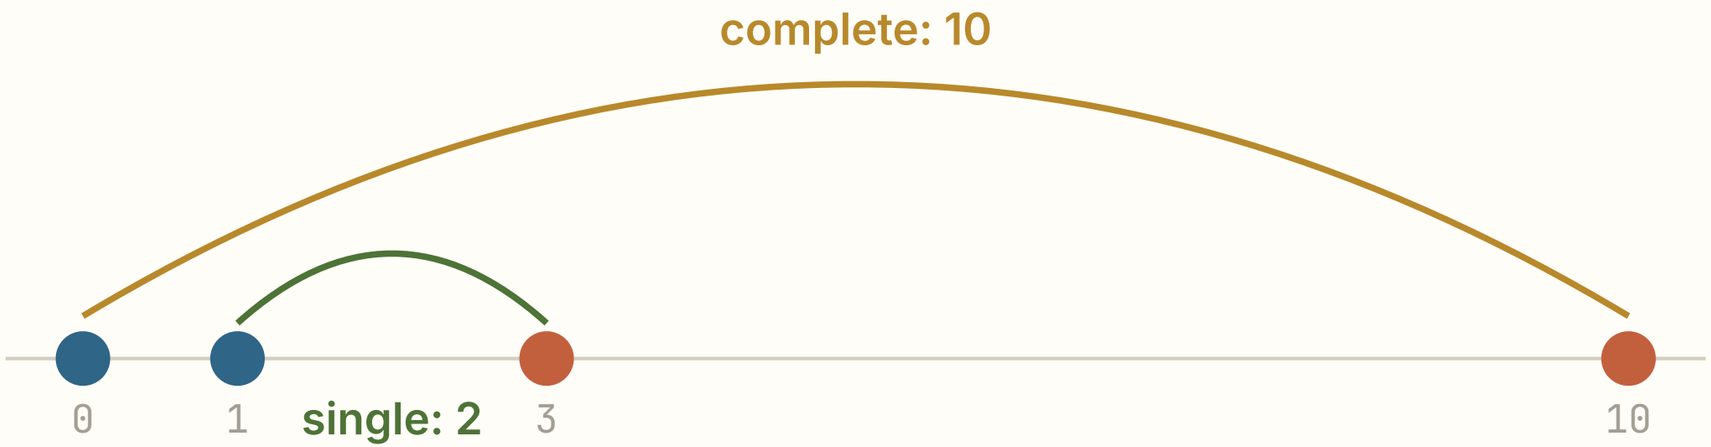
Agglomerative: mỗi điểm một cụm, gộp dần hai cụm gần nhất.

Linkage: *single* (cặp gần nhất), *complete* (cặp xa nhất), *average*, *Ward*.

Spectral: dựng đồ thị láng giềng, lấy vector riêng của Laplacian làm tọa độ, rồi K-Means.

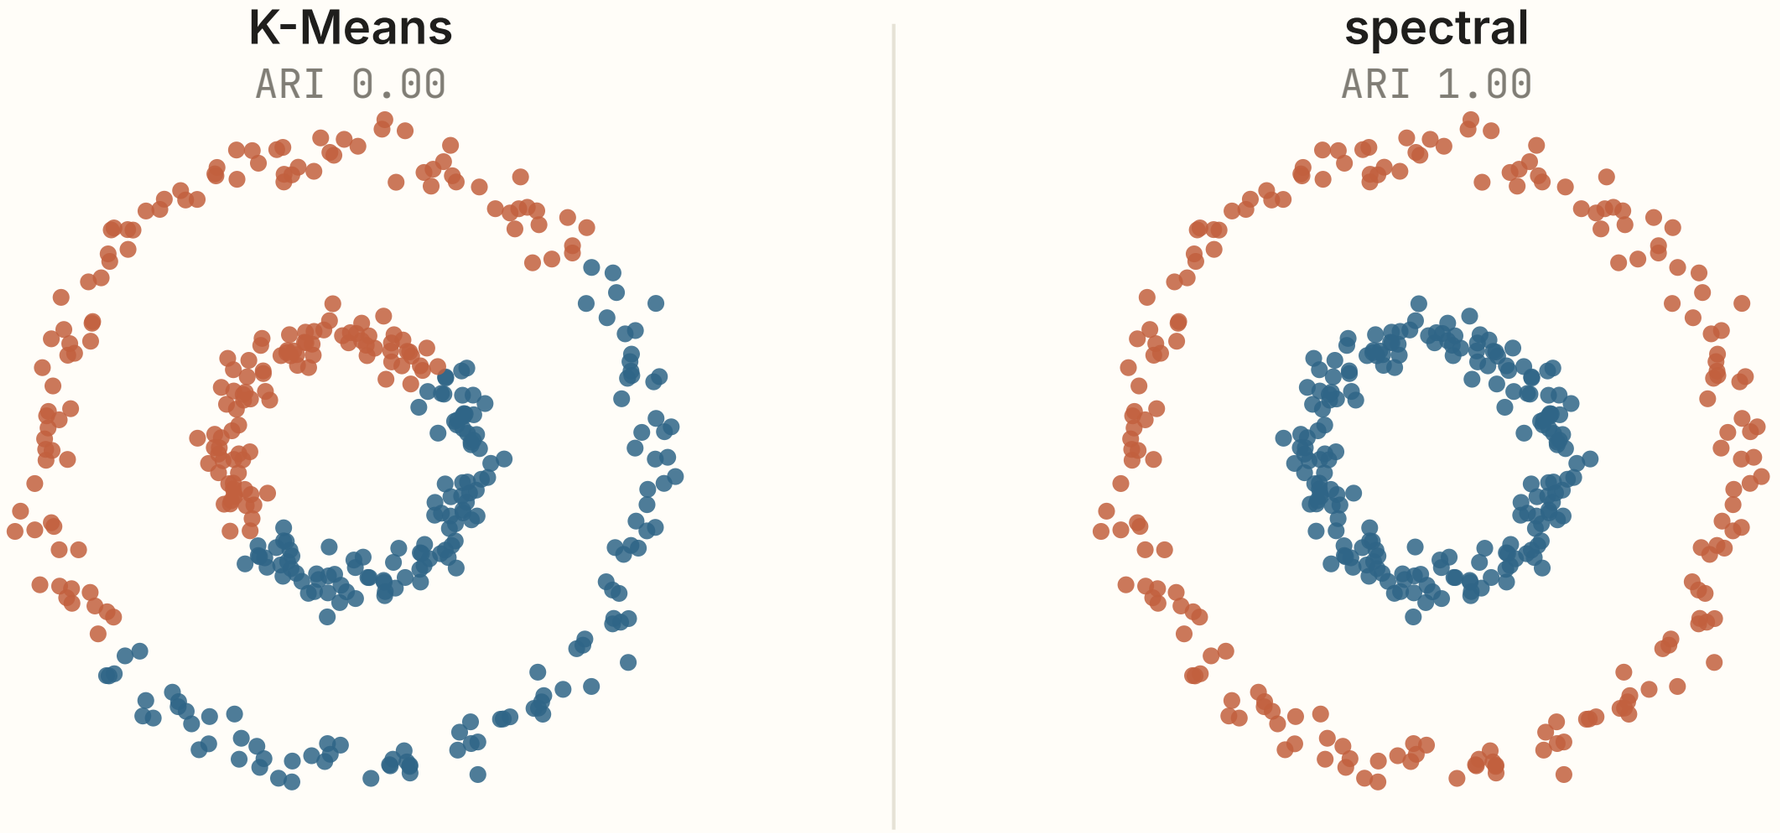
Mạnh với cụm không lồi; tốn kém khi n lớn.

Single và complete



Hai cụm {0, 1} và {3, 10}: single linkage đo cặp gần nhất (2), complete linkage đo cặp xa nhất (10).

Hai vòng đồng tâm



Hai vòng đồng tâm: K-Means cắt đôi theo một đường thẳng; spectral clustering trên đồ thị láng giềng tách đúng từng vòng.

HỎI NHANH

Hai cụm trên trục số là $\{0, 1\}$ và $\{3, 10\}$. Khoảng cách giữa chúng theo single linkage và theo complete linkage lần lượt là bao nhiêu?

A 3 và 9

B 6 và 6

C 2 và 6

D 2 và 10

HỎI NHANH

Hai vòng tròn đồng tâm, mỗi vòng là một cụm. K-Means với $K = 2$ cho ARI gần bằng 0, còn spectral clustering trên đồ thị láng giềng thì tách đúng. Lý do chính là gì?

A Đồ thị láng giềng gần như không có cạnh nối hai vòng

B Spectral clustering dùng nhiều tâm hơn K-Means

C Vòng trong có mật độ điểm cao hơn vòng ngoài

D K-Means không chạy được trên dữ liệu hai chiều

04

Đánh giá cách chia

Metric trả lời câu nào?

Có nhãn tham khảo: ARI, không phụ thuộc tên ID cụm.

Không nhãn: silhouette, cần điều kiện số cụm và cách xử lý noise.

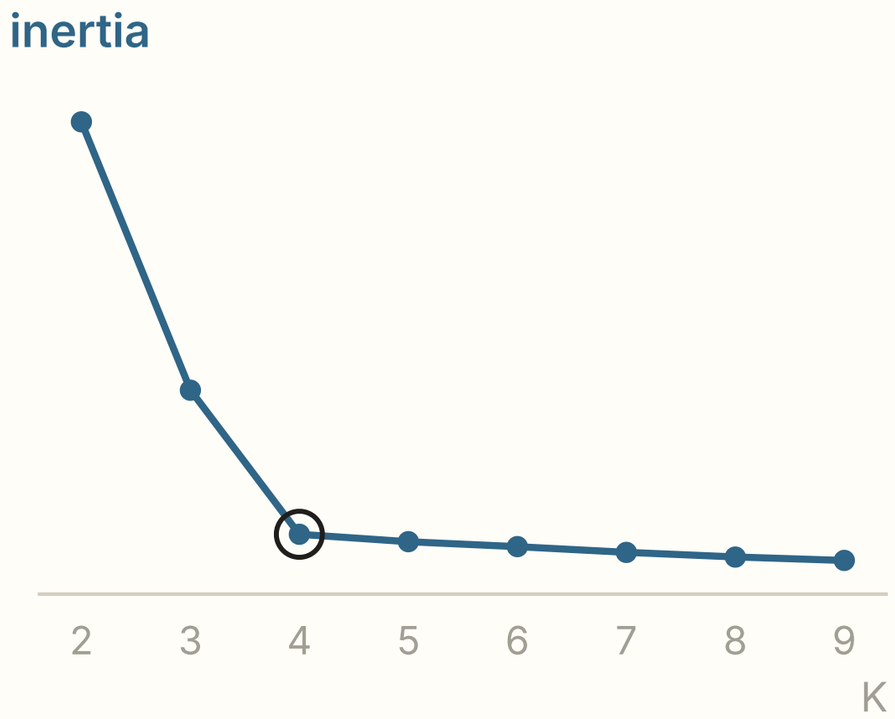
Inertia nhỏ nhất tự đẩy về K lớn.

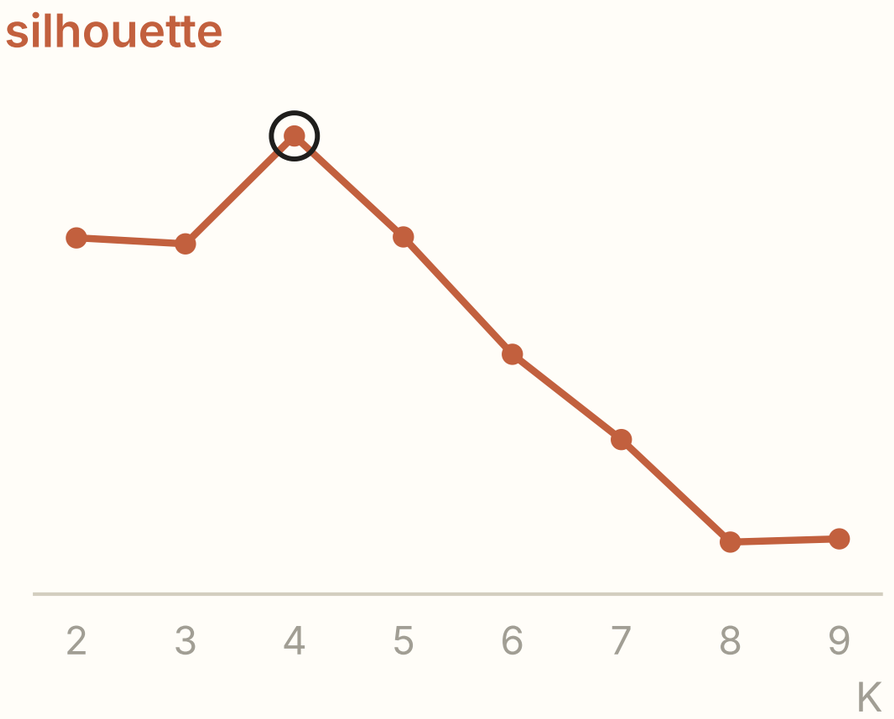
Elbow là gợi ý, không định lý về K thật.

Cụm số 0 chưa có nghĩa là “giỏi”.

$s(i) = \frac{b(i)-a(i)}{\max\{a(i),b(i)\}}$: gần 1 là gọn và tách, gần 0 là ở giữa, âm là có thể xếp nhầm.

Chọn K





Bốn cụm sinh sẵn: inertia giảm mãi theo K nhưng gãy khúc ở K = 4; silhouette cao nhất cũng ở K = 4.

HỎI NHANH

Một điểm có $a(i) = 1$, tức khoảng cách trung bình tới cụm của nó, và $b(i) = 4$, tức khoảng cách trung bình tới cụm khác gần nhất. Silhouette của điểm này bằng bao nhiêu?

A 0.25

B 3

C 0.75

D -0.75

HỎI NHANH

Nhãn tham khảo là $[0, 0, 1, 1]$, mô hình trả về $[1, 1, 0, 0]$. Accuracy so thẳng và ARI lần lượt bằng bao nhiêu?

A 0 và 1

B 1 và 1

C 0 và 0

D 0.5 và 0

Cùng dữ liệu, metric có thể trái chiều

KẾT QUẢ

```
K-Means ARI = 0.47  silhouette = 0.5
DBSCAN  ARI = 1.0  silhouette = 0.39
```

Trên `make_moons`, DBSCAN khớp nhãn tham khảo tốt hơn theo ARI dù silhouette thấp hơn. Metric phải khớp câu hỏi và cách xử lý noise.

Nếu có nhãn tham khảo, ARI/NMI không phụ thuộc tên ID cụm. Nếu không có nhãn, silhouette chỉ đo một khía cạnh hình học.

`eps=0.3` chỉ có nghĩa sau `StandardScaler`.

HỎI NHANH

Trong code trên, nhân `X` đã chuẩn hóa lên 10 lần nhưng giữ `eps=0.3`. DBSCAN sẽ trả về gì?

A Gần như mọi điểm thành noise

B Như cũ, vì hình dạng các cụm không đổi

C Hai mặt trăng bị gộp thành một cụm

D Số cụm tăng lên khoảng mười lần

Khi đi thi

- Chấm bằng ARI/NMI: chọn thuật toán theo hình dạng dữ liệu, không mặc định K-Means.
- Cụm làm tiền xử lý hay đặc trưng: mã cụm, khoảng cách đến tâm.
- Cụm làm group cho `GroupKFold` khi có bản ghi gần trùng.
- Chuẩn hóa trước thuật toán dựa trên khoảng cách; fit scaler đúng giao thức.

05

Luyện đề

LUYỆN ĐỀ 1

Có bảy điểm $x_1, \ldots, x_7$, $K = 2$, hai tâm khởi tạo là x_3 và x_6. Khoảng cách từ x_1, x_2, x_4, x_5, x_7 tới x_3 lần lượt là 3, 4, 4, 3, 6. Tới x_6 lần lượt là 2, 7, 1, 8, 1. Sau bước gán đầu tiên, hai cụm là gì?

A $\{x_1, x_2, x_3, x_4\}$ và $\{x_5, x_6, x_7\}$

B $\{x_2, x_3, x_5\}$ và $\{x_1, x_4, x_6, x_7\}$

C $\{x_1, x_2, x_3, x_5\}$ và $\{x_4, x_6, x_7\}$

D $\{x_2, x_3, x_4, x_7\}$ và $\{x_1, x_5, x_6\}$

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q8.3

LUYỆN ĐỀ 2

Mỗi bộ dữ liệu gồm 400 điểm (x, y) sinh từ bốn hàm: mũ, log, sin và tuyến tính, mỗi hàm 100 điểm có nhiễu. Baseline của đề chạy K-Means với $k = 4$ trên (x, y), rồi fit riêng từng cụm. Bước phân cụm này yếu ở đâu?

A $k = 4$ là sai, vì đề chưa cho số hàm thật

B K-Means không chạy được trên dữ liệu hai chiều

C Thiếu chuẩn hóa y nên K-Means báo lỗi

D Các đường cong cắt nhau, nên các cụm bị trộn lẫn

PHỎNG THEO USA-NA-AIO 2026 · Vòng 2 · Ngày 2 · Problem 5

Chốt ba điều

K-Means tối ưu inertia theo các bước gán và cập nhật, nhưng cần K và khởi tạo tốt.

DBSCAN dùng mật độ: phân biệt core, border và noise theo `eps`, `min_samples` và thang đo.

Đọc số cụm, metric và ảnh hưởng thang đo mà không tự gọi cụm là nhãn thật.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook từ đầu; đổi `K`, `eps` hoặc thang đo, dự đoán inertia/nhãn noise, rồi kiểm lại bằng output.