Feature engineering

Tạo đặc trưng tốt từ thông tin có lúc dự đoán

Chương 2 · Bài 2.11

Đặc trưng có sẵn lúc nào?

Dự đoán số đơn đầu giờ.

Giờ, cửa hàng và doanh số quá khứ đã biết.

Doanh số giờ đang dự đoán chưa biết.

Feature tốt phải vừa có nghĩa vừa có sẵn đúng thời điểm.

Mục tiêu

- Tạo đặc trưng từ cột số, cột phân loại, thời gian và lịch sử.
- Dùng lag, rolling và encoding theo nhóm.
- So các nhóm đặc trưng bằng cùng fold; tránh leakage.

01

Biểu diễn dữ liệu

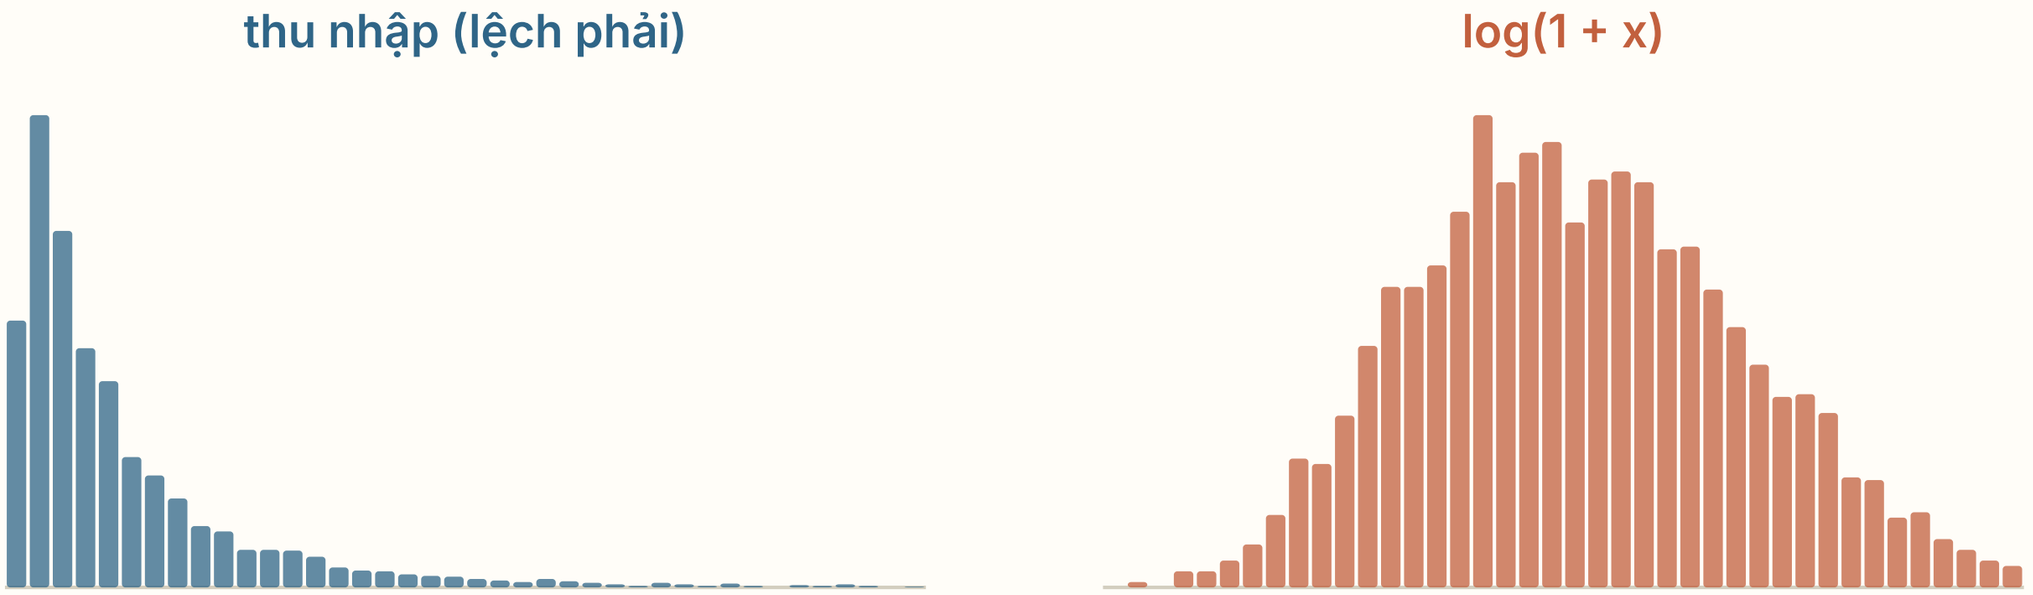
Số và danh mục

Thao tác	Linear/kNN/SVM	Cây
Scale	Thường cần	Không cần cho ngưỡng
Log biến lệch	Thường có ích	Gần như không đổi
One-hot	Danh mục không thứ tự	Tùy thư viện
Tương tác, tỉ số	Thường phải tạo	Học được một phần

Mã cửa hàng 1, 2, 3 không có nghĩa là khoảng cách: dùng one-hot.

Mã theo thứ tự chỉ khi thứ tự có thật.

Log cho biến lệch



Thu nhập dồn sát 0 với đuôi dài; sau log(1 + x) gần cân đối.

HỎI NHANH

Áp $\log(1+x)$ cho cột thu nhập, rồi học lại một cây quyết định trên cùng dữ liệu. Chuyện gì xảy ra?

A Cây sâu hơn, vì phân phối cân đối hơn

B Cây chia train y hệt, chỉ có ngưỡng là đổi

C Cây tốt hơn hẳn, nhờ bớt lệch phải

D Phải chuẩn hóa lại thì cây mới chạy được

HỎI NHANH

Cần dự đoán giá nhà trước khi bán. Cột `price/area` được tạo từ giá bán thực tế. Lúc dự đoán, `area` đã biết nhưng `price` thì chưa. Feature này có hợp lệ không?

A Có, vì chia cho diện tích đã loại ảnh hưởng của target

B Có, nếu chỉ fit scaler trên train

C Có, nếu dùng cây thay cho linear regression

D Không, vì phép tính cần chính target chưa biết

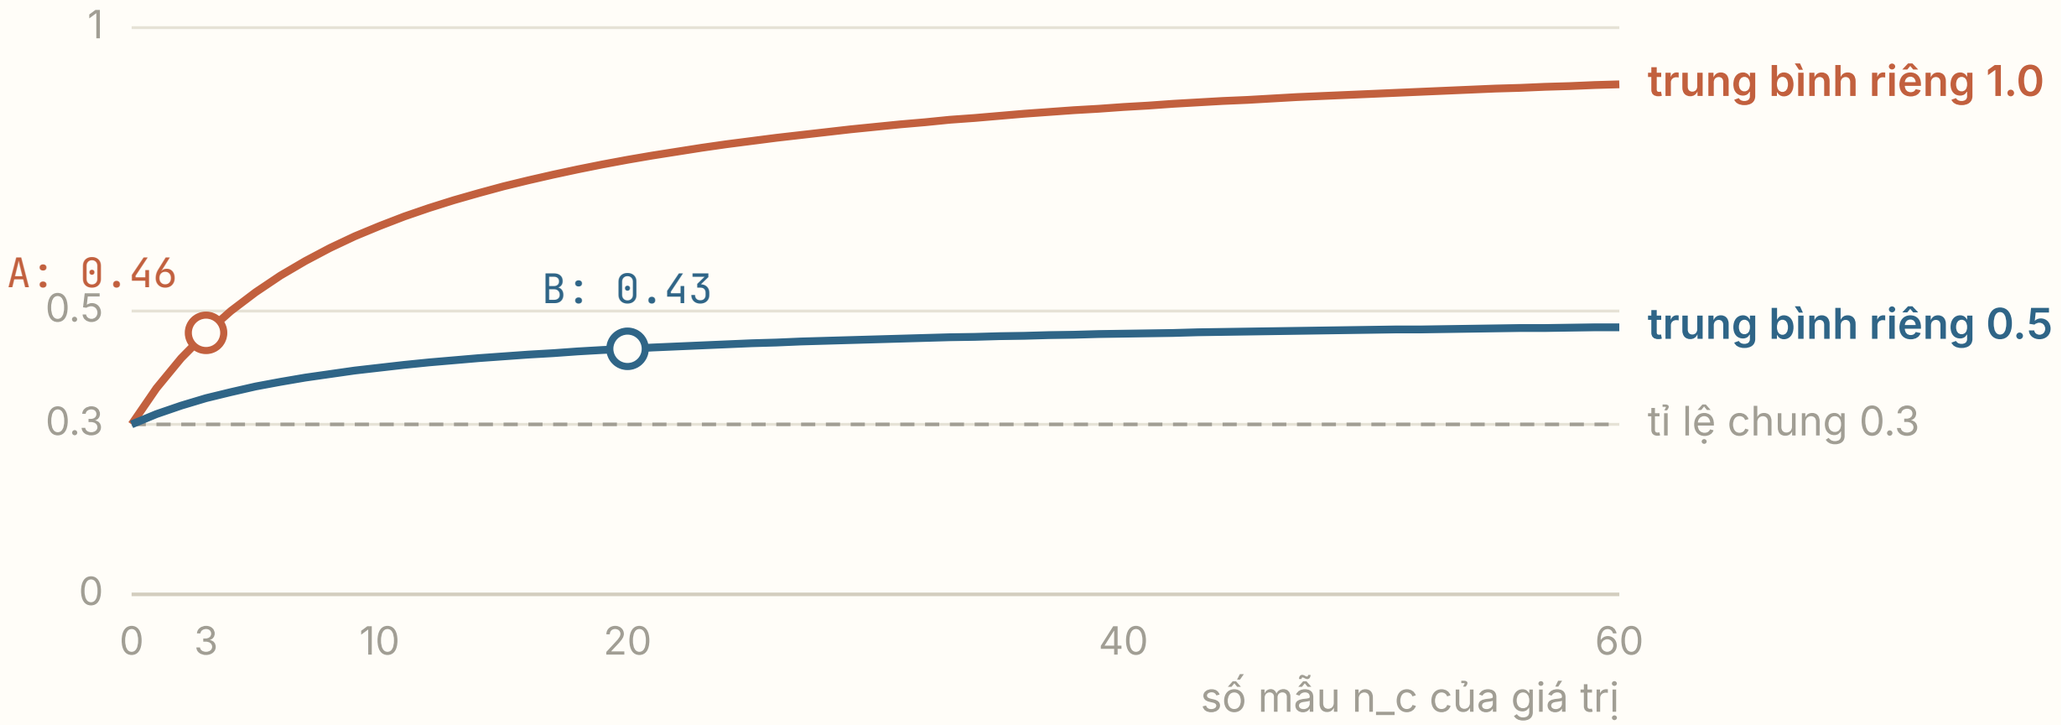
Target encoding cần cross-fitting

$$TE(c) = \frac{n_c \bar{y}_c + m\bar{y}}{n_c + m}$$

Giá trị của mỗi mẫu không được dùng nhãn của chính nó: tính out-of-fold.

Ví dụ $n_c = 3$, $\bar{y}_c = 1$, $m = 10$, $\bar{y} = 0.3$: $TE(c) = \frac{3+3}{13} \approx 0.46$, không phải 1.0.

Làm mượt theo số mẫu



Giá trị ít mẫu bị kéo về tỉ lệ chung; nhiều mẫu thì gần trung bình riêng.

HỎI NHANH

Vẫn $m = 10$ và tỉ lệ chung là 0.3. Quận B có 20 mẫu, một nửa mang nhãn 1. Giá trị mã hóa của B bằng bao nhiêu?

A khoảng 0.43

B 0.50

C 0.30

D khoảng 0.40

HỎI NHANH

Khách bỏ trống ô thu nhập có tỉ lệ vỡ nợ 40%, khách điền đầy đủ chỉ 10%. Ta điền median vào ô trống và không thêm cột nào khác. Hệ quả chính là gì?

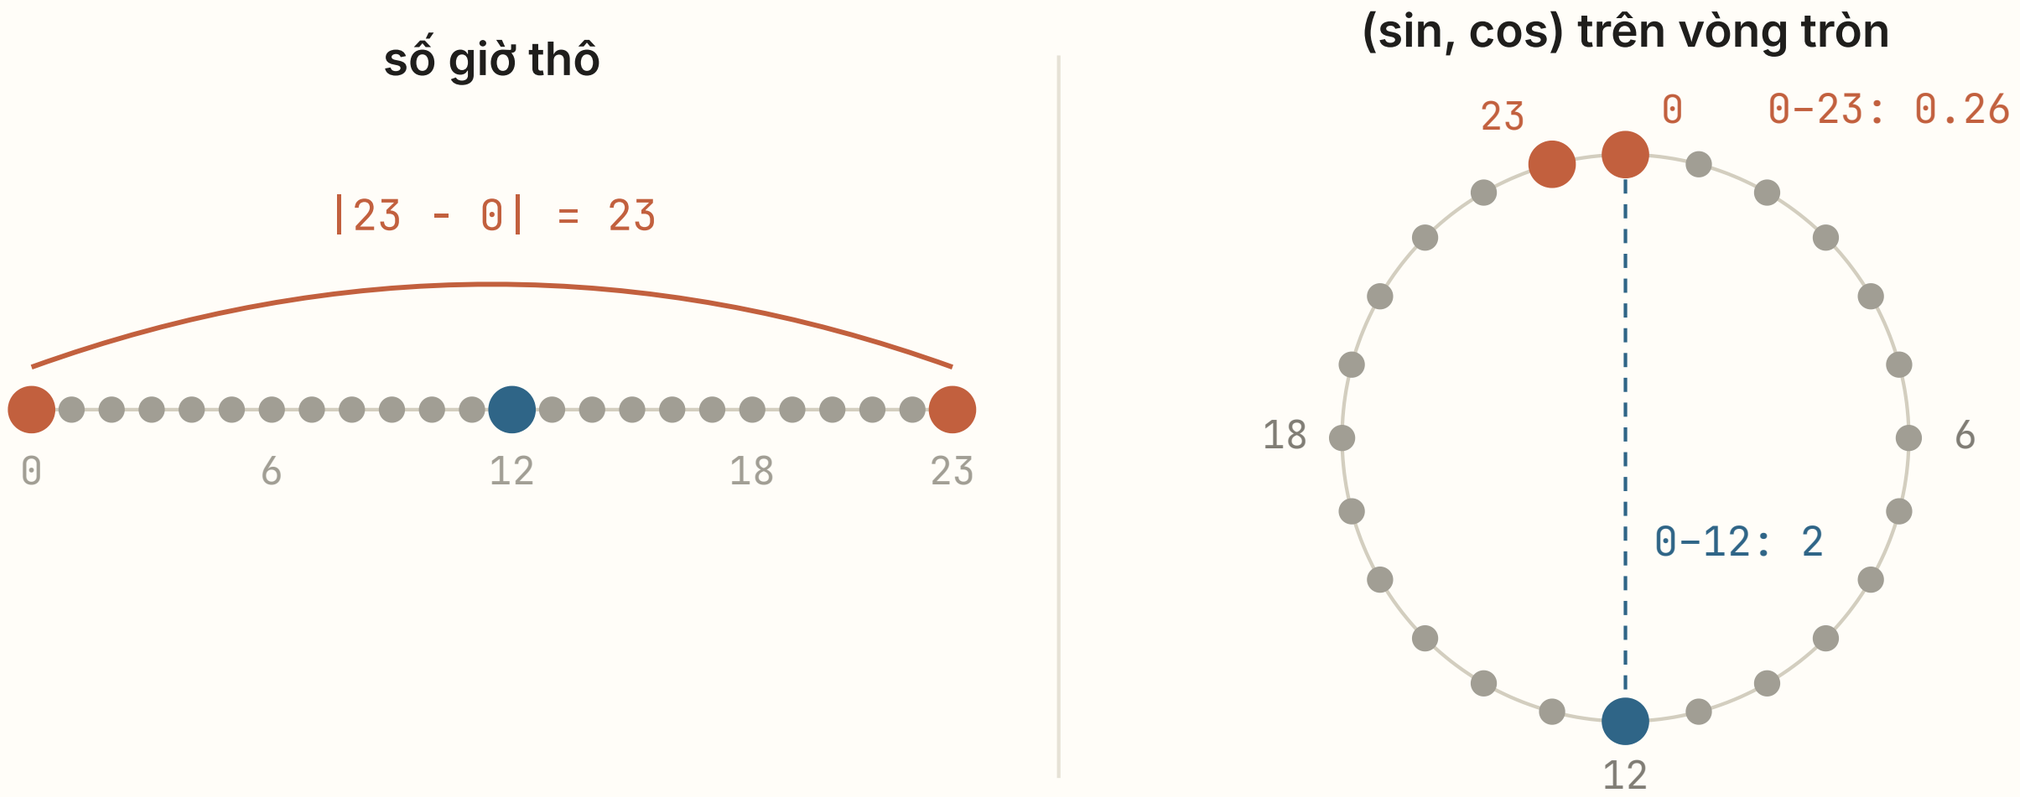
A Mô hình mất đi tín hiệu “bỏ trống”, một tín hiệu rất mạnh

B Không sao, vì median giữ nguyên phân phối

C Tốt hơn, vì dữ liệu không còn giá trị NaN

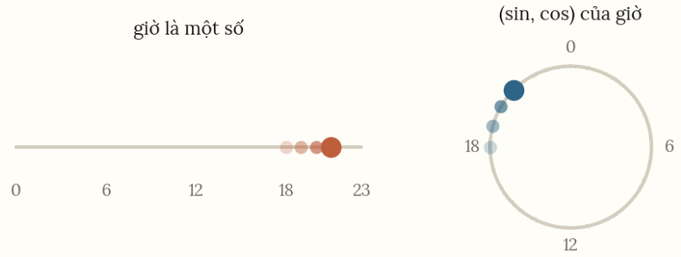
D Mô hình báo lỗi, vì cột đã đổi kiểu dữ liệu

Thời gian có chu kỳ

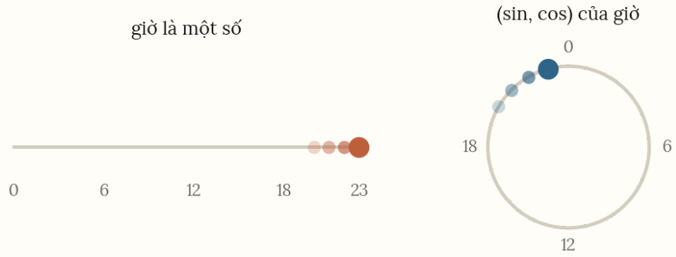


Mã hóa (sin, cos) đặt 23 giờ cạnh 0 giờ trên vòng tròn.

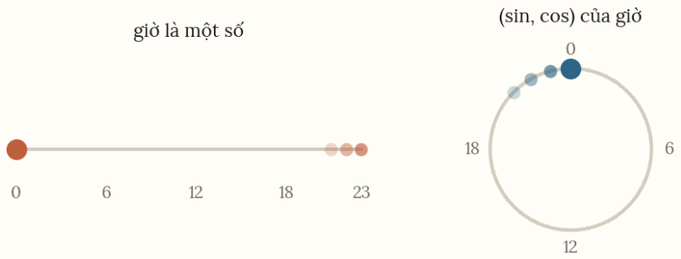
Giờ đi qua nửa đêm



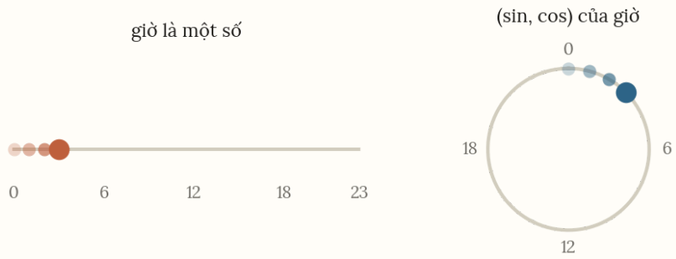
21 giờ: sin −0.71, cos +0.71



23 giờ: sin −0.26, cos +0.97



0 giờ: sin +0.00, cos +1.00 · trên trục số nhảy từ 23 về 0, trên vòng tròn chỉ đi một bước



3 giờ: sin +0.71, cos +0.71

Giờ trong ngày chạy từ 18 giờ qua nửa đêm: trên trục số 23 và 0 cách nhau xa nhất; mã hóa (sin, cos) đặt chúng cạnh nhau trên vòng tròn.

Tọa độ của chu kỳ 24 giờ

$$x_{\sin} = \sin\frac{2\pi t}{24}, \qquad x_{\cos} = \cos\frac{2\pi t}{24}.$$

23 giờ và 0 giờ cách nhau khoảng 0.26 trên đường tròn; 12 giờ và 0 giờ cách nhau 2. Hai tọa độ giữ quan hệ cuối ngày và đầu ngày.

HỎI NHANH

Sau khi mã hóa giờ bằng sin và cos với $T = 24$, khoảng cách Euclid giữa 22 giờ và 2 giờ bằng bao nhiêu?

A 20

B 1

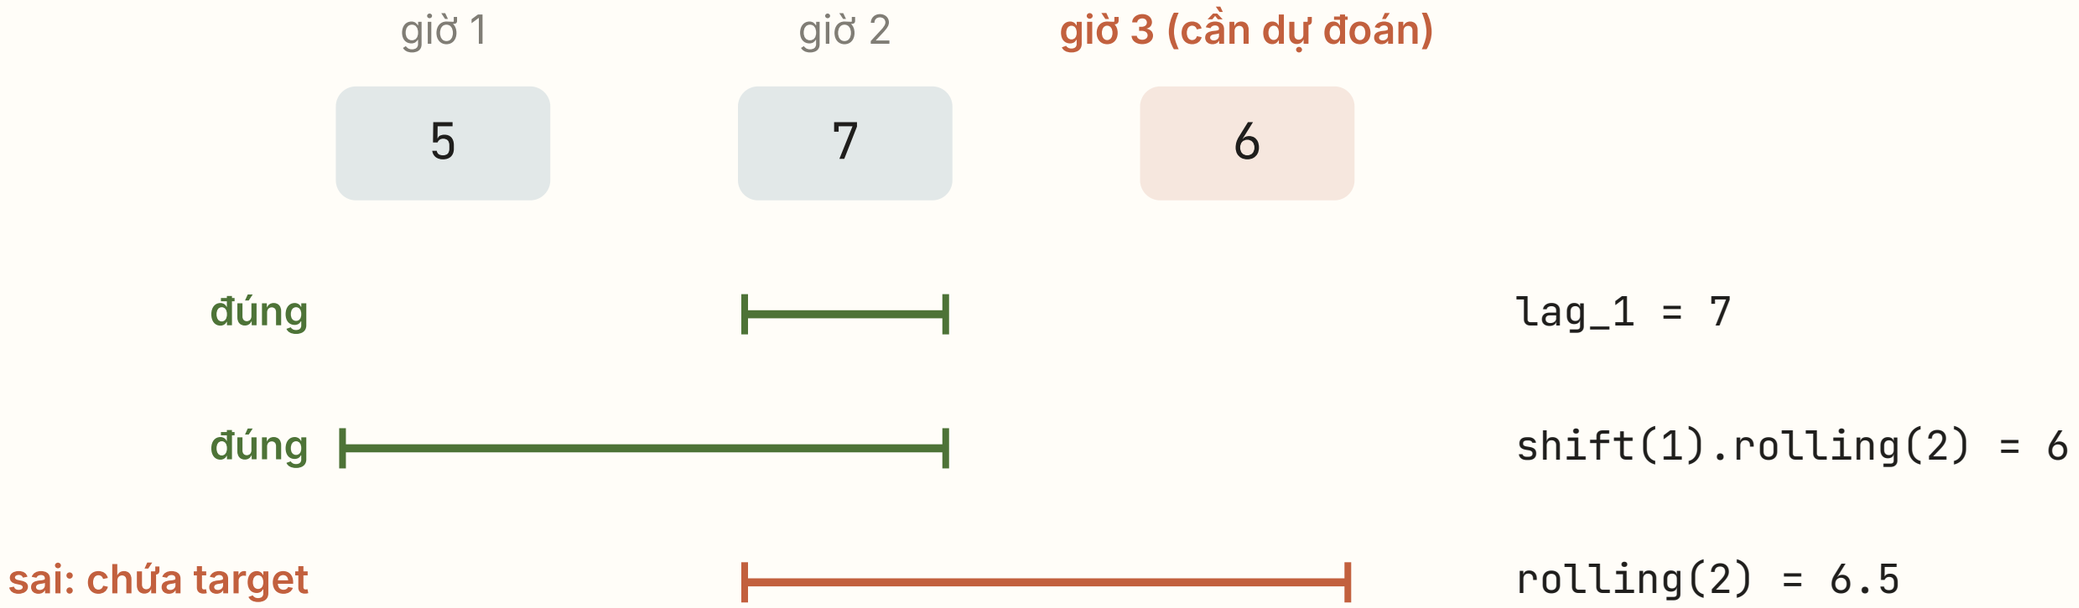
C 4

D khoảng 0.26

02

Thông tin từ quá khứ

Cửa sổ nào được phép?



Sau shift(1), lag và rolling chỉ dùng giờ trước giờ cần dự đoán.

Mọi feature ở bên trái vạch phải có sẵn trước thời điểm dự đoán; target ở bên phải chưa được dùng.

HỎI NHANH

Dùng sai phân $y_t - y_{t-1}$ làm feature để dự đoán y_t. Có hợp lệ không?

A Có, vì sai phân đo xu hướng gần nhất

B Có, nếu y_{t-1} đã được lấy bằng `shift(1)`

C Không, vì nó chứa chính y_t

D Không, vì sai phân chỉ thêm nhiễu

HỎI NHANH

Thêm cột `shop_mean = groupby("shop")["sales"].transform("mean")`, tính trên toàn bảng train theo giờ, rồi dùng nó để dự đoán `sales`. Có vấn đề gì?

A Không sao, đây chỉ là thống kê theo nhóm

B Cột này trùng thông tin với one-hot của shop

C `transform` làm xáo trộn thứ tự các hàng

D Mỗi hàng chứa cả sales của chính nó lẫn sales tương lai

Một hàng cụ thể

Dự đoán giờ 3 của A; hai giờ trước có 5, 7.

`lag_1=7`, `mean_prev_2=(5+7)/2=6`.

Shift trước rolling, sort thời gian trong nhóm.

NaN đầu chuỗi là thiếu lịch sử thật, không tự điền bằng tương lai.

HỎI NHANH

Quên `shift(1)`, viết thẳng `rolling(2).mean()` trên doanh số 5, 7, 6 của cửa hàng A. Giá trị ở giờ 3 bằng bao nhiêu?

A 6, giống hệt bản có shift

B 7, giá trị gần nhất trước đó

C 6.5, có chứa luôn target của giờ 3

D NaN, vì chưa đủ lịch sử

Lag và trung bình hai giờ trước

```
history = history.sort_values(["shop", "time"])
history["lag_1"] = history.groupby("shop")["sales"].shift(1)
history["mean_prev_2"] = history.groupby("shop")["sales"].transform(
    lambda s: s.shift(1).rolling(2, min_periods=2).mean()
)
```

KẾT QUẢ

shop	time	sales	lag_1	mean_prev_2
A	1	5.0	NaN	NaN
A	2	7.0	5.0	NaN
A	3	6.0	7.0	6.0
B	1	3.0	NaN	NaN
B	2	4.0	3.0	NaN

Chỉ giờ 3 của A có đủ hai giờ trước.

HỎI NHANH

Hàng 4, thuộc cửa hàng B, có `lag_1 = 3` nhưng `roll_mean_2` lại là NaN. Vì sao?

A `shift` làm mất dữ liệu của B

B Trước đó B mới có một giờ bán

C Rolling tính chung cả A và B

D Do `round(2)` khi in kết quả

Giá trị mới ở test

Fit OneHotEncoder trên A/B.

Test có C: `handle_unknown="ignore"`.

KẾT QUẢ

```
shape: (3, 3) (1, 3)
mẫu mới: [[0.0, 0.0, 0.0]]
```

C thành toàn 0 ở hai cột A, B: chạy được, nhưng model chưa học gì về C.

Không fit lại encoder trên test.

HỎI NHANH

Trong code trên, nếu lỡ gọi `preprocessor.fit_transform(new_features)` thay vì `transform`, đầu ra có shape gì?

A `(1, 3)`, như cũ

B `(1, 4)`

C `(1, 2)`

D Báo lỗi, vì C chưa từng xuất hiện

03

Kiểm giả thuyết

So sánh có kiểm soát

Giữ nguyên fold và metric.

Thêm hoặc bỏ một nhóm đặc trưng.

Ghi điểm từng fold, chi phí và giả thuyết.

Đổi feature lẫn split cùng lúc thì không biết điểm đổi vì đâu.

Feature importance chỉ gợi ý; bỏ từng nhóm trên cùng fold mới đo được đóng góp.

HỎI NHANH

Mô hình đầy đủ có MAE 2.0 trên các fold cố định. Bỏ nhóm lag thì MAE là 2.9, bỏ nhóm thời gian là 2.02, bỏ nhóm thống kê cửa hàng là 2.3. Nhóm nào đóng góp nhiều nhất?

A Nhóm lag

B Nhóm thời gian

C Nhóm thống kê cửa hàng

D Chưa biết khi chưa xem feature importance

HỎI NHANH

Với mô hình cây, cột `order_id` đứng đầu bảng feature importance. Phản ứng hợp lý nhất là gì?

A Giữ lại, vì importance cao là feature tốt

B Nghi ngờ, vì mã có thể tăng dần theo thời gian

C Chuẩn hóa `order_id` rồi học lại

D One-hot `order_id` cho mô hình hiểu rõ hơn

HỎI NHANH

Đếm tần suất của mã sản phẩm trên train và test gộp lại, không dùng nhãn. Cách này hợp lệ khi nào?

A Luôn hợp lệ, vì không đụng tới nhãn

B Không bao giờ, vì đã nhìn vào dữ liệu test

C Chỉ khi mô hình phía sau là cây

D Khi lúc dự đoán thật cũng có sẵn cả lô ấy

Khi đi thi

- Mỗi cột: sinh ra lúc nào, lúc dự đoán đã có chưa?
- Thống kê dùng nhãn: out-of-fold.
- Thêm từng nhóm feature, so trên cùng fold.

04

Luyện đề

LUYỆN ĐỀ 1

Dự đoán số khách của một buổi hòa nhạc. Một feature là “số khách của buổi trước, nếu biết”. Nên mã hóa thế nào?

A One-hot cho từng giá trị số khách

B Giữ dạng số đã chuẩn hóa, điền 0 khi không biết

C Giữ dạng số đã chuẩn hóa, thêm một cột đánh dấu khi không biết

D Bỏ cột này, vì đôi khi bị thiếu

PHỎNG THEO MIT 6.036 · Final, Spring 2022 · Q5(a)

LUYỆN ĐỀ 2

Đầu vào (x_1, x_2) được thay bằng vector feature $(1, x_1^2, x_2^2)$, rồi học logistic regression với tham số (b, w_1, w_2). Ranh giới quyết định, nơi $P(Y = 1) = P(Y = 0)$, là tập nào?

A $b + w_1 x_1^2 + w_2 x_2^2 = 0$, chẳng hạn một ellipse

B $b + w_1 x_1 + w_2 x_2 = 0$, một đường thẳng

C $w_1 x_1^2 = w_2 x_2^2$, hai đường thẳng qua gốc

D $x_1^2 + x_2^2 = 1$, luôn là đường tròn

PHỎNG THEO CMU 10-601 · Exam 2 Practice · Q2.5(a)

Chốt ý

Feature tốt vừa có nghĩa vừa có sẵn đúng lúc dự đoán.

Lag, rolling luôn `shift(1)` trước; thống kê dùng nhãn tính out-of-fold; so từng nhóm feature trên cùng fold.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook: bỏ `shift(1)`, xem validation đẹp lên bao nhiêu, rồi giải thích vì sao đó là rò rỉ.