# Feature engineering

Tạo đặc trưng số, phân loại, chu kỳ và lịch sử theo đúng thời điểm.

# Đặc trưng có sẵn lúc nào?

Dự đoán số đơn đầu giờ.

Giờ, cửa hàng và doanh số quá khứ đã biết.

Doanh số giờ đang dự đoán chưa biết.

Feature tốt phải vừa có nghĩa vừa có sẵn đúng thời điểm.

# 01

# Biểu diễn dữ liệu

# Số và danh mục

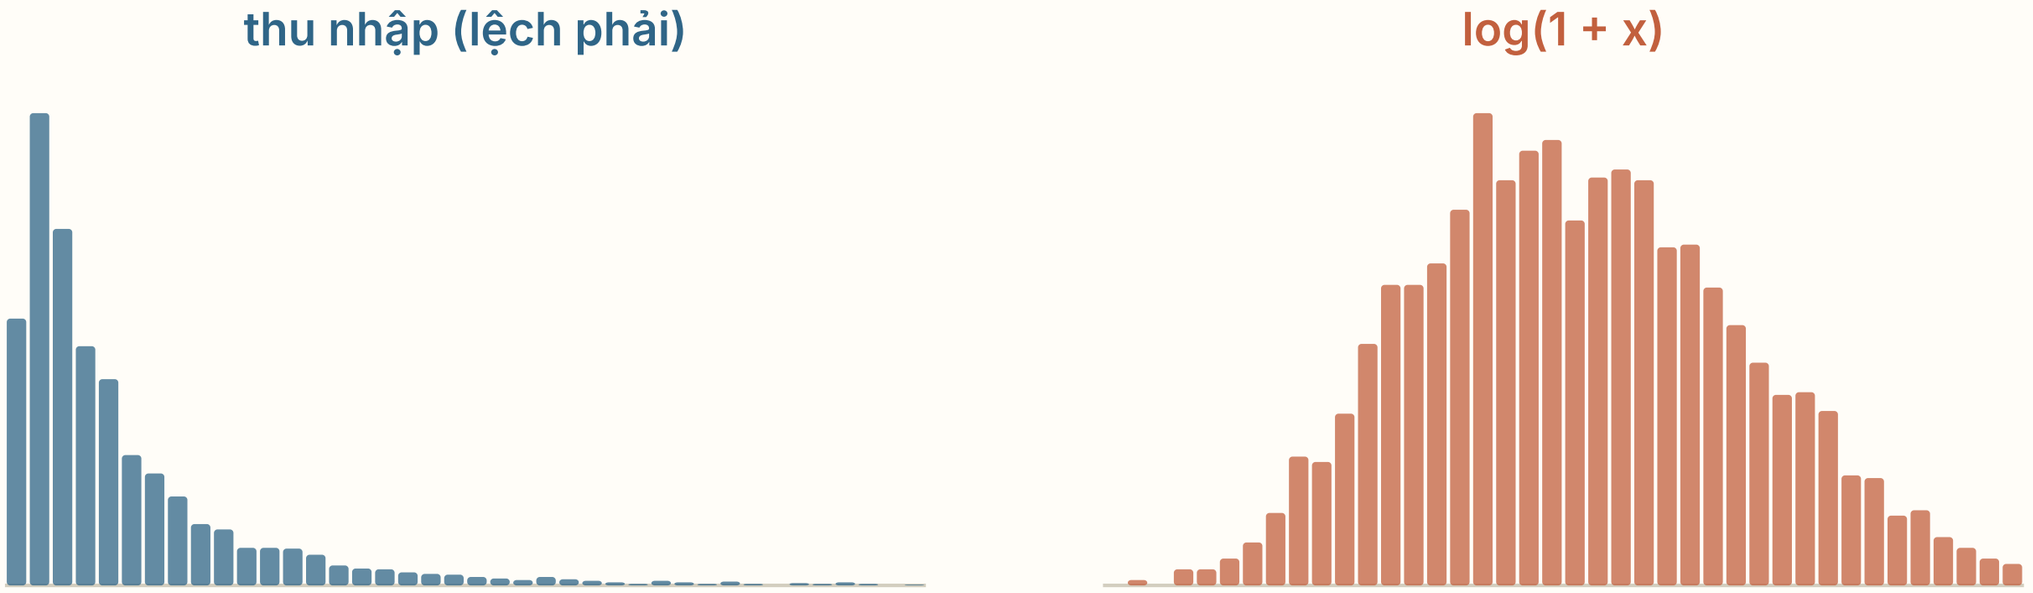
| Thao tác | Linear/kNN/SVM | Cây |
| --- | --- | --- |
| Scale | Thường cần | Không cần cho ngưỡng |
| Log biến lệch | Thường có ích | Gần như không đổi |
| One-hot | Danh mục không thứ tự | Tùy thư viện |
| Tương tác, tỉ số | Thường phải tạo | Học được một phần |

One-hot: category không có thứ tự.

Ordinal: chỉ khi thứ tự có ý nghĩa hoặc model xử lý rõ.

Không mã hóa mã cửa hàng thành 1, 2, 3 rồi để model hiểu đó là khoảng cách.

# Log cho biến lệch




Cùng 3000 giá trị thu nhập: phân phối gốc dồn sát 0 với đuôi dài; sau log(1 + x) gần cân đối, hợp với mô hình tuyến tính và kNN.

HỎI NHANH

## Áp $\log(1+x)$ cho cột thu nhập, rồi học lại một cây quyết định trên cùng dữ liệu. Chuyện gì xảy ra?

A Cây sâu hơn, vì phân phối cân đối hơn

B Cây chia train y hệt, chỉ có ngưỡng là đổi

C Cây tốt hơn hẳn, nhờ bớt lệch phải

D Phải chuẩn hóa lại thì cây mới chạy được

HỎI NHANH

## Cần dự đoán giá nhà trước khi bán. Cột `price/area` được tạo từ giá bán thực tế. Lúc dự đoán, `area` đã biết nhưng `price` thì chưa. Feature này có hợp lệ không?

A Có, vì chia cho diện tích đã loại ảnh hưởng của target

B Có, nếu chỉ fit scaler trên train

C Có, nếu dùng cây thay cho linear regression

D Không, vì phép tính cần chính target chưa biết

# Target encoding cần cross-fitting

$$TE(c) = \frac{n_c \bar{y}_c + m\bar{y}}{n_c + m}$$

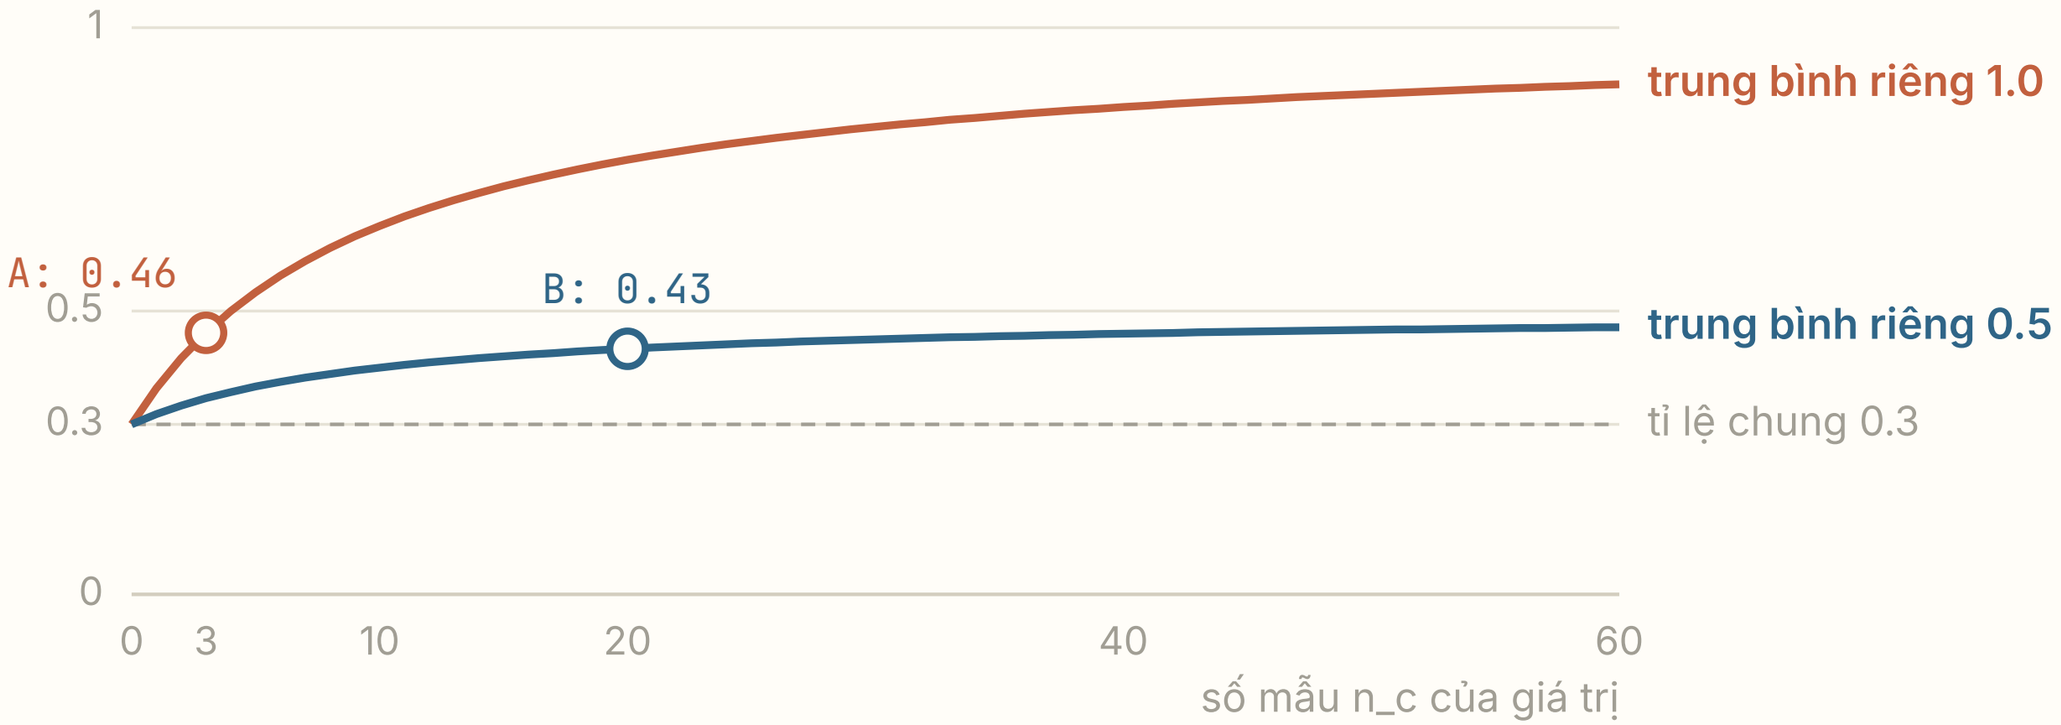
Giá trị feature của mẫu không dùng y của chính mẫu đó; outer CV phải bao cả encoder.

Ví dụ $n_c = 3$, $\bar{y}_c = 1$, $m = 10$, $\bar{y} = 0.3$:

$$TE(c) = \frac{3 \cdot 1 + 10 \cdot 0.3}{13} \approx 0.46,$$

không phải 1.0. Làm mượt giúp nhóm hiếm không quyết định cả mô hình.

# Làm mượt theo số mẫu




Target encoding làm mượt với m = 10: giá trị ít mẫu bị kéo về tỉ lệ chung 0.3, nhiều mẫu thì tiến dần về trung bình riêng.

HỎI NHANH

Vẫn $m = 10$ và tỉ lệ chung là 0.3. Quận B có 20 mẫu, một nửa mang nhãn 1. Giá trị mã hóa của B bằng bao nhiêu?

A khoảng 0.43

B 0.50

C 0.30

D khoảng 0.40

HỎI NHANH

## Khách bỏ trống ô thu nhập có tỉ lệ vỡ nợ 40%, khách điền đầy đủ chỉ 10%. Ta điền median vào ô trống và không thêm cột nào khác. Hệ quả chính là gì?

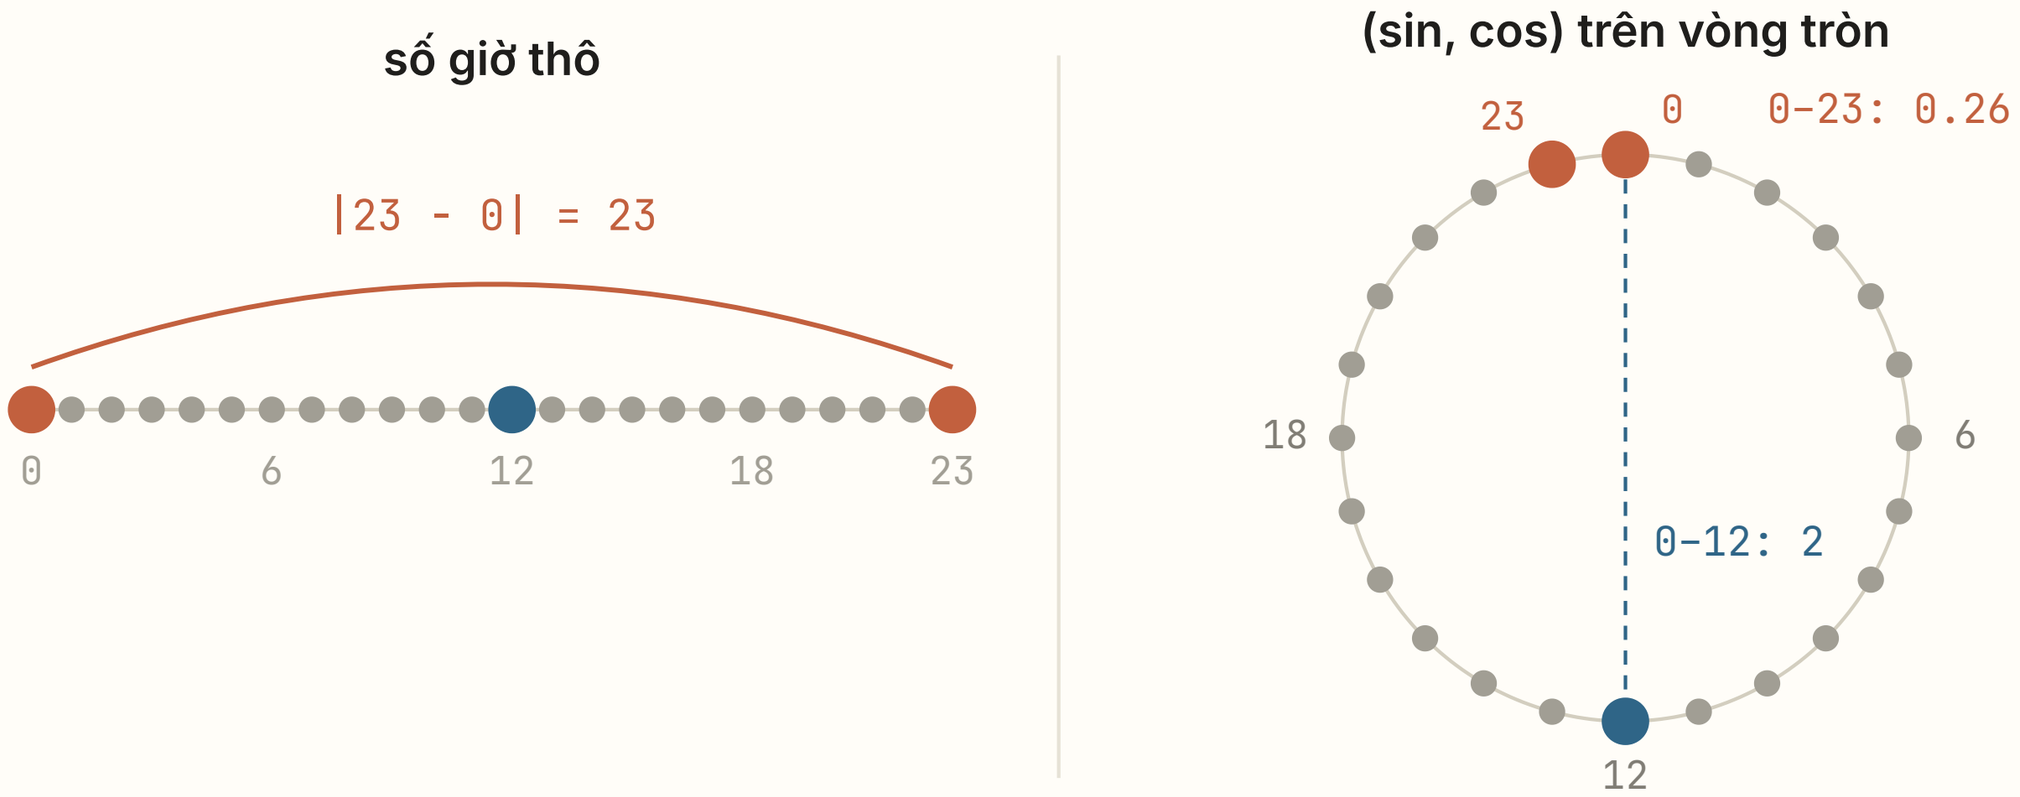
A Mô hình mất đi tín hiệu “bỏ trống”, một tín hiệu rất mạnh

B Không sao, vì median giữ nguyên phân phối

C Tốt hơn, vì dữ liệu không còn giá trị NaN

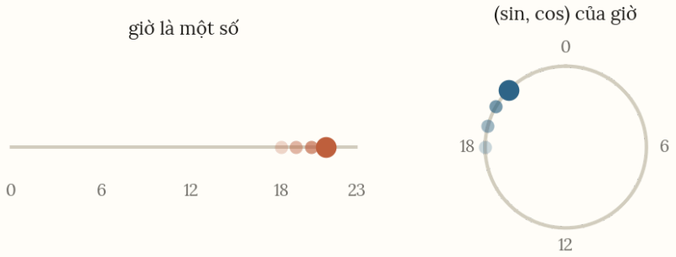
D Mô hình báo lỗi, vì cột đã đổi kiểu dữ liệu

# Thời gian có chu kỳ

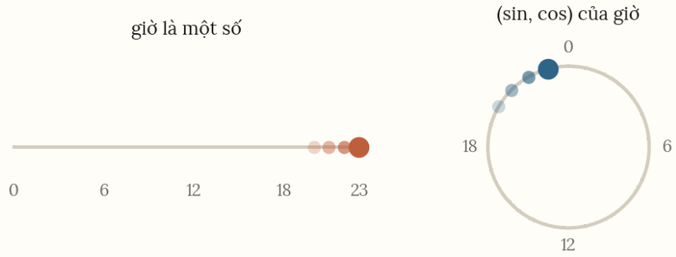



Số giờ thô đặt 23 giờ xa 0 giờ nhất; mã hóa (sin, cos) đặt chúng cạnh nhau trên vòng tròn.

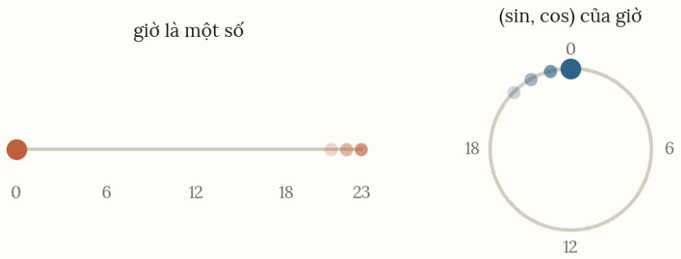
# Giờ đi qua nửa đêm



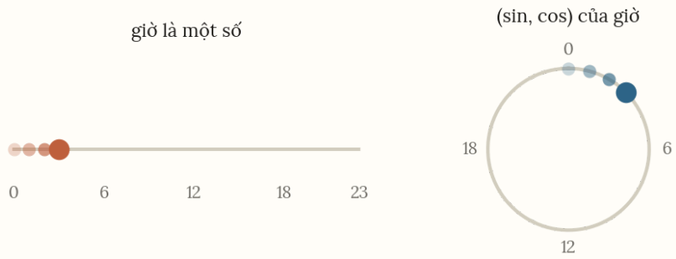

21 giờ: sin −0.71, cos +0.71




23 giờ: sin −0.26, cos +0.97




0 giờ: sin +0.00, cos +1.00 · trên trục số nhảy từ 23 về 0, trên vòng tròn chỉ đi một bước




3 giờ: sin +0.71, cos +0.71

Giờ trong ngày chạy từ 18 giờ qua nửa đêm: trên trục số 23 và 0 cách nhau xa nhất; mã hóa (sin, cos) đặt chúng cạnh nhau trên vòng tròn.

# Tọa độ của chu kỳ 24 giờ

$$x_{\sin} = \sin\frac{2\pi t}{24}, \qquad x_{\cos} = \cos\frac{2\pi t}{24}.$$

23 giờ và 0 giờ cách nhau khoảng 0.26 trên đường tròn; 12 giờ và 0 giờ cách nhau 2. Hai tọa độ giữ quan hệ cuối ngày và đầu ngày.

HỎI NHANH

Sau khi mã hóa giờ bằng sin và cos với $T = 24$, khoảng cách Euclid giữa 22 giờ và 2 giờ bằng bao nhiêu?

A $20$

B $1$

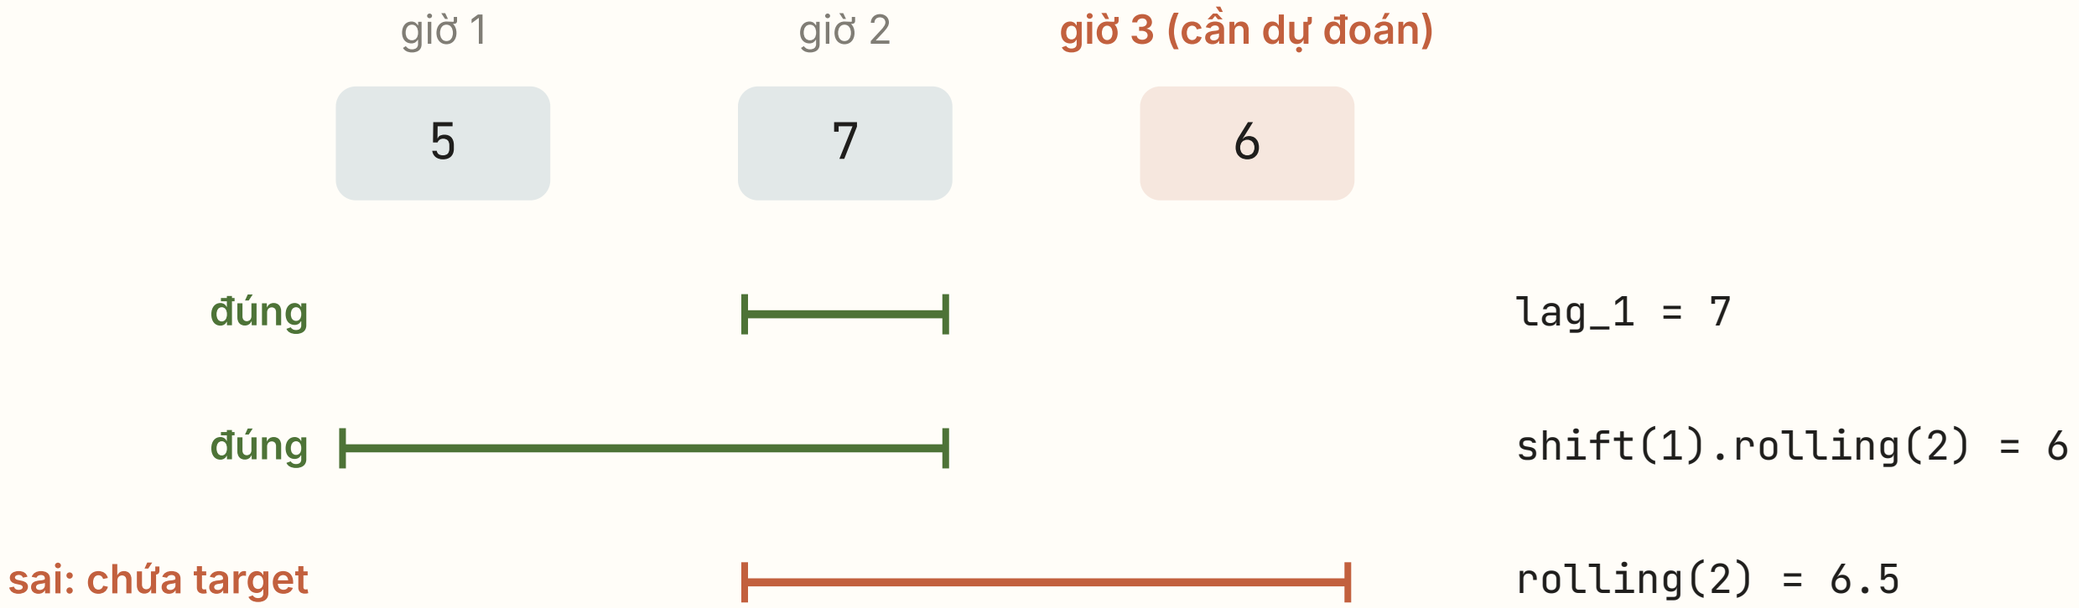
C $4$

D khoảng $0.26$

02

# Thông tin từ quá khứ

# Cửa sổ nào được phép?




Dự đoán giờ 3 của cửa hàng A: lag và rolling sau shift(1) chỉ dùng giờ 1–2; rolling thẳng ôm luôn doanh số giờ 3 cần dự đoán.

Mọi feature ở bên trái vạch phải có sẵn trước thời điểm dự đoán; target ở bên phải chưa được dùng.

HỎI NHANH

# Dùng sai phân $y_t - y_{t-1}$ làm feature để dự đoán $y_t$. Có hợp lệ không?

A Có, vì sai phân đo xu hướng gần nhất

B Có, nếu $y_{t-1}$ đã được lấy bằng `shift(1)`

C Không, vì nó chứa chính $y_t$

D Không, vì sai phân chỉ thêm nhiễu

HỎI NHANH

## Thêm cột `shop_mean = groupby("shop")["sales"].transform("mean")`, tính trên toàn bảng train theo giờ, rồi dùng nó để dự đoán `sales`. Có vấn đề gì?

A Không sao, đây chỉ là thống kê theo nhóm

B Cột này trùng thông tin với one-hot của shop

C `transform` làm xáo trộn thứ tự các hàng

D Mỗi hàng chứa cả sales của chính nó lẫn sales tương lai

# Một hàng cụ thể

Dự đoán giờ 3 của A; hai giờ trước có 5, 7.

`lag_1=7`, `mean_prev_2=(5+7)/2=6`.

Shift trước rolling, sort thời gian trong nhóm.

NaN đầu chuỗi là thiếu lịch sử thật, không tự điền bằng tương lai.

HỎI NHANH

## Quên `shift(1)`, viết thẳng `rolling(2).mean()` trên doanh số 5, 7, 6 của cửa hàng A. Giá trị ở giờ 3 bằng bao nhiêu?

A 6, giống hệt bản có shift

B 7, giá trị gần nhất trước đó

C 6.5, có chứa luôn target của giờ 3

D NaN, vì chưa đủ lịch sử

# Đối chiếu trên máy

Cửa hàng A bán 5, 7, 6 và B bán 3, 4 qua các giờ, như ví dụ trên.

```
def previous_mean(s):
    return s.shift(1).rolling(2).mean()

by_shop = history.groupby("shop")["sales"]
history["lag_1"] = by_shop.shift(1)
history["mean_prev_2"] = by_shop.transform(
    previous_mean
)
print(history["mean_prev_2"].tolist())
```

KẾT QUẢ

```
[nan, nan, 6.0, nan, nan]
```

`history` đã sort theo shop và time. A có sales 5,7,6; B có 3,4. Chỉ hàng thứ ba của A có đủ hai giá trị trước để lấy mean 6.

HỎI NHANH

## Hàng 4, thuộc cửa hàng B, có `lag_1 = 3` nhưng `roll_mean_2` lại là NaN. Vì sao?

A `shift` làm mất dữ liệu của B

B Trước đó B mới có một giờ bán

C Rolling tính chung cả A và B

D Do `round(2)` khi in kết quả

# Category mới

Fit OneHotEncoder trên A/B.

Test có C: `handle_unknown="ignore"`.

KẾT QUẢ

```
shape: (3, 3) (1, 3)
mẫu mới: [[0.0, 0.0, 0.0]]
```

Hai cột A/B bằng 0: schema chạy được, nhưng model chưa hiểu C.

Cột `size=20` bằng mean train sau impute nên cũng bằng 0.

Không fit lại encoder trên test.

HỎI NHANH

## Trong code trên, nếu lỡ gọi `preprocessor.fit_transform(new_features)` thay vì `transform`, đầu ra có shape gì?

A `(1, 3)`, như cũ

B `(1, 4)`

C `(1, 2)`

D Báo lỗi, vì C chưa từng xuất hiện

# 03

# Kiểm giả thuyết

# So sánh có kiểm soát

Giữ nguyên fold và metric.

Thêm hoặc bỏ một nhóm đặc trưng.

Ghi điểm từng fold, chi phí và giả thuyết.

Đổi feature lẫn split cùng lúc không tách được nguyên nhân.

Feature importance chỉ gợi ý; ablation trên cùng fold mới kiểm được đóng góp.

HỎI NHANH

Mô hình đầy đủ có MAE 2.0 trên các fold cố định. Bỏ nhóm lag thì MAE là 2.9, bỏ nhóm thời gian là 2.02, bỏ nhóm thống kê cửa hàng là 2.3. Nhóm nào đóng góp nhiều nhất?

A Nhóm lag

B Nhóm thời gian

C Nhóm thống kê cửa hàng

D Chưa biết khi chưa xem feature importance

HỎI NHANH

## Với mô hình cây, cột `order_id` đứng đầu bảng feature importance. Phản ứng hợp lý nhất là gì?

A Giữ lại, vì importance cao là feature tốt

B Nghi ngờ, vì mã có thể tăng dần theo thời gian

C Chuẩn hóa `order_id` rồi học lại

D One-hot `order_id` cho mô hình hiểu rõ hơn

HỎI NHANH

## Đếm tần suất của mã sản phẩm trên train và test gộp lại, không dùng nhãn. Cách này hợp lệ khi nào?

A Luôn hợp lệ, vì không đụng tới nhãn

B Không bao giờ, vì đã nhìn vào dữ liệu test

C Chỉ khi mô hình phía sau là cây

D Khi lúc dự đoán thật cũng có sẵn cả lô ấy

HỎI NHANH

## Với `TargetEncoder` của scikit-learn, `enc.fit(X, y).transform(X)` khác `enc.fit_transform(X, y)` ở đâu?

A Không khác, chỉ là cách viết gọn hơn

B Chỉ `transform` có bước làm mượt

C Chỉ `fit_transform` dùng cross-fitting

D `fit_transform` không dùng đến nhãn

# Bẫy cần nhớ

“Giá nhà chia diện tích” chỉ hợp lệ khi giá đó đã có lúc dự đoán. Nếu target là giá nhà, feature chứa trực tiếp target.

`shift(1)` trước rolling, fit encoder trên train và kiểm category mới theo schema; không dùng tương lai để lấp NaN đầu chuỗi.

# Khi đi thi

- Đọc mô tả dữ liệu như đọc đề: mỗi cột sinh ra lúc nào.
- Ưu tiên tỉ số, thống kê nhóm, thời gian cho gradient boosting.
- Target encoding và thống kê dùng nhãn: luôn out-of-fold.
- Soi cột ID, cột thời gian; mỗi lần đổi một thứ, cùng fold.

04

# Luyện đề

LUYỆN ĐỀ 1

# Dự đoán số khách của một buổi hòa nhạc. Một feature là “số khách của buổi trước, nếu biết”. Nên mã hóa thế nào?

A One-hot cho từng giá trị số khách

B Giữ dạng số đã chuẩn hóa, điền 0 khi không biết

C Giữ dạng số đã chuẩn hóa, thêm một cột đánh dấu khi không biết

D Bỏ cột này, vì đôi khi bị thiếu

PHỎNG THEO MIT 6.036 · Final, Spring 2022 · Q5(a)

LUYỆN ĐỀ 2

Đầu vào $(x_1, x_2)$ được thay bằng vector feature $(1, x_1^2, x_2^2)$, rồi học logistic regression với tham số $(b, w_1, w_2)$. Ranh giới quyết định, nơi $P(Y = 1) = P(Y = 0)$, là tập nào?

A $b + w_1 x_1^2 + w_2 x_2^2 = 0$, chẳng hạn một ellipse

B $b + w_1 x_1 + w_2 x_2 = 0$, một đường thẳng

C $w_1 x_1^2 = w_2 x_2^2$, hai đường thẳng qua gốc

D $x_1^2 + x_2^2 = 1$, luôn là đường tròn

PHỎNG THEO CMU 10-601 · Exam 2 Practice · Q2.5(a)

# Chốt ba điều

Tạo đặc trưng số, phân loại, chu kỳ và lịch sử từ thông tin đúng thời điểm.

Đọc shape/output của lag, rolling, target encoding và OneHotEncoder.

So nhóm đặc trưng bằng cùng fold; tránh target leakage và time leakage.

# Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook từ đầu; đổi thời điểm dự đoán hoặc category mới, dự đoán NaN/shape, rồi kiểm lại bằng output.