Optimizer

Gradient giống nhau, bước cập nhật khác nhau

Loss cứ lắc qua lại

Learning rate nhỏ: chiều thoải đi chậm.

Learning rate lớn: chiều dốc vượt đáy.

Optimizer biến gradient thành bước đi.

Ta kiểm trên $J = w_1^2 + 8w_2^2$ trước.

01

Các quy tắc cập nhật

SGD

$$w_{t+1} = w_t - \eta g_t.$$

g_t tính trên minibatch ngẫu nhiên: nhiễu, nhưng kỳ vọng bằng gradient đầy đủ.

$J = (w-3)^2$, $w = 2$, $g = -2$, $\eta = 0.1$ → w mới $= \mathbf{2.2}$.

HỎI NHANH

So gradient tính trên một minibatch (SGD) với gradient tính trên toàn bộ dữ liệu (GD). Câu nào đúng?

A Bước SGD nào cũng đưa tham số lại gần nghiệm tối ưu hơn

B Kỳ vọng của gradient SGD bằng gradient của GD

C Gradient của GD có phương sai lớn hơn gradient của SGD

D SGD và GD chỉ hội tụ khi hàm mục tiêu lồi chặt

PHỎNG THEO CMU 10-601 · Exam 2 Practice · Q1.3

Thung lũng hẹp

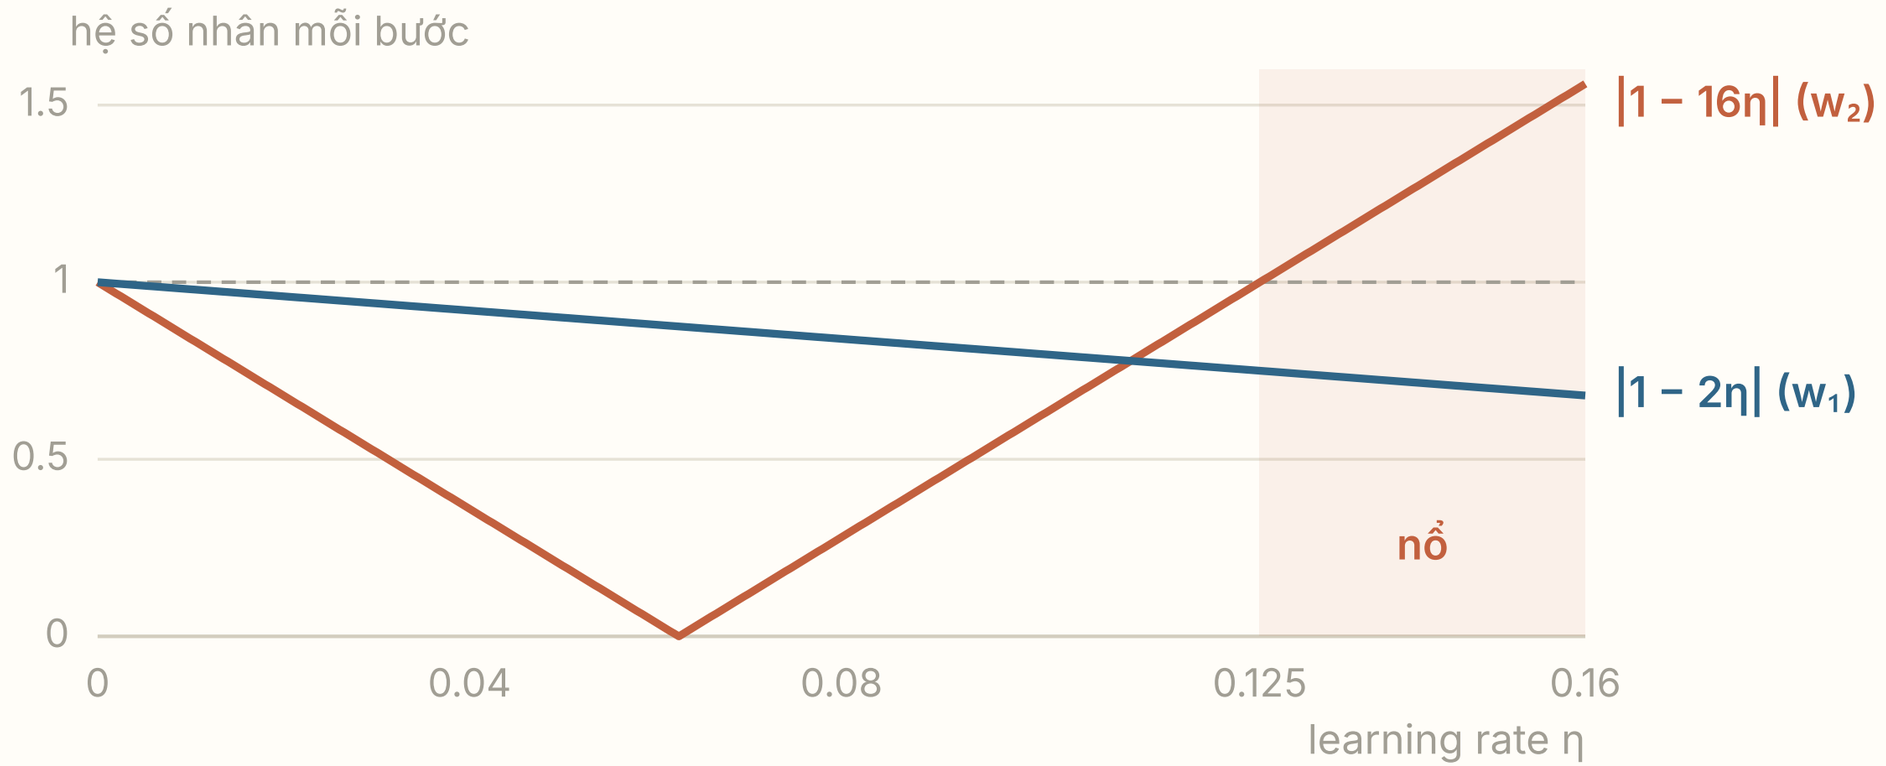
$$J = w_1^2 + 8w_2^2$$
$$w_1 \leftarrow (1 - 2\eta)\, w_1$$
$$w_2 \leftarrow (1 - 16\eta)\, w_2$$

Chiều dốc w_2 đặt ngưỡng: $|1 - 16\eta| < 1$, tức $\eta < 1/8$.

Chiều thoải w_1 đặt tốc độ: sát ngưỡng chỉ nhân 0.75 mỗi bước.

Tổng quát: $\eta < 2/\lambda_{\max}$.

Ngưỡng 1/8



SGD trên $J = w_1^2 + 8w_2^2$: mỗi bước nhân w_2 với $|1 - 16\eta|$ và w_1 với $|1 - 2\eta|$; η vượt 1/8 thì chiều w_2 nổ, còn ngay dưới ngưỡng chiều w_1 vẫn chỉ co 0.75.

HỎI NHANH

Đổi mặt loss thành $J = w_1^2 + 50w_2^2$. Learning rate của SGD phải dưới ngưỡng nào thì chiều w_2 không nổ?

A $\eta < 1$

B $\eta < 0.04$

C $\eta < 0.02$

D $\eta < 0.01$

Newton: chia theo độ cong

$$w \leftarrow w - H^{-1} \nabla J.$$

Trên hàm bậc hai này: tới đáy sau 1 bước.

$d = 10^4$ tham số → H có 10^8 phần tử.

Nghịch đảo: cỡ $d^3 = 10^{12}$ phép tính mỗi bước.

Bậc một: cỡ d mỗi bước → momentum, Adam.

Momentum nhớ hướng

$$v_t = \mu v_{t-1} + g_t.$$

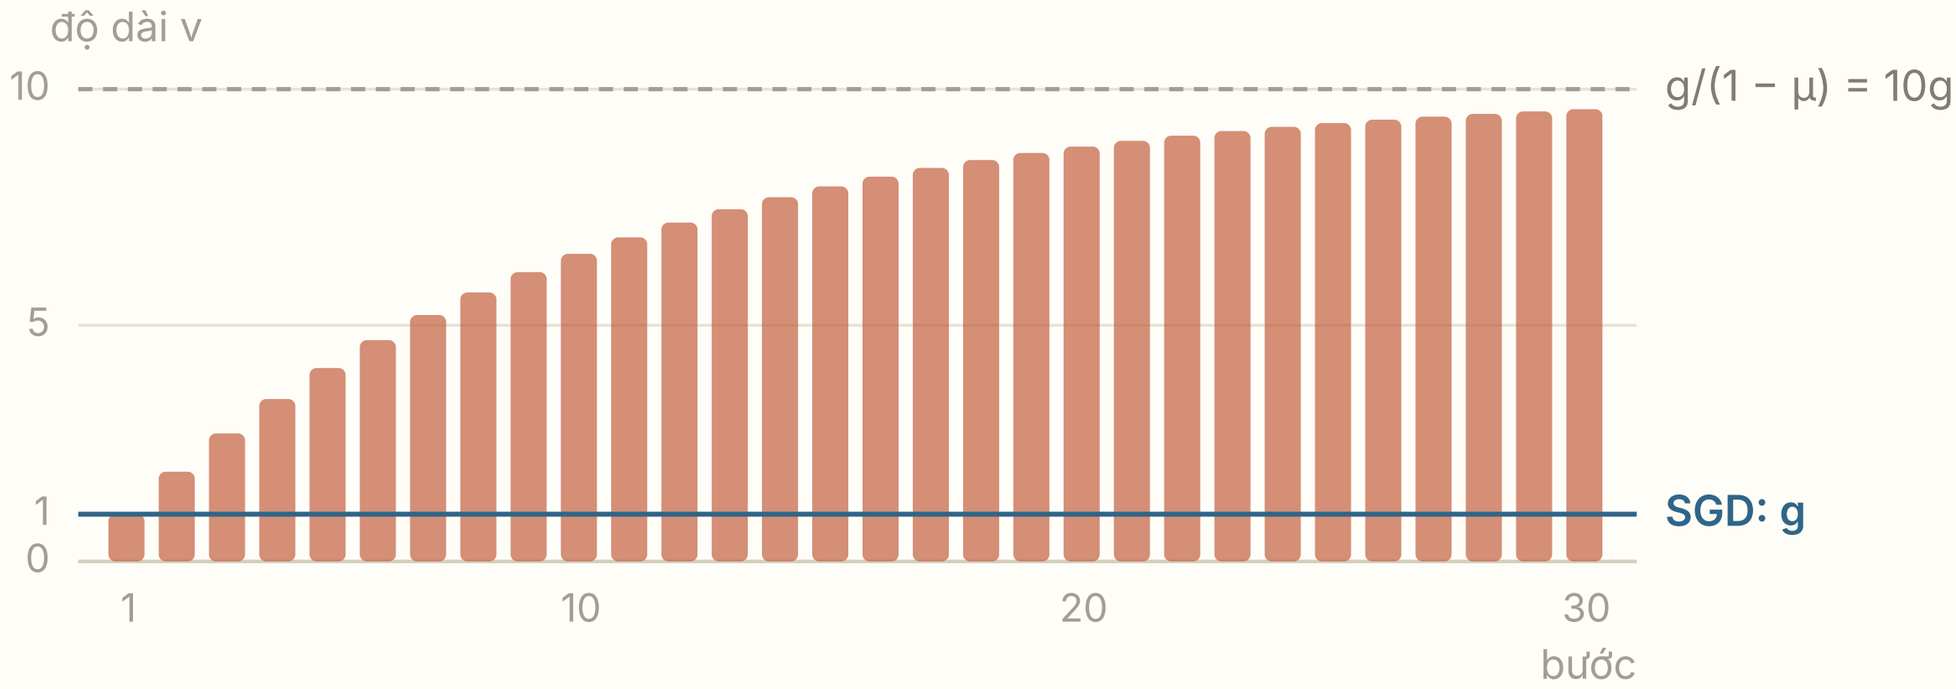
$$w_{t+1} = w_t - \eta v_t.$$

Cùng dấu: cộng dồn, bước dài dần.

Đổi dấu: triệt nhau, hãm dao động.

Sách khác thêm $(1-\mu)$: khác thang rate.

Gradient không đổi, v dài dần



Gradient không đổi g, μ = 0.9: v = g(1 + 0.9 + 0.9² + ...) tăng dần tới 10g, nên bước momentum về sau dài gấp 10 bước SGD.

HỎI NHANH

v cũ bằng 2, gradient mới bằng -1, $\mu = 0.9$. Theo quy ước $v \leftarrow \mu v + g$, v mới bằng bao nhiêu?

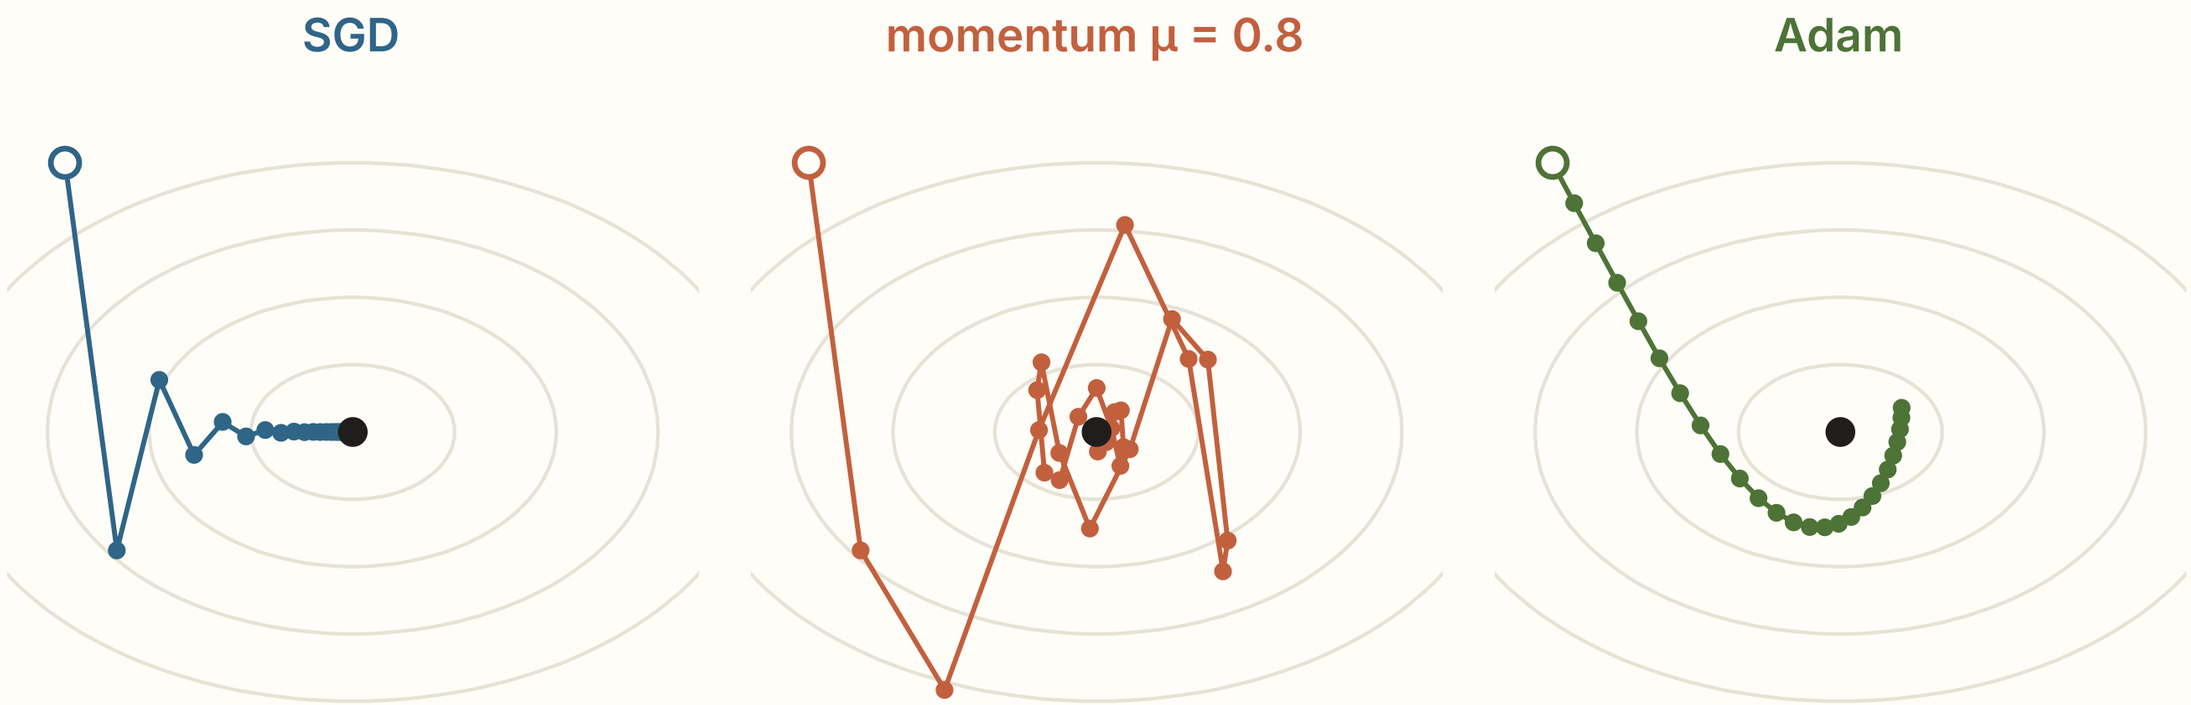
A -1

B -0.8

C 0.8

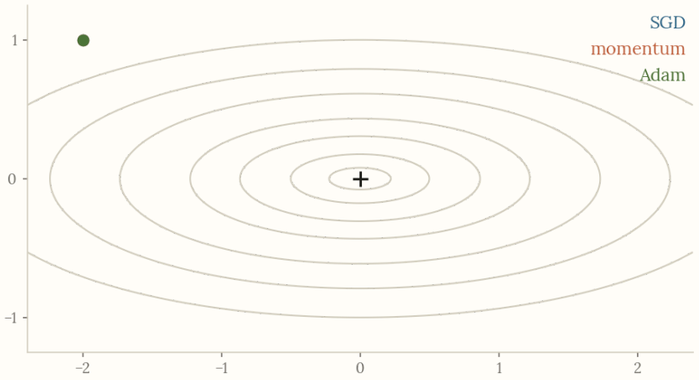
D 2.8

Ba đường trên cùng mặt loss

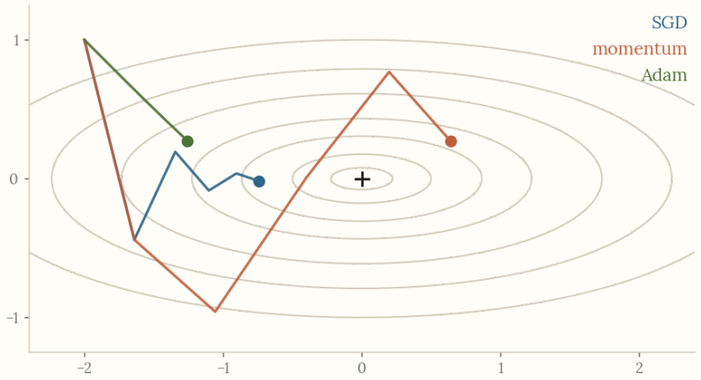


25 bước trên $J = w_1^2 + 8w_2^2$ từ $(-2, 1)$: SGD ($\eta = 0.09$) zigzag theo chiều dốc rồi về đáy; momentum vượt đáy rồi vòng lại; Adam ($\eta = 0.15$) đi gần chéo vì mỗi tọa độ bước cỡ η.

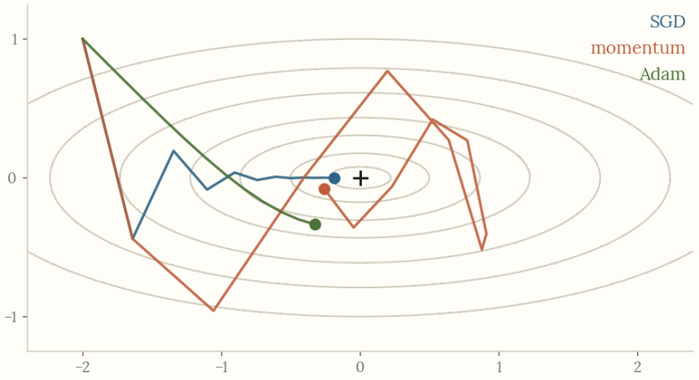
Ba optimizer chạy cùng lúc



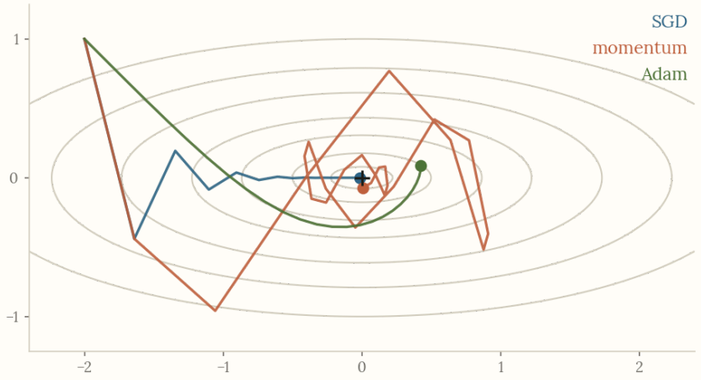
bước 0: J của SGD 12, momentum 12, Adam 12



bước 5: J của SGD 0.552, momentum 0.998, Adam 2.18



bước 12: J của SGD 0.0342, momentum 0.116, Adam 1.01



bước 25: J của SGD 0.000196, momentum 0.0424, Adam 0.246

Ba optimizer chạy cùng lúc trên $J = w_1^2 + 8w_2^2$ từ $(-2, 1)$, như hình trên: SGD ($\eta = 0.09$) zigzag, momentum ($\eta = 0.09$, $\mu = 0.8$) vượt đáy rồi vòng lại, Adam ($\eta = 0.15$) đi chéo.

HỎI NHANH

Gradient giữ nguyên bằng g qua rất nhiều bước, $\mu = 0.9$, quy ước $v \leftarrow \mu v + g$. Về sau, bước ηv dài gấp khoảng bao nhiêu lần bước SGD ηg?

A 0.9 lần

B 1.9 lần

C 9 lần

D 10 lần

Adam giữ hai thống kê

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t.$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2.$$

β_1, β_2 giữ ảnh hưởng của lịch sử. Ví dụ dùng 0.9 và 0.999, bắt đầu từ $m_0 = v_0 = 0$.

Bias correction bù khởi tạo 0:

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}.$$

$$\hat{v}_t = \frac{v_t}{1-\beta_2^t}.$$

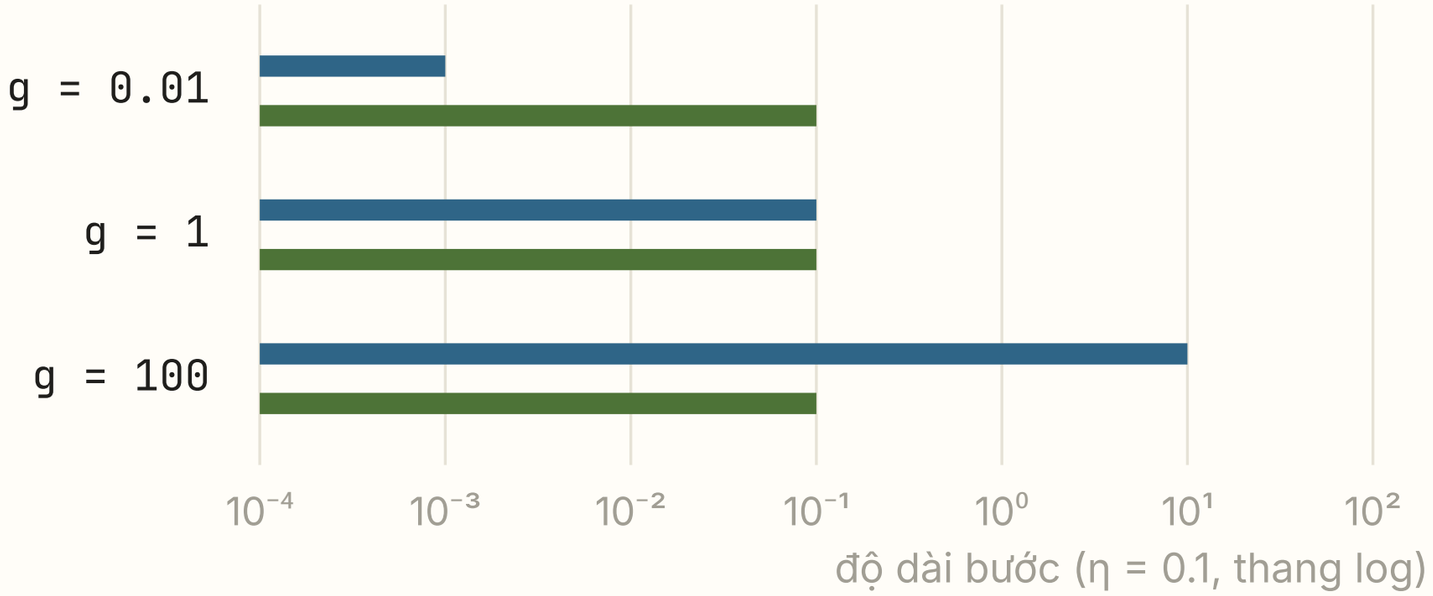
Bước Adam

$$w \leftarrow w - \eta \frac{\hat{m}}{\sqrt{\hat{v}} + \varepsilon}.$$

Gradient cố định g: bước $= \pm\eta$, dù g là 100 hay 0.01.

Gradient -2 ở bước đầu: $\hat{m} = -2$, $\hat{v} = 4$ → w từ 2 tới xấp xỉ $\mathbf{2.1}$.

Bước không phụ thuộc thang gradient



SGD: ηg

Adam bước đầu: ≈ η

Gradient 0.01, 1 hay 100: bước SGD tỉ lệ với g, còn bước đầu của Adam luôn dài cỡ η = 0.1 vì gradient đã được chia cho độ lớn của chính nó.

HỎI NHANH

Chạy Adam rất nhiều bước với $\beta_1 = 0.9$. Tọa độ A lúc nào cũng có gradient $+1$. Tọa độ B có gradient luân phiên $+1, -1, +1, \ldots$. So độ dài bước của B với A thế nào?

A Bằng nhau, vì $|g|$ ở hai tọa độ như nhau

B Dài hơn, vì $\hat{v}$ của B nhỏ hơn của A

C Bằng 0, vì các gradient triệt tiêu hết

D Ngắn hơn nhiều, vì $\hat{m}$ gần 0 trong khi $\hat{v}$ vẫn bằng 1

Tự tính rồi so thư viện

KẾT QUẢ

```
SGD: 2.2
Adam states: -0.2 0.004
Adam: 2.1
library match: True
```

Cùng gradient, khác cách chuẩn hóa bước.

Một bước đúng chưa chứng minh mọi loop đúng.

HỎI NHANH

Chạy tiếp ví dụ: sau bước đầu $w \approx 2.1$, gradient mới là $g_2 = 2(2.1 - 3) = -1.8$. Với $m_1 = -0.2$ và $\beta_1 = 0.9$, $\hat{m}_2$ bằng bao nhiêu?

A -3.6

B -1.89

C -1.8

D -0.36

02

So thực nghiệm và decay

Cùng 40 bước trên hàm bậc hai

Cấu hình	Loss đầu	Loss cuối
SGD 0.03	12	0.02833
Momentum 0.03	12	0.0005109
Adam 0.15	12	0.01883
SGD 0.2	12	1.981e+28

SGD 0.2 vượt ngưỡng $1/8$: w_2 nhân -2.2 mỗi bước.

Thứ hạng đổi theo ngân sách

KẾT QUẢ

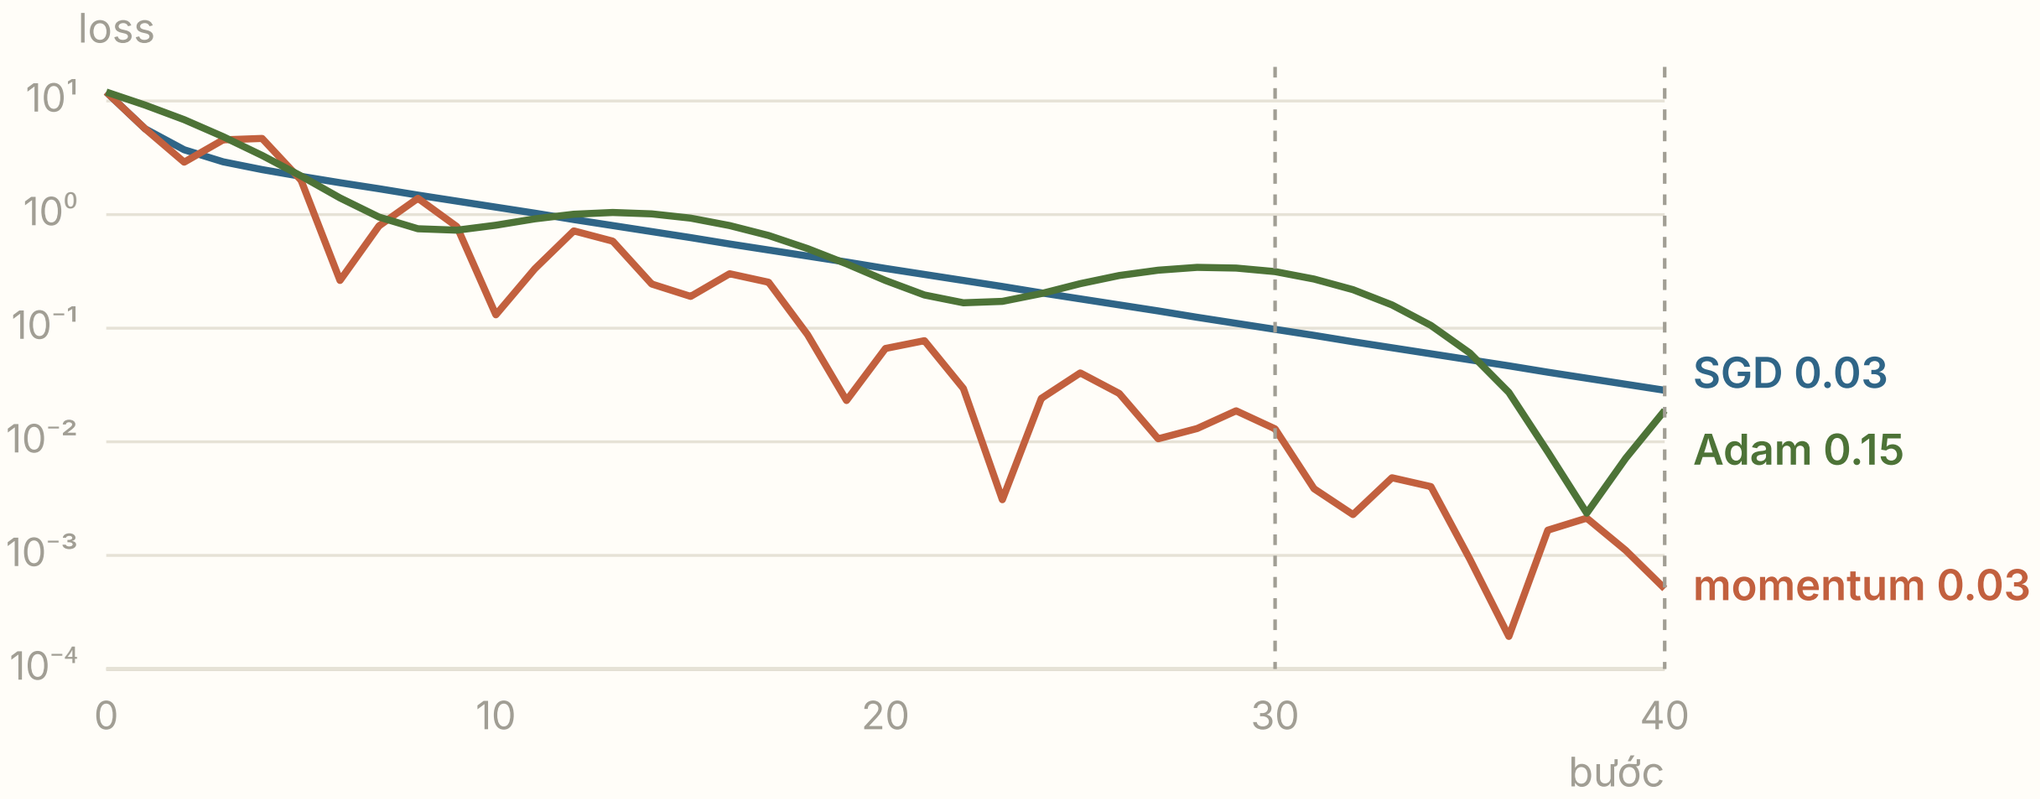
```
30 bước: SGD 0.0977 Adam 0.314
40 bước: SGD 0.0283 Adam 0.0188
```

SGD rate nhỏ đi xuống đều.

Adam, momentum vừa xuống vừa dao động.

Thứ hạng phụ thuộc lúc dừng.

Loss theo bước



Loss theo bước (thang log): SGD rate nhỏ đi xuống đều, Adam và momentum vừa xuống vừa dao động, nên thứ hạng ở bước 30 và bước 40 khác nhau.

HỎI NHANH

Một đội có 2 giờ GPU và cần chọn giữa SGD momentum và AdamW cho bài thi. So thế nào thì kết luận mới dùng được?

A Chạy cả hai với cùng learning rate 10^{-3}, chọn cái có train loss thấp hơn sau 2 giờ

B Dò learning rate riêng cho từng cái trên thang log, cùng ngân sách, rồi chấm trên validation

C Chạy mỗi cái vài trăm bước, chọn cái có loss giảm nhanh hơn ở đoạn đầu

D Chọn AdamW, vì nó tự điều chỉnh từng tọa độ nên luôn hội tụ nhanh hơn SGD

AdamW tách weight decay

$$w \leftarrow (1 - \eta\lambda)w.$$

$w = 2$, $\eta = 0.1$, $\lambda = 0.2$.

Gradient dữ liệu là tensor 0.

KẾT QUẢ

```
after decay: 1.96
```

AdamW vừa khởi tạo, moment bằng 0.

`Adam(weight_decay=λ)` của PyTorch: kiểu L2, λw đi qua $\sqrt{\hat{v}}$.

HỎI NHANH

Thay `AdamW` trong đoạn code trên bằng `torch.optim.Adam(..., weight_decay=.2)`, giữ nguyên mọi thứ khác: $w = 2$, learning rate 0.1, gradient bằng tensor 0, optimizer vừa tạo. Sau một bước, w bằng bao nhiêu?

A 2.0

B 1.96

C 1.9

D 1.6

03

Learning rate theo thời gian

Step, cosine, warmup

$$\eta_t = \eta_{\min} + \tfrac{1}{2}(\eta_{\max} - \eta_{\min})\big(1 + \cos\tfrac{\pi t}{T}\big).$$

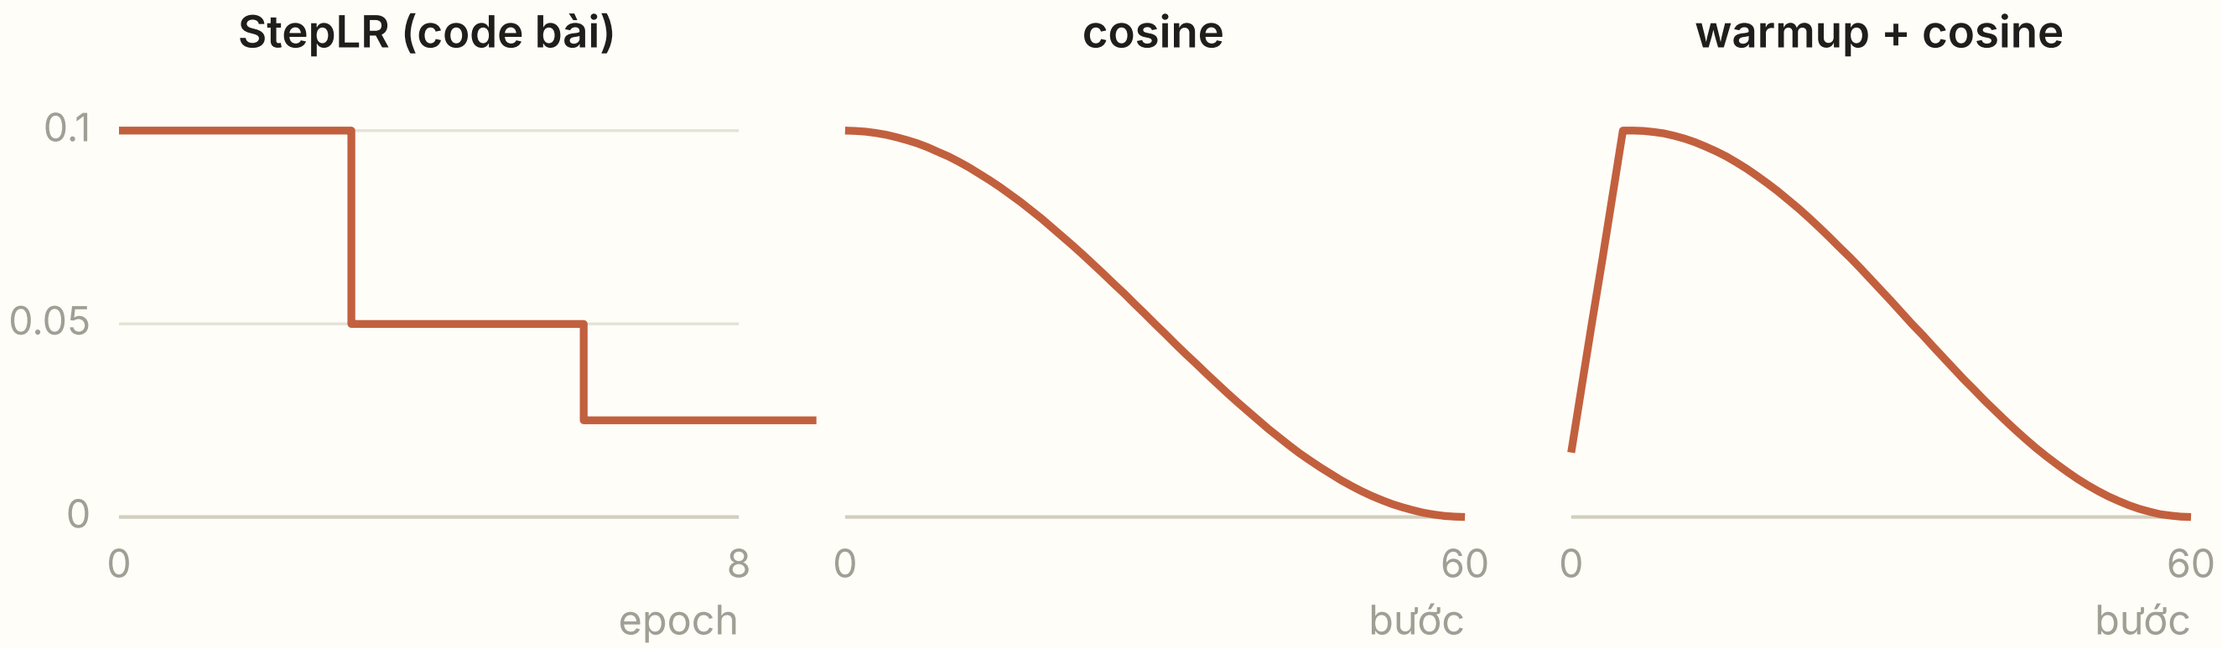
Giữa lịch: trung bình hai đầu.

Warmup: tăng từ gần 0, chờ $\hat{v}$ của Adam ổn định.

Về cuối: bước nhỏ để đi sâu vào đáy.

ReduceLROnPlateau: giảm khi metric ngừng tốt lên.

Ba lịch learning rate



Ba lịch learning rate: StepLR của bài nhân 0.5 sau mỗi 3 epoch; cosine giảm trơn về 0; warmup tăng tuyến tính vài bước đầu rồi mới giảm.

Đặt scheduler đúng chỗ

```
scheduler = torch.optim.lr_scheduler.StepLR(
    sgd, step_size=3, gamma=.5
)
# Sau khi hoàn tất các batch của một epoch:
scheduler.step()
```

`sgd.step()` chạy sau backward của mỗi batch; `scheduler.step()` ở trên chạy cuối mỗi epoch, sau các lần cập nhật.

3 epoch đầu: 0.1.

3 epoch sau: 0.05.

3 epoch tiếp: 0.025.

Theo step và theo epoch là hai lịch khác.

HỎI NHANH

StepLR được thiết kế để giảm learning rate sau mỗi 3 epoch, và mỗi epoch có nhiều batch. Gọi `scheduler.step()` ở đâu thì lịch chạy đúng thiết kế?

A Một lần sau các optimizer step của mỗi epoch

B Sau mỗi optimizer step của từng batch

C Trước `optimizer.step()` đầu tiên, để bỏ learning rate ban đầu

D Sau mỗi lần validation, truyền validation loss vào

Bẫy cài đặt

Quên `zero_grad`: gradient cộng dồn qua các bước.

Tạo optimizer mới mỗi epoch: mất m, v, số bước.

Thay lớp sau khi tạo optimizer: lớp mới không được cập nhật.

Chạy tiếp: nạp cả state optimizer và scheduler.

HỎI NHANH

Dòng `optimizer = torch.optim.Adam(model.parameters(), lr=1e-3)` bị đặt bên trong vòng lặp epoch, ngay trước vòng lặp batch. Model vẫn học, nhưng loss có gai nhọn ở đầu mỗi epoch. Vì sao?

A m, v và bộ đếm bước về 0, nên bước đầu mỗi epoch lại dài cỡ learning rate ở mọi tọa độ

B Tham số của model bị khởi tạo lại theo seed ở đầu mỗi epoch

C Hai optimizer cùng giữ một tham số nên learning rate bị nhân đôi

D DataLoader xáo lại dữ liệu nên batch đầu mỗi epoch luôn khó hơn

Khi đi thi

- Baseline: AdamW rate 10^{-3}; SGD momentum dò rate riêng.
- Dò rate trên thang log bằng lượt chạy ngắn; nan sớm: giảm rate hoặc warmup.
- Cosine, OneCycle: tính trước tổng số bước T.
- Loss đi ngang, dao động: giảm rate trước khi đổi kiến trúc.
- So trên validation, cùng ngân sách; checkpoint cả optimizer, scheduler.

04

Luyện đề

LUYỆN ĐỀ 1

Một bạn cài phương pháp Newton cho một mạng nhỏ 3 lớp có khoảng 10 nghìn tham số. Mô hình hội tụ tốt hơn, nhưng tổng thời gian chậm hơn Adam 100 lần, và profiler cho thấy 95% thời gian nằm ở một phép toán. Nhiều khả năng đó là phép nào?

A Forward qua toàn bộ mạng ở mỗi bước

B Backprop để tính gradient của loss theo tham số

C Đọc minibatch dữ liệu từ ổ đĩa vào bộ nhớ

D Nghịch đảo ma trận Hessian $10^4 \times 10^4$

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 85

LUYỆN ĐỀ 2

Warmup 1000 bước, sau đó cosine giảm từ 10^{-3} về 10^{-6}, tổng cộng 100000 bước. Learning rate ở bước 50000 khoảng bao nhiêu?

A khoảng 2.5×10^{-4}

B khoảng 5.0×10^{-4}

C khoảng 7.5×10^{-4}

D khoảng 10^{-3}

ĐỀ THI NOAI 2026 Singapore · Chung kết · Câu 10

LUYỆN ĐỀ 3

SGD với learning rate cố định 0.1 trong 200 epoch. Từ epoch 50, loss dao động quanh 0.45. Nên đổi lịch thế nào?

A Giảm 10 lần ở epoch 100, rồi thêm 10 lần ở epoch 150

B Dùng 0.01 ngay từ đầu

C Tăng dần từ 0.01 lên 0.1 trong 100 epoch đầu

D Giữ 0.1, tăng batch từ 128 lên 512

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 297

Chốt lựa chọn

SGD đi theo độ dốc · momentum nhớ hướng · Adam chỉnh thang.

Chiều cong nhất đặt ngưỡng rate; AdamW tách decay; scheduler đổi rate theo lịch.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; đổi rate SGD quanh ngưỡng $1/8$ và dự đoán trước đường loss.