Sử dụng model pretrained

Khóa đúng checkpoint, processor và phép kiểm đầu tiên

Kho ảnh câu lạc bộ

Ít ảnh có nhãn, muốn xếp nhóm để tìm lại.

Có model đã được công bố. Ta cần gì ngoài tên model?

CÂU HỎI XUYÊN SUỐT

Làm sao biết đã nạp đúng, đưa đúng input và giữ đúng thứ tự output?

Mục tiêu buổi này

- Phân biệt kiến trúc, trọng số, processor và nhãn.
- Nạp asset local, chạy batch và giữ đúng thứ tự ID.
- Tính phần bộ nhớ dành cho trọng số.
- Ghi revision, hash và kiểm lại asset offline.

01

Hợp đồng của một gói model

Kiến trúc khác checkpoint

`nn.Linear(2, 3)` tạo các phép toán và trọng số ban đầu.

Pretrained cần **trọng số đã học** từ nhiệm vụ trước.

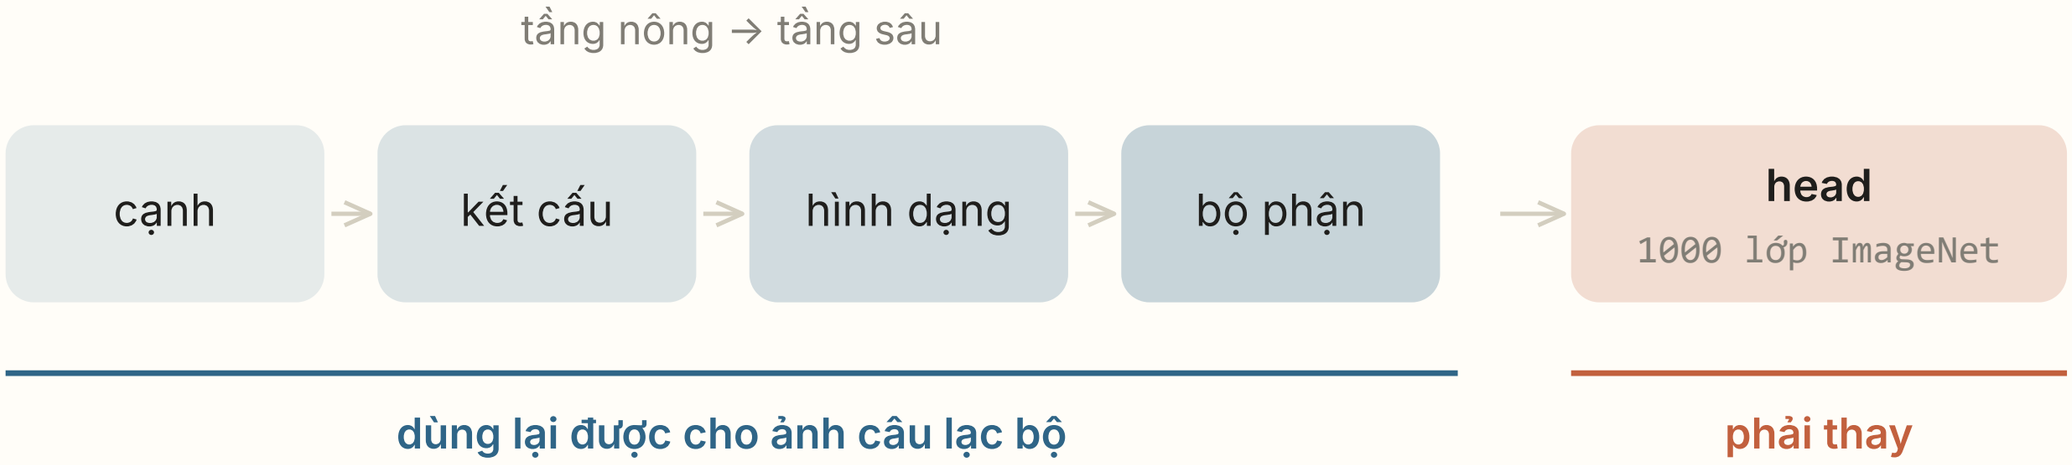
Processor quyết định input:

- Ảnh: resize, RGB, chuẩn hóa.
- Chữ: tokenizer, special token, padding.
- Head: nhãn và thứ tự lớp.

Vì sao trọng số cũ có ích?

- Phân biệt hơn một triệu ảnh của 1000 lớp buộc mạng học cạnh, kết cấu, hình dạng.
- Những đặc trưng ấy có trong mọi ảnh, kể cả ảnh câu lạc bộ.
- Chỉ **head** gắn chặt với 1000 lớp cũ.

Phần dùng lại, phần phải thay



Các tầng của mạng ImageNet học đặc trưng chung (cạnh, kết cấu, hình dạng, bộ phận) dùng lại được; chỉ head cuối gắn với 1000 lớp cũ.

HỎI NHANH

Có kiến trúc ResNet, và trọng số được khởi tạo ngẫu nhiên. Mô hình này đã là một model pretrained chưa?

A Rồi, vì tên kiến trúc trùng với model đã công bố

B Rồi, sau khi gọi `model.eval()` để suy luận

C Chưa, vì chưa nạp trọng số đã học

D Chưa, vì phải fine-tune trên dữ liệu mới trước

Shape trước khi chạy

Loại input	Shape
Ảnh	`(B, C, H, W)`
Token IDs	`(B, L)`
Logits phân loại	`(B, K)`

: batch · : lớp · : độ dài token.

Ảnh có kênh, chiều cao và chiều rộng .

ImageNet: chia 255, rồi chuẩn hóa mean/std từng kênh.

HỎI NHANH

Processor của checkpoint nhận pixel từ 0 đến 255, tự chia cho 255, rồi trừ mean và chia std. Code của đội lại đã chia cho 255 trước khi gọi processor. Chuyện gì xảy ra?

A Báo lỗi kiểu dữ liệu, vì input không còn là số nguyên

B Chạy bình thường, nhưng ảnh nào cũng gần như một màu

C Kết quả y hệt, vì chia hai lần vẫn giữ thứ tự các pixel

D Chỉ chậm hơn một chút, còn dự đoán không đổi

02

Kiểm bằng gói nhỏ

Một gói nhỏ, đủ các bước

Trọng số đặt tay để mọi số đều tính tay được.

```
model.load_state_dict(
    loaded["state_dict"], strict=True)
model.eval()
print("shape W:", tuple(model.weight.shape))
```

KẾT QUẢ

```
shape W: (3, 2)
```

- `strict=True`: kiểm tên và shape.
- `map_location="cpu"`: mở trên CPU.
- `weights_only=True`: chỉ mở tensor, số, chuỗi.
- Gói còn có mean, scale và nhãn.

HỎI NHANH

Checkpoint được lưu từ một model bọc trong `DataParallel`, nên các khóa là `module.weight` và `module.bias`, trong khi model mới chờ `weight` và `bias`. Đội gọi `load_state_dict(sd, strict=False)`. Kết quả là gì?

A PyTorch tự bỏ tiền tố `module.` rồi nạp đủ

B Báo lỗi ngay khi nạp, vì tên khóa không khớp

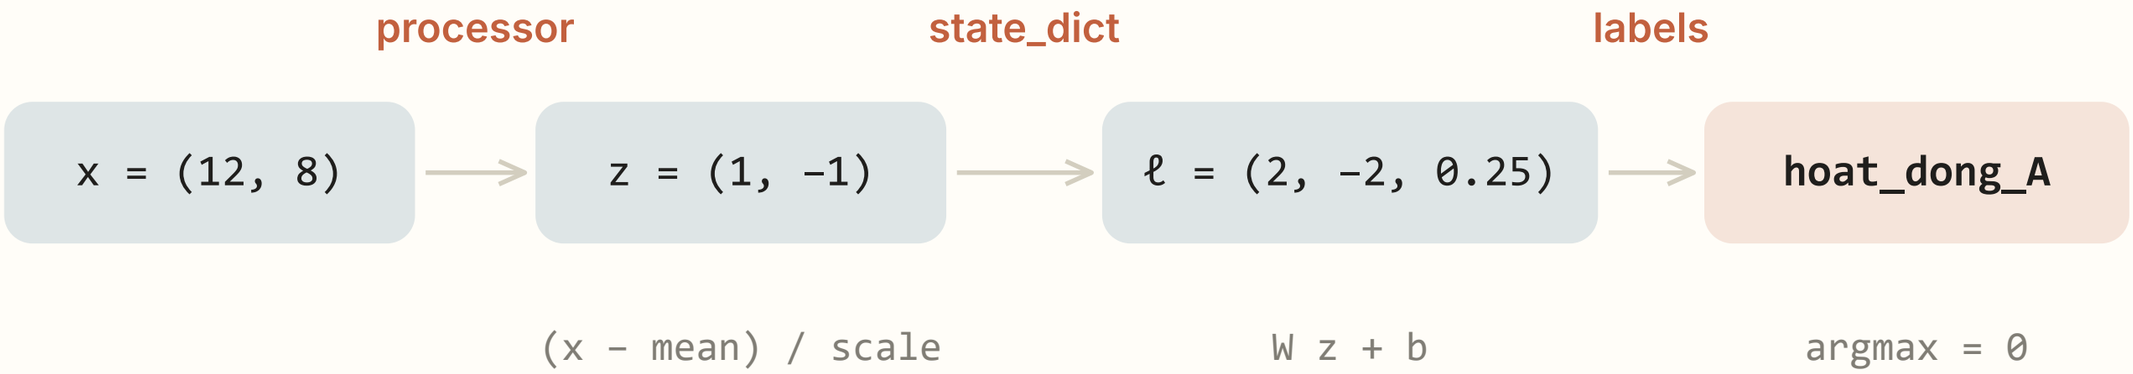
C Nạp được `bias`, còn `weight` vẫn ngẫu nhiên

D Không lỗi gì, nhưng model vẫn giữ trọng số khởi tạo

Một mẫu tính tay

Đây là logits của một mẫu. Lớp 0 thắng; argmax không cần softmax.

Ba phần của gói, ba bước



thiếu hay lệch một phần nào, chương trình vẫn chạy mà trả lời sai

Một mẫu đi qua ba phần của gói: processor đổi (12, 8) thành (1, −1), trọng số cho logits (2, −2, 0.25), bảng nhãn đổi chỉ số 0 thành tên.

Đọc logits

```
with torch.inference_mode():
    logits = model(process(raw))
    predicted = logits.argmax(dim=1)
print(logits.numpy().round(2))
```

KẾT QUẢ

```
[[ 2.   -2.    0.25]
 [-2.    2.    0.25]
 [ 0.    0.    0.25]
 [ 4.   -4.    0.25]
 [-1.    1.    0.25]]
```

Hàng thứ ba chỉ còn bias: input ở đúng trung bình.

HỎI NHANH

`logits` có shape `(5, 3)`. Muốn mỗi mẫu có một nhãn, ta dùng gì?

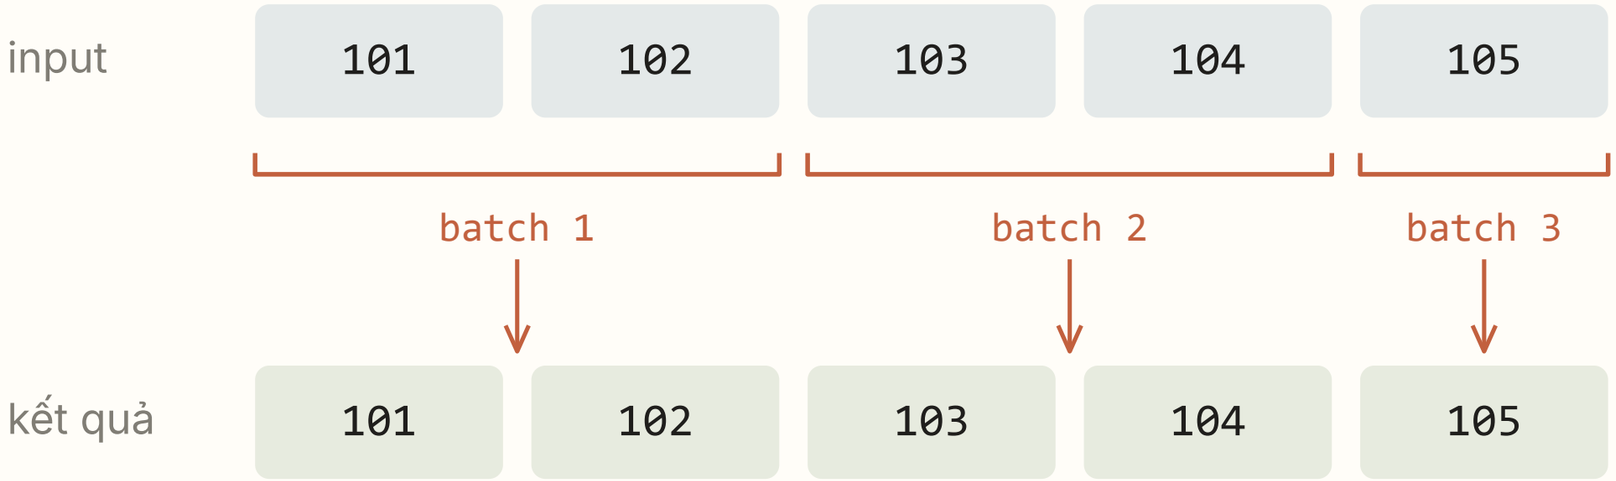
A `logits.argmax(dim=1)`

B `logits.argmax(dim=0)`

C `logits.argmax()`

D `logits.max(dim=1).values`

Batch cuối không được mất



batch 2, 2, 1 nối lại đúng thứ tự; giữ id theo từng hàng

Năm mẫu chia batch 2, 2, 1: batch cuối thiếu mẫu vẫn phải chạy, và kết quả nối lại theo đúng thứ tự id ban đầu.

Hai phép kiểm khác nhau

```
print("batch khop:",
      torch.allclose(batched, logits))
print("NumPy khop:",
      np.allclose(batched.numpy(), expected))
print("so mau:", len(batched))
```

KẾT QUẢ

```
batch khop: True
NumPy khop: True
so mau: 5
```

Phép so batch kiểm việc ghép hàng.

Phép so NumPy kiểm công thức bằng một đường tính độc lập.

ID phải đi cùng mỗi output.

`eval()` và `inference_mode()` kiểm hai việc khác nhau

`model.eval()`:

Dropout và BatchNorm chuyển cách hoạt động.

`torch.inference_mode()`:

Không theo dõi gradient cho suy luận.

Nó không tự gọi `eval()`.

BatchNorm cần `eval()`

- Train mode: chuẩn hóa bằng thống kê **của batch**, đầu ra của một ảnh phụ thuộc ảnh đi cùng.
- Eval mode: dùng running statistics trong checkpoint, chia batch kiểu gì cũng như nhau.

HỎI NHANH

CNN pretrained có BatchNorm. Đội quên gọi `eval()`, nhưng có `inference_mode()`. Chạy cùng tập test với batch 32 rồi với batch 8, hai file nộp khác nhau ở vài dòng. Vì sao?

A `inference_mode()` làm phép tính không còn tất định

B Ở chế độ train, BatchNorm dùng thống kê của từng batch

C Batch cuối thiếu mẫu nên các dòng bị lệch hàng

D Batch nhỏ làm trọng số được cập nhật nhiều lần hơn

HỎI NHANH

Model đã gọi `eval()`, nhưng vòng dự đoán không bọc trong `inference_mode()` hay `no_grad()`. Tham số vẫn có `requires_grad=True`, còn input thì không. Câu nào đúng?

A Không ghi graph, vì `eval()` đã tắt autograd

B Không ghi graph, vì input không cần gradient

C Vẫn ghi graph, nhưng chỉ khi chạy trên GPU

D Vẫn ghi graph, vì `eval()` không đụng tới autograd

03

Tài nguyên và asset

Tính phần bộ nhớ trọng số

là số tham số; là byte mỗi tham số: FP32 dùng 4, FP16 dùng 2.

Một MiB bằng byte.

Model 100 triệu tham số:

Precision	Trọng số thô
FP32	381.47 MiB
FP16	190.73 MiB

Chưa tính input, activation, buffer, optimizer.

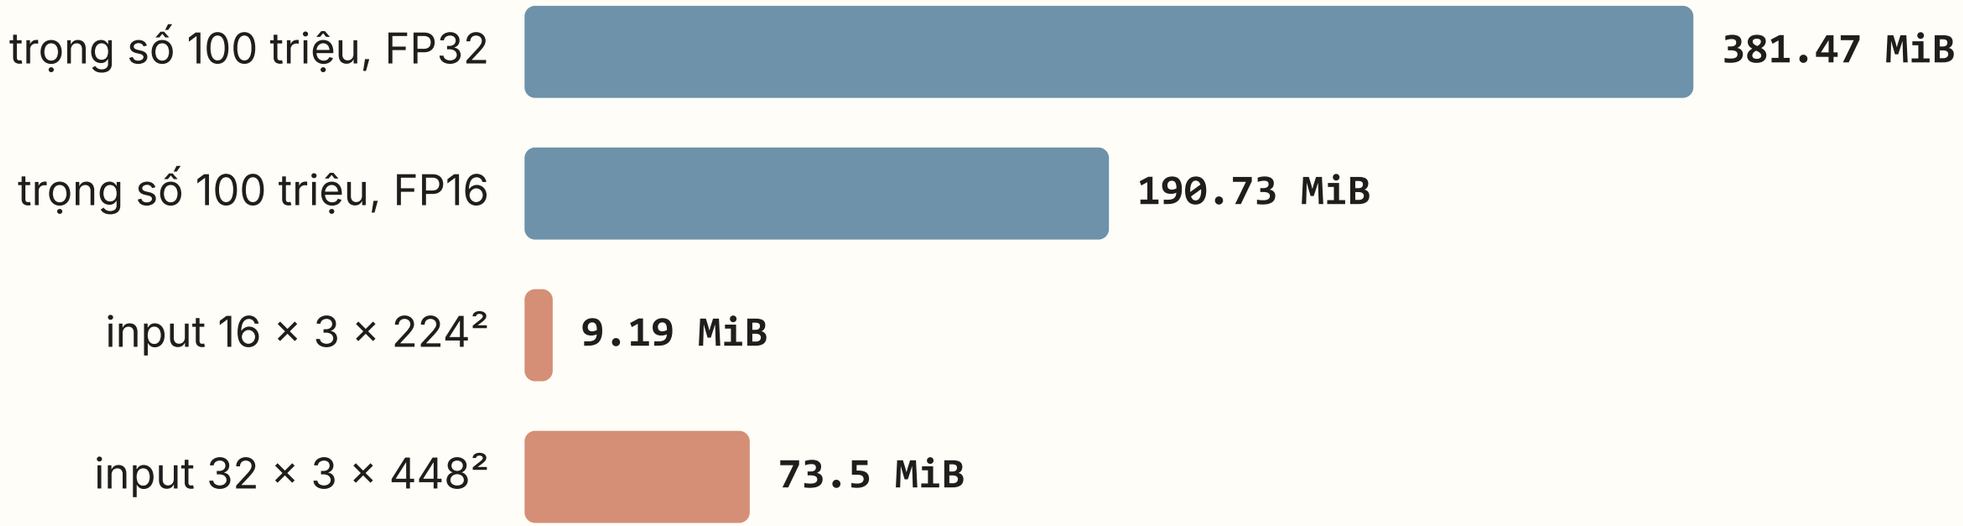
Input và activation theo

Batch 16 ảnh RGB , `float32`:

Gấp đôi cạnh ảnh tốn ngang gấp bốn batch.

Đo một batch nhỏ trên đúng thiết bị rồi tăng dần.

Trọng số và input



chưa tính activation, gradient, optimizer và bộ nhớ dự trữ

Bộ nhớ thô của trọng số và của tensor input: gấp đôi batch và gấp đôi cạnh ảnh làm input gấp 8, từ 9.19 lên 73.5 MiB.

HỎI NHANH

Một batch 16 ảnh RGB kiểu `float32` chiếm 9.19 MiB. Đổi sang batch 32 và ảnh thì tensor input chiếm bao nhiêu?

A 18.38 MiB

B 36.75 MiB

C 73.50 MiB

D 147.00 MiB

Đọc model card trước

- Học trên dữ liệu gì, input nào, nhãn nào, license nào.
- Head ImageNet chỉ chọn trong 1000 lớp cũ.
- Dùng lại các tầng dưới: 4.2 lấy đặc trưng, 4.3 học head mới.

HỎI NHANH

Đội đưa ảnh câu lạc bộ vào một ResNet học trên ImageNet, còn nguyên head, rồi lấy argmax trên 1000 logits. Kết quả là gì?

A Nhãn của câu lạc bộ, nếu ảnh đủ rõ và đúng cỡ

B Một lớp của ImageNet, không phải nhãn câu lạc bộ

C Báo lỗi shape, vì 1000 lớp không khớp ba nhãn mới

D Một nhãn ngẫu nhiên, vì model chưa thấy ảnh này

Dùng asset thật offline

Lượt có mạng:

- Đọc model card và license.
- Chốt revision commit.
- Ghi hash các tệp.

Lượt offline:

- Kiểm hash.
- Nạp model và processor local.
- `local_files_only=True`.
- Chạy dữ liệu nhỏ, ghi `RESULT.json`.

Hash khớp → bytes đúng; shape, ID khớp → đường dữ liệu đúng; rồi mới tới validation.

HỎI NHANH

Hai tuần sau, đội tải lại cùng model ID từ nhánh `main`, chạy năm ảnh kiểm ở chế độ eval, và thấy logits khác lần trước ngay từ chữ số đầu. Nên kiểm gì đầu tiên?

A Commit và SHA-256, so với `ASSET.json` cũ

B Seed của NumPy và PyTorch trong notebook

C Batch size, vì đổi batch là đổi logits

D Phiên bản CUDA, vì GPU khác cho số khác

Hai lỗi processor trên ảnh thật

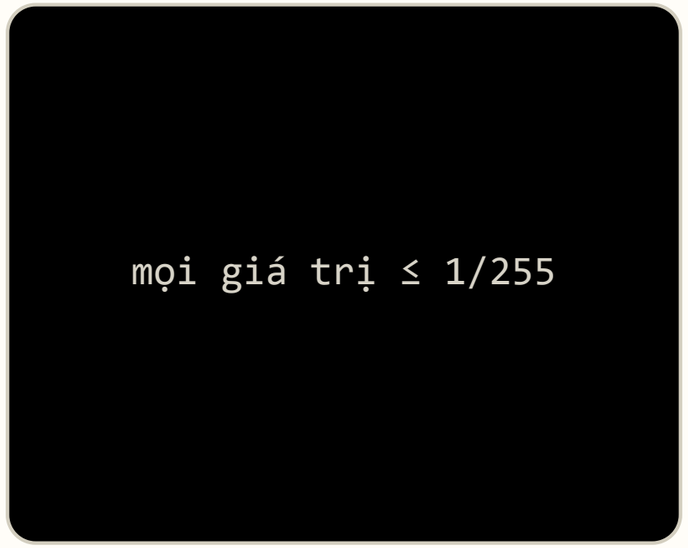
RGB đúng



đọc bằng cv2 (BGR)



chia 255 hai lần



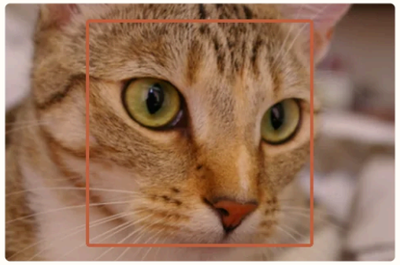
shape, dtype đều đúng: không có lỗi nào báo ra

Cùng một ảnh thật đưa vào processor RGB: đọc bằng cv2 thì đỏ và lam bị đảo; chia 255 trước khi processor chia lần nữa thì mọi pixel gần 0, mạng thấy gần như một màu.

Ảnh thật qua processor và model



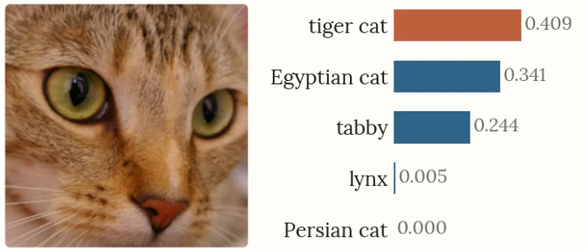
ảnh gốc 300 × 451 × 3, giá trị 0–255



cắt giữa một ô 224 × 224



chia 255, trừ mean, chia std từng kênh R, G, B: số nằm quanh 0



ResNet-18 trả 1000 xác suất; 5 lớp cao nhất cộng lại 1.000

Ảnh mèo thật qua đúng preprocessing của ResNet-18 ImageNet rồi qua model: ba lớp mèo đứng đầu, chia nhau gần hết xác suất.

Khi đi thi

- Đọc quy định asset, Internet, thư viện trước khi chuẩn bị.
- Thử nạp offline và tạo file nộp thử ngay đầu giờ.
- Khóa processor cùng checkpoint, giống hệt ở validation và test.
- Đo bộ nhớ bằng batch thật; giữ một cấu hình chạy chắc trên CPU.
- Giữ ID suốt đường suy luận; chọn model bằng validation của đề.

04

Luyện đề

LUYỆN ĐỀ 1

ResNet-50 nhận input `(B, 3, 224, 224)`. Phần đầu, gồm conv stride 2 rồi max-pool stride 2, đưa ảnh về . `layer1` giữ và cho ra 256 kênh. Khối đầu của `layer2` có conv stride 2 trên 128 kênh, rồi conv mở ra 512 kênh. Đầu ra của `layer2` có shape gì?

A `(B, 128, 28, 28)`

B `(B, 512, 28, 28)`

C `(B, 512, 56, 56)`

D `(B, 28, 28, 512)`

PHỎNG THEO USA-NA-AIO 2026 · Vòng 1 · Part 8.2

LUYỆN ĐỀ 2

Biểu thức nào đếm đúng số tham số học được của ResNet-50?

A
```
len(list(model.parameters()))
```

B
```
sum(t.numel() for t in
model.state_dict().values())
```

C
```
sum(p.numel() for p in
model.parameters())
```

D
```
sum(p.numel() * p.element_size()
for p in model.parameters())
```

PHỎNG THEO USA-NA-AIO 2026 · Vòng 1 · Part 8.1

LUYỆN ĐỀ 3

Trên Colab, đội lưu `torch.save(model, "m.pt")`, tức lưu cả đối tượng model. Máy chấm dùng PyTorch mới, và `torch.load("m.pt")` báo lỗi “Weights only load failed”. Lần sau nên lưu thế nào cho bền?

A Lưu `state_dict()` kèm config, rồi dựng model và nạp vào

B Gọi `model.save("m.pt")` như trong Keras

C Vẫn dùng `torch.save(model)`, và nạp với `weights_only=False`

D Chỉ lưu dự đoán trên validation thay cho model

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 134

Bốn điều phải khóa trước khi chạy

- Gói phải giữ trọng số, kiến trúc và hợp đồng input/output.
- Phép kiểm phải giữ ID và có một đường tính độc lập.
- Tài nguyên phải được đo trên batch và thiết bị thật.
- Asset thật phải có revision, hash và chạy được offline.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; đổi batch size và kiểm thứ tự output.

Đọc recipe; khi được phép, tải asset thật theo revision rồi nạp lại offline.