Zero-shot

Dự đoán nhãn mới bằng kiến thức đã học

Chưa có bộ ảnh đã gán nhãn

Muốn nhận “bàn”, “bảng”, “máy tính”.

Có model từng học ghép ảnh với mô tả.

CÂU HỎI

Có thể dùng tên lớp làm classifier? Điểm của model ngôn ngữ có đo đáp án đúng không?

Mục tiêu buổi này

- Phân biệt zero-shot, few-shot, fine-tuning.
- Dựng điểm CLIP đúng shape và chuẩn hóa.
- Tính tổng và mean log-probability, rồi suy ra perplexity.
- Phân biệt điểm model với chất lượng đã được đánh giá.

01

Ảnh và chữ chung không gian

Cặp đúng nằm trên đường chéo

	a photo of a pagoda	a photo of a flower	a handwritten 3
	**kéo lên**	đẩy xuống	đẩy xuống
	đẩy xuống	**kéo lên**	đẩy xuống
	đẩy xuống	đẩy xuống	**kéo lên**

mỗi hàng: ảnh chọn đúng caption · mỗi cột: caption chọn đúng ảnh

Một batch ba cặp ảnh–caption: pretraining kéo điểm của cặp đúng trên đường chéo lên và đẩy mọi ô khác xuống, theo cả hàng lẫn cột.

Contrastive pretraining

Image encoder và text encoder học chung.

Cặp phù hợp được khuyến khích có điểm cao hơn cặp không khớp.

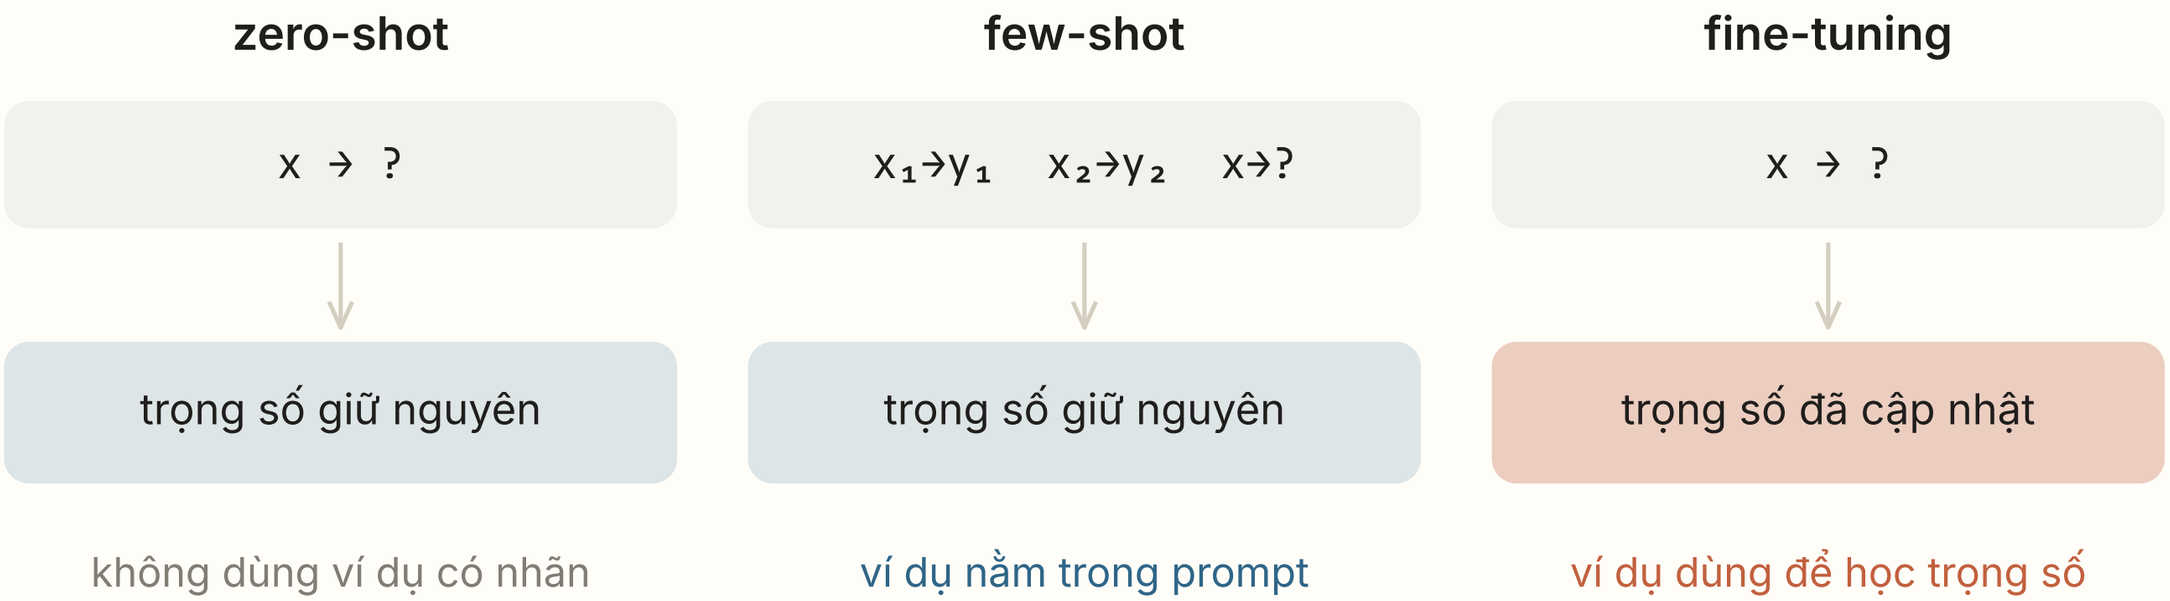
Hai encoder tùy ý cùng số chiều chưa có chung ý nghĩa.

Zero-shot: không dùng ví dụ có nhãn của nhiệm vụ mới.

Few-shot: vài ví dụ có nhãn trong prompt; trọng số giữ nguyên.

Fine-tuning: cập nhật trọng số bằng ví dụ có nhãn.

Ba cách dùng ví dụ có nhãn



Ba cách dùng ví dụ có nhãn của nhiệm vụ mới: zero-shot không dùng, few-shot đặt vài ví dụ vào prompt, fine-tuning dùng chúng để cập nhật trọng số.

HỎI NHANH

Một batch có hai ảnh mèo khác nhau, và cả hai đều đi với caption “a photo of a cat”. Trong contrastive loss, ô (ảnh mèo 1, caption của ảnh mèo 2) được xử lý thế nào?

A Được coi là cặp đúng thứ hai của ảnh mèo 1

B Bị bỏ khỏi loss, vì hai caption trùng nhau

C Vẫn là một cặp không khớp trong loss

D Không ảnh hưởng gì, vì loss chỉ đọc đường chéo

HỎI NHANH

Một đội lấy embedding ảnh 512 chiều từ một ResNet đã học trên ImageNet, và embedding 512 chiều của tên lớp từ một text encoder khác, chuẩn hóa cả hai, rồi gán nhãn bằng cosine. Cách làm này thế nào?

A Dùng được, vì cùng số chiều và đã chuẩn hóa

B Không có cơ sở, vì hai encoder chưa học chung một không gian

C Dùng được, nếu nhân thêm logit scale của CLIP

D Dùng được, nếu prompt mô tả đủ chi tiết

Tên lớp thành vector lớp

$$\ell_k = s\,\mathbf{u}^\top \mathbf{v}_k, \qquad \hat{y} = \arg\max_k \ell_k$$

Vector đã chuẩn hóa; $s > 0$ là logit scale, CLIP học sẵn.

$U : (B, D)$, $V : (K, D)$; vì vậy $UV^\top : (B, K)$.

HỎI NHANH

`U` có shape `(8, 512)`, `V` có shape `(3, 512)`. Điểm của tám ảnh với ba lớp có shape gì?

A `(8, 3)`

B `(3, 8)`

C `(8, 512)`

D `(512, 512)`

HỎI NHANH

Nhân mọi logits với một scale dương lớn hơn, giữ nguyên embedding và tập lớp. Thứ gì chắc chắn giữ nguyên?

A Mọi xác suất softmax

B Cross-entropy của mọi mẫu

C Khoảng cách giữa hai logit lớn nhất

D Chỉ số của logit lớn nhất

Hai lớp tính tay

Ảnh $(0.8, 0.6)$; lớp $(1, 0)$ và $(0, 1)$.

Cosine: 0.8, 0.6. Scale 5 cho logits 4, 3.

Softmax hai lớp cho lớp đầu **0.7311**.

Vector hai chiều tự đặt; CLIP có hàng trăm chiều.

Ba ảnh, ba lớp

KẾT QUẢ

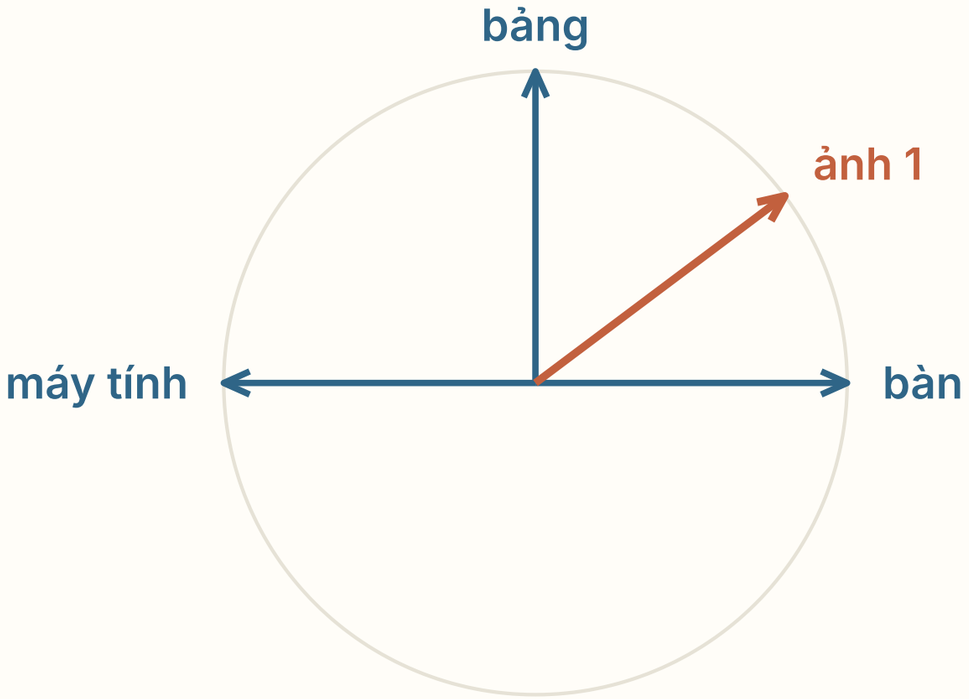
```
shape logits: (3, 3)
cosine: [[ 0.8  0.6 -0.8]
 [ 0.6  0.8 -0.6]
 [-1.   0.   1. ]]
nhan: ['ban', 'bang', 'may_tinh']
```

Hàng đầu softmax:

`[0.7309, 0.2689, 0.0002]`.

Mỗi ảnh nhận lớp có hướng gần nhất.

Ảnh 1 và ba vector lớp



	cosine	× 5	softmax
bàn	0.8	4	**0.7309**
bảng	0.6	3	0.2689
máy tính	-0.8	-4	0.0002

Ảnh 1 (0.8, 0.6) so với ba vector lớp dài 1 (số từ code bài): cosine 0.8, 0.6, −0.8; nhân scale 5 rồi softmax cho “bàn” 0.7309.

HỎI NHANH

Quên chuẩn hóa `texts`, và vector của lớp thứ hai là $(0, 3)$ thay vì $(0, 1)$. Ảnh $(0.8, 0.6)$ được gán vào lớp nào?

A Lớp thứ hai, vì tích vô hướng thành 1.8

B Lớp thứ hai, vì cosine thành 1.8

C Lớp đầu, vì cosine với lớp đầu vẫn là 0.8

D Lớp đầu, vì nhân một hằng số không đổi argmax

Kiểm hình học độc lập

Tích vô hướng bằng vòng lặp khớp NumPy.

Loss của các cặp trên đường chéo:

KẾT QUẢ

```
dot khop vong lap: True
image-to-text loss: 0.2114
text-to-image loss: 0.2135
loss trung binh: 0.2124
```

Hàng: ảnh tìm chữ · cột: chữ tìm ảnh.

Softmax theo hàng và theo cột

softmax theo hàng: ảnh tìm chữ

	bàn	bảng	máy tính
ảnh 1	0.731	0.269	0.000
ảnh 2	0.269	0.731	0.001
ảnh 3	0.000	0.007	0.993

loss 0.2114

softmax theo cột: chữ tìm ảnh

	bàn	bảng	máy tính
ảnh 1	0.731	0.265	0.000
ảnh 2	0.269	0.721	0.000
ảnh 3	0.000	0.013	1.000

loss 0.2135

loss = trung bình −log của ba ô đường chéo

Cùng ma trận logits, softmax theo hàng và theo cột cho hai phân phối khác nhau (số từ code bài): loss ảnh tìm chữ 0.2114, chữ tìm ảnh 0.2135.

02

Tập lớp và prompt

“Desk” và “a photo of a desk”

Text encoder đọc cả chuỗi.

Template và ngôn ngữ có thể đổi vector lớp.

Có thể trung bình nhiều template rồi chuẩn hóa lại.

Chọn template bằng nhãn validation cần khai báo trong giao thức zero-shot.

HỎI NHANH

Một đội thử 20 template, giữ template có accuracy cao nhất trên 100 ảnh validation có nhãn, rồi báo chính con số ấy là “accuracy zero-shot”. Báo như vậy có ổn không?

A Ổn, vì không trọng số nào được cập nhật

B Ổn, nếu cả 20 template đều do người viết tay

C Không ổn, con số quá lạc quan, vì nhãn đã được dùng để chọn template

D Không ổn, vì zero-shot không được dùng nhiều template

Không phải độ tin cậy thế giới mở

KẾT QUẢ

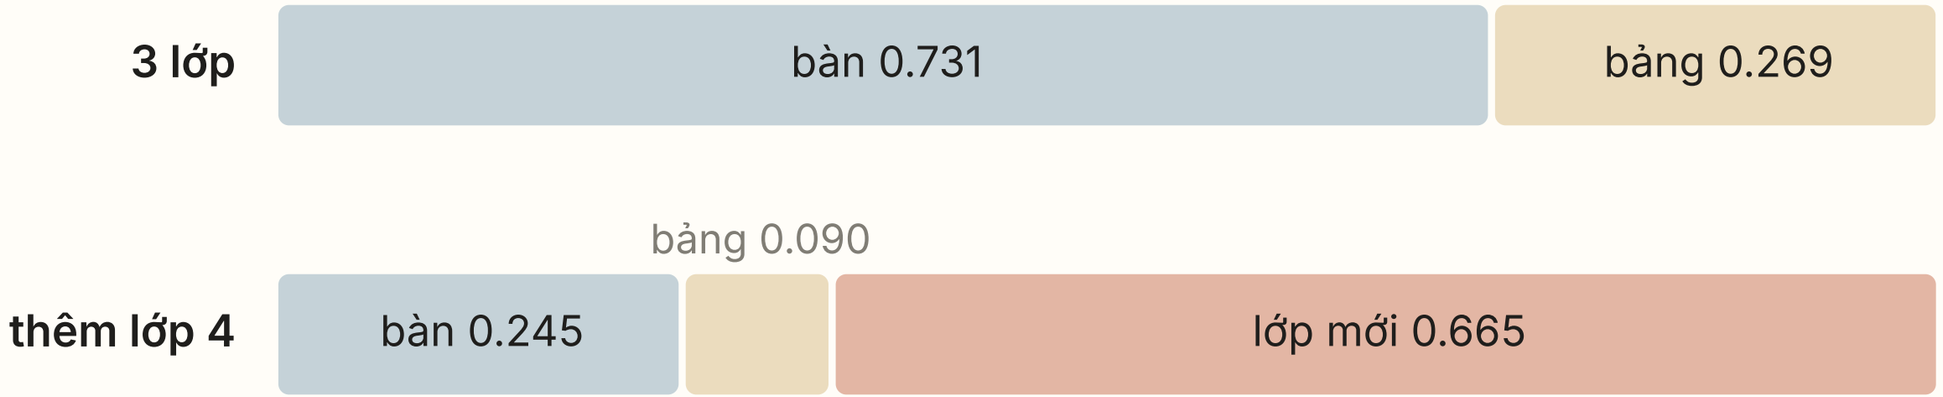
```
xac suat lop cu truoc: 0.7309
xac suat lop cu sau: 0.2447
chi so thang sau: 3
```

Ảnh và vector lớp cũ không đổi.

Mẫu số softmax đổi.

Thêm từ “other” không tự tạo bộ phát hiện ngoài miền tốt.

Một ứng viên mới làm đổi cuộc so sánh



Softmax của ảnh 1 trước và sau khi thêm một lớp trùng hướng ảnh (số từ code bài): “bàn” từ 0.731 xuống 0.245, lớp mới thắng với 0.665.

HỎI NHANH

Ảnh chụp một cái ghế, nhưng tập lớp chỉ có bàn, bảng và máy tính. Softmax cho “bàn” 0.92. Hiểu con số này thế nào?

A Bàn là lớp khớp nhất trong ba lớp đã cho

B Ảnh có 92% khả năng là một cái bàn

C Ảnh là cái bàn, vì 0.92 vượt ngưỡng 0.5

D Model hỏng, vì ảnh lạ thì softmax phải nhỏ

03

Chấm chuỗi bằng xác suất

Causal language model

$$\log p(t_1, \ldots, t_m \mid c) = \sum_j \log p(t_j \mid c, t_{<j})$$

Chỉ chấm token ứng viên, không lẫn token prompt.

Logits vị trí hiện tại dự đoán token **kế tiếp**.

HỎI NHANH

Hai ứng viên dùng chung một prompt 40 token. Một bạn lỡ cộng log-prob của 40 token prompt vào điểm của mỗi ứng viên. Thứ hạng theo tổng log và theo trung bình log có thể đổi không?

A Theo tổng có thể đổi, theo trung bình thì không

B Theo tổng không đổi, theo trung bình thì có thể đổi

C Cả hai đều không đổi

D Cả hai đều có thể đổi

Độ dài có thể đổi tiêu chí

A: `(0.6,0.8)` có xác suất chuỗi 0.48.

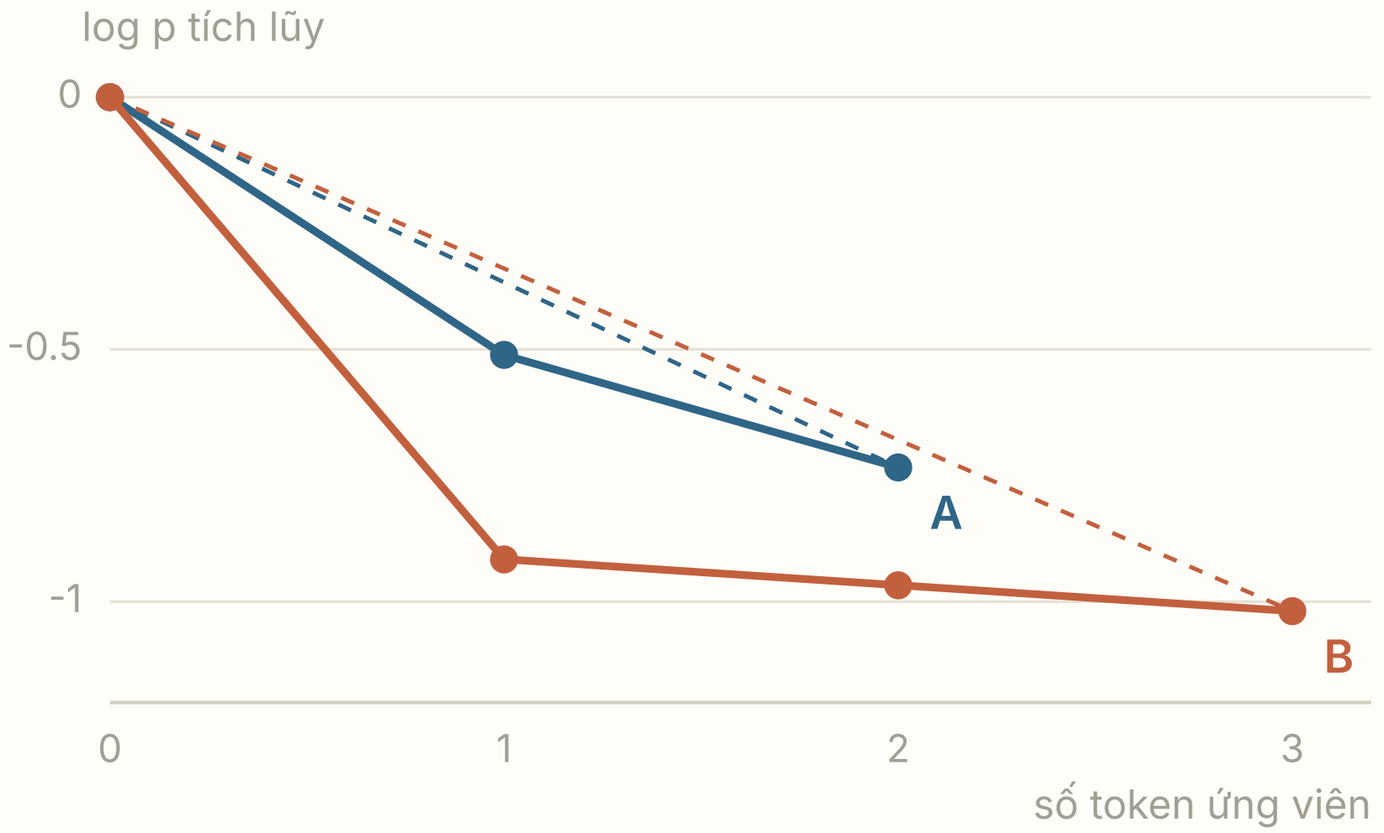
B: `(0.4,0.95,0.95)` có xác suất chuỗi 0.361.

Bảng tự đặt; model thật đọc số từ softmax.

Ứng viên	Tổng log	Mean log
A	-0.7340	-0.3670
B	-1.0189	-0.3396

Tổng chọn **A**; mean chọn **B**.

Đổi tiêu chí, đổi thứ hạng



	tổng	mean
A	-0.734	-0.367
B	-1.019	-0.340
chọn	A	B
	điểm cuối	độ dốc

Log-probability tích lũy qua từng token của hai ứng viên (số từ code bài): tổng log là điểm cuối nên chọn A; mean log là độ dốc từ gốc nên chọn B.

HỎI NHANH

Nối thêm vào cuối B một token có xác suất có điều kiện 0.99. Tổng log và trung bình log của B thay đổi thế nào?

A Tổng tăng, trung bình tăng

B Tổng tăng, trung bình giảm

C Tổng giảm, trung bình tăng

D Tổng giảm, trung bình giảm

Perplexity

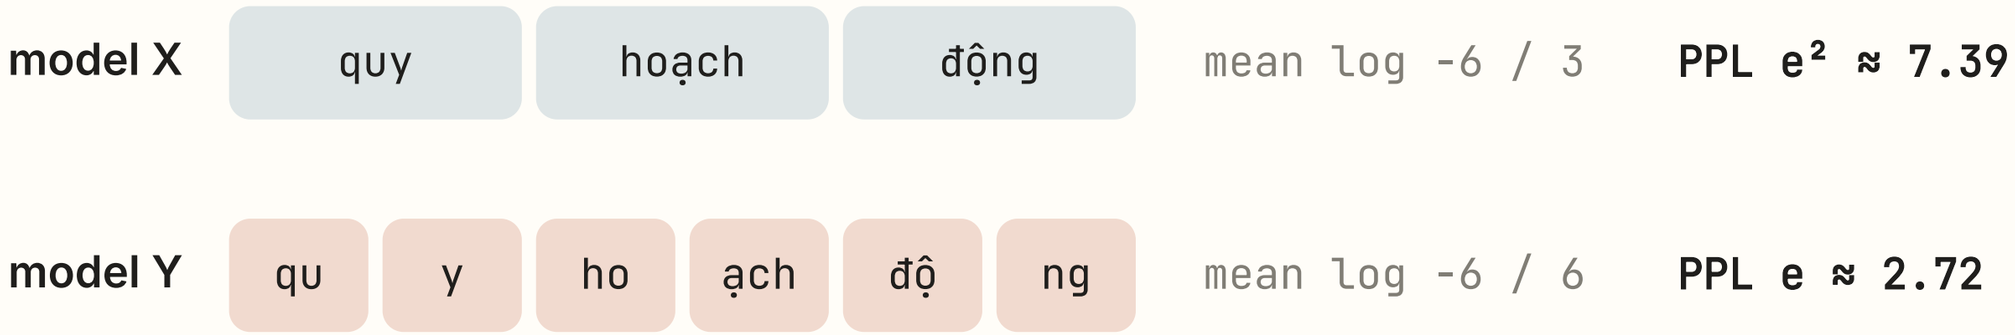
$$\mathrm{PPL} = \exp(-\text{mean log-probability})$$

A: 1.4434 · B: 1.4044.

Mỗi token xác suất 0.5 cho PPL bằng 2.

Dễ đoán không đồng nghĩa lời giải đúng.

Cùng câu, khác tokenizer



cùng một câu, cùng tổng log −6: chỉ mẫu số khác nhau

Cùng một câu và cùng tổng log-probability −6, tokenizer tách 3 hay 6 token cho PPL 7.39 hay 2.72: PPL chỉ so được trong cùng một tokenizer.

HỎI NHANH

Cùng một câu, model X tách thành 3 token, model Y tách thành 6 token, và cả hai cho tổng log-probability của câu bằng −6. PPL theo token của hai model là bao nhiêu?

A Cả hai khoảng 7.39, vì cùng tổng log

B X khoảng 2.72, Y khoảng 7.39, và câu có cùng xác suất ở hai model

C X khoảng 7.39, Y khoảng 2.72, nên Y đoán câu này tốt hơn

D X khoảng 7.39, Y khoảng 2.72, và câu có cùng xác suất ở hai model

Recipe với asset thật

CLIP: JSON prompt mỗi lớp + CSV ảnh.

Logits API dùng scale đã học.

Có nhãn thì ghi accuracy, macro-F1.

GPT-2: prompt + danh sách ứng viên.

Dịch logits một vị trí, chỉ chấm token ứng viên.

Ghi log-prob từng token, tổng, mean, PPL.

HỎI NHANH

Prompt là `"The algorithm uses"`, nhưng ứng viên được ghi là `"dynamic programming"`, thiếu khoảng trắng ở đầu. Recipe tokenize prompt và ứng viên riêng rồi ghép ID lại. Chuyện gì xảy ra?

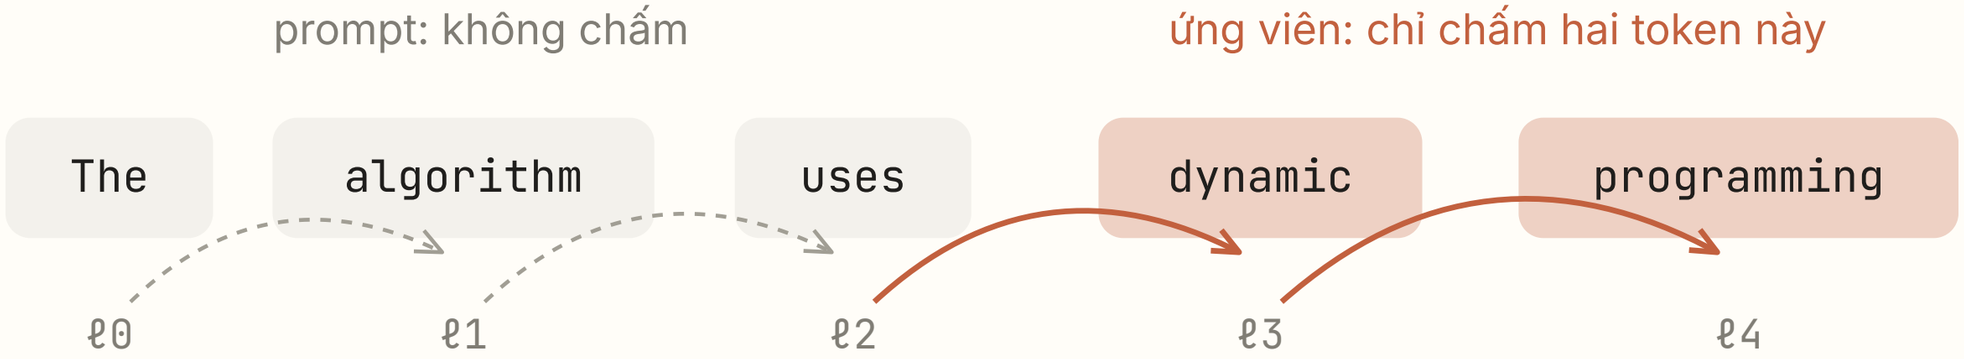
A Không sao, tokenizer tự chèn khoảng trắng giữa hai phần

B Model chấm một chuỗi dính liền “usesdynamic”, nên điểm thấp oan

C Recipe dừng lại, vì ứng viên vượt quá context

D Chỉ trung bình log đổi, còn tổng log giữ nguyên

Chỉ chấm token ứng viên



logits ở vị trí j dự đoán token j + 1, nên nhãn dịch đi một vị trí

Chấm một ứng viên bằng causal language model: logits ở vị trí j dự đoán token j + 1; chỉ cộng log-prob của các token thuộc ứng viên.

Zero-shot với CLIP trên ảnh thật



ảnh 1: chọn “cat”, cosine 0.285, softmax 0.99



ảnh 2: chọn “cup of coffee”, cosine 0.302, softmax 1.00



ảnh 4: chọn “temple”, cosine 0.257, softmax 1.00



ảnh 6: chọn “astronaut”, cosine 0.268, softmax 1.00

Zero-shot với CLIP ViT-B/32 trên ảnh thật: mỗi lớp chỉ là một câu “a photo of a ...”, ảnh chọn câu có cosine cao nhất; không ảnh nào được dùng để train.

HỎI NHANH

Hàng của `V` theo thứ tự ban, may_tinh, bang. Code lấy `class_names = sorted(prompts)`, tức `['ban', 'bang', 'may_tinh']`, rồi `label = class_names[int(logits[0].argmax())]`. Ảnh đầu là máy tính, và cột máy tính lớn nhất. `label` là gì?

A `'may_tinh'`

B `'ban'`

C `'bang'`

D `IndexError`

Khi đi thi

- Có asset: dựng baseline zero-shot, rồi so head-only.
- Đọc đề: “zero-shot” cho dùng nhãn tới đâu.
- Prompt, cột logits, submission: một danh sách lớp.
- Chấm chuỗi: một giao thức, chọn tổng/mean bằng validation.
- Asset/Internet theo thông báo; encode prompt lớp một lần.

04

Luyện đề

LUYỆN ĐỀ 1

Câu lạc bộ đã có bộ phân loại CLIP ba lớp: bàn, bảng, máy tính. Nay cần thêm lớp “máy chiếu”, nhưng chưa có ảnh máy chiếu nào được gán nhãn. Làm thế nào là hợp lý?

A Thêm prompt, tính text embedding, rồi thêm một hàng vào V

B Gán nhãn ảnh máy chiếu rồi học lại head bốn lớp

C Fine-tune image encoder trên ảnh máy chiếu

D Không làm được, vì máy chiếu không phải lớp của ImageNet

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 261

LUYỆN ĐỀ 2

Để kiểm xem các prompt lớp có quá giống nhau không, một đội lấy `T` gồm K text embedding đã chuẩn hóa từng hàng, tính `S = T @ T.T`, rồi `nearest = S.argmax(axis=1)`. Không có hai embedding nào trùng nhau. `nearest` cho ra gì?

A Mỗi hàng ra prompt gần nhất, khác chính nó

B Mỗi hàng ra chính chỉ số của nó

C Mỗi hàng ra prompt xa nhất của nó

D Báo lỗi, vì `S` không phải ma trận vuông

PHỎNG THEO USA-NA-AIO 2026 · Vòng 1 · Part 5.8–5.9

LUYỆN ĐỀ 3

Nhật ký train một language model ghi train loss 1.8, là trung bình negative log-likelihood theo token với log tự nhiên, và validation perplexity 19.1, cùng tokenizer và cùng cách đếm token. Trung bình negative log-likelihood trên validation khoảng bao nhiêu?

A Khoảng 1.28, thấp hơn train loss

B Khoảng 2.95, cao hơn train loss

C Khoảng 6.05, cao hơn train loss

D 19.1, vì PPL chính là loss trung bình

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 84

Điều cần giữ lại

- CLIP dùng mô tả lớp trong không gian ảnh–chữ chung.
- Softmax phụ thuộc tập lớp; log-probability phụ thuộc chuỗi và tokenizer.
- Điểm model chưa chứng minh chất lượng hay tính đúng của kết quả.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; thêm một lớp ứng viên và xem softmax của lớp cũ đổi ra sao.

Chạy recipe CLIP/GPT-2 trên dữ liệu tự chuẩn bị, đọc `RESULT.json`.