Self-supervised và CLIP

Tìm ảnh bằng câu chữ

Kho ảnh chưa có nhãn lớp

Câu truy vấn: “học sinh đọc sách cạnh cửa sổ”.

Ảnh chưa nhãn vẫn có quan hệ để học: hai view của một ảnh, ảnh và caption.

Cần một không gian vector chung để tìm kiếm.

01

Tạo tín hiệu học

Pretext task

Che rồi đoán phần bị che.

Xoay rồi đoán góc.

Hai view của một ảnh phải gần nhau.

Không có nhãn người gán cho từng mẫu.

Vẫn có mục tiêu, giả định và cách đánh giá.

HỎI NHANH

Một đội muốn tận dụng 800 ảnh không nhãn bằng pretext task “đoán xem ảnh đã bị xoay 0°, 90°, 180° hay 270°”. Bộ ảnh là các hình học vốn được vẽ ở góc xoay ngẫu nhiên. Pretext task này có hợp không?

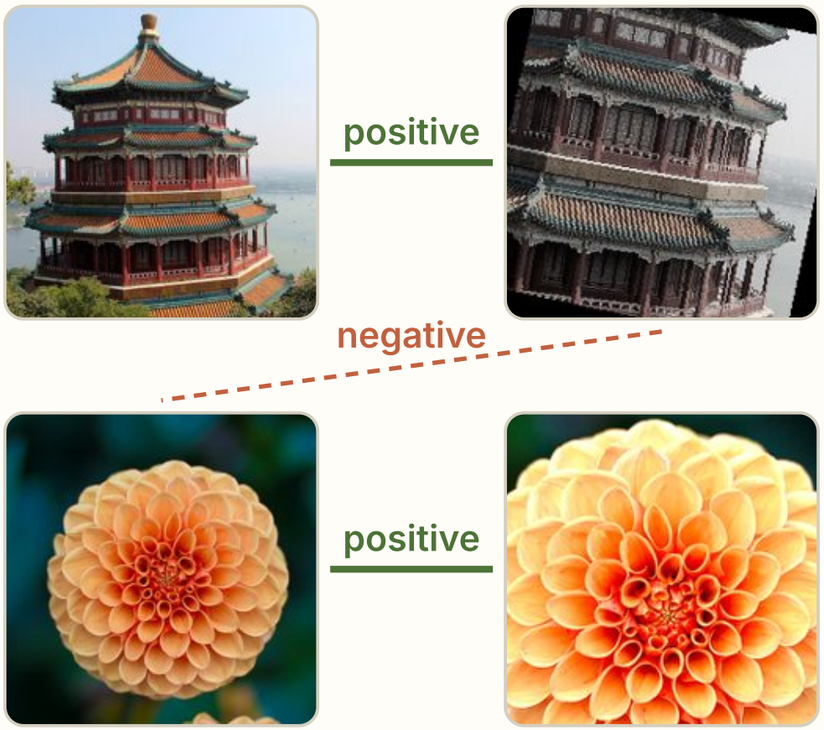
A Hợp, vì nhãn góc xoay được tạo miễn phí từ dữ liệu

B Không hợp, vì ảnh gốc không có hướng chuẩn để so

C Hợp, nếu train đủ lâu để đoán đúng mọi góc

D Không hợp, vì pretext task nào cũng cần nhãn người

Positive đến từ đâu?



positive: hai view của một ảnh

crop, xoay, đổi màu, lật, đổi sáng

negative: view của ảnh khác

trong cùng batch

SimCLR trên ảnh thật: hai view augmentation của cùng một ảnh là cặp positive; view của ảnh khác trong batch là negative.

Negative chặn sụp đổ

Chỉ kéo hai view lại gần: vector hằng cho mọi ảnh là lời giải tối ưu.

Negative buộc các ảnh khác nhau tách ra.

HỎI NHANH

Một đội bỏ negative, chỉ minimize giữa hai view của cùng một ảnh. Sau vài epoch, loss bằng đúng trên mọi batch. Chuyện gì đang xảy ra?

A Encoder đã học xong, có thể dừng và dùng ngay

B Learning rate quá lớn làm loss kẹt ở cực trị

C Hai view quá giống nhau, cần augmentation mạnh hơn

D Nhiều khả năng encoder trả về một vector cho mọi ảnh

SimCLR và CLIP

SimCLR: hai view augmentation của cùng ảnh.

Ảnh–ảnh, không cần chữ.

CLIP: ảnh và caption đi kèm.

Caption do người viết: giám sát yếu bằng ngôn ngữ.

02

Cosine và ma trận ghép cặp

Cosine

sau khi chuẩn hóa từng vector về độ dài 1.

với : cosine .

Xếp hạng vector đặt tay

`similarities` là ma trận cosine của ba ảnh (hàng) và ba mô tả (cột).

```
print("best text for each image:", similarities.argmax(axis=1).tolist())
print("best image for text 1:", int(similarities[:, 1].argmax()))
```

KẾT QUẢ

```
best text for each image: [0, 1, 2]
best image for text 1: 1
```

Hàng: tìm chữ cho ảnh. Cột: tìm ảnh cho chữ.

HỎI NHANH

Ma trận cosine giữa hai ảnh, xếp theo hàng, và ba câu, xếp theo cột, là . Tìm ảnh cho câu thứ hai, tức cột giữa, thì được ảnh nào? Tìm câu cho ảnh thứ hai, tức hàng dưới, thì được câu nào?

A Ảnh thứ hai, và ảnh ấy chọn câu thứ hai

B Ảnh thứ hai, và ảnh ấy chọn câu thứ nhất

C Ảnh thứ nhất, và ảnh thứ hai chọn câu thứ nhất

D Ảnh thứ nhất, và ảnh thứ hai chọn câu thứ hai

03

Cặp đúng thắng cặp khác

Cross-entropy trong batch

$$\frac{}{}$$

Target của hàng là cột ; là temperature.

CLIP lấy trung bình hai chiều ảnh → chữ và chữ → ảnh.

SimCLR: view

Mỗi view: 1 partner, negative.

Đường chéo gán : không tự so với chính nó.

HỎI NHANH

SimCLR với batch ảnh, mỗi ảnh có hai view. Mỗi view có bao nhiêu negative? Mẫu số của nó, sau khi bỏ chính nó, có bao nhiêu số hạng?

A 127 negative, 128 số hạng

B 255 negative, 256 số hạng

C 254 negative, 255 số hạng

D 254 negative, 256 số hạng

Gradient tăng điểm đúng

```
print("symmetric loss:", round(contrastive_loss.item(), 4))
print("diagonal gradients:", [round(float(v), 4) for v in logits.grad.diag()])
print("negative gradient [0,1]:", round(logits.grad[0, 1].item(), 4))
```

KẾT QUẢ

```
symmetric loss: 0.2255
diagonal gradients: [-0.0572, -0.083, -0.0609]
negative gradient [0,1]: 0.0434
```

Gradient âm ở đường chéo: logit cặp đúng tăng. Gradient dương ở ô sai: logit ấy giảm.

Logits và gradient

	caption 0	caption 1	caption 2
ảnh 0	2	0.2	−1
ảnh 1	0.1	2	0.3
ảnh 2	−1	0.2	2

logits

−0.057	+0.043	+0.014
+0.039	−0.083	+0.048
+0.014	+0.043	−0.061

gradient của loss đối xứng

âm trên đường chéo: tăng; dương ngoài: giảm

Ma trận logits 3×3 kiểu CLIP và gradient của loss đối xứng (số từ code bài): ô đường chéo nhận gradient âm nên được tăng, ô ngoài đường chéo nhận gradient dương nên bị giảm.

HỎI NHANH

Trong output trên, cặp thứ hai có gradient ở đường chéo bằng , lớn nhất về độ lớn, dù ba logit đúng đều bằng 2. Vì sao?

A Hàng và cột của nó có logit sai cao nhất

B Logit đúng của nó lớn nhất trong cả ba cặp

C Ô giữa nhận gradient từ cả hàng lẫn cột

D Gradient được khởi tạo ngẫu nhiên nên khác nhau

False negative

Caption khác vẫn có thể mô tả đúng cùng ảnh.

SimCLR: hai tam giác khác nhau luôn là negative của nhau.

Batch lớn thêm negative, cũng thêm những cặp như vậy.

04

Temperature và số negative

Temperature dồn lực vào negative khó

Positive 0.8, một negative khó 0.7, sáu negative 0.

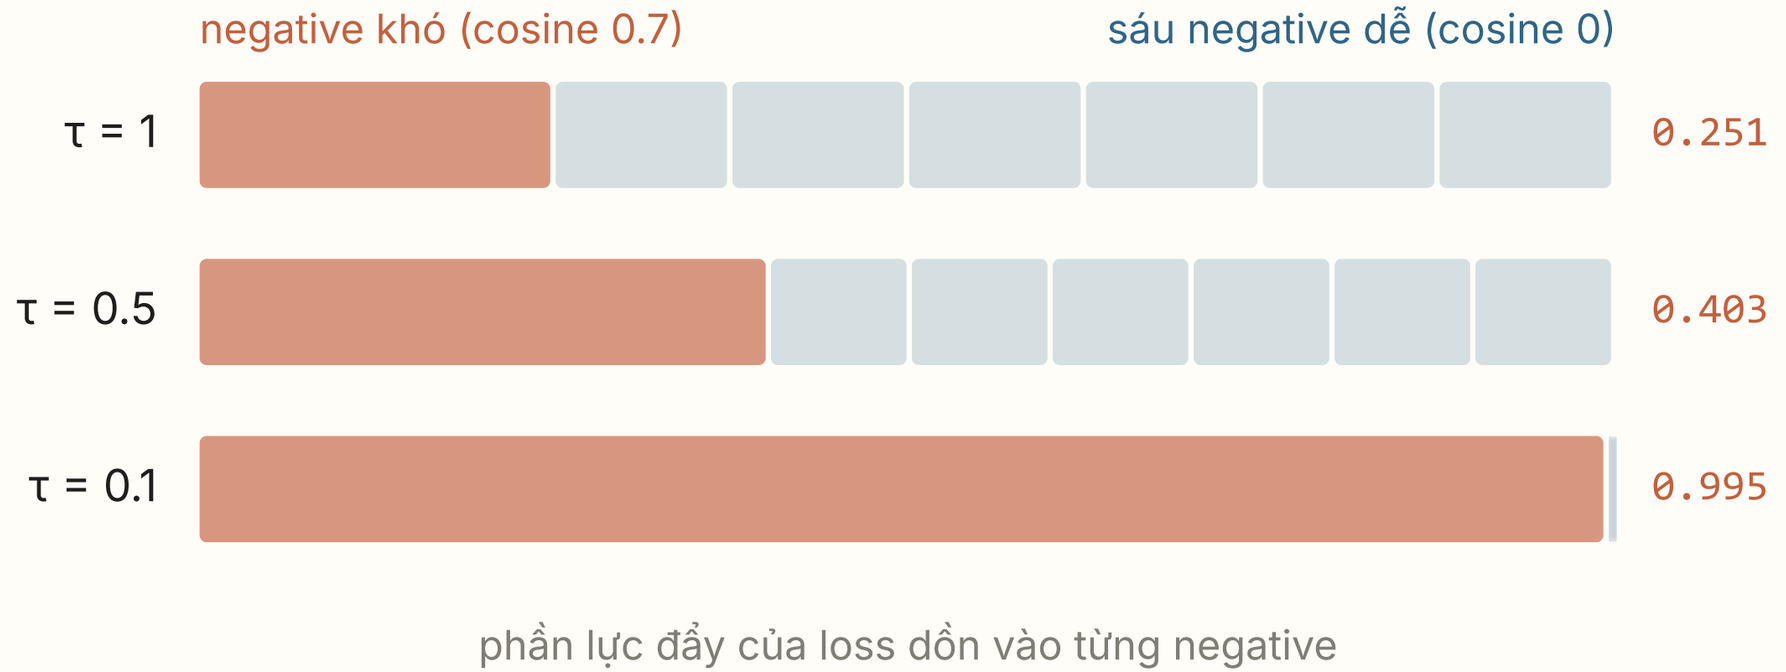
```
probabilities = (row_scores / tau).softmax(0)
push = probabilities[1:] / tau          # lực đẩy lên từng negative
```

KẾT QUẢ

```
tau=1.0: loss 1.526, hard-negative share 0.251
tau=0.5: loss 1.109, hard-negative share 0.403
tau=0.1: loss 0.315, hard-negative share 0.995
```

Tốt nếu negative khó khác nghĩa thật; hại nếu là false negative.

Lực đẩy theo temperature



Phần lực đẩy dồn vào negative khó theo temperature (số từ code bài): 0.251 ở τ = 1, 0.403 ở τ = 0.5, 0.995 ở τ = 0.1.

HỎI NHANH

SimCLR trên bộ ảnh ba lớp hình, batch 256 ảnh, nên khoảng một phần ba batch cùng lớp với mỗi anchor. Hạ từ 0.5 xuống 0.05 thì rủi ro lớn nhất là gì?

A Loss không còn khả vi vì softmax quá nhọn

B Số negative trong mẫu số giảm theo

C Augmentation bị bỏ qua khi tính loss

D Lực đẩy dồn vào những ảnh cùng lớp với anchor

Mốc đoán mò

Mọi similarity bằng nhau: loss , với số ứng viên.

SimCLR: .

Loss 3.0 với (mốc 6.24): tiến bộ lớn.

Loss 3.0 với (mốc 3.43): gần đoán mò.

HỎI NHANH

Đội A train contrastive kiểu CLIP với batch 1024, loss cuối là 2.9. Đội B dùng batch 64, loss cuối là 2.1. Ta kết luận được gì?

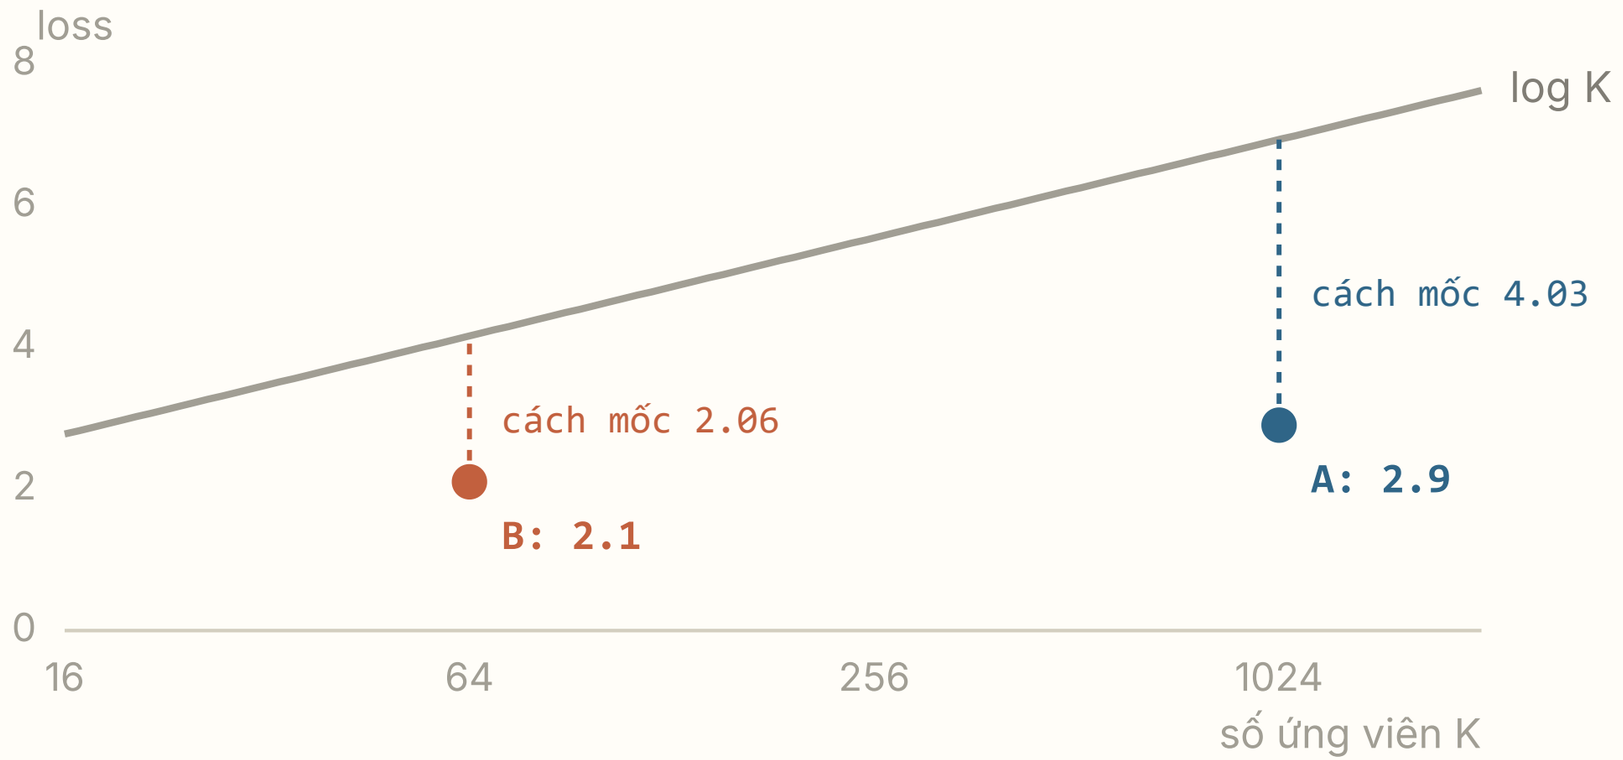
A B tốt hơn, vì cùng loại loss mà B thấp hơn

B A tốt hơn, vì batch lớn luôn cho biểu diễn tốt hơn

C Chưa so được, vì mốc đoán mò là và

D Chưa so được, vì phải train cả hai cùng số epoch

Hai loss trên hai thang



Mốc đoán mò log K của loss contrastive theo số ứng viên: đội A (batch 1024, loss 2.9) và đội B (batch 64, loss 2.1) đo trên hai thang khác nhau, nên không so trực tiếp được.

05

Thí nghiệm: học hình không cần nhãn

Dữ liệu như một đề thi

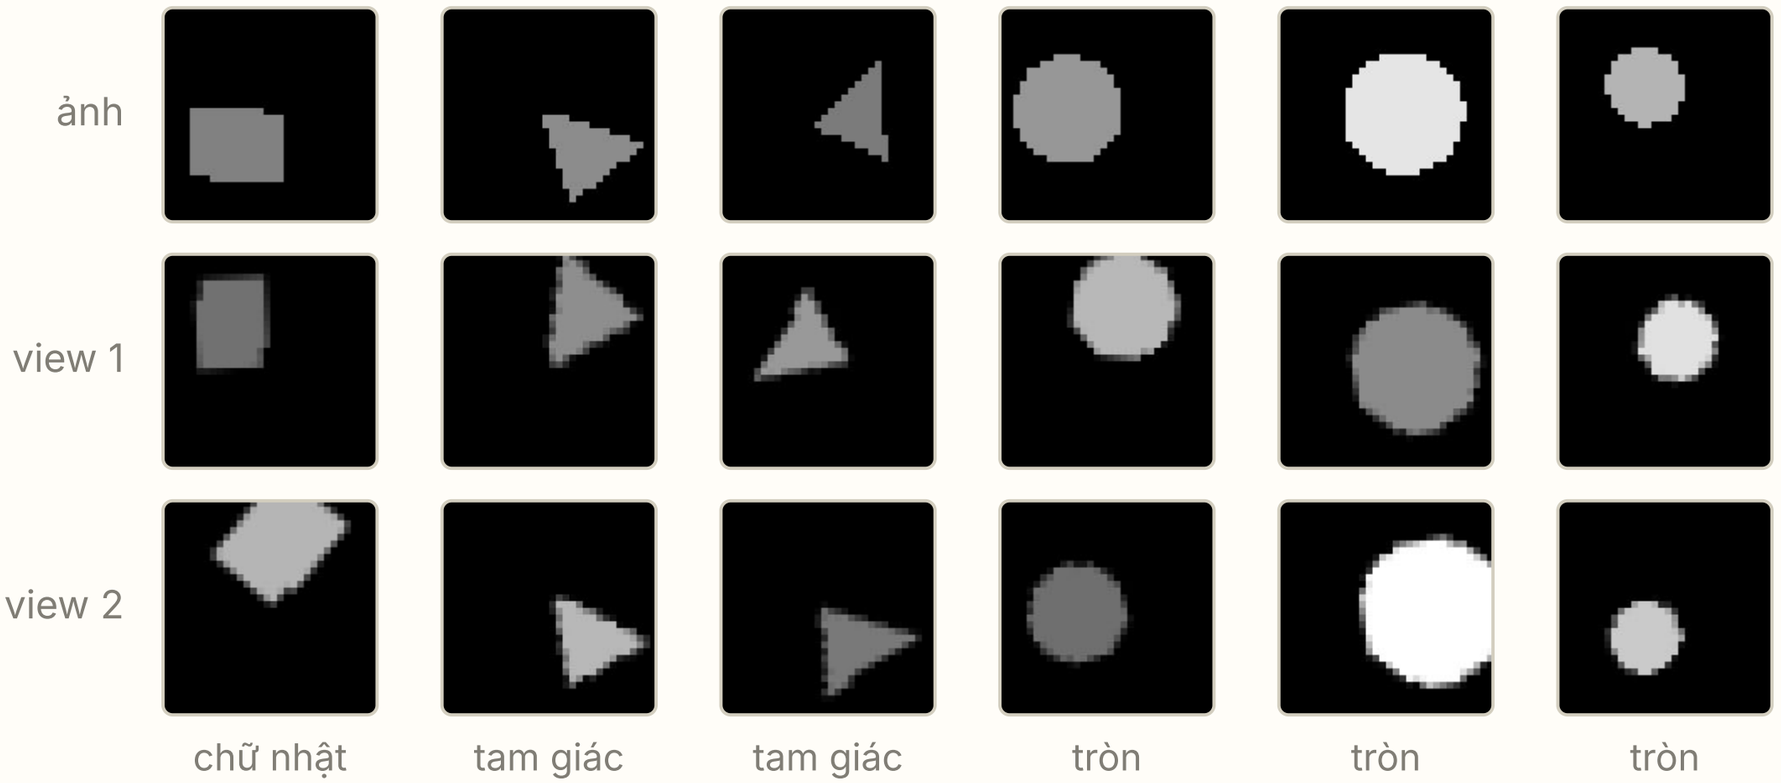
USA-NA-AIO 2026: tròn, tam giác, chữ nhật; 200 nhãn trên 1000 ảnh; cấm pretrained; macro-F1.

Bản nhỏ: ảnh xám sinh bằng code.

Augmentation giữ lớp: xoay bất kỳ, co giãn 0.8–1.2, dịch 10%, đổi độ sáng.

CNN ba tầng → 64 chiều; projection 32 chiều.

Ảnh và hai view



Sáu ảnh hình học do code bài sinh và hai view augmentation của mỗi ảnh (xoay, co giãn, dịch, đổi sáng): lớp của hình giữ nguyên qua mọi view.

Train không đọc nhãn

```
z1 = projection(encoder(augment(batch, generator)))
z2 = projection(encoder(augment(batch, generator)))
loss = nt_xent(z1, z2, temperature)       # tau = 0.2
```

KẾT QUẢ

```
chance loss log(2N-1): 5.517
epoch 1: loss 5.246
epoch 5: loss 4.765
epoch 10: loss 4.273
```

Loss giảm chưa nói encoder phân loại được; phải đo trên nhiệm vụ đích.

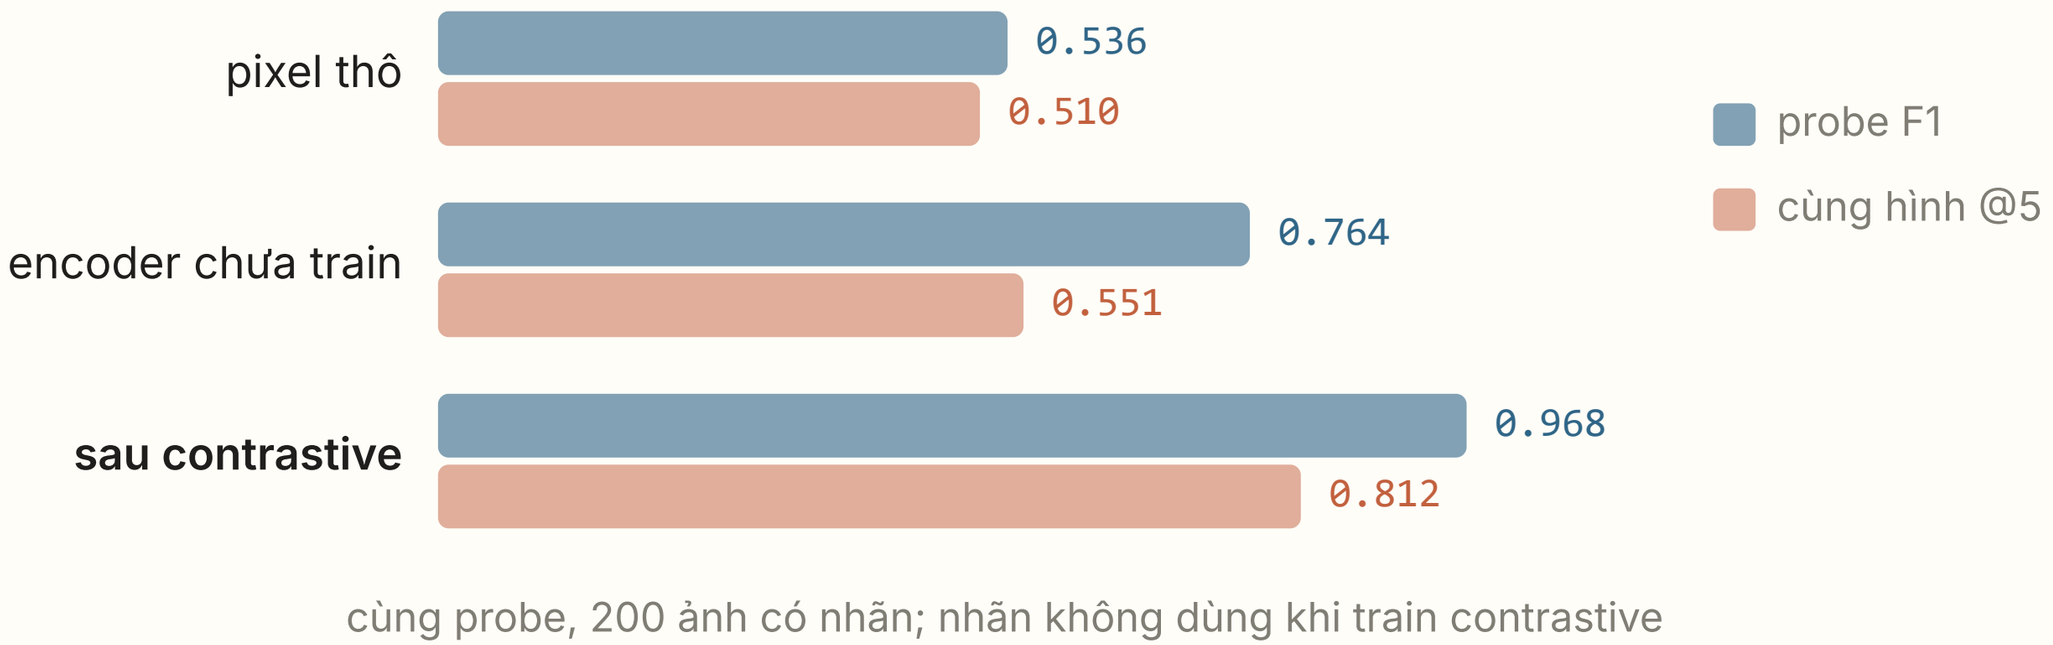
Linear probe trên 200 ảnh có nhãn

KẾT QUẢ

features	probe F1	same shape@5
pixels	0.536	0.510
random encoder	0.764	0.551
contrastive	0.968	0.812

Cùng probe, chỉ đổi đặc trưng. Đối chứng đúng là encoder chưa train: 0.764 → 0.968.

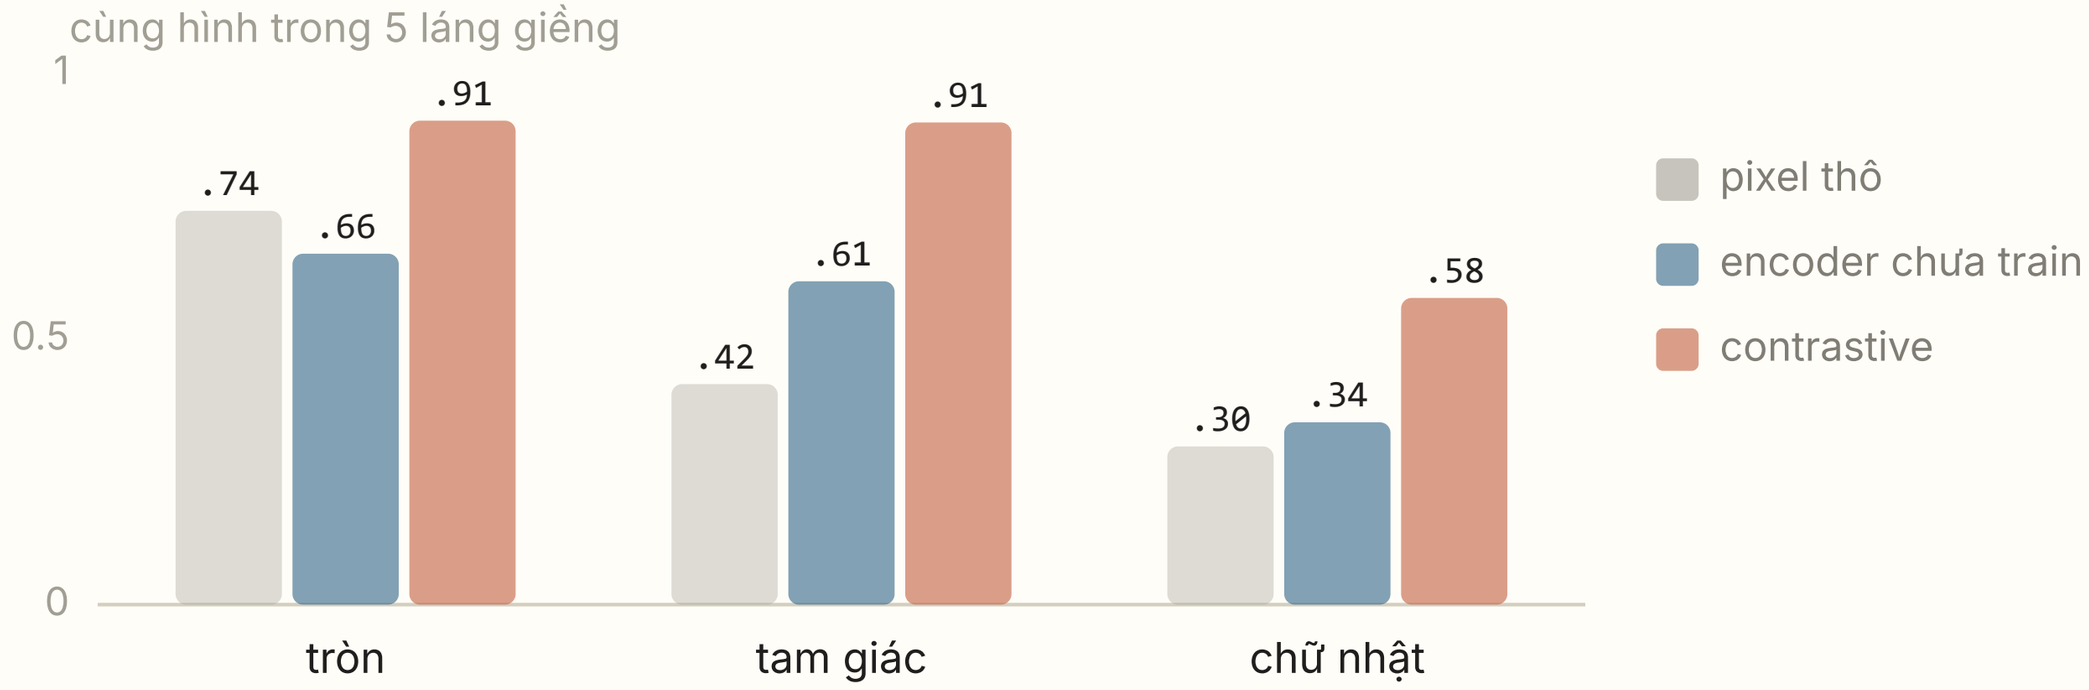
Ba loại đặc trưng



cùng probe, 200 ảnh có nhãn; nhãn không dùng khi train contrastive

Linear probe trên 200 ảnh có nhãn và tỉ lệ cùng hình trong 5 láng giềng (số từ output bài): pixel thô 0.536, encoder chưa train 0.764, sau contrastive 0.968.

Láng giềng theo cosine



Tỉ lệ ảnh cùng hình trong 5 láng giềng cosine của mỗi ảnh test, tách theo lớp (số chạy lại từ code bài). Contrastive cao nhất ở cả ba lớp; chữ nhật vẫn khó nhất.

HỎI NHANH

Encoder chưa train đạt probe F1 0.764, còn pixel thô chỉ được 0.536, dù cả hai chưa học gì từ 800 ảnh không nhãn. Vì sao có chênh lệch này?

A Contrastive gần như vô dụng, phần lớn điểm là nhờ probe

B Kiến trúc CNN sẵn có một phần bất biến với vị trí

C Encoder ngẫu nhiên đã vô tình được pretrained

D Pixel thô kém vì logistic regression chưa hội tụ

06

Tìm ảnh bằng câu chữ

Cùng không gian, hai cách dùng

Retrieval: một câu, xếp hạng hàng nghìn ảnh.

Cache vector ảnh; đo bằng recall@k.

Zero-shot (bài 4.5): một ảnh, chọn một trong vài câu mô tả lớp.

HỎI NHANH

Có bốn query, mỗi query có đúng một ảnh đúng, nằm ở thứ hạng 1, 3, 7 và 2 trong kết quả. Recall@1 và recall@5 bằng bao nhiêu?

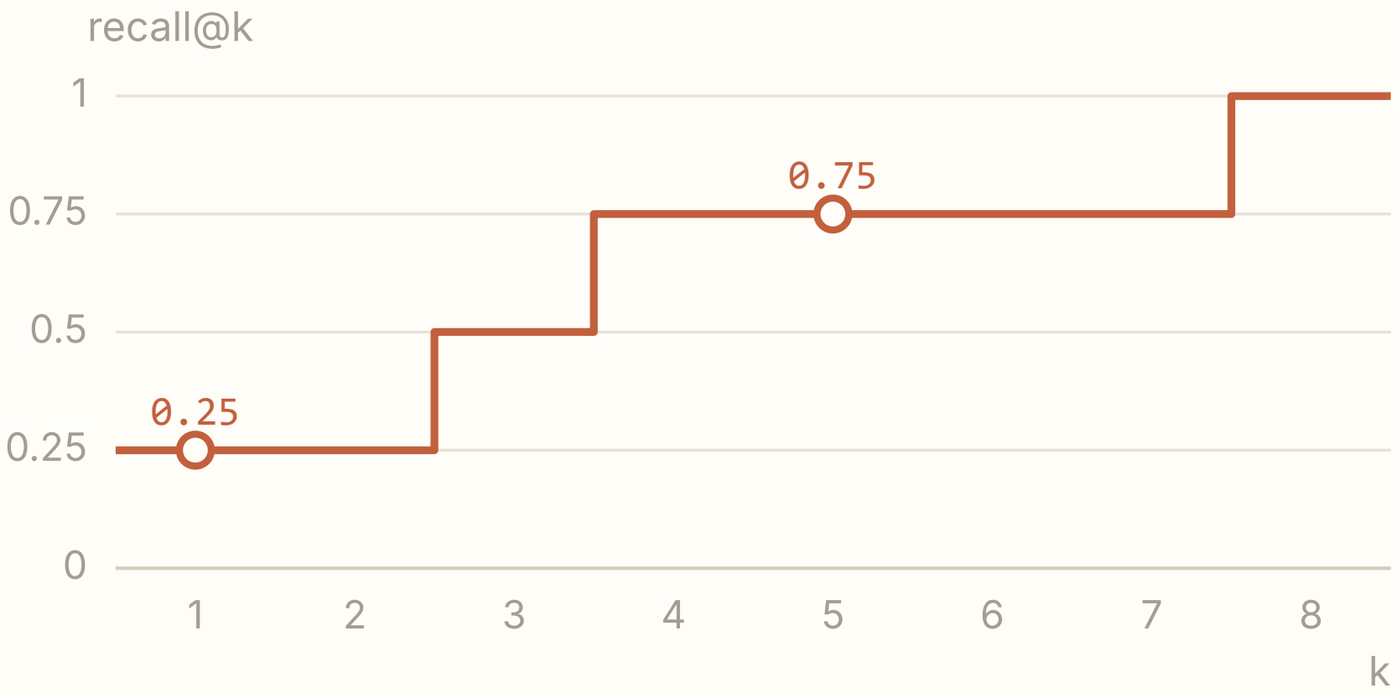
A 0.25 và 0.75

B 0.25 và 1.00

C 0.50 và 0.75

D 0.25 và 0.50

Recall@k theo k



hạng ảnh đúng của 4 query

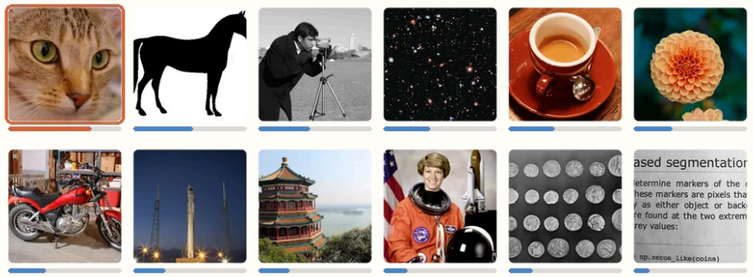
`1, 3, 7, 2`

Recall@k của bốn query có ảnh đúng ở hạng 1, 3, 7, 2: recall@1 = 0.25, recall@5 = 0.75, đủ 1 từ k = 7.

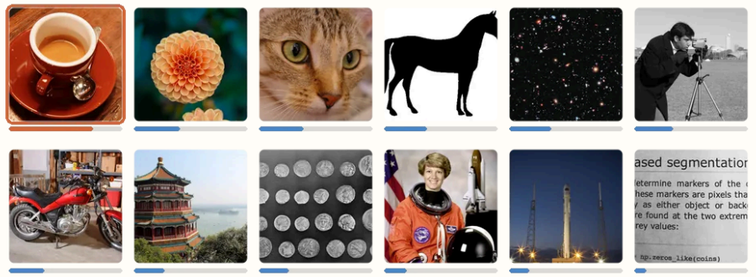
CLIP trên kho ảnh trường

- Recipe nạp checkpoint và processor cục bộ, offline.
- Encode kho ảnh một lần, chuẩn hóa, cache kèm checkpoint.
- Đo recall@k trên query đã đánh dấu tay.
- Nhóm lỗi: chỉ thấy sách, chỉ thấy cửa sổ, sai quan hệ.

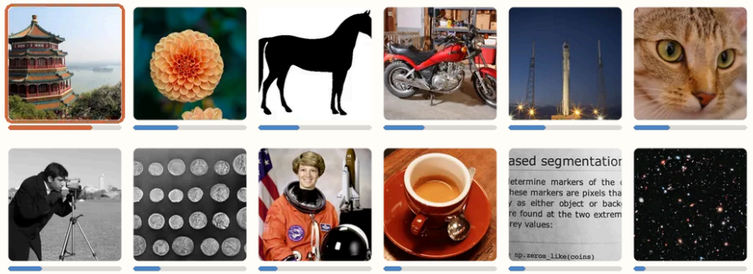
CLIP xếp hạng ảnh thật theo câu truy vấn



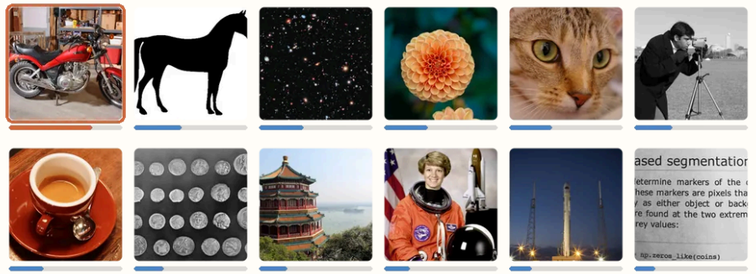
“a photo of a cat” · hạng 1 cosine 0.285



“a cup of coffee” · hạng 1 cosine 0.286



“an old pagoda” · hạng 1 cosine 0.286



“a motorcycle” · hạng 1 cosine 0.284

CLIP ViT-B/32 xếp 12 ảnh thật theo cosine với từng câu truy vấn; vạch dưới ảnh là cosine.

HỎI NHANH

Trường cần chọn một trong hai checkpoint CLIP cho bộ tìm ảnh. So hai checkpoint bằng cách nào?

A So cosine trung bình của kết quả top-1 hai bên

B So loss pretraining mà hai nhà phát hành công bố

C Chọn checkpoint có softmax top-1 tự tin hơn

D Đánh dấu ảnh đúng cho một tập query, rồi so recall@k

Khi đi thi

- Ảnh không nhãn: contrastive rồi linear probe, so với encoder chưa train.
- Augmentation theo bất biến của đề.
- Loss contrastive đọc theo mốc .
- Đọc luật dùng pretrained trước khi chọn CLIP.
- Bộ nhớ ; cache embedding.
- Recall@k trên query giữ riêng.

07

Luyện đề

LUYỆN ĐỀ 1

Contrastive loss của CLIP kéo cặp đúng lại gần và tách cặp sai ra xa. Cộng cùng một hằng số vào mọi ô trong hàng của ma trận điểm , trước khi chia cho . Loss ảnh sang chữ của hàng thay đổi thế nào?

A Giảm, vì logit cặp đúng tăng thêm

B Tăng, vì logit mọi cặp sai đều tăng thêm

C Không đổi, nhưng chỉ khi nhỏ hơn

D Không đổi, với mọi giá trị của

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 259

LUYỆN ĐỀ 2

Ảnh và mô tả được encode bằng CLIP rồi để chung một index. Tìm ảnh bằng câu chữ thì tốt. Nhưng khi query là một ảnh, top-10 toàn là ảnh. Vì sao?

A Text encoder lỗi, vector chữ gần như ngẫu nhiên

B Thiếu softmax có temperature trước khi xếp hạng

C Cosine ảnh–ảnh và ảnh–chữ không cùng một thang

D Ảnh nhiều thông tin hơn nên gần nhau hơn

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 258

LUYỆN ĐỀ 3

Biểu diễn pretrained của CLIP dùng được cho nhiều nhiệm vụ. Câu lạc bộ có 300 ảnh dụng cụ thí nghiệm đã gán 5 nhãn. Zero-shot bằng tên lớp đạt macro-F1 0.62 trên validation. Đề cho phép dùng CLIP. Bước tiếp theo nên là gì?

A Linear probe trên embedding ảnh đã cache

B Fine-tune toàn bộ CLIP với learning rate lớn

C Đổi prompt đến khi validation vượt 0.9

D Train CNN từ đầu trên 300 ảnh, bỏ CLIP

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 262

Chốt ý

Biểu diễn được học bằng một nhiệm vụ ghép cặp; negative chặn sụp đổ.

Temperature và số negative quyết định loss đẩy cái gì, mạnh đến đâu.

Đánh giá bằng linear probe hoặc recall@k, không bằng loss.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; thử và , dự đoán trước probe F1 rồi kiểm lại.