Phân tích hành vi model

Model đọc hướng nét hay dấu góc?

Cùng điểm, khác hành vi

A và B đều đúng trên dữ liệu nguồn.

Camera mới làm một model thất bại.

Đúng trong điều kiện nào, nhờ thông tin nào?

Mục tiêu

- So hai model trên từng mẫu và từng nhóm dữ liệu.
- Thiết kế thí nghiệm kiểm model có dùng dấu hiệu tình cờ không.
- Dùng occlusion, saliency, Grad-CAM và biết giới hạn của chúng.

01

Từ điểm tổng đến giả thuyết

Bảng chéo theo ID

Lưu ID, nhãn, score, thuộc tính hợp lệ.

Đọc nhiều chỉ số theo nhóm, ghi số mẫu.

Bốn ô: cả hai đúng, chỉ A đúng, chỉ B đúng, cả hai sai.

Hai ô giữa phân biệt model; ô cả hai sai: xem ảnh trước.

HỎI NHANH

Trên cùng 100 ảnh validation, A và B đều đúng 90 ảnh. Có 6 ảnh A đúng còn B sai. Có bao nhiêu ảnh cả hai cùng sai?

A 0

B 4

C 6

D 10

Bốn ô của bảng chéo

	B đúng	B sai
A đúng	84	6
A sai	6	4

A và B cùng đúng 90 trên 100 ảnh

A và B cùng đúng 90 ảnh, nhưng mỗi model đúng riêng 6 ảnh.

hai ô giữa phân biệt hai model

ô cả hai sai: xem ảnh trước

HỎI NHANH

Model sai 300 ảnh validation, nhưng ta chỉ đủ thời gian xem kỹ 30 ảnh. Chọn 30 ảnh nào thì bức tranh về lỗi đáng tin nhất?

A 30 ảnh sai đầu tiên theo tên tệp, vì thứ tự tên tệp coi như ngẫu nhiên

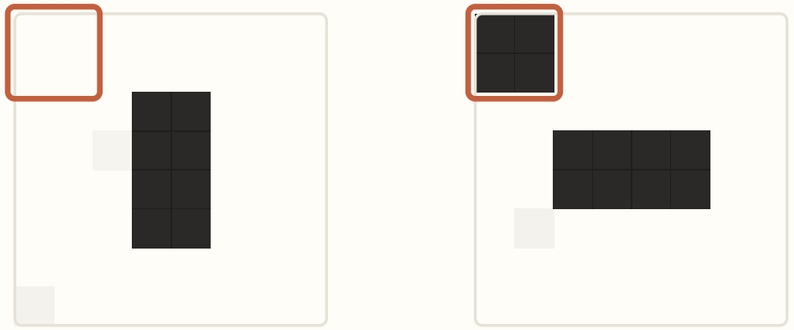
B 30 ảnh có heatmap rõ nhất, vì dễ giải thích cho cả đội

C 30 ảnh có score sát ngưỡng 0.5, vì đó là những ảnh khó nhất

D Lấy ngẫu nhiên trong từng nhóm, thêm vài ảnh sai mà score rất cao

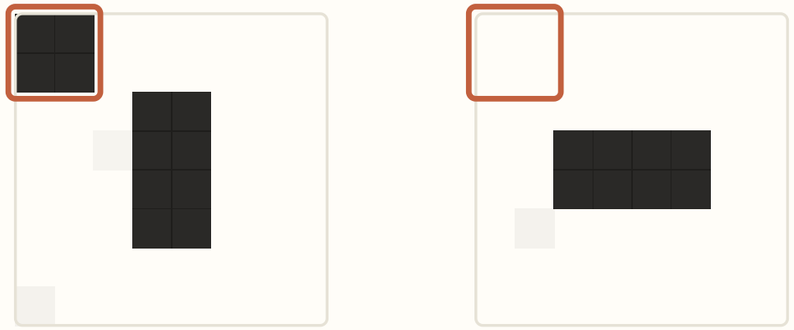
Một tương quan được tạo rõ

nguồn: góc sáng đi với nét ngang



đứng ngang

đổi góc: nhãn giữ nguyên



đứng ngang

khung cam: ô góc 2×2 mà model A đọc; model B chỉ đọc vùng nét ở giữa

Ở tập nguồn, ô góc sáng luôn đi với nét ngang; tập kiểm đảo ô góc.

Hai model minh họa

A: logistic regression đọc độ sáng ô góc.

B: logistic regression đọc shape score.

Biết trước mỗi model đọc gì để kiểm phép đánh giá.

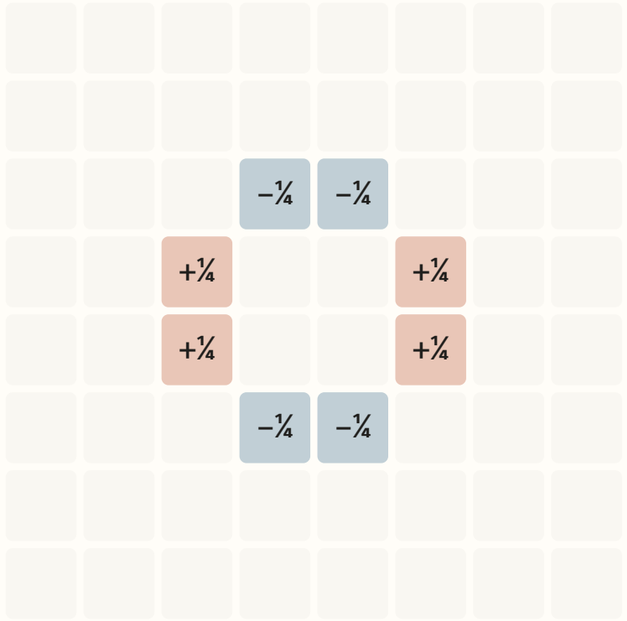
Shape score của một filter

Filter : bốn ô −, bốn ô −, còn lại 0.

Nét ngang sạch cho , nét đứng sạch cho ; dấu góc không góp vào score.

Filter hướng nét

$$(H - V)/4$$



+¼: chỉ thuộc nét ngang

−¼: chỉ thuộc nét đứng

ngang sạch: score +1

đứng sạch: score −1

ô góc nằm ngoài filter

Filter của model B chỉ có trọng số trên vùng nét, không có ở ô góc.

HỎI NHANH

Trong code, nét ngang chiếm `[3:5, 2:6]`. Dịch nó xuống một hàng thành `[4:6, 2:6]`, ảnh sạch, dấu góc giữ nguyên. Shape score bằng bao nhiêu?

A

B

C

D

Kiểm can thiệp giữ tín hiệu

```
print("same labels after intervention:", np.array_equal(labels, changed_labels))
print("shape features preserved:",
      np.allclose(features(normal_images)[1], features(changed_images)[1]))
```

KẾT QUẢ

```
same labels after intervention: True
shape features preserved: True
```

Kết quả cùng tập mẫu

KẾT QUẢ

```
normal A/B accuracy: 1.0 1.0
changed corner A/B accuracy: 0.0 1.0
A correct, B wrong: 0
B correct, A wrong: 40
```

HỎI NHANH

Trên tập changed corner, A có accuracy 0.0 chứ không phải khoảng 0.5. Con số này nói lên điều gì?

A Quyết định của A đi theo dấu góc trên mọi ảnh

B A đoán gần như ngẫu nhiên khi gặp ảnh lạ

C Nhãn của tập changed corner đã bị đảo nhầm

D A học được hướng nét, nhưng theo chiều ngược lại

HỎI NHANH

Nếu sinh `changed_images` bằng seed nhiễu 3 thay vì seed 2 như `normal_images`, phép so trước và sau mất đi điều gì?

A Không mất gì, vì nhiễu chỉ có độ lệch chuẩn 0.02

B Nhãn của hai tập không còn khớp nhau theo từng ID

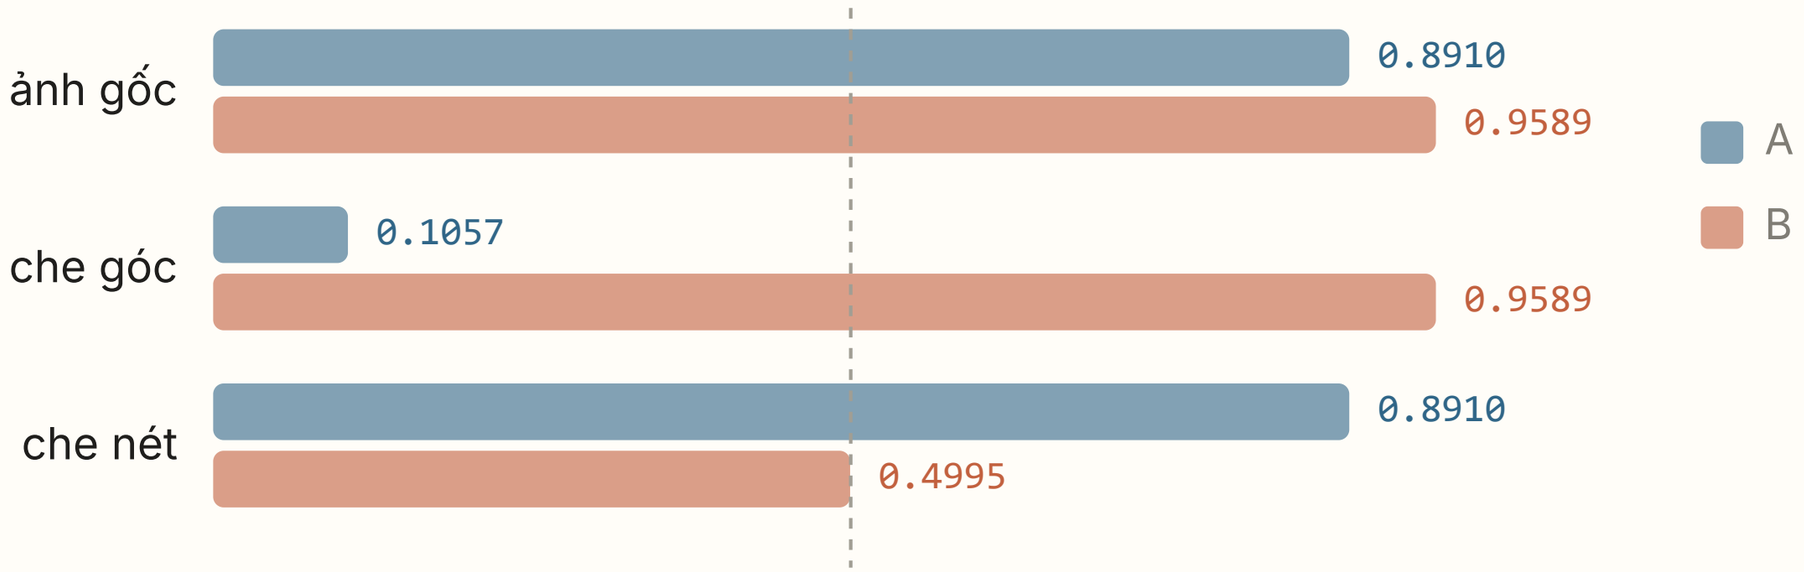
C Model B không còn dự đoán được trên ảnh mới

D Mất phép so cặp, vì mỗi cặp khác nhau cả nhiễu lẫn dấu góc

02

Che vùng, giữ đại lượng so

Xác suất lớp 1 khi che



xác suất lớp 1 (ngang) trước và sau khi che

Che góc làm A đổi hẳn dự đoán; che nét làm B đổi dự đoán.

HỎI NHANH

Che góc làm A đổi argmax từ lớp 1 sang lớp 0. Vì sao ta vẫn đọc xác suất của lớp 1, cả trước lẫn sau khi che?

A Để model không thể đổi nhãn dự đoán sau khi che

B Để so cùng một đại lượng trước và sau khi che

C Vì xác suất hai lớp luôn bằng nhau sau khi che

D Vì lớp argmax mới luôn có score thấp hơn lớp cũ

Baseline che ảnh có ảnh hưởng

Ô đen có thể là nhiễu ngoài phân phối.

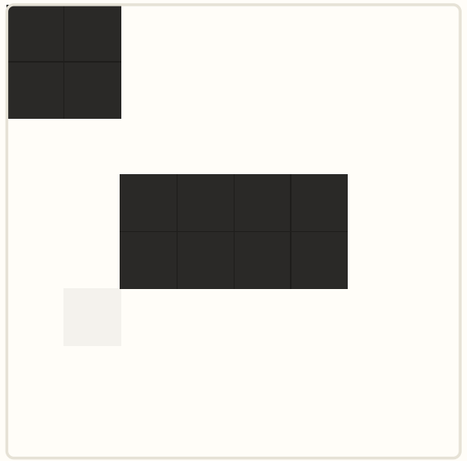
Thử nhiều baseline, cửa sổ và nhóm ảnh.

Hai tín hiệu thay thế nhau: che cả tổ hợp.

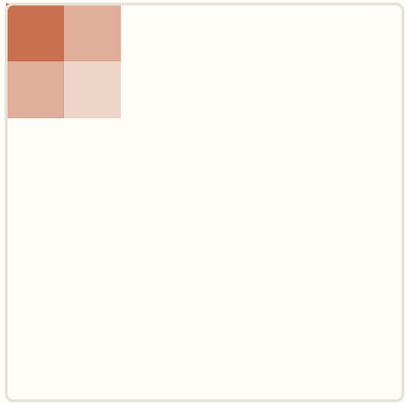
Che hết nét thì ảnh không còn giữ nhãn hướng.

Trượt cửa sổ che

ảnh ngang

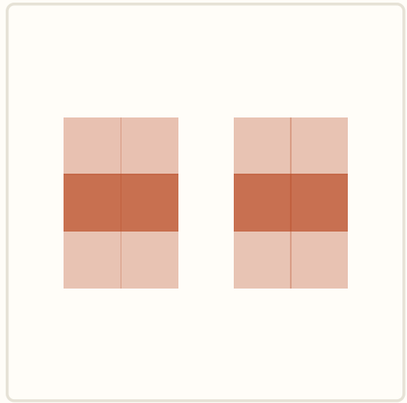


model A



giảm tối đa 0.79

model B

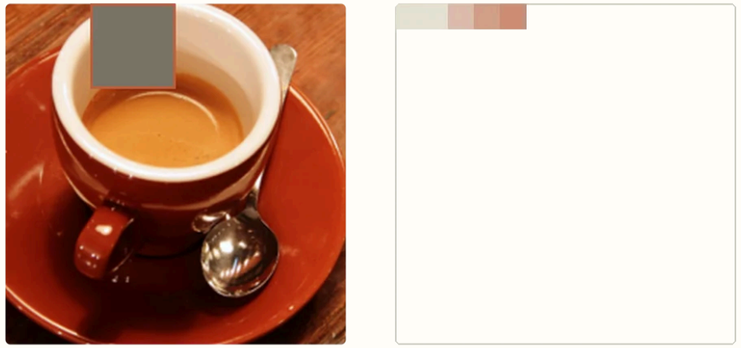


giảm tối đa 0.13

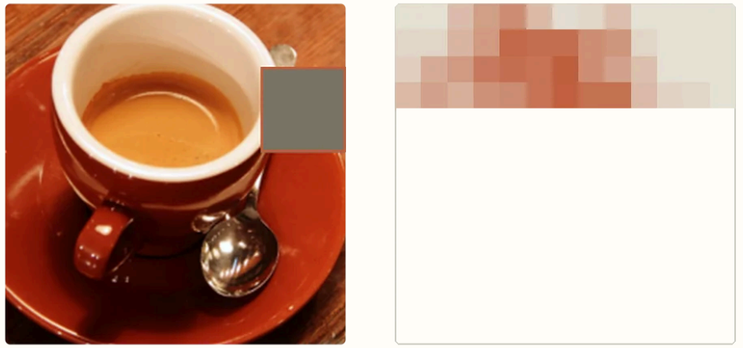
mỗi ô: score lớp 1 giảm bao nhiêu khi che cửa sổ 2×2 bắt đầu ở đó

Bản đồ occlusion: A chỉ nhạy với ô góc, B nhạy với vùng nét.

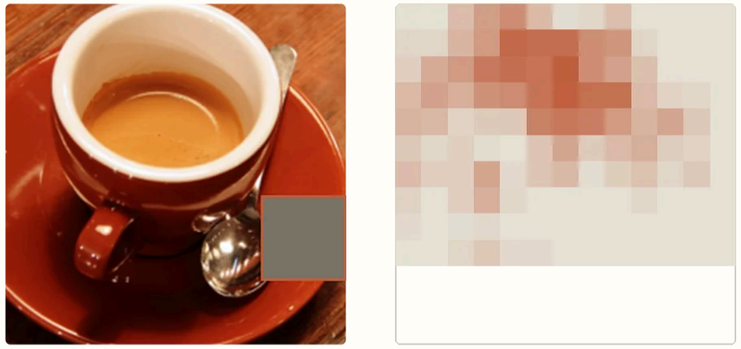
Occlusion trên ảnh thật



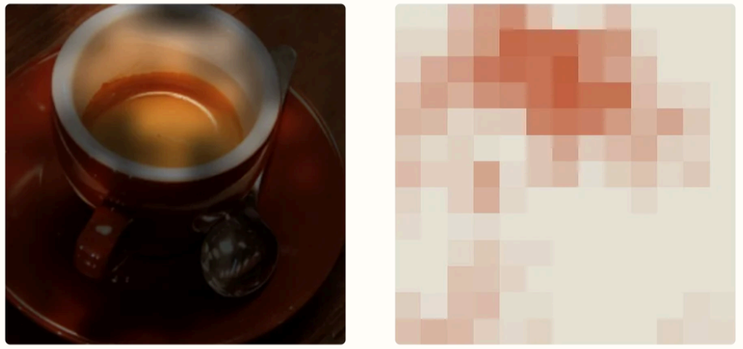
che ô hàng 1, cột 5: p(“espresso”) = 0.50 (gốc 0.85)



che ô hàng 4, cột 13: p(“espresso”) = 0.90 (gốc 0.85)



che ô hàng 10, cột 13: p(“espresso”) = 0.93 (gốc 0.85)



vùng che làm p(“espresso”) giảm mạnh nhất được giữ sáng: mặt tách cà phê

Che từng vùng ảnh: vùng nào làm xác suất lớp giảm nhiều thì càng cam.

HỎI NHANH

Ảnh , cửa sổ che , bước trượt 8 theo cả hai chiều, không padding. Không kể ảnh gốc, một ảnh cần bao nhiêu lượt forward để vẽ occlusion map?

A 196

B 729

C 784

D 50 176

03

Heatmap để đặt câu hỏi

Saliency bằng autograd

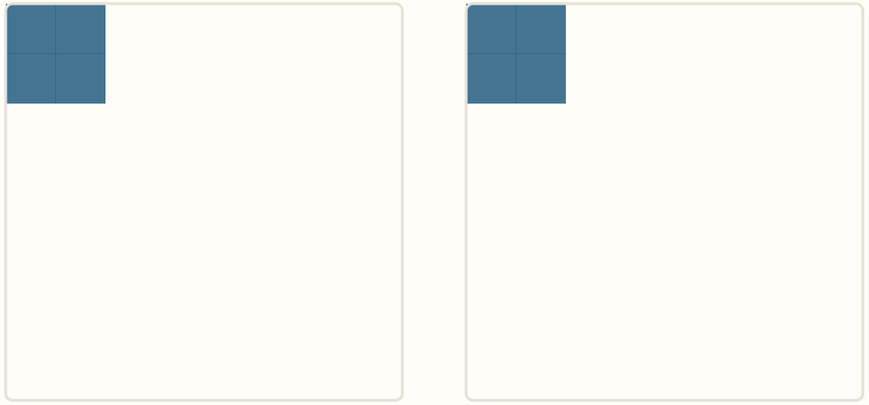
```
def saliency(name, image, use_probability=False):
    model, read_feature = readers[name]
    pixels = torch.tensor(image, requires_grad=True)
    score = (float(model.coef_[0, 0]) * read_feature(pixels)
             + float(model.intercept_[0]))
    score.backward()
    return pixels.grad.abs().numpy()
```

KẾT QUẢ

```
A corner: 1.0 | max: 1.0688 | same on vertical: True
B corner: 0.0 | max: 0.8026 | same on vertical: True
B max grad of probability: 0.0316
```

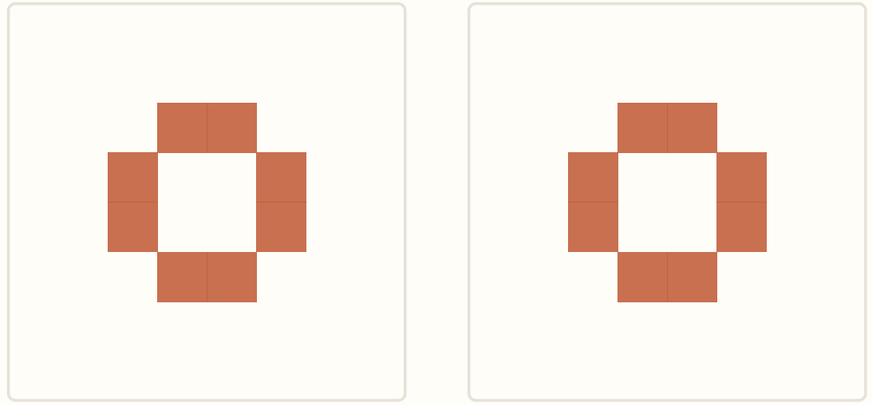
Hai saliency map

saliency của A



ảnh ngang ảnh đứng

saliency của B



ảnh ngang ảnh đứng

model tuyến tính: gradient chính là trọng số, giống nhau trên mọi ảnh

Saliency: A dồn vào ô góc, B dồn vào vùng nét.

HỎI NHANH

Saliency của B trên ảnh ngang và trên ảnh đứng trùng nhau từng ô. Điều đó cho biết gì?

A Model tuyến tính có gradient không phụ thuộc ảnh

B Hai ảnh có nội dung giống nhau ở vùng giữa

C Autograd chưa bật nên map trả về giá trị mặc định

D B đã học đúng hướng nét trên mọi ảnh có thể gặp

Saliency và Grad-CAM

Saliency: một forward, một backward.

Bão hòa: gradient của xác suất nhỏ đi khoảng 25 lần.

Grad-CAM: trọng số kênh ở một lớp conv.

Lớp sâu có nghĩa nhưng thô: cho ảnh .

Grad-CAM

là score của lớp đang xét; là feature map kênh , có kích thước . Lấy trung bình gradient để gán trọng số cho mỗi kênh.

HỎI NHANH

Lớp được chọn có hai kênh . Kênh có mọi gradient bằng 0.5. Kênh có gradient . Map Grad-CAM bằng bao nhiêu?

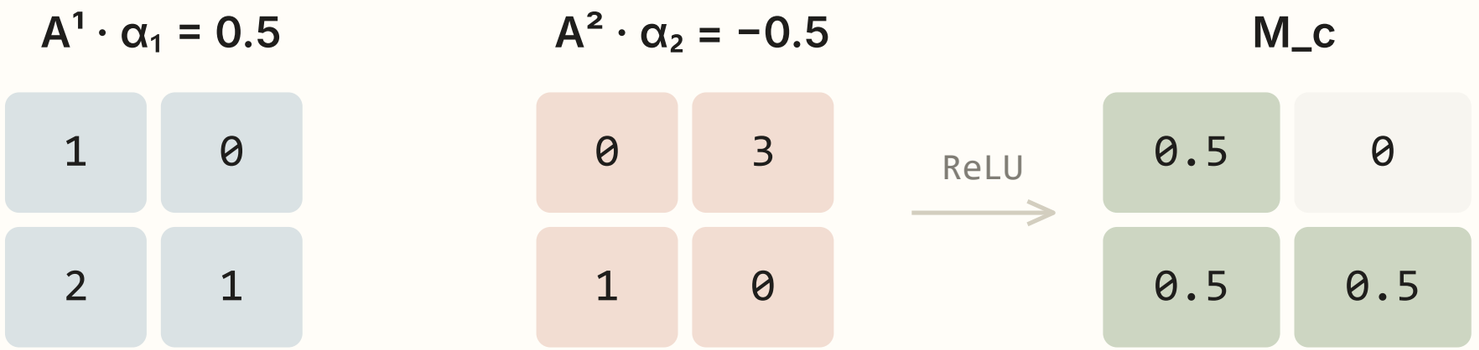
A

B

C

D

Grad-CAM trên lưới nhỏ



α = trung bình gradient theo không gian

$0.5 \cdot A^1 - 0.5 \cdot A^2 = (0.5, -1.5; 0.5, 0.5) \rightarrow \text{ReLU}$

Grad-CAM trên lưới nhỏ: ô góc trên phải ra −1.5, ReLU đưa về 0.

04

Ma trận kiểm

Mỗi model thắng một hàng

KẾT QUẢ

condition	A	B
normal	1.000	1.000
changed corner	0.000	1.000
shift 1 row	1.000	0.775
shift 2 rows	1.000	0.500

Dịch một hàng: shape score của ảnh ngang , B quyết định theo nhiễu.

Ma trận kiểm

	A (đọc góc)	B (đọc nét)
normal	1.000	1.000
changed corner	0.000	1.000
shift 1 row	1.000	0.775
shift 2 rows	1.000	0.500

mỗi model thắng
ở một hàng khác

A sụp khi đổi ô góc; B giữ được nhưng tụt khi nét dịch chỗ.

HỎI NHANH

Hãy đoán trước một hàng chưa có trong ma trận: dịch nét hai hàng **và** đổi dấu góc cùng lúc. Accuracy của A và B lần lượt là bao nhiêu?

A A 1.0, B 0.5

B A 0.0, B 1.0

C A 0.5, B 0.5

D A 0.0, B 0.5

Adversarial: FGSM

Logit tuyến tính: đổi .

Chiếu về giới hạn đề, kiểm lại, lưu input và seed.

Một kết luận có phạm vi

A phụ thuộc dấu góc trong thí nghiệm.

B sai khi nét dịch hai hàng.

Ghi điều kiện đã kiểm và chưa kiểm.

HỎI NHANH

Pipeline đưa ảnh trong qua `Normalize` theo mean `(0.485, 0.456, 0.406)` và std của ImageNet, rồi vào model. Code occlusion gán 0 vào vùng che **sau** bước `Normalize`. Vùng che thực chất có màu gì?

A Màu trung bình của ImageNet, một màu xám hơi ấm

B Màu đen, vì giá trị 0 luôn là pixel tối nhất

C Màu trắng, vì Normalize đảo dấu giá trị pixel

D Không xác định được, vì Normalize là phép phi tuyến

Cùng “che bằng 0”, hai màu

gán 0 trước Normalize



gán 0 sau Normalize



sau Normalize, 0 ứng với mean ImageNet:

`(124, 116, 104)`

che đen phải gán ≈ −2.1 ở kênh R

Gán 0 trước Normalize cho ô đen; gán 0 sau Normalize cho ô màu trung bình.

Khi đi thi

- Lưu prediction theo ID.
- Một giả thuyết, một can thiệp.
- Heatmap để chọn thí nghiệm.

05

Luyện đề

LUYỆN ĐỀ 1

Một model phát hiện ảnh lỗi đoán ngẫu nhiên. Nó không nhìn ảnh, cứ mỗi ảnh gọi "lỗi" với xác suất 1/2. Camera X có 50% ảnh lỗi thật, camera Y có 10%. Đại lượng nào **khác nhau** giữa hai camera?

A Recall, tức tỉ lệ ảnh lỗi thật được gọi là lỗi

B False positive rate, tức tỉ lệ ảnh tốt nhưng bị gọi là lỗi

C Precision, tức tỉ lệ lỗi thật trong các ảnh bị gọi là lỗi

D Tỉ lệ ảnh bị model gọi là lỗi trên toàn nhóm

PHỎNG THEO CMU 10-601 · Exam 2 Practice · Q5.3

LUYỆN ĐỀ 2

Một mạng một chiều gồm một filter convolution cho ra , các giá trị khác nhau, rồi . Ảnh có pattern ở hai vị trí: lớn nhất, lớn nhì. Saliency theo cho kết quả nào?

A Chỉ khác 0, và bằng

B Chỉ khác 0, và bằng 1

C và cùng khác 0

D với mọi

PHỎNG THEO MIT 6.036 · Final, Spring 2022 · Q8(d)

LUYỆN ĐỀ 3

Đề phân loại hình tròn, tam giác và chữ nhật trên nền trắng. Vị trí, cỡ, góc xoay và màu của hình đều ngẫu nhiên, và chỉ có 200 ảnh có nhãn. Model đạt macro-F1 0.90 trên validation, nhưng hầu hết lỗi là ảnh hình màu đỏ bị gọi là tam giác. Thí nghiệm nào kiểm nhanh nhất giả thuyết “model dùng màu”?

A Vẽ Grad-CAM cho vài ảnh tam giác đỏ và xem vùng sáng

B Đổi màu hình bằng code, giữ hình dạng, rồi so dự đoán theo ID

C Train thêm epoch rồi so lại macro-F1 trên validation

D Bỏ kênh R khỏi mọi ảnh rồi train lại model từ đầu cho chắc

PHỎNG THEO USA-NA-AIO 2026 · Vòng 2 · Ngày 2 · Problem 4

Chốt ý

Quan sát theo ID, can thiệp có đối chứng, đọc score của cùng lớp.

Heatmap gợi giả thuyết; ma trận kiểm ghi phạm vi.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; dịch nét lên một hàng (`rows=-1`), đoán trước accuracy của A và B rồi mới chạy.