Dữ liệu âm thanh

Từ một dãy số đến ảnh phổ có trục đúng

Một giây âm thanh nói gì?

Điện thoại trả hàng nghìn số.

Waveform dày đặc chưa cho biết âm nào xuất hiện trước, âm nào xuất hiện sau.

Cần một biểu diễn cho thấy tần số nào xuất hiện ở lúc nào: spectrogram.

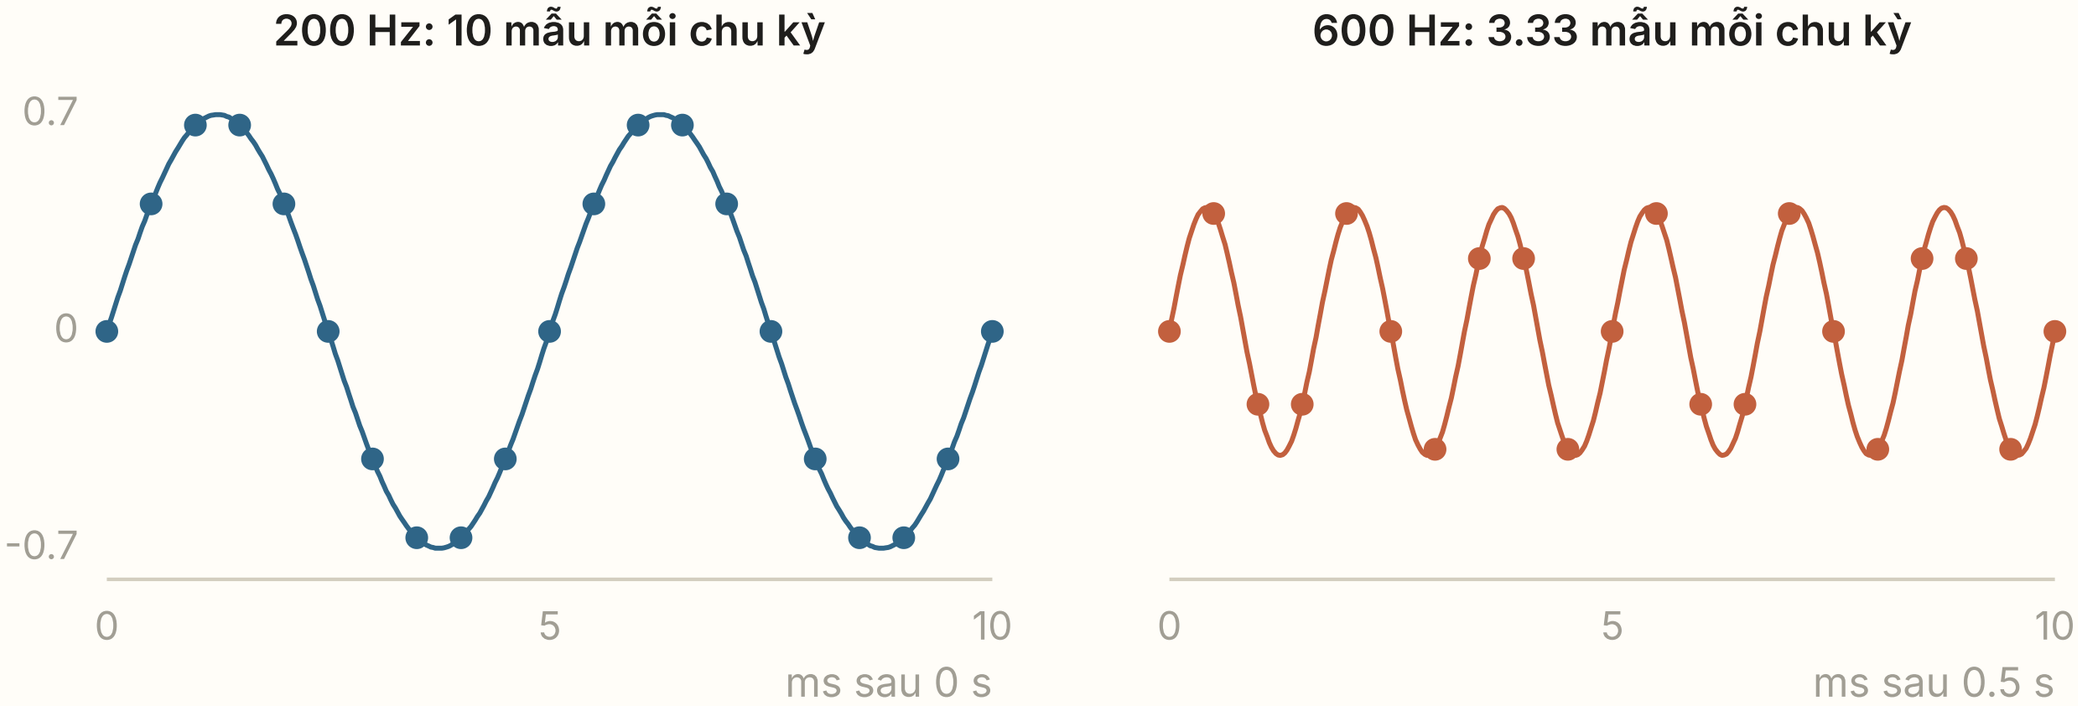
Mục tiêu

- Tính thời lượng từ số mẫu và sample rate; đổi sample rate không bị aliasing.
- Đọc spectrogram; hiểu window và hop của STFT.
- Tự tính log-mel.
- Chọn augmentation hợp với nhãn.

01

Waveform và lấy mẫu

Phóng to 20 ms



mỗi chấm là một mẫu, cách nhau 0.5 ms (sample rate 2000 Hz)

Ở 2000 Hz, âm 200 Hz có 10 mẫu mỗi chu kỳ, âm 600 Hz chỉ khoảng 3.3 mẫu.

Giữ đúng đơn vị

$$t_n = \frac{n}{f_s}, \qquad T = \frac{N}{f_s}.$$

f_s là số mẫu mỗi giây; N là tổng số mẫu. n là chỉ số mẫu tính từ 0.

2000 mẫu ở 2000 Hz dài **1 giây**.

WAV 16-bit: chia cho 32 768 để về $[-1, 1)$. Stereo: tính theo trục mẫu.

Dữ liệu biết trước đáp án

Nửa đầu: sine 200 Hz.

Nửa sau: sine 600 Hz.

Spectrogram đúng phải cho thấy 200 Hz rồi 600 Hz.

```
print(waveform.shape)
print(f"thời lượng = {duration:.3f} s")
print(f"khoảng mẫu = {interval_ms:.3f} ms")
```

KẾT QUẢ

```
(2000,)
thời lượng = 1.000 s
khoảng mẫu = 0.500 ms
```

HỎI NHANH

File WAV stereo 16 kHz được đọc thành mảng shape `(48000, 2)`, tức 48 000 mẫu cho mỗi kênh. File dài bao nhiêu giây?

A 0.000125 giây

B 1.5 giây

C 3 giây

D 6 giây

HỎI NHANH

Microphone phải của một bản ghi stereo bị đấu ngược cực, nên kênh phải đúng bằng kênh trái đổi dấu. Downmix bằng cách lấy trung bình hai kênh thì được gì?

A Toàn số 0, vì hai kênh triệt tiêu nhau

B Giống kênh trái, vì trung bình giữ nguyên dạng sóng

C Biên độ gấp đôi kênh trái, vì hai kênh cộng lại

D Kênh trái đổi dấu, vì kênh phải chiếm ưu thế

Aliasing xảy ra trước model

Cosine 350 Hz và 650 Hz có cùng mẫu khi $f_s = 1000$ Hz.

Nyquist frequency: $f_s/2$. Thành phần $f \in (f_s/2, f_s)$ hiện ra ở $f_s - f$.

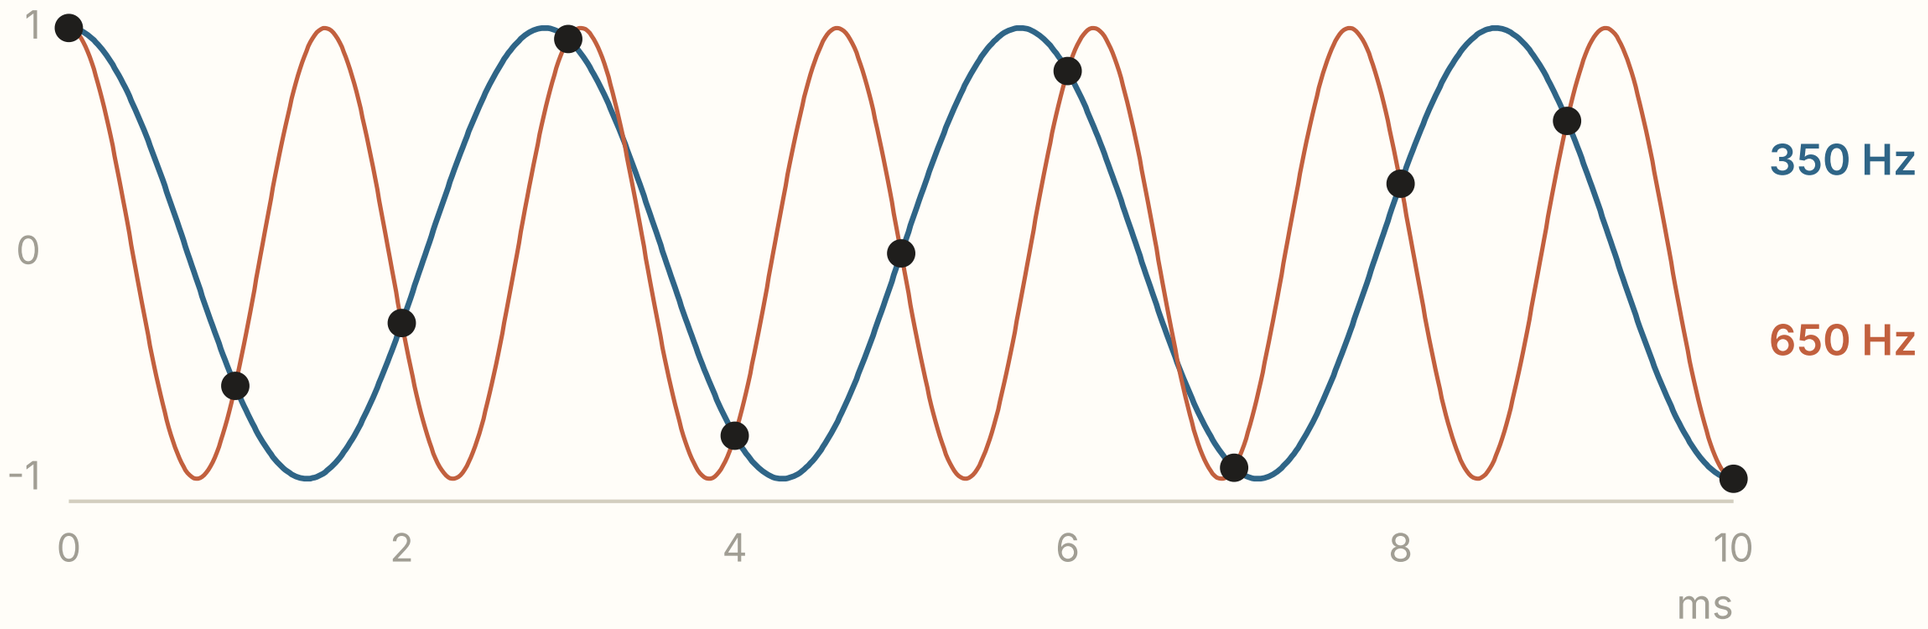
```
print(np.allclose(low_tone, high_tone))
```

KẾT QUẢ

```
True
```

Thông tin không còn phân biệt được trong input.

Hai cosine, cùng các chấm



lấy mẫu 1000 Hz: hai cosine đi qua đúng cùng các chấm, 650 = 1000 − 350

Lấy mẫu 1000 Hz: cosine 350 Hz và 650 Hz đi qua đúng cùng các điểm mẫu.

Bỏ mẫu hay lọc rồi bỏ mẫu

`waveform[::2]`: còn 1000 Hz, Nyquist 500 Hz.

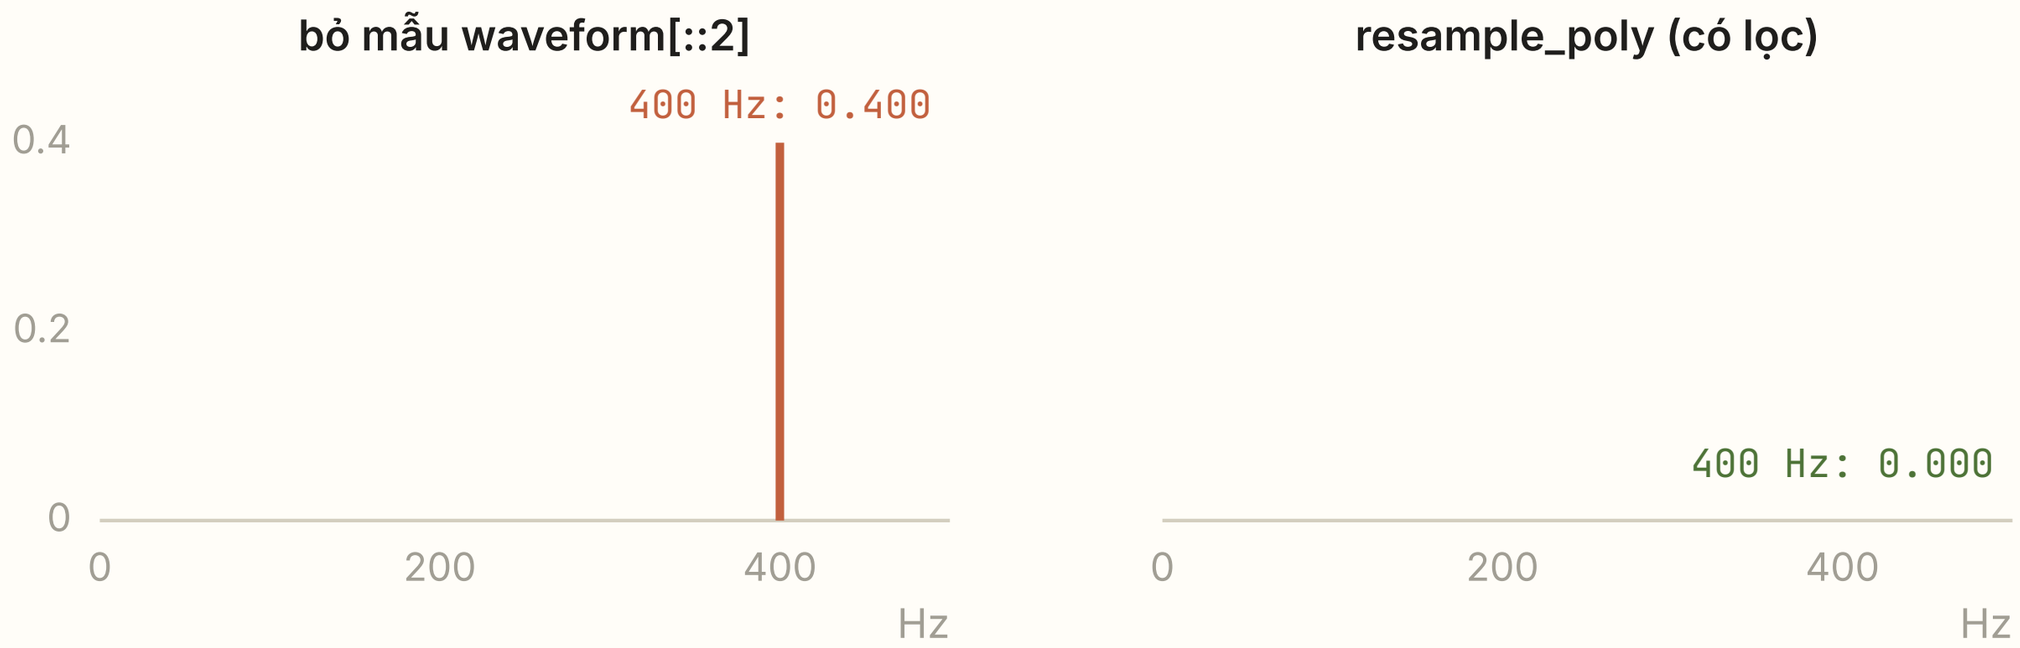
Đoạn 600 Hz gập về 400 Hz, vì $1000 - 600 = 400$.

KẾT QUẢ

```
bỏ mẫu: 1000 mẫu, biên độ ở 400 Hz = 0.400
có lọc: 1000 mẫu, biên độ ở 400 Hz = 0.000
```

`resample_poly` lọc thông thấp trước: mất 600 Hz nhưng không bịa âm mới.

Phổ sau khi hạ sample rate



nửa sau chỉ có âm 600 Hz; ở 1000 Hz, Nyquist còn 500 Hz

Bỏ mẫu sinh âm giả 400 Hz; resample_poly lọc trước nên không có.

Metadata khác resample

Giữ 2000 mẫu nhưng gắn 4000 Hz: phát trong 0.5 giây.

Resample lên 4000 mẫu ở 4000 Hz: vẫn 1 giây.

KẾT QUẢ

```
đổi metadata: 0.500 s
resample: 1.000 s
```

Upsample không thêm âm cao mà bản ghi chưa từng có.

HỎI NHANH

Thu âm ở 8000 Hz mà không có bộ lọc chống aliasing, trong khi trong phòng có tiếng rít 5000 Hz. Trên spectrogram của bản ghi, tiếng rít hiện ra ở đâu?

A Ở 5000 Hz, đúng vị trí của nó

B Ở 1000 Hz, tức phần vượt quá Nyquist

C Không thấy, vì nó vượt Nyquist 4000 Hz

D Ở 3000 Hz, sau khi gập qua mốc Nyquist

HỎI NHANH

Clip 16 kHz dài 2 giây chứa tiếng còi 1000 Hz. Một bước tiền xử lý chỉ sửa header thành 24 kHz, giữ nguyên mảng. Phát lại, hoặc đưa vào model 24 kHz, thì clip ra sao?

A Dài 2 giây, còi 1000 Hz, vì mảng không đổi

B Dài khoảng 1.33 giây, còi 1500 Hz

C Dài khoảng 1.33 giây, còi 667 Hz

D Dài 3 giây, còi 1500 Hz

02

STFT: tần số theo thời gian

Cắt frame rồi FFT

Window $L = 200$ mẫu, tức 100 ms.

Hop $H = 100$ mẫu, tức 50 ms.

Hann window làm hai đầu frame nhỏ dần.

Không padding:

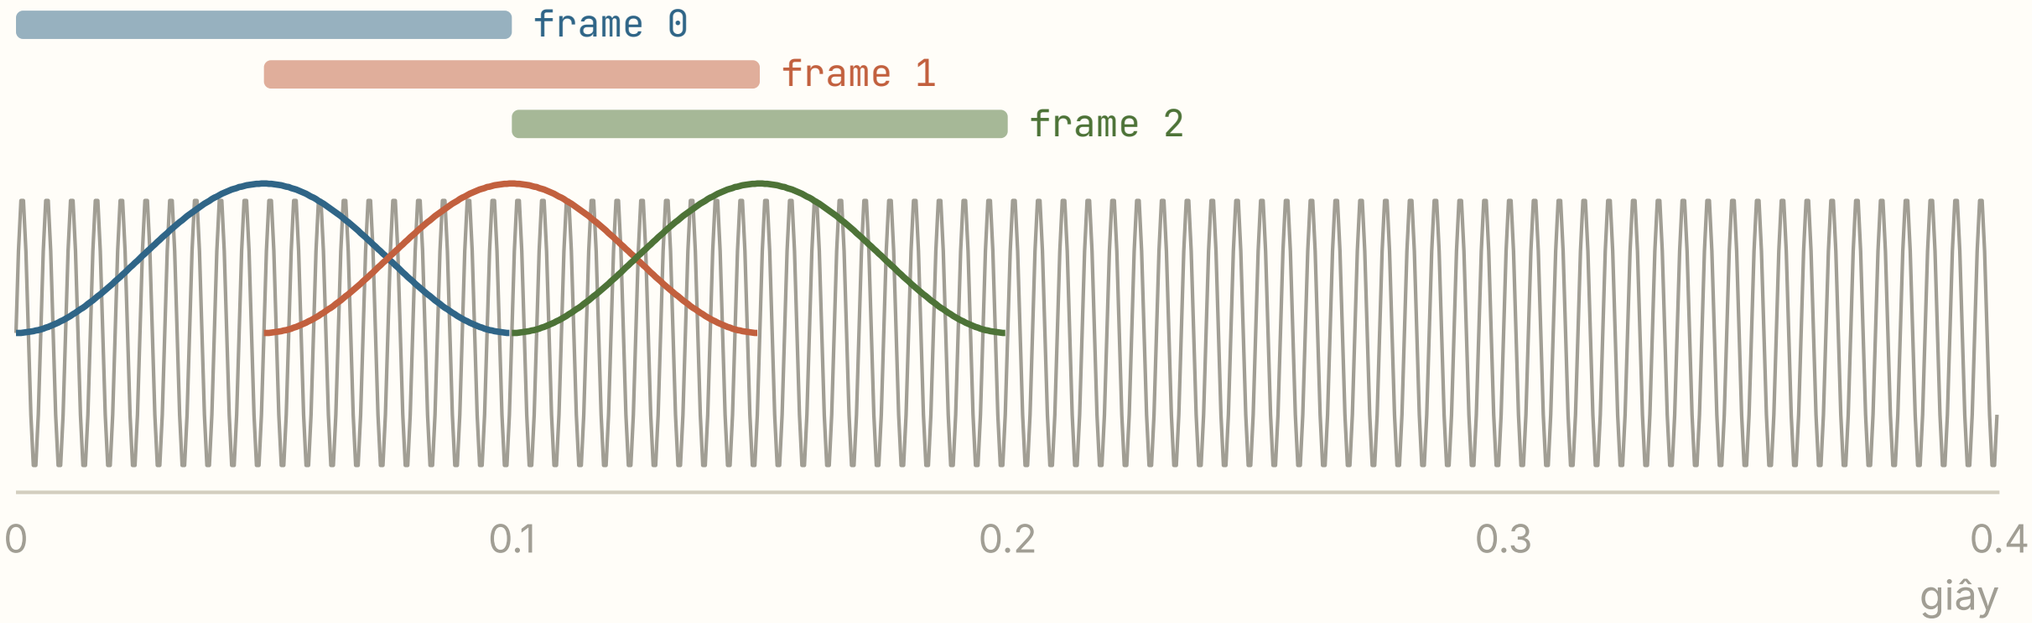
$$F = 1 + \left\lfloor \frac{N - L}{H} \right\rfloor = 19.$$

Hop quyết định bước trượt; window quyết định đoạn được quan sát.

`center=True` đệm $L/2$ mỗi đầu:

$$F = 1 + \left\lfloor \frac{N}{H} \right\rfloor .$$

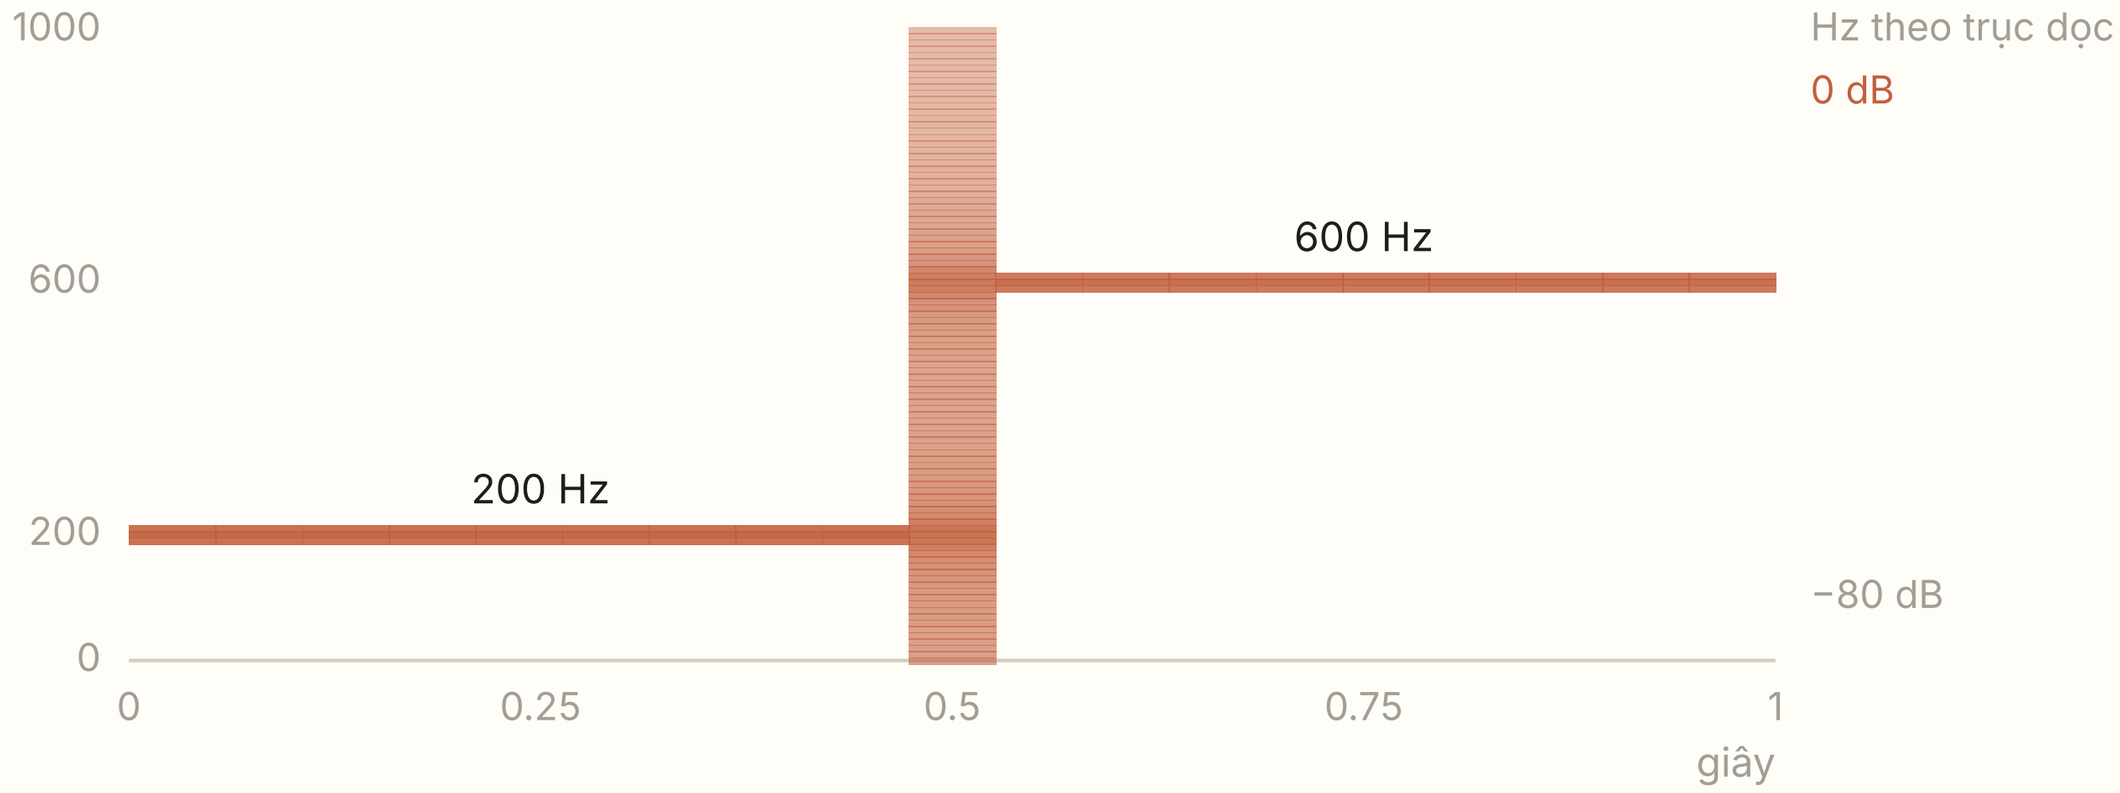
Window, hop và Hann



window 200 mẫu (100 ms), hop 100 mẫu (50 ms): mỗi frame chồng nửa frame trước; đường cong là Hann

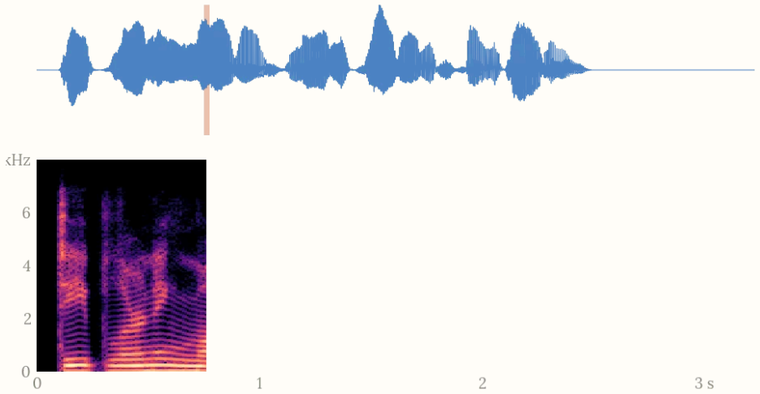
STFT chia waveform thành các frame chồng nửa nhau, nhân cửa sổ Hann.

Hai dải xuất hiện ở hai lúc

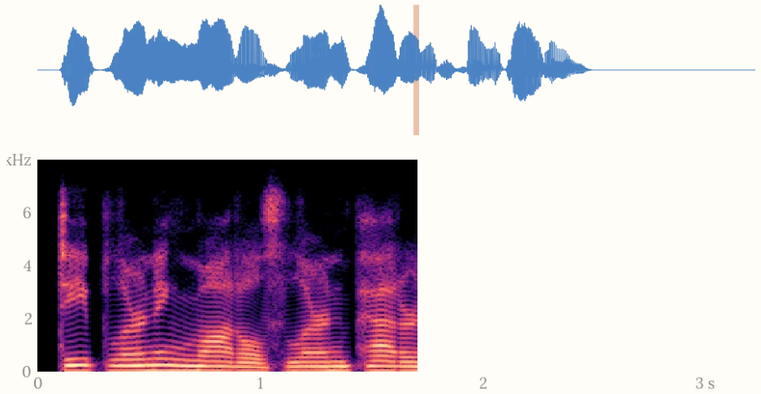


Spectrogram: 200 Hz ở nửa giây đầu, 600 Hz ở nửa giây sau.

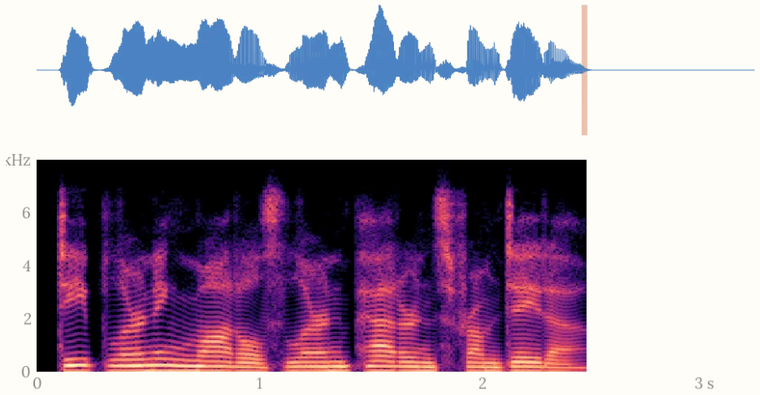
STFT trên một câu đọc thật



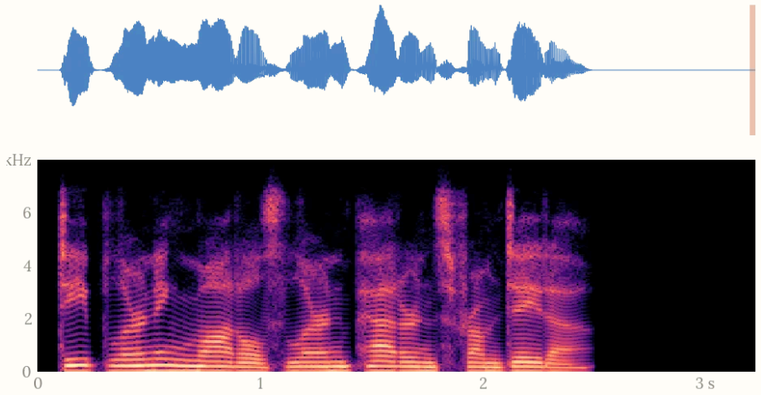
khung 76/321: cửa sổ 25 ms bắt đầu ở 750 ms, FFT cho một cột của spectrogram



khung 170/321: cửa sổ 25 ms bắt đầu ở 1690 ms, FFT cho một cột của spectrogram



khung 246/321: cửa sổ 25 ms bắt đầu ở 2450 ms, FFT cho một cột của spectrogram



đủ 321 khung, mỗi khung cách nhau 10 ms: câu “Deep learning models learn patterns from data.”

Cửa sổ 25 ms trượt trên waveform; mỗi vị trí qua FFT thành một cột spectrogram.

Đọc shape và đỉnh

```
print(power.shape)
peaks = np.argmax(power[:, [0, -1]], axis=0)
print(frequencies[peaks])
print(centers[[0, -1]].round(2))
```

KẾT QUẢ

```
(101, 19)
[200. 600.]
[0.05 0.95]
```

101 hàng: bin tần số.

19 cột: frame.

Power trong bài là bình phương biên độ tương đối, không phải watt/Hz.

HỎI NHANH

Tiếng nói 16 kHz, window 400 mẫu tức 25 ms, không zero-padding. `rfft` của một frame cho bao nhiêu bin, và các bin cách nhau bao nhiêu Hz?

A 200 bin, cách nhau 40 Hz

B 201 bin, cách nhau 20 Hz

C 400 bin, cách nhau 20 Hz

D 201 bin, cách nhau 40 Hz

HỎI NHANH

Giữ window length 200 mẫu, giảm hop từ 100 xuống 50 mẫu trên waveform của bài. Điều gì thay đổi trực tiếp?

A Có nhiều frame hơn trên cùng bản ghi

B Mỗi frame quan sát một đoạn dài gấp đôi

C Nyquist frequency tăng lên gấp đôi

D Mỗi bin tần số rộng ra gấp đôi

Window và độ phân giải

Window dài: tách tần số gần nhau tốt hơn, nhưng nhòe theo thời gian.

Window ngắn: định vị sự kiện nhanh tốt hơn, đỉnh phổ rộng hơn.

Zero-padding: lưới bin dày hơn, f_s/n_{fft} thay cho f_s/L.

Không thêm chu kỳ quan sát, nên không tăng độ phân giải thật.

HỎI NHANH

Hai bài toán có cùng sample rate. Bài (1) định vị tiếng gõ phím chỉ kéo dài vài mili giây. Bài (2) phân biệt hai nốt nhạc ngân dài, cao độ chênh nhau vài Hz. Nên chọn window thế nào?

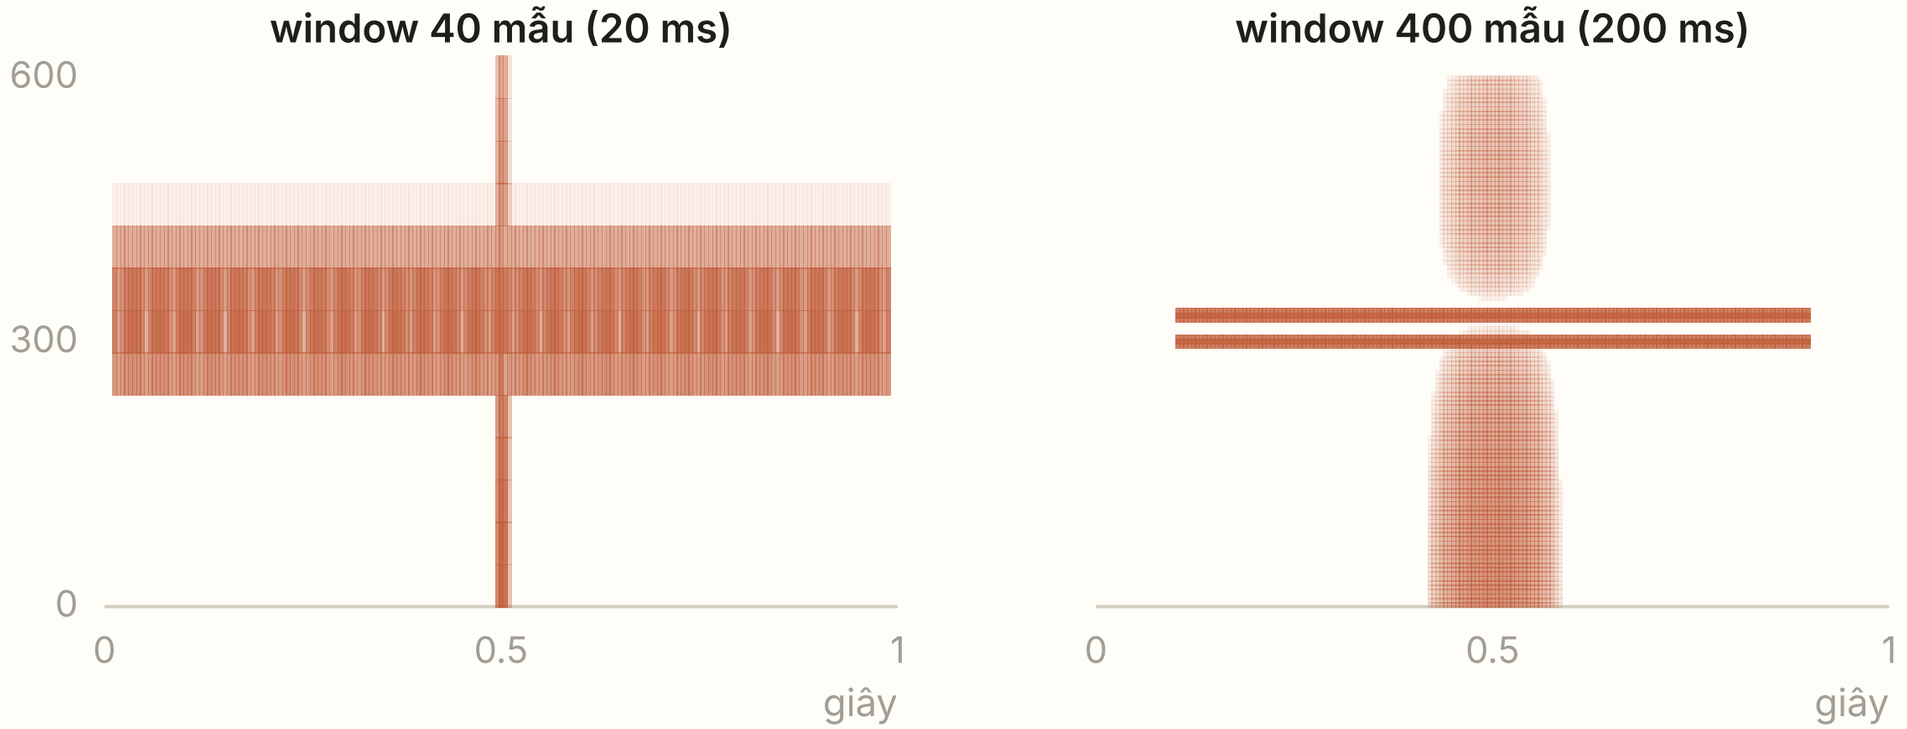
A Bài (1) dùng window dài, bài (2) dùng window ngắn

B Như nhau, vì window chỉ đổi số cột thời gian

C Bài (1) dùng window ngắn, bài (2) dùng window dài

D Cả hai dùng window dài, rồi giảm hop để định vị

Đánh đổi thời gian và tần số



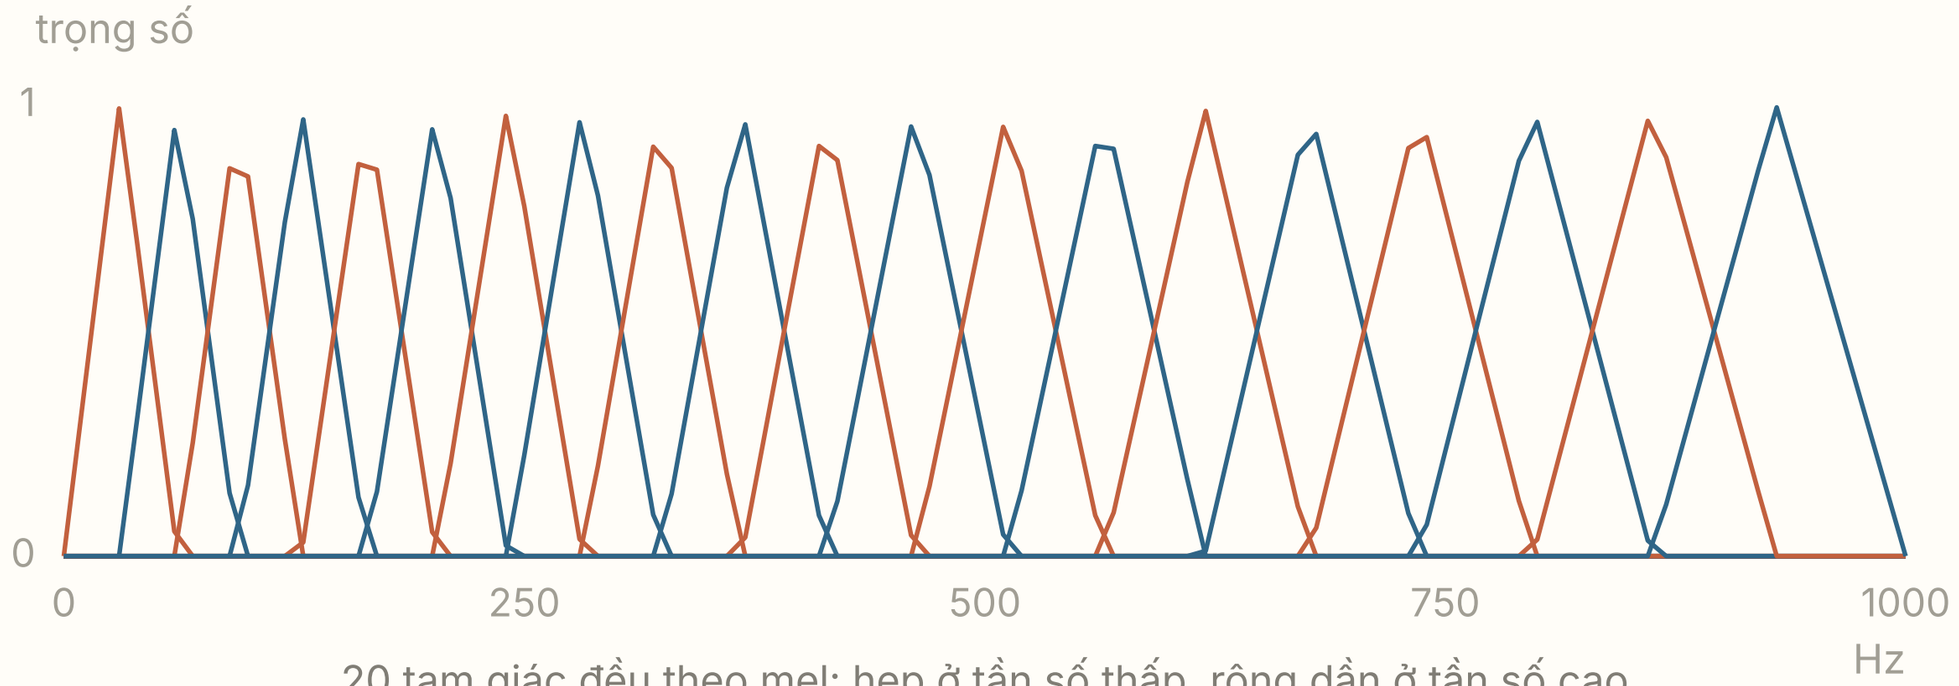
tín hiệu: hai âm 300 Hz và 330 Hz, cộng một tiếng gõ ngắn ở 0.5 s

Cửa sổ ngắn định vị tiếng gõ sắc nhưng nhòe tần số; cửa sổ dài thì ngược lại.

03

Mel và log

Gộp 101 bin thành 20 band



20 tam giác đều theo mel: hẹp ở tần số thấp, rộng dần ở tần số cao

Bộ lọc mel hẹp ở tần số thấp, rộng dần ở tần số cao.

HỎI NHANH

Bộ lọc của bài đặt 22 mốc đều theo mel trên dải 0–1000 Hz. Hai mốc đầu cách nhau khoảng 30 Hz. Hai mốc cuối cách nhau khoảng bao nhiêu?

A Khoảng 70 Hz, vì band cao rộng hơn

B Khoảng 30 Hz, vì các mốc được chia đều

C Khoảng 15 Hz, vì band cao hẹp hơn

D Khoảng 1000 Hz, vì band cuối phủ cả trục

Hai phép biến đổi

$$M = WP.$$

`(20,101) @ (101,19)` cho `(20,19)`.

$$L = 10 \log_{10} \frac{\max(M, \varepsilon)}{M_{\text{ref}}}.$$

Mốc của hình là đỉnh clip; quy ước mel là HTK.

HỎI NHANH

Mel power có phần tử bằng 0. Trước khi lấy log, vì sao người ta thường tính $\log(\max(\text{power}, \varepsilon))$ với $\varepsilon > 0$?

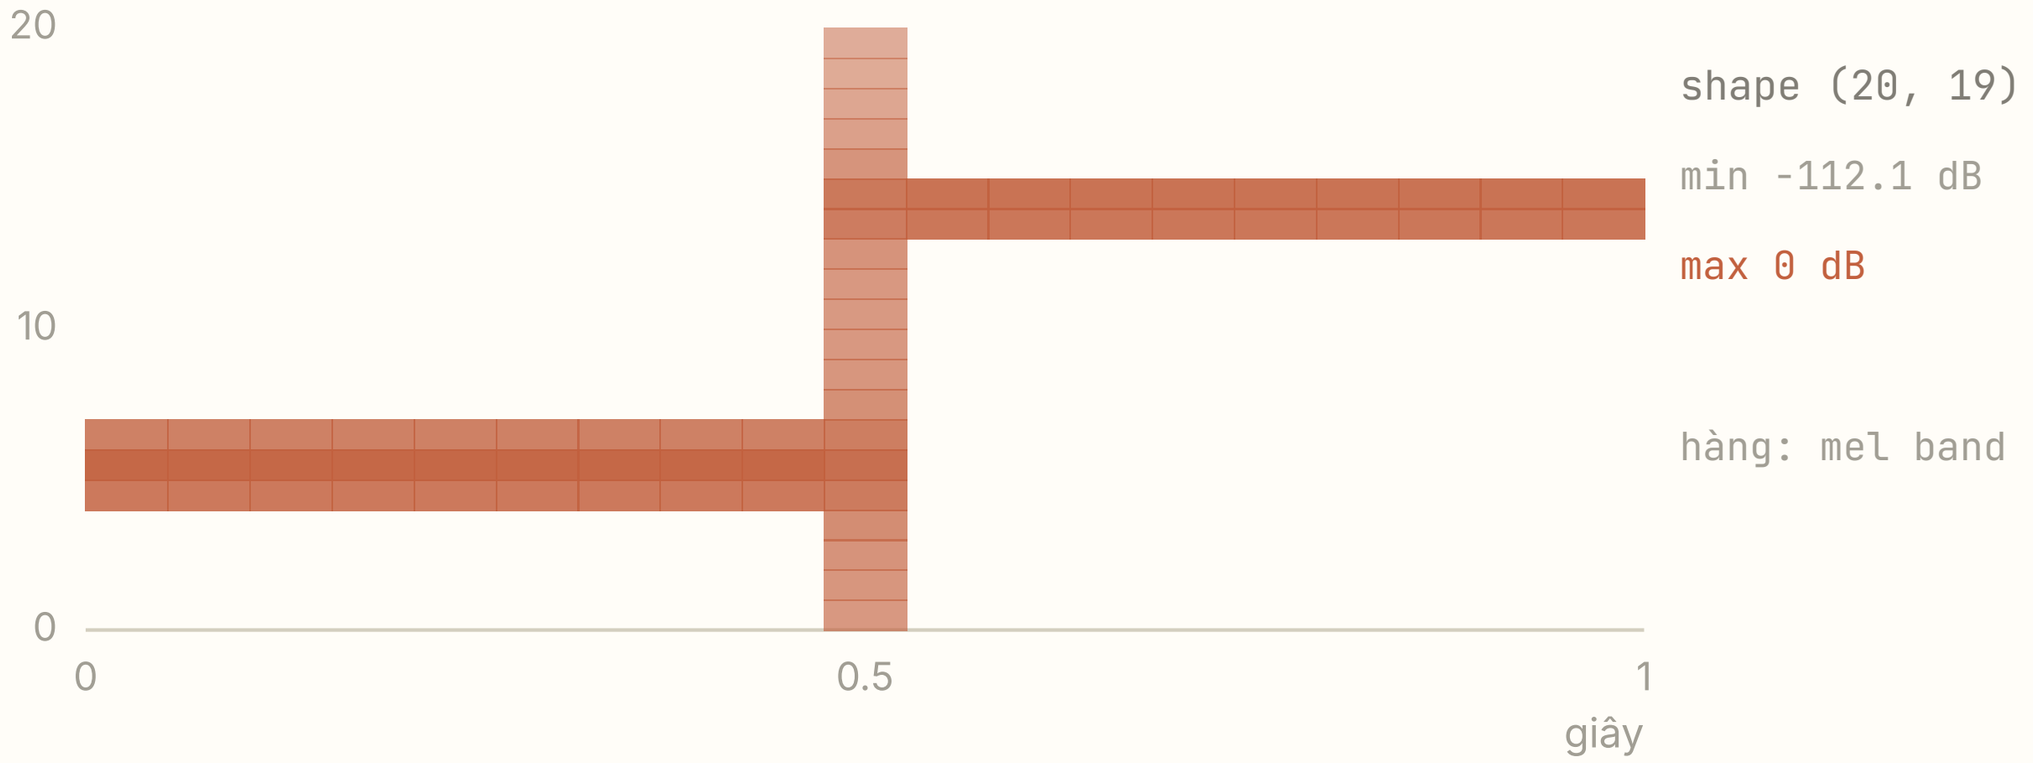
A Để mọi mel band có mean bằng 0

B Để log hữu hạn ở những ô có power bằng 0

C Để tăng độ phân giải tần số của STFT

D Để resample waveform về sample rate của model

Log-mel của clip



Log-mel: năng lượng ở band thấp nửa đầu, band cao hơn nửa sau.

Một mel band

Power $(1, 4, 1)$, trọng số $(0.5, 1, 0.5)$:

$$M = 0.5 + 4 + 0.5 = 5.$$

Mốc 5 cho 0 dB; power 0.5 cho -10 dB.

KẾT QUẢ

```
(20, 101) (20, 19)
[-112.1    0. ]
True
```

`True` kiểm mọi giá trị log-mel đều hữu hạn. Chặn trước log để tránh `-inf`; dải hiển thị có thể hẹp hơn dải số.

04

Chuẩn hóa và augmentation

Peak normalization

$(0, 0.2, -0.4, 0.2)$ chia cho 0.4:

KẾT QUẢ

```
[ 0.   0.5 -1.   0.5]
[0. 0. 0. 0.]
RMS trước = 0.245
```

Clip toàn 0 giữ nguyên, không chia cho peak 0.

Chuẩn hóa từng clip có thể xóa thông tin âm lượng hữu ích.

HỎI NHANH

Đề phân loại máy bơm “bình thường” và “kẹt”, ghi bằng cùng một microphone đặt cố định. Máy kẹt rung mạnh hơn: dạng sóng gần giống máy bình thường, nhưng biên độ gấp khoảng 3 lần. Một đội peak-normalize từng clip trước khi tính log-mel. Chuyện gì xảy ra?

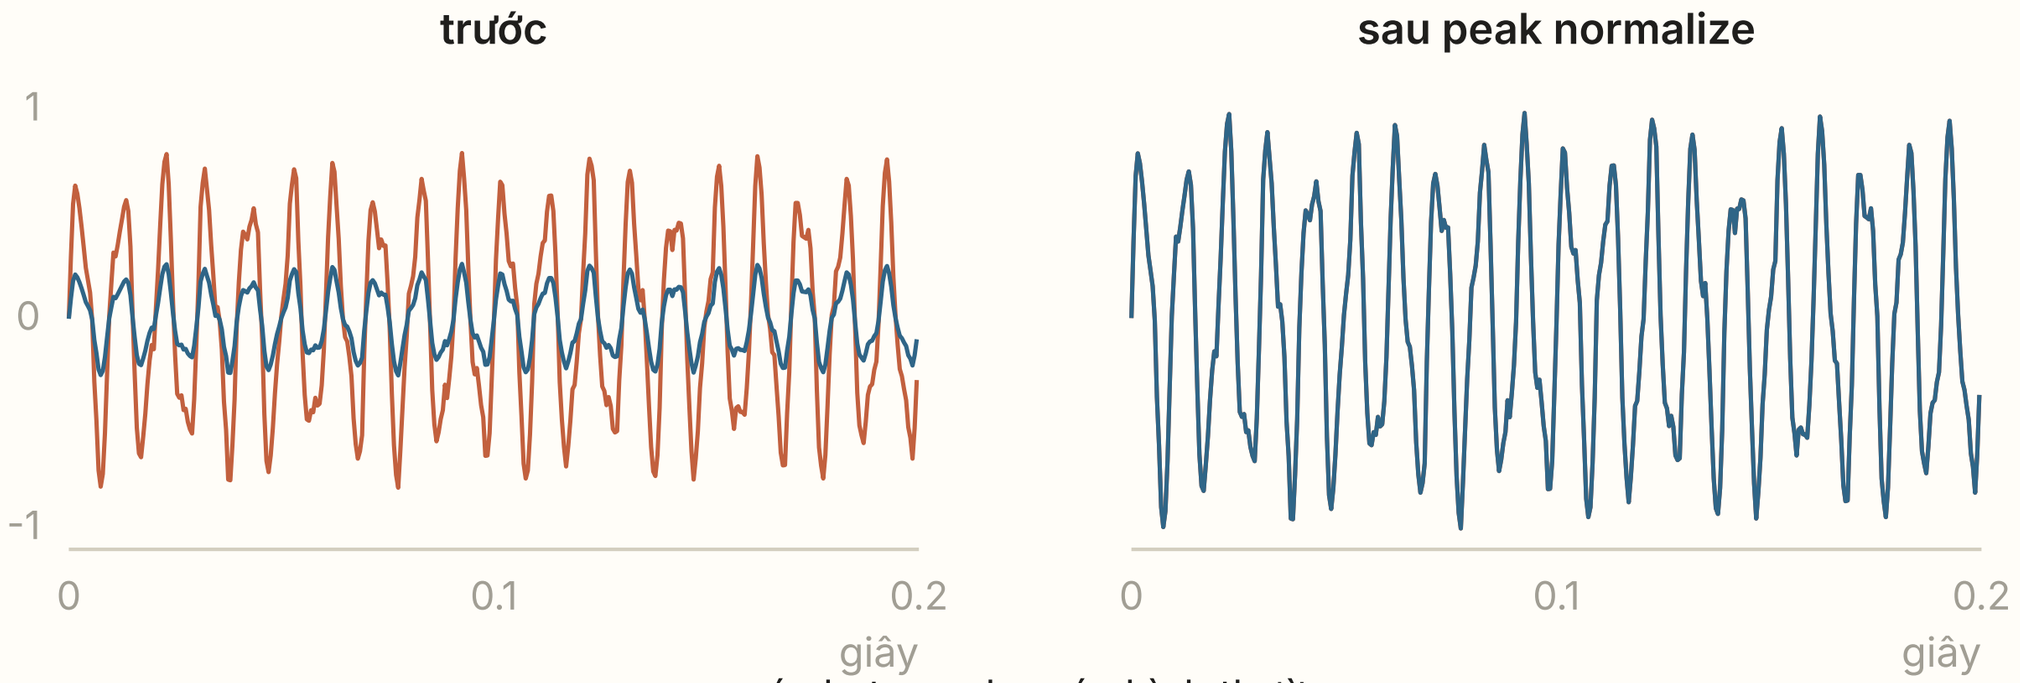
A Model học dễ hơn, vì mọi clip về cùng thang

B Khác biệt chính giữa hai lớp bị xóa trước khi vào model

C Không ảnh hưởng gì, vì log-mel tự bù lại biên độ

D Chỉ clip im lặng bị ảnh hưởng, do chia cho 0

Chuẩn hóa từng clip



cam: máy kẹt · xanh: máy bình thường

minh họa: hai clip cùng dạng sóng, biên độ gấp 3; chuẩn hóa từng clip làm chúng trùng nhau

Peak normalize từng clip xóa mất khác biệt biên độ giữa máy bơm kẹt và bình thường.

Augmentation phải giữ nhãn

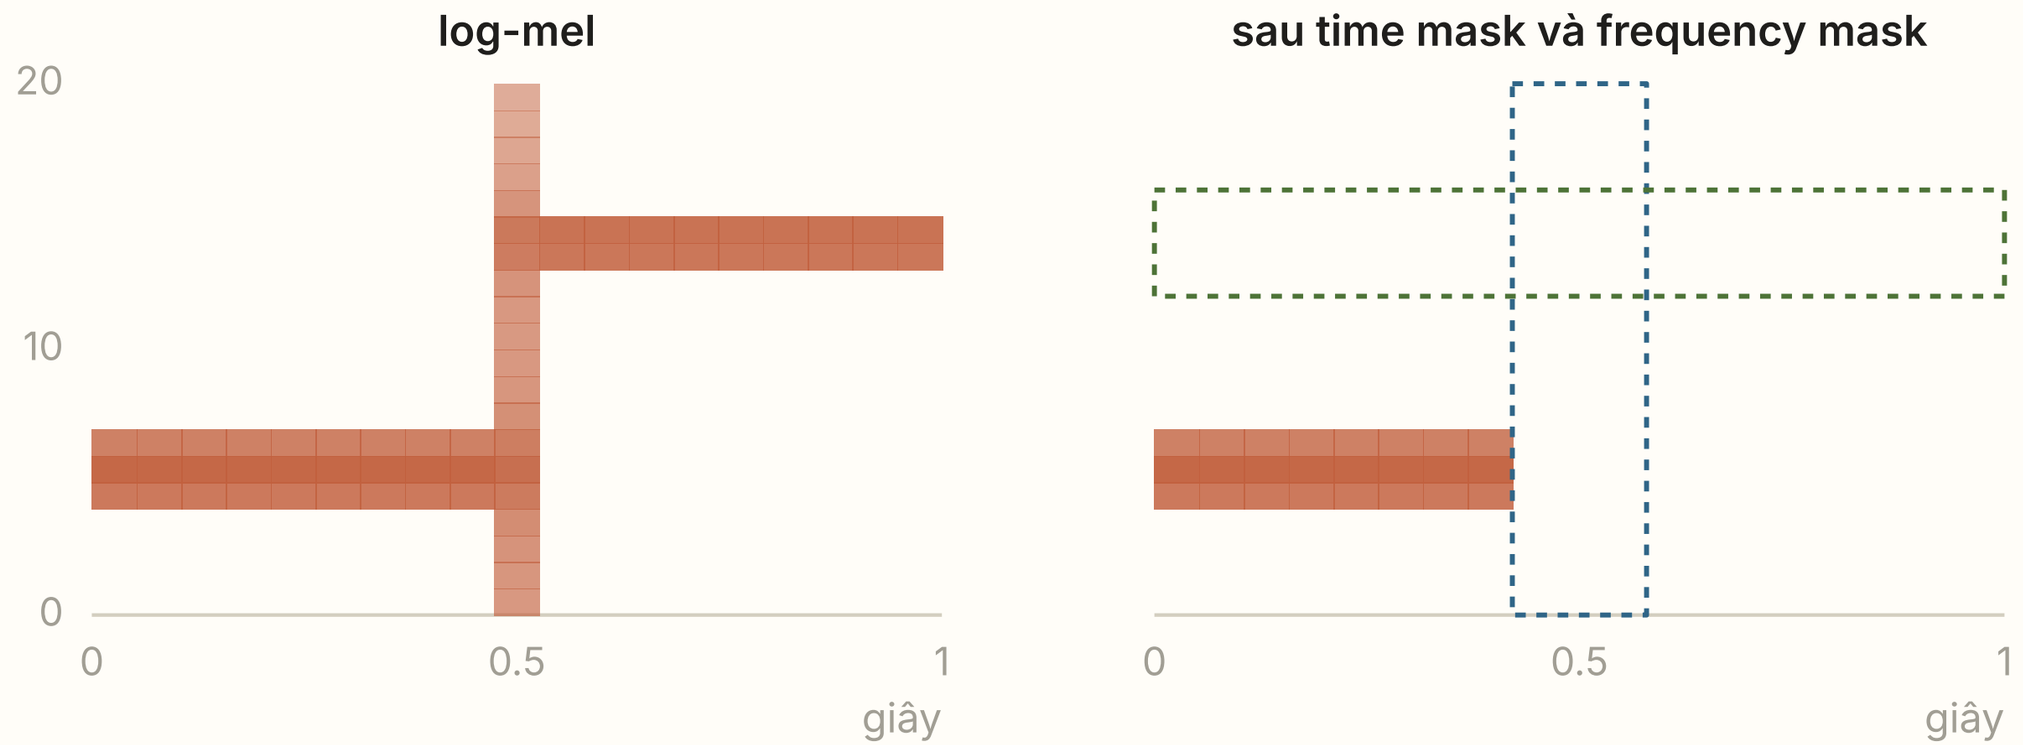
Hỏi trước: sau biến đổi, đáp án còn là đáp án cũ?

Nhãn cao độ nốt: pitch shift đổi nhãn.
Nhãn transcript: crop mất từ đổi nhãn.

SpecAugment che một dải thời gian hoặc tần số trên log-mel, chỉ lúc train.

Điền 0 sau z-score là điền mean của band.

Time mask và frequency mask



vùng che được điền một giá trị; điền gì phụ thuộc thang đang dùng (ở đây −80 dB)

SpecAugment che một dải thời gian và một dải tần khi train.

HỎI NHANH

Nhãn là transcript đầy đủ của câu nói. Crop ngẫu nhiên làm mất nửa cuối clip, nhưng vẫn giữ transcript cũ. Làm vậy có hợp lệ không?

A Có, vì augmentation không bao giờ đổi nhãn

B Có, nếu sample rate vẫn giữ nguyên

C Không, vì phần chữ cuối không còn trong âm thanh

D Có, nếu model là Transformer đủ lớn

HỎI NHANH

Nhãn là danh tính người nói, gồm 10 người trong một câu lạc bộ. Phép augmentation nào dễ làm sai nhãn nhất?

A Tăng hoặc giảm âm lượng 3 dB

B Trộn thêm tiếng quạt máy ở mức rất nhỏ

C Dịch clip sớm hoặc muộn 0.2 giây

D Pitch shift giọng lên 4 bán cung

Khi đi thi

- Header: sample rate, kênh, thời lượng, clip im lặng.
- Đúng sample rate và processor của checkpoint.
- Chia theo bản ghi gốc trước khi cắt đoạn.

05

Luyện đề

LUYỆN ĐỀ 1

Clip 1 giây ở 16 kHz, window 400 mẫu, hop 160 mẫu. Số frame STFT khi không padding, và khi `center=True`, tức đệm 200 mẫu mỗi đầu, lần lượt là bao nhiêu?

A 97 và 100

B 98 và 100

C 100 và 101

D 98 và 101

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q1.2(b)

LUYỆN ĐỀ 2

STFT của bài, với window 200, hop 100 và Hann, có thể viết bằng `nn.Conv1d(1, 202, kernel_size=200, stride=s, bias=False)` với 202 kernel cố định, gồm 101 cosine và 101 sine đã nhân Hann. Với waveform shape `(1, 1, 2000)`, `s` bằng bao nhiêu, và output có shape gì?

A `s=1`, output `(1, 202, 1801)`

B `s=100`, output `(1, 202, 19)`

C `s=100`, output `(1, 101, 19)`

D `s=200`, output `(1, 202, 10)`

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 201

LUYỆN ĐỀ 3

Đề cho mỗi mẫu là một chuỗi 500 giá trị cảm biến, không ghi sample rate. Một đội cắt frame dài 50, hop 25, rồi lấy `rfft` của mỗi frame làm token cho Transformer. Có bao nhiêu token, và trục tần số của mỗi token đọc thế nào?

A 20 token, bin k ứng với $10k$ Hz

B 20 token, bin k ứng với $k/50$ chu kỳ mỗi mẫu

C 19 token, bin k ứng với $k/50$ chu kỳ mỗi mẫu

D 19 token, bin k ứng với $10k$ Hz

PHỎNG THEO USA-NA-AIO 2026 · Vòng 2 · Ngày 1 · Part 1.4

Chốt ý

Waveform luôn đi cùng sample rate; giảm sample rate phải lọc trước.

STFT: window quyết định đoạn quan sát, hop quyết định bước trượt; log-mel nén lại cho model.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; đổi `hop` của `stft_power`, dự đoán số frame trước rồi kiểm bằng `power.shape`.