Audio classification

Phân biệt âm thấp→cao với cao→thấp

Cùng tần số, khác đáp án

Thấp→cao: bắt đầu.

Cao→thấp: kết thúc.

CÂU HỎI

Biểu diễn nào giữ được phần quyết định nhãn: thứ tự?

Mục tiêu buổi này

- Chọn mức clip hay frame, single-label hay multi-label.
- So baseline gộp theo thời gian với CNN trên log-mel.
- Split theo đơn vị của test; chấm macro-F1.
- Cắt cửa sổ khi train, gộp khi dự đoán.
- Pool hidden states có mask theo độ dài sau encoder.

01

Nhiệm vụ và dữ liệu

Một nhãn hay một dãy nhãn?

một nhãn cho clip

`(B, C)`

softmax, cross-entropy

nhiều nhãn có/không

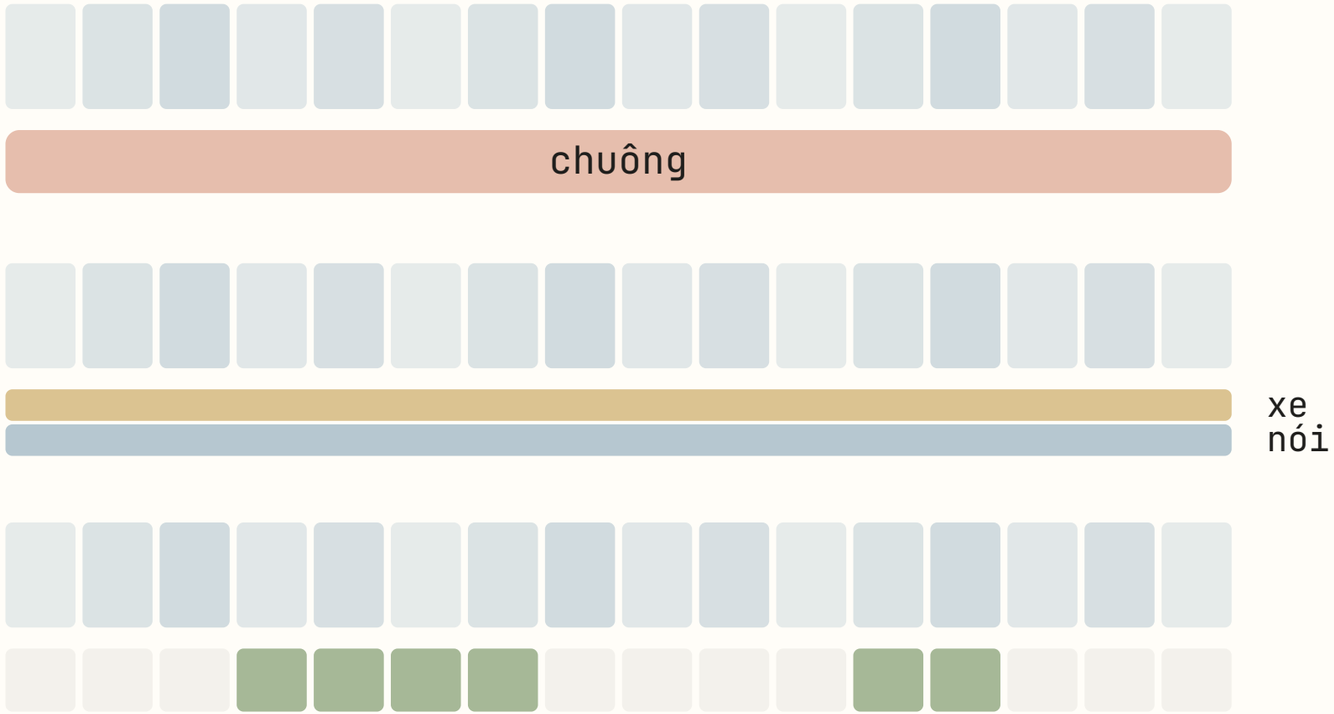
`(B, C)`

sigmoid, BCE

nhãn theo thời gian

`(B, T, C)`

mỗi frame một dự đoán



Ba dạng bài trên cùng một clip: một nhãn loại trừ cho cả clip, nhiều nhãn có/không độc lập (sigmoid, BCE), hoặc một dự đoán cho mỗi frame theo thời gian.

Loss theo nhiệm vụ

Single-label: logits `(B,C)`, target `(B,)`, CrossEntropyLoss.

Multi-label: mỗi lớp có/không, BCEWithLogitsLoss.

Tiếng xe và tiếng nói có thể cùng xuất hiện.

HỎI NHANH

Mỗi clip 10 giây có thể chứa tiếng xe, tiếng nói, cả hai, hoặc không có gì. Đề chấm xác suất riêng cho từng loại. Nên dùng head và loss nào?

A Softmax hai lớp với CrossEntropyLoss, nhãn là âm to hơn

B Hai logits độc lập, sigmoid, với BCEWithLogitsLoss

C Softmax hai lớp, đặt ngưỡng 0.5 riêng trên mỗi cột

D Softmax ba lớp gồm xe, nói và cả hai, với CrossEntropyLoss

Dữ liệu tổng hợp

20 phiên giả lập, mỗi phiên 4 clip.

Hai clip trong cặp dùng cùng hai nửa, đổi thứ tự.

80 clip: 20 phiên, mỗi phiên 4 clip; `session` là group dùng để split.

KẾT QUẢ

```
(80, 24, 8) (80,)
thời lượng = 0.50 s
```

24 band, 8 frame; ranh giới hai nửa nằm giữa frame 4 và 5.

HỎI NHANH

Mỗi cặp clip dùng đúng hai nửa waveform giống nhau, chỉ đổi thứ tự. Thiết kế này nhằm mục đích gì?

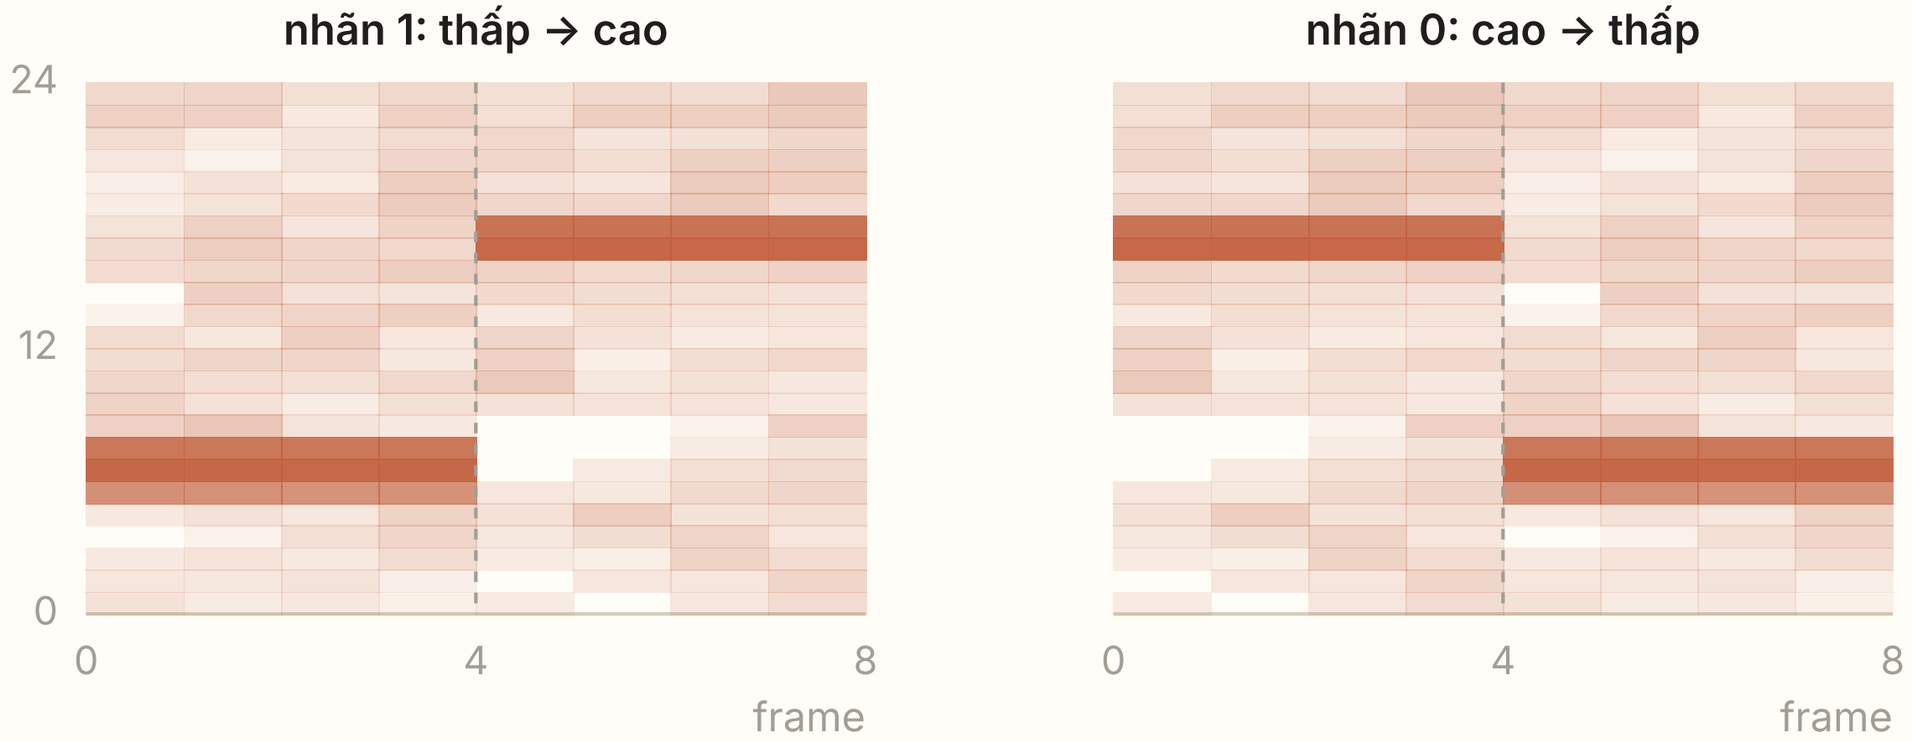
A Để mỗi phiên có bản sao của cùng clip ở cả train và validation

B Để hai lớp khác nhau rõ ở cao độ trung bình của cả clip

C Để mọi đặc trưng bỏ qua thứ tự đều trùng nhau trong một cặp

D Để năng lượng hai nửa khác nhau, dễ thấy trên log-mel

Log-mel của một cặp clip



Log-mel 24 × 8 của một cặp clip đầu tiên trong dữ liệu bài (từ code): nhãn 1 có âm thấp ở bốn frame đầu, nhãn 0 đảo lại; hai clip có cùng tập frame, chỉ khác thứ tự.

02

Validation và baseline

Giữ phiên ở một phía

GroupShuffleSplit: 15 phiên train, 5 phiên validation.

Group theo đơn vị của test: test là người nói mới thì group theo speaker ID.

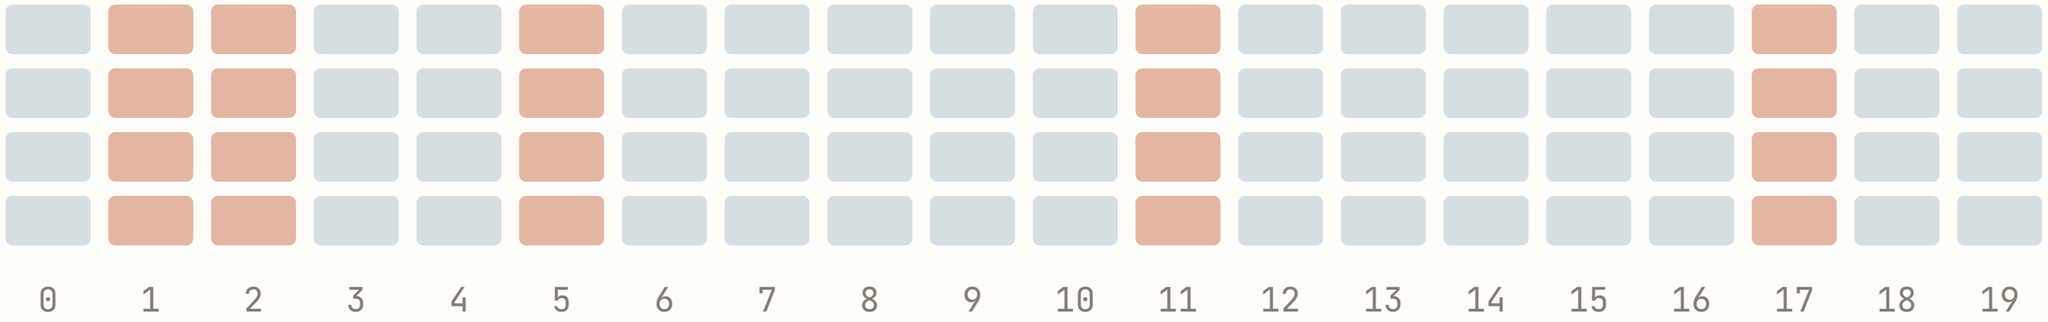
Crop và augmentation tạo sau khi split.

KẾT QUẢ

```
60 20
group giao nhau = 0
[10 10]
```

Kiểm cả group và phân bố lớp.

Năm phiên sang validation



validation (cam): 5 phiên, 20 clip; giao group với train bằng 0

GroupShuffleSplit của bài (từ code): 5 trong 20 phiên vào validation, mỗi phiên giữ trọn bốn clip ở một phía, nên không phiên nào nằm ở cả train lẫn validation.

HỎI NHANH

Đề chấm trên những người nói chưa từng xuất hiện. Dữ liệu có 30 người, mỗi người thu 3 phiên. Một đội chia GroupKFold theo mã phiên. Rủi ro chính là gì?

A Một người có phiên ở cả hai phía, nên validation lạc quan

B Không có rủi ro, vì không phiên nào bị chia ra hai phía

C GroupKFold báo lỗi, vì số phiên không chia hết cho số fold

D Validation bi quan hơn test, vì mỗi phiên có quá ít clip để học

Baseline gộp theo thời gian

```
pooled_features = features.mean(axis=2)
baseline = make_pipeline(
    StandardScaler(),
    LogisticRegression(max_iter=300),
)
```

KẾT QUẢ

```
accuracy = 0.500
macro-F1 = 0.333
[[10  0]
 [10  0]]
```

Hàng là nhãn thật, cột là nhãn dự đoán theo thứ tự `[0, 1]`; model chỉ đoán lớp 0.

HỎI NHANH

Baseline đoán lớp 0 cho cả 20 clip validation, mỗi lớp 10 clip. Accuracy là 0.500, macro-F1 là 0.333. F1 của lớp 0 và của lớp 1 lần lượt là bao nhiêu?

A 0.500 và 0.167

B 0.667 và 0

C 1.000 và 0

D 0.333 và 0.333

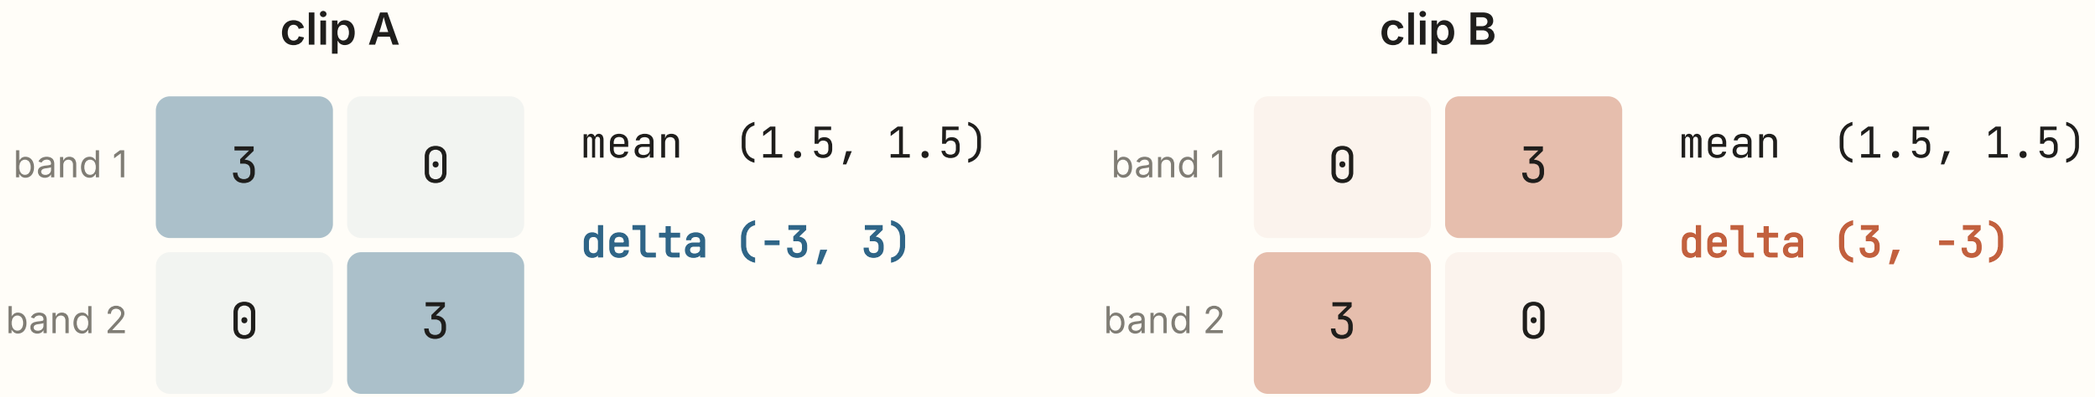
Tính tay: pooling mất gì?

$$A = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix}, \quad B = \begin{bmatrix} 0 & 3 \\ 3 & 0 \end{bmatrix}.$$

Cả hai có mean theo thời gian $(1.5, 1.5)$, nên mỗi cặp luôn một clip đúng, một clip sai: accuracy chắc chắn 0.500.

Delta trung bình $= (\text{cuối} - \text{đầu})/(T-1)$: A $(-3, 3)$, B $(3, -3)$, đổi dấu.

Nhìn từ trái sang phải



mean theo thời gian bằng nhau: không hàm nào của mean tách được hai clip

delta (frame sau trừ frame trước) đổi dấu khi đảo thứ tự

Ví dụ tính tay: hai clip chỉ đổi thứ tự hai frame có cùng vector mean (1.5, 1.5), nên baseline gộp thời gian không tách được; trung bình delta đổi dấu từ (−3, 3) sang (3, −3).

HỎI NHANH

Thay mean bằng ba thống kê theo thời gian của mỗi band là mean, std và max, được 72 số. Logistic regression trên vector này có tách được hai lớp của bài không?

A Có, vì max cho biết frame nào có năng lượng lớn nhất

B Có, vì std đo mức thay đổi của band theo thời gian

C Không, trừ khi tăng `max_iter` để solver hội tụ hẳn

D Không, vì cả ba đều giữ nguyên khi đổi thứ tự frame

03

CNN giữ vị trí

Đường shape

`(80,24,8)` → thêm channel → `(80,1,24,8)`.

Conv2d, 4 channel, padding 1 → `(B,4,24,8)`.

Flatten → `(B,768)` → Linear → `(B,2)` logits.

CNN học từ đầu

```
model = nn.Sequential(
    nn.Conv2d(1, 4, 3, padding=1),
    nn.ReLU(),
    nn.Flatten(),
    nn.Linear(4 * 24 * 8, 2),
)
```

KẾT QUẢ

```
(80, 1, 24, 8)
accuracy = 1.000
macro-F1 = 1.000
[[10  0]
 [ 0 10]]
```

Chuẩn hóa riêng từng band bằng thống kê train.

Đọc confusion matrix trước khi mừng accuracy

baseline: mean từng band

	đoán 0	đoán 1
thật 0	10	0
thật 1	10	0

acc 0.500 · macro-F1 0.333

CNN trên log-mel

	đoán 0	đoán 1
thật 0	10	0
thật 1	0	10

acc 1.000 · macro-F1 1.000

Confusion matrix trên 20 clip validation (số từ output bài): baseline gộp thời gian đoán lớp 0 cho mọi clip; CNN giữ vị trí tới head nên đúng cả 20.

Gộp sau conv thì sao?

```
head = nn.Sequential(
    nn.Conv2d(1, 4, kernel_size, padding=padding),
    nn.ReLU(),
    TimeMean(),
    nn.Flatten(),
    nn.Linear(4 * 24, 2),
)
```

Kernel, rồi mean theo thời gian	Train	Valid
3×3	1.000	0.950
$(3, 1)$	0.500	0.500

3×3 nhìn qua chỗ chuyển frame 4→5; $(3, 1)$ xử lý từng frame riêng.

HỎI NHANH

Đổi kernel thành $(1, 3)$, tức mỗi lần chỉ nhìn một band nhưng nhìn ba frame kề nhau, với padding `(0, 1)`, vẫn ReLU rồi mean theo thời gian. Model có học được không?

A Học được, vì kernel thấy band bật hay tắt ở chỗ chuyển

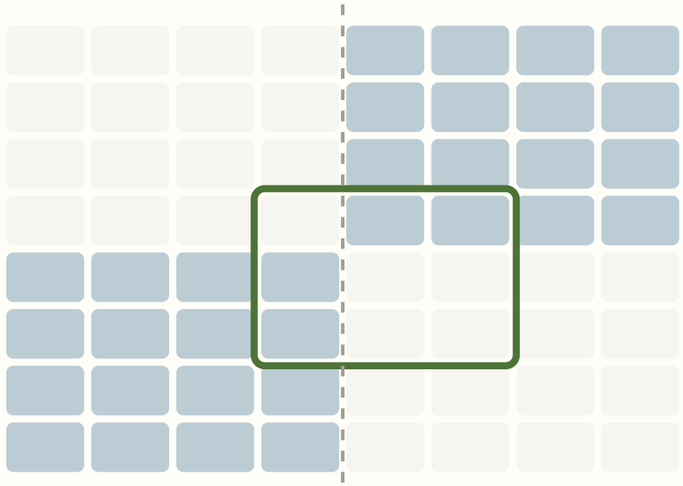
B Không, vì mean theo thời gian luôn xóa hết thứ tự frame

C Không, vì kernel phải phủ cả hai trục mới thấy được thứ tự

D Học được, nhưng chỉ khi bỏ ReLU đứng trước bước mean

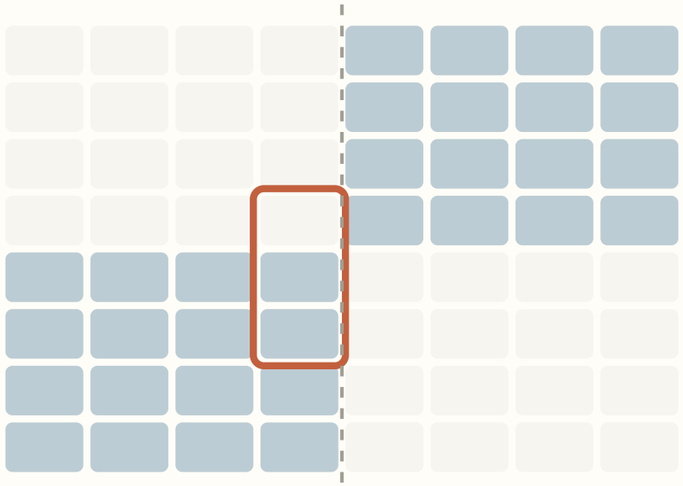
Kernel phải nhìn qua chỗ chuyển

kernel 3×3 rồi mean thời gian



`train 1.000 · valid 0.950`

kernel 3×1 rồi mean thời gian



`train 0.500 · valid 0.500`

kernel phải nhìn qua ranh giới frame 4 | 5 thì thứ tự mới còn sau bước gộp

Mean theo thời gian đặt sau conv (số từ output bài): kernel 3×3 phủ ba frame kề nhau nên thấy chỗ chuyển thấp → cao, valid 0.950; kernel 3×1 xử lý từng frame riêng nên vẫn kẹt ở 0.500.

Kết quả nói gì?

Thứ tự là thông tin quyết định nhãn của quy tắc này.

Gộp trước khi đọc thứ tự thì mất; gộp sau conv nhìn qua nhiều frame thì còn.

Với âm thật, CNN hay embedding phải đo trên validation của đề.

04

Clip dài: cửa sổ

Cắt khi train, gộp khi dự đoán

Train: crop ngẫu nhiên độ dài cố định; clip ngắn pad kèm mask.

Nhãn cả clip có thể vắng trong một cửa sổ (weak label).

Dự đoán: cửa sổ trượt, hop khoảng nửa cửa sổ.

Mean: nhãn mô tả cả clip. Max: sự kiện có ít nhất một lần.

Chọn cách gộp bằng metric mức clip.

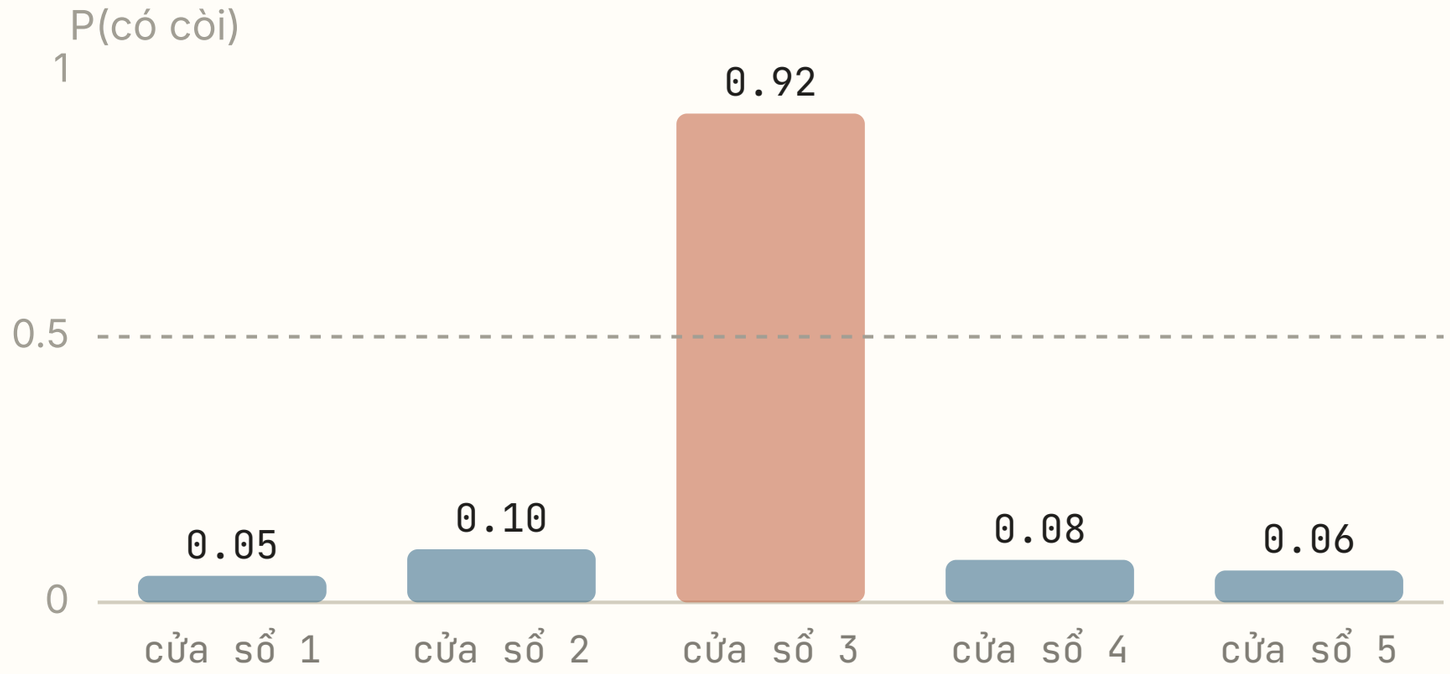
Tính tay: còi trong năm cửa sổ

$$P(\text{còi}) = 0.05,\ 0.10,\ 0.92,\ 0.08,\ 0.06$$

Mean $= 1.21/5 = 0.242$: dưới 0.5, bỏ sót tiếng còi.

Max $= 0.92$: bắt được.

Mean bỏ sót, max bắt được



mean 0.242

dưới 0.5: bỏ sót

max 0.920

một cửa sổ chắc là đủ

Ví dụ tính tay: năm cửa sổ của một clip cho xác suất có còi 0.05, 0.10, 0.92, 0.08, 0.06; trung bình 0.242 bỏ sót tiếng còi, max 0.92 bắt được.

HỎI NHANH

Ba cửa sổ của một clip cho xác suất lớp A và lớp B là $(0.9, 0.1)$, $(0.4, 0.6)$ và $(0.45, 0.55)$. Bỏ phiếu theo argmax và lấy trung bình xác suất lần lượt chọn lớp nào?

A Bỏ phiếu chọn A, trung bình chọn A

B Bỏ phiếu chọn A, trung bình chọn B

C Bỏ phiếu chọn B, trung bình chọn A

D Bỏ phiếu chọn B, trung bình chọn B

05

Embedding pretrained

Từ waveform đến vector

HuBERT, wav2vec2 trả `(B,T',D)`; 16 kHz cho 49 bước mỗi giây.

`T'` là số bước sau conv, không phải số mẫu waveform.

`from_pretrained` nạp trọng số đã học; `Model(config)` chỉ có kiến trúc.

Recipe chương: `--check` kiểm file, processor, sample rate, trọng số.

`--run` trích embedding, pool có mask, probe fit trên train.

So accuracy, macro-F1 với baseline trên cùng split.

Pooling có mask

$$\mathbf{z}_i = \frac{\sum_t a_{i,t}\mathbf{h}_{i,t}}{\sum_t a_{i,t}}.$$

$a_{i,t} = 1$ ở hidden frame hợp lệ, bằng 0 ở padding; mẫu số là số frame thật sau downsampling.

Hai vector thật $(1, 2), (3, 4)$: mean $(2, 3)$.

Thêm hai padding rồi chia cho 4: sai thành $(1, 1.5)$.

HỎI NHANH

Một clip 0.5 giây cho embedding khác nhau khi được ghép batch với một clip 0.5 giây khác và khi được ghép với một clip 2 giây. Chạy lại cùng một batch thì ra đúng kết quả cũ. Nguyên nhân có khả năng nhất là gì?

A Dropout của encoder vẫn bật, nên output đổi ngẫu nhiên

B Processor resample clip ngắn theo clip dài nhất trong batch

C StandardScaler của head được fit lại cho từng batch mới

D Pooling chia cho mọi bước hidden, gồm cả các bước padding

Chia cho số bước thật

clip 1: hai bước thật, hai bước padding

(1, 2)	(3, 4)	(0, 0)	(0, 0)
a = 1	a = 1	a = 0	a = 0

chia cho 4: (1, 1.5)

chia cho 2: (2, 3)

chia cho số bước đã pad thì embedding phụ thuộc clip nào được ghép cùng batch

$$z = \Sigma\, a_t\, h_t \,/\, \Sigma\, a_t$$

Mean pooling có mask trên hidden states đặt tay của bài: clip đầu có hai bước thật (1, 2), (3, 4); chia cho 2 bước thật ra (2, 3), chia cho cả 4 bước đã pad ra (1, 1.5).

Augmentation phải giữ đáp án

Time reversal: thấp→cao thành cao→thấp, đổi nhãn.

Time mask rộng hơn sự kiện ngắn nhất: mẫu dương mất bằng chứng.

Lớp hiếm: theo dõi recall riêng; class weight hoặc lấy mẫu lại trong train.

HỎI NHANH

Đề phân loại tiếng gõ cửa, tiếng ho và tiếng còi, với hop 10 ms. Tiếng gõ ngắn nhất chỉ dài khoảng 5 frame. Một đội bật time masking, che ngẫu nhiên tới 40 frame liên tiếp, và giữ nhãn cũ. Rủi ro chính là gì?

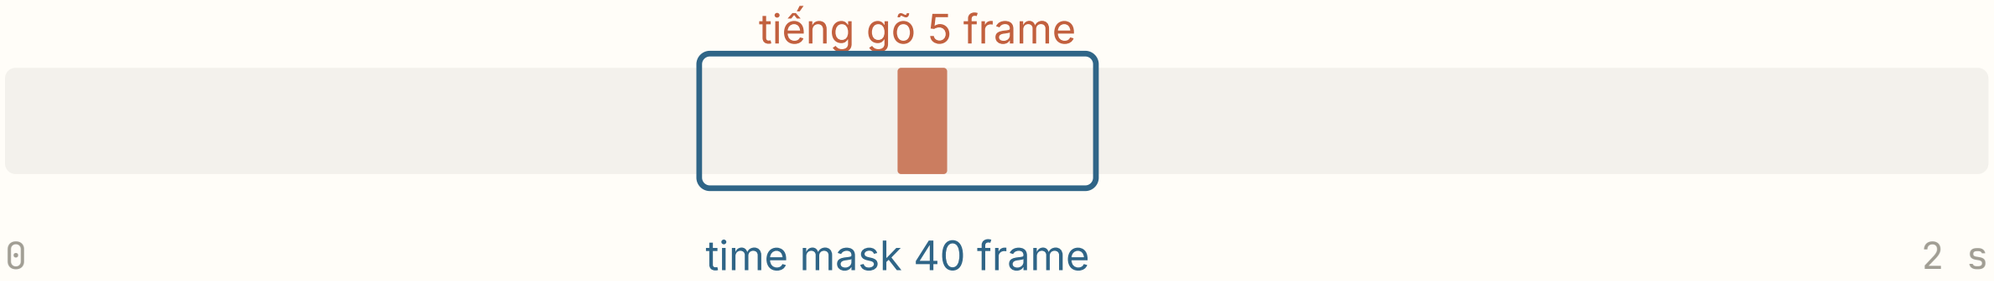
A Mask che trọn tiếng gõ, sinh ra mẫu “gõ cửa” không còn tiếng gõ

B Không có rủi ro, vì masking chỉ che chứ không dịch chuyển gì

C Masking đảo thứ tự các frame, giống hệt time reversal

D Model sẽ chỉ còn học tiếng còi, vì còi là âm dài nhất

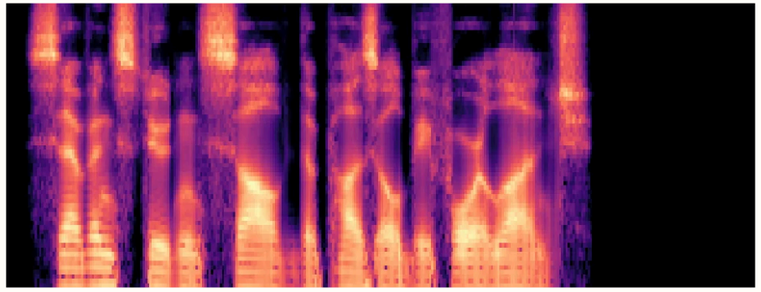
Mask rộng hơn sự kiện



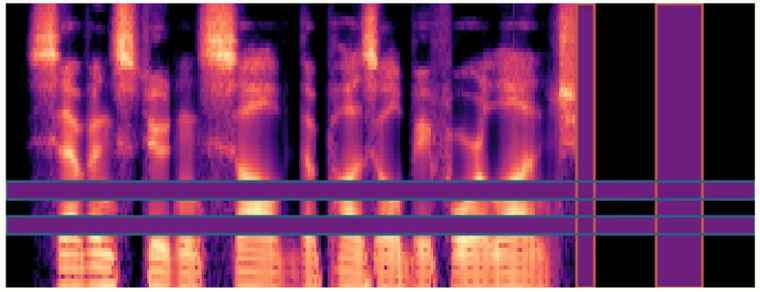
mask rộng hơn sự kiện ngắn nhất có thể che trọn bằng chứng mà nhãn vẫn là “gõ cửa”

Time mask 40 frame (0.4 s) so với tiếng gõ chỉ dài 5 frame: mask có thể che trọn sự kiện, sinh mẫu mang nhãn “gõ cửa” mà không còn tiếng gõ.

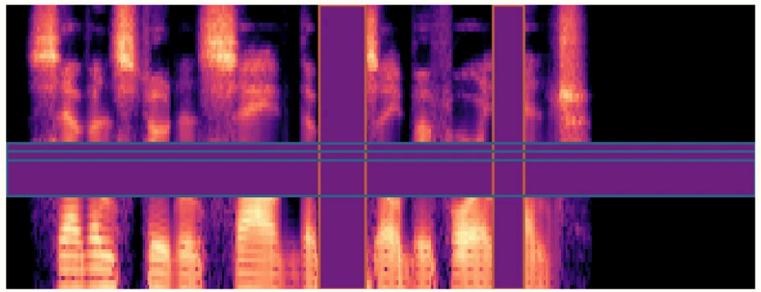
Mỗi epoch một kiểu che



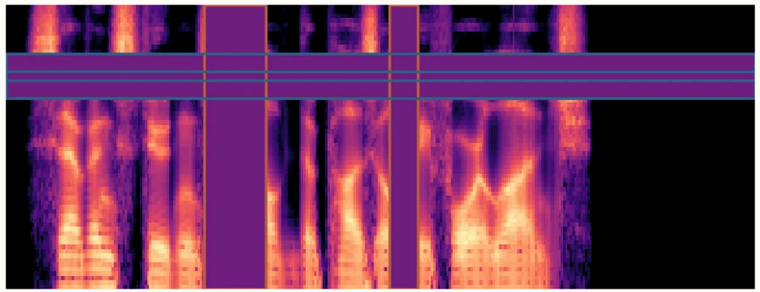
log-mel gốc: 64 dải mel × 1 khung mỗi 10 ms



epoch 1: che 290 ms thời gian (khung cam), 8 dải mel (khung xanh)



epoch 2: che 350 ms thời gian (khung cam), 14 dải mel (khung xanh)



epoch 3: che 410 ms thời gian (khung cam), 12 dải mel (khung xanh)

SpecAugment trên log-mel của một câu đọc thật: mỗi epoch che ngẫu nhiên vài đoạn thời gian và vài dải tần, nhãn giữ nguyên.

Khi đi thi

- Baseline gộp cùng logistic regression: kiểm file, ID, metric trước.
- Group theo đơn vị của test: người nói, thiết bị hay phiên.
- Gộp cửa sổ về clip rồi mới chấm macro-F1.
- Cache embedding kèm ID, checkpoint, processor.
- Nhãn nộp đúng tập của đề; xác suất đúng cột.

06

Luyện đề

LUYỆN ĐỀ 1

Clip dài từ 2 đến 10 giây, mỗi giây có 100 frame log-mel. CNN của bài dùng Flatten rồi Linear cho đúng 8 frame. Xử lý độ dài thay đổi thế nào mà không vứt bỏ phần lớn clip dài?

A Cắt mọi clip về 2 giây đầu để Flatten có độ dài cố định

B Resample từng clip để mọi clip có cùng số mẫu waveform

C Dùng conv hoặc RNN theo thời gian, rồi gộp có mask trên các bước thật

D Giữ Flatten, vì Linear tự co giãn theo số frame của từng clip

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q1.6

LUYỆN ĐỀ 2

Một đội chép nguyên pipeline augmentation ảnh sang log-mel của bài tín hiệu báo, trong đó thấp lên cao là “bắt đầu”. Pipeline gồm lật ngang, lật dọc, xoay 90°, và chỉnh độ sáng bằng cách cộng cùng một hằng số dB vào mọi ô. Phép nào giữ được nhãn?

A Lật ngang, vì nó chỉ đảo chiều trục thời gian

B Lật dọc, vì thứ tự thời gian vẫn nguyên

C Xoay 90°, vì tổng năng lượng không đổi

D Chỉnh độ sáng, vì nó tương đương với đổi âm lượng

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 212

LUYỆN ĐỀ 3

Tập âm thanh có 9800 clip bình thường và 200 clip kính vỡ. Một đội nhân bản mỗi clip kính vỡ 49 lần thành 9800 clip, rồi mới chia ngẫu nhiên 80/20 thành train và validation. Recall của lớp kính vỡ trên validation là 0.97, nhưng trên test chỉ 0.40. Vì sao?

A Ngưỡng 0.5 quá cao cho lớp hiếm, hạ ngưỡng thì test sẽ lên ngang validation

B Bản sao của cùng một clip nằm ở cả hai phía, nên validation chấm trí nhớ

C Test có ít clip kính vỡ hơn, nên recall trên test luôn thấp hơn

D Nhân bản làm model thiên về lớp hiếm quá mức, nên test phải tụt

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 275

Chốt ba điều

Chọn mức clip hay frame, single-label hay multi-label trước khi chọn head.

Gộp sau khi có gì đọc được thứ tự; mask theo độ dài thật.

Split theo đơn vị của test, chấm ở mức clip bằng metric của đề.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; đổi kernel của head gộp theo thời gian, dự đoán accuracy trước rồi kiểm bằng output.