Speech recognition

Từ nhiều frame âm đến một chuỗi chữ

Chữ không dài bằng âm

“Em học AI hôm nay”: năm từ, nhưng ba giây ở 16 kHz là 48 000 mẫu.

Người nói kéo âm, dừng rồi nói tiếp.

Alignment được học thế nào? Transcript đúng đến đâu?

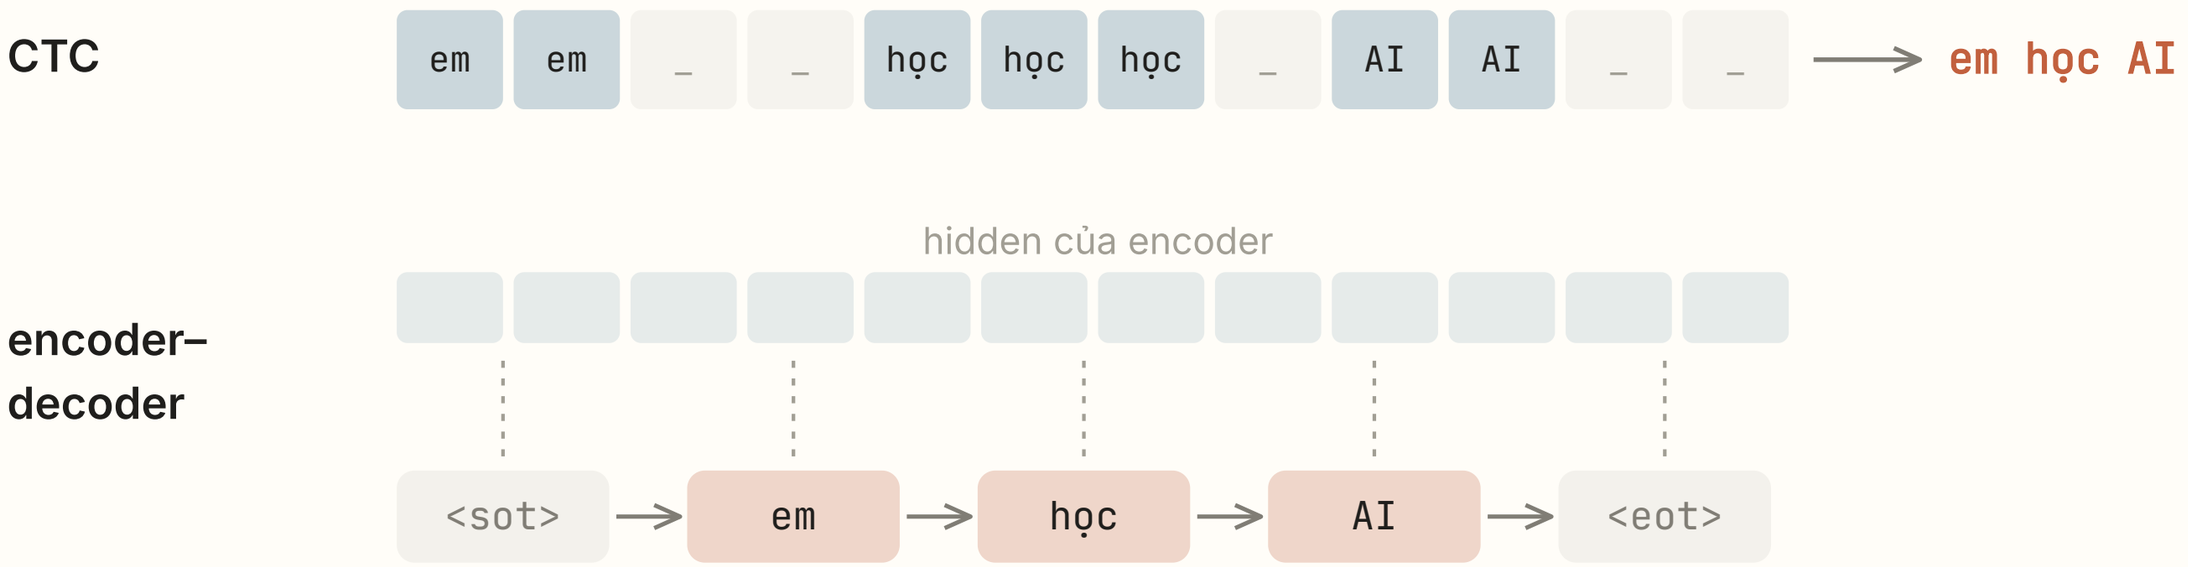
Mục tiêu

- Phân biệt CTC và encoder–decoder cho nhận dạng giọng nói.
- Tính CTC bằng tay và bằng quy hoạch động.
- Tính WER.
- Dùng Whisper và kiểm các lỗi hay gặp.

01

Alignment và CTC

Hai hướng ASR



CTC cho mỗi frame một nhãn rồi gộp; encoder–decoder sinh từng token.

HỎI NHANH

Đội có 2000 clip kèm transcript, nhưng không có mốc thời gian của từng ký tự. Một bạn đề xuất chia đều các frame cho các ký tự, rồi train cross-entropy theo frame. Cách này sai ở đâu?

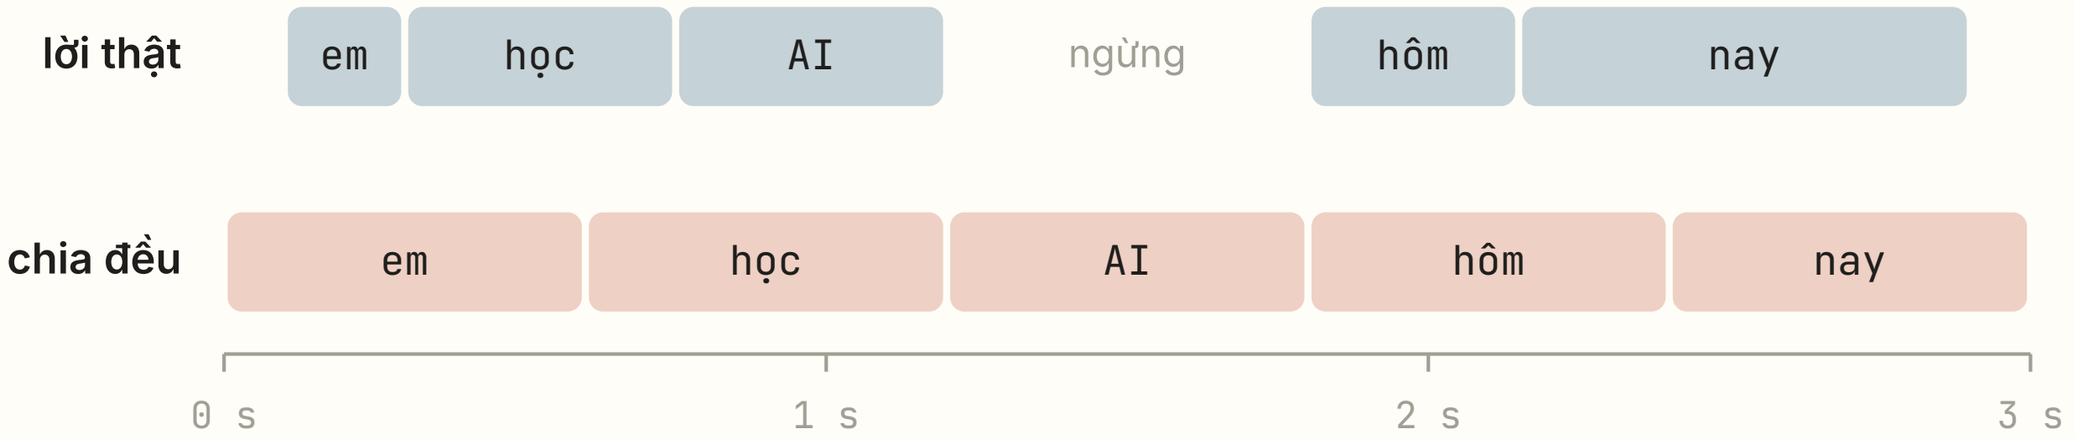
A Cross-entropy không dùng được khi có hơn hai lớp

B Tốc độ nói không đều, nên nhãn của frame bị gán lệch

C Transcript phải đổi sang phiên âm trước khi train

D Chia đều chỉ sai với những clip dài hơn 30 giây

Nói không đều



Người nói ngừng giữa câu, nên chia đều thời gian cho các từ sẽ lệch.

Blank tách hai lần phát cùng chữ

a a _ a → gộp liền kề → a _ a → bỏ blank → **aa**.

a a a → **a**.

Không xóa blank trước khi gộp nhãn lặp.

HỎI NHANH

Path a _ a collapse thành gì?

A _aa

B a

C aa

D Chuỗi rỗng

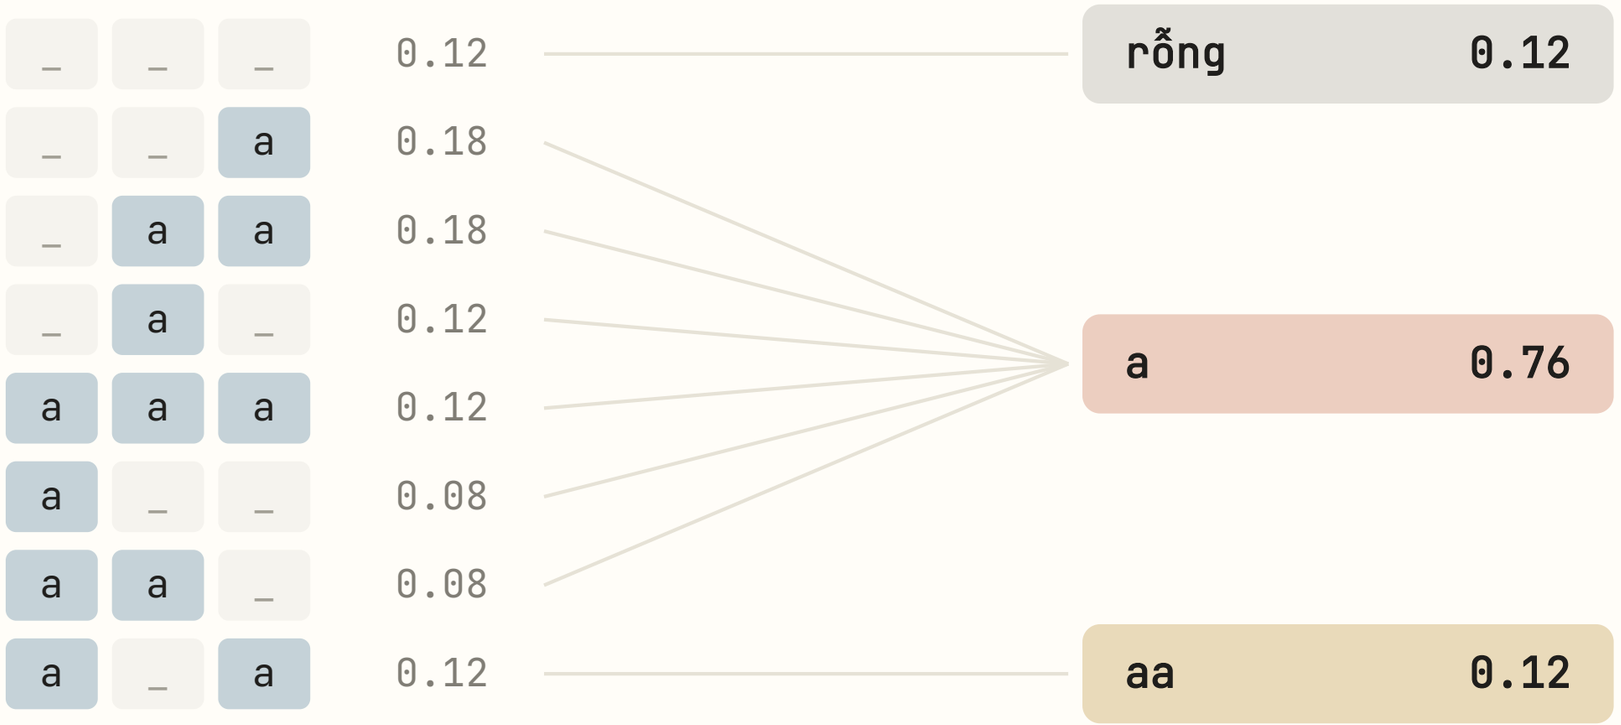
Một transcript nhận nhiều path

$$P(y \mid X) = \sum_{\pi : \mathcal{B}(\pi) = y} \prod_{t} p_t(\pi_t).$$

$$\mathcal{L} = -\log P(y \mid X).$$

Greedy tìm một path; CTC loss cộng mọi alignment hợp lệ.

Tám path, ba transcript



Tám path gộp thành ba transcript; “a” gom sáu path, xác suất 0.76.

Liệt kê tám path

___: $0.6 \cdot 0.5 \cdot 0.4 = 0.12$.

a_a: $0.4 \cdot 0.5 \cdot 0.6 = 0.12$.

Sáu path còn lại cho a.

KẾT QUẢ

```
P(rỗng) = 0.120
P(a) = 0.760
P(aa) = 0.120
loss = 0.2744
```

Path tốt nhất chưa chắc cho transcript tốt nhất

Greedy: argmax từng frame rồi collapse.

Transcript tốt nhất: tổng xác suất lớn nhất trên mọi path của nó.

Beam search giữ nhiều tiền tố, cộng các path về cùng tiền tố.

HỎI NHANH

Có hai frame, mỗi frame có $P(_) = 0.6$ và $P(a) = 0.4$. Greedy decoding cho transcript nào, và transcript nào có xác suất lớn nhất?

A Greedy cho chuỗi rỗng, còn lớn nhất là a với xác suất 0.64

B Greedy cho chuỗi rỗng, còn lớn nhất là chuỗi rỗng với xác suất 0.36

C Greedy cho a, và lớn nhất là a với xác suất 0.64

D Greedy cho chuỗi rỗng, còn lớn nhất là aa với xác suất 0.16

Greedy và tổng xác suất

	t = 1	t = 2
_	0.6	0.6
a	0.4	0.4

greedy chọn _ ở cả hai frame

rỗng	__	0.36
a	a_ + _a + aa	0.64

Path tốt nhất ra chuỗi rỗng, nhưng transcript “a” có tổng xác suất cao hơn.

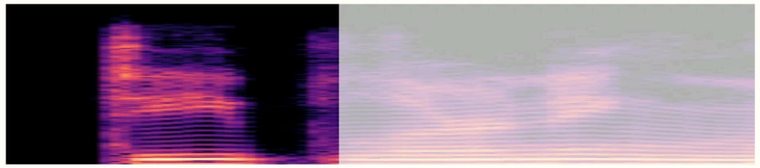
CTC trên một câu đọc thật



· · · · · D · E

DE

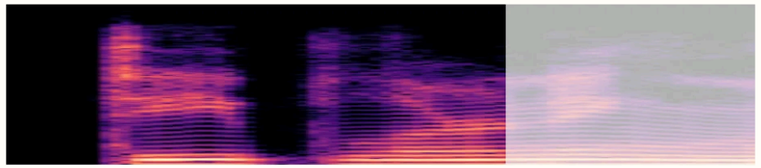
8/36 khung (đầu câu) đã đọc: hàng giữa là ký tự argmax của mỗi khung 20 ms, chấm là blank; dòng dưới là kết quả sau khi gộp



· · · · · D · E · · · EP · · ␣

DEEP

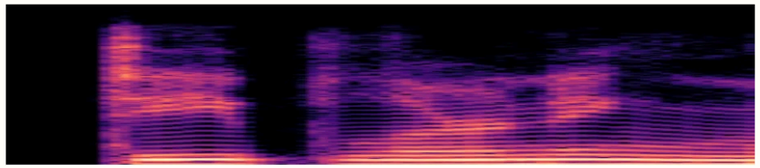
16/36 khung (đầu câu) đã đọc: hàng giữa là ký tự argmax của mỗi khung 20 ms, chấm là blank; dòng dưới là kết quả sau khi gộp



· · · · · D · E · · · EP · · ␣␣ · L · EEAR

DEEP LEAR

24/36 khung (đầu câu) đã đọc: hàng giữa là ký tự argmax của mỗi khung 20 ms, chấm là blank; dòng dưới là kết quả sau khi gộp



· · · · · D · E · · · EP · · ␣␣ · L · EEARRN · · INGG␣␣␣ ·

DEEP LEARNING

36 khung đầu, 16 khung là blank. Cả câu 161 khung cho: “DEEP LEARNING MODELS LEARN PATTERNS FROM DATA”

Mỗi khung 20 ms cho một ký tự hoặc blank; gộp ký tự lặp rồi bỏ blank.

02

Dynamic programming và CTCLoss

Chuỗi mở rộng và truy hồi α

$$\ell' = (_, y_1, _, \ldots, y_U, _) \text{ dài } 2U+1.$$

$$\alpha_t(s) = \big(\alpha_{t-1}(s) + \alpha_{t-1}(s-1) + \text{nhảy}\big)\, p_t(\ell'_s)$$

Số hạng nhảy $\alpha_{t-1}(s-2)$ chỉ có khi $\ell'_s \neq _$ và $\ell'_s \neq \ell'_{s-2}$.

$P(y \mid X) = \alpha_T(2U+1) + \alpha_T(2U)$; thời gian $O(TU)$.

Bảng α cho target a

Ba cột: _ a _.

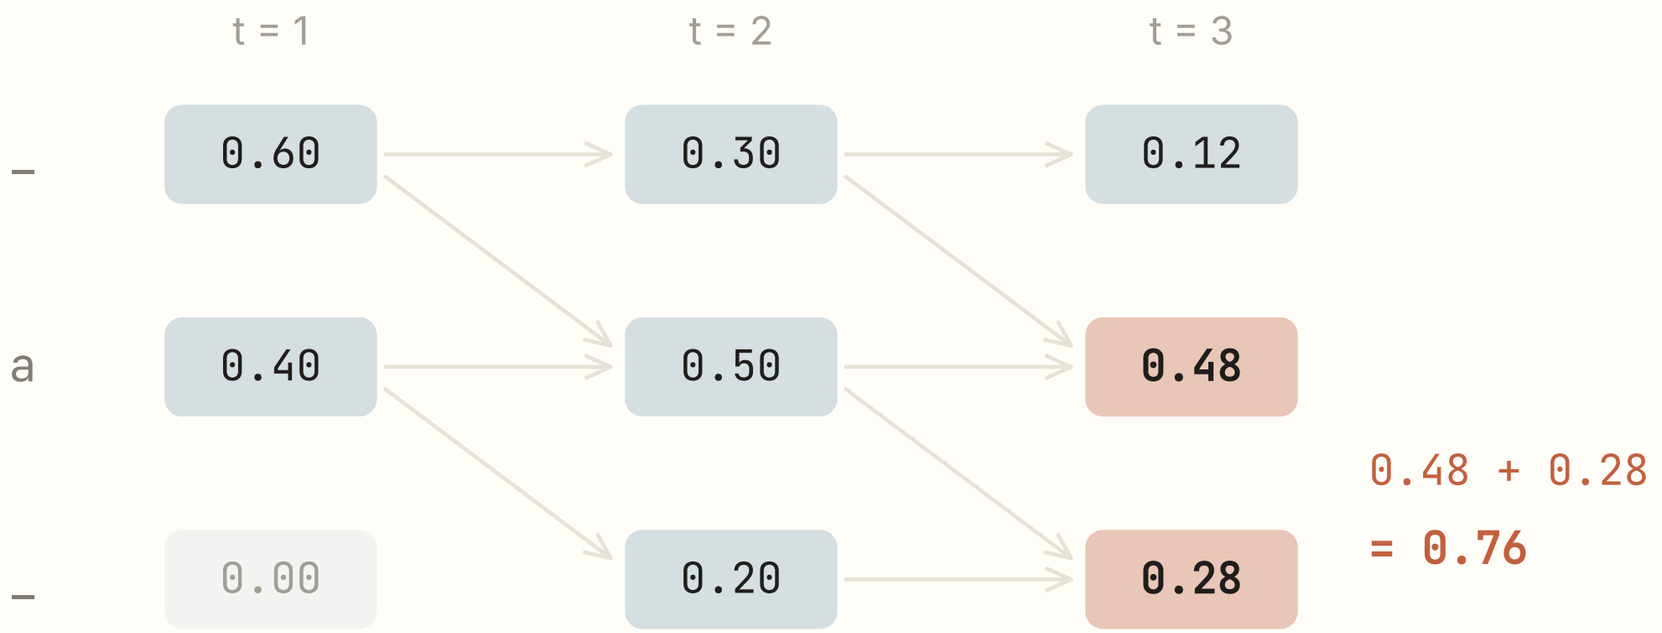
$t = 2$, ô a: $(0.4 + 0.6) \cdot 0.5 = 0.5$.

Hai ô cuối: $0.48 + 0.28 = 0.76$.

KẾT QUẢ

```
t=1: 0.60  0.40  0.00
t=2: 0.30  0.50  0.20
t=3: 0.12  0.48  0.28
P(a) = 0.76
```

Lưới α



Quy hoạch động trên lưới α: hai ô cuối cộng ra 0.76.

HỎI NHANH

Một bạn viết đúng truy hồi ở trên, nhưng bằng xác suất thường, cho một clip 1000 frame, xác suất mỗi frame quanh 0.1. Loss in ra `inf`, dù target ngắn và lengths đủ. Nguyên nhân là gì, và sửa thế nào?

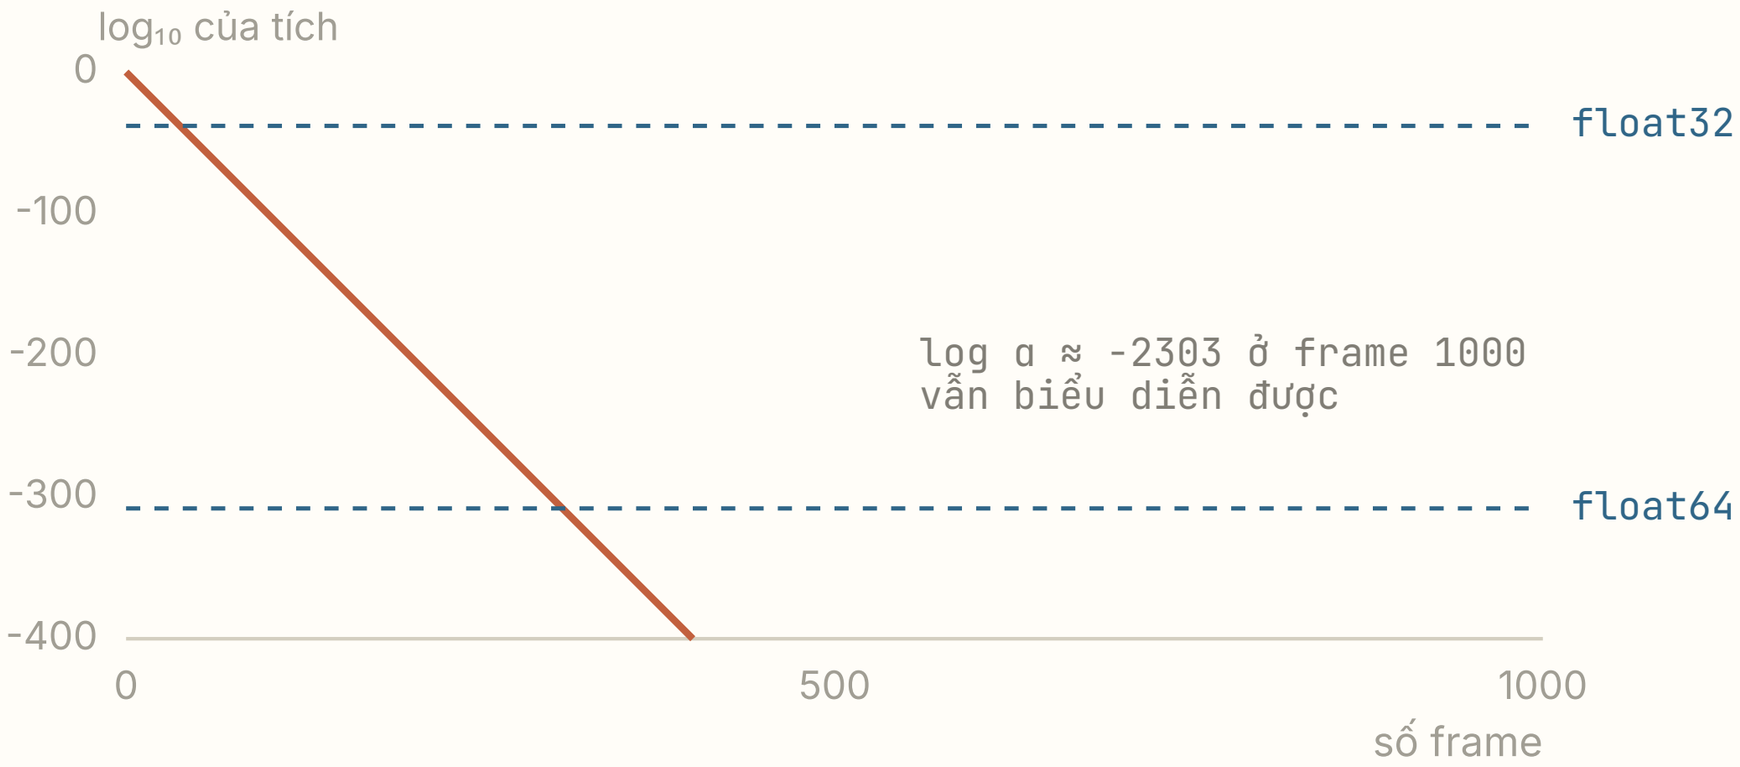
A T quá dài so với target nên mất path hợp lệ, cần cắt bớt frame

B Tích 10^{-1000} tràn dưới thành 0, cần chuyển sang log-space

C Sai số làm tròn cộng dồn qua 1000 bước, cần đổi sang `float32`

D Bảng xác suất chưa chuẩn hóa, cần chia mỗi hàng cho tổng của nó

Tích nhỏ dần tới 0



Tích xác suất nhỏ dần về 0 sau vài chục frame; log-space thì không.

Đối chiếu PyTorch

`CTCLoss` nhận log probabilities `(T,B,C)`; `reduction='sum'` để so với $-\ln 0.76$.

Bảng ngẫu nhiên 12 frame, target `1 2 2 3`:

KẾT QUẢ

```
DP = 10.588453, CTCLoss = 10.588453
```

KẾT QUẢ

```
(3, 1, 2)
CTCLoss = 0.2744
target aa, 2 frame: inf = True
```

Cần ít nhất $U + r$ bước

aa cần a _ a: 3 bước.

r là số cặp nhãn giống nhau đứng liền nhau trong target.

`zero_infinity` chỉ che loss, không thêm bước.

HỎI NHANH

Khối `CTCLoss` ở trên cho target `aa` với chỉ hai frame. Vì sao loss là `inf`?

A Vì CTC không biểu diễn được hai chữ giống nhau liền nhau

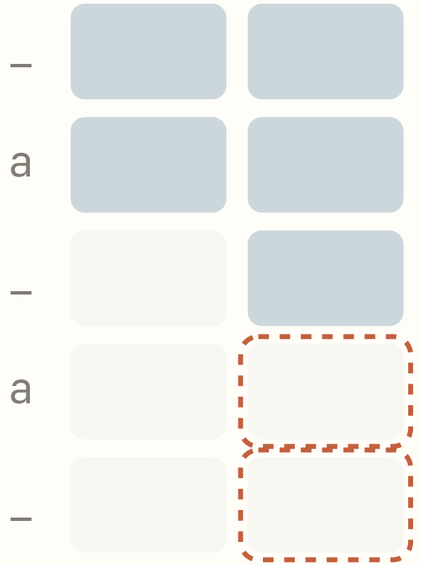
B Vì target phải ghi blank giữa hai `a` mà lại thiếu

C Vì mỗi nhãn cần ít nhất hai frame, tổng cộng là bốn

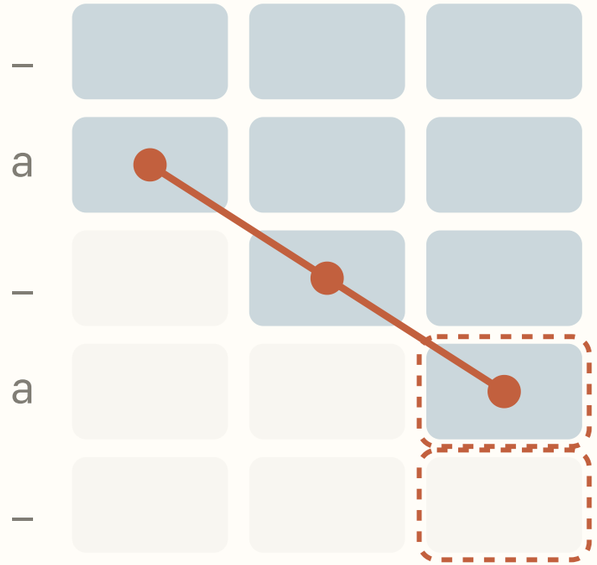
D Vì hai `a` liền nhau cần blank chen giữa, tối thiểu 3 bước

Hai frame không đủ cho aa

T = 2: không tới ô cuối



T = 3: a _ a



khung đứt: hai ô path phải dừng ở frame cuối

Target “aa” cần blank chen giữa, nên 2 frame không đủ.

03

Encoder–decoder và Whisper

Sinh chữ với ngữ cảnh

$$P(y \mid X) = \prod_{u} P(y_u \mid y_{<u}, X).$$

Train: teacher forcing và causal mask. Suy luận: nhận lại token vừa sinh.

Cross-attention đọc encoder; không blank, không collapse.

Whisper đọc từng cửa sổ 30 giây

16 kHz, log-mel 25 ms, bước 10 ms: 3000 frame.

Conv stride 2: 1500 vị trí encoder.

Token khởi đầu: `<|startoftranscript|>`, `<|vi|>`, `<|transcribe|>`.

`<|translate|>`: dịch sang tiếng Anh.

Dùng processor đi kèm checkpoint.

Kiến thức ngôn ngữ: giúp và hại

Decoder chọn câu có nghĩa khi âm mờ.

Clip im lặng, nhiễu: vẫn sinh chữ, có khi lặp.

Qwen2-Audio, Voxtral nhận chỉ dẫn: “chép nguyên lời” khác “tóm tắt”.

Processor, template, adapter theo từng kiến trúc.

HỎI NHANH

Với một clip tiếng Việt, Whisper trả về câu tiếng Anh trôi chảy, đúng ý người nói. WER so với reference tiếng Việt gần bằng 1. Nên kiểm gì trước?

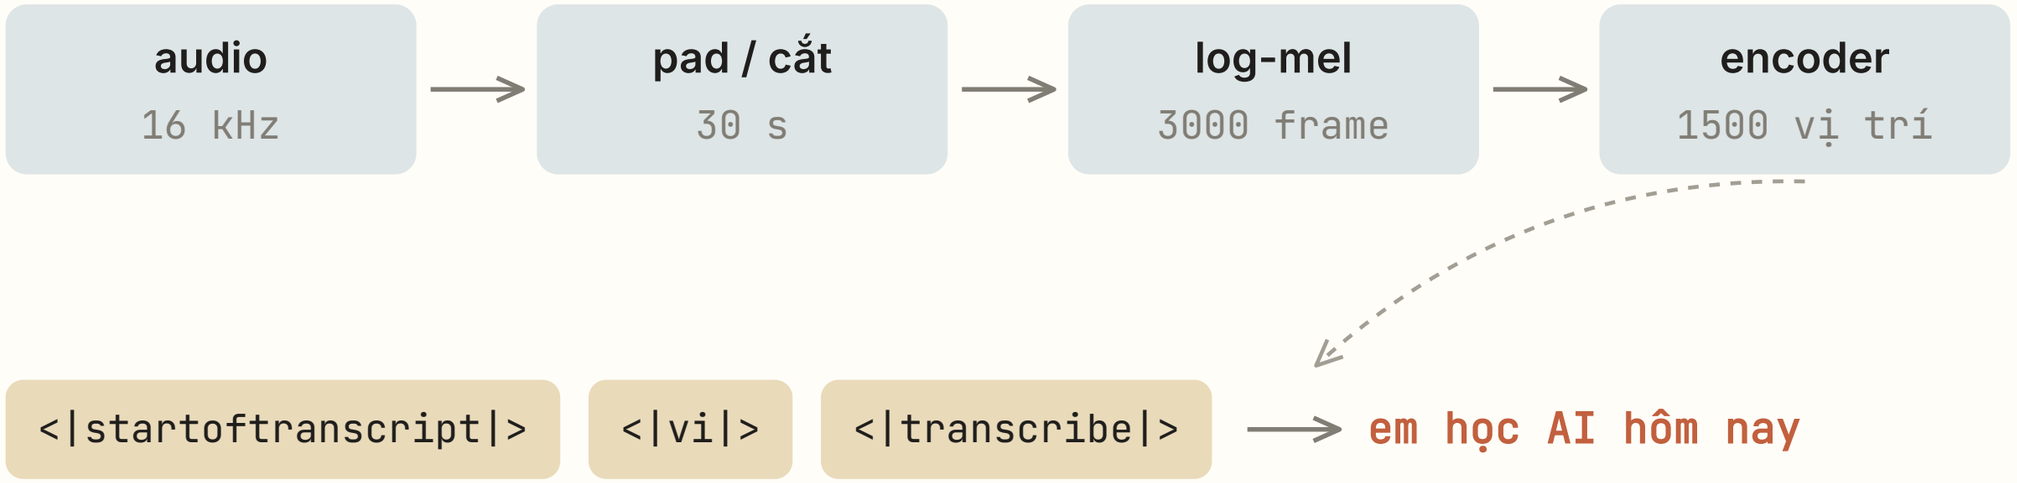
A Beam size quá nhỏ nên decoder chọn nhầm ngôn ngữ

B Reference có dấu tiếng Việt, còn output thì không

C Dãy token khởi đầu đang chọn task `<|translate|>`

D Sample rate 16 kHz quá thấp cho tiếng Việt

Một clip đi qua Whisper



decoder bắt đầu bằng dãy token chọn ngôn ngữ và việc cần làm

Whisper đưa audio về 30 giây, 3000 frame log-mel, 1500 vị trí encoder.

04

WER và dynamic programming

Đếm sửa, xóa và chèn

$$\mathrm{WER} = \frac{S + D + I}{N_{\mathrm{ref}}}.$$

S là thay, D là xóa, I là chèn; N_{ref} là số token tham chiếu.

Levenshtein distance tìm tổng lỗi nhỏ nhất.

WER của một câu

Reference: `em học ai hôm nay.`

Prediction: `em học toán nay.`

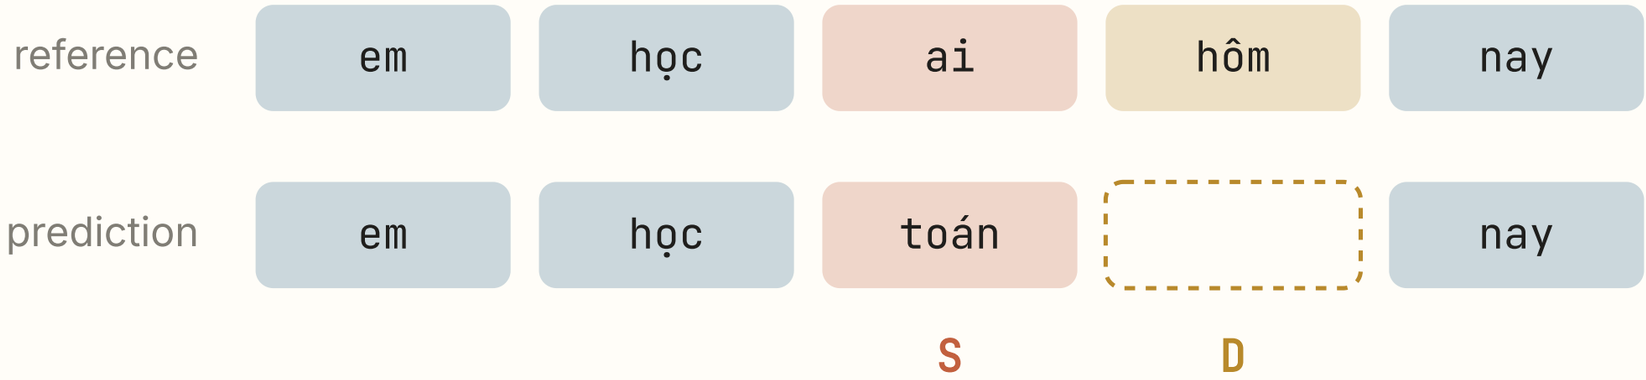
Thay `ai` bằng `toán`; xóa `hôm`.

KẾT QUẢ

```
lỗi = 2, token tham chiếu = 5
WER = 0.400
```

DP hai hàng: bộ nhớ tuyến tính theo độ dài prediction.

Thay một từ, xóa một từ



$$WER = (S + D + I) / N = (1 + 1 + 0) / 5 = 0.4$$

Một thay thế, một xóa trên 5 từ: WER 0.4.

WER là một đường đi trên ma trận DP

reference \ prediction		em	học	toán	nay
	0	1	2	3	4
em	1	0	1	2	3
học	2	1	0	1	2
ai	3	2	1	1	2
hôm	4	3	2	2	2
nay	5	4	3	3	2 ← distance 2

Bảng edit distance; đường tô màu là một cách ghép tối ưu.

HỎI NHANH

Reference có 4 token. Prediction giữ đúng cả 4 token ấy và chèn thêm 5 token. WER bằng bao nhiêu?

A 0

B 0.56

C 1

D 1.25

Chuẩn hóa trước khi chấm

ọ: một ký tự (NFC) hoặc o cộng dấu rời (NFD).

“lập trình”: một từ, hai token.

Chữ hoa, dấu câu, số, Unicode: theo scorer của đề, cho cả hai phía.

CER: sai một dấu mất một ký tự; WER mất cả từ.

HỎI NHANH

Reference là `mai thi`, prediction là `thi đấu`. Hai đội cài cùng một DP, nhưng phá hòa khác nhau khi lần backpointer. Một đội báo 2 substitution, đội kia báo 1 deletion và 1 insertion. WER trong hai báo cáo là bao nhiêu?

A Đội đầu 1.0, đội sau 0.5 vì giữ được `thi`

B Đội đầu 0.5, đội sau 1.0 vì thay thế nhẹ hơn

C Cả hai đều 1.0, vì tổng lỗi tối ưu chỉ có một

D Không xác định được, vì alignment không duy nhất

Gộp corpus đúng cách

Một lỗi trên câu 3 token; câu 8 token đúng.

Corpus: $1/11$.

Mean câu: $(1/3 + 0)/2$.

KẾT QUẢ

```
[1, 0] [3, 8]
corpus WER = 0.091
mean sentence WER = 0.167
```

Hai cách gộp

em học AI — sai 1 / 3

mai lớp em học lập trình thi đấu — đúng 8 / 8

corpus

1/11 = 0.091

trung bình câu

(1/3 + 0)/2 = 0.167

Corpus WER 0.091; trung bình WER từng câu 0.167.

HỎI NHANH

Validation có một câu 4 token và một câu 36 token. Model A sai 2 token ở câu ngắn, đúng hết câu dài. Model B đúng hết câu ngắn, sai 6 token ở câu dài. Corpus WER và trung bình WER từng câu chọn model nào?

A Corpus chọn B, trung bình câu chọn A

B Corpus chọn A, trung bình câu chọn B

C Cả hai cách đều chọn A

D Cả hai cách đều chọn B

HỎI NHANH

Ba clip có tổng cộng 20 token reference và 2 lỗi. Clip thứ tư im lặng, reference rỗng, nhưng model sinh ra 4 từ “cảm ơn đã xem”. Corpus WER của cả bốn clip bằng bao nhiêu?

A Không tính được, vì chia cho 0

B 0.10

C 0.25

D 0.30

05

Hậu xử lý và dữ liệu thật

Trôi chảy hơn chưa chắc đúng hơn

Reference: `mai thi ai.`

Transcript gốc đúng.

Sửa thành `mai thi toán` là đổi nội dung.

KẾT QUẢ

```
gốc: WER = 0.000
sửa: WER = 0.333
```

Giữ transcript gốc; so cặp trước và sau trên cùng validation.

HỎI NHANH

Reference là `phòng mười lăm`. ASR ra `phòng mười năm`, rồi language model sửa thành `phòng 15`, đúng ý người nói. Scorer viết thường, tách theo khoảng trắng, và không chuẩn hóa số. WER trước và sau khi sửa là bao nhiêu?

A 0.333, rồi tăng lên 0.667

B 0.333, rồi giảm về 0

C 0.333, rồi giữ nguyên 0.333

D 0.667, rồi giảm về 0.333

Chạy Whisper trên máy

Script của chương: checkpoint có sẵn trên máy, CPU, `task="transcribe"`.

Ghi transcript, lỗi từng clip, thời gian và corpus WER.

Clip quá 30 s: dừng; cần chunking riêng.

Clip ngắn vẫn được pad lên 30 s.

HỎI NHANH

Trên một clip 30 giây, Whisper chép mất 6 giây. Test có 1500 clip, mỗi clip 3 giây. Một bạn ước thời gian là $1500 \cdot 6 \cdot 3/30 = 900$ giây. Ước lượng này sai ở đâu?

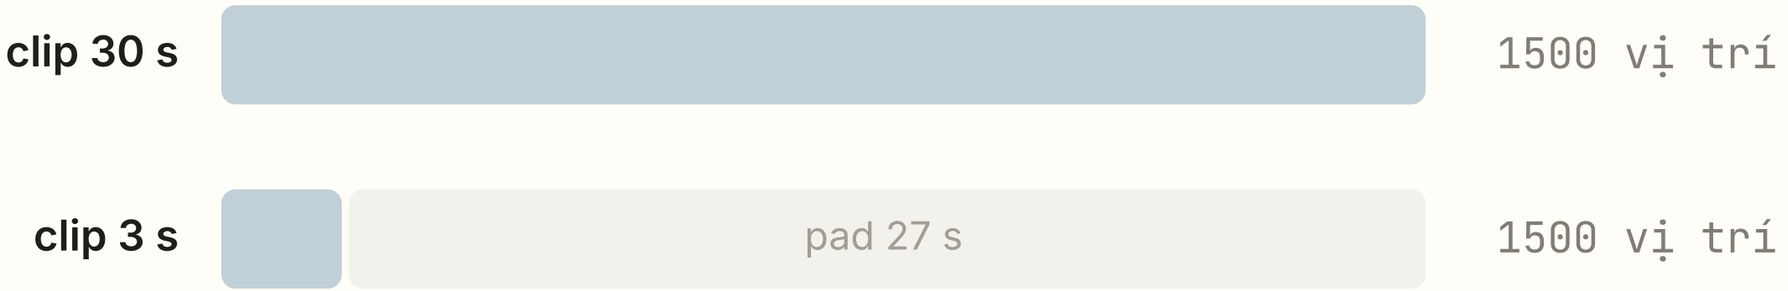
A Không sai, vì thời gian tỉ lệ thuận với thời lượng audio

B Mỗi clip được pad lên 30 giây, nên phần encoder không giảm

C Thời gian chỉ phụ thuộc số token, nên phải nhân theo số từ

D Còn thiếu thời gian resample, phần tốn nhất của pipeline

Clip ngắn vẫn chiếm đủ 30 giây



encoder làm cùng một lượng tính; chỉ decoder ngắn đi

Clip 3 giây vẫn được pad lên 30 giây, nên thời gian chạy giảm ít.

Khi đi thi

- Scorer local đúng normalization của đề.
- Đo thời gian trên clip giống test.
- CTC: kiểm độ dài; loss `inf` là lỗi dữ liệu.

06

Luyện đề

LUYỆN ĐỀ 1

CTC loss vẫn dao động sau 50 epoch, thỉnh thoảng ra `inf`. Nên kiểm gì trước?

A Dữ liệu, gồm target và lengths, rồi tới đầu vào của loss

B Gradient và độ cong, rồi giảm learning rate

C Norm gradient, LR range test, momentum

D Tăng batch, thêm clipping, đổi sang AdamW

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 282

LUYỆN ĐỀ 2

Log-mel có 100 frame mỗi giây. Đội tăng tổng stride của encoder từ 4 lên 8 để train nhanh hơn. Một clip 2.4 giây có transcript 29 ký tự, trong đó có 2 chỗ hai ký tự giống nhau đứng liền nhau. Với stride 8, CTC còn train được trên clip này không?

A Được, vì 30 bước vẫn nhiều hơn 29 ký tự

B Không, vì 30 bước ít hơn 31 bước tối thiểu

C Được, vì CTC tự chèn blank vào target khi thiếu

D Không, vì cần ít nhất 58 bước, gấp đôi số ký tự

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q1.1(b)

Chốt ý

CTC cộng mọi alignment có blank bằng DP; encoder–decoder sinh token theo task.

WER đếm sửa, xóa, chèn sau normalization của scorer; corpus WER chia tổng lỗi cho tổng token.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; đổi bảng xác suất, tính α trên giấy rồi đối chiếu `ctc_forward` và `CTCLoss`.