Multimodal

Ghép nhiều nguồn và đo nguồn nào giúp

Ảnh, chữ, lời thay đổi

Ảnh cho biết phòng học.

Chữ cho biết hoạt động.

Audio báo thay đổi phút cuối.

CÂU HỎI

Ghép ở đâu và làm sao biết nguồn mới có ích?

Mục tiêu buổi này

- Ghép đúng cặp theo ID và theo thời gian.
- Phân biệt early fusion, late fusion, gating.
- Đo đóng góp bằng ablation; xử lý thiếu nguồn.
- Học căn chỉnh từ cặp; đọc VLM, kiểm schema.

01

Cặp dữ liệu và early fusion

Cùng một sự việc, cùng ID

Ảnh nào đi với caption nào?

Audio thuộc clip nào và khoảng thời gian nào?

Join theo ID; đếm ID trùng và thiếu.

Split theo sự kiện, người hoặc file trước khi tạo bản sao.

Shape đúng chưa bảo đảm cặp đúng.

HỎI NHANH

Ảnh và caption nằm ở hai CSV được sắp xếp khác nhau, và cả hai đều có cột `id`. Ghép thế nào cho đáng tin nhất?

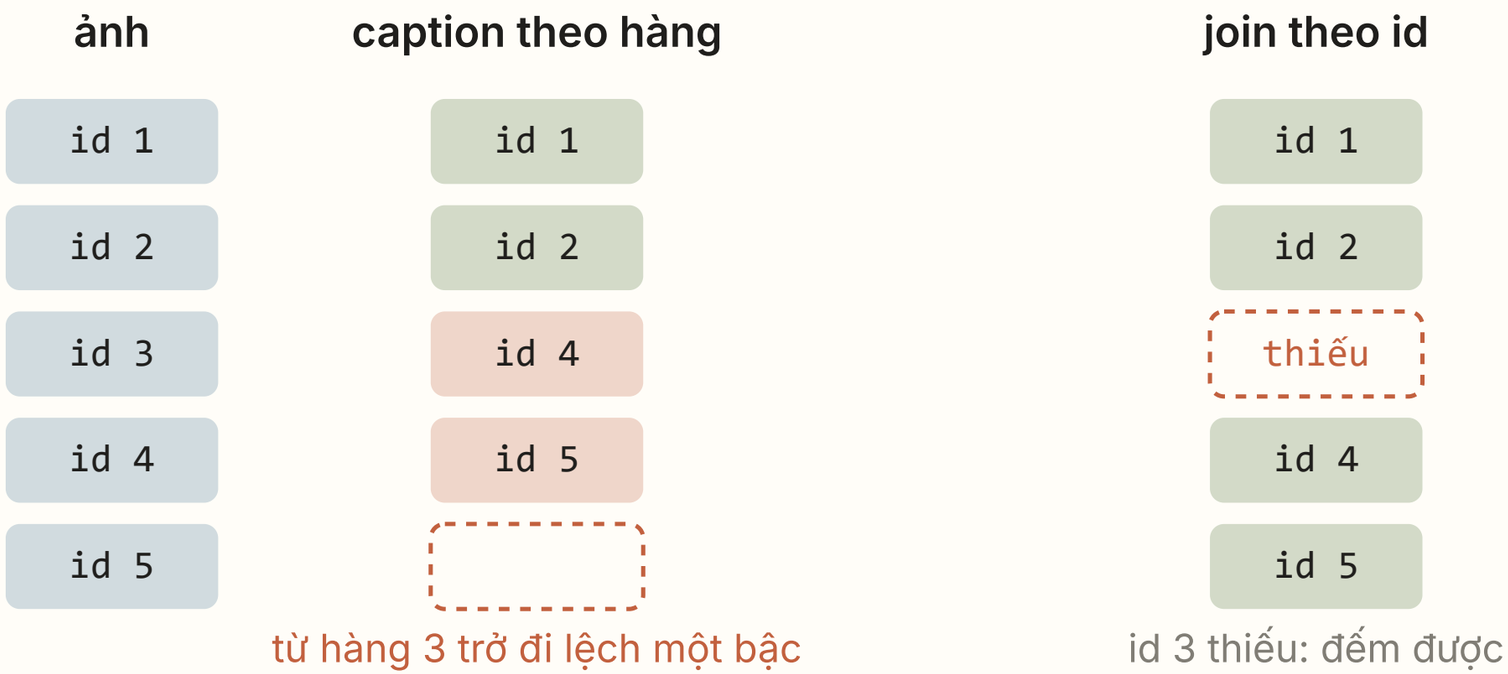
A Ghép hàng thứ i với hàng thứ i, vì hai file có cùng số dòng

B Sắp cả hai file theo `id`, rồi ghép theo thứ tự hàng

C Join theo `id`, rồi đếm số ID bị trùng và bị thiếu

D Chỉ dùng ảnh, để khỏi phải kiểm quan hệ cặp

Ghép theo hàng và join theo id



Năm ảnh, bốn caption (thiếu id 3): ghép theo thứ tự hàng làm mọi hàng sau lệch một bậc mà shape vẫn đúng; join theo id giữ đúng cặp và để lộ chỗ thiếu.

Căn theo thời gian

Video 25 khung mỗi giây.

Đặc trưng âm hop 10 ms: 100 frame mỗi giây.

Đổi chỉ số về giây trước:

$$t \qquad k \qquad t$$

Lệch vài khung: lời nói đi với khuôn mặt khác.

HỎI NHANH

Video có 25 khung mỗi giây, còn đặc trưng âm có hop 10 ms. Tiếng còi bắt đầu ở frame âm 430, đếm từ 0. Khung hình nào chứa thời điểm đó?

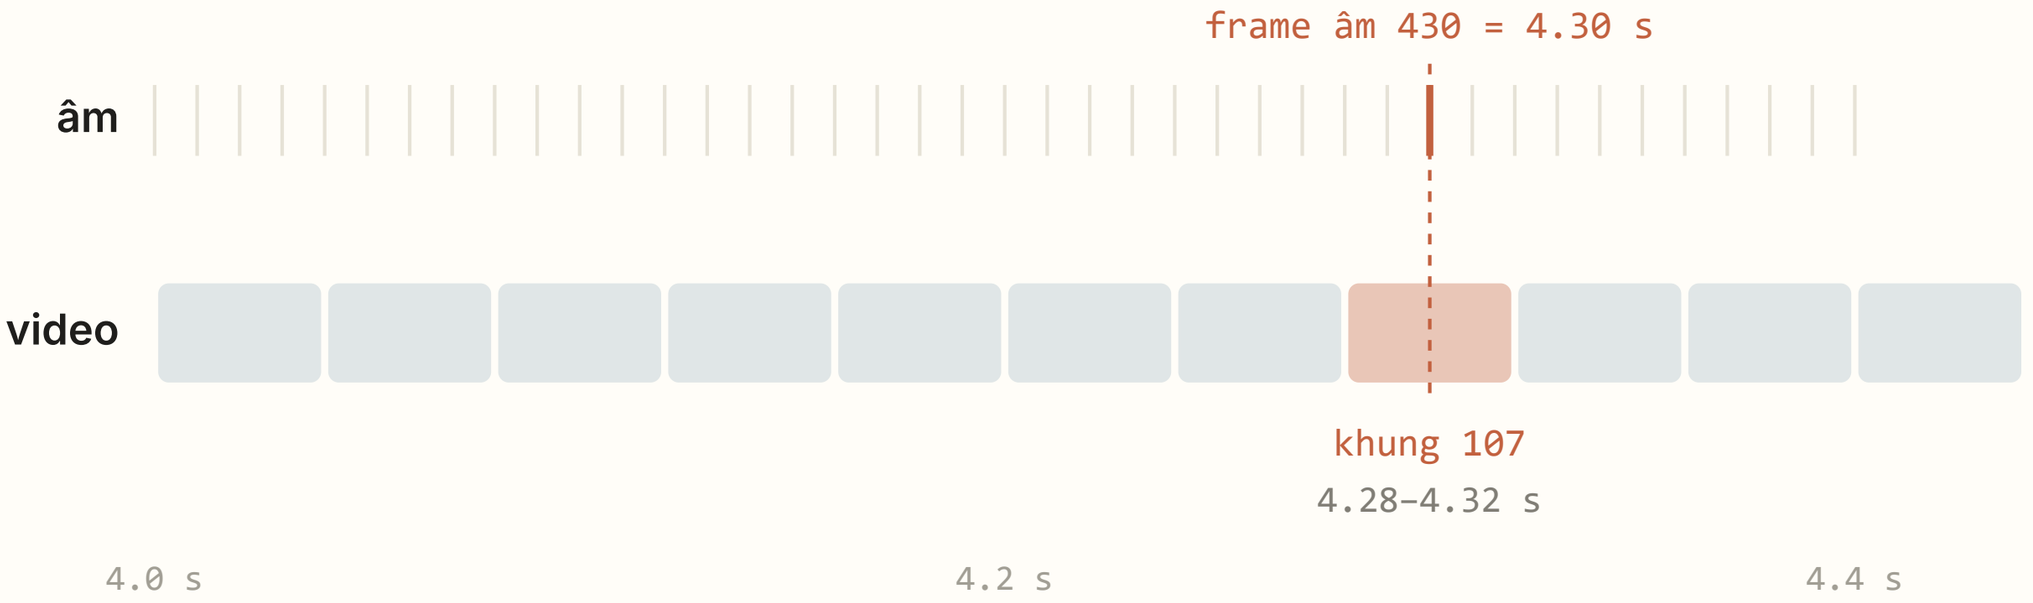
A Khung 17

B Khung 107

C Khung 430

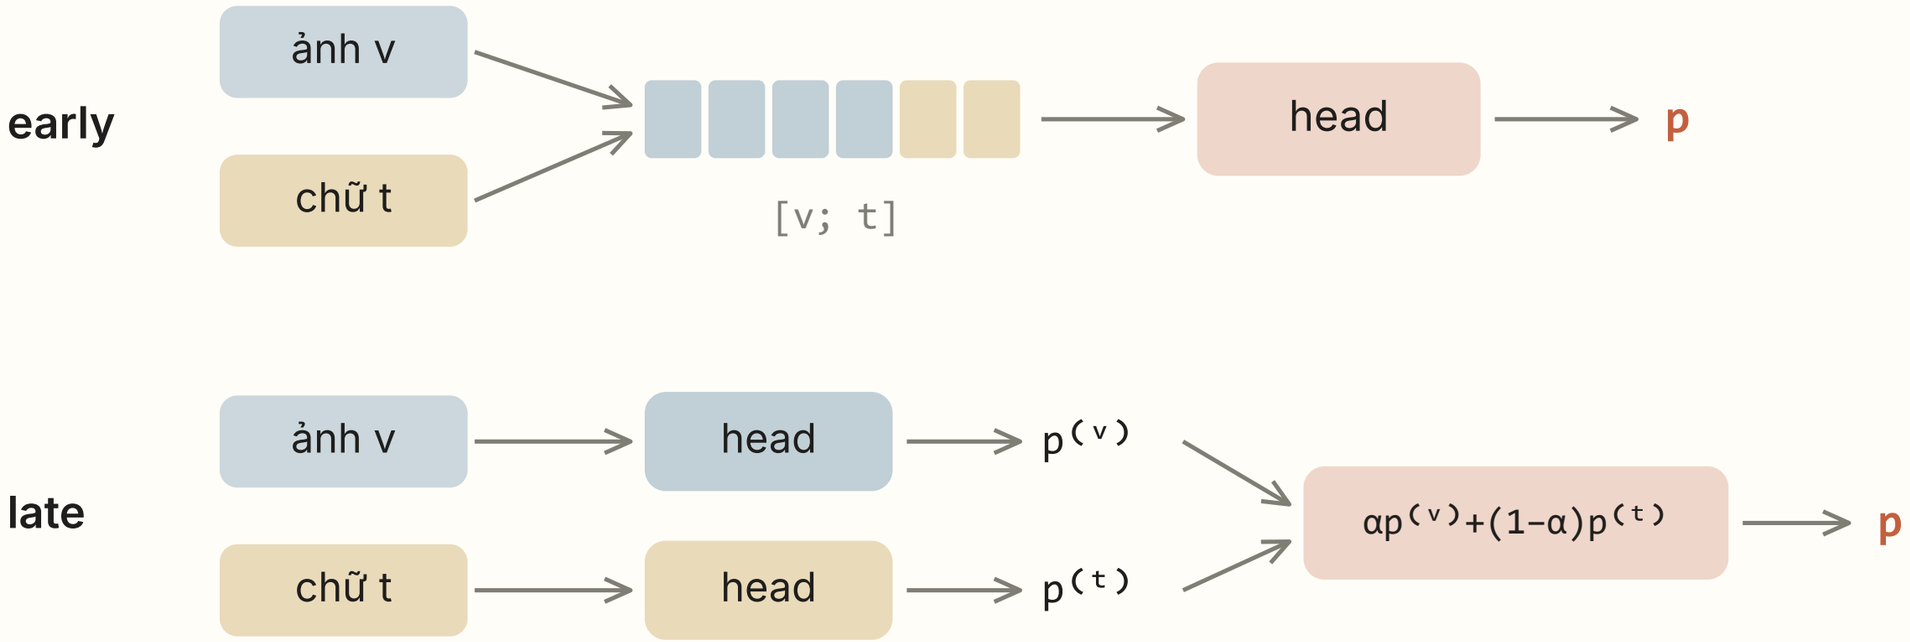
D Khung 1075

Hai nhịp thời gian



Hai nhịp khác nhau: âm 100 frame mỗi giây, video 25 khung mỗi giây. Frame âm 430 bắt đầu ở 4.30 s, rơi vào khung hình 107 (4.28 đến 4.32 s).

Ghép trước head hay sau head?



Early fusion nối vector hai nguồn thành một input cho một head; late fusion cho mỗi nguồn một head trên cùng các lớp, rồi gộp xác suất bằng trọng số α.

Concatenation giữ các nguồn

$$B \qquad B \qquad B$$

Linear head chỉ là tổng các điểm riêng:

$$b_v \quad t \quad a \quad b$$

Quy tắc tổng hợp XOR

Hai tín hiệu nhị phân khác nhau: lớp 1.

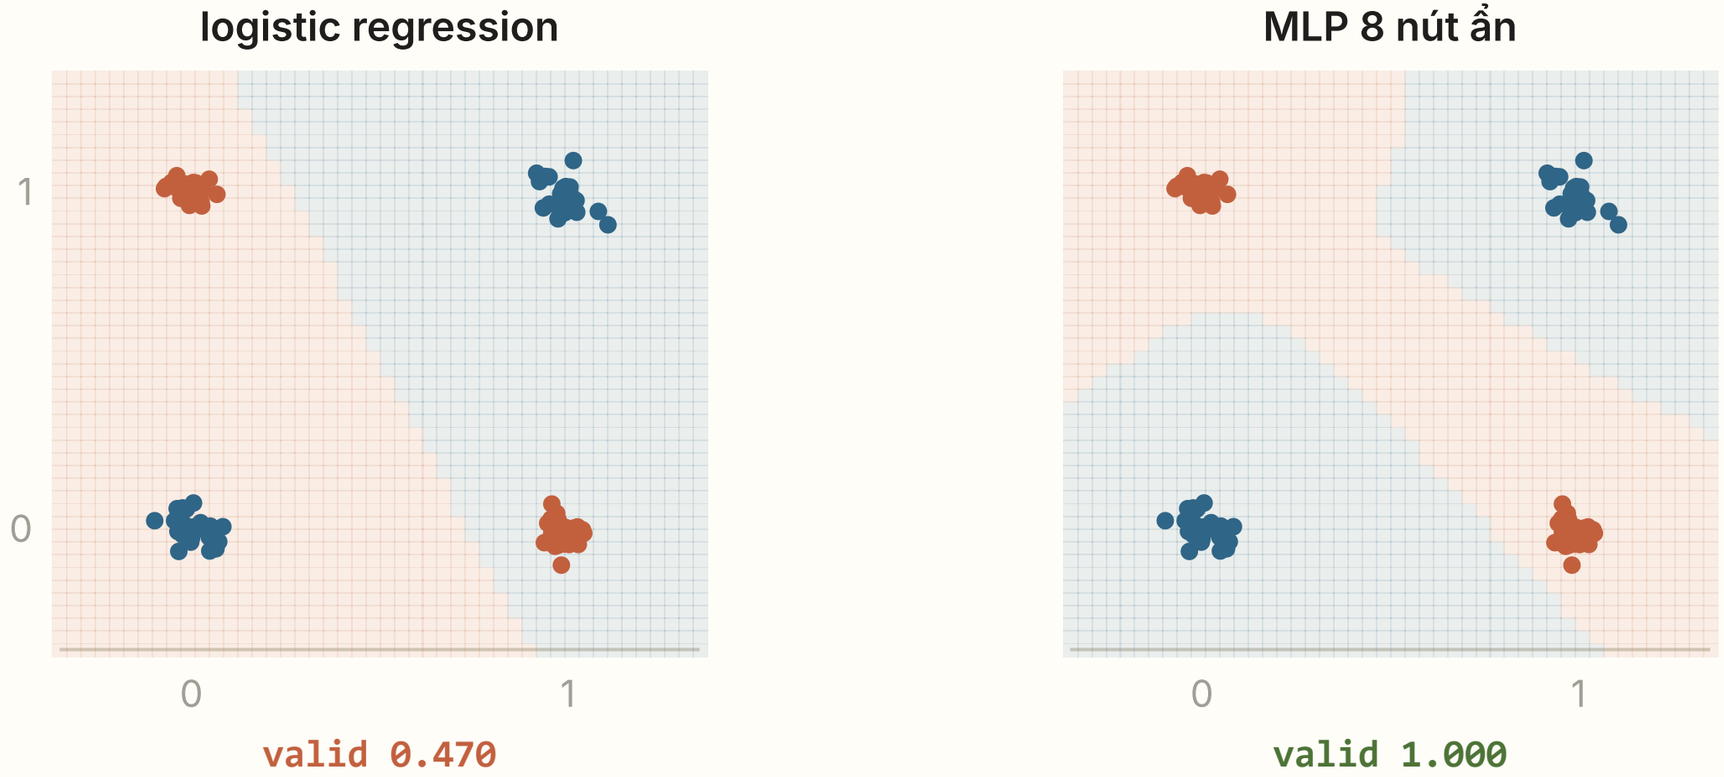
Tổng hai điểm riêng không đủ; cần hàm phi tuyến của cả hai.

KẾT QUẢ

```
linear: accuracy = 0.470
MLP: accuracy = 1.000
(400, 2)
```

100 mẫu validation: linear ngang đoán ngẫu nhiên.

Biên quyết định trên XOR



Dữ liệu XOR của bài (từ code): 100 điểm validation, cam là lớp 1. Một đường thẳng chỉ chia mặt phẳng làm hai nửa nên logistic regression đạt 0.470; MLP 8 nút ẩn tách đúng bốn góc.

HỎI NHANH

Với hai tín hiệu XOR ở trên, một đội giữ logistic regression, nhưng đưa vào x x x x thay cho x x. Kết quả thế nào?

A Tách được, vì nhãn bằng x x x x

B Vẫn không tách được, vì head vẫn tuyến tính

C Tách được, nhưng phải thêm cả x và x

D Không đổi gì, vì x x suy ra được từ x, x

02

Late fusion và ablation

Cùng lớp, cùng thang ý nghĩa

α^{v} α^{t} α

Các cột cùng `class_to_index`; α và calibration chọn trên validation.

Trung bình logits khác trung bình probabilities.

Gating: α σ g đổi theo từng mẫu.

Bảng xác suất đặt sẵn

Tám mẫu; hai nhánh sai ở những mẫu khác nhau.

Lỗi bổ sung là lúc fusion có ích nhất.

KẾT QUẢ

```
image: accuracy = 0.500
text: accuracy = 0.500
fusion: accuracy = 1.000
```

Dữ liệu thật: đo trên cùng validation.

Tính tay một sample

Nhãn 1; ảnh cho 0.40, chữ cho 0.85.

$$p$$

Gộp đúng mẫu này.

Nếu ảnh sai 0.01 còn chữ đúng nhẹ 0.55:

$$p$$

Nhánh tự tin sai kéo kết quả gộp sai.

Hai nguồn bù lỗi cho nhau

	y = 1	y = 1	y = 1	y = 1	y = 0	y = 0	y = 0	y = 0	
ảnh	0.9	0.8	0.4	0.3	0.1	0.2	0.6	0.7	0.500
chữ	0.4	0.35	0.85	0.9	0.55	0.65	0.25	0.2	0.500
fusion	0.65	0.575	0.625	0.6	0.325	0.425	0.425	0.45	**1.000**

xanh: đúng phía ngưỡng 0.5, cam: sai; hai nhánh sai ở những mẫu khác nhau

Bảng tám mẫu của bài: nhánh ảnh sai bốn mẫu, nhánh chữ sai bốn mẫu khác, nên trung bình hai xác suất đúng cả tám (accuracy 0.5, 0.5 rồi 1.0).

HỎI NHANH

Trên validation, nhánh ảnh đáng tin khi ảnh đủ sáng, còn với ảnh tối thì nhánh chữ đúng hơn. Cách gộp nào biểu diễn được quy tắc này?

A Late fusion với một α cố định, dò trên validation

B Early fusion với một linear head

C Gating, tức một mạng nhỏ cho ra α riêng cho từng mẫu

D Cộng logit hai nhánh, sau khi nhân nhánh ảnh với 2

Phá cặp có kiểm soát

Dịch vòng caption bốn vị trí, shape giữ nguyên.

```
wrongly_paired_text = np.roll(
    text_probability, 4
)
wrong_fusion = (
    image_probability + wrongly_paired_text
) / 2
```

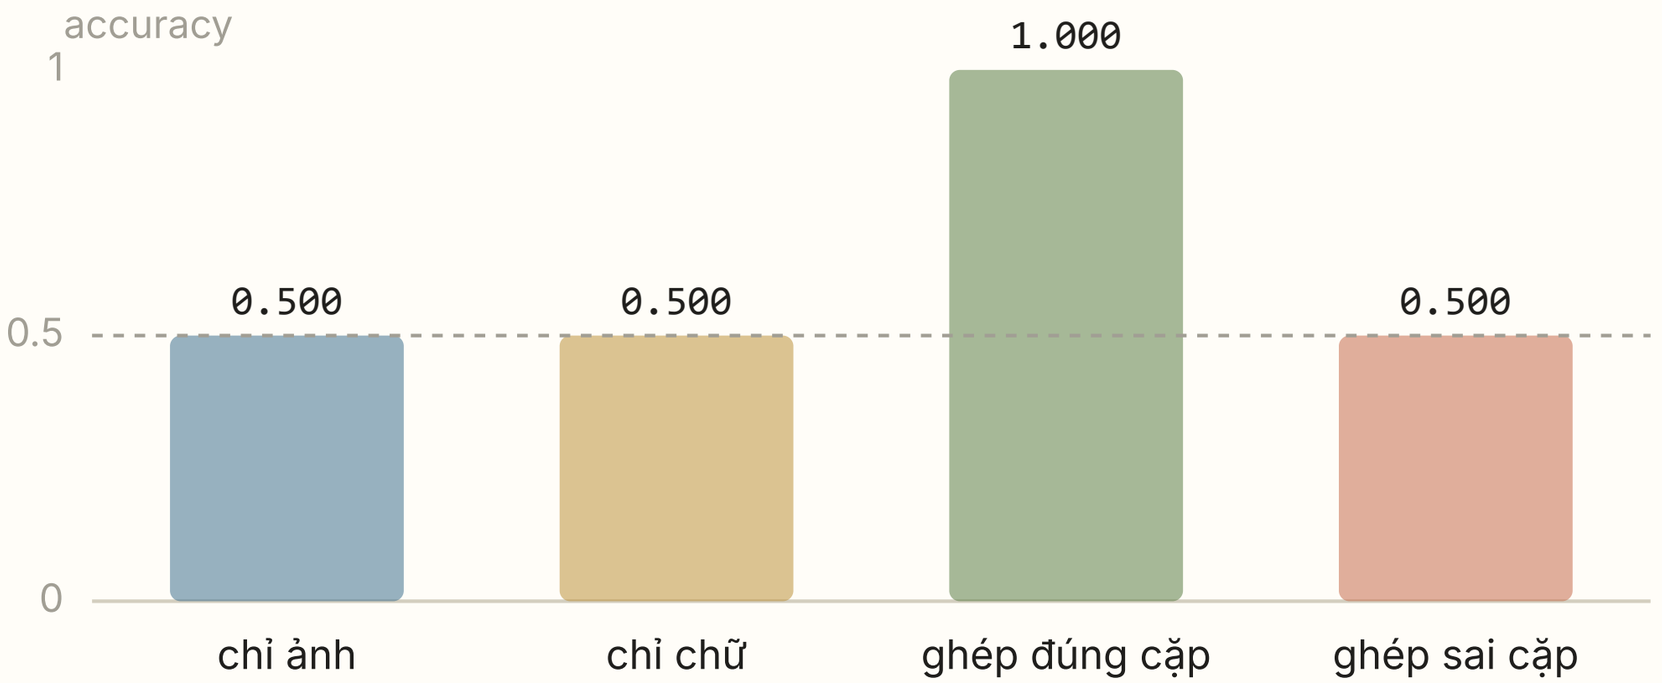
KẾT QUẢ

```
sai cap: accuracy = 0.500
```

Cặp dữ liệu là một phần thông tin.

Hỏi đáp ảnh: thử baseline chỉ đọc câu hỏi.

Bảng ablation



Ablation trên bảng tám mẫu (số từ output bài): mỗi nhánh riêng 0.500, ghép đúng cặp 1.000, dịch vòng caption bốn vị trí thì về 0.500 dù shape vẫn đúng.

HỎI NHANH

Model ảnh cộng caption đạt accuracy 0.84 trên 300 mẫu validation. Chỉ dùng ảnh thì được 0.83. Giữ ảnh, xáo caption giữa các mẫu, cũng được 0.83. Kết quả này nói lên gì?

A Caption là nguồn chính, còn ảnh chỉ thêm nhiễu

B Caption gần như không góp thêm gì ngoài ảnh

C Xáo caption làm hỏng dữ liệu, nên số đo vô nghĩa

D Fusion đã học tốt tương tác giữa ảnh và chữ

Thiếu modality

Đặt trọng số nhánh thiếu về 0, chuẩn hóa lại tổng trọng số.

Thiếu tất cả: dùng fallback đã quy định trước.

KẾT QUẢ

```
[0.3  0.25]
thieu nguon: accuracy = 0.875
```

Nhánh còn lại có thể đúng hoặc sai; không chia cho số nhánh ban đầu.

HỎI NHANH

Late fusion với trọng số đều. Một mẫu bị mất ảnh, còn nhánh chữ cho xác suất lớp 1 là 0.8. Đặt trọng số của ảnh về 0, rồi chuẩn hóa lại tổng trọng số, thì được bao nhiêu?

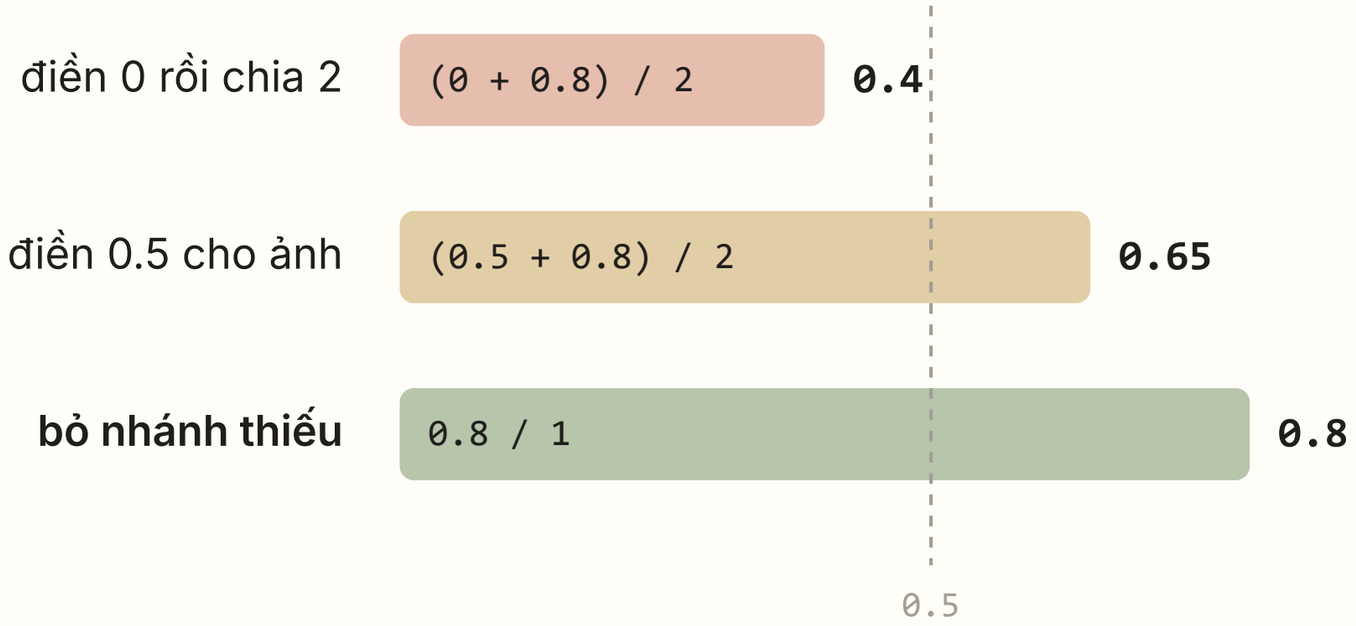
A 0.4

B 0.65

C 0.8

D 1.6

Ba cách xử lý nhánh thiếu



Một mẫu mất ảnh, nhánh chữ cho 0.8: điền 0 rồi chia 2 ra 0.4 (đổi cả đáp án), điền 0.5 kéo về 0.65, bỏ nhánh thiếu và chuẩn hóa lại trọng số giữ 0.8.

03

Biểu diễn chung

Cùng chiều chưa đủ

Ảnh `(B,512)`, chữ `(B,512)`: tích vô hướng tính được.

Hai encoder train riêng có hai hệ trục riêng.

Căn chỉnh phải học từ các cặp: CLIP, projector.

Học W từ 40 cặp

Nội dung 8 chiều, mỗi encoder xoay hệ trục riêng.

$$W \quad X_v W \quad X_t$$

Đo recall@1 trên 20 cặp validation.

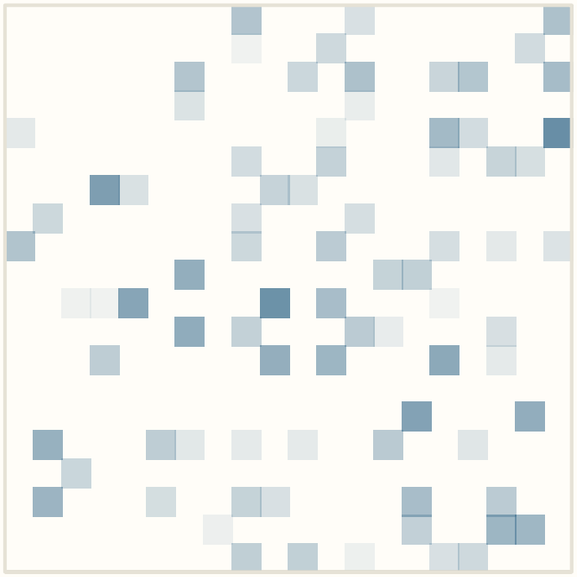
KẾT QUẢ

```
cosine cap dung, chua can chinh: -0.019
recall@1 chua can chinh: 0.05
recall@1 sau khi hoc W: 0.95
recall@1 khi hoc W tu cap bi xao: 0.00
```

Thông tin căn chỉnh nằm ở quan hệ cặp.

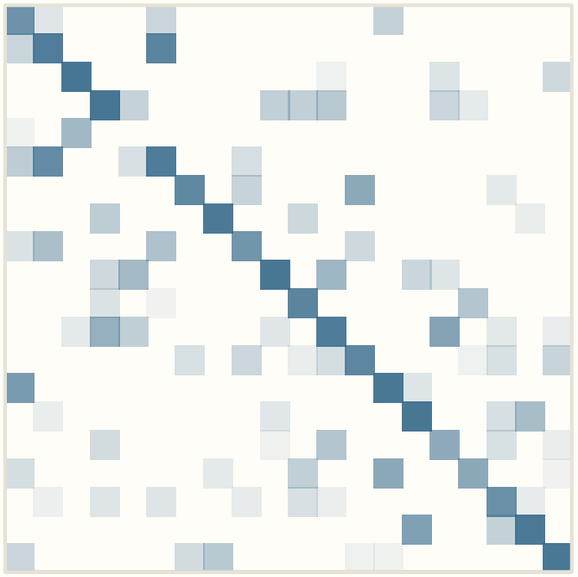
Đường chéo của ma trận cosine

chưa căn chỉnh



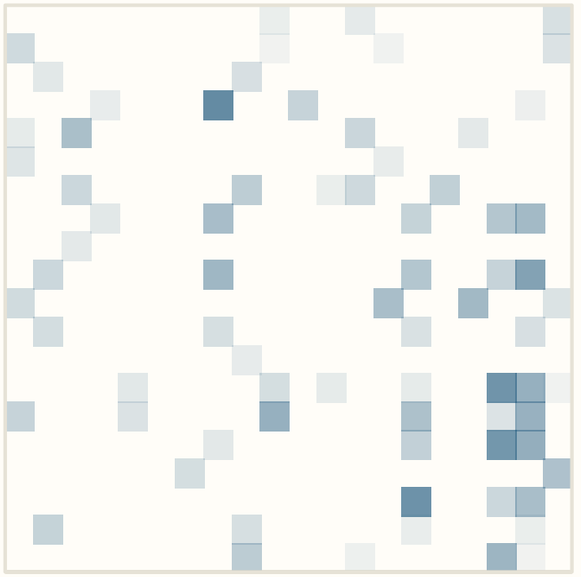
recall@1 0.05

học W từ cặp đúng



recall@1 0.95

học W từ cặp xáo



recall@1 0.00

Cosine giữa 20 ảnh (hàng) và 20 caption (cột) validation, từ code bài: chưa căn chỉnh thì không có đường chéo; W học từ cặp đúng làm đường chéo sáng lên; W học từ cặp xáo thì không.

Học riêng hay học chung

HỎI NHANH

Một đội lấy encoder ảnh và encoder chữ train riêng, cùng 512 chiều, rồi tính cosine trực tiếp để tìm ảnh cho 1000 câu. Mỗi câu có đúng một ảnh đúng trong 1000 ảnh. Recall@1 ra 0.001. Vì sao?

A Quên chuẩn hóa vector, chuẩn hóa xong sẽ ổn

B Đây là mức đoán bừa, vì hai hệ trục chưa được căn chỉnh

C 512 chiều quá ít, phải dùng encoder lớn hơn

D Phải dùng khoảng cách Euclid thay cho cosine

HỎI NHANH

Trong thí nghiệm, W có số, và mỗi cặp cho 8 phương trình. Nếu chỉ có 8 cặp train thì sao?

A `lstsq` báo lỗi, vì không đủ phương trình

B Vẫn tốt như với 40 cặp, vì W chỉ là một phép xoay

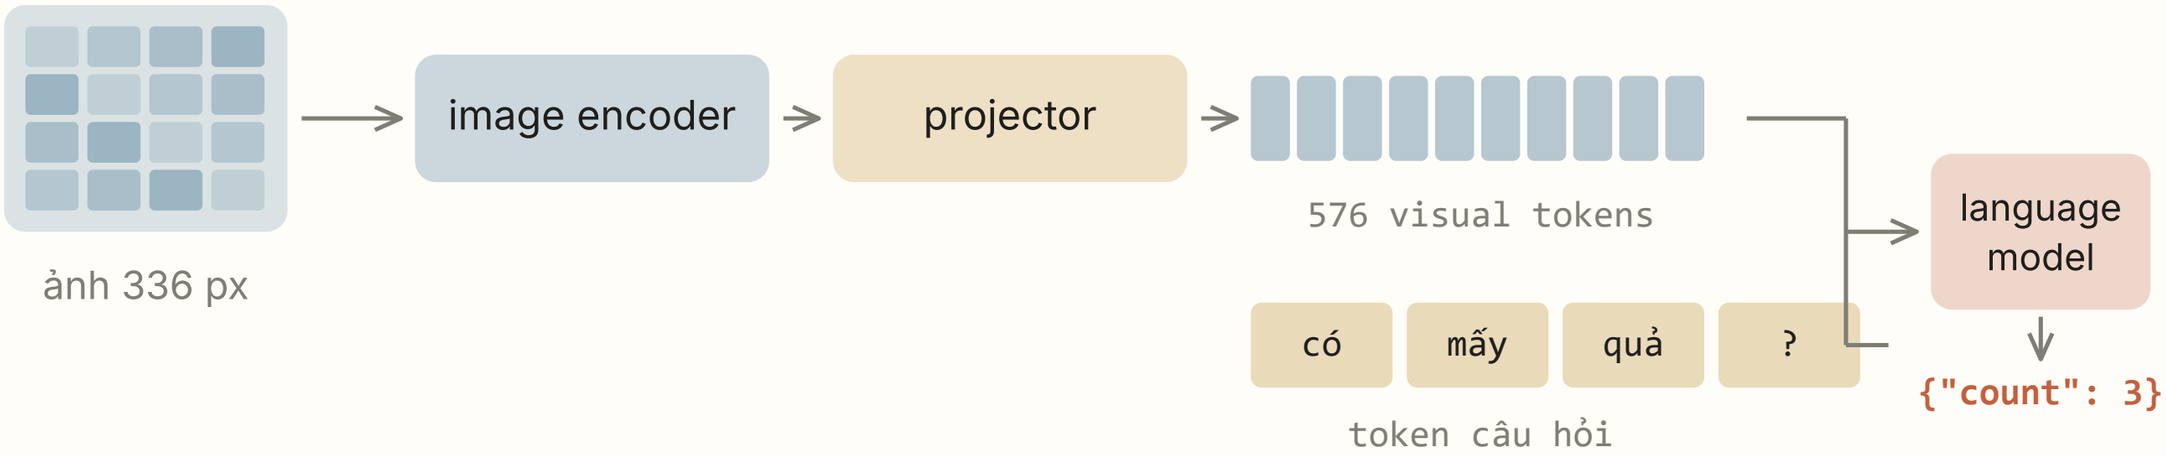
C Phải có ít nhất 64 cặp mới học được W

D W khớp đúng 8 cặp train, kể cả phần nhiễu

04

VLM và output

Cùng ảnh, câu hỏi khác



VLM kiểu LLaVA: image encoder rồi projector biến ảnh thành 576 visual tokens; chúng được nối với token câu hỏi và language model đọc cả chuỗi để sinh đáp án.

Chèn token hay cross-attention

Chèn (LLaVA-1.5): ảnh 336 px, patch 14 cho visual tokens nối với câu hỏi.

Self-attention đọc cả chuỗi.

Cross-attention (Flamingo): query từ chữ, key và value từ ảnh.

Chuỗi chữ không dài thêm; cần train lớp mới.

HỎI NHANH

Câu hỏi có 40 token, còn ảnh cho 576 visual tokens. Nếu chèn visual tokens vào chuỗi, language model phải đọc một chuỗi dài bao nhiêu? Nếu dùng cross-attention từ chữ sang ảnh, ma trận điểm của một head có shape gì?

A Chuỗi 616 token, ma trận `(40, 576)`

B Chuỗi 616 token, ma trận `(576, 40)`

C Chuỗi 40 token, ma trận `(616, 616)`

D Chuỗi 576 token, ma trận `(40, 40)`

Chuỗi dài ra hay ma trận chữ × ảnh

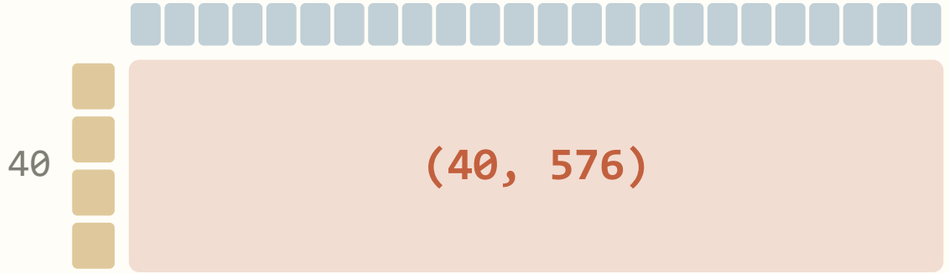
chèn visual tokens



576 + 40 = 616 token

self-attention 616 × 616

cross-attention chữ → ảnh



576 key, value từ ảnh

chuỗi chữ vẫn dài 40

Hai cách đọc ảnh: chèn 576 visual tokens trước 40 token câu hỏi thành chuỗi 616; cross-attention giữ chuỗi chữ 40 token, mỗi head có ma trận điểm 40 × 576 (query chữ, key ảnh).

Processor và template là hợp đồng

Resize và crop quyết định vùng ảnh nhìn thấy.

Template chèn ảnh, chữ và special tokens đúng vị trí.

“Có mấy quả bóng?” cần số đếm.

“Bóng màu gì?” cần nhãn màu.

Checkpoint, processor và template phải đi cùng nhau.

Parser kiểm định dạng

Ba chuỗi JSON đặt sẵn:

`{"count": 3}` nhận 3.

`{"count": true}` và `{"count": "3"}` bị từ chối: boolean và chuỗi không phải số nguyên theo schema.

KẾT QUẢ

```
3
count phai la so nguyen khong am
count phai la so nguyen khong am
```

Schema đúng chưa chứng minh nội dung ảnh đúng.

HỎI NHANH

Parser `parse_count` ở trên nhận chuỗi nào?

A `{"count": 3.0}`

B `{'count': 3}`

C `{ "count" : 3 }`

D `{"count": 3, "unit": "qua"}`

Bẫy cài đặt

Kiểm ID cặp, shape, thứ tự lớp, mask trước khi train.

Đổi một nhánh: đo lại calibration và trọng số.

VLM: tách lỗi vùng ảnh, hiểu câu hỏi, schema.

Sửa đúng bước trước khi fine-tune.

HỎI NHANH

Thay nhánh chữ bằng một model mới. Accuracy riêng của nhánh chữ tăng từ 0.78 lên 0.83, nhưng fusion với α cũ lại giảm từ 0.86 xuống 0.84. Bước tiếp theo nên là gì?

A Quay lại model chữ cũ, vì điểm cuối là điểm của fusion

B Giữ α cũ, và train model chữ mới thêm vài epoch

C Chọn α sao cho điểm test cao nhất có thể

D Dò lại α và calibration trên validation

Khi đi thi

- Bảng ablation: từng nhánh, các cách ghép, cùng split; ghi thời gian, bộ nhớ.
- Join theo ID, đếm thiếu, trùng; audio, video đổi frame về giây.
- Mô phỏng thiếu nguồn đúng tỉ lệ đề; fallback khi thiếu hết.
- Tính chi phí visual tokens, encode audio trước khi chạy cả tập.
- Parser schema; khóa α, prompt, checkpoint trước test.

05

Luyện đề

LUYỆN ĐỀ 1

Bài toán nào là đa phương thức thật sự?

A Đoán thể loại của clip từ khung hình, âm thanh và phụ đề

B Phân loại tiếng chim bằng cách vẽ audio thành spectrogram rồi đưa vào CNN

C Phân loại cảm xúc của bình luận, kèm bản dịch máy của bình luận ấy

D Phân loại ảnh, ghép ảnh gốc với năm bản augmentation của nó

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 257

LUYỆN ĐỀ 2

Một VLM đạt accuracy 0.71 trên validation hỏi đáp ảnh. Thay mọi ảnh bằng một ảnh xám trống, giữ nguyên câu hỏi, thì được 0.66. Phần lớn câu hỏi là có/không hoặc đếm. Ta kết luận được gì?

A Model dùng ảnh tốt, vì 0.66 vẫn thấp hơn 0.71

B Ảnh xám làm hỏng processor, nên số 0.66 vô nghĩa

C Nên bỏ hẳn nhánh ảnh để inference nhanh hơn

D Câu hỏi tự để lộ phần lớn đáp án, còn ảnh góp ít

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 264

LUYỆN ĐỀ 3

Một đội có 2 triệu ảnh không chú thích và 2 triệu đoạn tin tức, hai kho không liên quan đến nhau. Đội muốn train từ đầu hai encoder ảnh và chữ trong cùng một không gian, để tìm ảnh bằng câu. Trở ngại chính là gì?

A Không có cặp ghép nào, nên không có gì để căn chỉnh

B Dữ liệu quá ít so với pretraining chỉ có chữ

C Hai encoder phải có cùng số chiều ngay từ đầu

D Ảnh và chữ phải dùng chung tokenizer mới so được

PHỎNG THEO NOAI 2026 Singapore · Vòng sơ loại · Câu 266

Chốt ý

Ghép đúng cặp theo ID và thời gian trước mọi model.

Linear head chỉ cộng điểm riêng; tương tác cần MLP, đặc trưng tích, gating.

Ablation đo đóng góp thật; thêm modality không chắc tăng điểm.

Cùng chiều chưa cùng hệ trục; căn chỉnh học từ cặp.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; đổi số cặp dùng để học W (8, 20, 40), đoán trước recall@1 rồi kiểm lại.