Phân tích dữ liệu trước huấn luyện

Kiểm điểm cao đang đo tổng quát hay nhớ nguồn

Validation gần hoàn hảo

Validation gần hoàn hảo sau vài phút.

Thử trên tài liệu từ nguồn khác: dự đoán thất thường.

Model tốt hay đang nhớ nguồn? Câu hỏi cần chốt trước khi tăng epoch.

CÂU HỎI XUYÊN SUỐT

Validation chứa mẫu mới theo đúng mục tiêu chưa?

Mục tiêu buổi này

- Đọc schema và xác định đơn vị độc lập của một mẫu.
- Kiểm thiếu, trùng và nhãn mâu thuẫn trước khi sửa.
- Chia theo nhóm hoặc thời gian khi đó là mục tiêu sử dụng.
- Phân biệt đường tắt, rò rỉ và các kiểu lệch phân phối.
- Kiểm bằng baseline, ablation và lát dữ liệu kèm số mẫu.

01

Hiểu từng hàng dữ liệu

ID dòng và nguồn là hai khóa

`id`: định danh đoạn.

`document`: tài liệu gốc.

`device`: nguồn thu.

`signal`: đặc trưng số.

KẾT QUẢ

```
shape (8, 5)
duplicated ids ['003']
labels {0: 4, 1: 4}
```

Một `signal` bị thiếu.

Tám dòng chưa chắc là tám mẫu độc lập.

ID trả lời “dòng nào”; `document` trả lời “nguồn nào”.

HỎI NHANH

Hai dòng có `id` khác nhau nhưng cùng `document`. Điều này nói gì về cách chia validation?

A Hai dòng có thể chung nguồn, và cách chia tùy vào mục tiêu

B Hai dòng độc lập vì mỗi dòng có ID riêng, nên chia theo dòng

C Hai dòng là bản trùng, nên phải xóa bớt một dòng

D Hai dòng mang hai nhãn khác nhau, vì ID khác nhau

HỎI NHANH

Trên dữ liệu đầy đủ, đếm ô thiếu theo thiết bị thì thấy `signal` thiếu 0% ở `old` nhưng thiếu 60% ở `new`. Bước tiếp theo nên là gì?

A Xem file gốc của thiết bị mới trước khi điền

B Điền mean của cả cột, vì thiếu là ngẫu nhiên

C Bỏ cột `signal`, vì cột này thiếu quá nhiều

D Bỏ mọi dòng `new`, vì thiết bị này ghi lỗi

Trùng không chỉ là hàng giống hệt

`df.duplicated()`: trùng toàn bộ hàng.

Khác tên file, khác dấu cách, đổi định dạng: phép so hàng không thấy.

- Văn bản: chuẩn hóa khoảng trắng rồi băm.
- Ảnh: băm bytes cho trùng chính xác.
- Gần trùng: so embedding để đề xuất cặp, rồi người xem lại.

HỎI NHANH

Hai bài đánh giá chỉ khác nhau ở chữ hoa đầu câu và một dấu cách thừa. Băm bytes gốc thì ra hai mã hash khác nhau. Ta kết luận được gì?

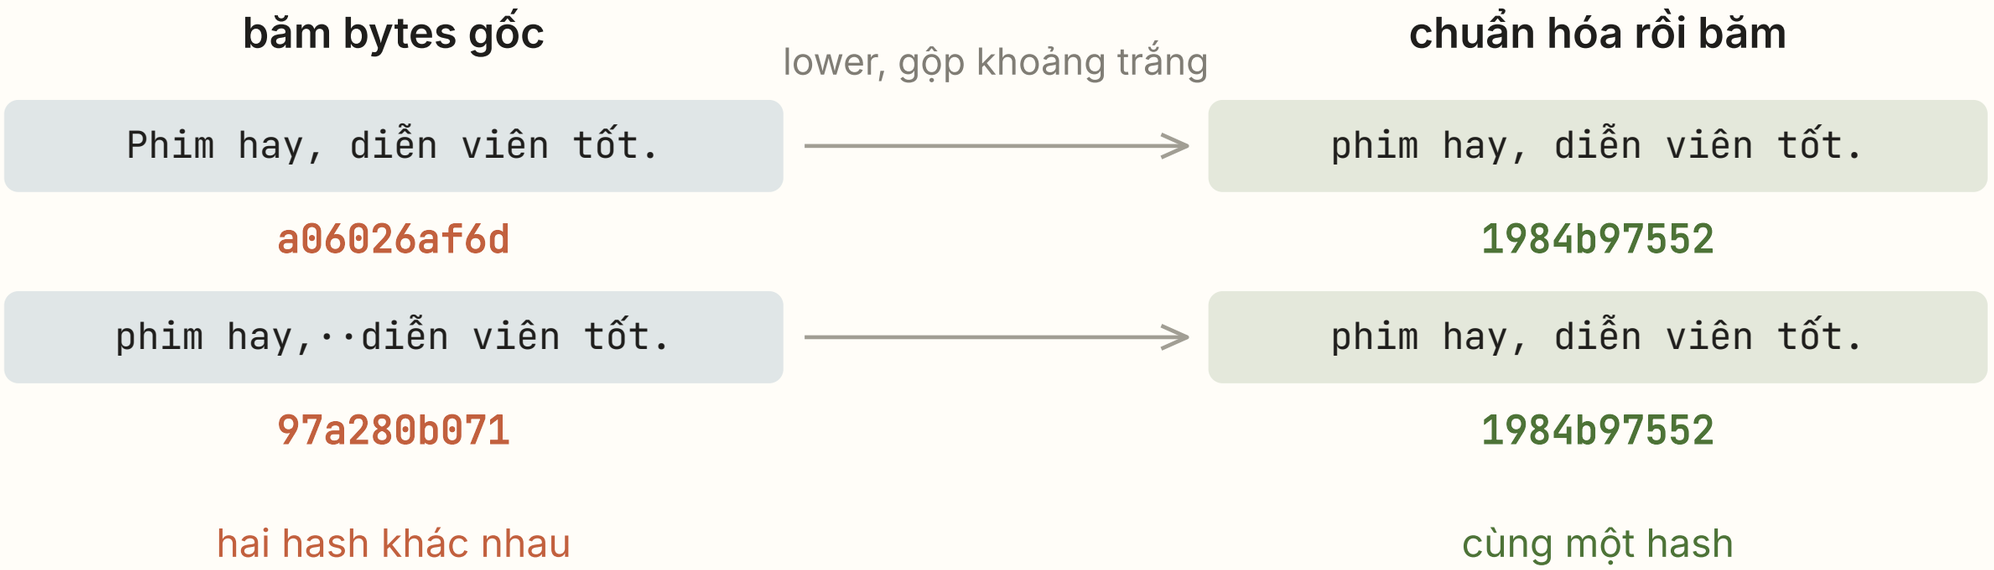
A Hai bài chắc chắn khác nội dung, vì hash khác nhau

B Hàm băm bị lỗi, cần đổi sang một thuật toán băm khác

C Phải so embedding mới biết hai bài có trùng không

D Hash chỉ so bytes, nên cần chuẩn hóa văn bản rồi băm lại

Băm sau khi chuẩn hóa



Hai bài chỉ khác chữ hoa đầu câu và một dấu cách thừa (··): băm bytes gốc cho hai hash khác nhau; hạ chữ thường và gộp khoảng trắng trước khi băm thì ra cùng một hash.

Băm ảnh để tìm bản gần trùng



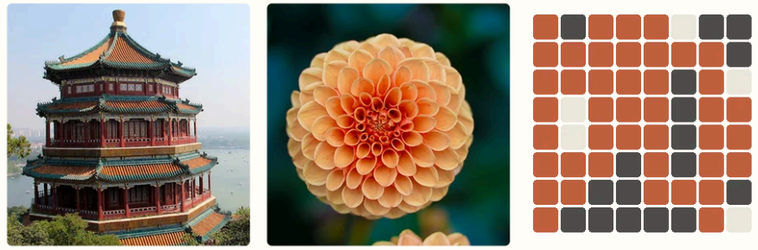
ảnh gốc: lệch 0/64 bit so với ảnh gốc (ô cam là bit khác)



nén JPEG chất lượng 15: lệch 0/64 bit so với ảnh gốc (ô cam là bit khác)



lật ngang: lệch 28/64 bit so với ảnh gốc (ô cam là bit khác)



một ảnh khác: lệch 42/64 bit so với ảnh gốc (ô cam là bit khác)

dHash: thu ảnh về 9 × 8 điểm xám, mỗi bit ghi điểm bên phải sáng hơn bên trái hay không; bản sửa nhẹ của cùng ảnh chỉ lệch vài bit, lật ngang hay ảnh khác lệch rất nhiều.

Mâu thuẫn là ứng viên cần kiểm

KẾT QUẢ

```
conflicting feature groups 1
[('doc-b', 'old', -0.8)]
exact duplicated rows 1
```

Cùng đặc trưng, hai nhãn:

- Có thể nhãn nhiễu.
- Có thể thiếu một đặc trưng.
- Có thể định nghĩa mẫu khác nhau.

Không lấy dự đoán model làm nhãn đúng tự động.

Ba chỗ cần xem trong tám dòng

id	document	device	signal	label	
001	doc-a	old	1.2	1	
002	doc-a	old	1.3	1	
003	doc-b	old	-0.8	0	
004	doc-c	new	–	1	signal thiếu
005	doc-d	new	0.4	0	
006	doc-e	old	-0.8	0	
007	doc-b	old	-0.8	1	doc-b: nhãn 0 và 1
003	doc-b	old	-0.8	0	id 003 lặp

Bảng tám dòng của bài: id 003 xuất hiện hai lần, một ô signal bị thiếu, và nhóm doc-b (dải vàng) cùng đặc trưng nhưng mang cả nhãn 0 lẫn 1.

HỎI NHANH

Hai mẫu có đặc trưng giống hệt nhau, nhưng nhãn lại khác nhau. Việc đầu tiên nên làm là gì?

A Sửa cả hai nhãn theo dự đoán của model

B Xem nguồn và cách gán nhãn của hai mẫu

C Xóa mẫu mang nhãn ít gặp hơn

D Bỏ cả hai mẫu khỏi train và validation

02

Split theo câu hỏi sử dụng

Dấu vết nguồn, nhãn ngẫu nhiên theo tài liệu

```
X = np.eye(60)[groups]
y = document_labels[groups]
```

One-hot không mang quy luật sang tài liệu mới: chỉ nhớ được.

KẾT QUẢ

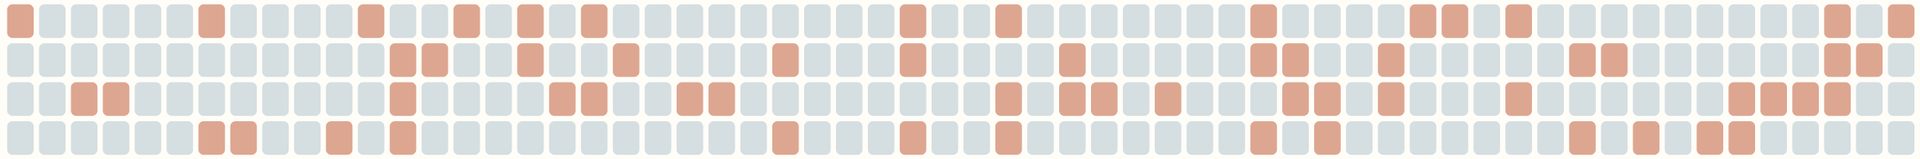
```
random overlap 39 accuracy 1.000
group overlap 0 accuracy 0.733
group predictions [1] val label counts [16, 44]
```

Tài liệu mới cách đều mọi hàng train: 1-NN hòa, trả nhãn 1.

$44/60 \approx 0.733$ chỉ là tỉ lệ lớp.

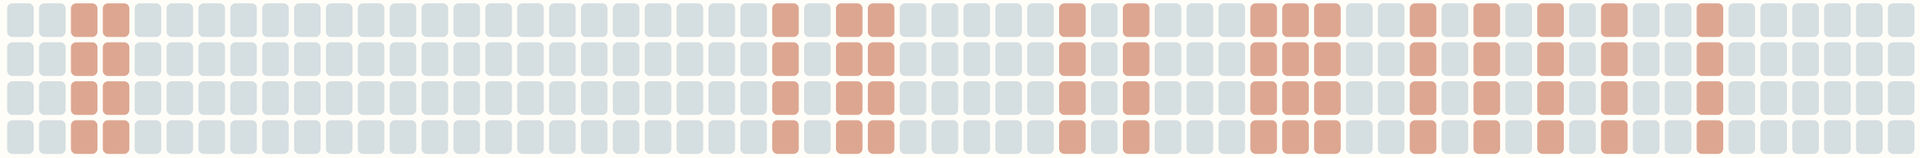
Tài liệu mới phải được giữ riêng

chia ngẫu nhiên theo dòng



chung 39

chia theo tài liệu



chung 0

mỗi cột là một tài liệu, bốn ô là bốn đoạn; cam là validation

Split của bài trên 60 tài liệu × 4 đoạn (từ code): chia ngẫu nhiên theo dòng để 39 tài liệu có đoạn ở cả hai phía; chia theo tài liệu giữ mỗi cột trọn ở một phía.

HỎI NHANH

Ở group-split, train có 100 nhãn 1 và 80 nhãn 0. Baseline luôn đoán lớp đông nhất của train đạt accuracy bao nhiêu trên cùng validation?

A 0.500

B 0.267

C 0.556

D 0.733

Tính tay xác suất chia đôi nguồn

Bốn đoạn, mỗi đoạn vào validation với xác suất 0.25:

$$1 - 0.75^4 - 0.25^4 \approx 0.680$$

Dự đoán $60 \cdot 0.680 \approx 40.8$ tài liệu bị chia đôi; thí nghiệm có 39.

Nằm trọn ở validation: $0.25^4 \approx 0.004$.

HỎI NHANH

Có 40 tài liệu. 4 tài liệu dài, mỗi tài liệu 100 đoạn. 36 tài liệu ngắn, mỗi tài liệu 5 đoạn. `GroupShuffleSplit(test_size=0.25)` chọn 10 tài liệu làm validation. Số dòng của validation có thể nằm trong khoảng nào?

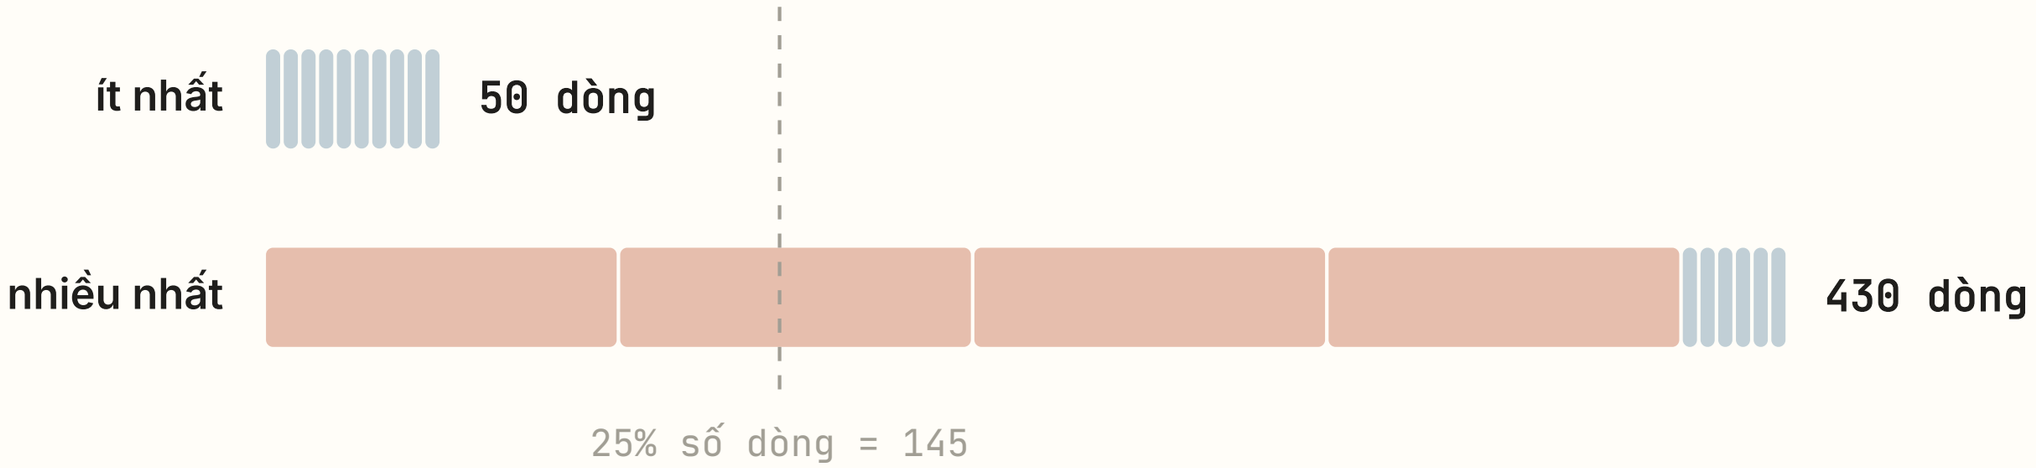
A Luôn đúng 145 dòng

B Từ 50 đến 430 dòng

C Từ 10 đến 40 dòng

D Từ 50 đến 400 dòng

10 tài liệu, số dòng rất khác



cùng 10 tài liệu validation; tài liệu dài 100 đoạn, ngắn 5 đoạn

GroupShuffleSplit chọn 10 trong 40 tài liệu: nếu cả 10 là tài liệu ngắn thì validation có 50 dòng; nếu gồm 4 tài liệu dài và 6 ngắn thì có 430 dòng, xa mốc 145 dòng.

03

Đường tắt và miền mới

Rò rỉ và đường tắt

Rò rỉ (leakage): dùng thông tin không có lúc dự đoán.

Ví dụ kết quả kiểm định ghi sau khi biết nhãn.

Đường tắt (shortcut): tín hiệu dễ học nhưng quan hệ không bền.

Ví dụ viền camera gắn với lớp ở train.

Có mặt lúc inference; hại khi miền mới không giữ quan hệ.

Phép thử: model chỉ dùng metadata vượt xa baseline.

HỎI NHANH

Trong train, phần lớn bài đánh giá tiêu cực kết thúc bằng dòng “Gửi từ ứng dụng X”, còn bài tích cực hiếm khi có. Dòng chữ này có sẵn lúc dự đoán. Đây là loại vấn đề gì, và khi nào nó gây hại?

A Là rò rỉ, gây hại ngay cả khi test cùng nguồn

B Là rò rỉ, chỉ gây hại khi test lấy từ nguồn khác

C Là đường tắt, vô hại vì có sẵn lúc dự đoán

D Là đường tắt, gây hại khi test làm đổi quan hệ ấy

Ba kiểu lệch phân phối

Covariate shift: đặc trưng đổi, nhãn của một đầu vào giữ nguyên.

Label shift: tỉ lệ lớp đổi; chọn lại ngưỡng.

Concept shift: cùng đầu vào, nhãn đúng đã khác.

Histogram khác nhau chỉ cho thấy đặc trưng đổi.

Không có nhãn thì chưa biết quan hệ với nhãn có đổi.

HỎI NHANH

Histogram của một đặc trưng trên test không nhãn lệch hẳn so với train. Ta kết luận được gì?

A Nhãn test có nhiều lỗi ghi nhãn, do đến từ nguồn khác

B Đặc trưng đã đổi, nhưng tác động lên nhãn thì chưa biết

C Quan hệ giữa đặc trưng và nhãn đã bị đảo ngược

D Model chắc chắn sẽ đạt điểm kém trên test

Adversarial validation

Chỉ khi đề cho phép dùng input test.

Train: nhãn 0. Test: nhãn 1. Học classifier phân biệt.

AUC ≈ 0.5: không tách được bằng các cột đã đưa vào.

AUC ≈ 1: có cột lệch mạnh; xem độ quan trọng của cột.

Chỉ so đầu vào: không thấy concept shift.

HỎI NHANH

Một classifier phân biệt train với test đạt AUC 0.98, và cột quan trọng nhất là `id`, vốn tăng dần theo thời điểm thu dữ liệu. Nên làm gì tiếp?

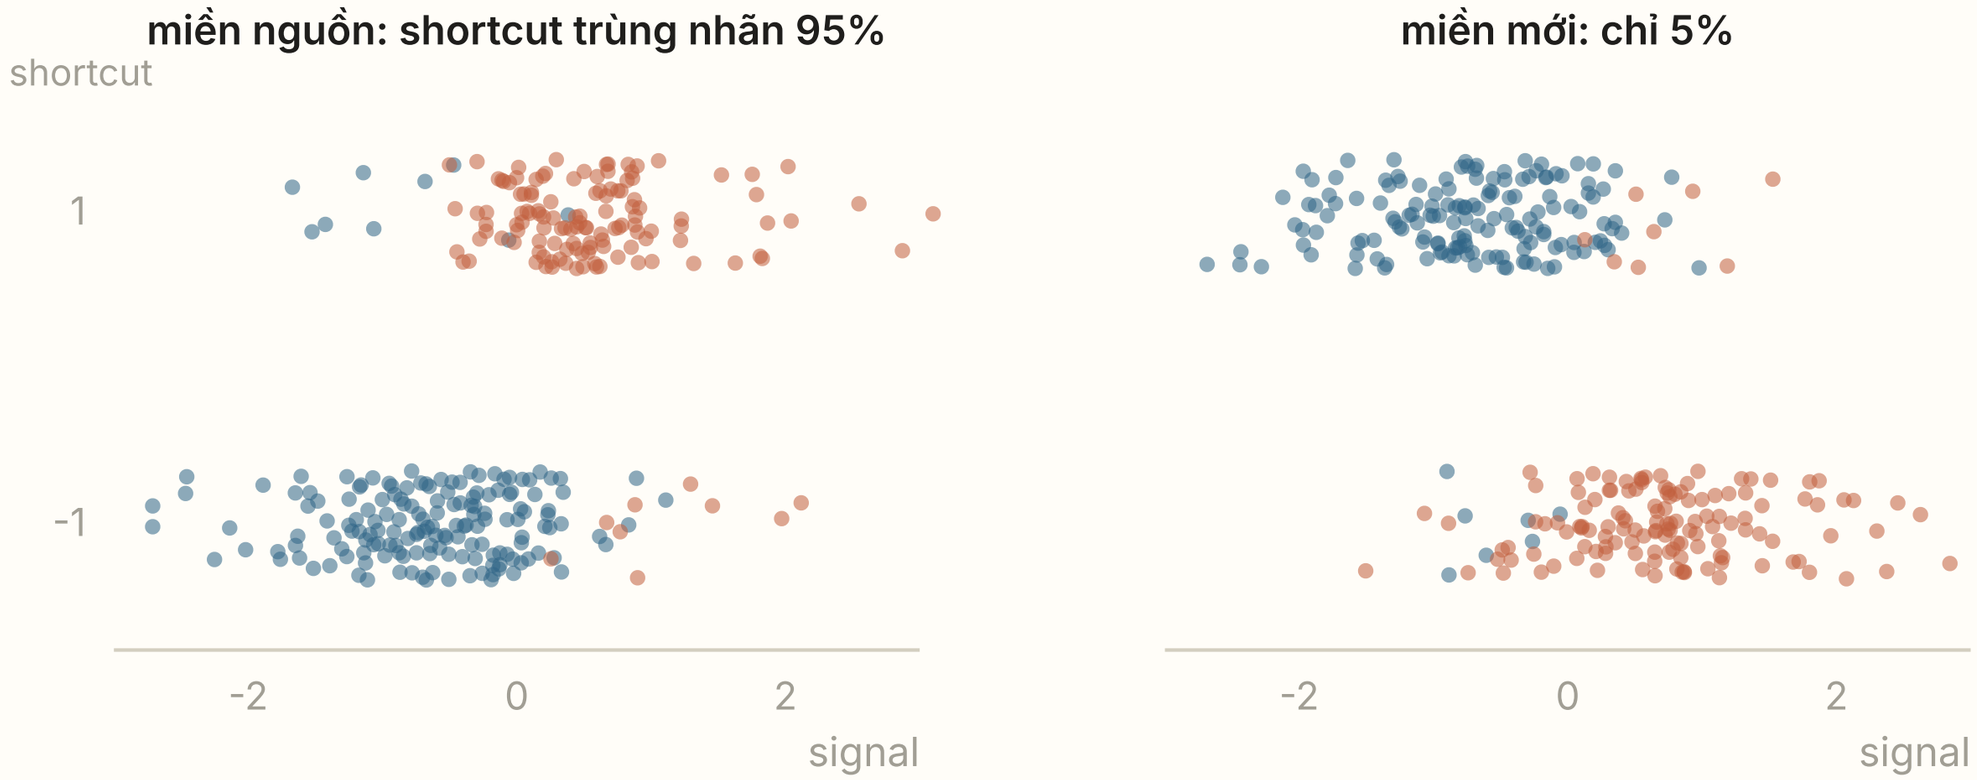
A Dùng classifier này làm model chính, vì AUC rất cao

B Bỏ qua kết quả, vì `id` chỉ là số thứ tự vô nghĩa

C Test đến sau train, nên chia validation theo `id`

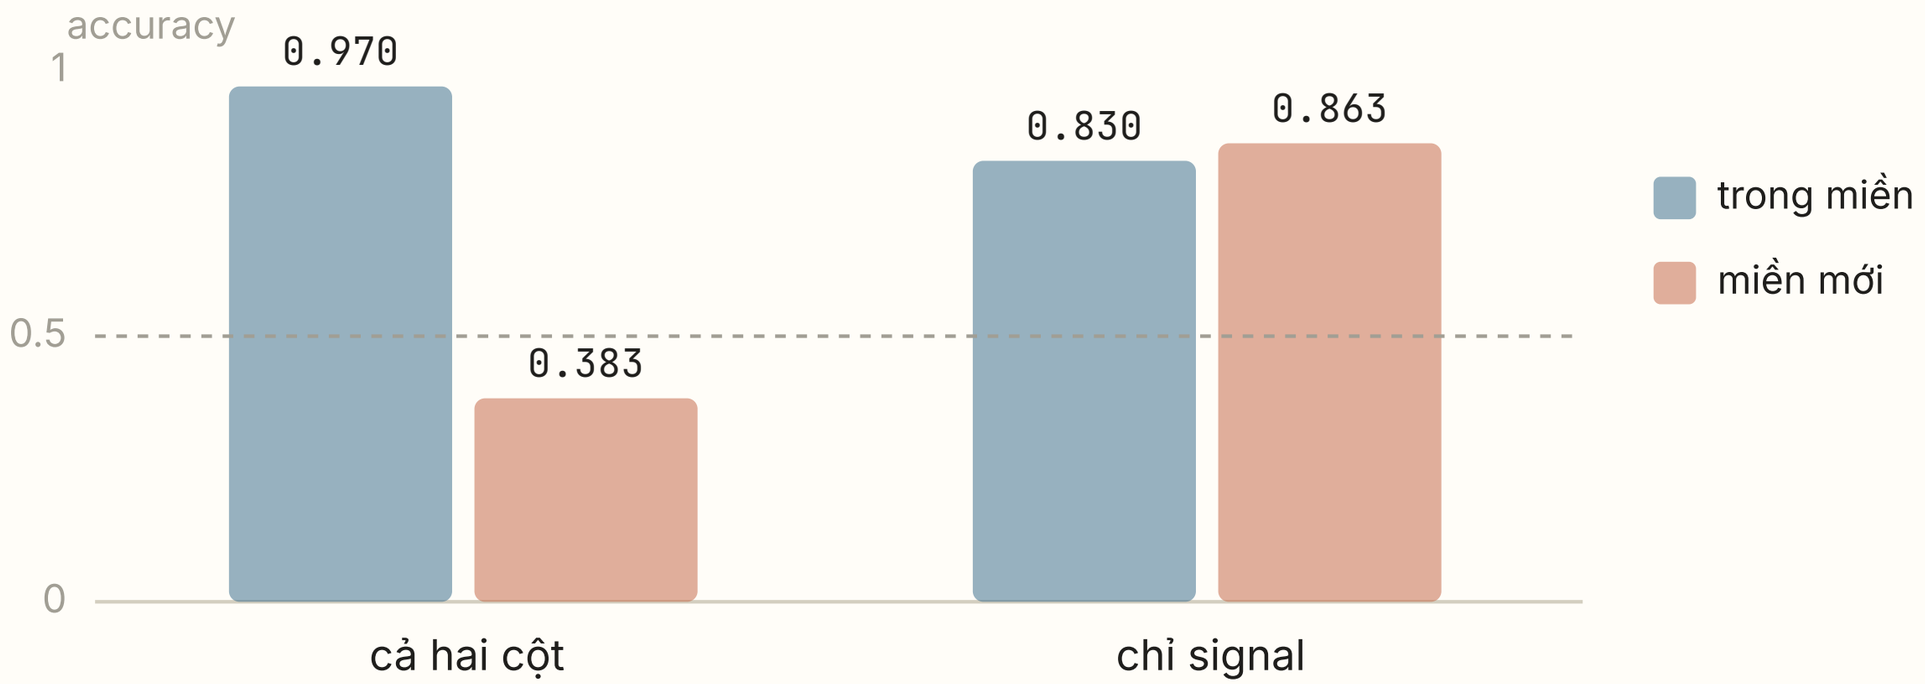
D Yên tâm, vì AUC cao báo trước điểm cao cho model chính

Hai miền tự sinh



Dữ liệu tự sinh của bài (300 điểm mỗi miền, cam là nhãn 1): signal tách hai lớp như nhau ở cả hai miền; shortcut (±1, rải dọc cho dễ nhìn) trùng nhãn ở miền nguồn nhưng bị đảo ở miền mới.

Bỏ đường tắt: mất điểm nguồn, giữ miền mới



Ablation của bài (số từ output): dùng cả shortcut đạt 0.970 trong miền nhưng rơi còn 0.383 khi quan hệ bị đảo; chỉ dùng signal đạt 0.830 và giữ 0.863 ở miền mới.

Đọc thí nghiệm ablation

KẾT QUẢ

```
both in-domain 0.970 shifted 0.383
signal-only in-domain 0.830 shifted 0.863
```

Không suy ra “ít cột luôn tốt”.

Ta biết cơ chế ở đây vì tự sinh dữ liệu.

Chênh 0.14 và 0.48 đều rõ, đúng chiều trên 20 seed khác; chênh vài phần nghìn thì so với dao động giữa fold.

HỎI NHANH

Đề nói rõ test lấy từ cùng nguồn, cùng giai đoạn với train, nên quan hệ của `shortcut` giữ nguyên. Theo output ở trên, nên chọn cấu hình nào?

A Dùng cả hai cột, vì số in-domain mới là ước lượng đúng cho test

B Chỉ dùng `signal`, vì đường tắt nào cũng là rủi ro

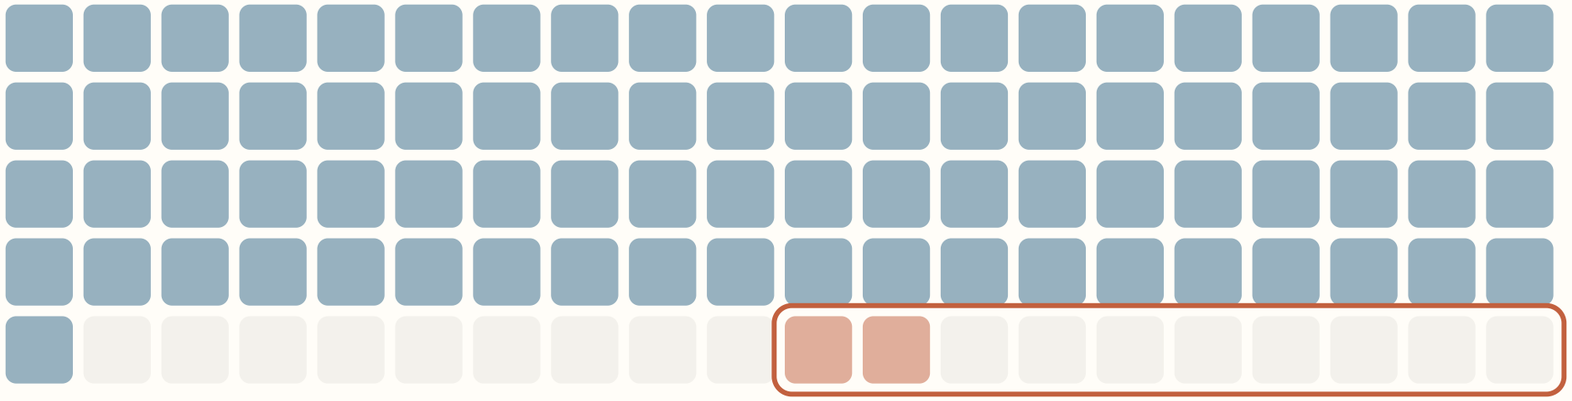
C Chỉ dùng `signal`, vì điểm shifted của nó cao hơn

D Chọn cấu hình có trung bình in-domain và shifted cao hơn

04

Lát dữ liệu và quyết định

Accuracy theo từng camera



cũ 81/90 = 0.90

mới 2/10 = 0.20

chung 0.83

trung bình
hai miền 0.55

ô đặc là đoán đúng; hàng cuối, khung cam là 10 ảnh camera mới

Mỗi ô là một mẫu validation, ô đặc là đúng: camera cũ đúng 81/90, camera mới (khung cam) chỉ 2/10; accuracy chung 0.83 che khuất nhóm 0.20.

Trung bình che một nhóm khó

Camera cũ: $81/90 = 0.90$.

Camera mới: $2/10 = 0.20$.

$$\text{Accuracy chung} = \frac{83}{100} = 0.83$$

Mean ngang miền $= (0.90 + 0.20)/2 = 0.55$.

Hai phép đo có trọng số khác nhau.

Metric chính theo statement; mean ngang miền dùng để chẩn đoán.

Lát nhỏ, khoảng rộng

Sai số chuẩn của accuracy p trên n mẫu:

$$\mathrm{SE} \approx \sqrt{p(1-p)/n}$$

$p \pm 2\,\mathrm{SE}$: vùng hợp lý của accuracy thật.

Lát vài chục mẫu đủ để báo động, chưa đủ để xếp hạng.

HỎI NHANH

Theo công thức sai số chuẩn, accuracy của camera mới, 2/10, và của camera cũ, 81/90, có sai số chuẩn xấp xỉ bao nhiêu?

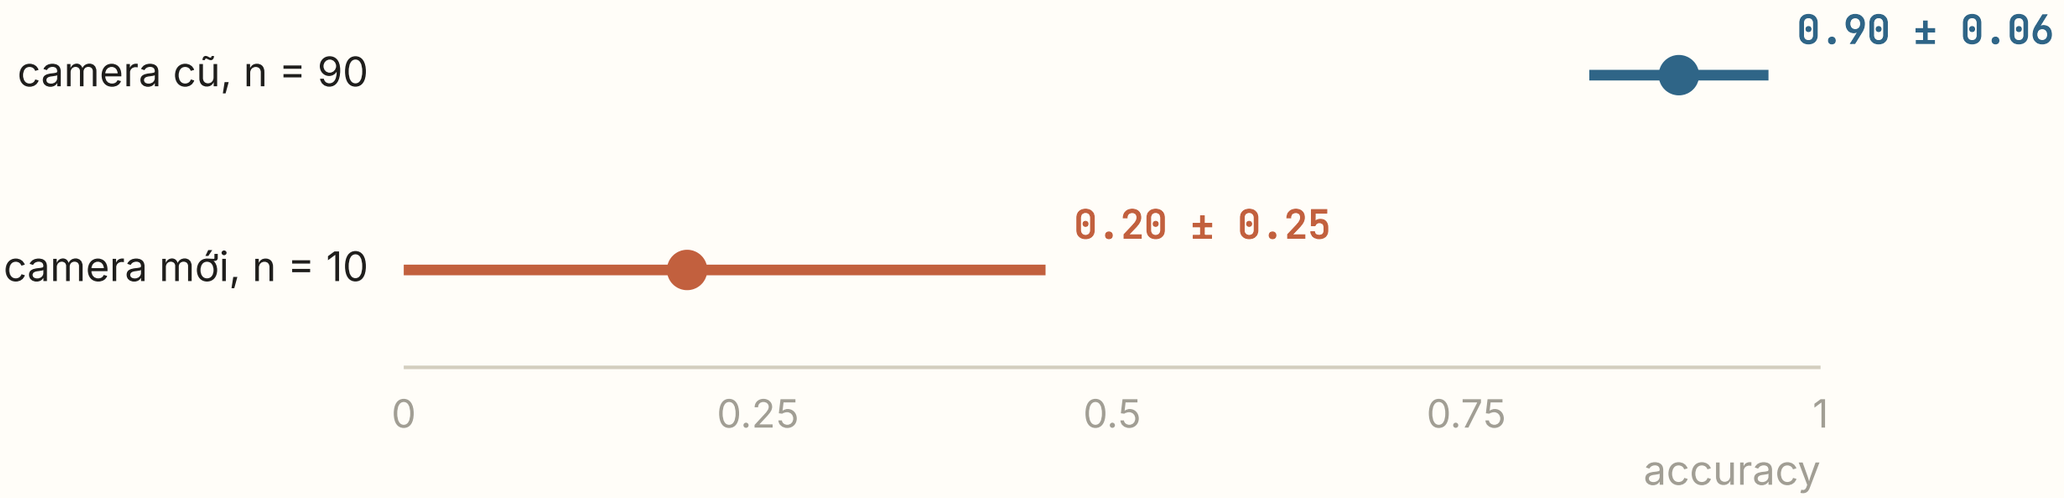
A Camera mới 0.016, camera cũ 0.001

B Camera mới 0.03, camera cũ 0.13

C Camera mới 0.13, camera cũ 0.03

D Camera mới 0.40, camera cũ 0.30

Khoảng ± 2 sai số chuẩn



Khoảng accuracy ± 2 sai số chuẩn: camera cũ 0.90 ± 0.06 với 90 mẫu, camera mới 0.20 ± 0.25 với 10 mẫu, trải từ gần 0 đến khoảng 0.45.

Quay lại bài văn bản

- Kiểm document overlap trước khi tăng epoch.
- Giữ split phù hợp mục tiêu.
- Dùng `Pipeline` để fit preprocessing trên train của từng split.
- Nhớ rằng `Pipeline` không tự tìm ra nhóm hoặc trật tự thời gian.
- Ghi số mẫu cạnh metric nhóm.
- Lọc nhãn nghi nhiễu chỉ trong train; validation giữ nguyên.
- Phân biệt lỗi đã xác nhận với ứng viên cần xem nguồn.

HỎI NHANH

Một đội bỏ 10% số mẫu mà model 5-fold đoán sai với độ tự tin cao, rồi chạy lại 5-fold trên phần còn lại. Điểm CV từ 0.81 lên 0.90. Đọc kết quả này thế nào?

A Chưa so được, vì validation mới đã bỏ đi những mẫu khó

B Nhãn nhiễu đã được dọn, nên test sẽ tăng khoảng 0.09

C Nên lặp thêm vài vòng lọc cho tới khi CV gần 1.0

D Kết quả sai, vì không được chạy 5-fold sau khi lọc

Khi đi thi

- Đọc dòng thật, dtype, ID trùng, ô thiếu theo nguồn.
- Tìm khóa nhóm trước khi chia; in nhóm chung và số dòng.
- Đặt baseline lớp đông nhất và baseline metadata cạnh model.
- So test với train chỉ trong phạm vi đề cho phép.
- Ghi split, số mẫu, dao động; chênh nhỏ hơn dao động thì chưa chọn.

05

Luyện đề

LUYỆN ĐỀ 1

Một đội ghép điểm đánh giá phim từ ba trang web để làm hệ gợi ý. Trang A chấm từ 1 đến 5, trang B từ 1 đến 10, trang C từ 1 đến 100. Người dùng và phim đã được khớp giữa ba trang. Trước khi học trên bảng điểm gộp, cần làm bước nào?

A Đưa điểm của từng trang về cùng một thang, chẳng hạn $[0, 1]$

B Gộp nguyên điểm, vì model sẽ tự học được khác biệt thang đo

C Bỏ trang C, vì điểm của nó lớn và lấn át hai trang kia

D Chuẩn hóa z-score một lần trên cả cột điểm đã gộp

PHỎNG THEO CMU 10-601 · Exam 3 Practice · Q7.5

LUYỆN ĐỀ 2

Model tín dụng học trên dữ liệu 2023. Đến tháng 6/2024, thu nhập người nộp giảm, nhóm làm việc gig tăng từ 5% lên 15%, tuổi giảm, và accuracy từ 81% xuống 76% sau một đợt suy thoái. Nên làm gì?

A Chỉ đổi ngưỡng, không train lại

B Đầu vào đã đổi, nên train lại với dữ liệu 2024

C Đây là dao động bình thường, chỉ cần theo dõi

D Bỏ thu nhập và loại việc làm

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 311

LUYỆN ĐỀ 3

Một model duyệt khoản vay đang chạy. Ba tuần liên tiếp, tỉ lệ hồ sơ được duyệt là 40%, 35% và 30%, còn tỉ lệ request bị lỗi của hệ thống giữ ở 0.1%. Nhãn thật, tức người vay có trả nợ hay không, phải 3 tháng sau mới có. Chỉ số nào báo động sớm nhất rằng model có thể đang gặp vấn đề?

A Tỉ lệ lỗi hệ thống, vì nó đo trực tiếp việc model chạy

B Accuracy so với nhãn thật, vì chỉ nó đo được chất lượng

C Không chỉ số nào, phải đợi nhãn thật sau 3 tháng

D Tỉ lệ duyệt, vì phân phối dự đoán đang trôi đều

ĐỀ THI NOAI 2026 Singapore · Vòng sơ loại · Câu 310

Chốt ý

Schema → nguồn mẫu → split → baseline, ablation → lỗi theo nhóm.

Điểm giảm sau khi sửa split có thể là phép đo tiến bộ.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook; đổi `test_size` của `GroupShuffleSplit`, đoán trước số dòng validation rồi in ra kiểm.