Pandas và Matplotlib

Đọc, xử lý và vẽ dữ liệu bảng

Phase 0 · Bài 0.3

Ba file của một đề thi

- `train.csv`: đặc trưng và đáp án.
- `test.csv`: chỉ có đặc trưng.
- `sample_submission.csv`: file nộp phải trông thế nào.

Đề của bài: dự đoán điểm Toán cuối kỳ từ lớp, giờ tự học, điểm HK1.

CÂU HỎI

Trước khi nghĩ đến mô hình, cần biết gì về các bảng này?

Và làm sao chắc file nộp không bị máy chấm từ chối?

Sau buổi này, các em có thể

- Đọc CSV, kiểm tra shape, kiểu từng cột, số ô trống.
- Lọc, chọn, `groupby`, `merge` mà không nhân bản dòng.
- Chọn đúng biểu đồ cho một câu hỏi, vẽ không gây hiểu lầm.
- Tạo file nộp đúng thứ tự, đúng cột, không ô trống.

01

Đọc và nhìn dữ liệu

Năm việc ngay sau khi đọc

```
train = pd.read_csv("train.csv")
print(train.shape)
print(train.head(3))
print(train.dtypes)
print(train.isna().sum())
print(train.describe())
```

- `(400, 5)`, test `(100, 4)`.
- `lop` là chữ: pandas 3 ghi `str`, pandas 2 ghi `object`.
- `gio_tu_hoc`: 23 ô trống, nên là `float64`.
- `describe` để soi giá trị lạ: điểm âm, trên 10.

02

Chọn, lọc, sửa

Điều kiện trong ngoặc, nối bằng &

```
gioi = train[(train["diem_hk1"] ⩾ 8)
             & (train["lop"] ≠ "10A3")]
train.loc[train["gio_tu_hoc"] > 20,
          ["id", "lop", "gio_tu_hoc"]]
train["tien_bo"] = train["diem_toan"] - train["diem_hk1"]
```

- `&`, `|`, `~` thay cho `and`, `or`, `not`.
- Mỗi điều kiện trong ngoặc: `&` được tính trước ⩾.
- `loc`: nhãn và tên cột. `iloc`: vị trí.

Sửa bằng một lần `loc`

```
demo[demo["lop"] == "10A1"]["diem_toan"] = 0   # SAI
print((demo["diem_toan"] == 0).sum())
demo.loc[demo["lop"] == "10A1", "diem_toan"] = 0   # ĐÚNG
print((demo["diem_toan"] == 0).sum())
```

KẾT QUẢ

```
0
98
```

Hai lần chọn: pandas sửa trên **bảng tạm** rồi vứt đi.

Chạy được, chỉ có cảnh báo, không ô nào đổi.

HỎI NHANH

Lệnh nào lọc đúng học sinh lớp 10A1 có điểm HK1 dưới 5?

A
```
train[train["lop"] == "10A1" and train["diem_hk1"] < 5]
```

B
```
train[train["lop"] == "10A1" & train["diem_hk1"] < 5]
```

C
```
train[(train["lop"] == "10A1") & (train["diem_hk1"] < 5)]
```

D
```
train.loc["10A1", "diem_hk1" < 5]
```

03

Ô trống, groupby, merge

Điền ô trống bằng thống kê của train

```
med_all = train["gio_tu_hoc"].median()
med_lop = train.groupby("lop")["gio_tu_hoc"].median()
print(round(med_all, 2), med_lop.round(2).to_dict())
for df in (train, test):
    df["gio_tu_hoc"] = df["gio_tu_hoc"].fillna(
        df["lop"].map(med_lop))
print(train["gio_tu_hoc"].isna().sum(), test["gio_tu_hoc"].isna().sum())
```

KẾT QUẢ

```
4.4 {'10A1': 4.2, '10A2': 4.4, '10A3': 4.7, '10A4': 4.45}
0 0
```

- Trung vị theo lớp: gần với mẫu hơn trung vị chung.
- Tính **chỉ từ train**, áp cho cả train và test.
- Tính trên test là rò rỉ dữ liệu (bài 1.4).

agg và transform

```
train.groupby("lop")["diem_toan"].agg(["mean", "std", "count"])
```

lop	mean	std	count
10A1	6.79	1.00	98
10A2	6.41	1.17	89
10A3	5.96	1.14	103
10A4	6.58	1.16	110

Cách	Kết quả
`.agg("mean")`	Một giá trị mỗi nhóm: $(4,)$
`.transform("mean")`	Một giá trị mỗi dòng: $(400,)$

`transform` gán thẳng thành cột mới được.

HỎI NHANH

400 dòng, 4 lớp. `groupby("lop")["diem_toan"].transform("max")` có bao nhiêu phần tử?

A 4

B 400

C 1

D 1600

merge không được nhân bản dòng

```
merged = train.merge(lop_info, on="lop", how="left")
print(train.shape, merged.shape)
dup = pd.concat([lop_info, lop_info.iloc[[0]]])
print(train.merge(dup, on="lop", how="left").shape)
```

KẾT QUẢ

```
(400, 7) (400, 9)
(498, 9)
```

- Khóa trùng ở bảng phải: mỗi học sinh 10A1 thành hai dòng.
- `validate="many_to_one"` báo `MergeError` ngay.
- `how="inner"` có thể làm mất mẫu âm thầm.

04

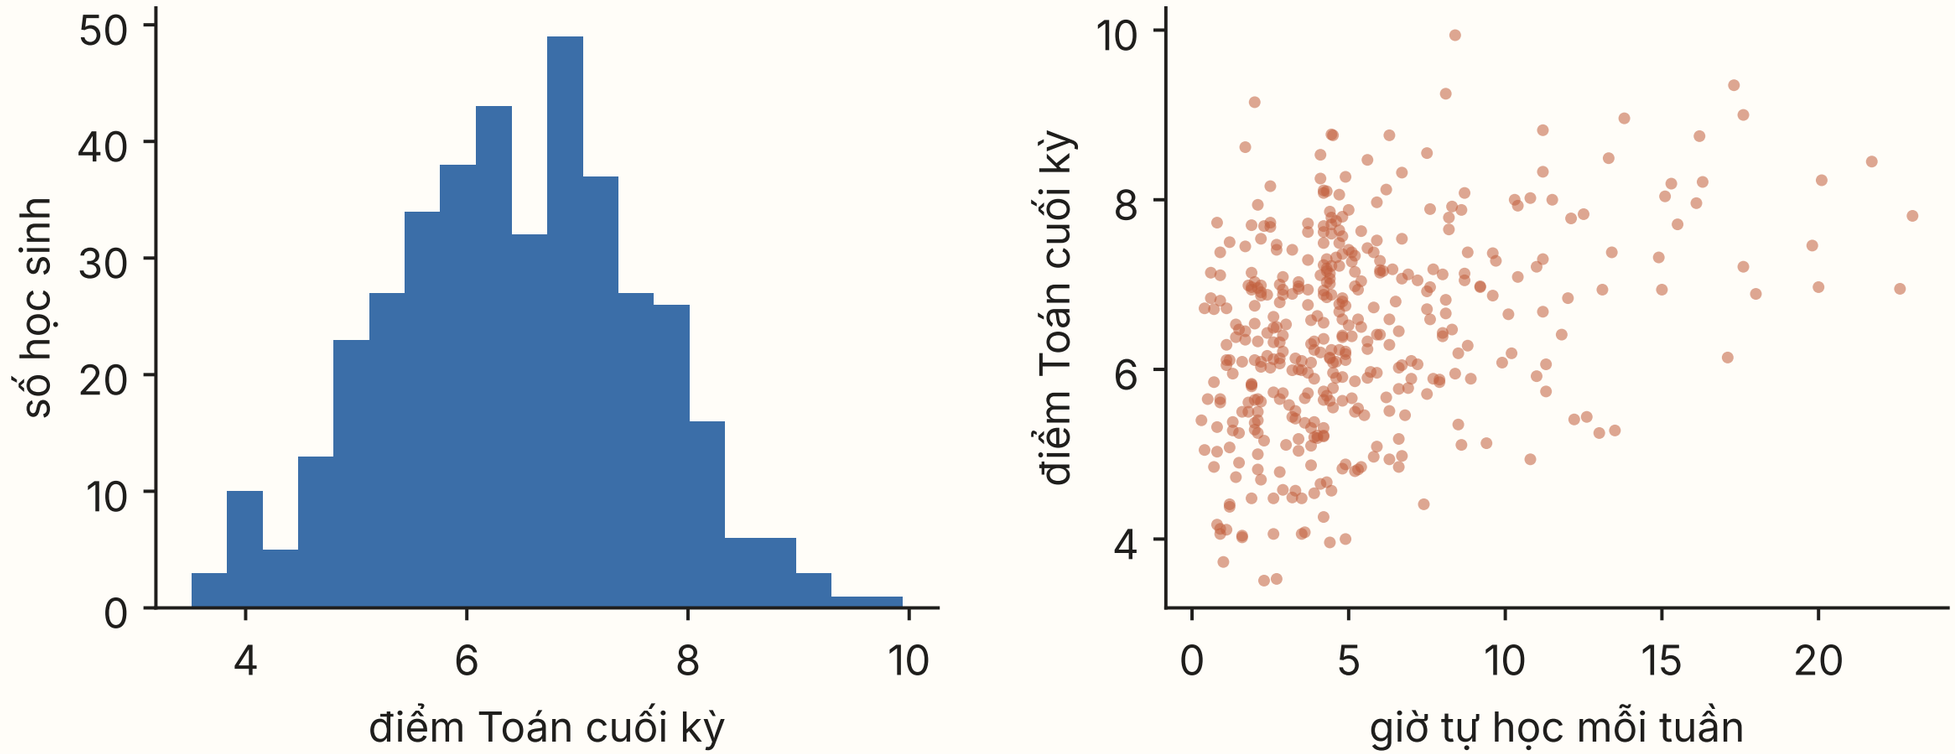
Biểu đồ

Chọn biểu đồ theo câu hỏi

Câu hỏi	Biểu đồ	Matplotlib
Một biến phân bố thế nào?	Histogram	`ax.hist`
Hai biến số có liên quan không?	Scatter	`ax.scatter`
So sánh giá trị giữa các nhóm	Bar	`ax.bar`
Thay đổi theo thời gian	Line	`ax.plot`

Cách viết `fig, ax = plt.subplots()`, gọi phương thức trên `ax`, luôn có nhãn trục.

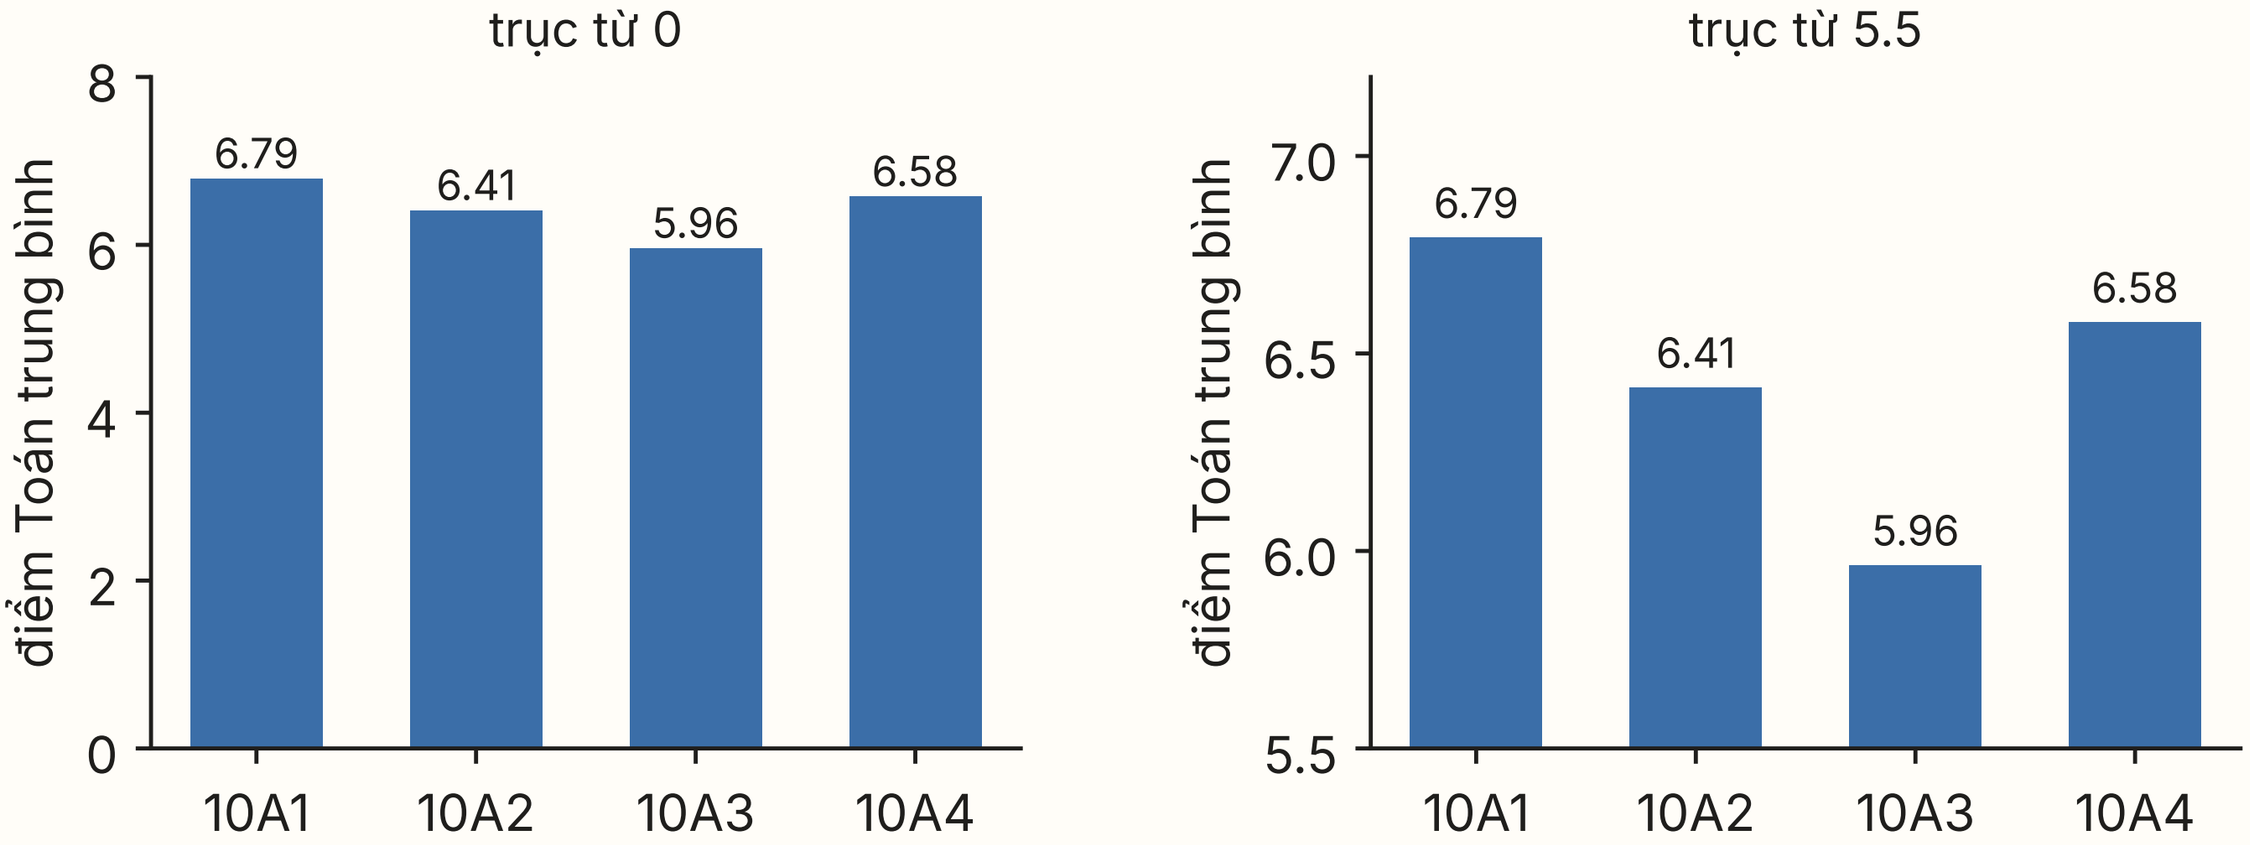
Phân bố và quan hệ



Điểm tập trung quanh 6–7; học nhiều có xu hướng điểm cao hơn nhưng tản rộng.

Tương quan với điểm Toán: điểm HK1 0.56, giờ tự học 0.36. Chỉ đo quan hệ **tuyến tính**, không nói nhân quả.

Đừng cắt trục biểu đồ cột



Cùng số liệu; trục từ 5.5 làm 10A1 trông cao gần gấp ba 10A3.

HỎI NHANH

Muốn biết điểm HK1 có liên quan đến điểm Toán cuối kỳ không, vẽ gì?

A Histogram điểm Toán

B Scatter điểm HK1 và điểm Toán

C Cột điểm trung bình theo lớp

D Đường theo `id`

05

File nộp

Lấy khung từ file mẫu

```
sample = pd.read_csv("sample_submission.csv")
sub = sample[["id"]].merge(test[["id", "diem_toan"]],
        on="id", how="left", validate="one_to_one")
assert sub.shape == sample.shape
assert list(sub.columns) == list(sample.columns)
assert sub["id"].equals(sample["id"])
assert sub["diem_toan"].notna().all()
sub.to_csv("submission.csv", index=False)
```

- Ghép theo `id`, không giả định thứ tự dòng.
- Kiểm tra đúng thứ máy chấm kiểm tra.
- Quên `index=False`:

KẾT QUẢ

```
['Unnamed: 0', 'id', 'diem_toan']
```

Tính tay trên lớp

Lớp A: $6, 8, 7$. Lớp B: $5, \text{NaN}, 9$.

1. `groupby("lop")["diem"].mean()`
2. `groupby("lop")["diem"].transform("max")`
3. Ghép với bảng lớp có `A` lặp hai lần
4. `(df["diem"] ≥ 7).mean()`

1. A: 7; B: $(5 + 9)/2 = 7$
2. $8, 8, 8, 9, 9, 9$
3. $3 \cdot 2 + 3 = 9$ dòng
4. $3/6 = 0.5$: `NaN ≥ 7` là `False`

Bẫy cài đặt

Bẫy	Hậu quả	Cách tránh
Ô `"?"` trong cột số	Cả cột thành chữ	`pd.to_numeric(..., errors="coerce")`
`df[mask]["col"] = v`	Không sửa gì	`df.loc[mask, "col"] = v`
Khóa trùng khi `merge`	Nhân bản dòng	`validate=`, so shape
Quên `index=False`	Thừa cột không tên	`to_csv(..., index=False)`
Sai dấu phân cách	`shape[1] == 1`	`sep=";"`, `decimal=","`

Khi đi thi

- **Năm lệnh đầu tiên** cho cả train và test; so hai tập có khác nhau không.
- **Vẽ phân bố của nhãn** trước khi chọn metric và mô hình.
- `validate=` và in shape ở mỗi lần ghép.
- **File nộp từ** `sample_submission`, ghép theo `id`, `assert`, `index=False`.
- **Nộp baseline sớm** để bắt lỗi định dạng.

Tóm tắt

- `read_csv` rồi kiểm tra ngay `shape`, `dtypes`, `isna().sum()`, `describe()`.
- Lọc bằng điều kiện trong ngoặc với `&`, `|`, `~`; sửa bằng một lần `loc`.
- `agg`: một dòng mỗi nhóm; `transform`: một giá trị mỗi dòng gốc.
- `merge` với `validate=` để không nhân bản dòng.
- Biểu đồ theo câu hỏi, có nhãn trục, cột bắt đầu từ 0.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook của bài: vẽ scatter điểm HK1 và điểm Toán, tô màu theo lớp, rồi thử một baseline dùng cả điểm HK1.