Regularization

Khi mô hình học thuộc thay vì học quy luật

Phase 2 · Bài 2.2

Dữ liệu “phong phú” hơn

Vẫn định giá căn hộ, nhưng bảng có thêm **30 cột** không liên quan: số tầng, hướng cửa, số chữ cái trong tên chủ nhà...

Chỉ có **40 căn** để học, 60 căn để kiểm tra.

CÂU HỎI

Linear regression sẽ dùng 30 cột rác này thế nào?

Và làm sao bắt nó bỏ qua chúng?

Sau buổi này, các em có thể

- Nhận ra mô hình đang học thuộc qua khoảng cách giữa điểm train và test.
- Dùng Ridge và Lasso, chọn mức phạt λ bằng cross-validation.
- Giải thích vì sao Lasso đưa trọng số về đúng 0, còn Ridge thì không.
- Biết khi nào bắt buộc chuẩn hóa và đọc đúng `alpha`, `C` của scikit-learn.

01

Khi mô hình học thuộc

Linear regression trên 40 căn

```
w, b = fit_ols(A_tr, y_tr)
print("R2 train:", round(r2(A_tr @ w + b, y_tr), 3),
      " R2 test:", round(r2(A_te @ w + b, y_te), 3))
print("2 hệ số thật:", w[:2].round(2),
      " |hệ số rác| lớn nhất:", np.abs(w[2:]).max().round(2))
```

KẾT QUẢ

```
R2 train: 0.985  R2 test: 0.349
2 hệ số thật: [ 1.15 -0.79]  |hệ số rác| lớn nhất: 0.44
```

- Train gần hoàn hảo, test tệ: **overfitting**.
- Cột rác nhận hệ số tới 0.44, cỡ một nửa hệ số của khoảng cách.
- 33 tham số, 40 mẫu: luôn có cách dùng cột rác để khớp nốt phần nhiễu.

02

Phạt độ lớn trọng số

Lỗi cộng phạt

$$J(\mathbf{w}, b) = \underbrace{\sum_i \left(\mathbf{w}^\top \mathbf{x}_i + b - y_i\right)^2}_{\text{khớp dữ liệu}} + \underbrace{\lambda\, \Omega(\mathbf{w})}_{\text{phạt độ lớn}}$$

Trọng số lớn: dự đoán nhạy với dao động nhỏ, tức variance cao.

$\lambda = 0$: least squares · $\lambda \to \infty$: chỉ còn đoán trung bình · bias b không bị phạt

Ridge và Lasso

	Ridge (L2)	Lasso (L1)
Khoản phạt	$\sum_j w_j^2$	$\sum_j \lvert w_j \rvert$
Tác dụng	Co mọi trọng số về gần 0	Đưa nhiều trọng số về **đúng** 0
Hợp khi	Nhiều đặc trưng cùng có ích, có tương quan	Chỉ ít đặc trưng thật sự quan trọng

HỎI NHANH

Với λ rất lớn, mô hình Ridge dự đoán gì cho mọi căn hộ?

A Giá 0 đồng

B Giá trung bình của tập train

C Giống hệt linear regression thường

D Mô hình không chạy được

03

Ridge

Nghiệm đóng

Trừ trung bình khỏi X và $\mathbf{y}$ để không phạt b:

$$\mathbf{w}^* = \left(X_c^\top X_c + \lambda I\right)^{-1} X_c^\top \mathbf{y}_c$$

$$b = \bar{y} - \bar{\mathbf{x}}^\top \mathbf{w}$$

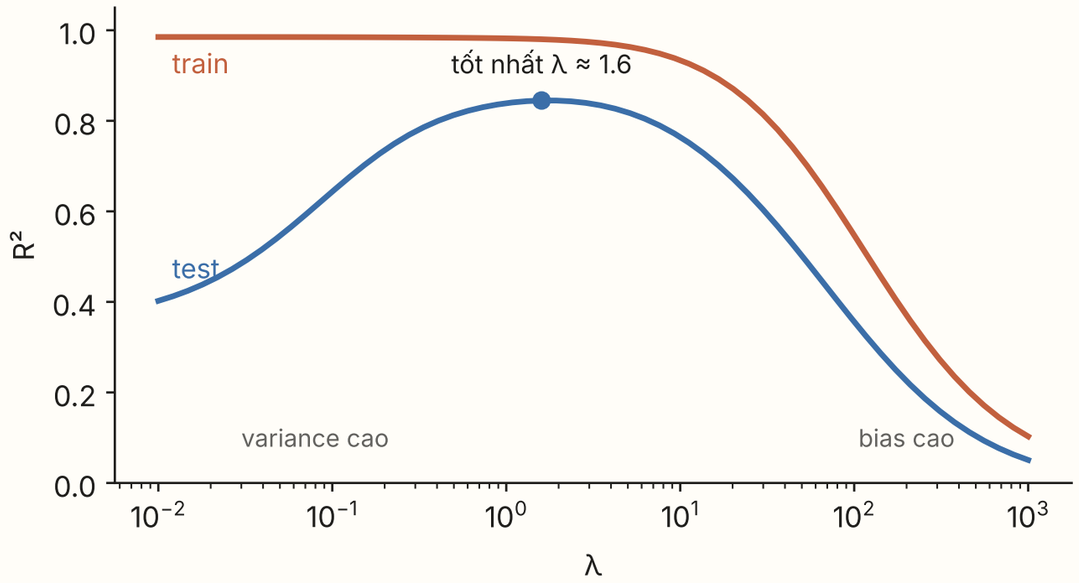
λI làm ma trận luôn khả nghịch: chữa luôn đa cộng tuyến.

```
def fit_ridge(A, y, lam):
    a_mean, y_mean = A.mean(axis=0), y.mean()
    Ac, yc = A - a_mean, y - y_mean
    w = np.linalg.solve(
        Ac.T @ Ac + lam * np.eye(A.shape[1]),
        Ac.T @ yc)
    return w, y_mean - a_mean @ w
```

Trùng `Ridge(alpha=lam)` của scikit-learn.

Thử nhiều mức phạt

λ	R^2 train	R^2 test
0	0.985	0.349
0.1	0.985	0.644
1	0.982	**0.839**
3	0.974	**0.839**
10	0.934	0.764
100	0.547	0.356

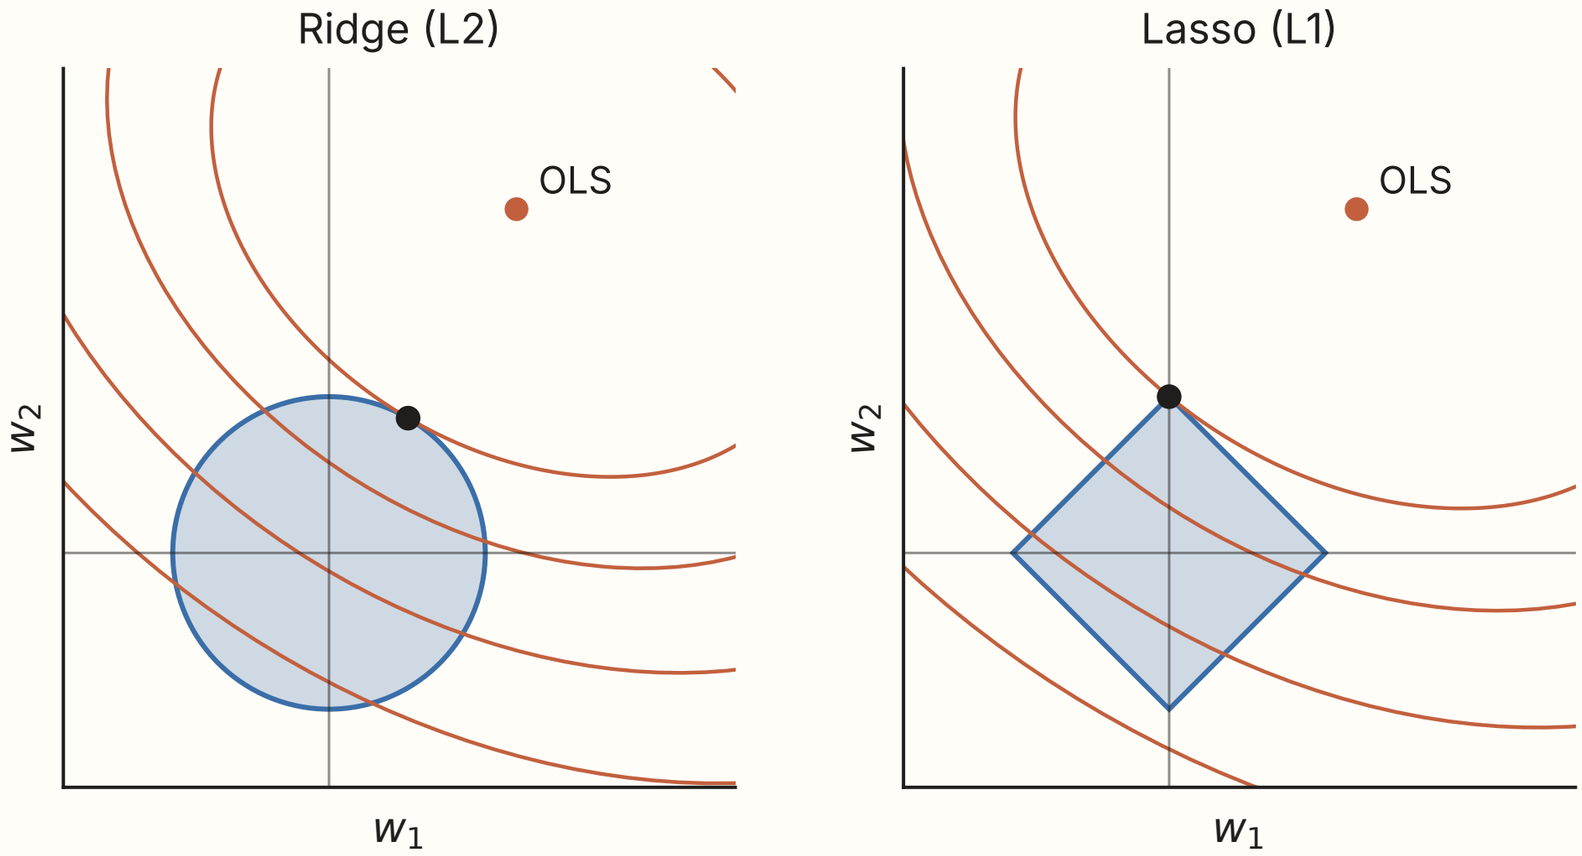


Train luôn giảm; test tăng rồi giảm.

04

Lasso

Vì sao L1 cho số 0: hình học



Đường đồng mức của lỗi chạm hình thoi L1 thường ở góc, nơi một trọng số bằng 0.

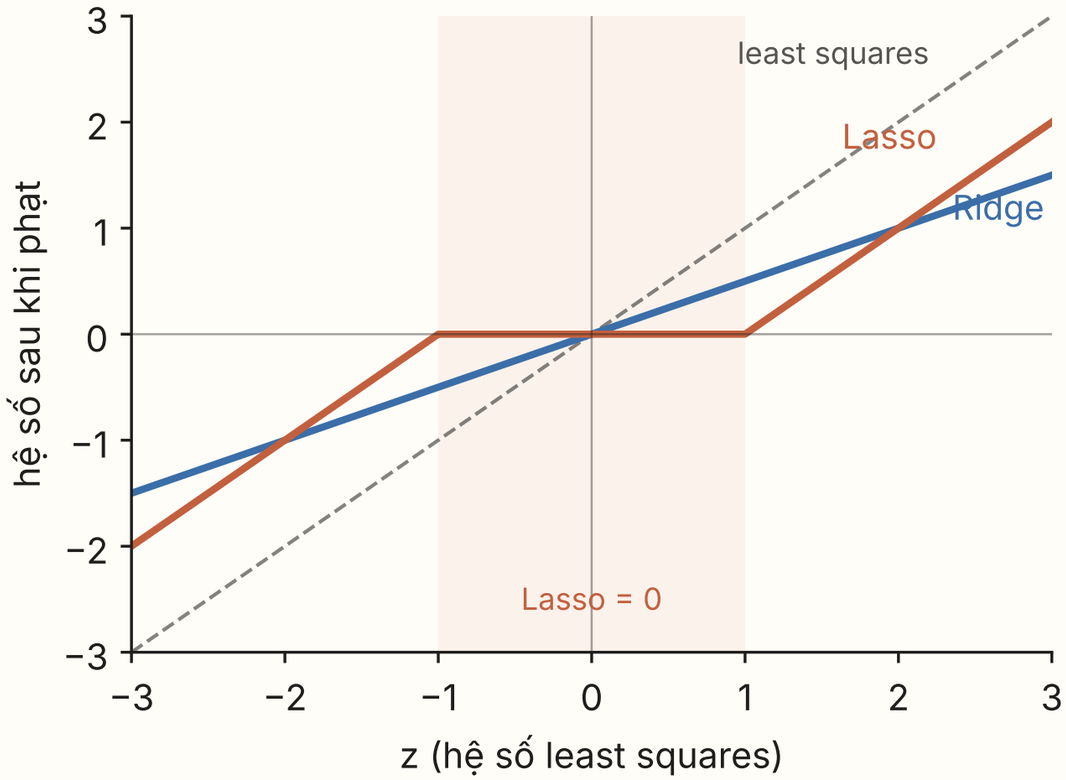
Vì sao L1 cho số 0: tính thẳng

Các cột trực chuẩn, z_j là hệ số least squares:

$$w_j^{\text{ridge}} = \frac{z_j}{1+\lambda}$$

$$w_j^{\text{lasso}} = \text{sign}(z_j)\max\left(|z_j| - \lambda,\ 0\right)$$

Lasso trừ đi λ rồi cắt về 0: **soft-thresholding**.



Ridge co theo tỉ lệ; Lasso bằng 0 trên cả đoạn $|z| \le \lambda$.

Tính tay trên lớp

$\mathbf{z} = (3,\ 0.5,\ -1.2)$, $\lambda = 1$, các cột trực chuẩn.

Tính hệ số Ridge và Lasso.

Ridge: $\mathbf{w} = (1.5,\ 0.25,\ -0.6)$

Lasso: $\mathbf{w} = (2,\ 0,\ -0.2)$

Lasso loại đặc trưng thứ hai và vừa chọn đặc trưng, vừa ước lượng.

Coordinate descent

Lần lượt tối ưu từng w_j; mỗi bước là một phép soft-thresholding.

```
for j in range(len(w)):
    r_j = yc - Ac @ w + Ac[:, j] * w[j]
    w[j] = soft(Ac[:, j] @ r_j, lam) / col_sq[j]
```

Với $\lambda = 8$ trên dữ liệu căn hộ:

KẾT QUẢ

```
giữ lại các cột: [0 1]  hệ số: [ 1.037 -0.408]
R2 test: 0.891
```

Đúng diện tích và khoảng cách. Không ai nói cho nó biết cột nào là rác.

05

Chọn mức phạt và chuẩn hóa

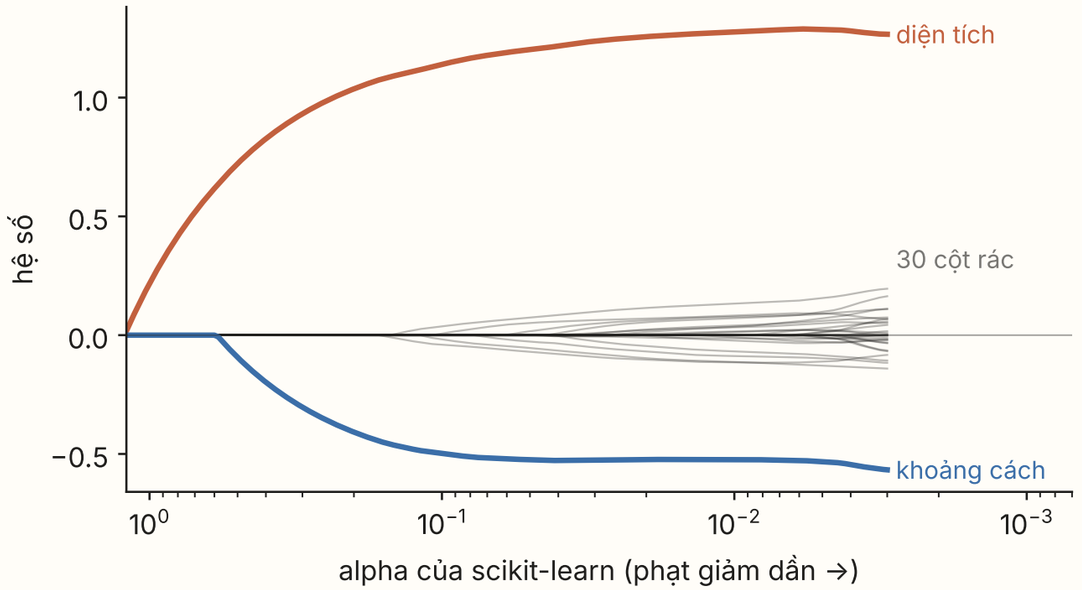
Cross-validation trên lưới log

```
ridge = RidgeCV(alphas=np.logspace(-2, 3, 11))
lasso = LassoCV(cv=5, random_state=0)
```

KẾT QUẢ

```
Ridge: alpha = 3.16   R2 test = 0.837
Lasso: alpha = 0.061   giữ 8 cột,   R2 test = 0.926
```

Cross-validation chọn cho **dự đoán**, không nhằm tìm đúng tập đặc trưng thật.



Regularization path: cột rác về 0 trước, hai cột thật trụ lại.

Chuẩn hóa trước khi phạt

Đổi khoảng cách từ km sang m: hệ số nhỏ đi 1000 lần, khoản phạt w^2 nhỏ đi 10^6 lần.

KẾT QUẢ

```
khoảng cách theo km: hệ số quy về mỗi km = -0.058
khoảng cách theo  m: hệ số quy về mỗi km = -0.175
```

Cùng dữ liệu, cùng λ, chỉ đổi đơn vị.

Mức phạt phụ thuộc đơn vị, không phụ thuộc mức quan trọng.

`make_pipeline(StandardScaler(), Ridge())` để cross-validation chuẩn hóa đúng trên từng fold.

HỎI NHANH

`LogisticRegression(C=0.01)` so với `LogisticRegression(C=100)`:

A `C=0.01` phạt mạnh hơn, trọng số nhỏ hơn

B `C=0.01` phạt yếu hơn, trọng số lớn hơn

C Hai mô hình như nhau

D `C` là số vòng lặp

Elastic Net

$$\lambda \left(\rho \|\mathbf{w}\|_1 + \frac{1-\rho}{2} \|\mathbf{w}\|_2^2 \right)$$

Thưa như Lasso, nhưng giữ được cả nhóm đặc trưng tương quan.

$\rho = 1$: Lasso · $\rho = 0$: Ridge · trong scikit-learn, ρ là `l1_ratio`

Tên gọi trong scikit-learn

Lớp	Hàm mất mát	Tham số phạt
`Ridge`	$\sum r_i^2 + \alpha \lVert \mathbf{w} \rVert_2^2$	`alpha` $= \lambda$
`Lasso`, `ElasticNet`	$\frac{1}{2n} \sum r_i^2 + \alpha \lVert \mathbf{w} \rVert_1$	`alpha` $= \lambda / n$
`LogisticRegression`, `SVC`		`C` tỉ lệ nghịch với λ

Chép `alpha` từ `Ridge` sang `Lasso` là sai thang đo. `C` nhỏ là phạt mạnh.

Regularization ở khắp nơi

- C trong logistic regression (2.3) và SVM (2.8).
- Độ sâu tối đa, số mẫu tối thiểu ở lá của decision tree (2.5).
- Phạt L1, L2 trên giá trị lá trong XGBoost, LightGBM (2.7).
- Weight decay, dropout, early stopping trong mạng neural (3.6).

Khi đi thi

- **Nhiều đặc trưng thưa** (one-hot, TF-IDF): mô hình tuyến tính có phạt L2 là baseline mạnh và rất nhanh.
- **Nghi có cột rác**: chạy Lasso để xem cột nào sống sót.
- **Ít mẫu, nhiều đặc trưng**: regularization là bắt buộc.
- **Dò** `alpha`**,** `C` **trên thang log**, chuẩn hóa trong pipeline.

Tóm tắt

- Cực tiểu lỗi cộng phạt độ lớn trọng số; λ cân bằng bias và variance; không phạt b.
- Ridge co đều, có nghiệm đóng, ổn định khi đặc trưng tương quan.
- Lasso cắt hệ số nhỏ về đúng 0, nên chọn được đặc trưng.
- Chuẩn hóa trước khi phạt; chọn λ bằng cross-validation trên lưới log.

Sau giờ học

Làm **10 câu kiểm tra cuối bài** trên trang bài học.

Chạy notebook của bài: tăng số cột rác lên 100, xem Ridge và Lasso thay đổi thế nào.